前言

互联网的飞速发展伴随着海量信息的产生，而海量信息的背后对应的则是海量数据。如何从这些海量数据中获取有价值的信息来供人们学习和工作使用，这就不得不用到大数据挖掘和分析技术。数据分析作为大数据技术的核心一环，其重要性不言而喻。

在数据分析领域，Python语言以其简单易用，并提供了优秀、好用的第三方库和数据分析的完整框架而深受数据分析人员的青睐。可以说，Python已经当仁不让地成为了数据分析人员的一把“利器”。程序员想要进入数据分析行业，首先要掌握Python数据分析技术，只有这样才能在严峻的就业市场中具有较强的竞争力。

目前图书市场上关于Python数据分析的图书主要是几本翻译图书，其定位相对高端，而且翻译质量参差不齐，案例数据不方便下载，阅读难度系数较大，初学者不容易上手，故不适合初学者学习；而国内的几本原创Python数据分析图书质量也良莠不齐，不成系统，也不适合初学者阅读。可以说，图书市场上还鲜见一本通俗易懂且适合“小白”阅读的Python数据分析入门图书，基于此，笔者编写了本书。本书从Python数据分析的基础知识入手讲解，然后结合大量的数据分析案例，系统地介绍了Python数据分析的方法和流程，手把手带领读者掌握Python数据分析的相关知识，并提高读者的项目实践能力。

本书特色

1．视频教学，高效、直观

为了便于读者高效、直观地学习，笔者专门为本书的重点内容录制了配套教学视频，读者可以一边看书，一边结合教学视频进行学习，以取得更好的学习效果。

2．内容全面，讲解系统

本书不但全面介绍了从Numpy到pandas，从matplotlib到pyecharts的数据分析必学技术，而且还系统地讲解了从数据读取到数据清洗，从数据处理到数据可视化的详细步骤。

3．给出了数据分析环境的安装和配置步骤

本书详细介绍了Python数据分析集成环境Anaconda的安装步骤和使用方法，可以大大降低初学者学习Python数据分析的门槛，从而让读者快速跨进Python数据分析的大门。

4．详细介绍了数据分析的流程

本书从一开始便对数据分析的流程进行了详细介绍，而且在讲解中结合了多个实用性很强的数据分析项目案例，带领读者掌握Python数据分析的相关知识，以解决实际工作中的数据分析问题。

5．提供了9个有较高应用价值的项目案例，有很强的实用性

本书提供了9个实用性很强的数据分析项目案例，这些案例从不同的分析角度切入进行讲解，具有较高的应用价值。读者通过实际操练，可以更加透彻地理解数据分析的相关知识。

6．提供教学PPT，方便教学和学习

笔者专门为本书制作了专业的教学PPT，以方便相关院校的教学人员授课时使用；读者也可以通过教学PPT，提纲挈领地掌握书中的内容脉络。

本书内容

第1章　Python环境搭建与使用

本章介绍了如何搭建和使用Python数据分析环境，并介绍了如何使用Jupyter Notebook进行数据分析编程。

第2章　NumPy入门和实战

本章首先介绍了Numpy的基本数据结构——多维数组；然后介绍了多维数组的创建和基本属性、数组的切片和索引方法，以及数组的运算与存取；最后通过综合案例，演示了如何实现图像的变换功能。

第3章　pandas入门和实战

本章首先介绍了pandas中两种基础数据结构的创建和使用方法；然后详细讲解了DataFrame的选取和操作，同时介绍了其算术运算、函数的使用和pandas的可视化方法；最后结合案例，介绍了数据分析流程。

第4章　外部数据的读取与存储

本章主要介绍了如何利用pandas库读取外部数据为DataFrame数据格式，并介绍了通过Python进行数据处理后如何将DataFrame类数据存储到相应的外部数据文件中。

第5章　数据清洗与整理

本章主要介绍了如何使用pandas进行多源数据的清洗和整理，并给出了针对多源数据的合并和连接方法，以及数据的重塑方法，最后通过一个综合案例演示了数据分析中的数据清洗过程。

第6章　数据分组与聚合

本章涵盖的主要内容有：GroupBy的原理和使用方法；聚合函数的使用；分组运算中transform和apply方法的使用；通过pandas创建数据透视表；通过综合案例，巩固数据分组统计的使用。

第7章　matplotlib可视化

本章涵盖的主要内容有：利用matplotlib进行图表绘制；学会使用自定义设置，个性化绘制图表；通过综合案例，巩固matplotlib可视化的方法和技巧。

第8章　seaborn可视化

本章涵盖的主要内容有：使用seaborn绘图；学会seaborn样式和分布图绘制；通过综合案例泰坦尼克号的生还者数据，巩固seaborn的可视化方法和技巧。

第9章　pyecharts可视化

本章涵盖的主要内容有：安装pyecharts库；学会使用pyecharts库绘制基本图表；学会绘制其他图表；通过综合案例，巩固pyecharts的绘制方法和技巧。

第10章　时间序列

本章涵盖的主要内容有：时间序列的构造和使用方法；时间序列的频率转换与重采样；通过综合案例，巩固时间序列数据的处理与分析方法。

第11章　综合案例——网站日志分析

本章通过一个综合案例，介绍了如何通过Python的第三方库解析网站日志；如何利用pandas对网站日志数据进行预处理；结合前面介绍的数据分析和数据可视化技术对网站日志数据进行分析。

本书配套资源获取方式

本书提供以下配套资源：

· 本书配套教学视频；

· 超值电子书（地图绘制技术）；

· 本书相关素材文件；

· 本书源代码文件；

· 本书教学PPT。

这些配套资源需要读者自行下载。请登录机械工业出版社华章公司网站www.hzbook.com，在该网站上搜索到本书，然后单击“资料下载”按钮即可找到“配书资源”下载链接。

适合阅读本书的读者

· 数据分析初学者；

· 数据分析爱好者；

· 数据分析从业人员；

· 数据分析培训学员；

· 高校相关专业的学生。

本书由罗攀主笔编写，蒋仟、陈瑞滕和潘丹三位小伙伴也参与了部分章节的编写工作，在此对他们表示特别的感谢！

由于作者水平所限，加之写作时间有限，书中可能还存在一些疏漏和不足之处，敬请各位读者斧正。联系我们请发电子邮件到hzbook2017@163.com。

罗攀

第1章　Python环境搭建与使用

Python语言在数据读取、数据处理、数据可视化和数据挖掘等方面都有极其广泛的应用。本章将讲解如何搭建和使用Python数据科学环境，并学习使用Jupyter Notebook进行编程。

下面给出本章涉及的知识点与学习目标。

· Anaconda安装和使用：学会数据科学环境的搭建和使用。

· Jupyter Notebook使用：学会Jupyter Notebook的基本操作和Python程序的编写。

1.1　Anaconda的安装和使用

“工欲善其事，必先利其器”。本节将介绍Python数据科学环境（Anaconda）的安装和使用方法。

1.1.1　Anaconda的安装

Anaconda是一个集成的Python数据科学环境。简单地说，Anaconda除了有Python外，还安装了180多个用于数据分析的第三方库，而且可以使用conda命令安装第三方库和创建多个环境。相对于只安装Python而言，安装Anaconda避免了安装第三方库的麻烦。

注意：因为许多与数据分析相关的Python第三方库依赖性强，不容易安装，建议使用Anaconda。

（1）打开浏览器，进入清华大学Anaconda开源镜像源（https://mirror.tuna.tsinghua.edu.cn/help/anaconda/），单击链接进行下载，如图1.1所示。

注意：由于网络限制，这里没有介绍如何在官网下载，而是选择通过镜像下载。

（2）通过下拉列表选择最新的Anaconda版本，读者可根据计算机操作系统进行下载，如图1.2所示。

注意：Anaconda 3为Python 3的版本。本书以Windows 64位操作系统为例。

图1.1　安装步骤1

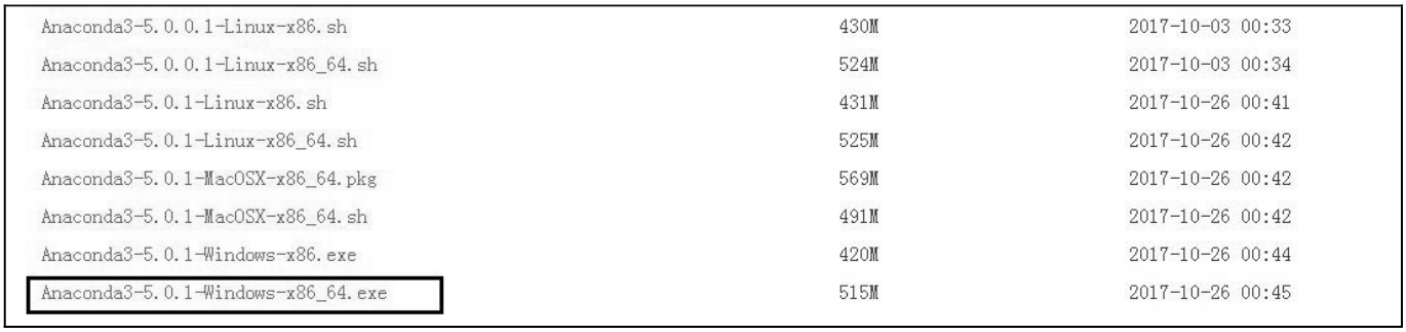

图1.2　安装步骤2

（3）双击打开下载好的程序，在欢迎界面单击Next按钮进入下一步，然后单击I Agree按钮同意进行安装，此时会要求读者选择使用的用户类型，读者可选择所有用户（All Users），然后单击Next按钮进入下一步，如图1.3所示。

（4）选择安装路径，建议安装到非系统盘，并安装到磁盘的根目录下，然后单击Next按钮进入下一步，如图1.4所示。

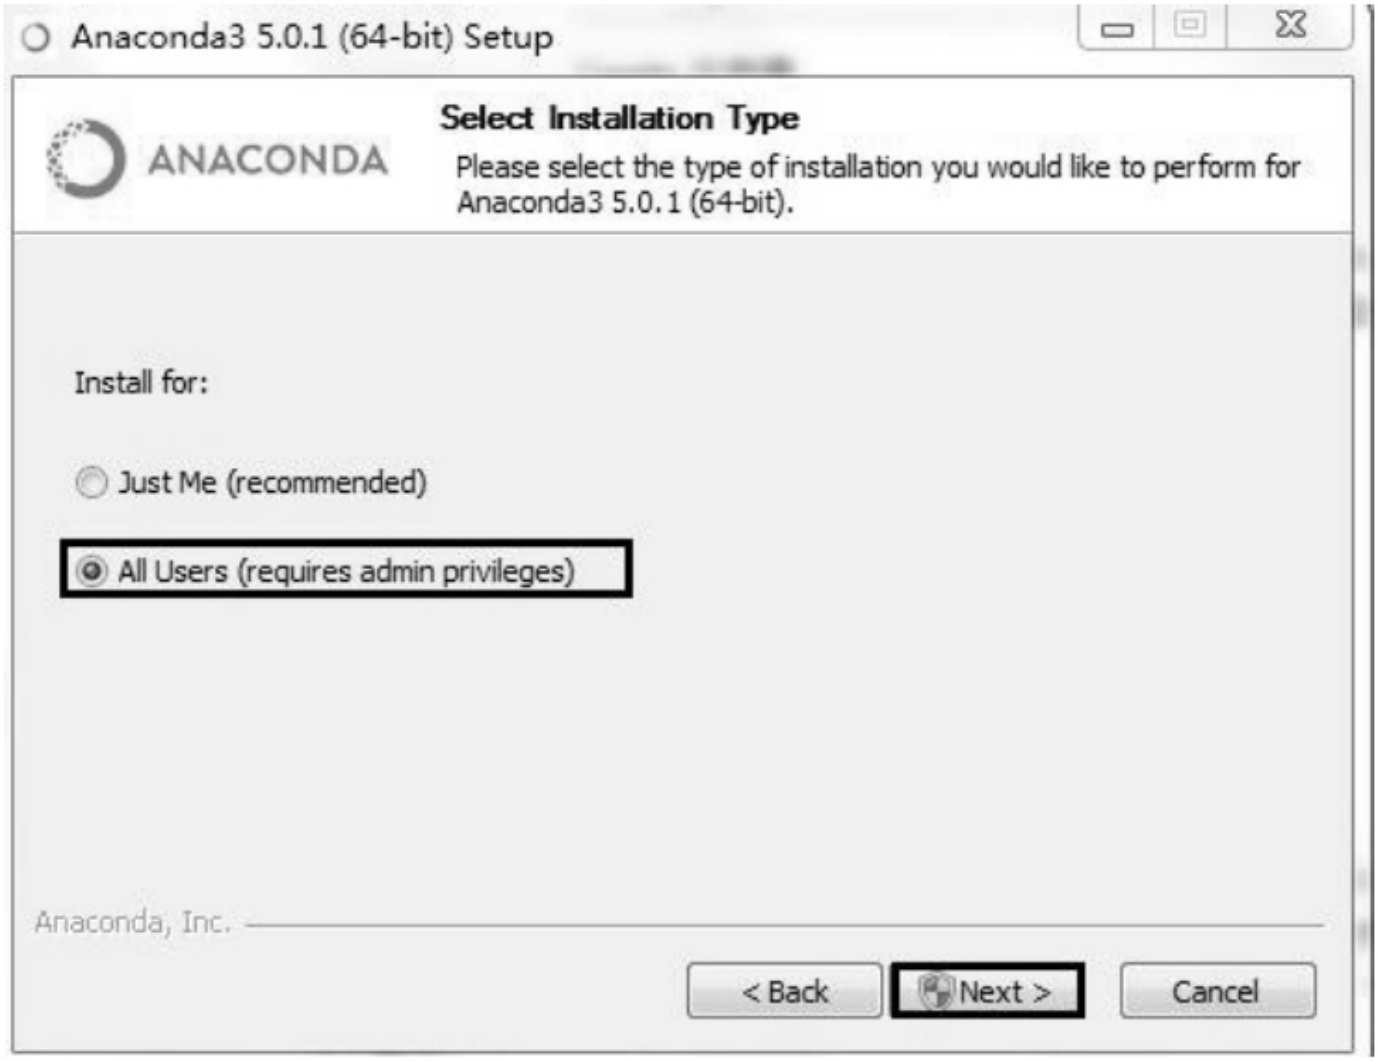
Anaconda3 5.0.1 (64-bit) Setup
ANACONDA
Select Installation Type
Please select the type of installation you would like to perform for Anaconda3 5.0.1 (64-bit).
Install for:
Just Me (recommended)
All Users (requires admin privileges)
Anaconda, Inc.
< Back
Next >
Cancel

图1.3　安装步骤3

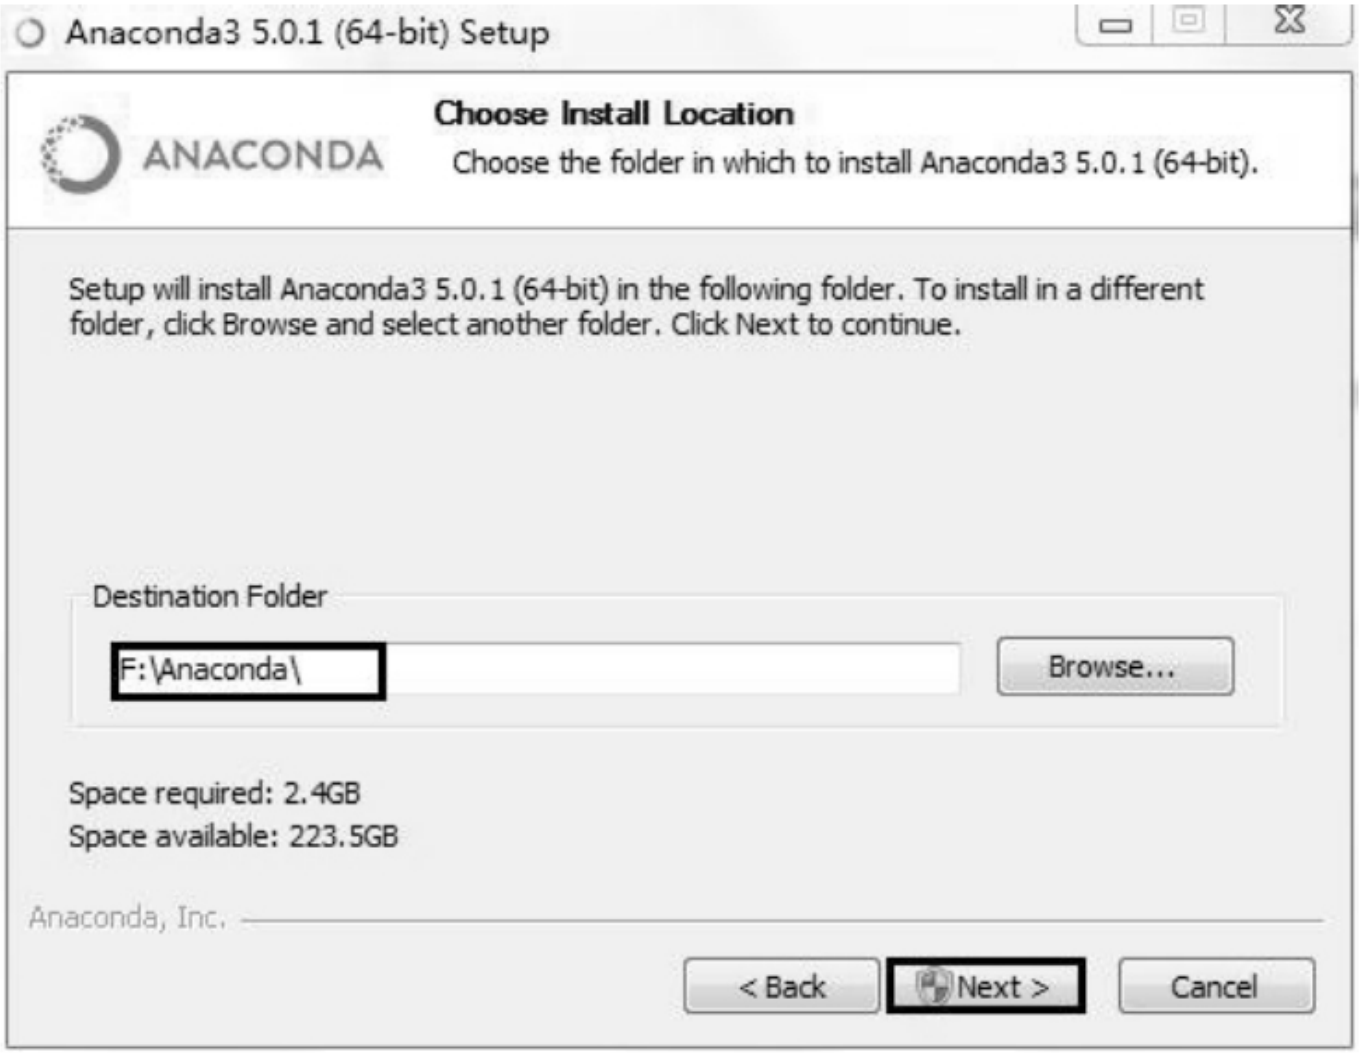

图1.4　安装步骤4

（5）在自定义选项中，勾选所有选项，单击Install按钮进行安装即可。安装完成后，单击Next按钮，再单击Finish按钮即可完成安装，如图1.5所示。

注意：第一个复选框选项是把Anaconda加入环境变量，勾选第二个复选框可以关联一些编辑器。

（6）安装完成后，在“开始”菜单栏中，选择Anaconda Prompt命令即可运行Anaconda环境，如图1.6所示。

Anaconda3 5.0.1 (64-bit) Setup
ANACONDA
Advanced Installation Options
Customize how Anaconda integrates with Windows
Advanced Options
Add Anaconda to the system PATH environment variable
Not recommended. Instead, open Anaconda with the Windows Start menu and select "Anaconda (64-bit)". This "add to PATH" option makes Anaconda get found before previously installed software, but may cause problems requiring you to uninstall and reinstall Anaconda.
Register Anaconda as the system Python 3.6
This will allow other programs, such as Python Tools for Visual Studio PyCharm, Wing IDE, PyDev, and MSI binary packages, to automatically detect Anaconda as the primary Python 3.6 on the system.
Anaconda, Inc.
< Back
Install
Cancel

图1.5　安装步骤5

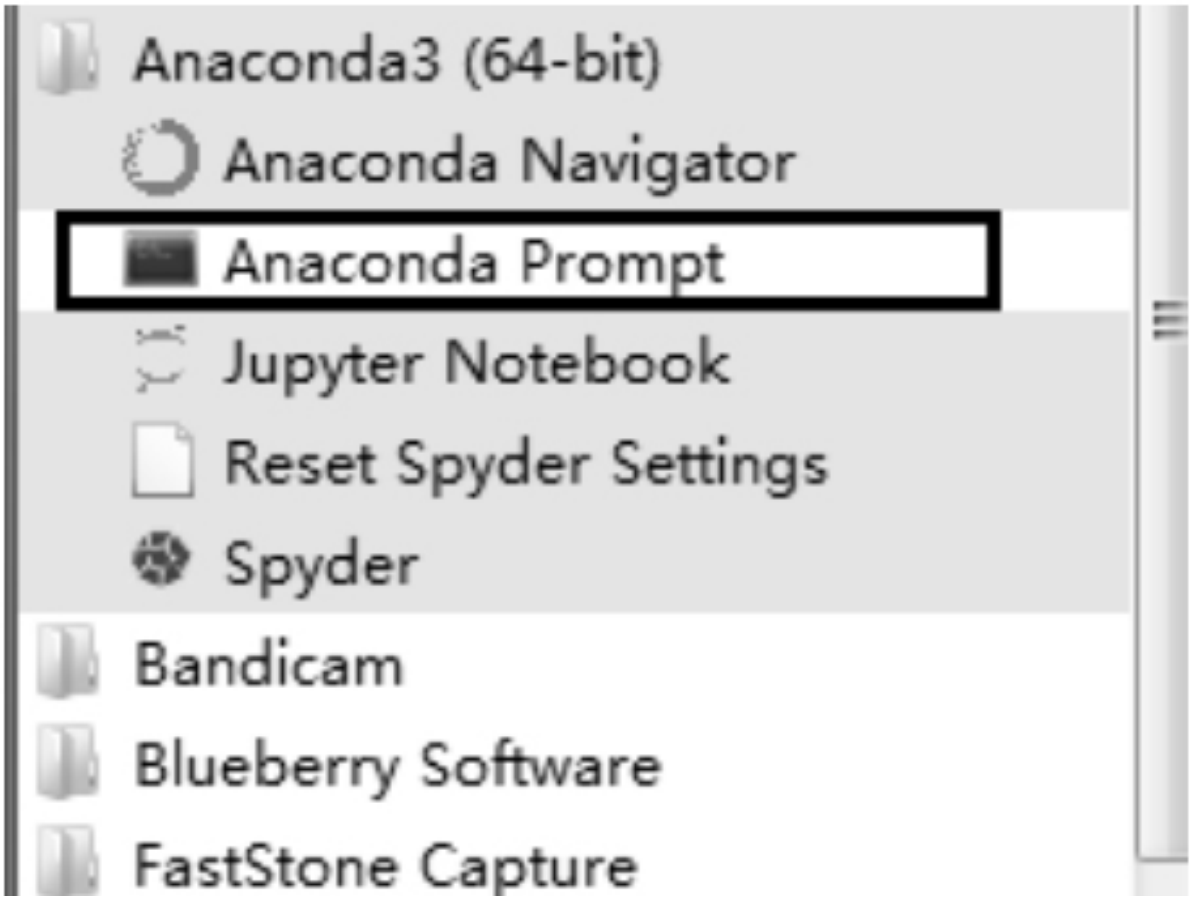
Anaconda3 (64-bit)
Anaconda Navigator
Anaconda Prompt
Jupyter Notebook
Reset Spyder Settings
Spyder
Bandicam
Blueberry Software
FastStone Capture

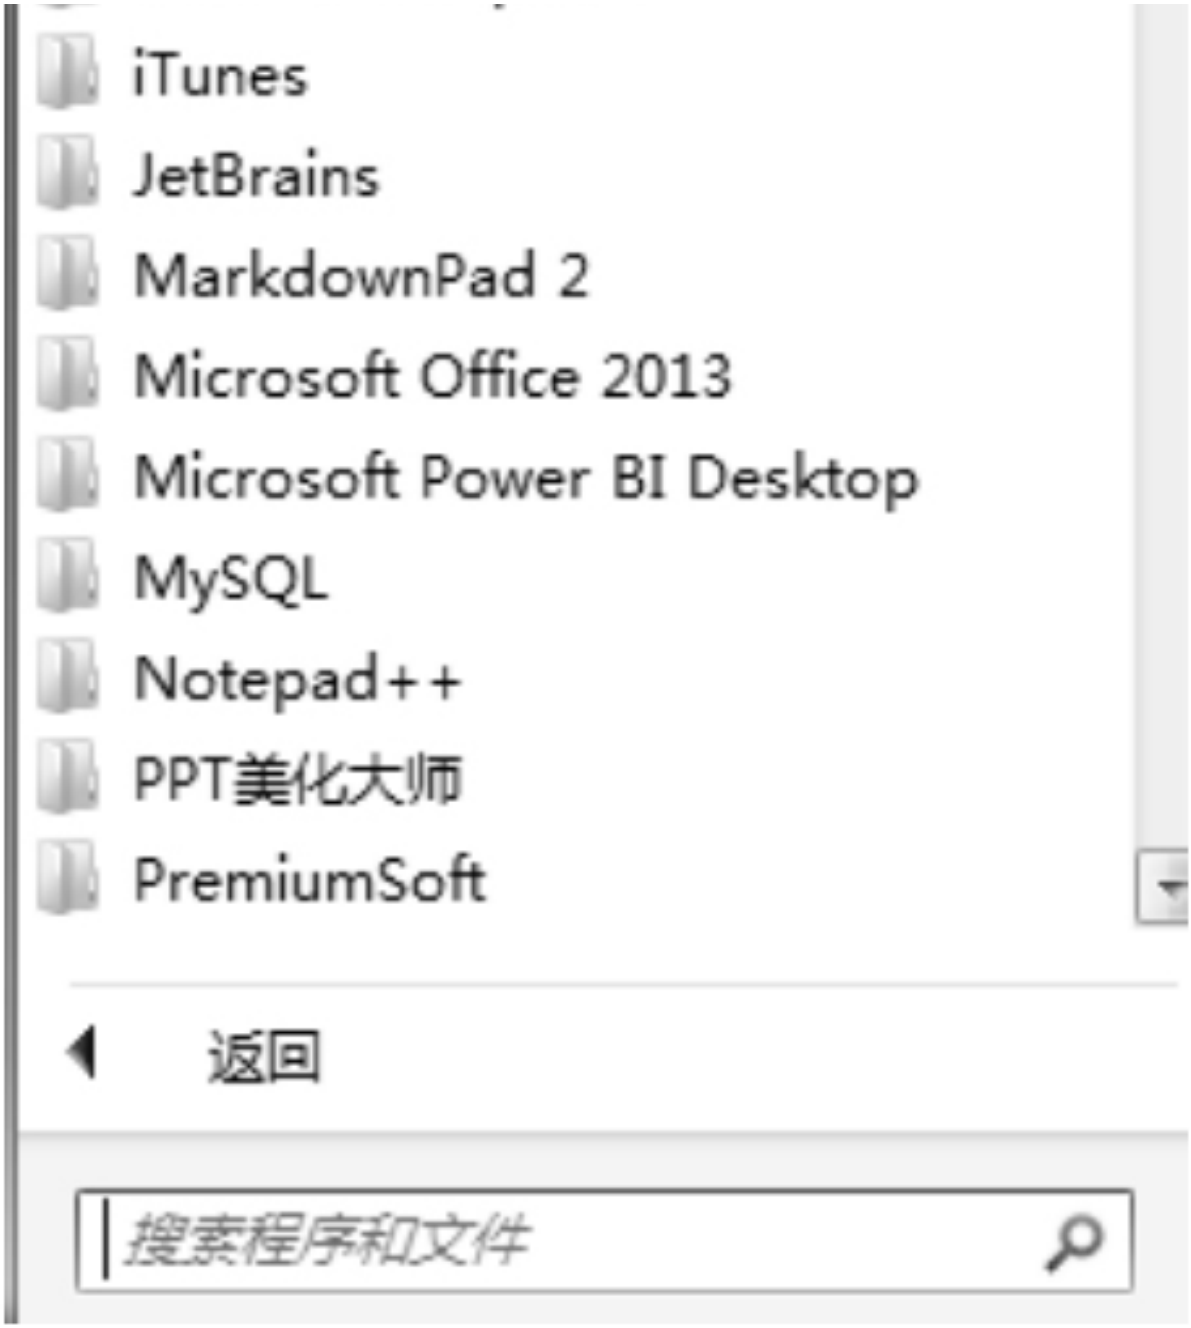

图1.6　运行Anaconda

1.1.2　Anaconda的使用

Anaconda其实是一个打包的集合，里面预装好了conda、某个版本的Python、众多包及科学计算工具等。对于Anaconda的使用，其实就是对conda的使用。conda可以理解为一个工具（或者是可执行的命令），其核心功能为第三方库（包）和环境的管理。

1．包管理

首先运行Anaconda，查看Python版本，如图1.7所示。由于这里安装的是Anaconda 3，对应的是Python 3版本。

通过conda list命令可以查看安装的包，部分结果如图1.8所示，可以看出，Anaconda集成了大量的包。

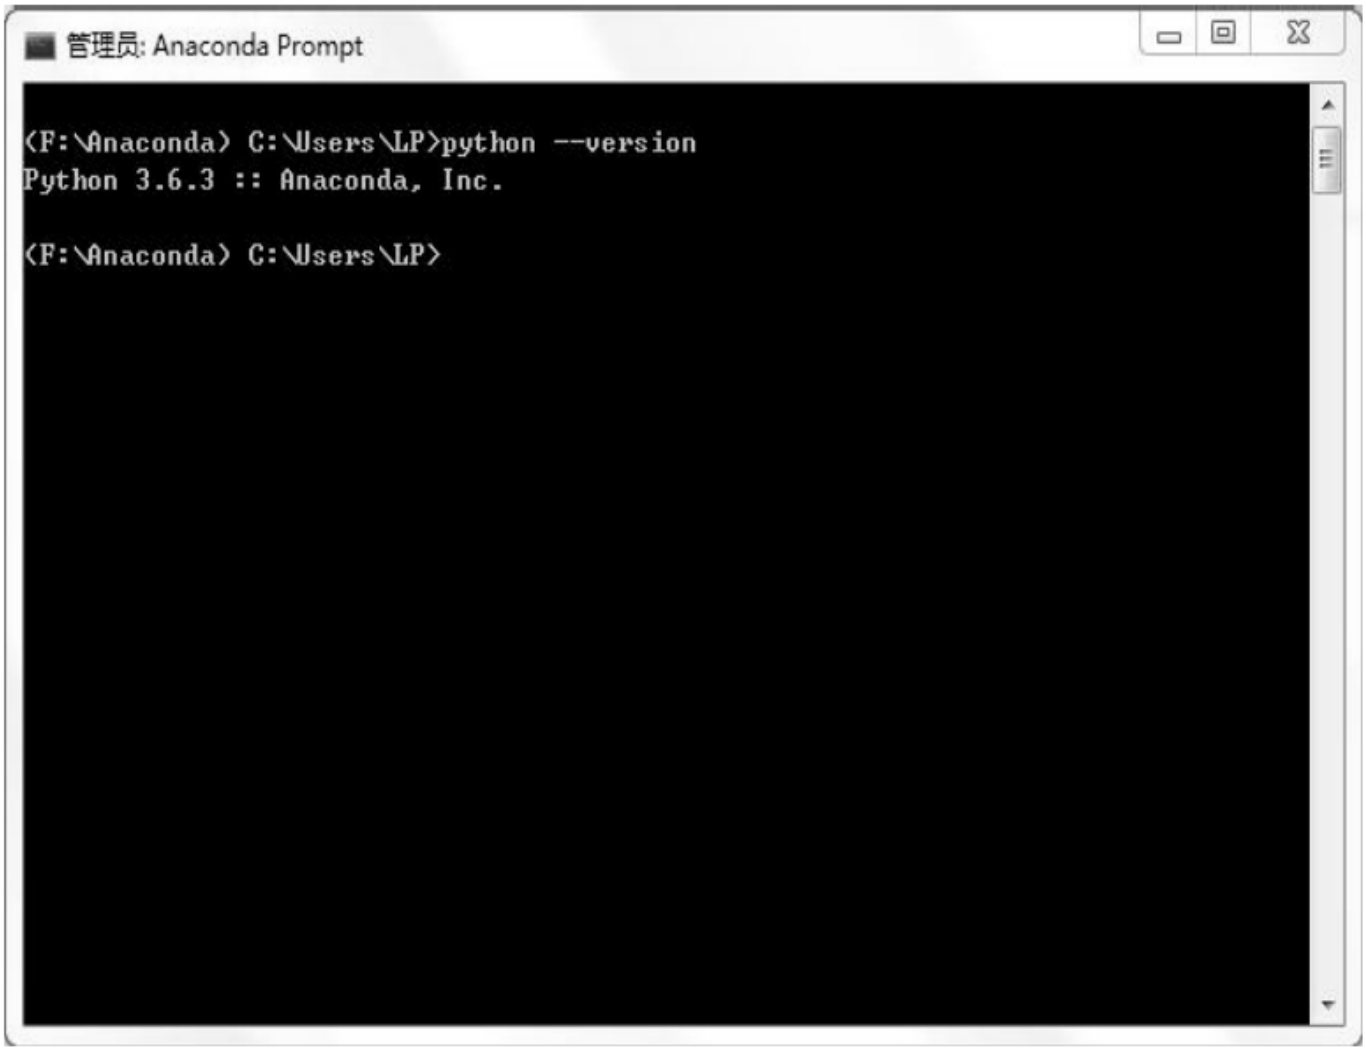

图1.7　查看Python版本

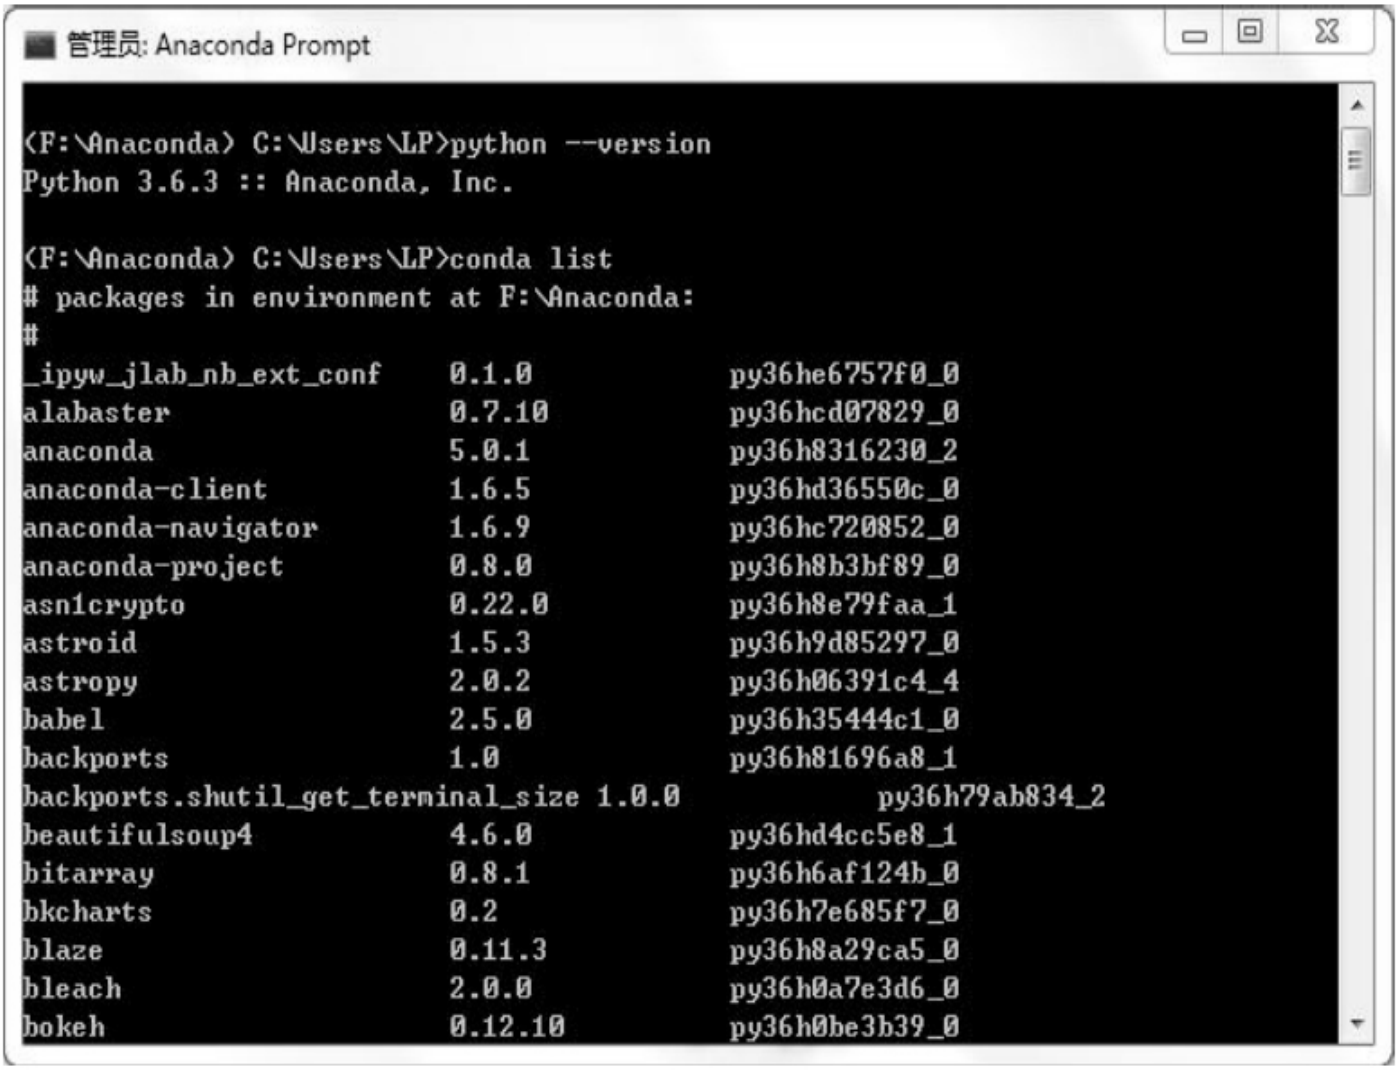

图1.8 查看包

通过conda命令可以进行包的安装和卸载，也可以通过pip命令进行包的安装和下载。具体使用方法如下：

```
conda install xxx                                    #xxx为包名称
conda remove xxx                                     #卸载包
pip install xxx
pip uninstall xxx
```

注意：建议使用conda命令安装包，在出错的情况下，再考虑使用pip命令进行安装。

2．环境管理

conda的环境管理功能允许开发者同时安装若干不同版本的Python。对于不同的项目而言，使用独立稳定的Python环境很重要，以下就是安装Python环境的conda命令。

```
conda create --name xxx python=2          #xxx为环境名称，创建了python版本为2的环境
conda create --name xxx python=3          #创建了python版本为3的环境
conda create --name xxx python=3 anaconda                                    #创建了python版本为3的环
```

这里创建一个名为data-analysis的Python环境，其是用于本书讲解Python数据分析的环境。由于数据分析需要Anaconda的原生包，这里需在conda命令末尾加上anaconda，如图1.9所示。

创建环境成功后，可通过activate data-analysis命令进入该环境中，通过deactivatedata-analysis命令退出该环境，如图1.10所示。

```
activate xxx                                         #激活环境
deactivate xxx                                       #退出环境
```

通过以下命令可以查看Anaconda的环境，方便用户进行Python环境的管理和使用，如图1.11所示。

```
conda info -envs
```

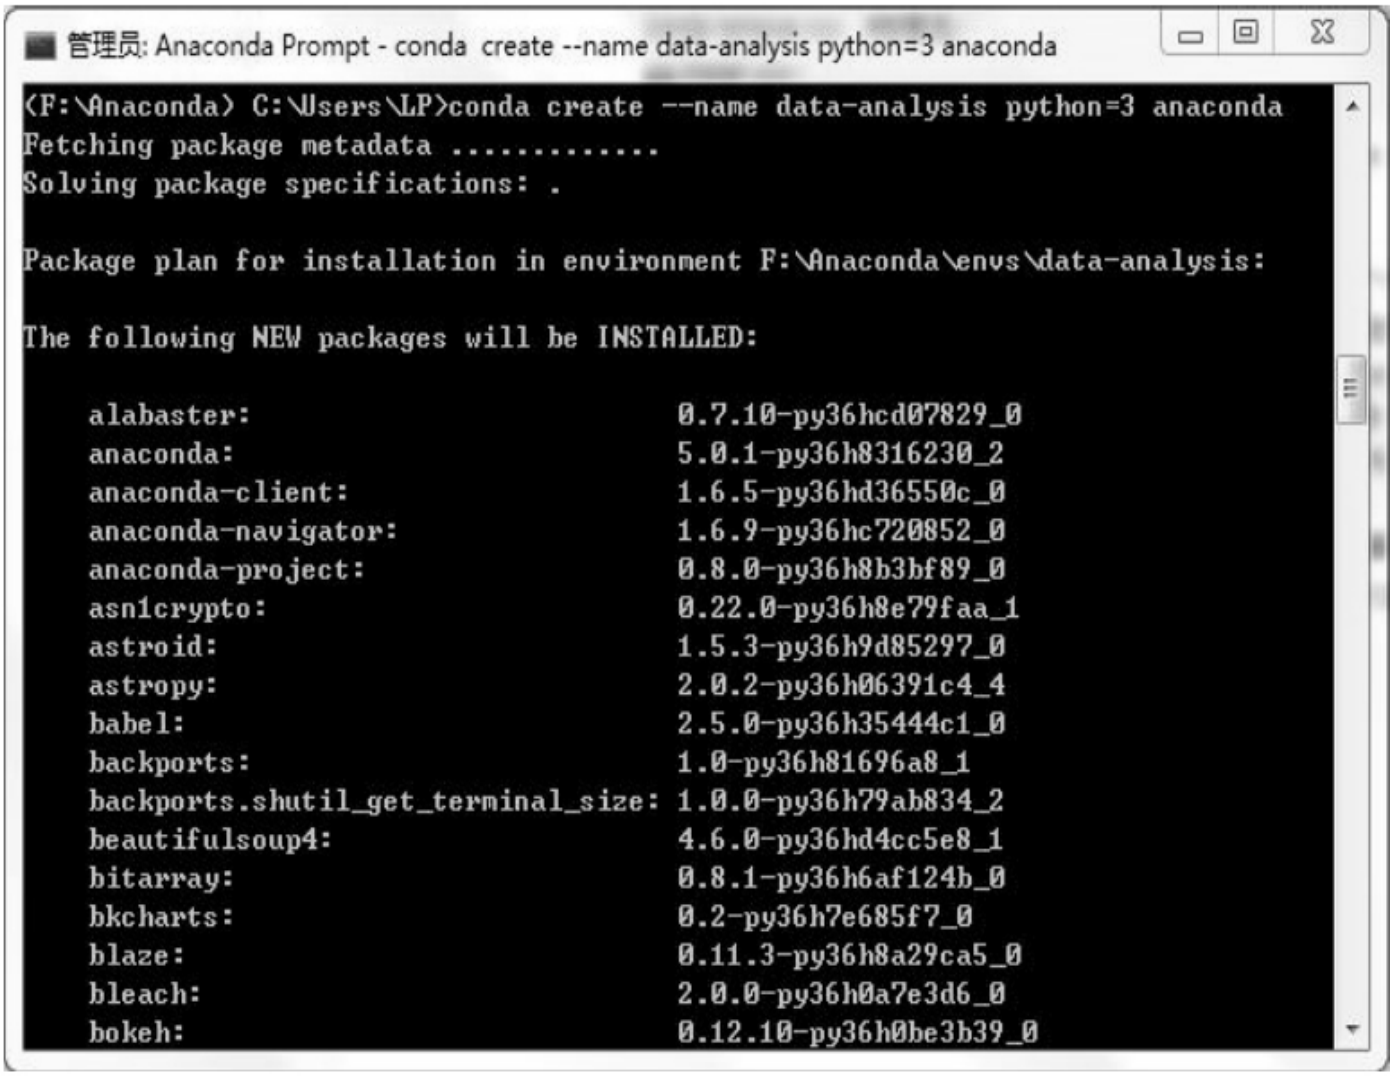

图1.9　创建Python环境

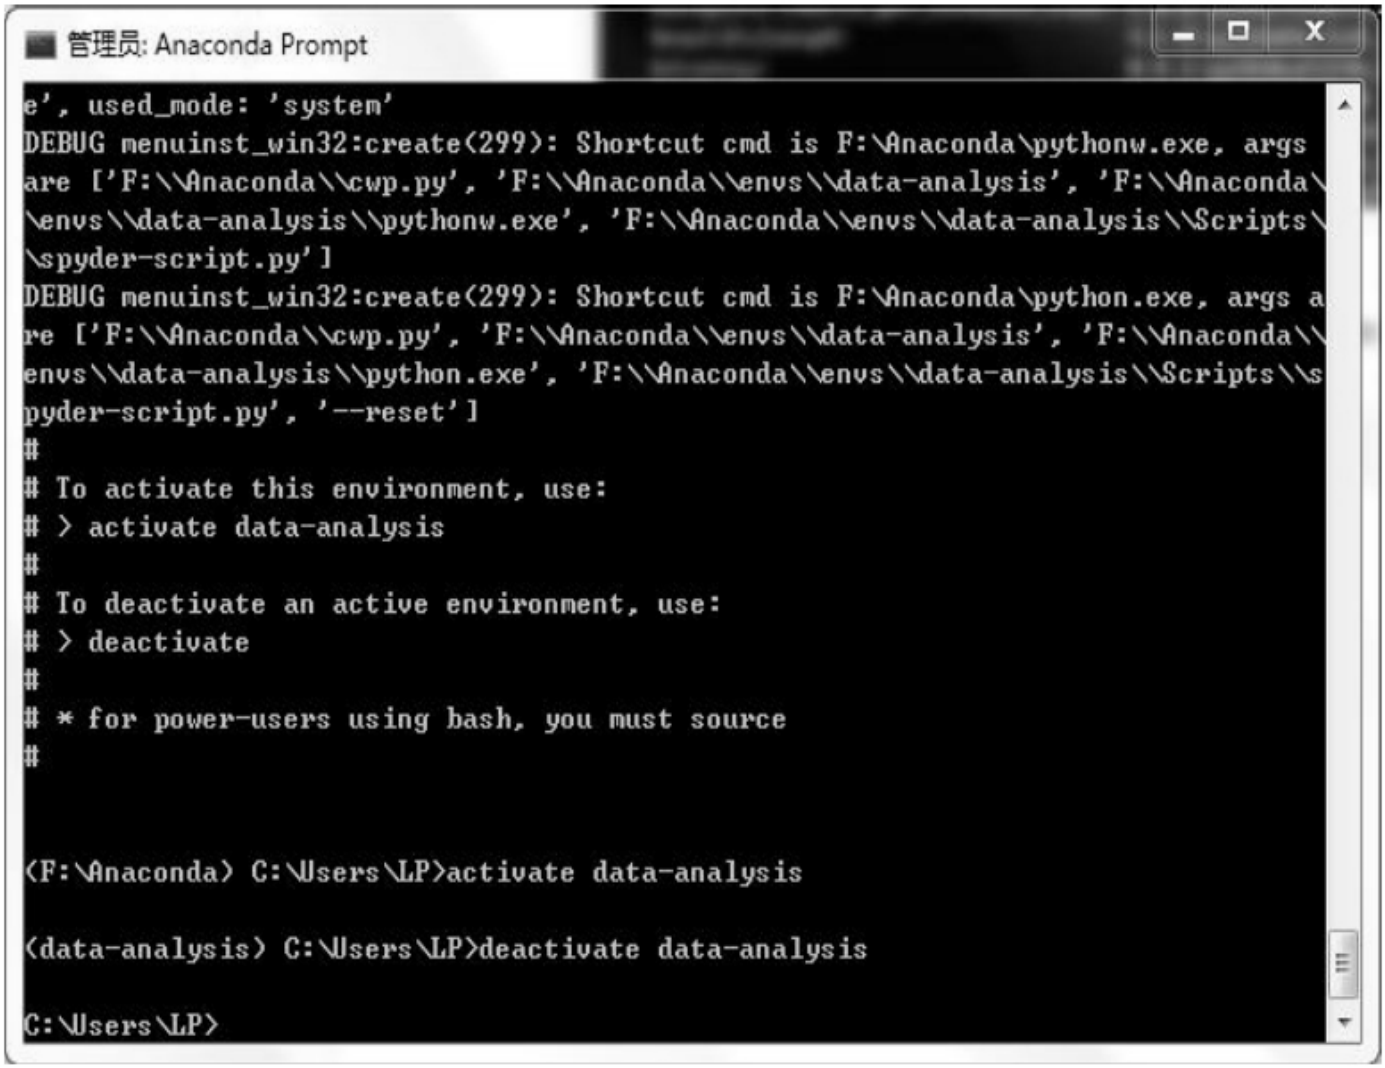

图1.10　激活和退出环境

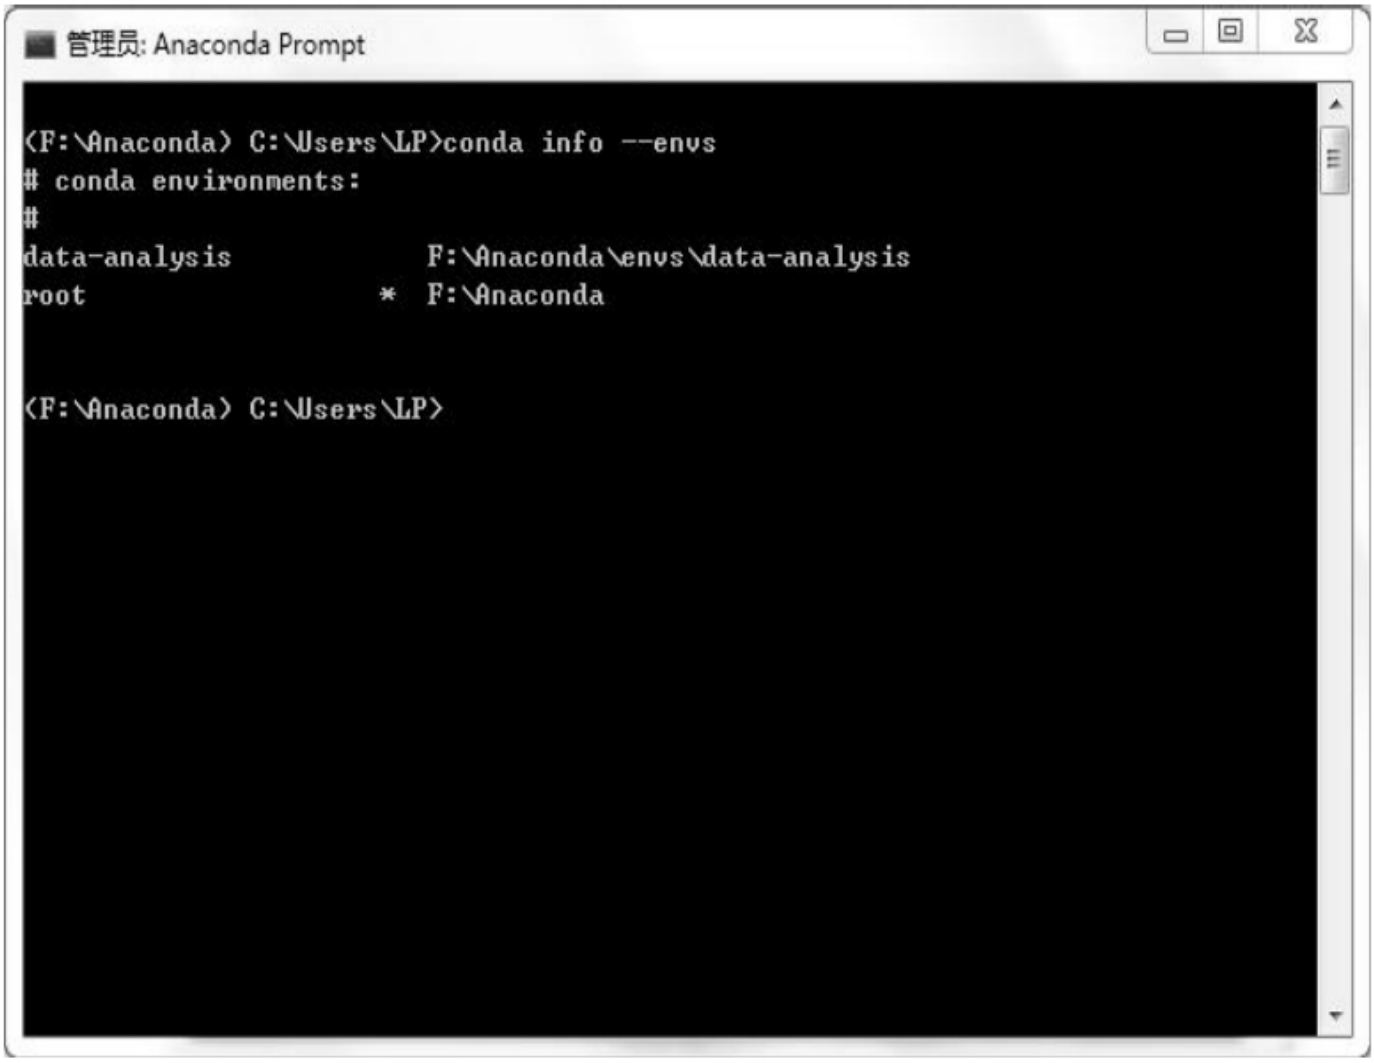

图1.11 查看环境

对于需要卸载的环境，可以通过以下命令来完成。

```
conda remove --name xxx --all                # 删除一个已有的环境
```

1.2 Jupyter Notebook的使用

Jupyter Notebook是一个互动性极好的编辑器，支持运行Python语言。本节将介绍Jupyter Notebook的使用方法。

1.2.1 更改工作空间

Jupyter Notebook是一个交互式笔记本，支持多种编程语言。由于其具有较好的操作性和交互性，Python数据分析常用到该工具。

注意：环境中自带Jupyter Notebook。如果没有使用Anaconda环境，可用pip install jupyter命令进行安装。

对于编程而言，编写的代码总是希望存储在相应创建好的文件夹中，这样方便代码的管理，读者可通过简单的命令更改工作空间。

注意：也可修改配置文件ipython_notebook_config.py，这里不做介绍。

（1）运行Anaconda，激活相应的环境，如图1.12所示。

（2）通过以下命令切换到工作空间中，如图1.13所示。

```
H:
cd H:\python数据分析\代码
```

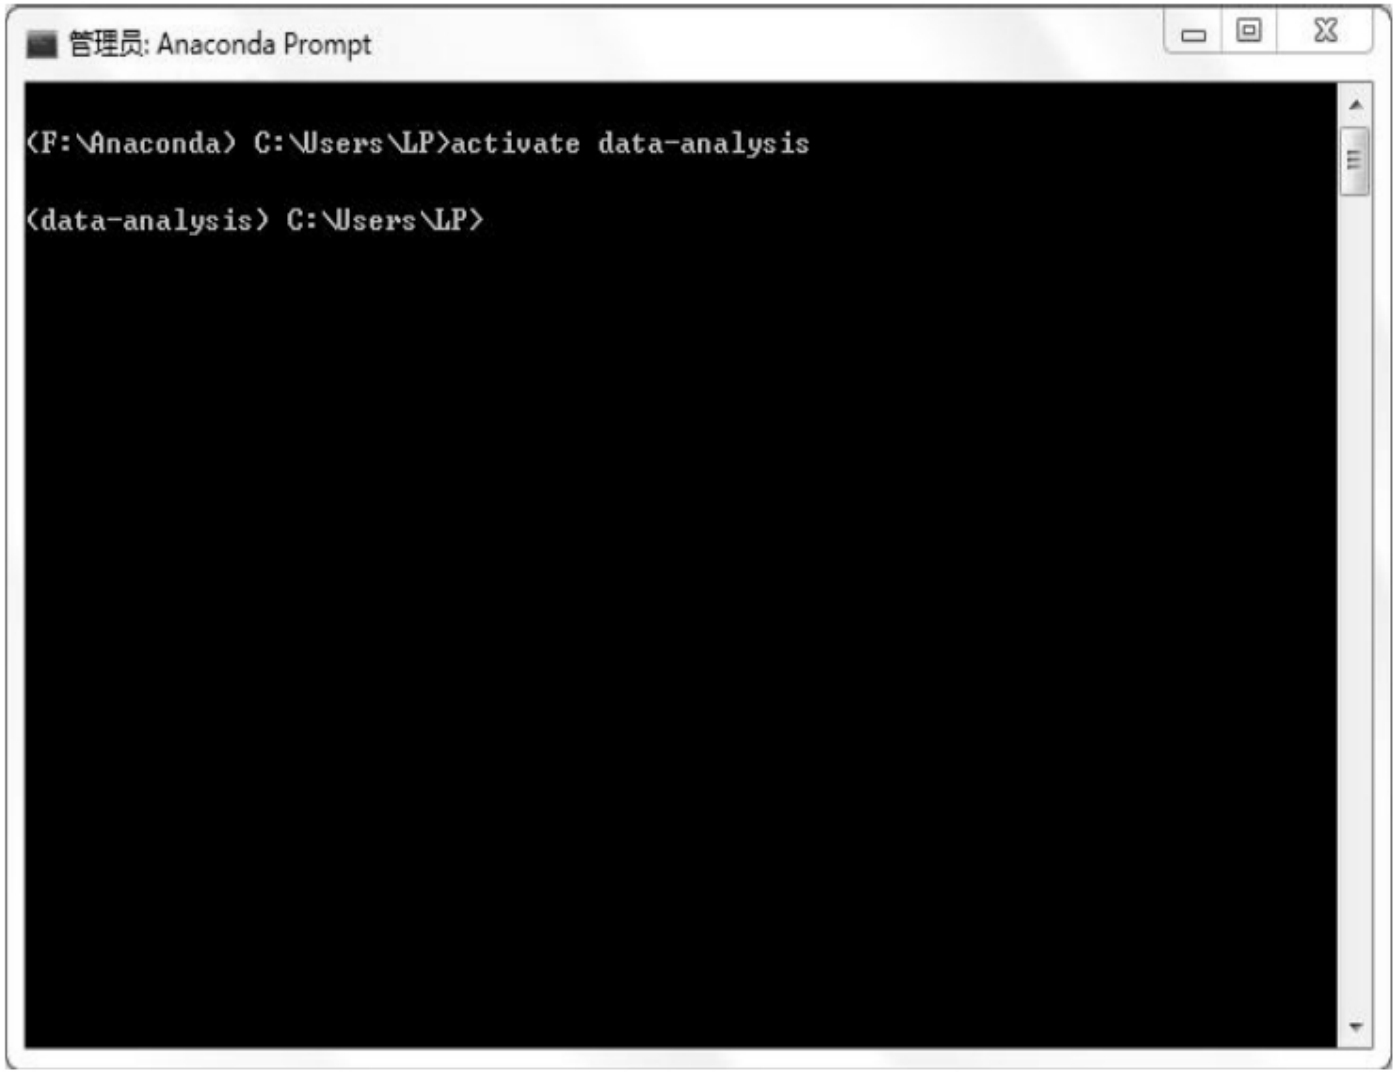
管理员: Anaconda Prompt
(F:\Anaconda) C:\Users\LP>activate data-analysis
(data-analysis) C:\Users\LP>

图1.12　激活环境

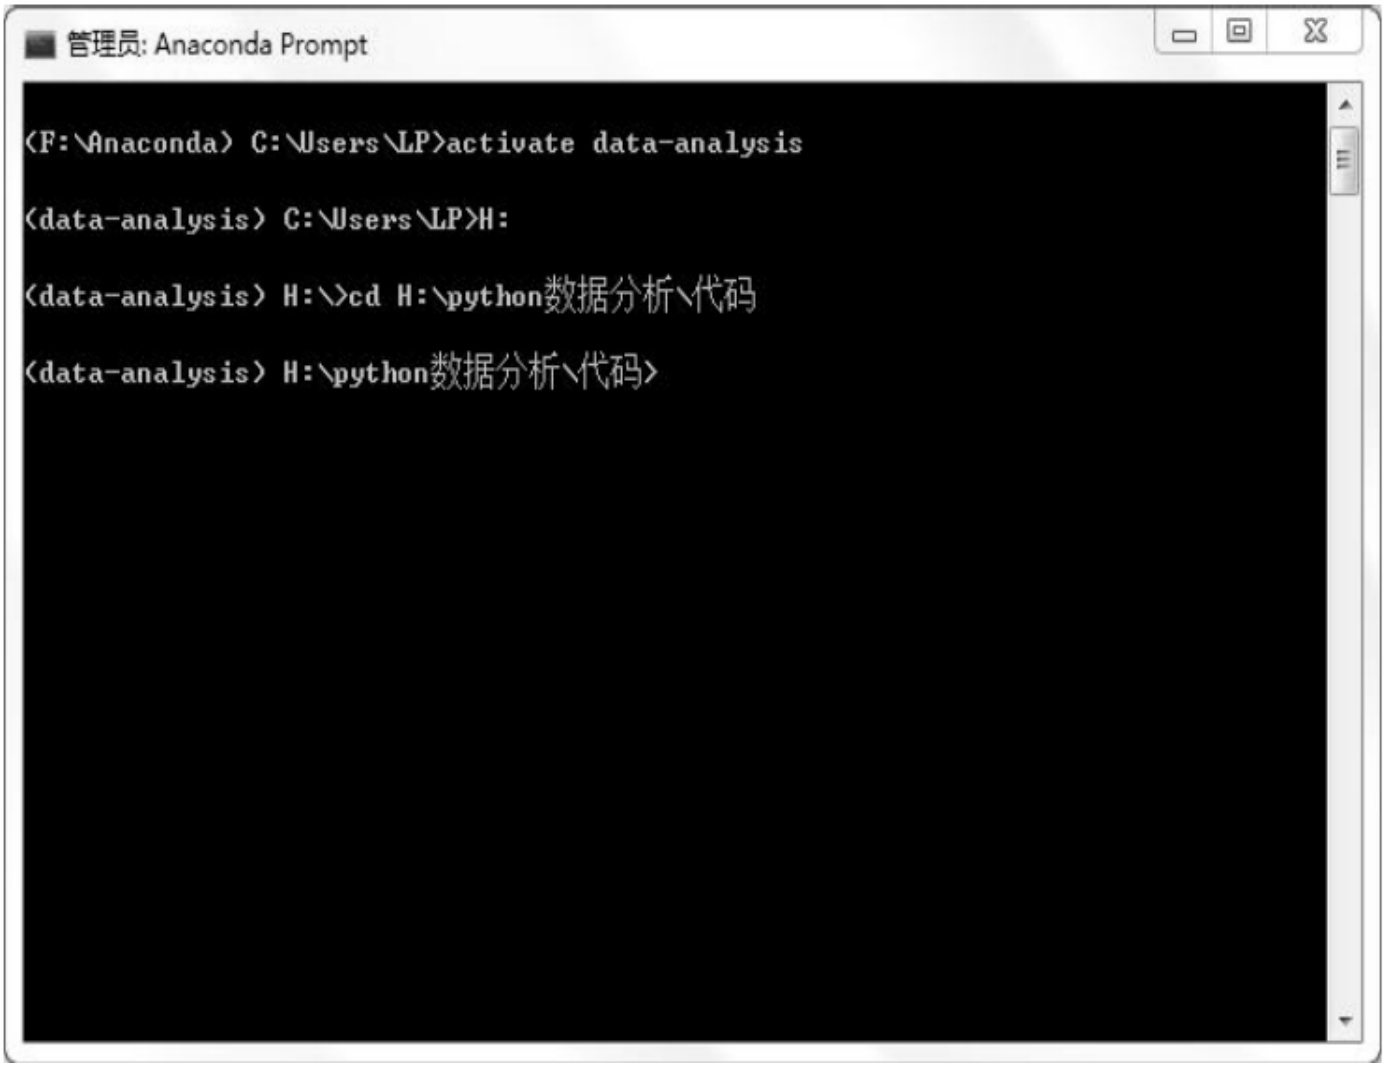

图1.13　切换工作空间

（3）最后输入jupyter notebook并回车，浏览器被弹出，并且会进入Jupyter Notebook主界面，如图1.14所示。

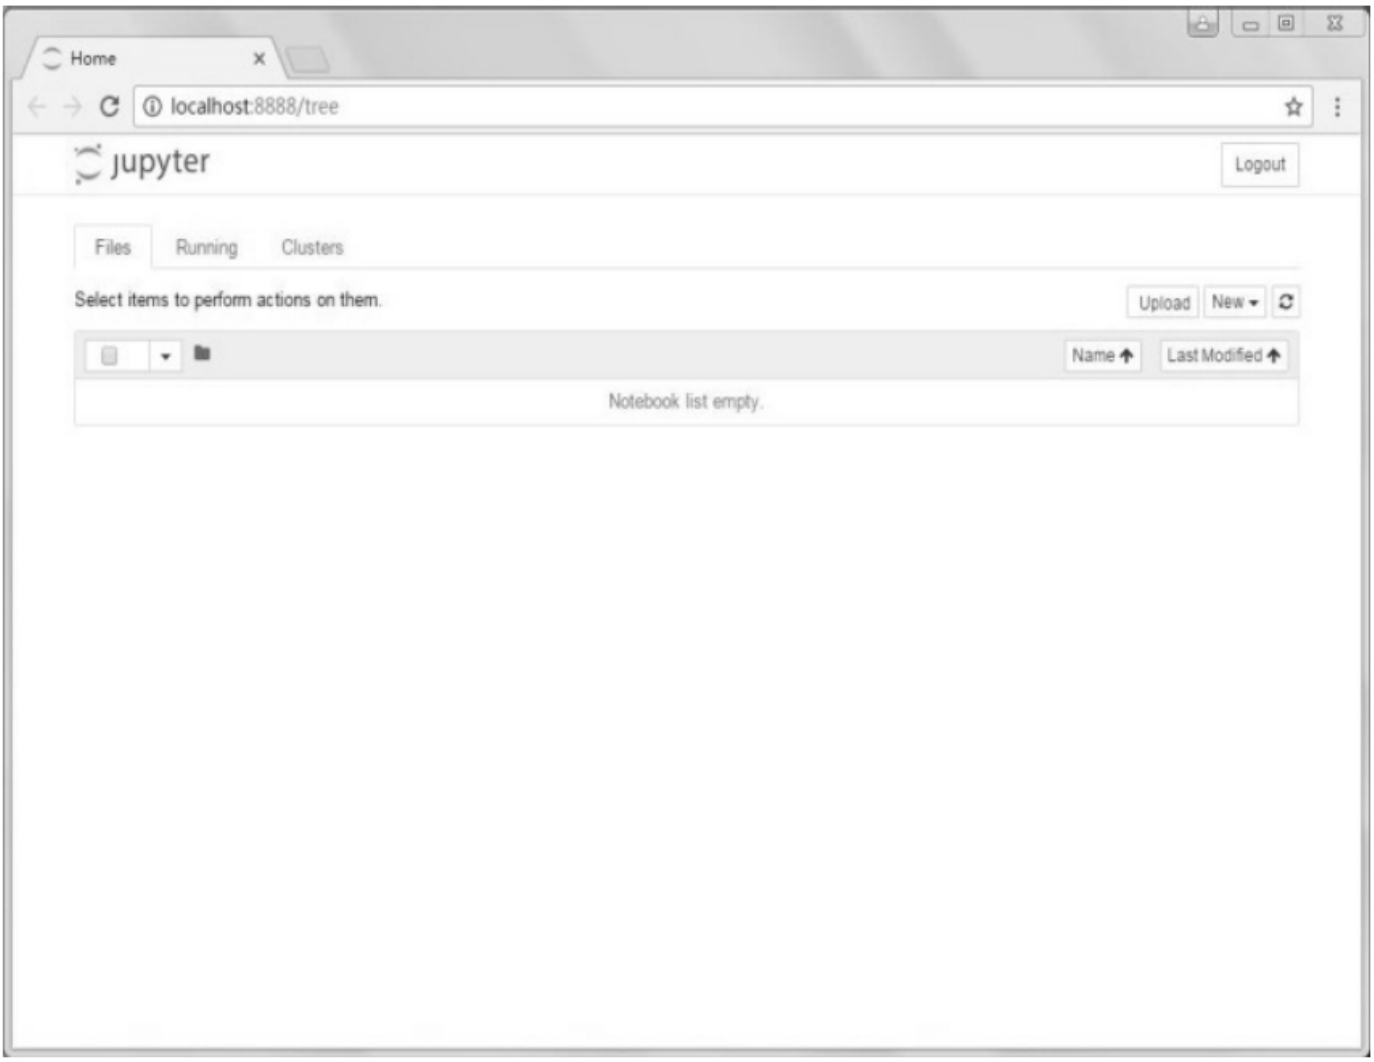

图1.14　Jupyter主界面

注意：建议使用Chrome浏览器作为计算机的默认浏览器。

1.2.2　界面介绍与使用

在Jupyter主界面中，只需选择New|Python 3命令，就可以新建一个用于编写Python程序的Notebook了，如图1.15所示。

图1.15　新建Notebook

在Notebook界面中，可以看到主要由以下几部分构成，如图1.16所示。

· Notebook名称；

· 主工具栏：提供保存、导出、运行等选项；

· 快捷按钮：常用的快捷按钮；

· 代码编辑区域。

图1.16　Notebook界面介绍

注意：本文主要讲解如何在Notebook中编写Python代码，工具不多做介绍。

代码编辑区域是由代码单元格（code cell）组成，在这种类型的单元格中输入Python代码，通过Shift+Enter组合键即可运行代码，运行后光标会被移动到一个新单元格中，如图1.17所示。

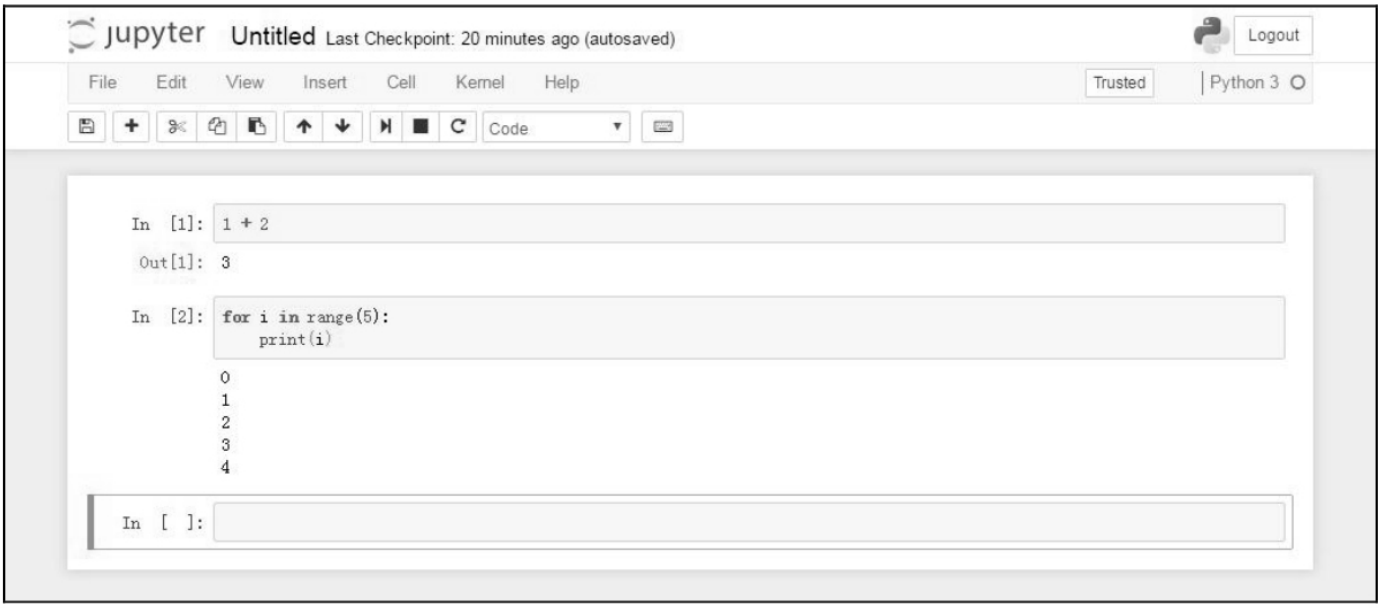

图1.17　编写Python代码

Notebook可修改运行过的代码，通过光标移动到第一个单元格，修改代码后重新运行，这时会发现前面中括号中的数字已变为3，体现出了极好的互动性和操作性，如图1.18所示。

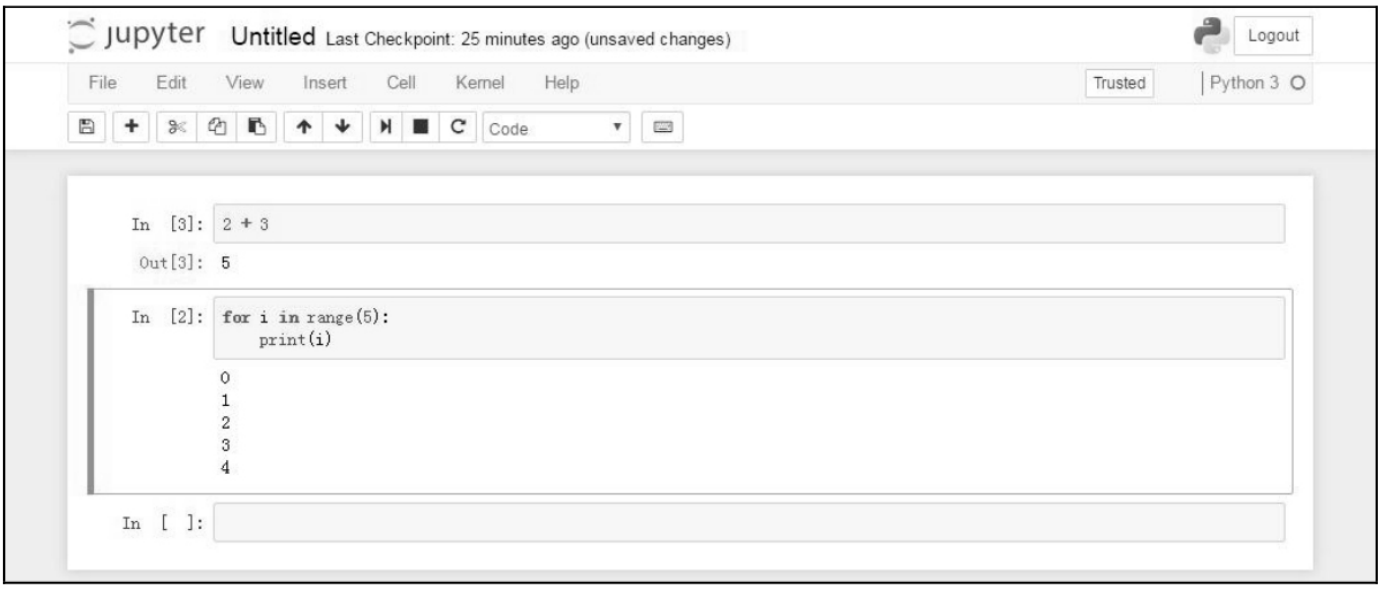

图1.18　修改代码

如图1.19所示，在Notebook中，也可以通过改变单元格类型来输入文本信息。

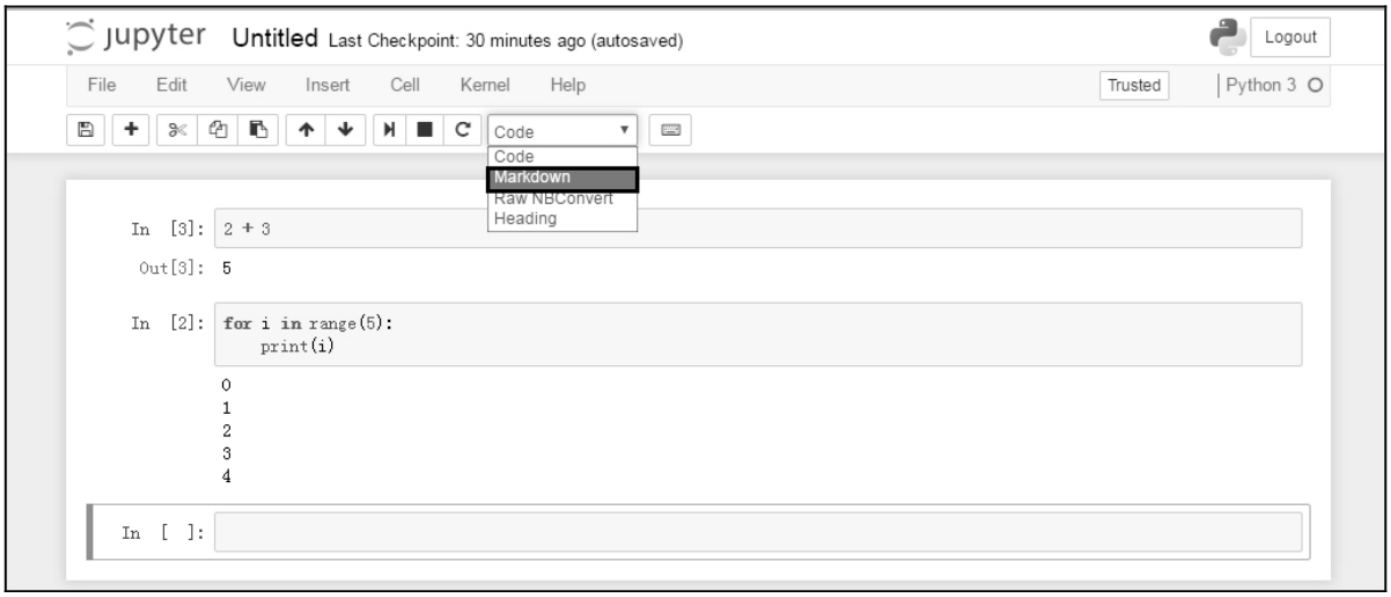

图1.19　写入文本

注意：文本格式为Markdown，读者可自行查阅该语法。

第2章　NumPy入门和实战

NumPy库是用于科学计算的一个开源Python扩充程序库，是其他数据分析包的基础包，它为Python提供了高性能数组与矩阵运算处理能力。本章将讲解多维数组的创建及其基本属性、数组的切片和索引方法、数组的运算与存取等内容，最后通过一个综合示例，实现图像的变换功能。

下面给出本章涉及的知识点和学习目标。

- ndarray数组：学会数组的创建和属性。
- 数组选择：学会数组的切片和索引方法。
- 数组运算：学会数组的各类运算方法和使用。
- 数组存取：完成数组的存储和读取方法。
- 图像变换：了解图像的处理方法。

2.1　ndarray多维数组

NumPy库为Python带来了真正的ndarray多维数组功能。ndarray对象是一个快速而灵活的数据集容器。本节主要讲解ndarray多维数组的创建方法、数组的属性和数组的简单操作等内容。

2.1.1　创建ndarray数组

通过NumPy库的array函数，即可轻松地创建ndarray数组。NumPy库能将序列数据（列表、元组、数组或其他序列类型）转换为ndarray数组，如图2.1所示。

对于多维数组的创建，使用嵌套序列数据即可完成，如图2.2所示。

通常来说，ndarray是一个通用的同构数据容器，即其中的所有元素都需要是相同的类型。当创建好一个ndarray数组时，同时会在内存中存储ndarray的shape和dtype。shape是ndarray维度大小的元组，dtype是解释说明ndarray数据类型的对象，如图2.3所示。

```
In [1]: import numpy as np

In [2]: data1 = [5, 7, 9, 20]      #列表
        arr1 = np.array(data1)
        arr1

Out[2]: array([ 5,  7,  9, 20])

In [3]: data2 = (5, 7, 9, 20)      #元组
        arr2 = np.array(data2)
        arr2

Out[3]: array([ 5,  7,  9, 20])
```

图2.1　创建ndarray数组

```
data3 = [[1, 2, 3, 4],[5, 6, 7, 8]]    #多维数组
arr3 = np.array(data3)
arr3
```

```
array([[1, 2, 3, 4],
       [5, 6, 7, 8]])
```

图2.2　创建多维数组

从图2.3中可以看出，在创建数组时，NumPy会为新建的数组推断出一个合适的数据类型，并保存在dtype对象中，如图2.4所示。当序列中有整数和浮点数时，NumPy会把数组的dtype定义为浮点数据类型。

```
arr3.shape
```

```
(2, 4)
```

```
arr3.dtype
```

```
dtype('int32')
```

图2.3　ndarray属性

```
data4 = [1.2, 2, 3.45, 5]
arr4 = np.array(data4)
arr4
```

```
array([ 1.2 ,  2.  ,  3.45,  5.  ])
```

```
arr4.dtype
```

```
dtype('float64')
```

图2.4　dtype数据类型

注意：也可以通过显式说明，给数组指定数据类型。

除了可以使用np.array创建数组外，NumPy库还有一些函数可创建一些特殊的数组。下面简单介绍几个常用的数组创建函数。

1．zeros函数

zeros函数可以创建指定长度或形状的全0数组，如图2.5所示。

```
np.zeros(8)
array([ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.])

np.zeros((3,4))
array([[ 0.,  0.,  0.,  0.],
       [ 0.,  0.,  0.,  0.],
       [ 0.,  0.,  0.,  0.]])
```

图2.5　全0数组

2．ones函数

ones函数可以创建指定长度或形状的全1数组，如图2.6所示。

```
np.ones(4)
array([ 1.,  1.,  1.,  1.])

np.ones((4,6))
array([[ 1.,  1.,  1.,  1.,  1.,  1.],
       [ 1.,  1.,  1.,  1.,  1.,  1.],
       [ 1.,  1.,  1.,  1.,  1.,  1.],
       [ 1.,  1.,  1.,  1.,  1.,  1.]])
```

图2.6　全1数组

3．empty函数

empty函数可以创建一个没有具体值的数组（即垃圾值），如图2.7所示。

```
np.empty((2, 2, 2))
```

```
array([[[  8.25089629e-322,   2.39127773e-321],
        [  2.47032823e-323,   3.90344271e-316]],

       [[  0.00000000e+000,   2.47032823e-323],
        [  3.90350911e-316,   0.00000000e+000]]])
```

图2.7　empty函数

注意：数据类型基本都是float64。

4．arange函数

arange函数类似于Python的内置函数range，但是arange函数主要用于创建数组，如图2.8所示。

```
np.arange(10)
```

```
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```

图2.8　arange函数

更多的数组创建函数，可以参考表2.1。

表2.1　数组创建函数

函　　数	使用说明
arange	类似于内置的range函数，用于创建数组
ones	创建指定长度或形状的全1数组
ones_like	以另一个数组为参考，根据其形状和dtype创建全1数组
zeros、zeros_like	类似于ones、ones_like，创建全0数组
empty、empty_like	同上，创建没有具体值的数
eye、identity	创建正方形的$N\times N$单位矩阵

这里再介绍下ones_like函数的用法，如图2.9所示。ones_like函数可以根据传入的数组形状和dtype创建全1数组。

```
arr3
```

```
array([[1, 2, 3, 4],
       [5, 6, 7, 8]])
```

```
arr5 = np.ones_like(arr3)
arr5
```

```
array([[1, 1, 1, 1],
       [1, 1, 1, 1]])
```

```
arr5.dtype
```

```
dtype('int32')
```

图2.9　ones_like函数的用法

2.1.2　ndarray对象属性

NumPy创建的ndarray对象属性，如表2.2所示。

表2.2　ndarray对象属性

属　　性	使用说明
.ndim	秩，即数据轴的个数
.shape	数组的维度
.size	元素的总个数
.dtype	数据类型
.itemsize	数组中每个元素的字节大小

对于shape和dtype属性在前面已经讲过，这里看下其他属性的使用，如图2.10所示。

arr数组的数据类型是int32位的，对于计算机而言，1个字节是8位，所以arr的itemsize属性值为4。

```
data = [[2, 4, 5],[3,5, 7]]
arr = np.array(data)
arr
```

```
array([[2, 4, 5],
       [3, 5, 7]])
```

```
arr.ndim
```

```
2
```

```
arr.size
```

```
6
```

```
arr.itemsize
```

```
4
```

```
arr.dtype
```

```
dtype('int32')
```

图2.10　数组属性

2.1.3　ndarray数据类型

由前面内容得知：在创建数组时，NumPy会为新建的数组推断出一个合适的数据类型。同样，也可以通过dtype给创建的数组指定数据类型，如图2.11所示。

```
arr1 = np.arange(5)
arr1
```

```
array([0, 1, 2, 3, 4])
```

```
arr1.dtype
```

```
dtype('int32')
```

```
arr2 = np.arange(5,dtype='float64')
arr2
```

```
array([ 0.,  1.,  2.,  3.,  4.])
```

```
arr2.dtype
```

```
dtype('float64')
```

图2.11　指定数据类型

数组的数据类型有很多，读者只需要记住最常见的几种数据类型即可，如浮点数（float）、整数（int）、复数（complex）、布尔值（bool）、字符串（string_）和Python对象（object）。

对于创建好的ndarray，可通过astype方法进行数据类型的转换，如图2.12所示。

```
arr1 = np.arange(6)
arr1
```

```
array([0, 1, 2, 3, 4, 5])
```

```
arr1.dtype
```

```
dtype('int32')
```

```
arr2 = arr1.astype(np.float64)
arr2
```

```
array([ 0.,  1.,  2.,  3.,  4.,  5.])
```

```
arr2.dtype
```

```
dtype('float64')
```

```
arr3 = arr1.astype('string_')
arr3
```

```
array([b'0', b'1', b'2', b'3', b'4', b'5'],
      dtype='|S11')
```

```
arr3.dtype
```

```
dtype('S11')
```

图2.12　astype方法

注意：np.float64和‘float64’都可以完成操作。

如果将浮点数转换为整数，并不会使用四舍五入的方式来转换，而是元素的小数部分都会被截断，如图2.13所示。

如果数组是字符串类型且全是数字的话，也可以通过astype方法将其转换为数值类型，如图2.14所示。

```
arr = np.array([2.3, 7.5, 5.6, 9.8])
arr
```

```
array([ 2.3,  7.5,  5.6,  9.8])
```

```
arr.astype('int32')
```

```
array([2, 7, 5, 9])
```

图2.13　浮点数转换为整数

```
arr3
```

```
array([b'0', b'1', b'2', b'3', b'4', b'5'],
      dtype='|S11')
```

```
arr3.astype(np.int32)
```

```
array([0, 1, 2, 3, 4, 5])
```

图2.14　字符串转换为数值

但如果字符串中有字符时，转换时就会报错，如图2.15所示。

astype方法也可以通过另外一个数组的dtype进行转换，如图2.16所示。astype方法会创建一个新的数组，并不会改变原有数组的数据类型，如图2.17所示。

```
arr = np.array(['2', 'hello'])
arr
```

```
array(['2', 'hello'],
      dtype='<U5')
```

```
arr.astype('int32')
```

```
---------------------------------------------------------------------------
ValueError                                Traceback (most recent call last)
<ipython-input-44-849446cb6004> in <module>()
----> 1 arr.astype('int32')

ValueError: invalid literal for int() with base 10: 'hello'
```

图2.15　转换失败

```
arr1 = np.arange(10)
arr1.dtype
```

```
dtype('int32')
```

```
arr2 = np.ones(5)
arr2.dtype
```

```
dtype('float64')
```

```
arr3 = arr1.astype(arr2.dtype)
arr3.dtype
```

```
dtype('float64')
```

图2.16　类似转换

```
arr = np.arange(3)
arr.dtype
```

```
dtype('int32')
```

```
arr.astype('float64')
```

```
array([ 0.,  1.,  2.])
```

```
arr
```

```
array([0, 1, 2])
```

图2.17　原数组变化情况

2.1.4 数组变换

1. 数组重塑

对于定义好的数组，可以通过reshape方法改变其数据维度。传入的参数为新维度的元组，如图2.18所示。

多维数组也可以被重塑，如图2.19所示。

```
arr = np.arange(9)
arr
```

```
array([0, 1, 2, 3, 4, 5, 6, 7, 8])
```

```
arr.reshape((3,3))
```

```
array([[0, 1, 2],
       [3, 4, 5],
       [6, 7, 8]])
```

图2.18 数组重塑1

```
arr = np.array([[3, 4, 5],[1, 2, 3]])
arr.reshape((3,2))
```

```
array([[3, 4],
       [5, 1],
       [2, 3]])
```

图2.19 数组重塑2

reshape的参数中的一维参数可以设置为-1，表示数组的维度可以通过数据本身来推断，如图2.20所示。

```
arr = np.arange(12)
arr.reshape((3,-1))
```

```
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])
```

图2.20　数组重塑3

与reshape相反的方法是数据散开（ravel）数据或扁平化（flatten），如图2.21和图2.22所示。

注意：数据重塑不会改变原数组。

```
arr = np.arange(10).reshape((5,2))
arr
```

```
array([[0, 1],
       [2, 3],
       [4, 5],
       [6, 7],
       [8, 9]])
```

```
arr.ravel()
```

```
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```

```
arr
```

```
array([[0, 1],
       [2, 3],
       [4, 5],
       [6, 7],
       [8, 9]])
```

图2.21　数据散开

```
arr.flatten()
```

```
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```

```
arr
```

```
array([[0, 1],
       [2, 3],
       [4, 5],
       [6, 7],
       [8, 9]])
```

图2.22　数据扁平化

2．数组合并

数组合并用于几个数组间的操作，concatenate方法通过指定轴方向，将多个数组合并在一起，如图2.23所示。

```
arr1 = np.arange(12).reshape(3,4)
arr1
```

```
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])
```

```
arr2 = np.arange(12,24).reshape(3,4)
arr2
```

```
array([[12, 13, 14, 15],
       [16, 17, 18, 19],
       [20, 21, 22, 23]])
```

```
np.concatenate([arr1, arr2],axis=0)
```

```
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11],
       [12, 13, 14, 15],
       [16, 17, 18, 19],
       [20, 21, 22, 23]])
```

```
np.concatenate([arr1, arr2],axis=1)
```

```
array([[ 0,  1,  2,  3, 12, 13, 14, 15],
       [ 4,  5,  6,  7, 16, 17, 18, 19],
       [ 8,  9, 10, 11, 20, 21, 22, 23]])
```

图2.23　数组合并1

注意：关于轴向的内容，将在数组索引中进行讲解。

此外，NumPy中提供了几个比较简单易懂的方法，也可以进行数组合并，如vstack和hstack，如图2.24所示。

```
np.vstack((arr1,arr2))
```

```
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11],
       [12, 13, 14, 15],
       [16, 17, 18, 19],
       [20, 21, 22, 23]])
```

```
np.hstack((arr1, arr2))
```

```
array([[ 0,  1,  2,  3, 12, 13, 14, 15],
       [ 4,  5,  6,  7, 16, 17, 18, 19],
       [ 8,  9, 10, 11, 20, 21, 22, 23]])
```

图2.24　数组合并2

3．数组拆分

数组拆分是数组合并的相反操作，通过split方法可以将数组拆分为多个数组，如图2.25所示。

```
arr = np.arange(12).reshape((6,2))
arr
```

```
array([[ 0,  1],
       [ 2,  3],
       [ 4,  5],
       [ 6,  7],
       [ 8,  9],
       [10, 11]])
```

```
np.split(arr,[2, 4])
```

```
[array([[0, 1],
        [2, 3]]), array([[4, 5],
        [6, 7]]), array([[ 8,  9],
        [10, 11]])]
```

图2.25　数组拆分

4．数组转置和轴对换

转置是数组重塑的一种特殊形式，可以通过transpose方法进行转置。transpose方法需要传入轴编号组成的元组，这样就完成了数组的转置，如图2.26所示。

除了使用transpose方法外，数组有着T属性，可用于数组的转置，如图2.27所示。

```
arr = np.arange(12).reshape(3,4)
arr
```

```
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])
```

```
arr.transpose((1,0))
```

```
array([[ 0,  4,  8],
       [ 1,  5,  9],
       [ 2,  6, 10],
       [ 3,  7, 11]])
```

图2.26　数组转置1

```
arr.T
```

```
array([[ 0,  4,  8],
       [ 1,  5,  9],
       [ 2,  6, 10],
       [ 3,  7, 11]])
```

图2.27　数组转置2

ndarray的swapaxes方法用于轴对换，如图2.28所示。

```
arr = np.arange(16).reshape((2, 2, 4))
arr
```

```
array([[[ 0,  1,  2,  3],
        [ 4,  5,  6,  7]],

       [[ 8,  9, 10, 11],
        [12, 13, 14, 15]]])
```

```
arr.swapaxes(1, 2)
```

```
array([[[ 0,  4],
        [ 1,  5],
        [ 2,  6],
        [ 3,  7]],

       [[ 8, 12],
        [ 9, 13],
        [10, 14],
        [11, 15]]])
```

图2.28　轴对换

2.1.5　NumPy的随机数函数

在numpy.random模块中，提供了多种随机数生成函数。例如，可以通过randint函数生成整数随机数，如图2.29所示。

random模块中还提供了一些概率分布的样本值函数，如randn函数，例如，生成平均数为0，标准差为1的正态分布的随机数，如图2.30所示。

```
arr = np.random.randint(100, 200, size=(5, 4))
arr
```

```
array([[168, 180, 142, 134],
       [100, 106, 107, 147],
       [125, 170, 117, 192],
       [194, 172, 173, 102],
       [171, 171, 193, 180]])
```

图2.29　randint函数

```
arr = np.random.randn(2, 3, 5)
arr
```

```
array([[[-0.23022075, -1.53376604, -1.20506611, -0.72058013,  1.69808677],
        [-1.62102742, -1.1053548 ,  0.76182009, -1.24876097, -1.55001938],
        [ 0.04078704,  1.96669076, -2.24999391, -1.08302149,  0.52640131]],

       [[ 0.09381983,  1.16288913, -0.15885707,  0.93718335, -0.72444705],
        [-1.68017525, -0.18660456,  0.01881962,  0.16711124, -1.60857221],
        [ 0.93210884, -0.26899384, -0.35037258, -0.404521  ,  1.07034161]]])
```

图2.30　randn函数

通过normal函数生成指定均值和标准差的正态分布的数组，如图2.31所示。

```
arr = np.random.normal(4, 5, size=(3,5))
arr
```

```
array([[  8.29188165,  -6.11855239,  -1.5724349 ,   6.97515202,
          3.83049015],
       [  2.23989149,   7.81287044, -10.01907046,   3.68896253,
          3.01140917],
       [ 10.68983039,   7.63279875,  10.70678635,   2.66406148,
          3.76512045]])
```

图2.31　normal函数

表2.3中列出了部分numpy.random模块中的随机数函数。

表2.3　numpy.random模块中的随机数函数

函　　数	使用说明
rand	产生均匀分布的样本值
randint	给定范围内取随机整数
randn	产生正态分布的样本值
seed	随机数种子
permutation	对一个序列随机排序，不改变原数组
shuffle	对一个序列随机排序，改变原数组
uniform(low,high,size)	产生具有均匀分布的数组，low表示起始值，high表示结束值，size表示形状

（续）

函　　数	使用说明
normal(loc,scale,size)	产生具有正态分布的数组，loc表示均值，scale表示标准差
poisson(lam,size)	产生具有泊松分布的数组，lam表示随机事件发生率

最后来看看permutation和shuffle函数的用法，如图2.32和图2.33所示。

```
arr = np.random.randint(100, 200, size=(5, 4))
arr
```

```
array([[147, 122, 130, 169],
       [151, 152, 117, 119],
       [129, 140, 111, 131],
       [197, 126, 176, 199],
       [128, 174, 117, 143]])
```

```
np.random.permutation(arr)
```

```
array([[151, 152, 117, 119],
       [197, 126, 176, 199],
       [128, 174, 117, 143],
       [147, 122, 130, 169],
       [129, 140, 111, 131]])
```

```
arr
```

```
array([[147, 122, 130, 169],
       [151, 152, 117, 119],
       [129, 140, 111, 131],
       [197, 126, 176, 199],
       [128, 174, 117, 143]])
```

图2.32　permutation函数

```
arr = np.random.randint(100, 200, size=(5, 4))
arr
```

```
array([[196, 140, 199, 182],
       [161, 109, 193, 176],
       [102, 138, 165, 166],
       [191, 181, 108, 113],
       [168, 102, 199, 150]])
```

```
np.random.shuffle(arr)
```

```
arr
```

```
array([[168, 102, 199, 150],
       [191, 181, 108, 113],
       [102, 138, 165, 166],
       [161, 109, 193, 176],
       [196, 140, 199, 182]])
```

图2.33　shuffle函数

2.2　数组的索引和切片

在数据分析中常需要选取符合条件的数据，本节将主要讲解数组的索引和切片方法，并学会数组的灵活选择。

2.2.1　数组的索引

一维数组的索引类似Python列表，如图2.34所示。

```
import numpy as np
```

```
arr = np.arange(10)
arr
```

```
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```

```
arr[3]
```

```
3
```

```
arr[-1]
```

```
9
```

```
arr[2] = 123
arr
```

```
array([  0,   1, 123,   3,   4,   5,   6,   7,   8,   9])
```

图2.34　数组索引1

从代码中可以看出，数组的切片返回的是原始数组的视图。简单地说，视图就是原始数组的表现形式，切片操作并不会产生新数据，这就意味着在视图上的操作都会使原数组发生改变，如图2.35所示。

```
arr
```

```
array([  0,   1, 123,   3,   4,   5,   6,   7,   8,   9])
```

```
arr[3] = 88
arr
```

```
array([  0,   1, 123,  88,   4,   5,   6,   7,   8,   9])
```

```
arr1 = arr[-3:-1]
arr1
```

```
array([7, 8])
```

```
arr1[:] = 77
arr
```

```
array([  0,   1, 123,  88,   4,   5,   6,  77,  77,   9])
```

图2.35　数组索引2

注意：数组的切片和索引返回都是原始数组的视图。

如果需要的并非视图而是要复制数据，则可以通过copy方法来实现，如图2.36所示。

```
arr
```

```
array([  0,   1, 123,  88,   4,   5,   6,  77,  77,   9])
```

```
arr1 = arr[1].copy()
arr1 = 34
arr
```

```
array([  0,   1, 123,  88,   4,   5,   6,  77,  77,   9])
```

图2.36　数组索引3

对于二维数组，可在单个或多个轴向上完成切片，也可以跟整数索引一起混合使用，如图2.37所示。

```
arr = np.arange(15).reshape(3,5)
arr
```

```
array([[ 0,  1,  2,  3,  4],
       [ 5,  6,  7,  8,  9],
       [10, 11, 12, 13, 14]])
```

```
arr[0]
```

```
array([0, 1, 2, 3, 4])
```

```
arr[2]
```

```
array([10, 11, 12, 13, 14])
```

图2.37　二维数组索引1

如果需要获取各个元素，可通过以下办法，如图2.38所示。

```
arr
```

```
array([[ 0,  1,  2,  3,  4],
       [ 5,  6,  7,  8,  9],
       [10, 11, 12, 13, 14]])
```

```
arr[0][3]
```

```
3
```

```
arr[2,3]  #两种方法等价
```

```
13
```

图2.38　二维数组索引2

如果读者觉得代码不直观的话，可通过图2.39来理解轴的概念和二维数组的索引方式。在高维数组中，如果省略后面的索引，则会返回低一个维度的数组，如图2.40所示。

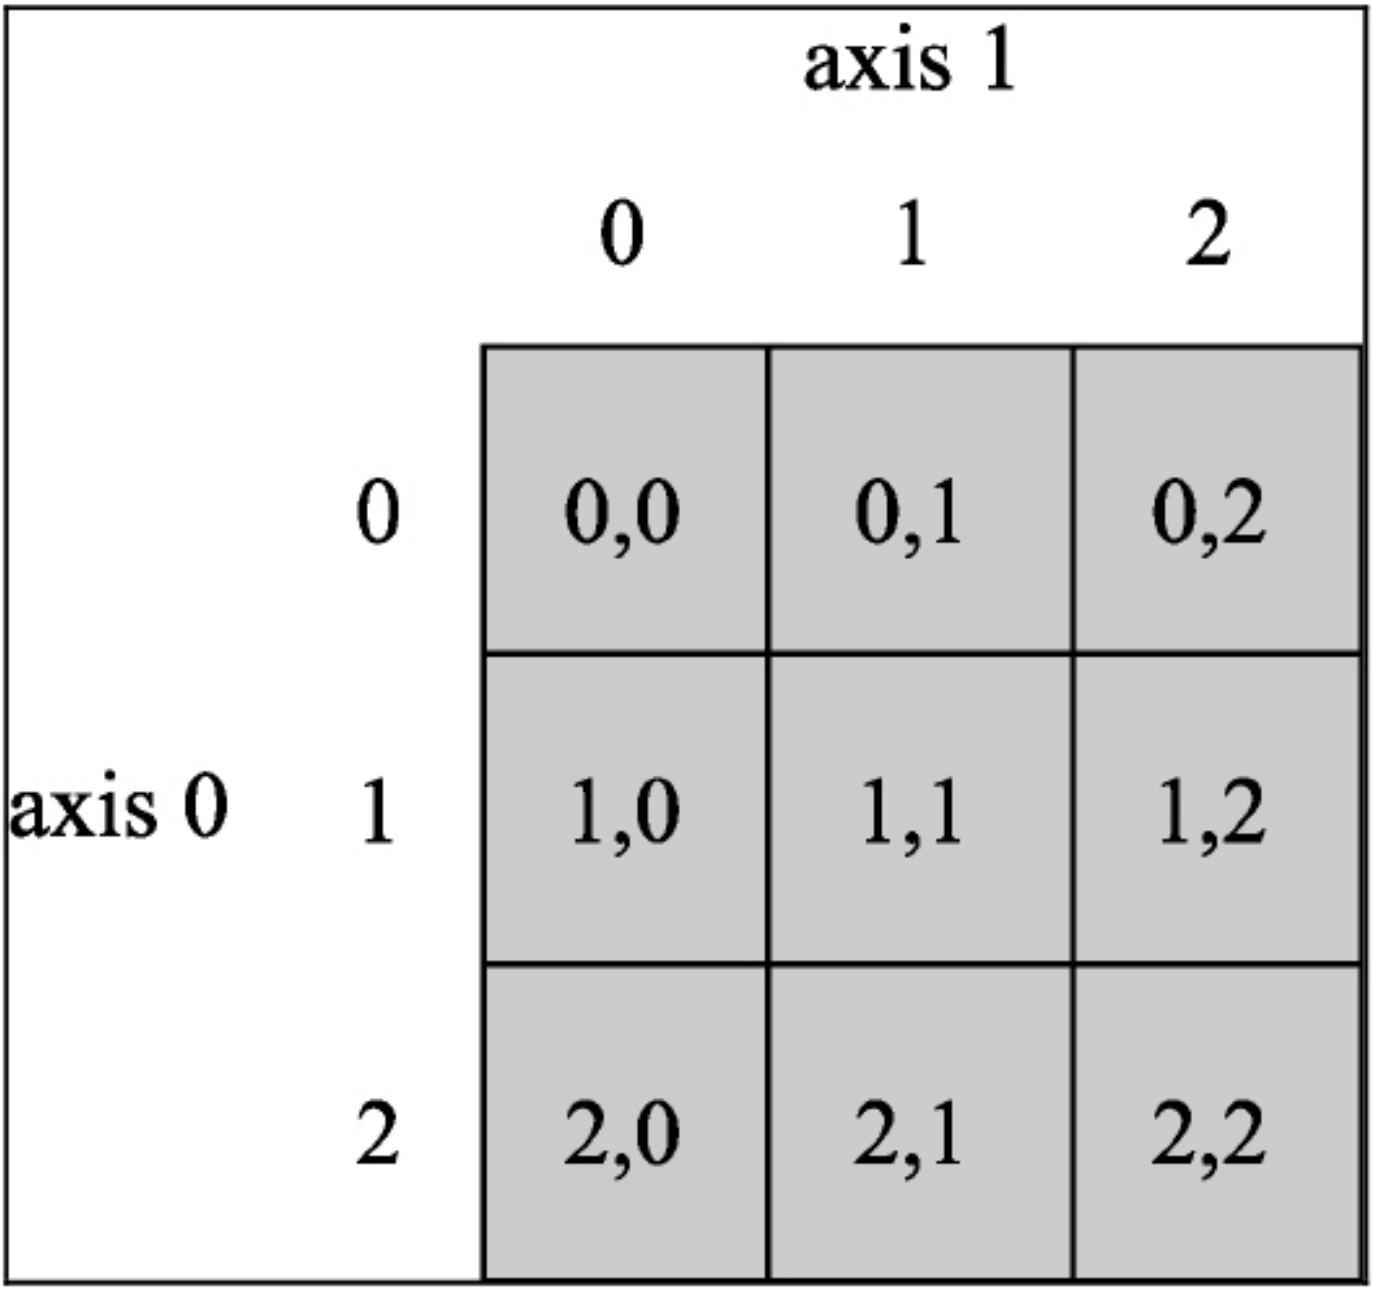

图2.39　二维数组索引方式

```
arr = np.arange(12).reshape(2,2,3)
arr
```

```
array([[[ 0,  1,  2],
        [ 3,  4,  5]],

       [[ 6,  7,  8],
        [ 9, 10, 11]]])
```

```
arr[0]
```

```
array([[0, 1, 2],
       [3, 4, 5]])
```

图2.40　高维数组索引1

标量值和数组都可以复制给arr[0]，如图2.41所示。

同样，类似于二维数组的切片，也可以索引到想要的部分元素或单个元素，如图2.42所示。

```
old = arr[0].copy()
arr[0] = 12
arr
```

```
array([[[12, 12, 12],
        [12, 12, 12]],

       [[ 6,  7,  8],
        [ 9, 10, 11]]])
```

```
arr[0] = old
arr
```

```
array([[[ 0,  1,  2],
        [ 3,  4,  5]],

       [[ 6,  7,  8],
        [ 9, 10, 11]]])
```

图2.41　高维数组索引2

```
arr
```

```
array([[[ 0,  1,  2],
        [ 3,  4,  5]],

       [[ 6,  7,  8],
        [ 9, 10, 11]]])
```

```
arr[1, 1]
```

```
array([ 9, 10, 11])
```

```
arr[0, 1, 2]
```

```
5
```

图2.42　高维数组索引3

2.2.2　数组的切片

一维数组的切片同样类似于Python列表，如图2.43所示。

多维数组的切片是按照轴方向进行的，当在中括号中输入一个参数时，数组就会按照0轴（也就是第一轴）方向进行切片，如图2.44所示。

```
arr = np.arange(6)
arr
```

```
array([0, 1, 2, 3, 4, 5])
```

```
arr[2:5]
```

```
array([2, 3, 4])
```

图2.43　一维数组切片

```
arr = np.arange(12).reshape(4,3)
arr
```

```
array([[ 0,  1,  2],
       [ 3,  4,  5],
       [ 6,  7,  8],
       [ 9, 10, 11]])
```

```
arr[2:]
```

```
array([[ 6,  7,  8],
       [ 9, 10, 11]])
```

图2.44　多维数组索引1

通过传入多个参数（可以是整数索引和切片），即可完成任意数据的获取，如图2.45所示。

```
arr
```

```
array([[ 0,  1,  2],
       [ 3,  4,  5],
       [ 6,  7,  8],
       [ 9, 10, 11]])
```

```
arr[:, 1]
```

```
array([ 1,  4,  7, 10])
```

```
arr[:, 1:2]
```

```
array([[ 1],
       [ 4],
       [ 7],
       [10]])
```

```
arr[2:, 1:]
```

```
array([[ 7,  8],
       [10, 11]])
```

图2.45　多维数组索引2

注意：只有使用冒号才会选取整个轴。

2.2.3　布尔型索引

首先创建两个数组，如图2.46所示。

如果每个水果对应于datas数组中的每一行，我们要取出‘pear’对应的datas的行，这时就需要用到布尔选择器，如图2.47所示。

```
fruits = np.array(['apple', 'banana', 'pear', 'banana', 'pear', 'apple', 'pear'])
datas = np.random.randint(-1, 1, size=(7,5))
```

```
fruits
```

```
array(['apple', 'banana', 'pear', 'banana', 'pear', 'apple', 'pear'],
      dtype='<U6')
```

```
datas
```

```
array([[ 0, -1, -1,  0, -1],
       [ 0, -1,  0, -1,  0],
       [-1, -1, -1, -1, -1],
       [-1, -1, -1, -1,  0],
       [-1,  0,  0, -1,  0],
       [-1,  0, -1,  0,  0],
       [-1, -1, -1,  0,  0]])
```

图2.46　数组情况

```
fruits == 'pear'
```

```
array([False, False,  True, False,  True, False,  True], dtype=bool)
```

```
datas[fruits == 'pear']
```

```
array([[-1,  0, -1, -1,  0],
       [ 0,  0,  0,  0, -1],
       [ 0,  0, -1,  0, -1]])
```

图2.47　布尔型索引1

注意：布尔型数组的长度必须和被索引的轴长度一致。

既然可以使用布尔选择，那么也同样适用于不等号（！=）、负号（-）、和（&）、或（|），如图2.48所示。

```
datas[fruits != 'pear']
```

```
array([[ 0, -1,  0,  0, -1],
       [-1, -1,  0,  0, -1],
       [-1,  0,  0, -1,  0],
       [-1, -1,  0,  0,  0]])
```

```
datas[(fruits == 'apple') | (fruits == 'banana')]
```

```
array([[ 0, -1,  0,  0, -1],
       [-1, -1,  0,  0, -1],
       [-1,  0,  0, -1,  0],
       [-1, -1,  0,  0,  0]])
```

图2.48　布尔型索引2

此外，布尔数组也可以结合切片和索引来使用，如图2.49所示。

通过以下代码可以完成datas数组中的0值替换为1值，如图2.50所示。

```
datas[fruits == 'pear',2:]
```

```
array([[-1, -1,  0],
       [ 0,  0, -1],
       [-1,  0, -1]])
```

```
datas[fruits == 'pear',2]
```

```
array([-1,  0, -1])
```

图2.49　布尔型索引3

```
datas[datas == 0] = 1
datas
```

```
array([[ 1, -1,  1,  1, -1],
       [-1, -1,  1,  1, -1],
       [-1,  1, -1, -1,  1],
       [-1,  1,  1, -1,  1],
       [ 1,  1,  1,  1, -1],
       [-1, -1,  1,  1,  1],
       [ 1,  1, -1,  1, -1]])
```

图2.50　布尔型索引4

2.2.4　花式索引

花式索引是NumPy中的术语，它可以通过整数列表或数组进行索引，如图2.51所示。也可以使用np.ix_函数完成同样的操作，如图2.52所示。

```
arr[[1, 3, 2]]
```

```
array([[ 3,  4,  5],
       [ 9, 10, 11],
       [ 6,  7,  8]])
```

```
arr[[3, 2]][:, [2, 1]]
```

```
array([[11, 10],
       [ 8,  7]])
```

图2.51　花式索引1

```
arr[np.ix_([3,2],[2, 1])]
```

```
array([[11, 10],
       [ 8,  7]])
```

图2.52　花式索引2

2.3　数组的运算

数组的运算支持向量化运算，将本来需要在Python级别进行的循环，放到C语言的运算中，明显地提高了程序的运算速度。本节将讲解数组的各种运算方法。

2.3.1　数组和标量间的运算

数组之所以很强大而且重要的原因，是其不需要通过循环就可以完成批量计算，也就是矢量化，如图2.53所示。相同维度的数组的算术运算都可以直接应用到元素中，也就是元素级运算，如图2.54所示。

```
a = [1, 2, 3]
b = []
for i in a:
    b.append(i * 10)
b
```

```
[10, 20, 30]
```

```
arr = np.array([1, 2, 3])
arr * 10
```

```
array([10, 20, 30])
```

图2.53　矢量化

```
arr * arr
```

```
array([1, 4, 9])
```

```
arr - arr
```

```
array([0, 0, 0])
```

图2.54　元素级运算

2.3.2　通用函数

通用函数（ufunc）是一种对数组中的数据执行元素级运算的函数，用法也很简单。例如，通过abs函数求绝对值，square函数求平方，如图2.55所示。

```
arr = np.random.randn(3,3)
arr
```

```
array([[-1.30289625, -1.62082859, -0.02086977],
       [ 0.61681656,  1.44215576,  1.7281482 ],
       [-0.96761142,  0.6475979 , -0.57524988]])
```

```
np.abs(arr)
```

```
array([[ 1.30289625,  1.62082859,  0.02086977],
       [ 0.61681656,  1.44215576,  1.7281482 ],
       [ 0.96761142,  0.6475979 ,  0.57524988]])
```

```
np.square(arr)
```

```
array([[  1.69753863e+00,   2.62708531e+00,   4.35547217e-04],
       [  3.80462668e-01,   2.07981323e+00,   2.98649619e+00],
       [  9.36271853e-01,   4.19383043e-01,   3.30912420e-01]])
```

图2.55　通用函数1

以上函数都是传入一个数组，所以这些函数都是一元函数。有一些函数需要传入两个数组并返回一个数组，这些函数被称为二元函数。例如，add函数用于两个数组的相加，minimum函数可以计算元素最小值，如图2.56所示。

有些通用函数还可以返回两个数组，例如modf函数，可以返回数组元素的小数和整数部分，如图2.57所示。

注意：更多通用函数的用法，可以去NumPy官网http://www.numpy.org/查阅。

```
arr1 = np.random.randint(1, 10, size=(5))
arr1
```

```
array([5, 2, 9, 4, 1])
```

```
arr2 = np.random.randint(1, 10, size=(5))
arr2
```

```
array([7, 6, 9, 1, 3])
```

```
np.add(arr1, arr2)
```

```
array([12,  8, 18,  5,  4])
```

```
np.minimum(arr1, arr2)
```

```
array([5, 2, 9, 1, 1])
```

图2.56　通用函数2

```
arr = np.random.normal(2,4,size=(6,))
arr
```

```
array([ 4.03156633,  2.24471147, -1.05295999,  3.17361538,  9.45900887,
        2.48014303])
```

```
np.modf(arr)
```

```
(array([ 0.03156633,  0.24471147, -0.05295999,  0.17361538,  0.45900887,
         0.48014303]), array([ 4.,  2., -1.,  3.,  9.,  2.]))
```

图2.57　通用函数3

2.3.3　条件逻辑运算

首先创建3个数组，如图2.58所示。

```
arr1 = np.array([1, 2, 3, 4])
arr2 = np.array([5, 6, 7, 8])
cond = np.array([True, False, False, True])
```

图2.58　创建数组

如果需要通过cond的值来选取arr1和arr2的值，当cond为True时，选择arr1的值，否则选择arr2的值，那么可以通过if语句判断来实现，如图2.59所示。

```
result = [(x if c else y) for x, y, c in zip(arr1, arr2, cond)]
result
```

```
[1, 6, 7, 4]
```

图2.59　条件逻辑

但这种方法存在两个问题：第一，对大规模数组处理速度不是很快；第二，无法用于多维数组。若使用NumPy的where函数则可以解决这两个问题，如图2.60所示。

```
result = np.where(cond, arr1, arr2)
result
```

```
array([1, 6, 7, 4])
```

图2.60　where函数1

where函数中的第二个和第三个参数可以为标量。在数据分析中，经常需要通过一些条件将数组进行处理。例如，新建一个随机符合正态分布的数组，通过数据处理将正值替换为1，负值替换为-1，如图2.61所示。

```
arr = np.random.randn(4, 4)
arr
```

```
array([[ 0.99483299, -0.42559031,  0.60728194, -0.28477079],
       [-0.47341549, -1.03284446, -1.24692688, -0.7168212 ],
       [-0.2463296 ,  0.9006737 , -0.8362647 ,  0.28860023],
       [ 0.24025673, -1.14644973,  0.84133157, -0.00742223]])
```

```
new_arr = np.where(arr > 0, 1, -1)
new_arr
```

```
array([[ 1, -1,  1, -1],
       [-1, -1, -1, -1],
       [-1,  1, -1,  1],
       [ 1, -1,  1, -1]])
```

图2.61　where函数2

使用elif函数可以进行多条件的判别。np.where函数通过嵌套的where表达式也可以完成同样的功能，如图2.62所示。

```
arr = np.random.randint(1, 300, size=(3,3))
arr
```

```
array([[177, 177,  99],
       [238, 233, 131],
       [125, 288,   5]])
```

```
new_arr = np.where(arr > 200, 3,
                   np.where(arr > 100, 2, 1))
new_arr
```

```
array([[2, 2, 1],
       [3, 3, 2],
       [2, 3, 1]])
```

图2.62　where函数3

2.3.4　统计运算

NumPy库支持对整个数组或按指定轴向的数据进行统计计算。例如，sum函数用于求和；mean函数用于求算术平均数；std函数用于求标准差，如图2.63所示。

```
arr = np.random.randn(4, 4)
arr
```

```
array([[-0.2460958 , -3.56262609,  2.28878812, -0.66155659],
       [-0.32224876, -0.62264566,  0.0759868 , -0.50014849],
       [ 0.38841614,  0.2260369 , -0.61771424,  0.00538855],
       [-0.29865896,  0.51231692,  0.48119231,  0.06256321]])
```

```
arr.sum()
```

```
-2.791005624657537
```

```
arr.mean()
```

```
-0.17443785154109606
```

```
arr.std()
```

```
1.1141240674492316
```

图2.63　统计计算1

上面的这些函数也可以传入axis参数，用于计算指定轴方向的统计值，如图2.64所示。

```
arr
```

```
array([[-0.2460958 , -3.56262609,  2.28878812, -0.66155659],
       [-0.32224876, -0.62264566,  0.0759868 , -0.50014849],
       [ 0.38841614,  0.2260369 , -0.61771424,  0.00538855],
       [-0.29865896,  0.51231692,  0.48119231,  0.06256321]])
```

```
arr.mean(axis=1)
```

```
array([ -5.45372587e-01,  -3.42264027e-01,   5.31836566e-04,
         1.89353371e-01])
```

```
arr.sum(0)
```

```
array([-0.47858738, -3.44691793,  2.228253  , -1.09375332])
```

图2.64　指定轴方向

cumsum和cumpod方法会产生计算结果组成的数组，如图2.65所示。

```
arr = np.arange(9).reshape(3,3)
arr
```

```
array([[0, 1, 2],
       [3, 4, 5],
       [6, 7, 8]])
```

```
arr.cumsum(0)
```

```
array([[ 0,  1,  2],
       [ 3,  5,  7],
       [ 9, 12, 15]], dtype=int32)
```

```
arr.cumprod(1)
```

```
array([[  0,   0,   0],
       [  3,  12,  60],
       [  6,  42, 336]], dtype=int32)
```

图2.65　统计计算2

基本数组的统计方法如表2.4所示。

表2.4　基本数组统计方法

方　　法	使用说明
sum	求和
mean	算术平均数
std、var	标准差和方差
min、max	最小值和最大值
argmin、argmax	最小和最大元素的索引
cumsum	所有元素的累计和
cumprod	所有元素的累计积

2.3.5　布尔型数组运算

对于布尔型数组，其布尔值会被强制转换为1（True）和0（False），如图2.66所示。

```
arr = np.random.randn(20)
arr
```

```
array([ 0.64854453, -1.02444099,  1.18506546,  1.0588872 , -1.67297679,
        1.11245385, -1.47720606,  0.67531455,  0.10707936,  1.60181681,
       -0.09663766,  0.13821122,  2.08949018, -0.85208144, -1.01504574,
       -1.01749498,  0.42782922, -0.83512655,  0.20623175, -0.23411408])
```

```
(arr > 0).sum()
```

```
11
```

图2.66　布尔型数组计算1

另外，还有两个方法any和all也可以用于布尔型数组运算。any方法用于测试数组中是否存在一个或多个True；all方法用于检查数组中的所有值是否为True，如图2.67所示。

```
arr = np.array([True, False, False, True])
arr
```

```
array([ True, False, False,  True], dtype=bool)
```

```
arr.any()
```

```
True
```

```
arr.all()
```

```
False
```

图2.67　布尔型数组计算2

2.3.6 排序

与Python列表类似，NumPy数组也可以通过sort方法进行排序，如图2.68所示。

```
arr = np.random.randn(10)
arr
```

```
array([-0.06763165,  0.70670621, -2.28090762,  0.61654106,  0.35562341,
        0.57962632,  0.09817634,  1.52590085,  0.24640778, -0.69223728])
```

```
arr.sort()
arr
```

```
array([-2.28090762, -0.69223728, -0.06763165,  0.09817634,  0.24640778,
        0.35562341,  0.57962632,  0.61654106,  0.70670621,  1.52590085])
```

图2.68 排序

对于多维数组，可以通过指定轴方向进行排序，如图2.69所示。

```
arr = np.random.randn(5,3)
arr
```

```
array([[ 0.76464658,  1.03958729,  0.83151511],
       [ 1.63188956, -0.62708685,  0.05175314],
       [ 0.85665906, -0.24305887,  1.30020042],
       [ 2.00108815, -1.49244044, -0.06771401],
       [ 0.26482398, -1.42061605, -1.0372988 ]])
```

```
arr.sort(1)
arr
```

```
array([[ 0.76464658,  0.83151511,  1.03958729],
       [-0.62708685,  0.05175314,  1.63188956],
       [-0.24305887,  0.85665906,  1.30020042],
       [-1.49244044, -0.06771401,  2.00108815],
       [-1.42061605, -1.0372988 ,  0.26482398]])
```

图2.69 按轴排序

2.3.7 集合运算

NumPy库中提供了针对一维数组的基本集合运算。在数据分析中，常使用np.unique方法来找出数组中的唯一值，如图2.70所示。

```
fruits = np.array(['apple', 'banana', 'pear', 'banana', 'pear', 'apple', 'pear'])
fruits
```

```
array(['apple', 'banana', 'pear', 'banana', 'pear', 'apple', 'pear'],
      dtype='<U6')
```

```
np.unique(fruits)
```

```
array(['apple', 'banana', 'pear'],
      dtype='<U6')
```

```
arr = np.array([2, 3, 3, 2, 8, 1])
arr
```

```
array([2, 3, 3, 2, 8, 1])
```

```
np.unique(arr)
```

```
array([1, 2, 3, 8])
```

图2.70　找出唯一值

注意：对唯一值进行了排序。

np.in1d方法用于测试几个数组中是否包含相同的值，返回一个布尔值数组，如图2.71所示。

```
arr = np.array([2, 3, 5, 7])
arr
```

```
array([2, 3, 5, 7])
```

```
np.in1d(arr, [2,7])
```

```
array([ True, False, False,  True], dtype=bool)
```

图2.71　包含运算

数组的集合运算如表2.5所示。

表2.5　集合运算

方　　法	使用说明
unique(x)	唯一值
intersect1d(x,y)	公共元素
union1d(x,y)	并集
in1d(x,y)	x 的元素是否在 y 中，返回布尔型数组
setdiff1d(x,y)	集合的差
setxor1d(x,y)	交集取反

2.3.8 线性代数

前面讲过数组的运算是元素级的，数组相乘的结果是各对应元素的积组成的数组。而对于矩阵而言，需要求的是点积，这里NumPy库提供了用于矩阵乘法的dot函数，如图2.72所示。

对于更多的矩阵计算，可通过NumPy库的linalg模块来完成，如图2.73所示为计算矩阵的行列式。

```
arr1 = np.array([[1, 2, 3], [4, 5, 6]])
arr1
```

```
array([[1, 2, 3],
       [4, 5, 6]])
```

```
arr2 = np.arange(9).reshape(3,3)
arr2
```

```
array([[0, 1, 2],
       [3, 4, 5],
       [6, 7, 8]])
```

```
np.dot(arr1,arr2)
```

```
array([[24, 30, 36],
       [51, 66, 81]])
```

图2.72　矩阵点积

```
from numpy.linalg import det
```

```
arr = np.array([[1, 2], [3, 4]])
arr
```

```
array([[1, 2],
       [3, 4]])
```

```
det(arr)
```

```
-2.0000000000000004
```

图2.73　矩阵行列式计算

注意：更多的矩阵运算说明可查看linalg帮助。

2.4　数组的存取

已经处理好的数组数据需要进行存储，而存储的数据也需要读取使用。本节将介绍数组的存储与读取的方法。

2.4.1　数组的存储

通过np.savetxt方法可以对数组进行存储，具体实现如图2.74所示。

```
arr = np.arange(12).reshape(4,3)
arr
```

```
array([[ 0,  1,  2],
       [ 3,  4,  5],
       [ 6,  7,  8],
       [ 9, 10, 11]])
```

```
np.savetxt('ch2ex1.csv', arr, fmt='%d',delimiter=',')
```

```
!type ch2ex1.csv
```

```
0,1,2
3,4,5
6,7,8
9,10,11
```

图2.74　数组存储

2.4.2　数组的读取

对于存储的文件，可以通过np.loadtxt方法进行读取，并将其加载到一个数组中，如图2.75所示。

```
arr = np.loadtxt('ch2ex1.csv', delimiter=',')
arr
```

```
array([[  0.,   1.,   2.],
       [  3.,   4.,   5.],
       [  6.,   7.,   8.],
       [  9.,  10.,  11.]])
```

图2.75　数据读取

2.5　综合示例——图像变换

图像一般采用的是RGB色彩模式，即每个像素点的颜色由R（红）、G（绿）、B（蓝）组成。通过三种颜色的叠加可以得到各种颜色，每个颜色的取值范围为0～255。Python中的PIL库是一个处理图像的第三方库，通过如图2.77所示的代码可以把如图2.76所示的图片转换为数组格式。

图2.76　图片

```
from PIL import Image
import numpy as np
```

```
im = np.array(Image.open('C:/Users/LP/Desktop/2.76.jpeg'))
print(im.shape,im.dtype)
```

```
(350, 583, 3) uint8
```

```
im
```

```
array([[[226, 226, 226],
        [226, 226, 226],
        [226, 226, 226],
        ...,
        [198, 198, 198],
        [197, 197, 197],
        [196, 196, 196]],

       [[226, 226, 226],
```

图2.77　图像转数组

通过图中的代码可以看出，图像转换成三维数组后，维度分别为宽度、长度和RGB值。

注意：在Anaconda中已经默认安装了PIL库，库名为pillow。

转换为数组后，可进行数组运算，运算完成后将其保存为新图像就完成了图像的变换，如图2.78和图2.79所示。

```
b = [255, 255, 255] - im     #数组运算
new_im = Image.fromarray(b.astype('uint8'))
new_im.save('C:/Users/LP/Desktop/2.79.jpeg')   #保存为新图像
```

图2.78　图像变换

图2.79　变换图片

第3章　pandas入门和实战

由于DataFrame数据结构为二维表格结构，这使得pandas库成为数据分析的“主力军”。本章将讲解pandas库中两种基础数据结构的创建和使用方法及DataFrame的选取和操作，带领读者掌握其算术运算与函数的使用，最后再结合一个综合示例，介绍数据分析流程和pandas的可视化。

下面给出本章涉及的知识点和学习目标。

· pandas数据结构：学会Series和DataFrame的创建。

· 索引操作：学会两种数据结构的索引方法和数据选取。

· 数据运算：学会两种数据的运算和函数应用。

· 层次化索引：学会创建和使用层次化索引。

· pandas可视化：学会利用pandas绘制各种基本图形。

3.1　pandas数据结构

pandas有两个基本的数据结构：Series和DataFrame。本节主要讲解这两个数据结构的创建和基本使用。

3.1.1　创建Series数据

Series数据结构类似于一维数组，但它是由一组数据（各种Numpy数据类型）和一组对应的索引组成。通过一组列表数据即可产生最简单的Series数据，如图3.1所示。

```
from pandas import Series,DataFrame
import pandas as pd
```

```
obj = Series([1, -2, 3, -4])
obj
```

```
0    1
1   -2
2    3
3   -4
dtype: int64
```

图3.1　创建Series数据1

Series数据：索引在左边，值在右边。可以看出，如果没有指定一组数据作为索引的话，Series数据会以0到N-1（N为数据的长度）作为索引，也可以通过指定索引的方式来创建Series数据，如图3.2所示。

```
obj2 = Series([1, -2, 3, -4], index=['a', 'b', 'c', 'd'])
obj2
```

```
a    1
b   -2
c    3
d   -4
dtype: int64
```

图3.2　创建Series数据2

Series有values和index属性，可返还值数据的数组形式和索引对象，如图3.3所示。

```
obj2.values
```

```
array([ 1, -2,  3, -4], dtype=int64)
```

```
obj2.index
```

```
Index(['a', 'b', 'c', 'd'], dtype='object')
```

图3.3　Series属性

Series与普通的一维数组相比，其具有索引对象，可通过索引来获取Series的单个或一组值，如图3.4所示。

```
obj2['b']
```

```
-2
```

```
obj2['c'] = 23
obj2[['c', 'd']]
```

```
c    23
d    -4
dtype: int64
```

图3.4　Series索引

Series运算都会保留索引和值之间的链接，如图3.5所示。

Series数据中的索引和值一一对应，类似于Python字典数据，所以也可以通过字典数据来创建Series，如图3.6所示。

```
obj2
```

```
a     1
b    -2
c    23
d    -4
dtype: int64
```

```
obj2[obj2 < 0 ]
```

```
b   -2
d   -4
dtype: int64
```

```
obj2 * 2
```

```
a     2
b    -4
c    46
d    -8
dtype: int64
```

```
import numpy as np
```

```
np.abs(obj2)
```

```
a     1
b     2
c    23
d     4
dtype: int64
```

图3.5　Series运算

```
data = {
    '张三':92,
    '李四':78,
    '王五':68,
    '小明':82
}
```

```
obj3 = Series(data)
obj3
```

```
小明    82
张三    92
李四    78
王五    68
dtype: int64
```

图3.6　创建Series数据3

由于字典结构是无序的，因此这里返回的Series也是无序的，这里依旧可以通过index指定索引的排列顺序，如图3.7所示。

Series对象和索引都有name属性，这样我们就可以给Series定义名称，让Series更具可读性，如图3.8所示。

```
names = ['张三', '李四', '王五', '小明']
obj4 = Series(data, index=names)
obj4
```

```
张三    92
李四    78
王五    68
小明    82
dtype: int64
```

图3.7　创建Series数据4

```
obj4.name = 'math'
obj4.index.name = 'students'
```

```
obj4
```

```
students
张三    92
李四    78
王五    68
小明    82
Name: math, dtype: int64
```

图3.8　name属性

3.1.2　创建DataFrame数据

DataFrame数据是Python数据分析最常用的数据，无论是创建的数据或外部数据，我们首先想到的都是如何将其转换为DataFrame数据，原因是DataFrame为表格型数据。说到表格型数据，多数人想到的可能是Excel表格，本章将会把DataFrame与Excel两种数据进行对比，让读者可以更加轻松地了解和使用DataFrame数据。

在Excel中，在单元格中输入数据即可创建一张表格。对于DataFrame数据而言，需要用代码实现，创建DataFrame数据的办法有很多，最常用的是传入由数组、列表或元组组成的字典，代码如图3.9所示。

```
import numpy as np
from pandas import Series,DataFrame
import pandas as pd
```

```
data = {
    'name':['张三', '李四', '王五', '小明'],
    'sex':['female', 'female', 'male', 'male'],
    'year':[2001, 2001, 2003, 2002],
    'city':['北京', '上海', '广州', '北京']
}
df = DataFrame(data)
df
```

图3.9　创建DataFrame数据1

返回的数据如图3.10所示，DataFrame数据有行索引和列索引，行索引类似于Excel表格中每行的编号（没有指定行索引的情况下），列索引类似于Excel表格的列名（通常也可称为字段）。

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	female	2001
2	广州	王五	male	2003
3	北京	小明	male	2002

图3.10　DataFrame数据

由于字典是无序的，因此可以通过columns指定列索引的排列顺序，如图3.11所示。

```
df = DataFrame(data, columns=['name', 'sex', 'year', 'city'])
df
```

	name	sex	year	city
0	张三	female	2001	北京
1	李四	female	2001	上海
2	王五	male	2003	广州
3	小明	male	2002	北京

图3.11　指定列索引顺序

当没有指定行索引的情况下，会使用0到N-1（N为数据的长度）作为行索引，这里也可以使用其他数据作为行索引，如图3.12所示。

```
df = DataFrame(data, columns=['name', 'sex', 'year', 'city'],index=['a', 'b', 'c', 'd'])
df
```

	name	sex	year	city
a	张三	female	2001	北京
b	李四	female	2001	上海
c	王五	male	2003	广州
d	小明	male	2002	北京

```
df.index
```

```
Index(['a', 'b', 'c', 'd'], dtype='object')
```

```
df.columns
```

```
Index(['name', 'sex', 'year', 'city'], dtype='object')
```

图3.12　指定行索引

使用嵌套字典的数据也可以创建DataFrame数据，如图3.13所示。

```
data2 = {
    'sex':{'张三':'female','李四':'female','王五':'male'},
    'city':{'张三':'北京','李四':'上海','王五':'广州'}
}
df2 = DataFrame(data2)
df2
```

	city	sex
张三	北京	female
李四	上海	female
王五	广州	male

图3.13　创建DataFrame数据2

表3.1中提供了部分常用的为创建DataFrame数据可传入的数据类型。

表3.1　创建DataFrame数据可输入的数据类型

类　　型	使用说明
二维ndarray	数据矩阵，可传入行列索引
由数组、列表或元组组成的字典	如图3.9所示
由Series组成的字典	每个Series为一列，Series索引合并为行索引
嵌套字典	如图3.13所示
字典或Series的列表	各项成为DataFrame一行，字典键或Series索引成为DataFrame列索引
由列表或元组组成的列表	类似于“二维数组”

如果df为某班级学生的信息，通过设置DataFrame的index和columns的name属性，可以将这些信息显示出来，如图3.14所示。

```
df.index.name = 'id'
df.columns.name = 'std_info'
```

```
df
```

std_info	name	sex	year	city
id				
a	张三	female	2001	北京
b	李四	female	2001	上海
c	王五	male	2003	广州
d	小明	male	2002	北京

图3.14　设置name属性

通过values属性可以将DataFrame数据转换为二维数组，如图3.15所示。

```
df.values
```

```
array([['张三', 'female', 2001, '北京'],
       ['李四', 'female', 2001, '上海'],
       ['王五', 'male', 2003, '广州'],
       ['小明', 'male', 2002, '北京']], dtype=object)
```

图3.15　转换为二维数组

注意：各列数据类型不同，返回的数组会兼顾所有数据类型。

3.1.3 索引对象

Series的索引和DataFrame的行和列索引都是索引对象，用于负责管理轴标签和元数据，如图3.16所示。

```
obj.index
```

```
Index(['a', 'b', 'c', 'd'], dtype='object')
```

```
df.index
```

```
Index(['a', 'b', 'c', 'd'], dtype='object', name='id')
```

```
df.columns
```

```
Index(['name', 'sex', 'year', 'city'], dtype='object', name='std_info')
```

图3.16 索引对象

索引对象是不可以进行修改的，如果修改就会报错，如图3.17所示。

```
index = obj.index
index[1] = 'f'
```

```
---------------------------------------------------------------------------
TypeError                                 Traceback (most recent call last)
<ipython-input-14-4f995da5e969> in <module>()
      1 index = obj.index
----> 2 index[1] = 'f'

F:\Anaconda\envs\data-analysis\lib\site-packages\pandas\core\indexes\base.py in __setitem__(self, key, value)
   1668
   1669     def __setitem__(self, key, value):
-> 1670         raise TypeError("Index does not support mutable operations")
   1671
   1672     def __getitem__(self, key):

TypeError: Index does not support mutable operations
```

图3.17 索引对象不可修改

索引对象类似于数组数据，其功能也类似于一个固定大小的集合，如图3.18所示。

```
df
```

std_info	name	sex	year	city
id				
a	张三	female	2001	北京
b	李四	female	2001	上海
c	王五	male	2003	广州
d	小明	male	2002	北京

```
'sex' in df.columns
```

```
True
```

```
'f' in df.index
```

```
False
```

图3.18　集合运算

注意：读者不需要了解索引对象的细节。

3.2　pandas索引操作

本节将针对Series和DataFrame数据，讲解Series和DataFrame索引操作的方法，通过将它们与Excel数据的类比，讲解DataFrame数据的选取与操作。

3.2.1　重新索引

前面说过，索引对象是无法进行修改的，本节所说的重新索引并不是给索引重新命名，而是对索引重新排序，如果某个索引值不存在的话，就会引入缺失值。首先来看下Series重新排序后的索引，如图3.19所示。

```
obj = Series([1, -2, 3, -4], index=['b', 'a', 'c', 'd'])
obj
```

```
b    1
a   -2
c    3
d   -4
dtype: int64
```

```
obj2 = obj.reindex(['a', 'b', 'c', 'd', 'e'])
obj2
```

```
a   -2.0
b    1.0
c    3.0
d   -4.0
e    NaN
dtype: float64
```

图3.19　Series重新排序后的索引

如果需要对插入的缺失值进行填充的话，可通过method参数来实现，参数值为ffill或pad时为向前填充，参数值为bfill或backfill时为向后填充，如图3.20所示。

```
obj = Series([1, -2, 3, -4], index=[0,2,3,5])
obj
```

```
0    1
2   -2
3    3
5   -4
dtype: int64
```

```
obj2 = obj.reindex(range(6),method='ffill')
obj2
```

```
0    1
1    1
2   -2
3    3
4    3
5   -4
dtype: int64
```

图3.20　填充缺失值

对于DataFrame数据来说，行和列索引都是可以重新索引的，如图3.21所示为重新索引行。

```
df = DataFrame(np.arange(9).reshape(3,3),index=['a','c','d'],columns=['name','id','sex'])
df
```

	name	id	sex
a	0	1	2
c	3	4	5
d	6	7	8

```
df2 = df.reindex(['a', 'b', 'c', 'd'])
df2
```

	name	id	sex
a	0.0	1.0	2.0
b	NaN	NaN	NaN
c	3.0	4.0	5.0
d	6.0	7.0	8.0

图3.21　重新索引行

重新索引列需要使用columns关键字，如图3.22所示。

```
df3 = df.reindex(columns=['name', 'year', 'id'], fill_value=0)
df3
```

	name	year	id
a	0	0	1
c	3	0	4
d	6	0	7

图3.22　重新索引列

如表3.2所示为reindex函数的各参数使用说明。

表3.2　reindex函数参数

类　　型	使用说明
index	用于索引的新序列
method	填充缺失值方法
fill_value	缺失值替代值
limit	最大填充量

3.2.2　更换索引

在DataFrame数据中，如果不希望使用默认行索引的话，可在创建的时候通过index参数来设置行索引。有时我们希望将列数据作为行索引，这时可通过set_index方法来实现，如图3.23所示。

与set_index方法相反的方法是reset_index方法，如图3.24所示。

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	female	2001
2	广州	王五	male	2003
3	北京	小明	male	2002

```
df2 = df.set_index('name')
df2
```

	city	sex	year
name			
张三	北京	female	2001
李四	上海	female	2001
王五	广州	male	2003
小明	北京	male	2002

图3.23　指定行索引

```
df3 = df2.reset_index()
df3
```

	name	city	sex	year
0	张三	北京	female	2001
1	李四	上海	female	2001
2	王五	广州	male	2003
3	小明	北京	male	2002

图3.24　恢复索引

下面给读者举一个实际的例子。对于Excel表格而言，排序之后，行索引并不会发生改变（依旧是从1开始计数），而对DataFrame数据，排序之后其行索引会改变，如图3.25所示。

```
data = {
    'name':['张三', '李四', '王五', '小明'],
    'grade':[68, 78, 63, 92]
}
df = DataFrame(data)
df
```

	grade	name
0	68	张三
1	78	李四
2	63	王五
3	92	小明

```
df2 = df.sort_values(by='grade')
df2
```

	grade	name
2	63	王五
0	68	张三
1	78	李四
3	92	小明

图3.25　排序改变行索引

说明：排序在后面内容中会详细讲解。

这里要获取成绩倒数两位同学的数据的话，需要记住其单独的索引。但当数据量大的时候，想查看多位排序过后的数据时，这种做法是很不方便的。我们可通过恢复索引，对数据进行排序，这样操作起来会方便很多，如图3.26所示。

原索引可通过drop参数进行删除，如图3.27所示。

```
df3 = df2.reset_index()
df3
```

	index	grade	name
0	2	63	王五
1	0	68	张三
2	1	78	李四
3	3	92	小明

图3.26　索引重排

```
df4 = df2.reset_index(drop=True)
df4
```

	grade	name
0	63	王五
1	68	张三
2	78	李四
3	92	小明

图3.27　删除原索引

3.2.3　索引和选取

在数据分析中，选取需要的数据进行处理和分析是很重要的。在Excel表格中，通过鼠标点选或扩选可以轻松地选取数据，而在pandas数据中，需要通过索引来完成数据的选取工作。

Series数据的选取较为简单，使用方法类似于Python的列表，这里不仅可以通过0到N-1（N是数据长度）来进行索引，同时也可以通过设置好的索引标签来进行索引，如图3.28所示。

```
obj = Series([1, -2, 3, -4], index=['a', 'b', 'c', 'd'])
obj
```

```
a    1
b   -2
c    3
d   -4
dtype: int64
```

```
obj[1]
```

```
-2
```

```
obj['b']
```

```
-2
```

```
obj[['a','c']]
```

```
a    1
c    3
dtype: int64
```

图3.28　Series索引

切片运算与Python列表略有不同，如果是利用索引标签切片，其尾端是被包含的，如图3.29所示。

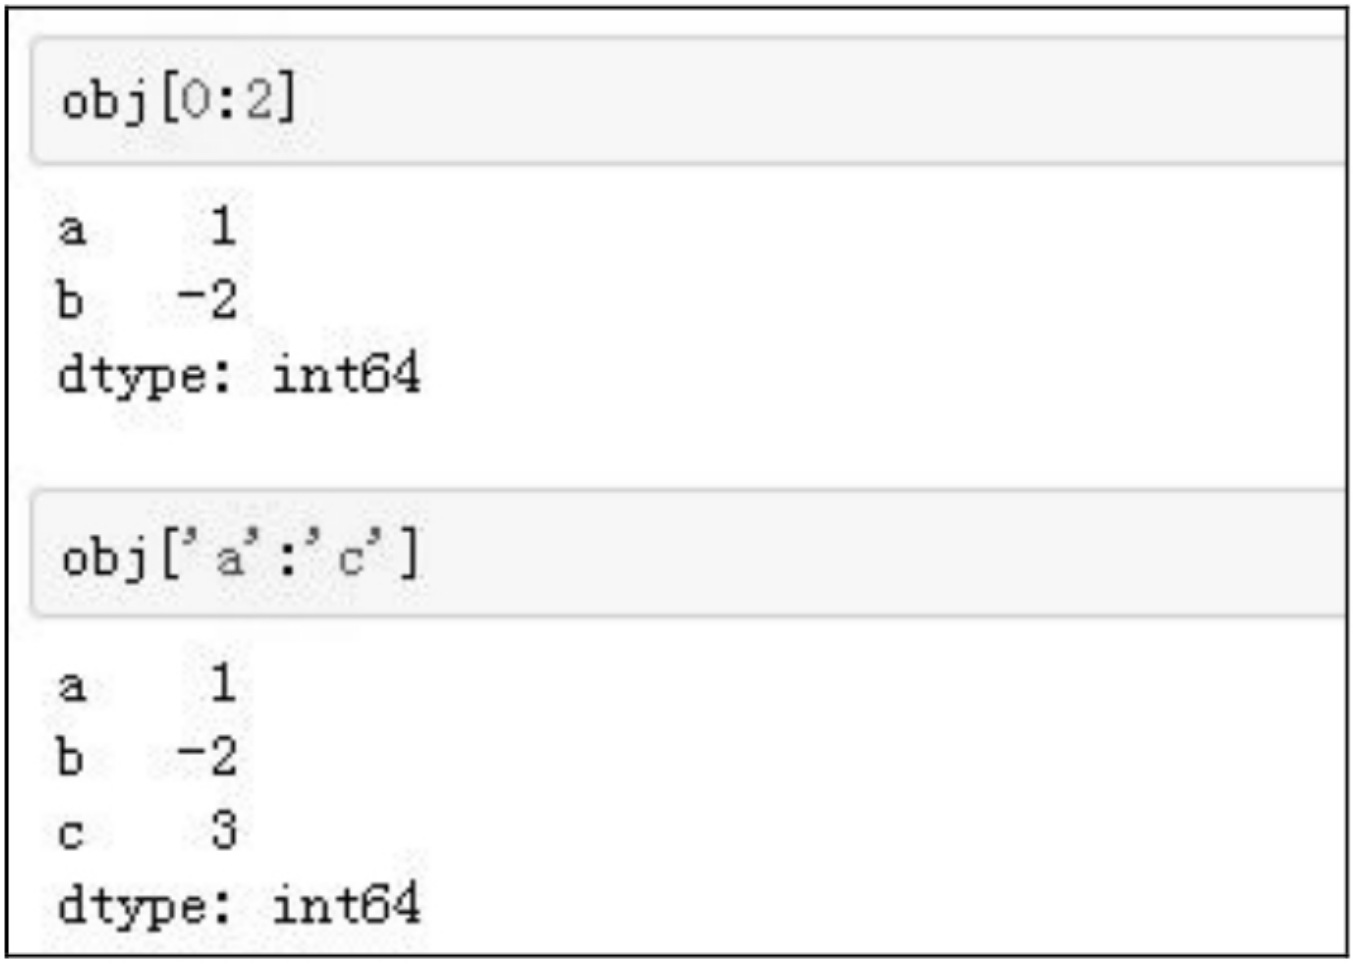

图3.29 Series切片

DataFrame数据的选取更复杂些，因为它是二维数组，选取列和行都有具体的使用方法。接下来将重点介绍DataFrame数据的选取。

1．选取列

通过列索引标签或以属性的方式可以单独获取DataFrame的列数据，返回的数据为Series结构，如图3.30所示。

通过两个中括号，可以获取多个列的数据，如图3.31所示。

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	female	2001
2	广州	王五	male	2003
3	北京	小明	male	2002

```
df['city']
```

```
0    北京
1    上海
2    广州
3    北京
Name: city, dtype: object
```

```
df.name
```

```
0    张三
1    李四
2    王五
3    小明
Name: name, dtype: object
```

图3.30　选取单独列

```
df[['city','sex']]
```

	city	sex
0	北京	female
1	上海	female
2	广州	male
3	北京	male

图3.31　选取多列

注意：选取列不能使用切片，因为切片用于选取行数据。

2．选取行

通过行索引标签或行索引位置（0到N-1）的切片形式可选取DataFrame的行数据，如图3.32和图3.33所示。

```
df2 = df.set_index('name')
df2
```

name	city	sex	year
张三	北京	female	2001
李四	上海	female	2001
王五	广州	male	2003
小明	北京	male	2002

```
df2[0:2]
```

name	city	sex	year
张三	北京	female	2001
李四	上海	female	2001

图3.32　选取行1

```
df2['李四':'王五']
```

name	city	sex	year
李四	上海	female	2001
王五	广州	male	2003

图3.33　选取行2

显然，切片方法选取行有很大的局限性。如果想获取单独的几行，通过loc和iloc方法可以实现。loc方法是按行索引标签选取数据，如图3.34所示；iloc方法是按行索引位置选取数据，如图3.35所示。

```
df2.loc['张三']
```

```
city        北京
sex       female
year        2001
Name: 张三, dtype: object
```

```
df2.loc[['张三','王五']]
```

name	city	sex	year
张三	北京	female	2001
王五	广州	male	2003

图3.34　通过loc方法选取行

```
df2.iloc[1]
```

```
city        上海
sex       female
year        2001
Name: 李四, dtype: object
```

```
df2.iloc[[1,3]]
```

name	city	sex	year
李四	上海	female	2001
小明	北京	male	2002

图3.35　通过iloc方法选取行

3．选取行和列

在数据分析中，有时可能只是对部分行和列进行操作，这时就需要选取DataFrame数据中行和列的子集，而通过ix方法就可以轻松地完成。ix方法同时支持索引标签和索引位置来进行数据的选取，如图3.36所示。

其实，ix方法除了可以选取部分行和列外，也可以选取单独的行或者列，如图3.37所示。

```
df2.ix[['张三','王五'],0:2]
```

name	city	sex
张三	北京	female
王五	广州	male

图3.36　通过ix方法选取行和列

```
df2.ix[:,['sex','year']] #获取列
```

name	sex	year
张三	female	2001
李四	female	2001
王五	male	2003
小明	male	2002

```
df2.ix[[1,3],:] #获取行
```

name	city	sex	year
李四	上海	female	2001
小明	北京	male	2002

图3.37　通过ix获取单独的行和列

4．布尔选择

以df 2为例，筛选出性别为female的数据，这时就需要通过布尔选择来完成，如图3.38所示。

与数组布尔型索引类似，既然可以使用布尔选择，那么同样也适用于不等于符号（！=）、负号（-）、和（&）、或（|），如图3.39所示。

```
df2['sex'] == 'female'
```

```
name
张三     True
李四     True
王五    False
小明    False
Name: sex, dtype: bool
```

```
df2[df2['sex'] == 'female']
```

name	city	sex	year
张三	北京	female	2001
李四	上海	female	2001

图3.38　布尔选择1

```
df2[(df2['sex'] == 'female') & (df2['city'] == '北京')]
```

name	city	sex	year
张三	北京	female	2001

图3.39　布尔选择2

3.2.4　操作行和列

在数据分析中，常用的基本操作为“增、删、改、查”，查（选取）在前面内容中已经详细讲解过，本节主要讲解其余的3个操作。

1．增加

以df数据为例，该班级转来了一个新生，需要在原有数据的基础上增加一行数据。可以通过append函数传入字典结构数据即可，如图3.40所示。

```
new_data = {
    'city':'武汉',
    'name':'小李',
    'sex':'male',
    'year':2002
}
```

```
df = df.append(new_data,ignore_index=True) #忽略索引值
df
```

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	female	2001
2	广州	王五	male	2003
3	北京	小明	male	2002
4	武汉	小李	male	2002

图3.40　新增行

这些学生都是2018级的，这里我们新建一列用于存放该信息。为一个不存在的列赋值，即可创建一个新列，如图3.41所示。

如果要新增的列中的数值不一样时，可以传入列表或数组结构数据进行赋值，如图3.42所示。

```
df['class'] = 2018
df
```

	city	name	sex	year	class
0	北京	张三	female	2001	2018
1	上海	李四	female	2001	2018
2	广州	王五	male	2003	2018
3	北京	小明	male	2002	2018
4	武汉	小李	male	2002	2018

图3.41　新增列1

```
df['math'] = [92,78,58,69,82]
df
```

	city	name	sex	year	class	math
0	北京	张三	female	2001	2018	92
1	上海	李四	female	2001	2018	78
2	广州	王五	male	2003	2018	58
3	北京	小明	male	2002	2018	69
4	武汉	小李	male	2002	2018	82

图3.42　新增列2

2．删除

如果王五同学转学了，class字段没有用了，就需要删除其信息。通过drop方法可以删除指定轴上的信息，如图3.43所示。

```
new_df = df.drop(2)  #删除行
new_df
```

	city	name	sex	year	class	math
0	北京	张三	female	2001	2018	92
1	上海	李四	female	2001	2018	78
3	北京	小明	male	2002	2018	69
4	武汉	小李	male	2002	2018	82

```
new_df = new_df.drop('class',axis=1)  #删除列
new_df
```

	city	name	sex	year	math
0	北京	张三	female	2001	92
1	上海	李四	female	2001	78
3	北京	小明	male	2002	69
4	武汉	小李	male	2002	82

图3.43　删除行和列

3．修改

这里的“改”指的是行和列索引标签的修改，通过rename函数，可完成由于某些原因导致的标签录入错误的问题，如图3.44所示。

```
new_df.rename(index={3:2,4:3},columns={'math':'Math'},inplace=True)  #inplace可在原数据上修改
new_df
```

	city	name	sex	year	Math
0	北京	张三	female	2001	92
1	上海	李四	female	2001	78
2	北京	小明	male	2002	69
3	武汉	小李	male	2002	82

图3.44　修改标签名

3.3　pandas数据运算

本节将针对Series和DataFrame数据，详细讲解二者的算术运行和函数的应用，这在数据分析中会经常使用，读者需要认真学习。

3.3.1　算术运算

pandas的数据对象在进行算术运算时，如果有相同索引对则进行算术运算，如果没有则会引入缺失值，这就是数据对齐。下面通过图3.45来看看Series数据的算术运算。

```
obj1 = Series([3.2,5.3,-4.4,-3.7],index=['a','c','g','f'])
obj1
```

```
a    3.2
c    5.3
g   -4.4
f   -3.7
dtype: float64
```

```
obj2 = Series([5.0,-2,4.4,3.4],index=['a','b','c','d'])
obj2
```

```
a    5.0
b   -2.0
c    4.4
d    3.4
dtype: float64
```

```
obj1 + obj2
```

```
a    8.2
b    NaN
c    9.7
d    NaN
f    NaN
g    NaN
dtype: float64
```

图3.45　Series数据运算

对于DataFrame数据而言，对齐操作会同时发生在行和列上，如图3.46所示。

```
df1 = DataFrame(np.arange(9).reshape(3,3),columns=['a','b','c'], index=['apple','tea','banana'])
df1
```

	a	b	c
apple	0	1	2
tea	3	4	5
banana	6	7	8

```
df2 = DataFrame(np.arange(9).reshape(3,3),columns=['a','b','d'], index=['apple','tea','coco'])
df2
```

	a	b	d
apple	0	1	2
tea	3	4	5
coco	6	7	8

```
df1 + df2
```

	a	b	c	d
apple	0.0	2.0	NaN	NaN
banana	NaN	NaN	NaN	NaN
coco	NaN	NaN	NaN	NaN
tea	6.0	8.0	NaN	NaN

图3.46　DataFrame数据运算

DataFrame和Series数据在进行运算时，先通过Series的索引匹配到相应的DataFrame列索引上，然后沿行向下运算（广播），如图3.47所示。

```
df1
```

	a	b	c
apple	0	1	2
tea	3	4	5
banana	6	7	8

```
s = df1.ix['apple']
s
```

```
a    0
b    1
c    2
Name: apple, dtype: int32
```

```
df1 - s
```

	a	b	c
apple	0	0	0
tea	3	3	3
banana	6	6	6

图3.47　Series与DataFrame运算

3.3.2　函数应用和映射

在数据分析时，常常会对数据进行较复杂的数据运算，这时需要定义函数。定义好的函数可以应用到pandas数据中，其中有三种方法：map函数，将函数套用在Series的每个元素中；apply函数，将函数套用到DataFrame的行与列上；applymap函数，将函数套用到DataFrame的每个元素上。

如图3.48所示，需要把price列的“元”字去掉，这时就需要用到map函数，使用方法如图3.49所示。

```
data = {
    'fruit':['apple', 'orange', 'grape', 'banana'],
    'price':['25元', '42元', '35元', '14元']
}
df1 = DataFrame(data)
df1
```

	fruit	price
0	apple	25元
1	orange	42元
2	grape	35元
3	banana	14元

图3.48　数据

```
def f(x):
    return x.split('元')[0]
df1['price'] = df1['price'].map(f)
df1
```

	fruit	price
0	apple	25
1	orange	42
2	grape	35
3	banana	14

图3.49　使用map函数

apply函数的使用方法如图3.50所示。

```
df2 = DataFrame(np.random.randn(3,3),columns=['a','b','c'],index=['app','win','mac'])
df2
```

	a	b	c
app	1.507962	-2.140018	0.053571
win	0.729671	0.207060	0.397773
mac	-0.191497	-0.765726	-0.266327

```
f = lambda x:x.max()-x.min()
df2.apply(f)
```

```
a    1.699460
b    2.347079
c    0.664100
dtype: float64
```

图3.50　使用apply函数

注意：lambda为匿名函数，和定义好的函数一样，可以节省代码量。

applymap函数可作用于每个元素，便于对整个DataFrame数据进行批量处理，如图3.51所示。

```
df2
```

	a	b	c
app	1.507962	-2.140018	0.053571
win	0.729671	0.207060	0.397773
mac	-0.191497	-0.765726	-0.266327

```
df2.applymap(lambda x:'%.2f'%x)
```

	a	b	c
app	1.51	-2.14	0.05
win	0.73	0.21	0.40
mac	-0.19	-0.77	-0.27

图3.51　使用applymap函数

3.3.3　排序

在Series中，通过sort_index函数可对索引进行排序，默认情况为升序，如图3.52所示。

```
obj1 = Series([-2,3,2,1],index=['b','a','d','c'])
obj1
```

```
b   -2
a    3
d    2
c    1
dtype: int64
```

```
obj1.sort_index()     #升序
```

```
a    3
b   -2
c    1
d    2
dtype: int64
```

```
obj1.sort_index(ascending=False)   #降序
```

```
d    2
c    1
b   -2
a    3
dtype: int64
```

图3.52　Series索引排序

通过sort_values方法可对值进行排序，如图3.53所示。

对于DataFrame数据而言，通过指定轴方向，使用sort_index函数可对行或者列索引进行排序，这里不多做示例了。要根据列进行排序，可以通过sort_values函数，把列名传给by参数即可，如图3.54所示。

```
obj1.sort_values()
```

```
b   -2
c    1
d    2
a    3
dtype: int64
```

图3.53　Series值排序

```
df2
```

	a	b	c
app	1.507962	-2.140018	0.053571
win	0.729671	0.207060	0.397773
mac	-0.191497	-0.765726	-0.266327

```
df2.sort_values(by='b')
```

	a	b	c
app	1.507962	-2.140018	0.053571
mac	-0.191497	-0.765726	-0.266327
win	0.729671	0.207060	0.397773

图3.54　DataFrame列排序

3.3.4　汇总与统计

在DataFrame数据中，通过sum函数可以对每列进行求和汇总，与Excel中的sum函数类似，如图3.55所示。

```
df = DataFrame(np.random.randn(9).reshape(3,3),columns=['a','b','c'])
df
```

	a	b	c
0	0.660215	-1.137716	-0.302954
1	1.496589	-0.768645	-2.091506
2	0.170316	-2.682284	-0.041099

```
df.sum()
```

```
a    2.327120
b   -4.588645
c   -2.435558
dtype: float64
```

图3.55　按列汇总

指定轴方向，通过sum函数可按行汇总，如图3.56所示。

describe方法可对每个数值型列进行统计，经常用于对数据的初步观察时使用，如图3.57所示。

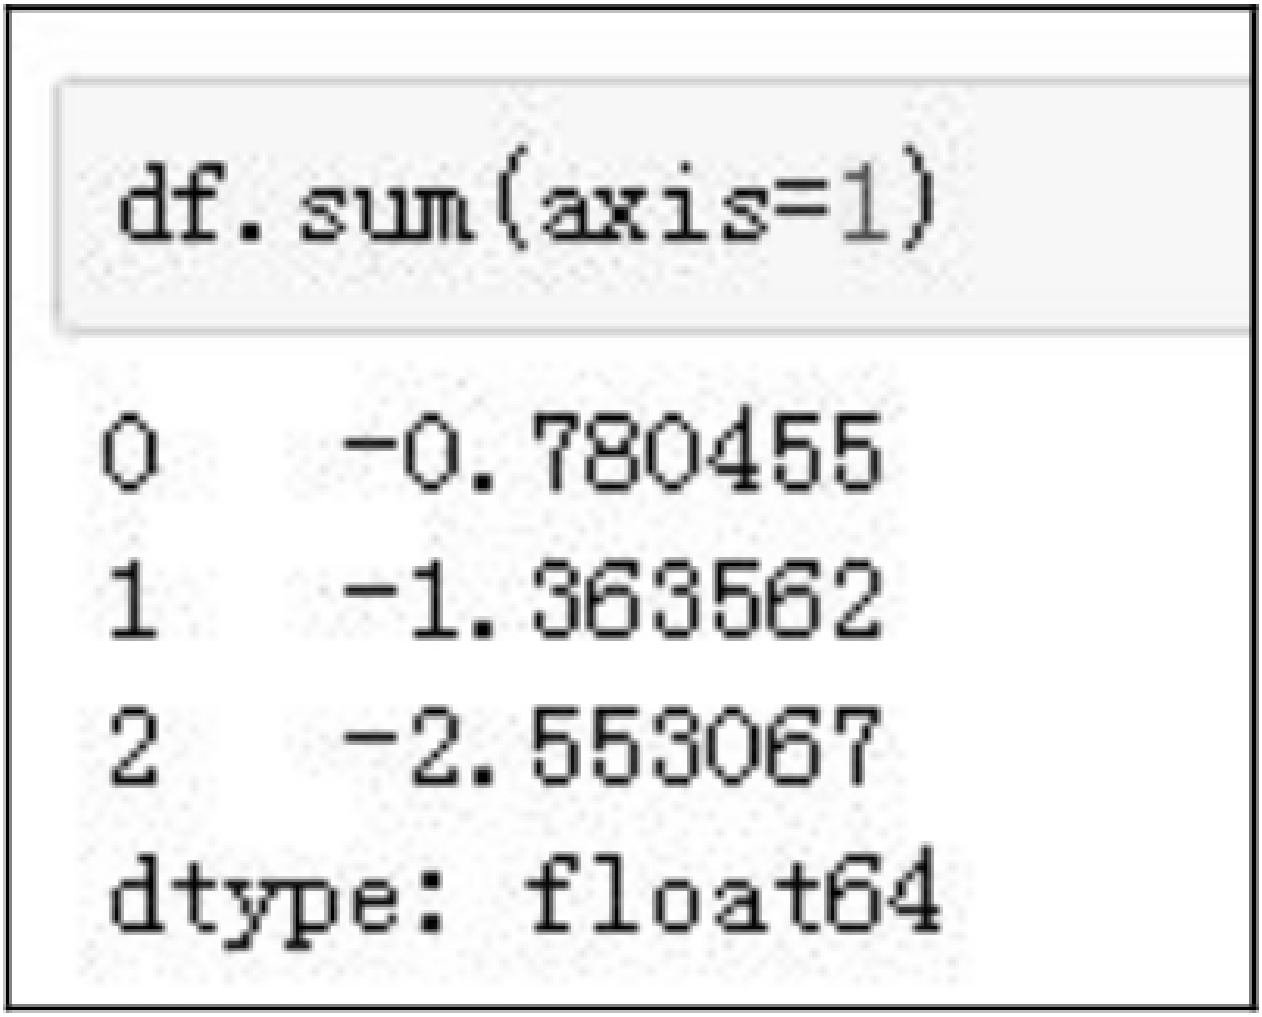

图3.56　按行汇总

	city	math	name	sex
0	北京	78	张三	female
1	上海	79	李四	female
2	广州	83	王五	male
3	北京	92	小明	male

```
df.describe()
```

	math
count	4.000000
mean	83.000000
std	6.377042
min	78.000000
25%	78.750000
50%	81.000000
75%	85.250000
max	92.000000

图3.57　汇总统计

3.3.5　唯一值和值计数

在Series中，通过unique函数可以获取不重复的数组，如图3.58所示。

通过values_counts方法可统计每个值出现的次数，如图3.59所示。

```
obj = Series(['a','b','a','c','b'])
obj
```

```
0    a
1    b
2    a
3    c
4    b
dtype: object
```

```
obj.unique()
```

```
array(['a', 'b', 'c'], dtype=object)
```

图3.58　唯一值

```
obj.value_counts()
```

```
a    2
b    2
c    1
dtype: int64
```

图3.59　值计数

注意：对于DataFrame的列而言，unique函数和values_counts方法同样适用，这里不再举例。

3.4　层次化索引

层出化索引是pandas重要的功能之一，本节将简单讲解层次化索引的创建过程和使用方法。

3.4.1　层次化索引简介

简单地说，层出化索引就是轴上有多个级别索引，如图3.60所示为创建一个层次化索引的Series对象。

```
obj = Series(np.random.randn(9),
             index=[['one','one','one','two','two','two','three','three','three'],
                    ['a','b','c','a','b','c','a','b','c']])
obj
```

```
one    a    0.697195
       b   -0.887408
       c    0.451851
two    a    0.390779
       b   -2.058070
       c    0.760594
three  a   -0.305534
       b   -0.720491
       c   -0.259225
dtype: float64
```

图3.60　Series层次化索引

该索引对象为MultiIndex对象，如图3.61所示。

层次化索引的对象，索引和选取操作都很简单，如图3.62所示。

```
obj.index
```

```
MultiIndex(levels=[['one', 'three', 'two'], ['a', 'b', 'c']],
           labels=[[0, 0, 0, 2, 2, 2, 1, 1, 1], [0, 1, 2, 0, 1, 2, 0, 1, 2]])
```

图3.61　MultiIndex对象

```
obj['two']
```

```
a    0.390779
b   -2.058070
c    0.760594
dtype: float64
```

```
obj[:,'a']  #内层选取
```

```
one      0.697195
two      0.390779
three   -0.305534
dtype: float64
```

图3.62　数据选取

对于DataFrame数据而言，行和列索引都可以为层次化索引，如图3.63所示。选取数据也很简单，如图3.64所示。

```
df = DataFrame(np.arange(16).reshape(4,4),
               index=[['one','one','two','two'],['a','b','a','b']],
               columns=[['apple','apple','orange','orange'],['red','green','red','green']])
df
```

		apple		orange	
		red	green	red	green
one	a	0	1	2	3
	b	4	5	6	7
two	a	8	9	10	11
	b	12	13	14	15

图3.63　DataFrame层次化索引

```
df['apple']
```

		red	green
one	a	0	1
	b	4	5
two	a	8	9
	b	12	13

图3.64　数据选取

3.4.2　重排分级顺序

通过swaplevel方法可以对层次化索引进行重排，如图3.65所示。

```
df.swaplevel(0,1)
```

		apple		orange	
		red	green	red	green
a	one	0	1	2	3
b	one	4	5	6	7
a	two	8	9	10	11
b	two	12	13	14	15

图3.65　重排分级顺序

3.4.3　汇总统计

在对层次化索引的pandas数据进行汇总统计时，可以通过level参数指定在某层次上进行汇总统计，如图3.66所示。

```
df.sum(level=0)
```

	apple		orange	
	red	green	red	green
one	4	6	8	10
two	20	22	24	26

```
df.sum(level=1,axis=1)
```

		green	red
one	a	4	2
	b	12	10
two	a	20	18
	b	28	26

图3.66　根据级别汇总统计

注意：层次化索引的用途在后面会详细讲解。

3.5　pandas可视化

pandas库中集成了matplotlib中的基础组件，让绘图更加简单。本节将讲解如何利用pandas绘制基本图形。

3.5.1　线形图

线形图通常用于描绘两组数据之间的趋势。例如，销售行中月份与销售量之间的趋势情况；金融行中股票收盘价与时间序列之间的走势。

pandas库中的Series和DataFrame中都有绘制各类图表的plot方法，默认情况绘制的是线形图。下面首先创建一个Series对象，如图3.67所示。

```
import numpy as np
from pandas import Series,DataFrame
import pandas as pd
import matplotlib as mpl
import matplotlib.pyplot as plt  #导入matplotlib库
%matplotlib inline    #魔法函数
```

```
s = Series(np.random.normal(size=10))
s
```

```
0   -0.468142
1   -1.408927
2   -0.182548
3   -0.043023
4    0.121437
5    0.539194
6    0.011423
7   -0.938207
8    1.589460
9    0.460753
dtype: float64
```

图3.67　Series数据

注意：%matplotlib inline为魔法函数，使用该函数绘制的图片会直接显示在Notebook中。

通过s.plot方法可以绘制线形图，如图3.68所示。从图中可以看出，Series的索引作为X轴，值为Y轴。

```
s.plot()
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xafc5390>
```

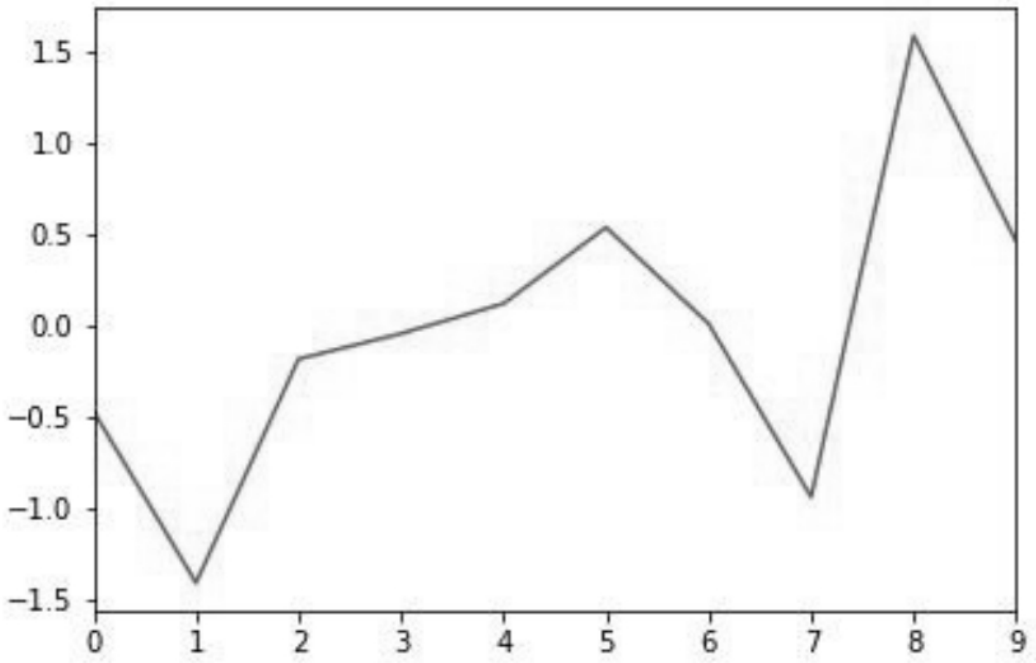

图3.68　Series的线形图

通过DataFrame数据的plot方法可以为各列绘制一条线，并会给其创建好图例。首先创建DataFrame数据，如图3.69所示。

```
df = DataFrame({'normal': np.random.normal(size=100),
                'gamma': np.random.gamma(1, size=100),
                'poisson': np.random.poisson(size=100)})
df.cumsum()
```

	gamma	normal	poisson
0	1.804045	1.788000	0.0
1	1.835715	0.089426	0.0
2	3.850210	0.870177	0.0
3	6.082898	0.902761	0.0
4	8.837446	0.959945	1.0
5	9.307126	1.658268	3.0

图3.69　DataFrame数据

绘制的图如图3.70所示。

注意：关于pandas绘图的参数，会在实际案例中具体介绍。

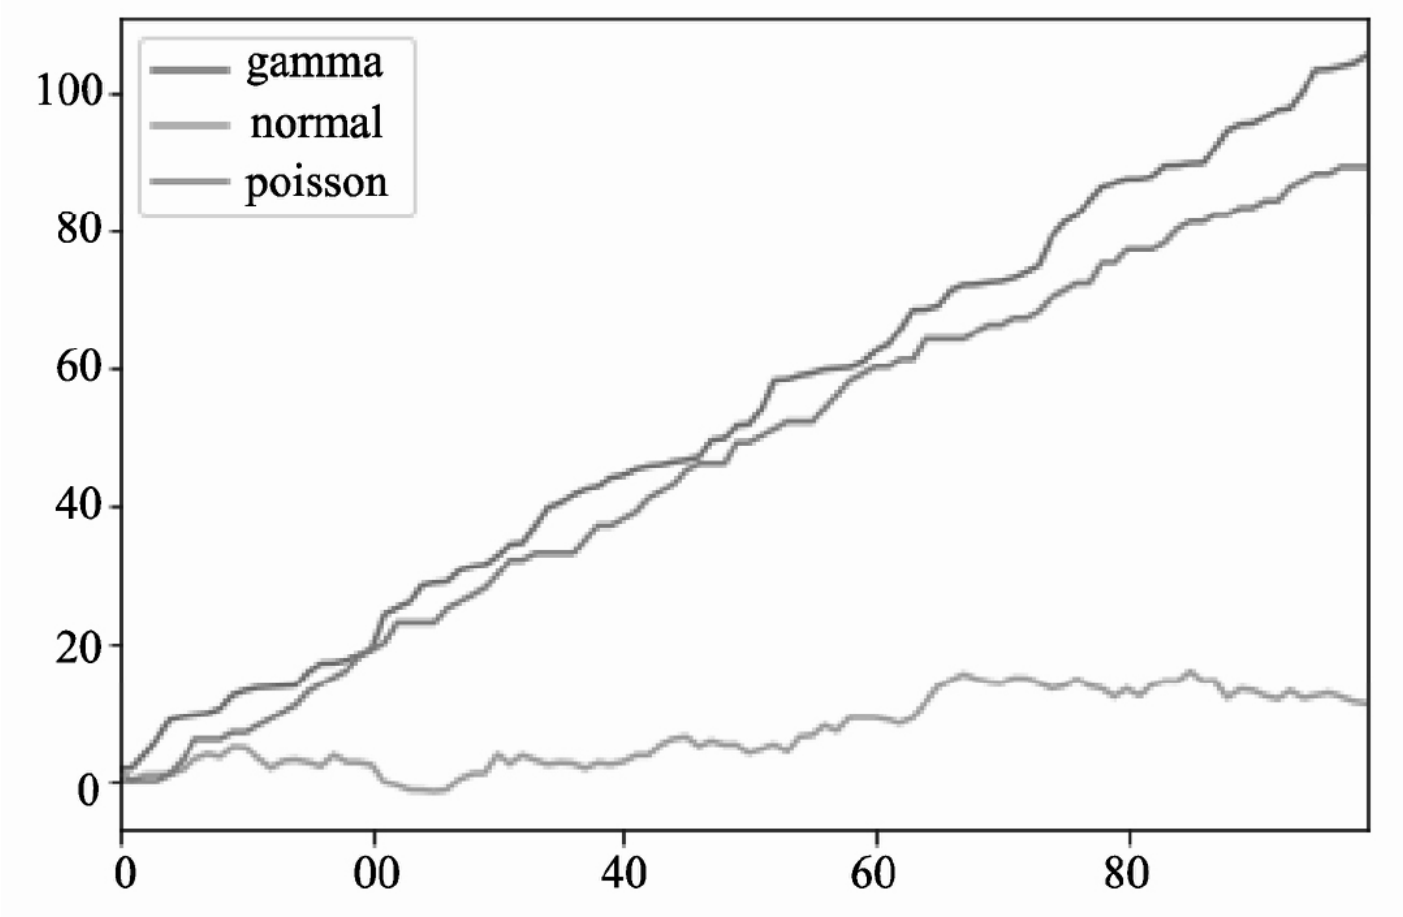

图3.70　DataFrame的线形图

3.5.2　柱状图

柱状图常描绘各类别之间的关系。例如，班级中男生和女生的分布情况；某零售店各商品的购买数量分布情况。通过pandas绘制柱状图很简单，只需要在plot函数中加入kind= ‘bar’ ，如果类别较多，可绘制水平柱状图（kind= ‘barh’ ）。

首先，创建一个DataFrame数据的学生信息表格，如果需要分析班级的男女比例是否平衡，这时就可以使用柱状图，通过value_counts计数，获取男女计数的Series数据，进而绘制柱状图，如图3.71和图3.72所示。

```
data = {
    'name':['张三', '李四', '王五', '小明', 'Peter'],
    'sex':['female', 'female', 'male', 'male','male'],
    'year':[2001, 2001, 2003, 2002, 2002],
    'city':['北京', '上海', '广州', '北京', '北京']
}
df = DataFrame(data)
df
```

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	female	2001
2	广州	王五	male	2003
3	北京	小明	male	2002
4	北京	Peter	male	2002

```
df['sex'].value_counts()
```

```
male      3
female    2
Name: sex, dtype: int64
```

图3.71　男女计数

```
df['sex'].value_counts().plot(kind='bar')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xaf1ac50>
```

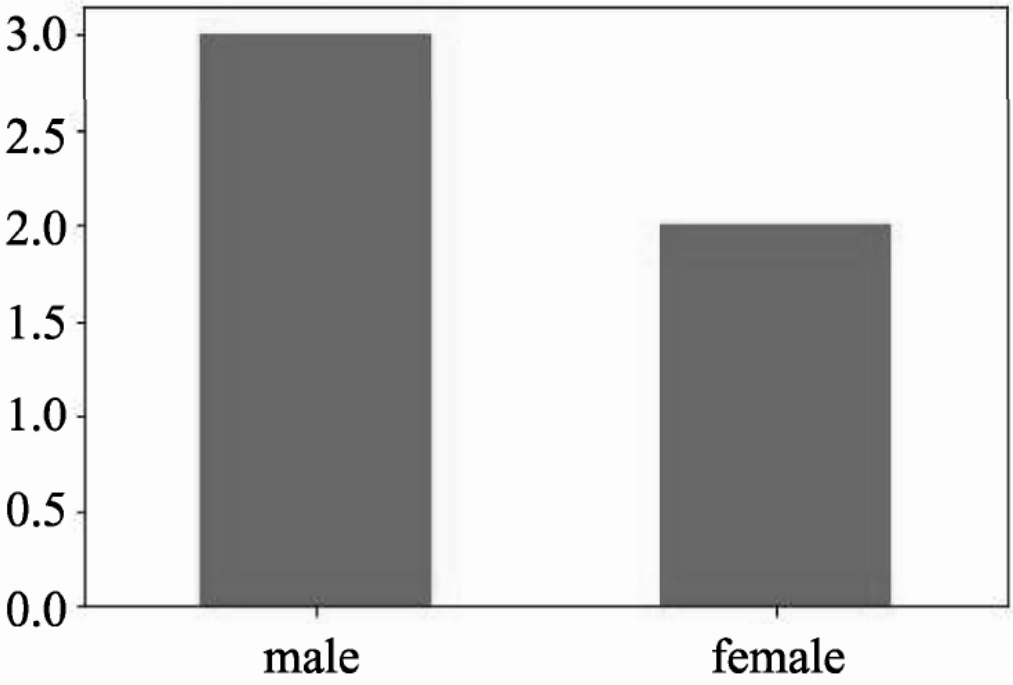

图3.72　班级学生性别分布情况

对于DataFrame数据而言，每一行的值会成为一组，如图3.73和图3.74所示。

说明：可视化效果会用不同的颜色来代表不同的类，鉴于本书是黑白印刷，读者可用代码实践一下，观察实际的图片效果。后面类似问题不再说明。

```
df2 = DataFrame(np.random.randint(0,100,size=(3,3)),
                index=('one','two','three'),
                columns = ['A','B','C'])
df2
```

	A	B	C
one	29	5	88
two	35	42	43
three	87	85	76

图3.73　DataFrame数据

```
df2.plot(kind='barh')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xb5b53c8>
```

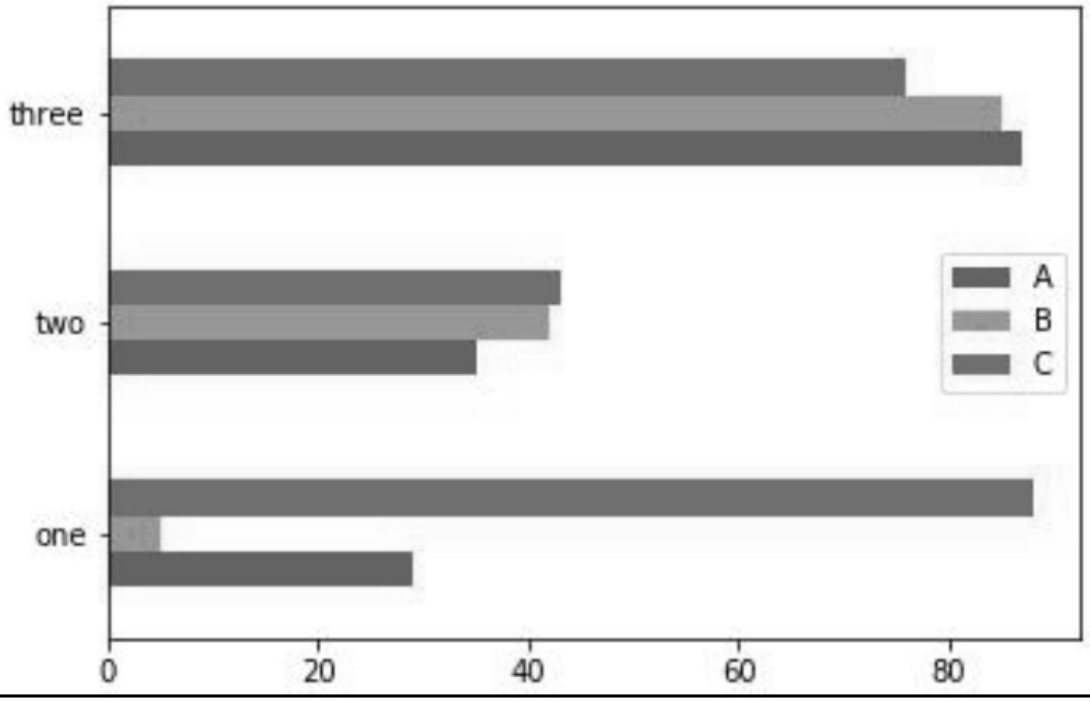

图3.74　DataFrame数据的柱状图

设置plot函数的stacked参数，可以绘制堆积柱状图，如图3.75所示。

```
df2.plot(kind='barh',stacked=True,alpha=0.5)
<matplotlib.axes._subplots.AxesSubplot at 0xd576cf8>
```

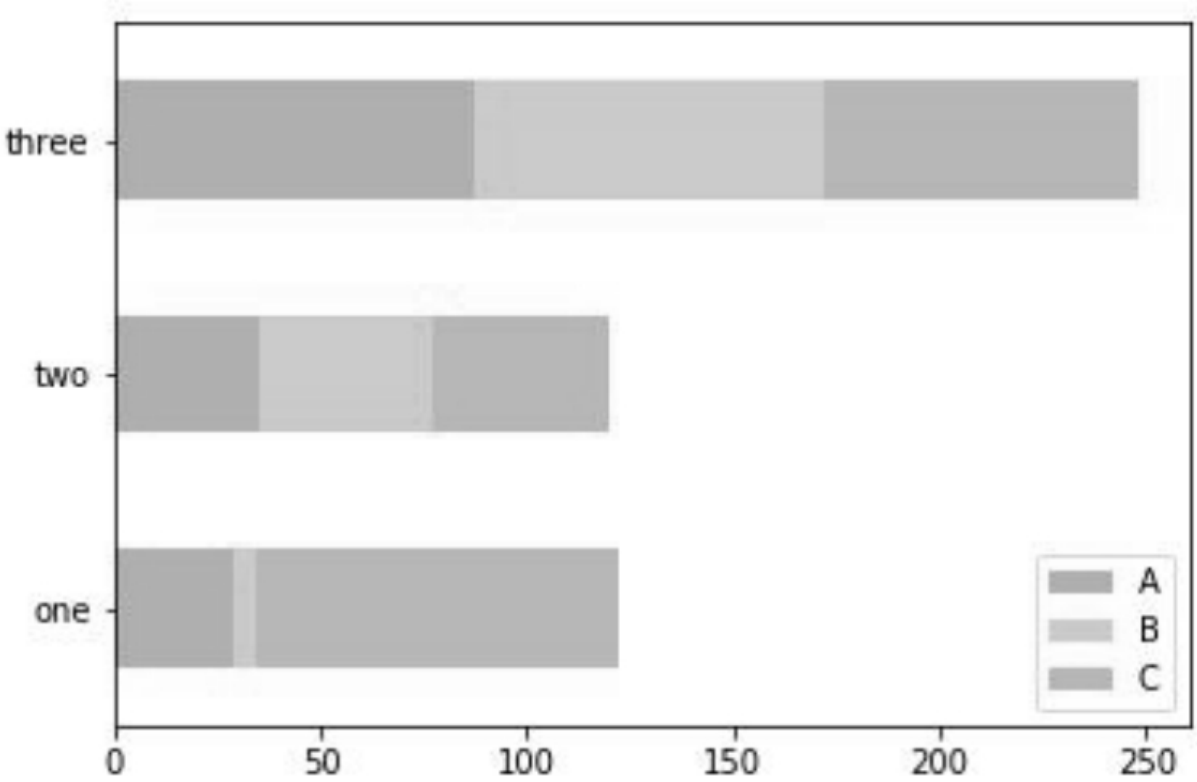

图3.75　堆积柱状图

说明：plot函数的alpha参数可设置颜色透明度。

3.5.3　直方图和密度图

直方图用于频率分布，y轴可为数值或者比率。直方图在统计分析中是经常使用的，绘制数据的直方图，可以看出其大概分布规律。例如，某班级的身高情况一般是服从正态分布，即高个子和矮个子的人较少，大部分都是在平均身高左右。

可以通过hist方法绘制直方图，如图3.76所示。

注意：通过设置grid参数可在图表中添加网格；bins参数是将值分为多少段，默认为10。

核密度估计（Kernel Density Estimate，KDE）是对真实密度的估计，其过程是将数据的分布近似为一组核（如正态分布）。通过plot函数的kind='kde'可进行绘制，如图3.77所示。

```
s = Series(np.random.normal(size=100))
s.hist(bins=20,grid=False)
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xcf9f5c0>
```

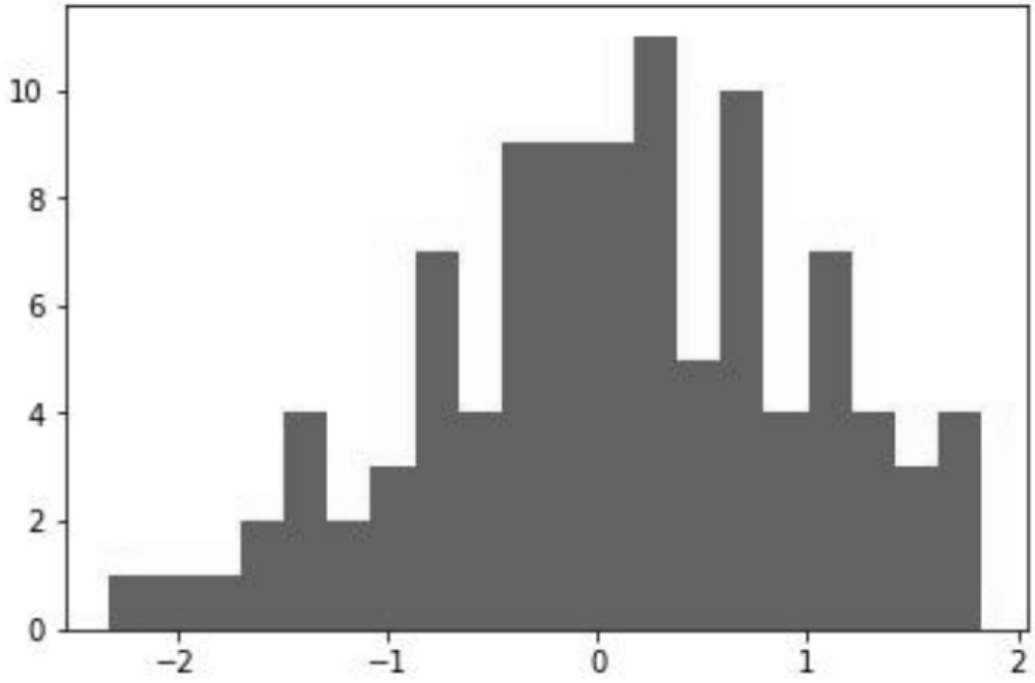

图3.76　直方图

```
s.plot(kind='kde')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xd266710>
```

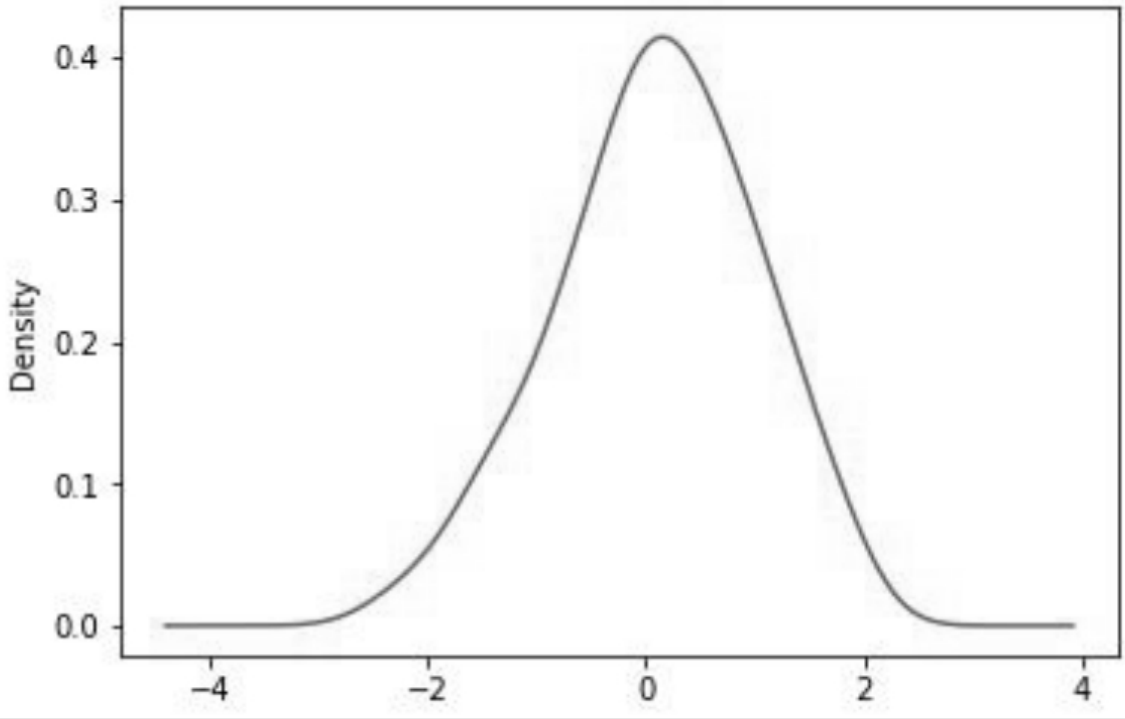

图3.77　密度图

3.5.4　散点图

散点图主要用来表现数据之间的规律。例如，身高和体重之间的规律。下面创建一个DataFrame数据，然后绘制散点图，如图3.78和图3.79所示。

```
df3 = DataFrame(np.arange(10),columns=['X'])
df3['Y'] = 2 * df3['X'] + 5
df3
```

	X	Y
0	0	5
1	1	7
2	2	9
3	3	11
4	4	13
5	5	15
6	6	17
7	7	19
8	8	21
9	9	23

图3.78　数据

```
df3.plot(kind='scatter',x='X',y='Y')
<matplotlib.axes._subplots.AxesSubplot at 0xb1f98d0>
```

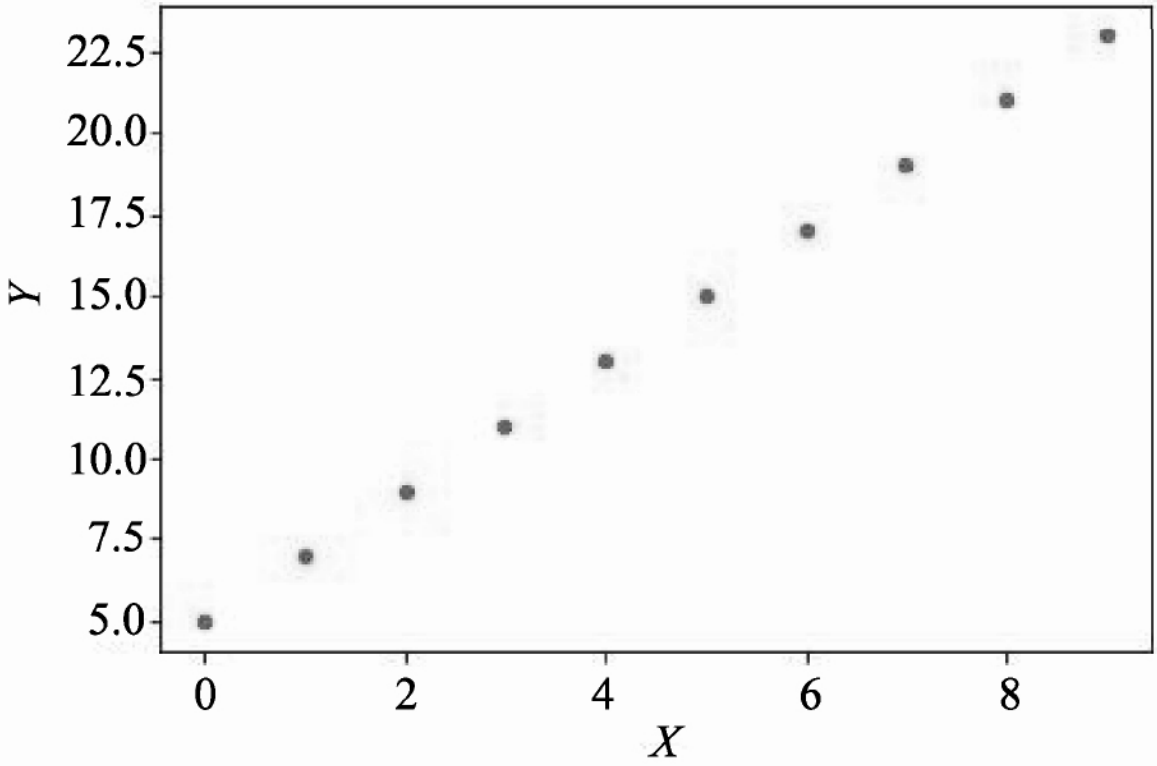

图3.79　散点图

3.6　综合示例——小费数据集

本节主要讲解数据分析的基本流程，对小费数据集进行数据的分析与可视化。

3.6.1　数据分析流程

数据分析的流程通常情况下分为5步。

（1）收集数据。在这一步中，需要对收集的数据有一定的认知，对各字段的含义和背景知识都要有着足够的理解。

（2）定义问题。根据各自的行业和业务知识，对数据定义多个待解决的问题。

（3）数据清洗与整理。由于各种问题，获取的数据不够“干净”，需通过各种手段对数据进行清洗与整理，以便得到准确的分析结果。

（4）数据探索。通过可视化等手段，对数据进行分析和探索，得出结论。

（5）数据展示。这部分用于输出，或撰写数据分析报告、或汇报给上级、或绘制PPT。

以上只是基本的数据分析流程，根据实际情况会略有不同。例如，在实际工作中，第（1）步和第（2）步可能会顺序颠倒，首先需要明确目标，然后再根据目标收集数据；在数据探索方面，也会使用数据挖掘等技术实现更具复杂和有实际操作意义的模型。但本书中的数据分析案例是按照以上的流程进行讲解（不讲解第（5）步）。

3.6.2　数据来源

小费数据集来源于Python第三方库seaborn（用于绘图）中自带的数据，加载该数据集，如图3.80所示。

```
import numpy as np
from pandas import Series,DataFrame
import pandas as pd
import seaborn as sns    #导入seaborn库
```

```
tips=sns.load_dataset('tips')
tips.head()
```

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

图3.80　小费数据集

注意：head函数会返回前5条数据，也可指定返回数据行数。

众所周知，在西方国家的服务行业中，顾客会给予服务员一定金额的小费。该小费数据为餐饮行业收集的数据。total_bill列为消费总金额；tip列为小费金额；sex列为顾客性别；smoker列为顾客是否抽烟；day列为消费的星期；time列为聚餐的时间段；size列为聚餐人数。

3.6.3　定义问题

本次分析中，围绕小费数据集提出几个问题：小费金额与消费总金额是否存在相关性？性别、是否吸烟、星期几、中/晚餐、聚餐人数和小费金额是否有一定的关联？小费金额占消费总金额的百分比服从正态分布？

3.6.4　数据清洗

首先对数据进行简单描述，看是否有缺失值或者异常值，如图3.81所示。

```
tips.shape
```

```
(244, 7)
```

```
tips.describe()
```

	total_bill	tip	size
count	244.000000	244.000000	244.000000
mean	19.785943	2.998279	2.569672
std	8.902412	1.383638	0.951100
min	3.070000	1.000000	1.000000
25%	13.347500	2.000000	2.000000
50%	17.795000	2.900000	2.000000
75%	24.127500	3.562500	3.000000
max	50.810000	10.000000	6.000000

图3.81　描述统计

通过结果可以看出，总共有244条数据，通过统计暂时看不出是否有缺失值。通过打印数据的info信息可以看出每列数据的类型和缺失值，本例中的小费数据集没有缺失值，如图3.82所示。

注意：本例数据非常“干净”，数据清洗的内容将在后面内容中详细讲解。

```
tips.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 244 entries, 0 to 243
Data columns (total 7 columns):
total_bill    244 non-null float64
tip           244 non-null float64
sex           244 non-null category
smoker        244 non-null category
day           244 non-null category
time          244 non-null category
size          244 non-null int64
dtypes: category(4), float64(2), int64(1)
memory usage: 7.2 KB
```

图3.82　查看缺失值

3.6.5　数据探索

首先对小费金额与消费总金额进行分析，看看它们之间是否有关联，通过下面代码绘制散点图，如图3.83所示。

```
tips.plot(kind='scatter',x='total_bill',y='tip')
```

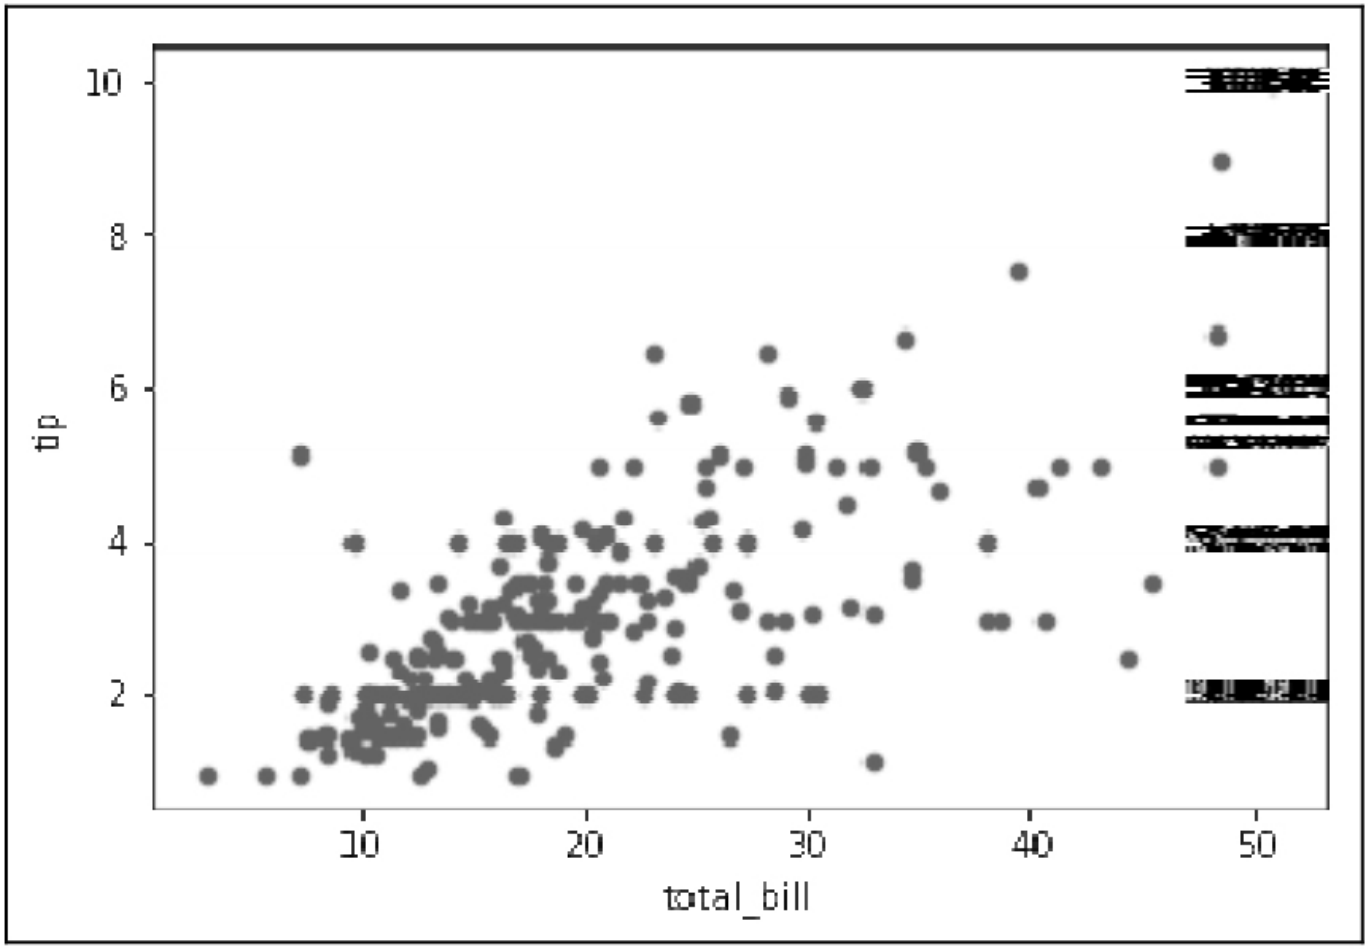

图3.83　小费金额与消费总金额散点图

通过图3.83可以看出，小费金额与消费总金额存在着正相关的关系，即消费的金额越多，给的小费也就越多，这是比较合理的。

我们再来看看性别不一样是否会影响小费的金额。这里使用柱状图，通过布尔选择男女性别，对小费数据进行平均后绘制柱状图，具体操作如图3.84所示。

柱状图如图3.85所示，女性小费金额少于男性小费金额。

注意：这种通过类别汇总的方法比较麻烦，下面讲解的groupby方法会简单许多。

```
male_tip = tips[tips['sex'] == 'Male']['tip'].mean()
male_tip
```

```
3.0896178343949052
```

```
female_tip = tips[tips['sex'] == 'Female']['tip'].mean()
female_tip
```

```
2.833448275862069
```

```
s = Series([male_tip,female_tip],index=['male','female'])
s
```

```
male      3.089618
female    2.833448
dtype: float64
```

```
s.plot(kind='bar')
```

图3.84　男女平均小费金额

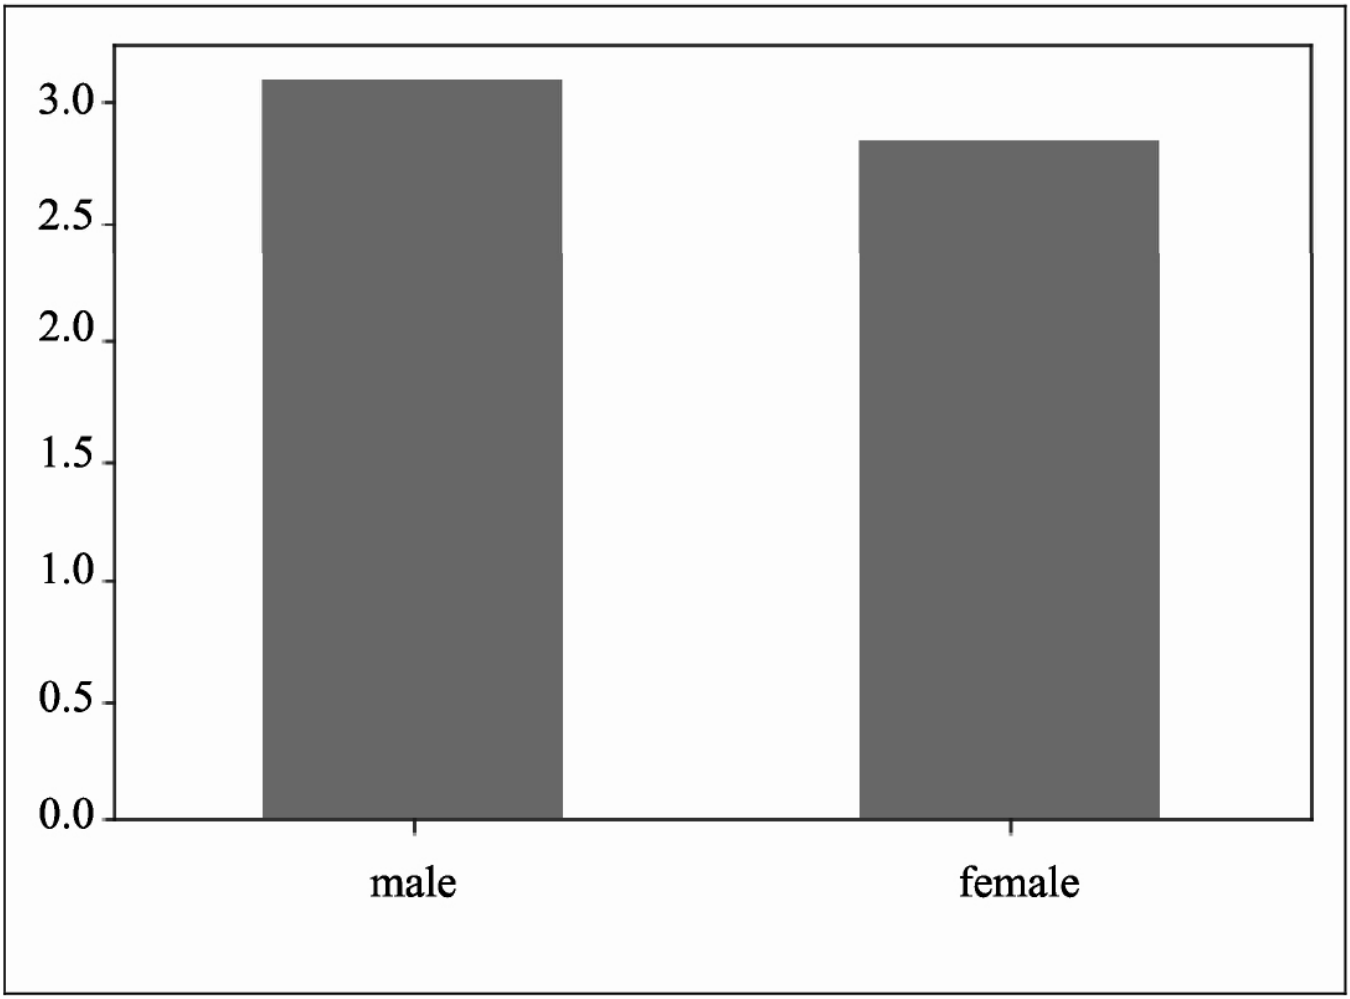

图3.85　男女平均小费柱状图

其他字段与小费的关系也是类似的方法。例如，日期与小费的关系，由于观察数据时只看到了前5行数据，通过unique函数看下日期的唯一值有哪些，如图3.86所示。

日期平均小费柱状图如图3.87所示，周六、周日的小费比周四、周五的小费高。

最后我们一起来分析一下小费百分比的分布情况，这里的消费总金额为小费的金额和聚餐所花费的金额（total_bill），通过DataFrame算术运算，新建一列，用于存储小费百分比，如图3.88所示。

```
tips['day'].unique()
```

```
[Sun, Sat, Thur, Fri]
Categories (4, object): [Sun, Sat, Thur, Fri]
```

图3.86　日期唯一值

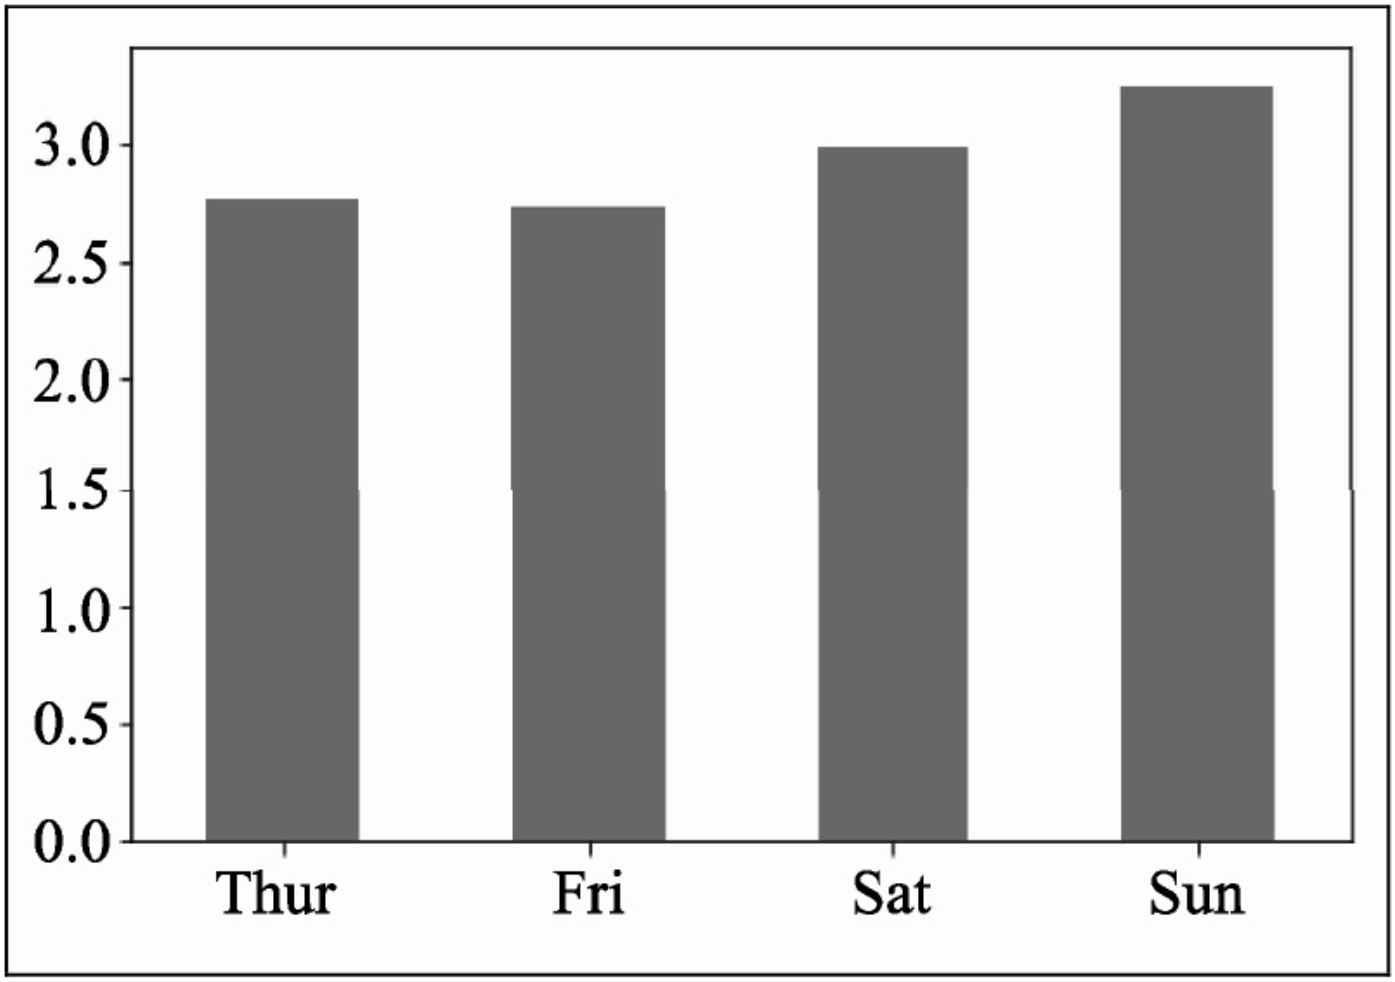

图3.87　日期平均小费柱状图

```
tips['percent_tip'] = tips['tip']/(tips['total_bill']+tips['tip'])
tips.head(10)
```

	total_bill	tip	sex	smoker	day	time	size	percent_tip
0	16.99	1.01	Female	No	Sun	Dinner	2	0.056111
1	10.34	1.66	Male	No	Sun	Dinner	3	0.138333
2	21.01	3.50	Male	No	Sun	Dinner	3	0.142799
3	23.68	3.31	Male	No	Sun	Dinner	2	0.122638
4	24.59	3.61	Female	No	Sun	Dinner	4	0.128014
5	25.29	4.71	Male	No	Sun	Dinner	4	0.157000
6	8.77	2.00	Male	No	Sun	Dinner	2	0.185701
7	26.88	3.12	Male	No	Sun	Dinner	4	0.104000
8	15.04	1.96	Male	No	Sun	Dinner	2	0.115294
9	14.78	3.23	Male	No	Sun	Dinner	2	0.179345

图3.88　小费百分比

直方图如图3.89所示，可以看出基本上符合正态分布，但也有几个异常点。

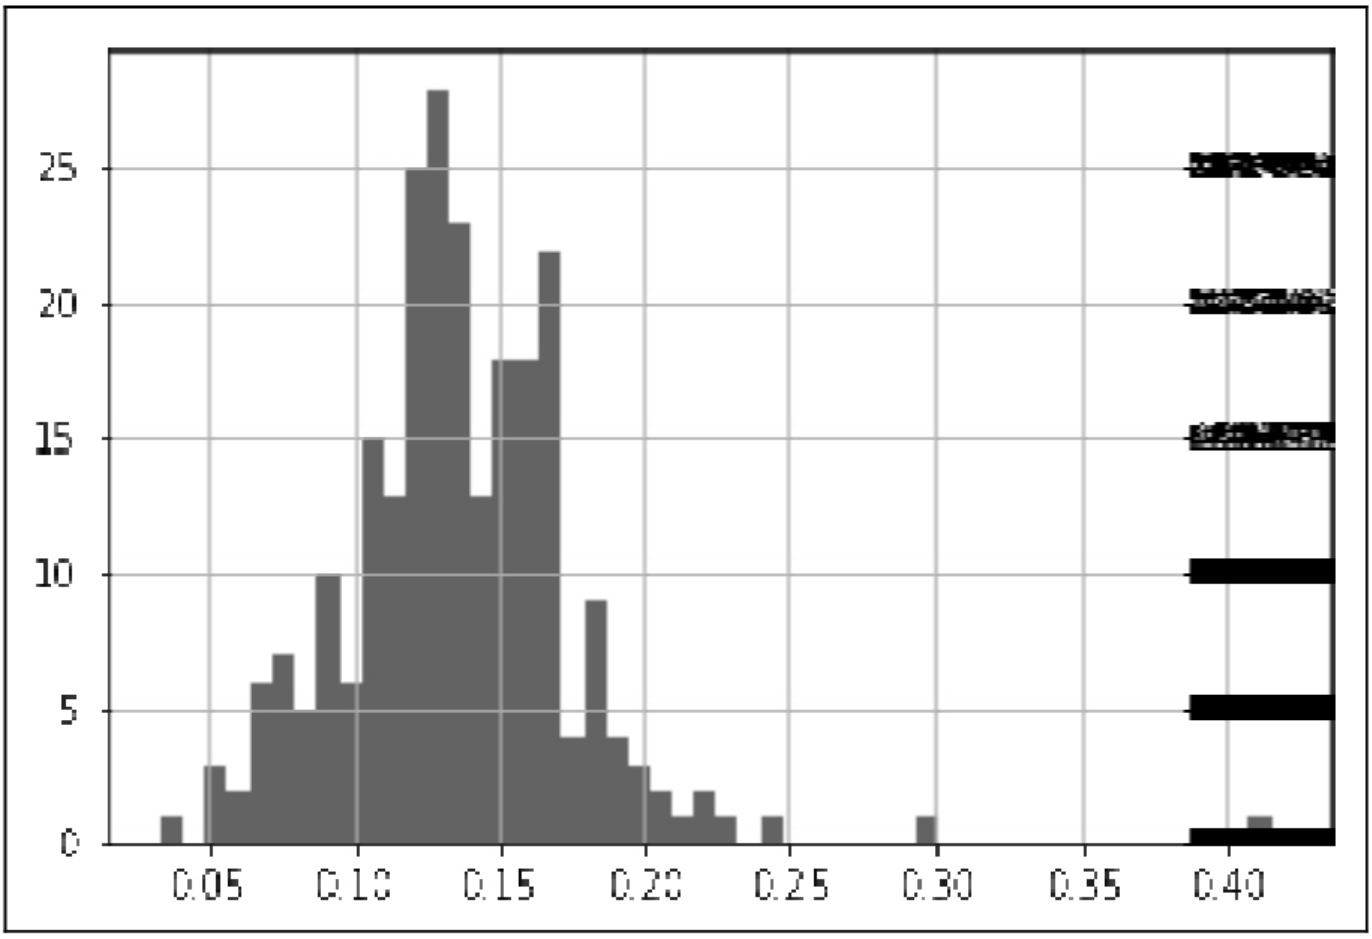

图3.89　小费百分比直方图

第4章　外部数据的读取与存储

对于数据分析而言，数据大部分来源于外部数据，如常用的CSV文件、Excel文件和数据库文件等。本章将讲解如何利用pandas库将外部数据转换为DataFrame数据格式，再通过Python对数据进行处理，将DataFrame数据存储到相应的外部数据文件中。

下面给出本章主要涉及的知识点与学习目标。

· 文本数据：学会CSV、TXT等文本文件的读取与存储，了解并熟悉pandas读取函数参数的使用。

· JSON和Excel数据：学会对JSON和Excel数据的读取与存储。

· 数据库数据：介绍MySQL数据库的读取和存储。

· Web数据：学会简单的Web数据的读取。

4.1　文本数据的读取与存储

本节主要介绍pandas解析文本数据的函数，通过简单的例子，灵活使用函数来读取和存储文本数据。

4.1.1　CSV文件的读取

pandas库提供了将表格型数据读取为DataFrame数据结构的函数。在现实应用中，常用的有read_csv和read_table函数，具体差异如表4.1所示。

表4.1　文本解析函数

字　　符	作　　用
read_csv	从文件中加载带分隔符的数据，默认分隔符为逗号
read_table	从文件中加载带分隔符的数据，默认分隔符为制表符

CSV是存储表格数据的常用文件格式，可通过read_csv函数进行读取。首先通过Python自带的csv库创建CSV文件。

```
import csv
fp = open('H:/python数据分析/数据/ch4ex1.csv','w',newline='')
writer = csv.writer(fp)
writer.writerow(('id','name','grade'))
writer.writerow(('1','lucky','87'))
writer.writerow(('2','peter','92'))
writer.writerow(('3','lili','85'))
fp.close()
```

除了通过打开文件查看数据外，还可以通过type方法查看数据，如图4.1所示。

图4.1　数据情况

注意：后面创建CSV文件的代码将不再展示；type方法只适用于Windows系统，UNIX系统使用!cat命令。

由于创建的文件是标准的CSV文件，所以使用read_csv函数读取即可，如图4.2所示。

```
import pandas as pd
df = pd.read_csv(open('H:/python数据分析/数据/ch4ex1.csv'))
df
```

	id	name	grade
0	1	lucky	87
1	2	peter	92
2	3	lili	85

图4.2　读取CSV文件1

注意：读取CSV文件时，如果文件路径中有中文，需要加open函数，否则会报错。

对于CSV文件，也可以使用read_table进行读取，指定分隔符即可，如图4.3所示。

```
df = pd.read_table(open('H:/python数据分析/数据/ch4ex1.csv'),sep=',')
df
```

	id	name	grade
0	1	lucky	87
1	2	peter	92
2	3	lili	85

图4.3　读取CSV文件2

但实际应用中，CSV文件的格式并不会如此规整。下面通过几个例子来讲解read_csv函数的参数（read_table函数参数也相同）使用，以解决各种CSV文件的读取方法。

1．指定列作为索引

默认情况下，读取的DataFrame的行索引是从0开始进行计数。以前面的CSV文件为例，读者可自由指定列为行索引。例如，通过index_col参数指定id列为行索引，如图4.4所示。

```
df = pd.read_csv(open('H:/python数据分析/数据/ch4ex1.csv'),index_col='id')
df
```

	name	grade
id		
1	lucky	87
2	peter	92
3	lili	85

图4.4　指定行索引

如果希望多个列做成一个层次化索引，传入列编号或者列名组成的列表即可。首先看下CSV文件，如图4.5所示。传入列编号和列名，可将多列做成层次化索引，如图4.6所示。

```
!type H:\python数据分析\数据\ch4ex2.csv
```

```
school,id,name,grade
a,1,lucky,87
a,2,peter,92
a,3,lili,85
b,1,coco,78
b,2,kevin,87
b,3,heven,96
```

图4.5　数据情况

```
df = pd.read_csv(open('H:/python数据分析/数据/ch4ex2.csv'),index_col=[0,'id'])
df
```

		name	grade
school	id		
a	1	lucky	87
	2	peter	92
	3	lili	85
b	1	coco	78
	2	kevin	87
	3	heven	96

图4.6　层次化索引

2．标题行设置

有些情况下，CSV文件没有标题行，如图4.7所示。

```
!type H:\python数据分析\数据\ch4ex3.csv
```

```
1,lucky,87
2,peter,92
3,lili,85
```

图4.7　数据情况

如果使用默认情况读取，会指定第一行为标题行，这是不符合实际情况的，如图4.8所示。

```
df = pd.read_csv(open('H:/python数据分析/数据/ch4ex3.csv'))
df
```

	1	lucky	87
0	2	peter	92
1	3	lili	85

图4.8　默认读取

读取该文件的方法有两种，一种是通过header参数分配默认的标题行，如图4.9所示。

```
df = pd.read_csv(open('H:/python数据分析/数据/ch4ex3.csv'),header=None)
df
```

	0	1	2
0	1	lucky	87
1	2	peter	92
2	3	lili	85

图4.9　默认标题行

另一种方法是通过names参数给其指定列名，如图4.10所示。

```
df = pd.read_csv(open('H:/python数据分析/数据/ch4ex3.csv'),names=['id','name','grade'])
df
```

	id	name	grade
0	1	lucky	87
1	2	peter	92
2	3	lili	85

图4.10　指定标题行

3．自定义读取

由于数据原因或者数据分析的需要，有时可能只需选择读取部分行或列。首先看一下数据情况，如图4.11所示。

```
!type H:\python数据分析\数据\ch4ex4.csv
#This is grade
id,name,grade
1,lucky,87
2,peter,92
3,lili,85
#time
```

图4.11　数据情况

这时可通过skiprows参数跳过一些行，如图4.12所示。

```
df = pd.read_csv(open('H:/python数据分析/数据/ch4ex4.csv'),skiprows=[0,5])
df
```

	id	name	grade
0	1	lucky	87
1	2	peter	92
2	3	lili	85

图4.12　跳过行

有时只需要读取部分数据，我们通过图4.13所示的数据，进行讲解。

```
!type H:\python数据分析\数据\titanic.csv
```

```
PassengerId,Survived,Pclass,Name,Sex,Age,SibSp,Parch,Ticket,Fare,Cabin,Embarked
1,0,3,"Braund, Mr. Owen Harris",male,22,1,0,A/5 21171,7.25,,S
2,1,1,"Cumings, Mrs. John Bradley (Florence Briggs Thayer)",female,38,1,0,PC 17599,71.2833,C85,C
3,1,3,"Heikkinen, Miss. Laina",female,26,0,0,STON/02. 3101282,7.925,,S
4,1,1,"Futrelle, Mrs. Jacques Heath (Lily May Peel)",female,35,1,0,113803,53.1,C123,S
5,0,3,"Allen, Mr. William Henry",male,35,0,0,373450,8.05,,S
6,0,3,"Moran, Mr. James",male,,0,0,330877,8.4583,,Q
7,0,1,"McCarthy, Mr. Timothy J",male,54,0,0,17463,51.8625,E46,S
8,0,3,"Palsson, Master. Gosta Leonard",male,2,3,1,349909,21.075,,S
9,1,3,"Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)",female,27,0,2,347742,11.1333,,S
10,1,2,"Nasser, Mrs. Nicholas (Adele Achem)",female,14,1,0,237736,30.0708,,C
11,1,3,"Sandstrom, Miss. Marguerite Rut",female,4,1,1,PP 9549,16.7,G6,S
12,1,1,"Bonnell, Miss. Elizabeth",female,58,0,0,113783,26.55,C103,S
13,0,3,"Saundercock, Mr. William Henry",male,20,0,0,A/5. 2151,8.05,,S
14,0,3,"Andersson, Mr. Anders Johan",male,39,1,5,347082,31.275,,S
15,0,3,"Vestrom, Miss. Hulda Amanda Adolfina",female,14,0,0,350406,7.8542,,S
16,1,2,"Hewlett, Mrs. (Mary D Kingcome) ",female,55,0,0,248706,16,,S
17,0,3,"Rice, Master. Eugene",male,2,4,1,382652,29.125,,Q
18,1,2,"Williams, Mr. Charles Eugene",male,,0,0,244373,13,,S
```

图4.13　数据情况

注意：该数据为Kaggle比赛中的泰坦尼克号生还者数据。

通过nrows参数，可以选择只读取部分数据，如图4.14所示。

```
df = pd.read_csv(open('H:/python数据分析/数据/titanic.csv'),nrows=10)
df
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S
5	6	0	3	Moran, Mr. James	male	NaN	0	0	330877	8.4583	NaN	Q
6	7	0	1	McCarthy, Mr. Timothy J	male	54.0	0	0	17463	51.8625	E46	S
7	8	0	3	Palsson, Master. Gosta Leonard	male	2.0	3	1	349909	21.0750	NaN	S
8	9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.0	0	2	347742	11.1333	NaN	S
9	10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.0	1	0	237736	30.0708	NaN	C

图4.14　选择读取行数

如果只是为了研究生还者（Survived）和性别（Sex）之间的关系，可通过usecols参数进行部分列的选取，如图4.15所示。

```
df = pd.read_csv(open('H:/python数据分析/数据/titanic.csv'),nrows=10,usecols=['Survived','Sex'])
df
```

	Survived	Sex
0	0	male
1	1	female
2	1	female
3	1	female
4	0	male
5	0	male
6	0	male
7	0	male
8	1	female
9	1	female

图4.15　读取部分列

在处理很大文件的时候，需要对文件进行逐块读取，首先通过info函数查看泰坦尼克号的生还者数据，共有891条数据，如图4.16所示。

注意：这里只是作为案例，891条数据并不多。

通过chunksize参数，即可逐步读取文件，如图4.17所示。

```
df = pd.read_csv(open('H:/python数据分析/数据/titanic.csv'))
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
PassengerId    891 non-null int64
Survived       891 non-null int64
Pclass         891 non-null int64
Name           891 non-null object
Sex            891 non-null object
Age            714 non-null float64
SibSp          891 non-null int64
Parch          891 non-null int64
Ticket         891 non-null object
Fare           891 non-null float64
Cabin          204 non-null object
Embarked       889 non-null object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.6+ KB
```

图4.16　数据信息

```
chunker = pd.read_csv(open('H:/python数据分析/数据/titanic.csv'),chunksize=100)
chunker
```

```
<pandas.io.parsers.TextFileReader at 0x83329e8>
```

图4.17　逐块读取

这里返回的是可迭代的TextFileReader。通过迭代，可以对Sex列进行计数，结果如图4.18所示。代码如下：

```
male      577.0
female    314.0
dtype: float64
```

图4.18　结果

```
from pandas import Series
import pandas as pd
chunker = pd.read_csv(open('H:/python数据分析/数据/titanic.csv'),
chunksize=100)
sex = Series([])
for i in chunker:
    sex = sex.add(i['Sex'].value_counts(),
    fill_value=0)
sex
```

read_csv常用的参数说明如表4.2所示，更多read_csv参数的使用说明，读者可自行查阅pandas官方文档。

表4.2　read_csv/read_table参数

参　　数	使用说明
path	文件的路径
sep	字段隔开的字符序列，也可使用正则表达式
header	指定列索引。默认为 0（第 1 行），也可以为 None，或没有 header 行

（续）

参　　数	使用说明
index_col	用于行索引的列名或列编号
names	指定列索引的列名
skiprows	需要忽略的行数（从文件开始处算）
nrows	需要读取的行数（从文件开始处算）
chunksize	文件块的大小
usecols	指定读取的列

4.1.2　TXT文件的读取

TXT文件使用的分隔符可能并不是逗号，这里创建一个分隔符为“？”的TXT文档。代码如下：

```
fp = open('H:/python数据分析/数据/ch4ex6.txt','a+')
fp.writelines('id?name?grade'+'\n')
fp.writelines('1?lucky?87'+'\n')
fp.writelines('2?peter?92'+'\n')
fp.writelines('3?lili?85'+'\n')
fp.close()
```

创建的TXT文档如图4.19所示。

```
!type H:\python数据分析\数据\ch4ex6.txt
```

```
id?name?grade
1?lucky?87
2?peter?92
3?lili?85
```

图4.19　数据情况

通过read_table函数中的sep参数进行分隔符的指定，如图4.20所示。

```
import pandas as pd
df = pd.read_table(open('H:/python数据分析/数据/ch4ex6.txt'),sep='?')
df
```

	id	name	grade
0	1	lucky	87
1	2	peter	92
2	3	lili	85

图4.20　指定分隔符

现实情况中，有些TXT文件并没有固定的分隔符，而是用一些数量不定的空白符进行分隔。数据情况如图4.21所示。

```
!type H:\python数据分析\数据\ch4ex7.txt
```

```
id   name grade
1 lucky  87
2  peter    92
3  lili 85
```

图4.21　数据情况

这种情况下也可以手动处理，但数据量过多时，手动处理就会很耗时。本例可通过正则表达式来处理，如图4.22所示。

```
df = pd.read_table(open('H:/python数据分析/数据/ch4ex7.txt'),sep='\s+')
df
```

	id	name	grade
0	1	lucky	87
1	2	peter	92
2	3	lili	85

图4.22　正则表达式使用

注意：正则表达式的内容第5章会有详细介绍。

4.1.3　文本数据的存储

在对数据进行处理和分析之后，通常会把数据存储起来。下面以前面的一个CSV文件为例讲解数据存储的方法，CSV文件数据如图4.23所示。

```
import pandas as pd
df = pd.read_csv(open('H:/python数据分析/数据/ch4ex1.csv'))
df
```

	id	name	grade
0	1	lucky	87
1	2	peter	92
2	3	lili	85

图4.23　CSV文件数据

利用DataFrame的to_csv方法，可以将数据存储到以逗号分隔的CSV文件中，如图4.24所示。

```
df.to_csv('H:/python数据分析/数据/out1.csv')
!type H:\python数据分析\数据\out1.csv
```

```
,id,name,grade
0,1,lucky,87
1,2,peter,92
2,3,lili,85
```

图4.24　存储数据1

也可以通过sep参数指定存储的分隔符，如图4.25所示。

```
df.to_csv('H:/python数据分析/数据/out2.csv',sep='?')
!type H:\python数据分析\数据\out2.csv
```

```
?id?name?grade
0?1?lucky?87
1?2?peter?92
2?3?lili?85
```

图4.25　存储数据2

这种情况下会存储行和列索引，我们可以通过设置index和header分别处理行和列索引，如图4.26所示。

```
df.to_csv('H:/python数据分析/数据/out3.csv',index=False)
!type H:\python数据分析\数据\out3.csv
```

```
id,name,grade
1,lucky,87
2,peter,92
3,lili,85
```

图4.26　存储数据3

4.2　JSON和Excel数据的读取与存储

本节主要介绍通过pandas解析JSON和Excel数据的方法，并学会这两种常见数据的存储方法。

4.2.1　JSON数据的读取与存储

JSON（Javascript Object Notation）数据是一种轻量级的数据交换格式，因其简洁和清晰的层次结构使JSON成为了理想的数据交换语言，如图4.27所示。

```
!type H:\python数据分析\数据\eueo2012.json
```


{"Team":{"0":"Croatia","1":"Czech Republic","2":"Denmark","3":"England","4":"France","5":"Germany","6":"Greece","7":"Italy","8":"Netherland
s","9":"Poland","10":"Portugal","11":"Republic of Ireland","12":"Russia","13":"Spain","14":"Sweden","15":"Ukraine"},"Goals":{"0":4,"1":
4,"2":4,"3":5,"4":3,"5":10,"6":5,"7":6,"8":2,"9":2,"10":6,"11":1,"12":5,"13":12,"14":5,"15":2},"Shots on target":{"0":13,"1":13,"2":10,"3":1
1,"4":22,"5":32,"6":8,"7":34,"8":12,"9":15,"10":22,"11":7,"12":9,"13":42,"14":17,"15":7},"Shots off target":{"0":12,"1":18,"2":10,"3":1
8,"4":24,"5":32,"6":18,"7":45,"8":36,"9":23,"10":42,"11":12,"12":31,"13":33,"14":19,"15":26},"Shooting Accuracy":{"0":"51.9%","1":"41.
9%","2":"50.0%","3":"50.0%","4":"37.9%","5":"47.8%","6":"30.7%","7":"43.0%","8":"25.0%","9":"39.4%","10":"34.3%","11":"36.8%","12":"22.
5%","13":"55.9%","14":"47.2%","15":"21.2%"},"% Goals-to-shots":{"0":"16.0%","1":"12.9%","2":"20.0%","3":"17.2%","4":"6.5%","5":"15.
6%","6":"19.2%","7":"7.5%","8":"4.1%","9":"5.2%","10":"9.3%","11":"5.2%","12":"12.5%","13":"16.0%","14":"13.8%","15":"6.0%"},"Total shots (i
nc. Blocked)":{"0":32,"1":39,"2":27,"3":40,"4":65,"5":80,"6":32,"7":110,"8":60,"9":48,"10":82,"11":28,"12":59,"13":100,"14":39,"15":38},"Hit
Woodwork":{"0":0,"1":0,"2":1,"3":0,"4":1,"5":2,"6":1,"7":2,"8":2,"9":0,"10":6,"11":0,"12":2,"13":0,"14":3,"15":0},"Penalty goals":{"0":
0,"1":0,"2":0,"3":0,"4":0,"5":1,"6":1,"7":0,"8":0,"9":0,"10":0,"11":0,"12":0,"13":1,"14":0,"15":0},"Penalties not scored":{"0":0,"1":0,"2":
0,"3":0,"4":0,"5":0,"6":1,"7":0,"8":0,"9":0,"10":0,"11":0,"12":0,"13":0,"14":0,"15":0},"Headed goals":{"0":2,"1":0,"2":3,"3":3,"4":0,"5":
2,"6":0,"7":2,"8":0,"9":1,"10":2,"11":1,"12":1,"13":2,"14":1,"15":2},"Passes":{"0":1076,"1":1565,"2":1298,"3":1488,"4":2066,"5":2774,"6":118
7,"7":3016,"8":1556,"9":1059,"10":1891,"11":851,"12":1602,"13":4317,"14":1192,"15":1276},"Passes completed":{"0":828,"1":1223,"2":1082,"3":1
200,"4":1803,"5":2427,"6":911,"7":2531,"8":1381,"9":852,"10":1461,"11":606,"12":1345,"13":3820,"14":965,"15":1043},"Passing Accuracy":
{"0":"76.9%","1":"78.1%","2":"83.3%","3":"80.6%","4":"87.2%","5":"87.4%","6":"76.7%","7":"83.9%","8":"88.7%","9":"80.4%","10":"77.2%","1
1":"71.2%","12":"83.9%","13":"88.4%","14":"80.9%","15":"81.7%"},"Touches":{"0":1706,"1":2358,"2":1873,"3":2440,"4":2909,"5":3761,"6":201
6,"7":4363,"8":2163,"9":1724,"10":2958,"11":1433,"12":2278,"13":5585,"14":1806,"15":1894},"Crosses":{"0":60,"1":46,"2":43,"3":58,"4":55,"5":
101,"6":52,"7":75,"8":50,"9":55,"10":91,"11":43,"12":40,"13":69,"14":44,"15":33},"Dribbles":{"0":42,"1":68,"2":32,"3":60,"4":76,"5":60,"6":5
3,"7":75,"8":49,"9":39,"10":64,"11":18,"12":40,"13":106,"14":29,"15":26},"Corners Taken":{"0":14,"1":21,"2":16,"3":16,"4":28,"5":35,"6":1
0,"7":30,"8":22,"9":14,"10":41,"11":8,"12":21,"13":44,"14":7,"15":18},"Tackles":{"0":49,"1":62,"2":40,"3":86,"4":71,"5":91,"6":65,"7":9
8,"8":34,"9":67,"10":78,"11":45,"12":65,"13":122,"14":56,"15":65},"Clearances":{"0":83,"1":98,"2":61,"3":106,"4":76,"5":73,"6":123,"7":13
7,"8":41,"9":87,"10":92,"11":78,"12":74,"13":102,"14":54,"15":97},"Interceptions":{"0":56,"1":37,"2":59,"3":72,"4":58,"5":69,"6":87,"7":13
6,"8":41,"9":62,"10":86,"11":43,"12":58,"13":79,"14":45,"15":29},"Clearances off line":{"0":null,"1":2.0,"2":0.0,"3":1.0,"4":0.0,"5":0.
0,"6":0.0,"7":1.0,"8":0.0,"9":0.0,"10":0.0,"11":1.0,"12":0.0,"13":0.0,"14":0.0,"15":0.0},"Clean Sheets":{"0":0,"1":1,"2":1,"3":2,"4":1,"5":
1,"6":1,"7":2,"8":0,"9":0,"10":2,"11":0,"12":0,"13":5,"14":1,"15":0},"Blocks":{"0":10,"1":10,"2":10,"3":29,"4":7,"5":11,"6":23,"7":18,"8":
9,"9":8,"10":11,"11":23,"12":8,"13":8,"14":12,"15":4},"Goals conceded":{"0":3,"1":6,"2":5,"3":3,"4":5,"5":6,"6":7,"7":7,"8":5,"9":3,"10":

图4.27　JSON数据

注意：该数据为2012欧洲杯比赛数据。

对于JSON数据，常使用两种方法来读取。一种是通过Python的第三方库json，通过下面的代码可以将JSON数据转化为字符串格式，如图4.28所示。

```
import json
f = open('H:/python数据分析/数据/eueo2012.json')
obj = f.read()
result = json.loads(obj)
result
```

```
{'% Goals-to-shots': {'0': '16.0%',
  '1': '12.9%',
  '10': '9.3%',
  '11': '5.2%',
  '12': '12.5%',
  '13': '16.0%',
  '14': '13.8%',
  '15': '6.0%',
  '2': '20.0%',
  '3': '17.2%',
  '4': '6.5%',
  '5': '15.6%',
  '6': '19.2%',
  '7': '7.5%',
  '8': '4.1%',
  '9': '5.2%'},
 'Blocks': {'0': 10,
  '1': 10,
  '10': 11,
```


图4.28　加载JSON数据

注意：也可以通过json.dumps将字符串转换为JSON格式。

然后将数据输入DataFrame构造器，即可完成对JSON数据的读取，如图4.29所示。

```
from pandas import DataFrame
df = DataFrame(result)
df
```

	% Goals-to-shots	Blocks	Clean Sheets	Clearances	Clearances off line	Corners Taken	Crosses	Dribbles	Fouls Conceded	Fouls Won	...	Shooting Accuracy	Shots off target	Shots on target	Subs off	Subs on	Tackles
0	16.0%	10	0	83	NaN	14	60	42	62	41	...	51.9%	12	13	9	9	49
1	12.9%	10	1	98	2.0	21	46	68	73	53	...	41.9%	18	13	11	11	62
10	9.3%	11	2	92	0.0	41	91	64	90	73	...	34.3%	42	22	14	14	78
11	5.2%	23	0	78	1.0	8	43	18	51	43	...	36.8%	12	7	10	10	45
12	12.5%	8	0	74	0.0	21	40	40	43	34	...	22.5%	31	9	7	7	65
13	16.0%	8	5	102	0.0	44	69	106	83	102	...	55.9%	33	42	17	17	122
14	13.8%	12	1	54	0.0	7	44	29	51	35	...	47.2%	19	17	9	9	56
15	6.0%	4	0	97	0.0	18	33	26	31	48	...	21.2%	26	7	9	9	65
2	20.0%	10	1	61	0.0	16	43	32	38	25	...	50.0%	10	10	7	7	40
3	17.2%	29	2	106	1.0	16	58	60	45	43	...	50.0%	18	11	11	11	86

图4.29　构造DataFrame

注意：由于数据类似字典结构，因此读取时会乱序。

另一种方法则是直接通过read_json函数来读取JSON数据，如图4.30所示。

```
import pandas as pd
df = pd.read_json('H:/python数据分析/数据/eueo2012.json')
df
```

	% Goals-to-shots	Blocks	Clean Sheets	Clearances	Clearances off line	Corners Taken	Crosses	Dribbles	Fouls Conceded	Fouls Won	...	Shooting Accuracy	Shots off target	Shots on target	Subs off	Subs on	Tackles
0	16.0%	10	0	83	NaN	14	60	42	62	41	...	51.9%	12	13	9	9	49
1	12.9%	10	1	98	2.0	21	46	68	73	53	...	41.9%	18	13	11	11	62
10	9.3%	11	2	92	0.0	41	91	64	90	73	...	34.3%	42	22	14	14	78
11	5.2%	23	0	78	1.0	8	43	18	51	43	...	36.8%	12	7	10	10	45
12	12.5%	8	0	74	0.0	21	40	40	43	34	...	22.5%	31	9	7	7	65
13	16.0%	8	5	102	0.0	44	69	106	83	102	...	55.9%	33	42	17	17	122
14	13.8%	12	1	54	0.0	7	44	29	51	35	...	47.2%	19	17	9	9	56
15	6.0%	4	0	97	0.0	18	33	26	31	48	...	21.2%	26	7	9	9	65
2	20.0%	10	1	61	0.0	16	43	32	38	25	...	50.0%	10	10	7	7	40
3	17.2%	29	2	106	1.0	16	58	60	45	43	...	50.0%	18	11	11	11	86

图4.30　读取JSON数据

由于读取时会乱序，这里重新对行索引进行排序，如图4.31所示。

```
df = df.sort_index()
df
```

	% Goals-to-shots	Blocks	Clean Sheets	Clearances	Clearances off line	Corners Taken	Crosses	Dribbles	Fouls Conceded	Fouls Won	...	Shooting Accuracy	Shots off target	Shots on target	Subs off	Subs on	Tackles
0	16.0%	10	0	83	NaN	14	60	42	62	41	...	51.9%	12	13	9	9	49
1	12.9%	10	1	98	2.0	21	46	68	73	53	...	41.9%	18	13	11	11	62
2	20.0%	10	1	61	0.0	16	43	32	38	25	...	50.0%	10	10	7	7	40
3	17.2%	29	2	106	1.0	16	58	60	45	43	...	50.0%	18	11	11	11	86
4	6.5%	7	1	76	0.0	28	55	76	51	36	...	37.9%	24	22	11	11	71
5	15.6%	11	1	73	0.0	35	101	60	49	63	...	47.8%	32	32	15	15	91
6	19.2%	23	1	123	0.0	10	52	53	48	67	...	30.7%	18	8	12	12	65
7	7.5%	18	2	137	1.0	30	75	75	89	101	...	43.0%	45	34	18	18	98
8	4.1%	9	0	41	0.0	22	50	49	30	35	...	25.0%	36	12	7	7	34
9	5.2%	8	0	87	0.0	14	55	39	56	48	...	39.4%	23	15	7	7	67
10	9.3%	11	2	92	0.0	41	91	64	90	73	...	34.3%	42	22	14	14	78
11	5.2%	23	0	78	1.0	8	43	18	51	43	...	36.8%	12	7	10	10	45

图4.31　重新排序

最后使用to_json函数对DataFrame数据进行相应的存储，如图4.32所示。

```
df.to_json('H:/python数据分析/数据/out4.json')
!type H:\python数据分析\数据\out4.json
```


{"% Goals-to-shots":{"0":"16.0%","1":"12.9%","2":"20.0%","3":"17.2%","4":"6.5%","5":"15.6%","6":"19.2%","7":"7.5%","8":"4.1%","9":"5.2%","1
0":"9.3%","11":"5.2%","12":"12.5%","13":"16.0%","14":"13.8%","15":"6.0%"},"Blocks":{"0":10,"1":10,"2":10,"3":29,"4":7,"5":11,"6":23,"7":1
8,"8":9,"9":8,"10":11,"11":23,"12":8,"13":8,"14":12,"15":4},"Clean Sheets":{"0":0,"1":1,"2":1,"3":2,"4":1,"5":1,"6":1,"7":2,"8":0,"9":0,"1
0":2,"11":0,"12":0,"13":5,"14":1,"15":0},"Clearances":{"0":83,"1":98,"2":61,"3":106,"4":76,"5":73,"6":123,"7":137,"8":41,"9":87,"10":92,"1
1":78,"12":74,"13":102,"14":54,"15":97},"Clearances off line":{"0":null,"1":2.0,"2":0.0,"3":1.0,"4":0.0,"5":0.0,"6":0.0,"7":1.0,"8":0.0,"9":
0.0,"10":0.0,"11":1.0,"12":0.0,"13":0.0,"14":0.0,"15":0.0},"Corners Taken":{"0":14,"1":21,"2":16,"3":16,"4":28,"5":35,"6":10,"7":30,"8":2
2,"9":14,"10":41,"11":8,"12":21,"13":44,"14":7,"15":18},"Crosses":{"0":60,"1":46,"2":43,"3":58,"4":55,"5":101,"6":52,"7":75,"8":50,"9":55,"1
0":91,"11":43,"12":40,"13":69,"14":44,"15":33},"Dribbles":{"0":42,"1":68,"2":32,"3":60,"4":76,"5":60,"6":53,"7":75,"8":49,"9":39,"10":64,"1
1":18,"12":40,"13":106,"14":29,"15":26},"Fouls Conceded":{"0":62,"1":73,"2":38,"3":45,"4":51,"5":49,"6":48,"7":89,"8":30,"9":56,"10":90,"1
1":51,"12":43,"13":83,"14":51,"15":31},"Fouls Won":{"0":41,"1":53,"2":25,"3":43,"4":36,"5":63,"6":67,"7":101,"8":35,"9":48,"10":73,"11":4
3,"12":34,"13":102,"14":35,"15":48},"Goals":{"0":4,"1":4,"2":4,"3":5,"4":3,"5":10,"6":5,"7":6,"8":2,"9":2,"10":6,"11":1,"12":5,"13":12,"14":
5,"15":2},"Goals conceded":{"0":3,"1":6,"2":5,"3":3,"4":5,"5":6,"6":7,"7":7,"8":5,"9":3,"10":4,"11":9,"12":3,"13":1,"14":5,"15":4},"Headed g
oals":{"0":2,"1":0,"2":3,"3":3,"4":0,"5":2,"6":0,"7":2,"8":0,"9":1,"10":2,"11":1,"12":1,"13":2,"14":1,"15":2},"Hit Woodwork":{"0":0,"1":
0,"2":1,"3":0,"4":1,"5":2,"6":1,"7":2,"8":2,"9":0,"10":6,"11":0,"12":2,"13":0,"14":3,"15":0},"Interceptions":{"0":56,"1":37,"2":59,"3":7
2,"4":58,"5":69,"6":87,"7":136,"8":41,"9":62,"10":86,"11":43,"12":58,"13":79,"14":45,"15":29},"Offsides":{"0":2,"1":8,"2":8,"3":6,"4":5,"5":

图4.32　JSON数据存储

4.2.2　Excel数据的读取与存储

Excel表格数据也是工作中常用的一种数据，读者应该对其并不陌生。我们可以通过read_excel和to_excel函数对Excel数据进行读取和存储。首先创建一个Excel数据，如图4.33所示。

通过read_excel函数读取数据，可通过参数sheetname指定读取的工作簿，如图4.34所示。

通过to_excel函数将DataFrame文件存储为Excel数据类型，如图4.35所示。代码如下：

```
df.to_excel('H:/python数据分析/数据/out5.xlsx',sheet_name='out',
index=None)
```

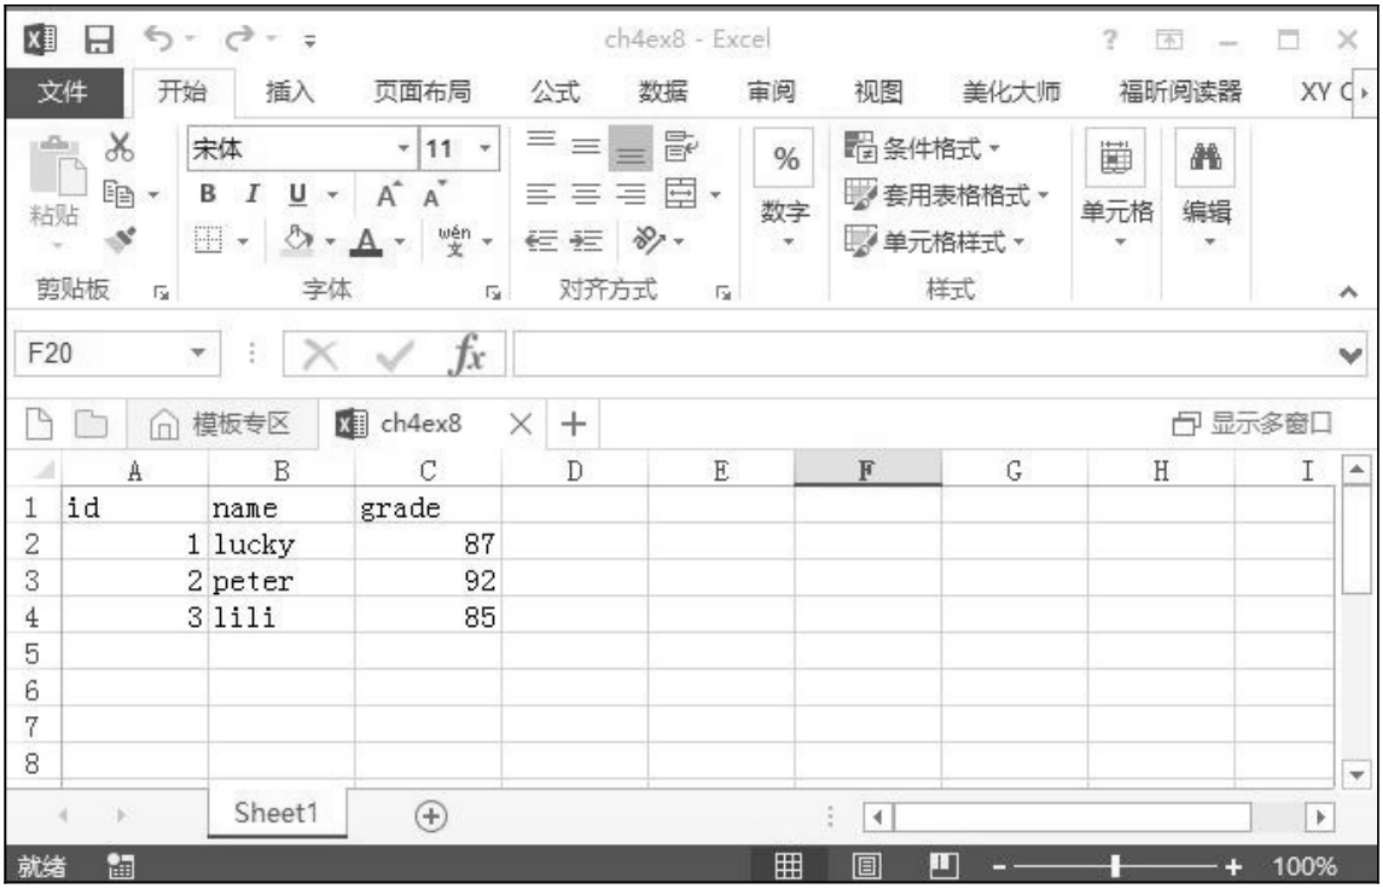

	A	B	C	D	E	F	G	H	I
1	id	name	grade						
2	1	lucky	87						
3	2	peter	92						
4	3	lili	85						
5									
6									
7									
8									

图4.33　数据情况

```
import pandas as pd
df = pd.read_excel('H:/python数据分析/数据/ch4ex8.xlsx',sheetname='Sheet1')
df
```

	id	name	grade
0	1	lucky	87
1	2	peter	92
2	3	lili	85

图4.34　读取Excel文件

图4.35　存储为Excel数据类型

4.3　数据库的读取与存储

在许多工作应用中，常使用的文件来源于数据库。本节主要介绍如何通过Python连接并操作MySQL数据库，以及pandas解析MySQL数据库的方法，并使读者学会MySQL数据库的存储方法。

4.3.1　连接数据库

MySQL是目前最受欢迎的开源关系型数据库。我们可以通过Python进行MySQL数据库的连接和使用，但是需要安装第三方库PyMySQL。可以通过conda命令来安装，如图4.36所示。

```
conda install pymysql
```

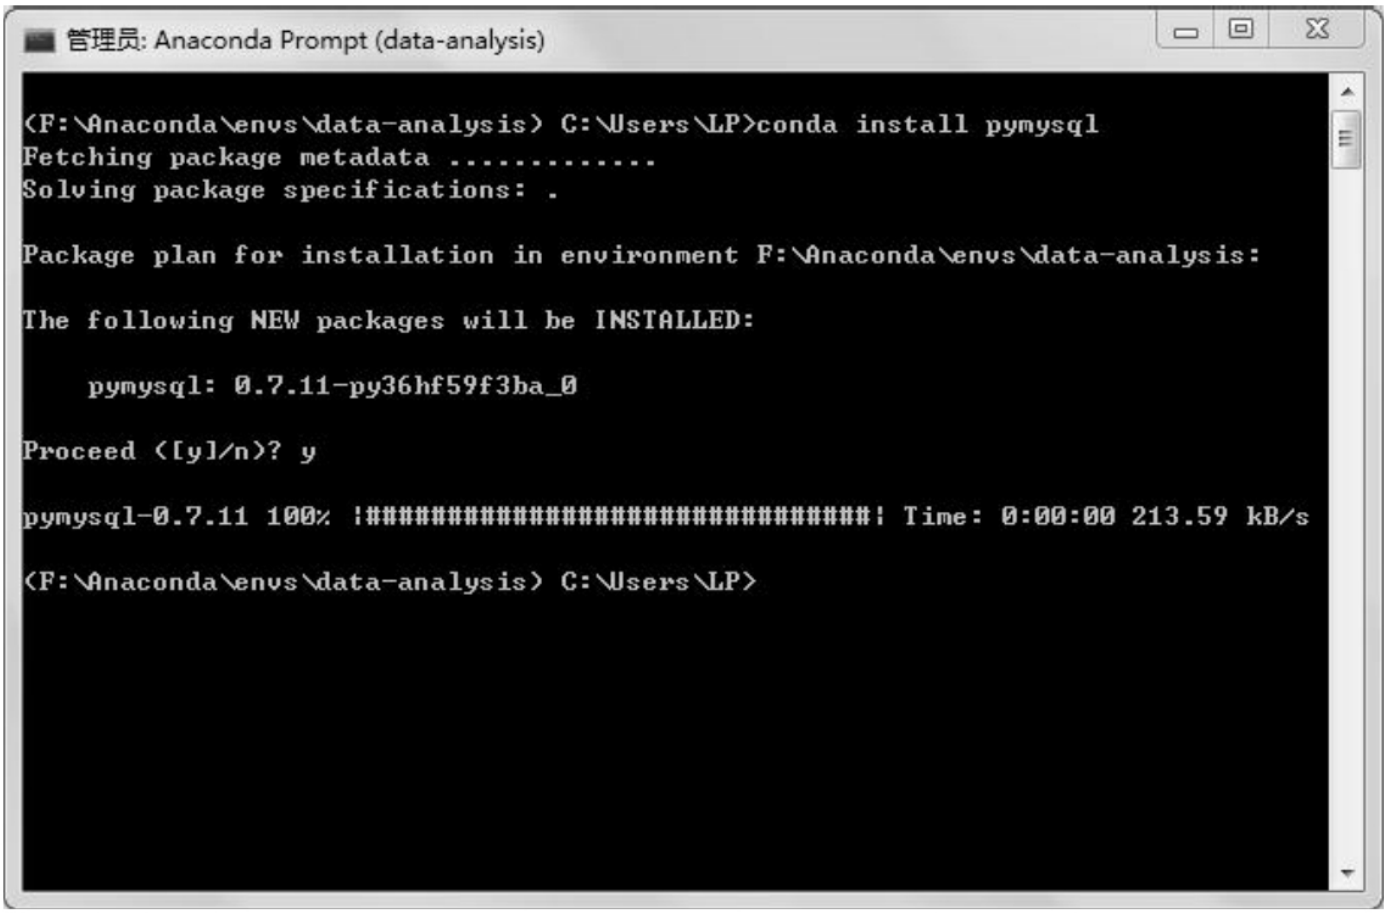

图4.36　安装PyMySQL库

通过下面的代码可连接到本地的MySQL数据库。

```
import pymysql
conn = pymysql.connect(
    host='localhost',
    user='root',
    passwd='123456',
    db='mydb',
    port=3306,
charset='utf8')
```

连接数据库后，可通过PyMySQL库来操作数据库，如建表、增、删、改和查等操作。首先通过以下代码新建一个样表。

```
01        import pymysql
02        conn = pymysql.connect(
03            host='localhost',
04            user='root',
05            passwd='123456',
06            db='mydb',
07            port=3306,
08            charset='utf8')                    #连接数据库
09        cursor = conn.cursor()                 #创建游标
10        creat = '''
11        CREATE TABLE ch4ex9 (
12            id int,
13            name char(8),
14            grade int
15        )ENGINE INNODB DEFAULT CHARSET=utf8;'''
16        cursor.execute(creat)                  #执行命令
17        conn.commit()                          #完成命令
```

第1行导入PyMySQL库；第2～8行用于连接MySQL数据库，conn为连接对象；第9行中的cursor为光标对象，用于操作MySQL数据库；第10～16行执行创建表的命令；最后通过commit命令完成建表的操作。

接下来插入几行数据，代码如下：

```
cursor.execute("insert into ch4ex9 (id,name,grade) values(%s,%s,%s)",
(1,'luchy',87))
cursor.execute("insert into ch4ex9 (id,name,grade) values(%s,%s,%s)",
(2,'peter',92))
cursor.execute("insert into ch4ex9 (id,name,grade) values(%s,%s,%s)",
(3,'lili',85))
conn.commit()
cursor.close()                                     #关闭游标
conn.close()                                       #关闭连接
```

新建的表如图4.37所示。

```
mysql> select * from ch4ex9;
+------+--------+--------+
| id   | name   | grade  |
+------+--------+--------+
|    1 | luchy  |     87 |
|    2 | peter  |     92 |
|    3 | lili   |     85 |
+------+--------+--------+
3 rows in set (0.00 sec)
```

图4.37　数据情况

4.3.2　读取数据库

这里为读者提供两种方法来读取MySQL数据。一种是通过PyMySQL库读取数据库，然后传入到DataFrame构造器中；另一种是直接使用read_sql函数进行数据的读取。

首先介绍第一种方法。先通过PyMySQL库读取数据：

```
from pandas import DataFrame
import pymysql
conn = pymysql.connect(
    host='localhost',
    user='root',
    passwd='123456',
    db='mydb',
    port=3306,
    charset='utf8')
cursor = conn.cursor()
rows = cursor.execute('select * from ch4ex9')
```

结果为3，说明有3行数据。通过游标的fetchall方法，取得所有数据，如图4.38所示。

```
data = cursor.fetchall()
data
```

```
((1, 'luchy', 87), (2, 'peter', 92), (3, 'lili', 85))
```

图4.38　获取数据

然后把这个元组列表化后传给DataFrame构造器，如图4.39所示。

```
from pandas import DataFrame
import pandas as pd
df = DataFrame(list(data))
df
```

	0	1	2
0	1	luchy	87
1	2	peter	92
2	3	lili	85

图4.39　构造DataFrame

另一种方法则是直接通过read_sql函数读取MySQL数据，如图4.40所示。

```
import pandas as pd
import pymysql
conn = pymysql.connect(
    host='localhost',
    user='root',
    passwd='123456',
    db='mydb',
    port=3306,
    charset='utf8')
df = pd.read_sql('select * from ch4ex9',conn)
df
```

	id	name	grade
0	1	luchy	87
1	2	peter	92
2	3	lili	85

图4.40　读取MySQL数据

4.3.3 存储数据库

通过to_sql函数实现DataFrame数据存储为MySQL数据，首先查看to_sql的参数：

```
df.to_sql(name, con, flavor=None, schema=None, if_exists='fail', index=True,
index_label=None, chunksize=None, dtype=None)
```

其中：

· name参数为存储的表名；

· con参数为连接的数据库；

· if_exists参数用于判断是否有重复表名。其中，fail表示如果有重复表名，就不保存；replace表示替换重复表名；append表示在该表中继续插入数据。

注意：新版pandas中，con参数不能使用pymysql连接数据库。

使用下面代码完成数据库的存储，结果如图4.41所示。

```
df.to_sql(name='out6',con='mysql+pymysql://root:123456@localhost:3306/
mydb?charset=utf8',if_exists='replace',index=False)
```

注意：con参数是固定写法，读者记住即可。

```
mysql> select * from out6;
+------+--------+-------+
| id   | name   | grade |
+------+--------+-------+
|    1 | luchy  |    87 |
|    2 | peter  |    92 |
|    3 | lili   |    85 |
+------+--------+-------+
3 rows in set (0.00 sec)
```

图4.41 存储数据

4.4 Web数据的读取

互联网时代，网络上每天都会产生大量的非结构化数据，如何从这些非结构化数据中提取有效的信息进行分析呢？本节将介绍如何使用pandas读取HTML表格中的数据，以及网络数据读取的简单思路。

4.4.1 读取HTML表格

对于HTML网页中的表格数据，使用pandas中的read_html函数就可以轻松地获取，如图4.42所示为2014年世界杯的赛程数据（http://worldcup.2014.163.com/schedule/）。

小组赛	时间	编号	对阵	补眠时刻	城市	电视直播	其
1场	06月13日 星期五 04:00	A1-A4	巴西 3-1 克罗地亚	22:00-04:00	圣保罗	CCTV5	战
2场	06月14日 星期六 00:00	A3-A2	墨西哥 1-0 喀麦隆	22:00-00:00	纳塔尔	CCTV5	战
3场	06月14日 星期六 03:00	B1-B4	西班牙 1-5 荷兰	22:00-03:00	萨尔瓦多	CCTV5	战
4场	06月14日 星期六 06:00	B2-B3	智利 3-1 澳大利亚	22:00-06:00	库亚巴	CCTV5	战
5场	06月15日 星期日 00:00	C1-C4	哥伦比亚 3-0 希腊	22:00-00:00	贝罗奥里藏特	CCTV5	战
7场	06月15日 星期日 03:00	D1-D3	乌拉圭 1-3 哥斯达黎加	22:00-03:00	福塔莱萨	CCTV5	战

图4.42 HTML表格

可以通过read_html函数来读取这些数据，如图4.43所示。

```
import pandas as pd
df = pd.read_html('http://worldcup.2014.163.com/schedule/')
df
```

```
[    Unnamed: 0 Unnamed: 1                时间     编号          对阵  \
 0          NaN         1场  06月13日 星期五 04:00   A1-A4   巴西  3-1  克罗地亚
 1          NaN         2场  06月14日 星期六 00:00   A3-A2   墨西哥  1-0  喀麦隆
 2          NaN         3场  06月14日 星期六 03:00   B1-B4   西班牙  1-5  荷兰
 3          NaN         4场  06月14日 星期六 06:00   B2-B3   智利  3-1  澳大利亚
 4          NaN         5场  06月15日 星期日 00:00   C1-C4   哥伦比亚  3-0  希腊
 5          NaN         7场  06月15日 星期日 03:00   D1-D3  乌拉圭  1-3  哥斯达黎加
 6          NaN         8场  06月15日 星期日 06:00   D2-D4   英格兰  1-2  意大利
 7          NaN         6场  06月15日 星期日 09:00   C2-C3   科特迪瓦  2-1  日本
 8          NaN         9场  06月16日 星期一 00:00   E1-E2   瑞士  2-1  厄瓜多尔
 9          NaN        10场  06月16日 星期一 03:00   E4-E3   法国  3-0  洪都拉斯
 10         NaN        11场  06月16日 星期一 06:00   F1-F4   阿根廷  2-1  波黑
 11         NaN        13场  06月17日 星期二 00:00   G1-G4   德国  4-0  葡萄牙
 12         NaN        12场  06月17日 星期二 03:00   F3-F2   伊朗  0-0  尼日利亚
 13         NaN        14场  06月17日 星期二 06:00   G2-G3   加纳  1-2  美国
 14         NaN        15场  06月18日 星期三 00:00   H1-H2  比利时  2-1  阿尔及利亚
 15         NaN        17场  06月18日 星期三 03:00   A1-A3   巴西  0-0  墨西哥
 16         NaN        16场  06月18日 星期三 06:00   H4-H3   俄罗斯  1-1  韩国
```

图4.43 读取HTML表格1

从图4.43中可以看出，返回的结果是列表结构，每个元素相当于一个表格数据，通过df[0]可读取第一个表格数据，如图4.44所示。

注意：读取时可能会出现一些小问题，读者可以自行修改。

df[0]

	Unnamed: 0	Unnamed: 1	时间	编号	对阵	补眠时刻	城市	电视直播	其他
0	NaN	1场	06月13日 星期五 04:00	A1-A4	巴西 3-1 克罗地亚	22:00-04:00	圣保罗	CCTV5	战报
1	NaN	2场	06月14日 星期六 00:00	A3-A2	墨西哥 1-0 喀麦隆	22:00-00:00	纳塔尔	CCTV5	战报
2	NaN	3场	06月14日 星期六 03:00	B1-B4	西班牙 1-5 荷兰	22:00-03:00	萨尔瓦多	CCTV5	战报
3	NaN	4场	06月14日 星期六 06:00	B2-B3	智利 3-1 澳大利亚	22:00-06:00	库亚巴	CCTV5	战报
4	NaN	5场	06月15日 星期日 00:00	C1-C4	哥伦比亚 3-0 希腊	22:00-00:00	贝罗奥里藏特	CCTV5	战报
5	NaN	7场	06月15日 星期日 03:00	D1-D3	乌拉圭 1-3 哥斯达黎加	22:00-03:00	福塔莱萨	CCTV5	战报
6	NaN	8场	06月15日 星期日 06:00	D2-D4	英格兰 1-2 意大利	22:00-06:00	玛瑙斯	CCTV5	战报
7	NaN	6场	06月15日 星期日 09:00	C2-C3	科特迪瓦 2-1 日本	22:00-09:00	累西腓	CCTV5	战报
8	NaN	9场	06月16日 星期一 00:00	E1-E2	瑞士 2-1 厄瓜多尔	22:00-00:00	巴西利亚	CCTV5	战报
9	NaN	10场	06月16日 星期一 03:00	E4-E3	法国 3-0 洪都拉斯	22:00-03:00	阿雷格里港	CCTV5	战报
10	NaN	11场	06月16日 星期一 06:00	F1-F4	阿根廷 2-1 波黑	22:00-06:00	里约热内卢	CCTV5	战报
11	NaN	13场	06月17日 星期二 00:00	G1-G4	德国 4-0 葡萄牙	22:00-00:00	萨尔瓦多	CCTV5	战报
12	NaN	12场	06月17日 星期二 03:00	F3-F2	伊朗 0-0 尼日利亚	22:00-03:00	库亚巴	CCTV5	战报
13	NaN	14场	06月17日 星期二 06:00	G2-G3	加纳 1-2 美国	22:00-06:00	纳塔尔	CCTV5	战报

图4.44　读取HTML表格2

4.4.2　网络爬虫

并非所有的网络数据都存储在HTML表格中，这时就需要通过网络爬虫来获取所需数据了，而Python提供了多种好用的第三方库来实现网络爬虫。因本书并不是一本教读者网络爬虫的书籍，因此这里只是提供读者网络爬虫到存储为DataFrame数据格式的过程和思路。

其实思路很简单，对爬虫过后的数据简单处理为DataFrame构造器可识别的数据类型即可。下面以酷狗榜单中酷狗TOP500的音乐信息为例（http://www.kugou.com/yy/rank/home/1-8888.html），爬取内容如图4.45所示。

爬取代码如下：

```
import requests
from bs4 import BeautifulSoup                                    #导入相应的库文件
data = []
wb_data = requests.get('http://www.kugou.com/yy/rank/home/1-8888.html')
soup = BeautifulSoup(wb_data.text,'lxml')
ranks = soup.select('span.pc_temp_num')
titles = soup.select('div.pc_temp_songlist > ul > li > a')
times = soup.select('span.pc_temp_tips_r > span')
for rank,title,time in zip(ranks,titles,times):
    a = {
        'rank':rank.get_text().strip(),
        'singer':title.get_text().split('-')[0],
        'song':title.get_text().split('-')[1],
        'time':time.get_text().strip()
    }
    data.append(a)                                               #爬取数据
data
```

图4.45　爬取内容

注意：关于爬虫代码这里不做过多解释，读者主要明白读取网络数据的思路即可。

结果如图4.46所示，该数据类型可传入到DataFrame构造器中。


```
[{'rank': '1', 'singer': '大壮 ', 'song': ' 我们不一样', 'time': '4:31'},
 {'rank': '2', 'singer': '张北北 ', 'song': ' 拥抱你离去', 'time': '4:02'},
 {'rank': '3', 'singer': '杨宗纬、张碧晨 ', 'song': ' 凉凉', 'time': '5:33'},
 {'rank': '4', 'singer': '赵雷 ', 'song': ' 成都', 'time': '5:28'},
 {'rank': '5', 'singer': '校长 ', 'song': ' 带你去旅行', 'time': '3:46'},
 {'rank': '6', 'singer': '金志文、徐佳莹 ', 'song': ' 远走高飞', 'time': '3:55'},
 {'rank': '7', 'singer': '秋裤大叔 ', 'song': ' 一晃就老了', 'time': '4:15'},
 {'rank': '8', 'singer': '毛不易 ', 'song': ' 消愁 (Live)', 'time': '2:59'},
 {'rank': '9', 'singer': '岑宁儿 ', 'song': ' 追光者', 'time': '3:55'},
 {'rank': '10', 'singer': '毛不易 ', 'song': ' 像我这样的人 (Live)', 'time': '2:51'},
 {'rank': '11', 'singer': 'PRC 巴音汗 ', 'song': ' 80000 !', 'time': '1:48'},
 {'rank': '12', 'singer': '白小白 ', 'song': ' 最美情侣', 'time': '4:02'},
 {'rank': '13', 'singer': 'CG ', 'song': ' 文爱', 'time': '3:20'},
 {'rank': '14', 'singer': '李玉刚 ', 'song': ' 刚好遇见你', 'time': '3:19'},
 {'rank': '15', 'singer': '贺敬轩 ', 'song': ' 罗曼蒂克的爱情', 'time': '3:29'},
 {'rank': '16', 'singer': 'Alan Walker ', 'song': ' Faded', 'time': '3:33'},
 {'rank': '17', 'singer': '王建房 ', 'song': ' 在人间', 'time': '3:54'},
 {'rank': '18', 'singer': 'Matteo ', 'song': ' Panama', 'time': '3:20'},
 {'rank': '19', 'singer': '金志文 ', 'song': ' 远走高飞', 'time': '4:01'},
 {'rank': '20', 'singer': 'Beyond ', 'song': ' 不再犹豫', 'time': '4:12'},
 {'rank': '21', 'singer': '周杰伦 ', 'song': ' 告白气球', 'time': '3:36'},
 {'rank': '22', 'singer': '黑龙 ', 'song': ' 盗心贼', 'time': '3:34'}]
```


图4.46　爬取数据

把爬取的数据传给DataFrame构造器，如图4.47所示。

```
from pandas import DataFrame
df = DataFrame(data)
df
```

	rank	singer	song	time
0	1	大壮	我们不一样	4:31
1	2	张北北	拥抱你离去	4:02
2	3	杨宗纬、张碧晨	凉凉	5:33
3	4	赵雷	成都	5:28
4	5	校长	带你去旅行	3:46
5	6	金志文、徐佳莹	远走高飞	3:55
6	7	秋裤大叔	一晃就老了	4:15
7	8	毛不易	消愁 (Live)	2:59
8	9	岑宁儿	追光者	3:55
9	10	毛不易	像我这样的人 (Live)	2:51
10	11	PRC 巴音汗	80000！	1:48
11	12	白小白	最美情侣	4:02
12	13	CG	文爱	3:20
13	14	李玉刚	刚好遇见你	3:19

图4.47　DataFrame数据

第5章　数据清洗与整理

有效的数据是进行数据分析的依据，因此在数据分析中，数据的处理往往需要花费70%的时间，可见数据处理的重要性。本章将讲解在pandas中如何进行多数据清洗和处理，并介绍针对多源数据的合并和连接，以及数据的重塑等内容，最后通过一个综合示例，让读者学会数据分析中的数据清洗方法。

下面给出本章涉及的知识点与学习目标。

· pandas数据清洗：学会常见的数据清洗方法。

· 数据合并：学会多源数据的合并和连接。

· 数据重塑：针对层次化索引，学会stack和unstack的使用。

· 字符串处理：学会DataFrame中字符串函数的使用。

5.1 数据清洗

现实中通过各种方式收集到的数据都是“肮脏”的。本节将着重讲解数据清洗的工作，如缺失值的处理、重复数据的处理及如何替代值等具体操作。

5.1.1 处理缺失值

有时由于设备原因（设备故障或无法存入数据等）或人为原因（没有录入或故意隐藏数据等），我们获取的部分数据可能是缺失值。这些缺失值对于数据分析而言是没有任何意义的，需要通过程序处理掉这些缺失值，以便下一步分析。

1. 侦查缺失值

通过人工查看DataFrame数据是否有缺失值的方法是很低效的。尤其当数据量大时，人工查看很耗时间。通过isnull和notnull方法，可以返回布尔值的对象，如图5.1和图5.2所示。

这时通过求和可以获取每列的缺失值数量，再通过求和就可以获取整个DataFrame的缺失值数量，如图5.3所示。

```
from pandas import Series,DataFrame
import pandas as pd
import numpy as np
```

```
df1 = DataFrame([[3,5,3],[1,6,np.nan],
                 ['lili',np.nan,'pop'],[np.nan,'a','b']])
df1
```

	0	1	2
0	3	5	3
1	1	6	NaN
2	lili	NaN	pop
3	NaN	a	b

图5.1 创建有缺失值的DataFrame

```
df1.isnull()    #True的为缺失值
```

	0	1	2
0	False	False	False
1	False	False	True
2	False	True	False
3	True	False	False

```
df1.notnull()    #False为缺失值
```

	0	1	2
0	True	True	True
1	True	True	False
2	True	False	True
3	False	True	True

图5.2　查看缺失值

通过info方法，也可以看出DataFrame每列数据的缺失值情况，如图5.4所示。

```
df1.isnull().sum()
```

```
0    1
1    1
2    1
dtype: int64
```

```
df1.isnull().sum().sum()
```

```
3
```

图5.3　缺失值计数

```
df1.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4 entries, 0 to 3
Data columns (total 3 columns):
0    3 non-null object
1    3 non-null object
2    3 non-null object
dtypes: object(3)
memory usage: 176.0+ bytes
```

图5.4　通过info方法查看缺失值

2．删除缺失值

在缺失值的处理方法中，删除缺失值是常用的方法之一。通过dropna方法可以删除具有缺失值的行，如图5.5所示。

```
df1.dropna()
```

	0	1	2
0	3	5	3

图5.5　删除缺失值行

传入how=’all’，则只会删除全为NaN的那些行，如图5.6所示。

```
df2 = DataFrame(np.arange(12).reshape(3,4))
df2
```

	0	1	2	3
0	0	1	2	3
1	4	5	6	7
2	8	9	10	11

```
df2.ix[2,:] = np.nan
df2[3] = np.nan
df2
```

	0	1	2	3
0	0.0	1.0	2.0	NaN
1	4.0	5.0	6.0	NaN
2	NaN	NaN	NaN	NaN

```
df2.dropna(how='all')
```

	0	1	2	3
0	0.0	1.0	2.0	NaN
1	4.0	5.0	6.0	NaN

图5.6　删除全为NaN的行

如果需要删除列，则指定轴方向即可，如图5.7所示。

```
df2.dropna(how='all',axis=1)
```

	0	1	2
0	0.0	1.0	2.0
1	4.0	5.0	6.0
2	NaN	NaN	NaN

图5.7　删除全为NaN的列

3．填充缺失值

当数据量不够或许其他部分信息很重要的时候，就不能删除数据了，这时就需要对缺失值进行填充。通过fillna方法可以将缺失值替换为常数值，如图5.8所示。

```
df2
```

	0	1	2	3
0	0.0	1.0	2.0	NaN
1	4.0	5.0	6.0	NaN
2	NaN	NaN	NaN	NaN

```
df2.fillna(0)
```

	0	1	2	3
0	0.0	1.0	2.0	0.0
1	4.0	5.0	6.0	0.0
2	0.0	0.0	0.0	0.0

图5.8　填充缺失值

在fillna中传入字典结构数据，可以针对不同列填充不同的值，fillna返回的是新对象，不会对原数据进行修改，可通过inplace就地进行修改，如图5.9所示。

```
df2.fillna({1:6,3:0})
```

	0	1	2	3
0	0.0	1.0	2.0	0.0
1	4.0	5.0	6.0	0.0
2	NaN	6.0	NaN	0.0

```
df2
```

	0	1	2	3
0	0.0	1.0	2.0	NaN
1	4.0	5.0	6.0	NaN
2	NaN	NaN	NaN	NaN

```
df2.fillna({1:6,3:0},inplace=True)
df2
```

	0	1	2	3
0	0.0	1.0	2.0	0.0
1	4.0	5.0	6.0	0.0
2	NaN	6.0	NaN	0.0

图5.9　针对不同列填充不同值

对重新索引（reindex）中填充缺失值的方法同样适用于fillna中，如图5.10所示。也可以通过平均值等作为填充数，具体操作如图5.11所示。

```
df2.fillna(method='ffill')
```

	0	1	2	3
0	0.0	1.0	2.0	0.0
1	4.0	5.0	6.0	0.0
2	4.0	6.0	6.0	0.0

图5.10　填充方法

```
df2
```

	0	1	2	3
0	0.0	1.0	2.0	0.0
1	4.0	5.0	6.0	0.0
2	NaN	6.0	NaN	0.0

```
df2[0] = df2[0].fillna(df2[0].mean())
df2
```

	0	1	2	3
0	0.0	1.0	2.0	0.0
1	4.0	5.0	6.0	0.0
2	2.0	6.0	NaN	0.0

图5.11　填充平均值

对于fillna的参数，可以通过“？”进行帮助查询，这也是自我学习最好的方法，如图5.12所示。

```
In [32]: df2.fillna?
In [ ]:
```

```
Signature: df2.fillna(value=None, method=None, axis=None, inplace=False, limit=None, downcast=None, **kwargs)
Docstring:
Fill NA/NaN values using the specified method

Parameters
----------
value : scalar, dict, Series, or DataFrame
    Value to use to fill holes (e.g. 0), alternately a
    dict/Series/DataFrame of values specifying which value to use for
    each index (for a Series) or column (for a DataFrame). (values not
    in the dict/Series/DataFrame will not be filled). This value cannot
    be a list.
method : {'backfill', 'bfill', 'pad', 'ffill', None}, default None
    Method to use for filling holes in reindexed Series
    pad / ffill: propagate last valid observation forward to next valid
    backfill / bfill: use NEXT valid observation to fill gap
axis : {0 or 'index', 1 or 'columns'}
```

图5.12　查看帮助

5.1.2　移除重复数据

在爬取的数据中往往会出现重复数据，对于重复数据保留一份即可，其余的可做移除处理。在DataFrame中，通过duplicated方法判断各行是否有重复数据，如图5.13所示。

```
data = {
    'name':['张三', '李四', '张三', '小明'],
    'sex':['female', 'male', 'female', 'male'],
    'year':[2001, 2002, 2001, 2002],
    'city':['北京', '上海', '北京', '北京']
}
df1 = DataFrame(data)
df1
```

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	male	2002
2	北京	张三	female	2001
3	北京	小明	male	2002

```
df1.duplicated()
```

```
0    False
1    False
2     True
3    False
dtype: bool
```

图5.13　查看重复值

通过drop_duplicates方法，可以删除多余的重复项，如图5.14所示。

在这种情况下，当每行的每个字段都相同时才会判断为重复项。当然，也可以通过指定部分列作为判断重复项的依据，如图5.15所示。

```
df1.drop_duplicates()
```

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	male	2002
3	北京	小明	male	2002

图5.14　删除重复项

```
df1.drop_duplicates(['sex','year'])
```

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	male	2002

图5.15　指定部分列

通过结果可看出，保留的数据为第一个出现的组合。传入keep='last'可以保留最后一个出现的组合，如图5.16所示。

```
df1.drop_duplicates(['sex','year'],keep='last')
```

	city	name	sex	year
2	北京	张三	female	2001
3	北京	小明	male	2002

图5.16　保留最后出现的组合

5.1.3　替换值

替换值类似于Excel中的替换功能，是对查询到的数据替换为相应的数据。在pandas中，通过replace可完成替换值的功能，如图5.17所示。

也可以同时针对不同值进行多值替换，参数传入方式可以是列表也可以是字典格式，如图5.18所示。

```
data = {
    'name':['张三', '李四', '王五', '小明'],
    'sex':['female', 'male', '', 'male'],
    'year':[2001, 2003, 2001, 2002],
    'city':['北京', '上海', '', '北京']
}
df1 = DataFrame(data)
df1
```

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	male	2003
2		王五		2001
3	北京	小明	male	2002

```
df1.replace('','不详')
```

	city	name	sex	year
0	北京	张三	female	2001
1	上海	李四	male	2003
2	不详	王五	不详	2001
3	北京	小明	male	2002

图5.17　替换值

```
df1.replace(['',2001],['不详',2002])
```

	city	name	sex	year
0	北京	张三	female	2002
1	上海	李四	male	2003
2	不详	王五	不详	2002
3	北京	小明	male	2002

```
df1.replace({'':'不详',2001:2002})
```

	city	name	sex	year
0	北京	张三	female	2002
1	上海	李四	male	2003
2	不详	王五	不详	2002
3	北京	小明	male	2002

图5.18　多值替换

5.1.4　利用函数或映射进行数据转换

在第3章中曾讲过函数应用和映射内容，本节将通过例子来讲解函数和映射在数据处理中的使用情况。如图5.19所示为某个班级学生的数学成绩表，我们定义一个等级情况：分数在90～100之间为优秀；分数在70～89之间为良好；分数在60～69之间为合格，分数低于60分为不合格。在Excel中，通过if函数去实现分数等级的划分，在pandas中定义好函数，通过map方法也可以实现同样的效果，如图5.20所示。

注意：对于一列数据的转换，也可以通过apply函数来实现。

```
data = {
    'name':['张三', '李四', '王五', '小明'],
    'math':[79, 52, 63, 92]
}
df2 = DataFrame(data)
df2
```

	math	name
0	79	张三
1	52	李四
2	63	王五
3	92	小明

图5.19　数学成绩

```
def f(x):
    if x >= 90:
        return '优秀'
    elif 70<=x<90:
        return '良好'
    elif 60<=x<70:
        return '合格'
    else:
        return '不合格'
```

```
df2['class'] = df2['math'].map(f)
df2
```

	math	name	class
0	79	张三	良好
1	52	李四	不合格
2	63	王五	合格
3	92	小明	优秀

图5.20　函数应用

5.1.5　检测异常值

设备故障和人为操作失误都会产生异常值，在数据分析中，通常会通过一些可视化的方法去找离群点，这些离群点可能就是异常值。但初学者一定要注意：并非所有的离群点都是异常值，需要根据业务常识等辅助经验进行判断。如图5.21和图5.22所示，查找的离群点可能是因为人为原因将小数点输错了，从而导致的异常点。

```
df3 = DataFrame(np.arange(10),columns=['X'])
df3['Y'] = 2 * df3['X'] + 0.5
df3.iloc[9,1] = 185
df3
```

	X	Y
0	0	0.5
1	1	2.5
2	2	4.5
3	3	6.5
4	4	8.5
5	5	10.5
6	6	12.5
7	7	14.5
8	8	16.5
9	9	185.0

```
df3.plot(kind='scatter',x='X',y='Y')
```

图5.21　DataFrame数据

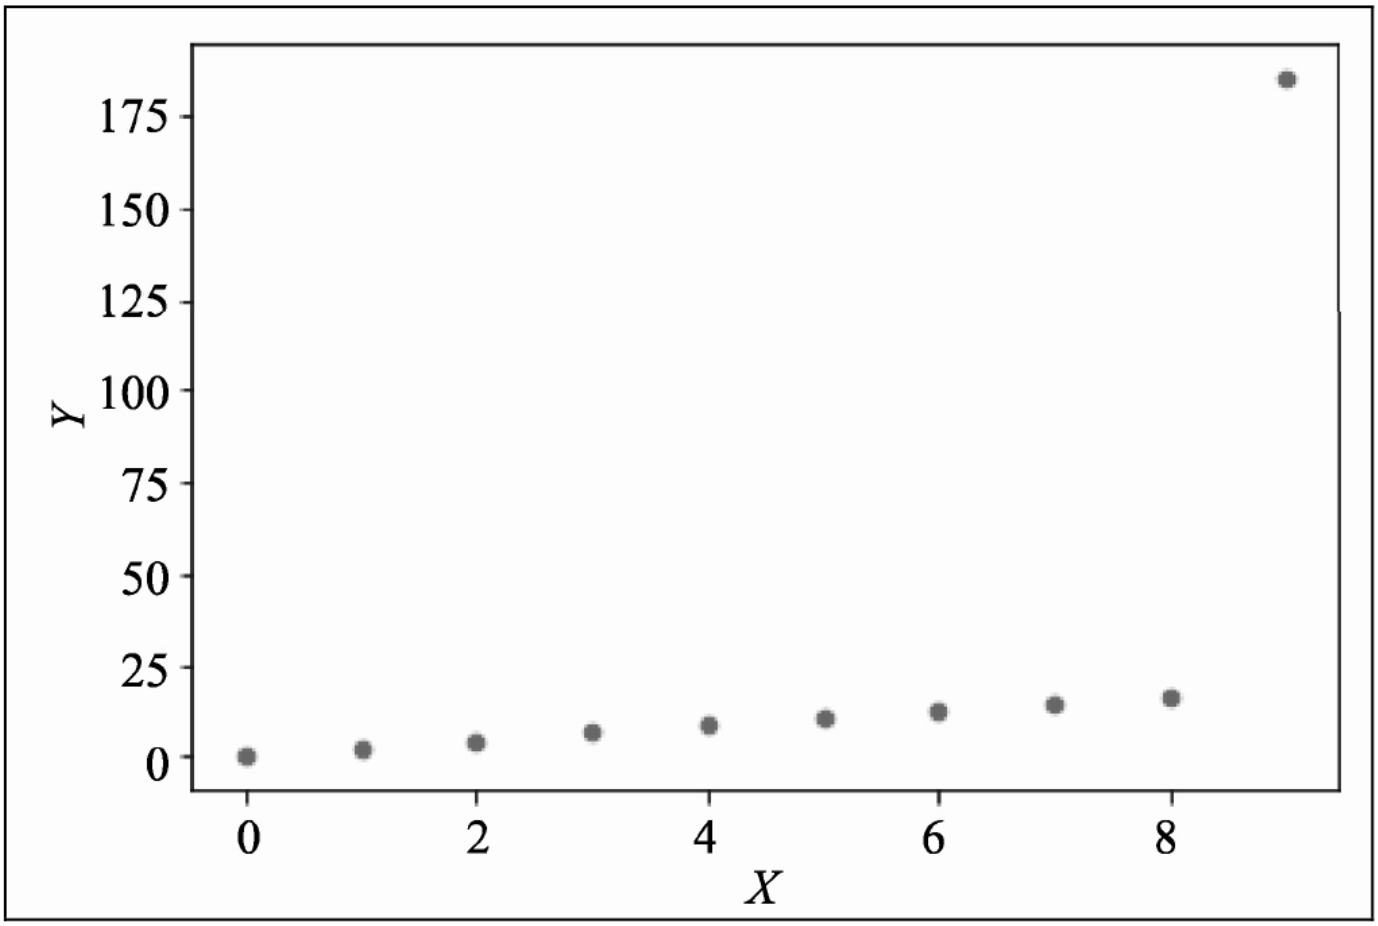

图5.22　检查异常点

5.1.6　虚拟变量

在数学建模和机器学习中，只有数值型数据才能供算法使用，对于一些分类变量则需要将其转换为虚拟变量（哑变量）（也就是0,1矩阵），通过get_dumnies函数即可实现该功能，如图5.23所示。

```
df = DataFrame({
    '朝向':['东','南','东','西','北'],
    '价格':[1200,2100,2300,2900,1400]
})
df
```

	价格	朝向
0	1200	东
1	2100	南
2	2300	东
3	2900	西
4	1400	北

```
pd.get_dummies(df['朝向'])
```

	东	北	南	西
0	1	0	0	0
1	0	0	1	0
2	1	0	0	0
3	0	0	0	1
4	0	1	0	0

图5.23　创建虚拟变量

如图5.24所示，对于多类别的数据而言，需要通过apply函数来实现。具体操作如图5.25所示。

```
df2 = DataFrame({
    '朝向':['东/北','西/南','东','西/北','北'],
    '价格':[1200,2100,2300,2900,1400]
})
df2
```

	价格	朝向
0	1200	东/北
1	2100	西/南
2	2300	东
3	2900	西/北
4	1400	北

图5.24　多类别的数据

```
dummies = df2['朝向'].apply(lambda x:Series(x.split('/')).value_counts())
dummies
```

	东	北	南	西
0	1.0	1.0	NaN	NaN
1	NaN	NaN	1.0	1.0
2	1.0	NaN	NaN	NaN
3	NaN	1.0	NaN	1.0
4	NaN	1.0	NaN	NaN

```
dummies = dummies.fillna(0).astype(int)
dummies
```

	东	北	南	西
0	1	1	0	0
1	0	0	1	1
2	1	0	0	0
3	0	1	0	1
4	0	1	0	0

图5.25　创建虚拟变量

5.2　数据合并和重塑

在实际的数据分析工作中，可能有不同的数据来源，这时需通过合并等操作对数据进行处理。本节将讲解pandas中的数据合并和重塑。

5.2.1　merge合并

merge函数是通过一个或多个键（DataFrame的列）将两个DataFrame按行合并起来，其方式与关系型数据库一样。首先来看一个简单的例子，数据情况如图5.26所示。

```
price = DataFrame({
    'fruit':['apple','banana','orange'],
    'price':[23,32,45]
})
amount = DataFrame({
    'fruit':['apple','banana','apple','apple','banana','pear'],
    'amount':[5,3,6,3,5,7]
})
```

```
price
```

	fruit	price
0	apple	23
1	banana	32
2	orange	45

```
amount
```

	amount	fruit
0	5	apple
1	3	banana
2	6	apple
3	3	apple
4	5	banana

图5.26　数据情况

这是多对一的合并情况，合并结果如图5.27所示。

```
pd.merge(amount,price)
```

	amount	fruit	price
0	5	apple	23
1	6	apple	23
2	3	apple	23
3	3	banana	32
4	5	banana	32

图5.27　内连接

由于两个DataFrame都有fruit列名，所以默认按该列进行合并。当然，也可以指定键名，如果两个DataFrame的列名不一样，也可以单独指定，如图5.28所示。

```
pd.merge(amount,price,on='fruit')
```

	amount	fruit	price
0	5	apple	23
1	6	apple	23
2	3	apple	23
3	3	banana	32
4	5	banana	32

```
pd.merge(amount,price,left_on='fruit',right_on='fruit')
```

	amount	fruit	price
0	5	apple	23
1	6	apple	23
2	3	apple	23
3	3	banana	32
4	5	banana	32

图5.28　指定连接键

通过图5.27可以看出，merge默认为内连接（inner），也就是返回交集。通过how参数可以选择连接方法：左连接（left）、右连接（right）和外连接（outer），如图5.29和图5.30所示。

```
pd.merge(amount,price,how='left')
```

	amount	fruit	price
0	5	apple	23.0
1	3	banana	32.0
2	6	apple	23.0
3	3	apple	23.0
4	5	banana	32.0
5	7	pear	NaN

```
pd.merge(amount,price,how='right')
```

	amount	fruit	price
0	5.0	apple	23
1	6.0	apple	23
2	3.0	apple	23
3	3.0	banana	32
4	5.0	banana	32
5	NaN	orange	45

图5.29　左、右连接

```
pd.merge(amount,price,how='outer')
```

	amount	fruit	price
0	5.0	apple	23.0
1	6.0	apple	23.0
2	3.0	apple	23.0
3	3.0	banana	32.0
4	5.0	banana	32.0
5	7.0	pear	NaN
6	NaN	orange	45.0

图5.30　外连接

多对多的连接会产生笛卡尔积，如图5.31所示。左边的DataFrame有3个apple，右边有2个apple，这样连接的DataFrame就有6个apple，如图5.32所示。

```
amount2
```

	amount	fruit
0	5	apple
1	3	banana
2	6	apple
3	3	apple
4	5	banana
5	7	pear

```
price2
```

	fruit	price
0	apple	23
1	banana	32
2	orange	45
3	apple	25

图5.31　多对多数据

当然，也可以通过多个键进行合并，即传入一个list即可，如图5.33所示。

```
pd.merge(amount2,price2)
```

	amount	fruit	price
0	5	apple	23
1	5	apple	25
2	6	apple	23
3	6	apple	25
4	3	apple	23
5	3	apple	25
6	3	banana	32
7	5	banana	32

图5.32　多对多连接

	key1	key2	val1
0	one	a	2
1	one	b	3
2	two	a	4

```
right
```

	key1	key2	val2
0	one	a	5
1	one	a	6
2	two	a	7
3	two	b	8

```
pd.merge(left,right,on=['key1','key2'],how='outer')
```

	key1	key2	val1	val2
0	one	a	2.0	5.0
1	one	a	2.0	6.0
2	one	b	3.0	NaN
3	two	a	4.0	7.0
4	two	b	NaN	8.0

图5.33　多键连接

在合并时要考虑到重复列名的问题，如图5.34所示。虽然可以人为进行重复列名的修改，但merge函数提供了suffixes用于处理该问题，如图5.35所示。

```
pd.merge(left,right,on='key1')
```

	key1	key2_x	val1	key2_y	val2
0	one	a	2	a	5
1	one	a	2	a	6
2	one	b	3	a	5
3	one	b	3	a	6
4	two	a	4	a	7
5	two	a	4	b	8

图5.34　重复列名默认处理

```
pd.merge(left,right,on='key1',suffixes=('_left','_right'))
```

	key1	key2_left	val1	key2_right	val2
0	one	a	2	a	5
1	one	a	2	a	6
2	one	b	3	a	5
3	one	b	3	a	6
4	two	a	4	a	7
5	two	a	4	b	8

图5.35　重复列名处理

有时连接的键位于DataFrame的行索引上，可通过传入left_index=True或者right_index=True指定将索引作为连接键来使用，如图5.36和图5.37所示。

```
left2
```

	key	val1
0	a	0
1	a	1
2	b	2
3	b	3
4	c	4

```
right2
```

	val2
a	5
b	7

图5.36　数据

```
pd.merge(left2,right2,left_on='key',right_index=True)
```

	key	val1	val2
0	a	0	5
1	a	1	5
2	b	2	7
3	b	3	7

图5.37　索引作为连接键

DataFrame中有一个join方法，可以快速完成按索引合并，如图5.38所示。

	val1
a	0
b	1
a	2
c	3

```
right3
```

	val2
a	5
b	7

```
left3.join(right3,how='outer')
```

	val1	val2
a	0	5.0
a	2	5.0
b	1	7.0
c	3	NaN

图5.38　join实例方法

通过以上的案例，总结merge使用的常用参数如表5.1所示。

表5.1　merge函数常用参数

参　　数	使用说明
left	参与合并的左侧DataFrame
right	参与合并的右侧DataFrame
how	连接方法：inner、left、right、outer
on	用于连接的列名
left_on	左侧DataFrame中用于连接键的列
right_on	右侧DataFrame中用于连接键的列
left_index	左侧DataFrame的行索引作为连接键
right_index	右侧DataFrame的行索引作为连接键
sort	合并后会对数据排序，默认为True
suffixes	修改重复名

5.2.2　concat连接

如果需要合并的DataFrame之间没有连接键，就不能使用merge方法了，这时可通过pandas的concat方法实现。如图5.39所示为3个没有相同索引的Series，使用concat连接，会按行的方向堆叠数据。

默认情况下，concat是在axis=0上工作的，当然通过指定轴向也可以按列进行连接，如图5.40所示。

```
s1 = Series([0,1],index=['a','b'])
s2 = Series([2,3],index=['c','d'])
s3 = Series([4,5],index=['e','f'])
```

```
pd.concat([s1,s2,s3])
```

```
a    0
b    1
c    2
d    3
e    4
f    5
dtype: int64
```

图5.39　concat连接

```
pd.concat([s1, s2, s3], axis=1)
```

	0	1	2
a	0.0	NaN	NaN
b	1.0	NaN	NaN
c	NaN	2.0	NaN
d	NaN	3.0	NaN
e	NaN	NaN	4.0
f	NaN	NaN	5.0

图5.40　按列连接

这样就会生成一个DataFrame。通过结果可以看出，这种连接方式为外连接（并集），通过传入join=’inner’可以实现内连接，如图5.41所示。

注意：concat只有内连接和外连接。

可以通过join_axes指定使用的索引顺序，如图5.42所示。

```
s4 = pd.concat([s1*10,s3])
s4
```

```
a     0
b    10
e     4
f     5
dtype: int64
```

```
pd.concat([s1,s4],axis=1)
```

	0	1
a	0.0	0
b	1.0	10
e	NaN	4
f	NaN	5

```
pd.concat([s1,s4],axis=1,join='inner')
```

	0	1
a	0	0
b	1	10

图5.41　内、外连接

```
pd.concat([s1,s4],axis=1,join='inner')
```

	0	1
a	0	0
b	1	10

```
pd.concat([s1,s4],axis=1,join='inner',join_axes=[['b','a']])
```

	0	1
b	1	10
a	0	0

图5.42　指定索引顺序

参与连接的数据对象在结果中是分不开的，可通过keys参数给连接对象创建一个层次化索引，如图5.43所示。

```
pd.concat([s1,s4])
```

```
a     0
b     1
a     0
b    10
e     4
f     5
dtype: int64
```

```
pd.concat([s1,s4],keys=['one','two'])
```

```
one  a     0
     b     1
two  a     0
     b    10
     e     4
     f     5
dtype: int64
```

图5.43　层次化索引

如果按列连接，keys就成了DataFrame的列索引，如图5.44所示。concat连接对于DataFrame是同样适用的，如图5.45所示。

```
pd.concat([s1,s4],axis=1,keys=['one','two'])
```

	one	two
a	0.0	0
b	1.0	10
e	NaN	4
f	NaN	5

图5.44　转换为列索引

```
df1
```

	val1
a	0
b	1
c	2

```
df2
```

	val2
a	5
b	7

```
pd.concat([df1,df2],axis=1,keys=['one','two'])
```

	one	two
	val1	val2
a	0	5.0
b	1	7.0
c	2	NaN

图5.45　DataFrame连接

除了传入列表，通过字典数据也可以完成连接，字典的键就是keys的值，如图5.46所示。

```
pd.concat({'one':df1,'two':df2},axis=1)
```

	one	two
	val1	val2
a	0	5.0
b	1	7.0
c	2	NaN

图5.46　传入字典结构

如图5.47所示，当行索引类似时，通过默认连接会出现重复行索引。这时可通过ignore_index= ‘True’忽略索引，以达到重排索引的效果，如图5.48所示。

```
df1 = DataFrame(np.random.randn(3,4),columns=['a','b','c','d'])
df2 = DataFrame(np.random.randn(2,2),columns=['d','c'])
```

```
df1
```

	a	b	c	d
0	0.023541	-0.694903	-0.515242	0.460737
1	-1.326048	0.259269	-0.685732	0.052237
2	-0.110079	2.729854	-0.503138	-1.721161

```
df2
```

	d	c
0	0.995995	-0.342845
1	0.848536	1.027354

图5.47　DataFrame数据

```
pd.concat([df1,df2])
```

	a	b	c	d
0	0.023541	-0.694903	-0.515242	0.460737
1	-1.326048	0.259269	-0.685732	0.052237
2	-0.110079	2.729854	-0.503138	-1.721161
0	NaN	NaN	-0.342845	0.995995
1	NaN	NaN	1.027354	0.848536

```
pd.concat([df1,df2],ignore_index=True)
```

	a	b	c	d
0	0.023541	-0.694903	-0.515242	0.460737
1	-1.326048	0.259269	-0.685732	0.052237
2	-0.110079	2.729854	-0.503138	-1.721161
3	NaN	NaN	-0.342845	0.995995
4	NaN	NaN	1.027354	0.848536

图5.48　忽略索引

5.2.3　combine_first合并

如图5.49所示，如果需要合并的两个DataFrame存在重复的索引，在这种情况下，若使用merge和concat方法都不能准确地解决问题，此时就需要使用combine_first方法，该方法类似于“打补丁”，如图5.50所示。

```
df1
```

	a	b
0	3.0	NaN
1	NaN	4.0
2	6.0	6.0
3	NaN	NaN

```
df2
```

	a	b
0	0	0
1	1	1
2	2	2
3	3	3
4	4	4

图5.49　数据情况

```
df1.combine_first(df2)
```

	a	b
0	3.0	0.0
1	1.0	4.0
2	6.0	6.0
3	3.0	3.0
4	4.0	4.0

图5.50　combine_first合并

5.2.4　数据重塑

数据重塑用于重排DataFrame，有两个常用的方法：stack方法用于将DataFrame的列“旋转”为行；unstack方法用于将DataFrame的行“旋转”为列。stack方法的具体用法如图5.51所示。

```
df = DataFrame(np.arange(9).reshape(3,3),
               index = ['a','b','c'],
               columns=['one','two','three'])
df.index.name = 'alph'
df.columns.name = 'number'
df
```

number	one	two	three
alph			
a	0	1	2
b	3	4	5
c	6	7	8

```
result = df.stack()
result
```

```
alph  number
a     one       0
      two       1
      three     2
b     one       3
      two       4
      three     5
c     one       6
      two       7
      three     8
dtype: int32
```

图5.51　stack方法

将列转换为行后，则生成了一个Series数据，通过unstack又会将其重排为原始数据的形式，如图5.52所示。

```
result.unstack()
```

number	one	two	three
alph			
a	0	1	2
b	3	4	5
c	6	7	8

图5.52　unstack方法

默认情况下，数据重塑的操作都是最内层的，也可以通过级别编号或名称来指定其他级别进行重塑操作，如图5.53所示。

```
result.unstack(0)
```

alph	a	b	c
number			
one	0	3	6
two	1	4	7
three	2	5	8

```
result.unstack('alph')
```

alph	a	b	c
number			
one	0	3	6
two	1	4	7
three	2	5	8

图5.53　指定级别

不仅数据重塑的操作是最内层的，操作的结果也会使旋转轴位于最低级别，如图5.54和图5.55所示。

```
df = DataFrame(np.arange(16).reshape(4,4),
               index=[['one','one','two','two'],['a','b','a','b']],
               columns=[['apple','apple','orange','orange'],['red','green','red','green']])
df
```

		apple		orange	
		red	green	red	green
one	a	0	1	2	3
	b	4	5	6	7
two	a	8	9	10	11
	b	12	13	14	15

图5.54　数据情况

```
df.stack()
```

			apple	orange
one	a	green	1	3
		red	0	2
	b	green	5	7
		red	4	6
two	a	green	9	11
		red	8	10
	b	green	13	15
		red	12	14

```
df.unstack()
```

	apple				orange			
	red		green		red		green	
	a	b	a	b	a	b	a	b
one	0	4	1	5	2	6	3	7
two	8	12	9	13	10	14	11	15

图5.55　重塑结果

5.3　字符串处理

在数据分析中常常会处理一些文本数据，pandas提供了处理字符串的矢量化函数。本节将讲解字符串矢量化函数的使用方法。

5.3.1　字符串方法

如图5.56所示，把数据分成两列，常用的方法是通过函数应用来完成。

```
data = {
    'data':['张三|男', '李四|女', '王五|女', '小明|男'],
}
df = DataFrame(data)
df
```

	data
0	张三|男
1	李四|女
2	王五|女
3	小明|男

```
result = df['data'].apply(lambda x:Series(x.split('|')))
result
```

	0	1
0	张三	男
1	李四	女
2	王五	女
3	小明	男

图5.56　函数应用

pandas中字段的str属性可以轻松调用字符串的方法，并运用到整个字段中（矢量化运算），如图5.57所示。

```
new_df = df['data'].str.split('|')
new_df
```

```
0    [张三, 男]
1    [李四, 女]
2    [王五, 女]
3    [小明, 男]
Name: data, dtype: object
```

```
df['name'] = new_df.str[0]
df['sex'] = new_df.str[1]
df
```

	data	name	sex
0	张三|男	张三	男
1	李四|女	李四	女
2	王五|女	王五	女
3	小明|男	小明	男

图5.57　字符串方法

5.3.2　正则表达式

字符串的矢量化操作同样适用于正则表达式，如图5.58所示。

```
df2 = DataFrame({
    'email':['102345@qq.com','342167@qq.com','65132@qq.com']
})
df2
```

	email
0	102345@qq.com
1	342167@qq.com
2	65132@qq.com

```
df2['email'].str.findall('(.*?)@')
```

```
0    [102345]
1    [342167]
2     [65132]
Name: email, dtype: object
```

```
df2['QQ'] = df2['email'].str.findall('(.*?)@').str.get(0)
df2
```

	email	QQ
0	102345@qq.com	102345
1	342167@qq.com	342167
2	65132@qq.com	65132

图5.58　正则表达式

5.4　综合示例——Iris数据集

本节将以修改过的Iris数据集为例，主要讲解数据分析中数据预处理的详细操作，并通过可视化的手段，分析Iris数据集分类的可操作性。

5.4.1　数据来源

本例使用的Iris（鸢尾花卉）数据集是经过修改的，以该数据集为基础来讲解数据的清洗操作，该数据会提供给读者使用。如图5.59所示，先加载该数据集。

以上的数据经常用于机器学习（分类算法）的入门例子中。其中，sepal_length_cm为花萼长度；sepal_width_cm为花萼宽度；petal_length_cm为花瓣长度；petal_width_cm为花瓣宽度。通过这4个数据，可以判断并分类出3种鸢尾花的类别（class）。

```
from pandas import Series,DataFrame
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib as mpl
import seaborn as sns  #导入seaborn绘图库
%matplotlib inline
```

```
iris_data = pd.read_csv(open('H:\python数据分析\数据\iris-data.csv'))
iris_data.head()
```

	sepal_length_cm	sepal_width_cm	petal_length_cm	petal_width_cm	class
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa

图5.59　Iris数据

5.4.2　定义问题

本例主要是学习如何对数据进行清洗，对于分类问题在本例中不做讲解。本例目的是通过数据可视化和分析，按照鸢尾花的特征分出鸢尾花的类别。

5.4.3　数据清洗

首先对数据进行简单描述，看其中是否有异常值，如图5.60所示。

```
iris_data.shape
```

```
(150, 5)
```

```
iris_data.describe()
```

	sepal_length_cm	sepal_width_cm	petal_length_cm	petal_width_cm
count	150.000000	150.000000	150.000000	145.000000
mean	5.644627	3.054667	3.758667	1.236552
std	1.312781	0.433123	1.764420	0.755058
min	0.055000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.400000
50%	5.700000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000

图5.60　描述统计

通过结果可看出，共有150条数据，通过每个字段的平均值和方差，看不出有异常值，如图5.61所示。查看class的类别，发现不是3种，可能是由于拼写错误造成的，在这里进行修改。

```
iris_data['class'].unique()
```

```
array(['Iris-setosa', 'Iris-setossa', 'Iris-versicolor', 'versicolor',
       'Iris-virginica'], dtype=object)
```

```
iris_data.ix[iris_data['class'] == 'versicolor', 'class'] = 'Iris-versicolor'
iris_data.ix[iris_data['class'] == 'Iris-setossa', 'class'] = 'Iris-setosa'

iris_data['class'].unique()
```

```
array(['Iris-setosa', 'Iris-versicolor', 'Iris-virginica'], dtype=object)
```

图5.61　查看唯一值

回到异常值的处理中，这里分析可能是分类的原因，数据都很均衡。下面利用seaborn绘制散点图矩阵，如图5.62所示，代码如下。

```
sns.pairplot(iris_data, hue='class')
```

注意：pandas根据类别绘制散点图时很麻烦，有兴趣的读者可以学习seaborn的可视化技术。

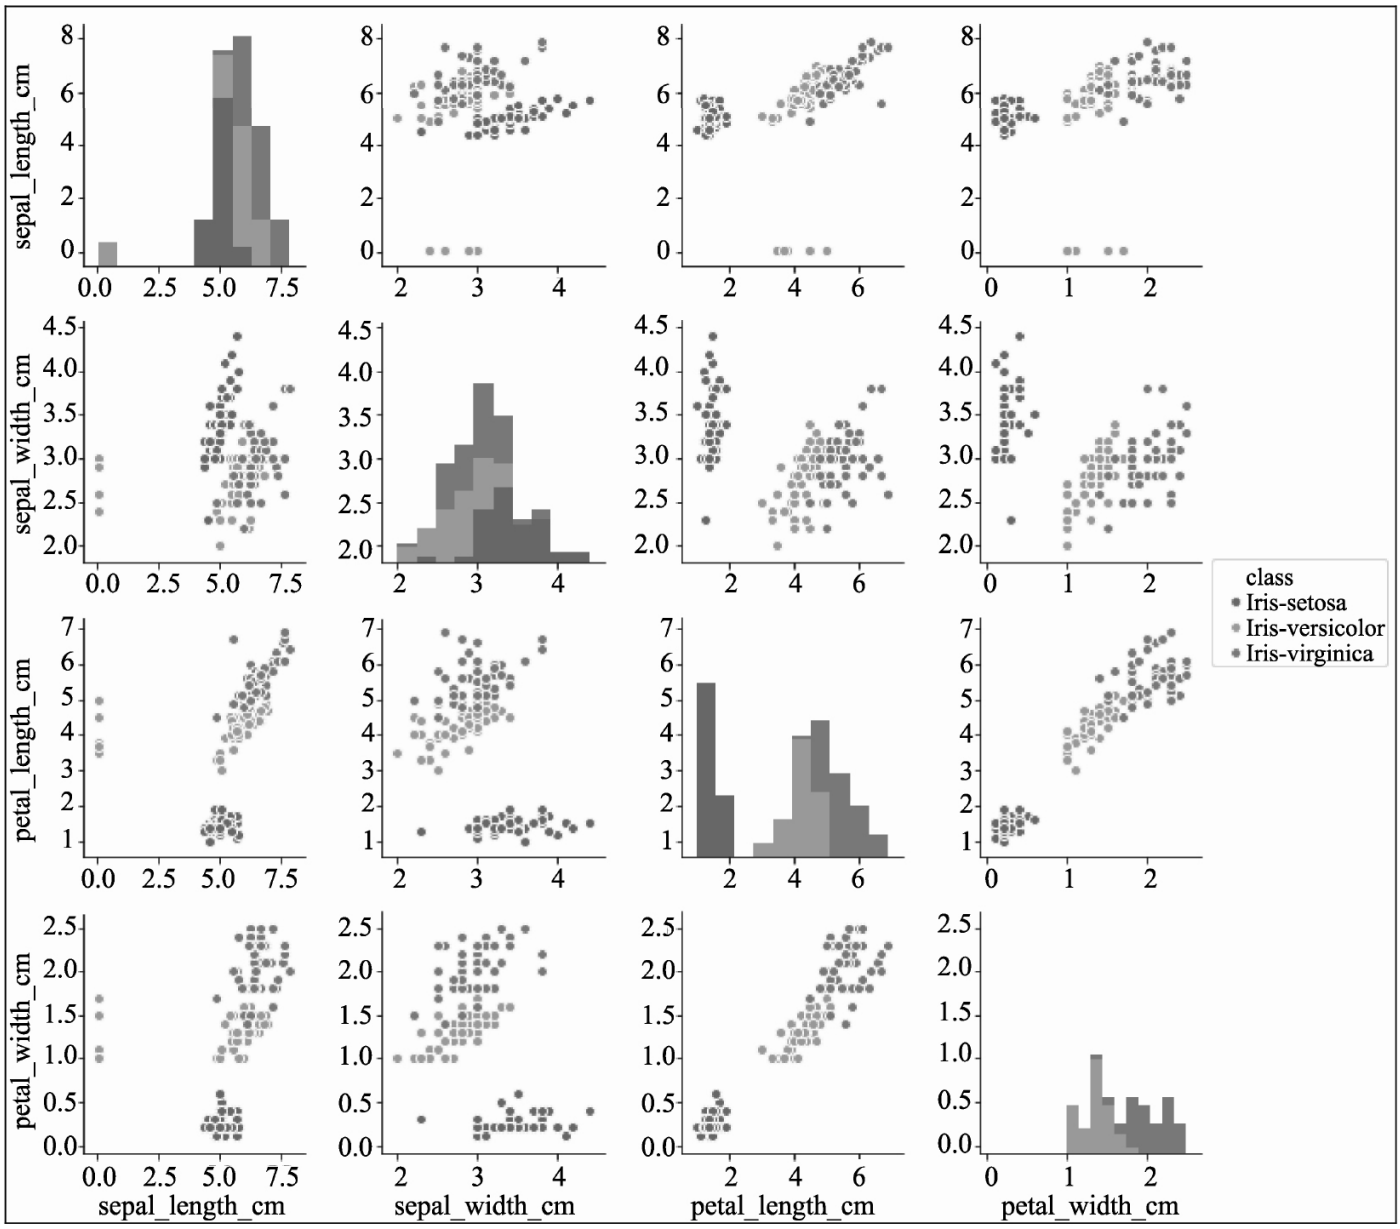

图5.62　散点图矩阵

通过第一列可以看出，有几个Iris-versicolor样本中的sepal_length_cm值偏移了大部分的点；通过第二行可以看出，一个Iris-setosa样本的sepal_width_cm值偏离了大部分的点。

通过对Iris-setosa的花萼宽度绘制直方图也能观测出异常，如图5.63所示。

```
iris_data.ix[iris_data['class'] == 'Iris-setosa', 'sepal_width_cm'].hist()
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x10bfd5c0>
```

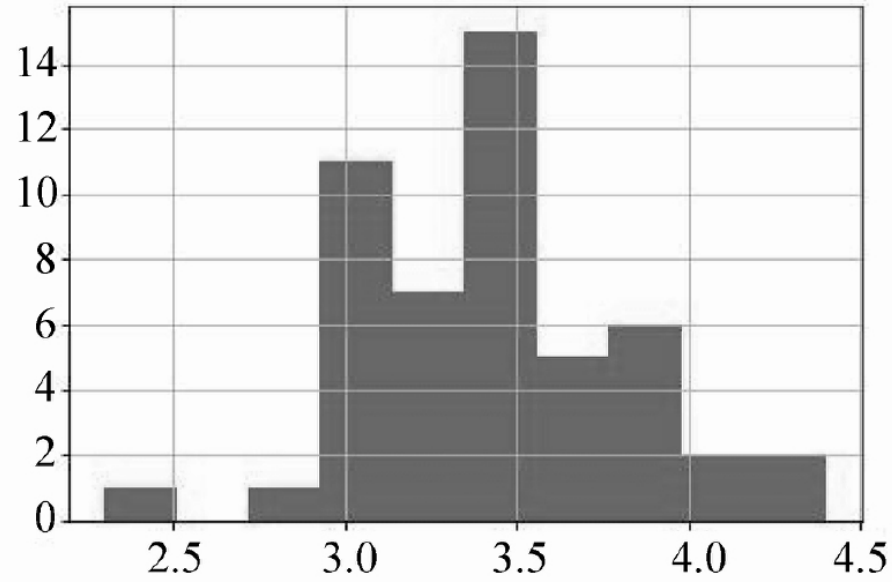

图5.63　Iris-setosa的花萼宽度直方图

这里对异常值产生的原因不够清楚，所以直接对小于2.5cm的数据进行过滤，直方图如图5.64所示。代码如下：

```
iris_data = iris_data.loc[(iris_data['class'] != 'Iris-setosa') | (iris_
data['sepal_width_cm'] >= 2.5)]
iris_data.loc[iris_data['class'] == 'Iris-setosa', 'sepal_width_cm'].hist()
```

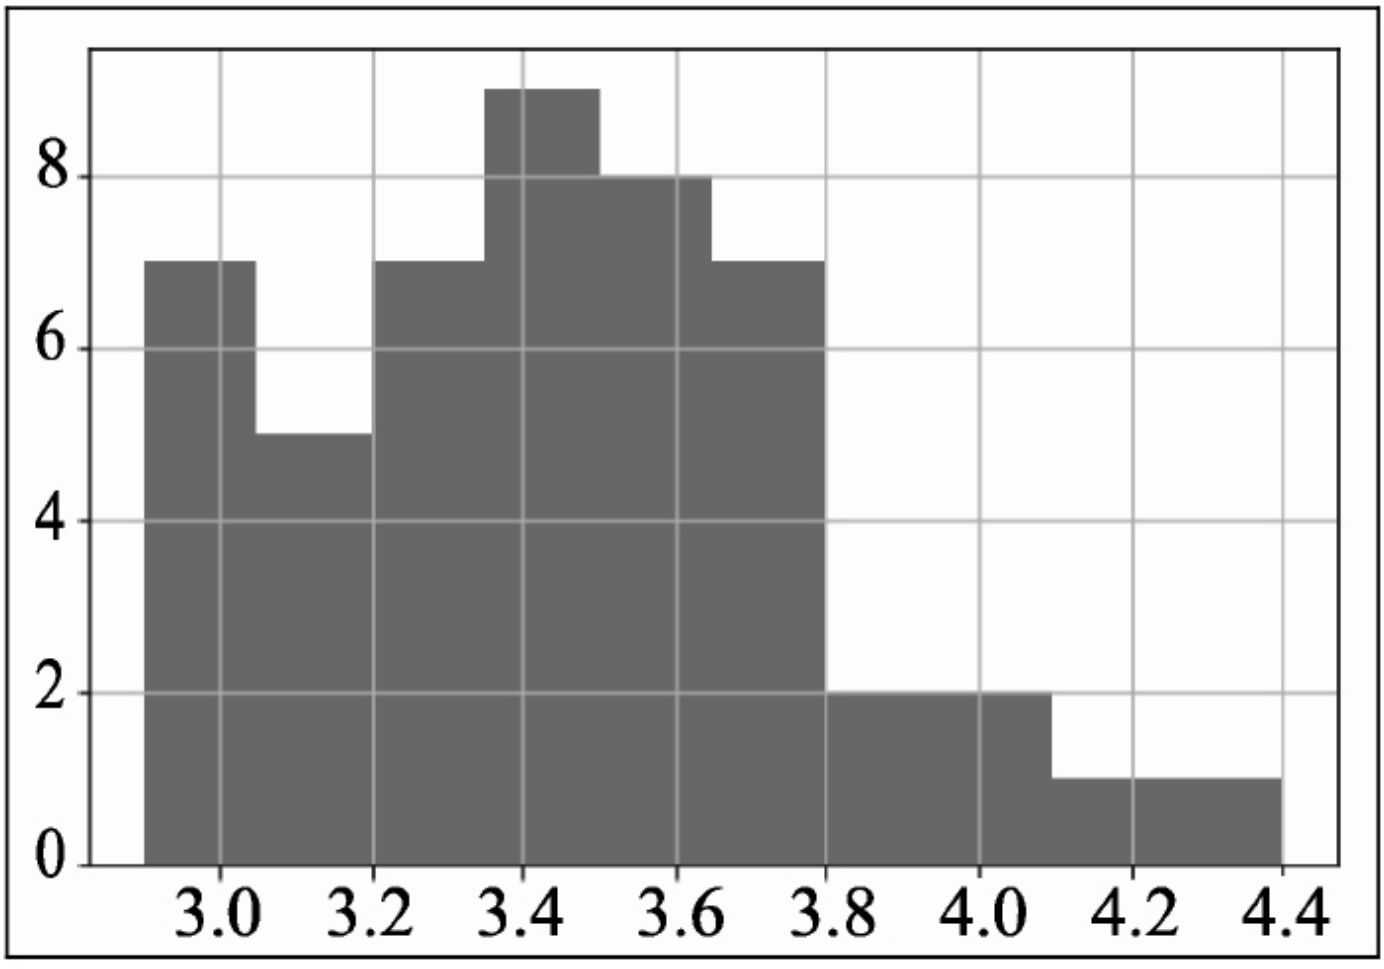

图5.64　处理后的直方图

通过索引选取Iris-versicolor样本中sepal_length_cm值小于0.1的数据，如图5.65所示。

图中的sepal_length_cm数据很小，有可能是单位错误，这里输入的是以m为单位，通过与其他数据比较，初步认为可能是单位设置问题。通过以下代码，对数据乘以100。

```
iris_data.loc[(iris_data['class'] == 'Iris-versicolor') &
              (iris_data['sepal_length_cm'] < 1.0),
              'sepal_length_cm'] *= 100.0
```

```
iris_data.loc[(iris_data['class'] == 'Iris-versicolor') &
              (iris_data['sepal_length_cm'] < 1.0)]
```

	sepal_length_cm	sepal_width_cm	petal_length_cm	petal_width_cm	class
77	0.067	3.0	5.0	1.7	Iris-versicolor
78	0.060	2.9	4.5	1.5	Iris-versicolor
79	0.057	2.6	3.5	1.0	Iris-versicolor
80	0.055	2.4	3.8	1.1	Iris-versicolor
81	0.055	2.4	3.7	1.0	Iris-versicolor

图5.65　选取异常数据

再查看是否有缺失值，如图5.66所示，发现花瓣宽度有5条缺失值，由于3种分类数据样本均衡，因此直接将缺失值进行删除处理。

```
iris_data.isnull().sum()
```

```
sepal_length_cm    0
sepal_width_cm     0
petal_length_cm    0
petal_width_cm     5
class              0
dtype: int64
```

```
iris_data[iris_data['petal_width_cm'].isnull()]
```

	sepal_length_cm	sepal_width_cm	petal_length_cm	petal_width_cm	class
7	5.0	3.4	1.5	NaN	Iris-setosa
8	4.4	2.9	1.4	NaN	Iris-setosa
9	4.9	3.1	1.5	NaN	Iris-setosa
10	5.4	3.7	1.5	NaN	Iris-setosa
11	4.8	3.4	1.6	NaN	Iris-setosa

```
iris_data.dropna(inplace=True)
```

图5.66　处理缺失值

最后对清洗好的数据进行存储，以方便进行下一步分析，如图5.67所示。

```
iris_data.to_csv('H:\python数据分析\数据\iris-clean-data.csv', index=False)
```

```
iris_data = pd.read_csv(open('H:\python数据分析\数据\iris-clean-data.csv'))
iris_data.head()
```

	sepal_length_cm	sepal_width_cm	petal_length_cm	petal_width_cm	class
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa

```
iris_data.shape
```

```
(144, 5)
```

图5.67　保存清洗的数据

5.4.4　数据探索

下面对处理好的数据绘制散点矩阵图。如图5.68所示，可以看出在大部分情况下数据接近正态分布，而且Iris-setosa与其他两种花是线性可分的（用一个直线就可以切分），其他两种花型可能需要通过非线性算法进行分类。

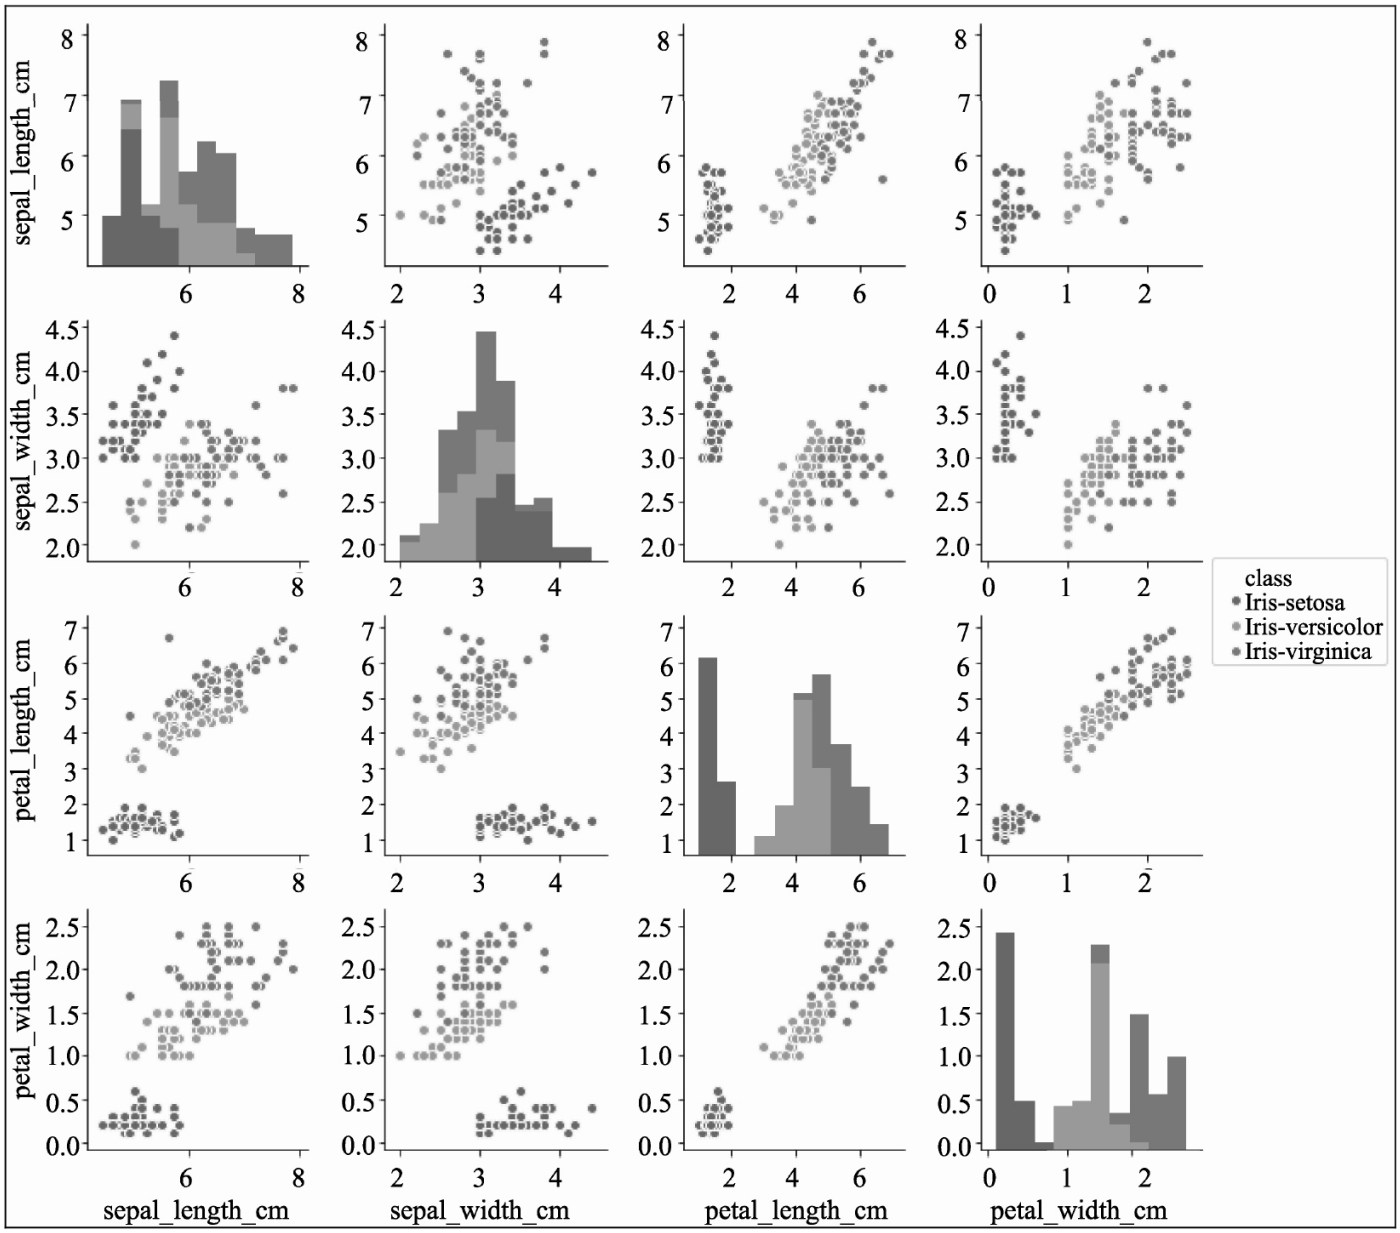

图5.68　散点矩阵图

通过绘制箱形图也可以发现该规律，通过petal_length_cm可以轻松区分Iris-setosa与其他两种花，如图5.69所示。

```
iris_data.boxplot(column='petal_length_cm', by='class',grid=False,figsize=(6,6))
```

注意：boxplot用于绘制箱形图，figsize可设置画布的大小。

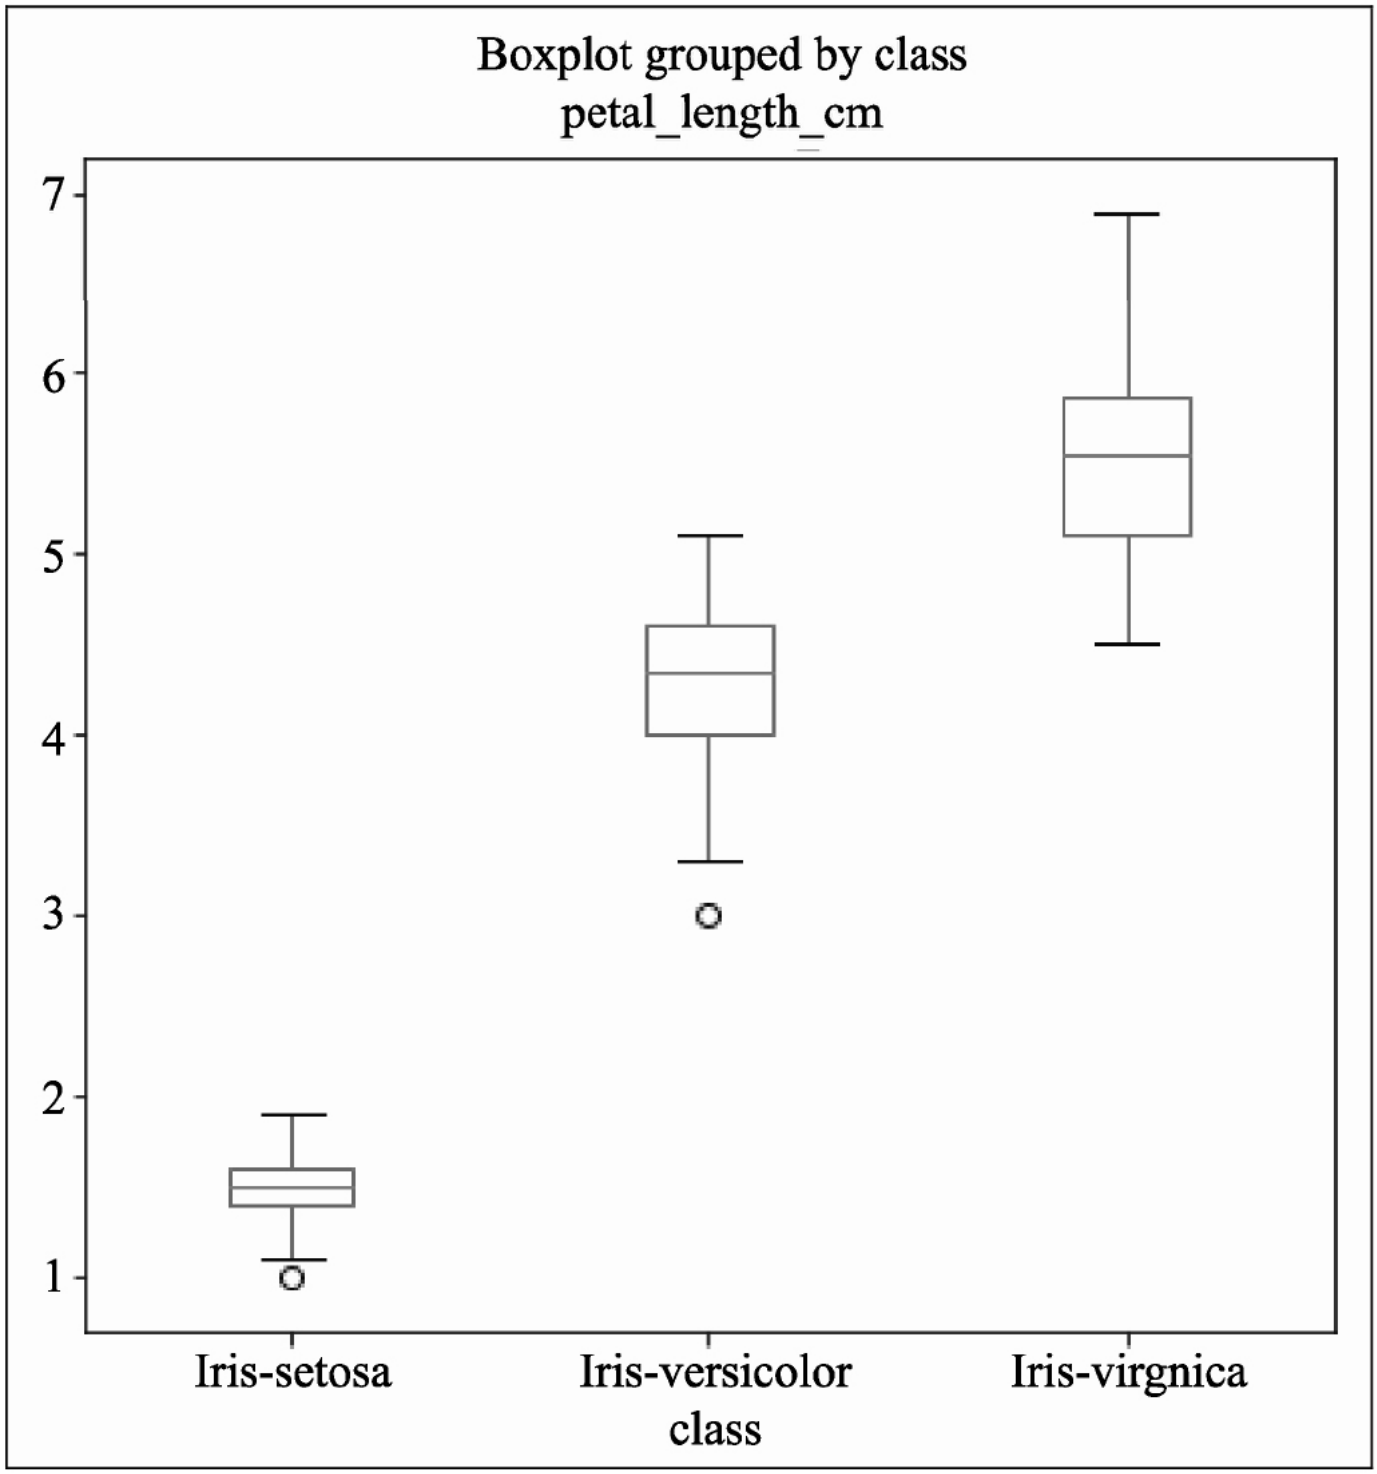

图5.69　箱形图

第6章　数据分组与聚合

数据的分组统计是数据分析工作中的重要环节。本章将讲解GroupBy的原理和使用方法；聚合函数的使用；分组运算中transform和apply方法的使用；通过pandas创建数据透视表的方法；最后通过一个综合示例，巩固数据分组统计的使用。

下面给出本章涉及的知识点与学习目标。

· 数据分组：了解数据分组的原理和GroupBy的使用方法。

· 聚合运算：学会分组数据的聚合运算方法和函数使用。

· 分组运算：重点掌握apply方法的使用。

· 数据透视表：学会构建数据透视表和交叉表。

6.1 数据分组

数据分组的思想来源于关系型数据库。本节将着重讲解数据分组的原理，通过简单案例，带领读者学会GroupBy的使用方法。

6.1.1 GroupBy简介

GroupBy技术用于数据分组运算，类似于Excel的分类汇总（对于不同分类进行运算），其运算的核心模式为split-apply-combine，如图6.1所示。首先，数据集按照key（分组键）的方式分成小的数据片（split）；然后对每一个数据片进行操作，如分类求和（apply）最后将结果再组合起来形成新的数据集（combine）。

在第3章的小费数据集分析中，通过性别分别计算了小费平均值。当时的做法是：通过布尔索引选取男性和女性的小费数据，分别求平均，然后以此构造Series数据。这个方法其实很繁琐，如果类别很多，难道要一个个地选取出来计算吗？当然不是。

其实，利用groupby方法可以轻松地完成分组统计的任务。以小费数据集为例，通过性别分别计算小费平均值，如图6.2所示。

注意：代码运行需导入相应的库（如pandas或seaborn）。小费数据集中的各列字段说明可参考3.6.1节，不再赘述。

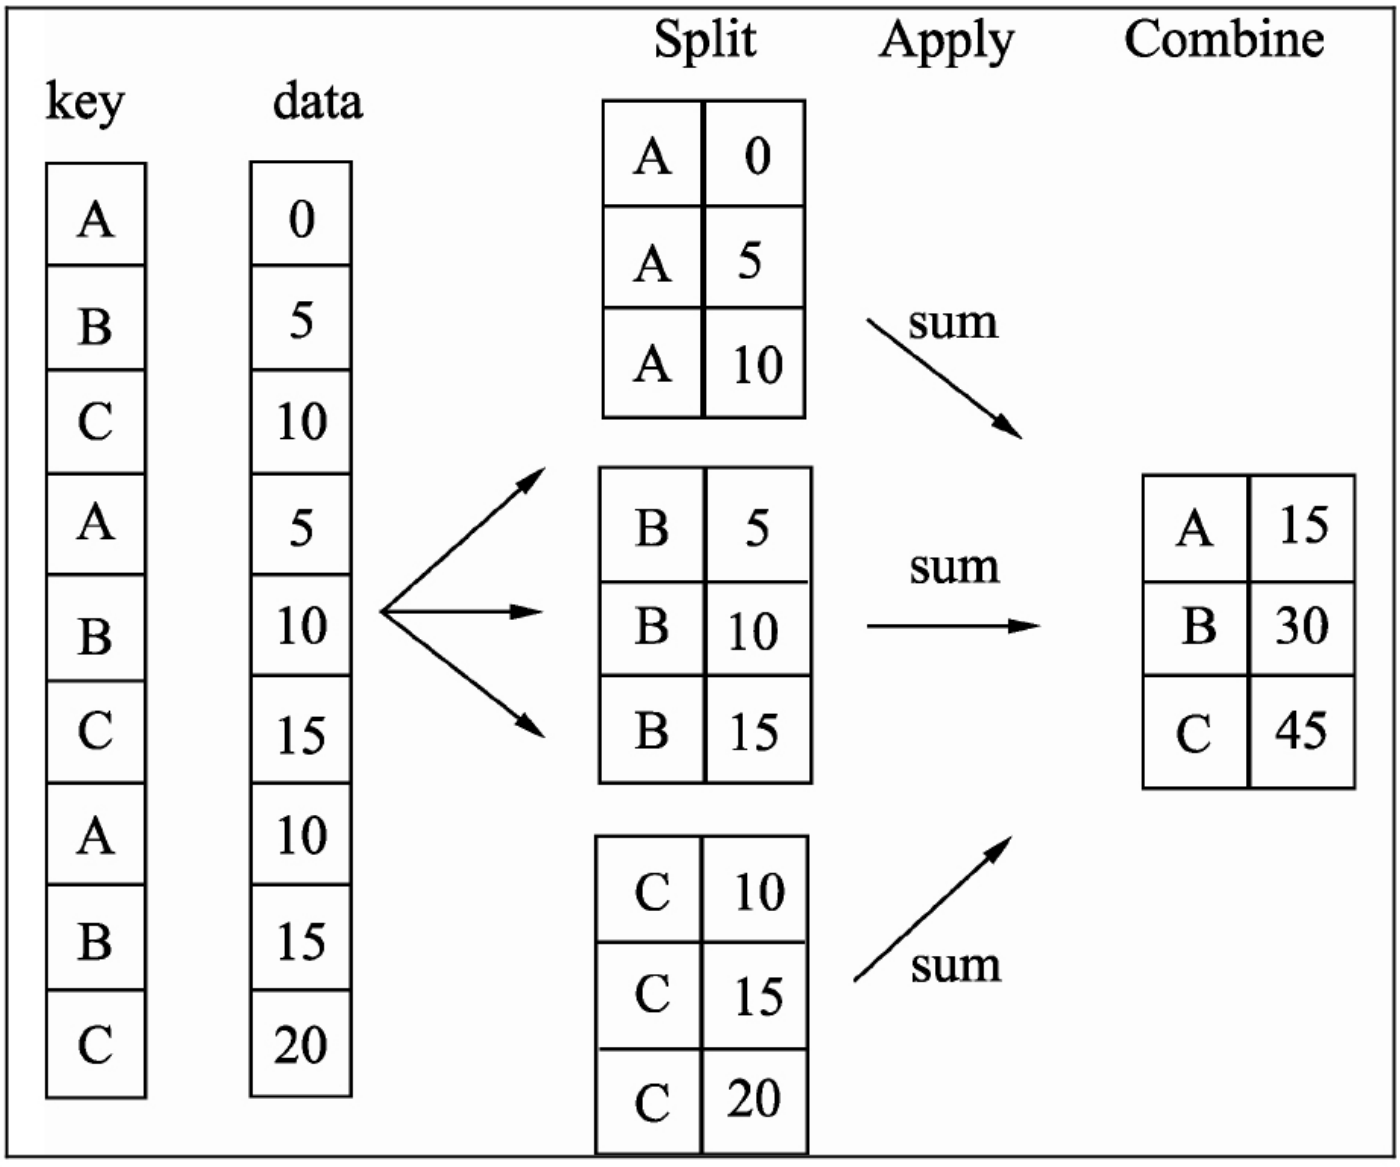

图6.1 GroupBy技术

```
tips=sns.load_dataset('tips')
tips.head()
```

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

```
grouped = tips['tip'].groupby(tips['sex'])
grouped
```

```
<pandas.core.groupby.SeriesGroupBy object at 0x000000000BCF8160>
```

图6.2　GroupBy分组

返回的grouped为GroupBy对象，是保存的中间数据，对该对象调用mean方法即可返回数据，如图6.3所示。

```
grouped.mean()
```

```
sex
Male      3.089618
Female    2.833448
Name: tip, dtype: float64
```

图6.3　GroupBy聚合

mean方法完成了分组数据的聚合运算，返回了一个Series数据，更多的聚合运算将在后面讲解。当然，也可以通过多个分组键进行计算，通过day和time，计算小费平均值，如图6.4所示。

```
date_mean = tips['tip'].groupby([tips['day'],tips['time']]).mean()
date_mean
```

```
day   time
Thur  Lunch     2.767705
      Dinner    3.000000
Fri   Lunch     2.382857
      Dinner    2.940000
Sat   Dinner    2.993103
Sun   Dinner    3.255132
Name: tip, dtype: float64
```

图6.4　多key分组

通过pandas绘图可分析出：晚餐（Dinner）比午餐（Lunch）的小费金额多，而且周六（Sat）、周日（Sun）的小费金额明显比周四（Thur）、周五（Fri）多，如图6.5所示。

```
date_mean.plot(kind='barh')
```

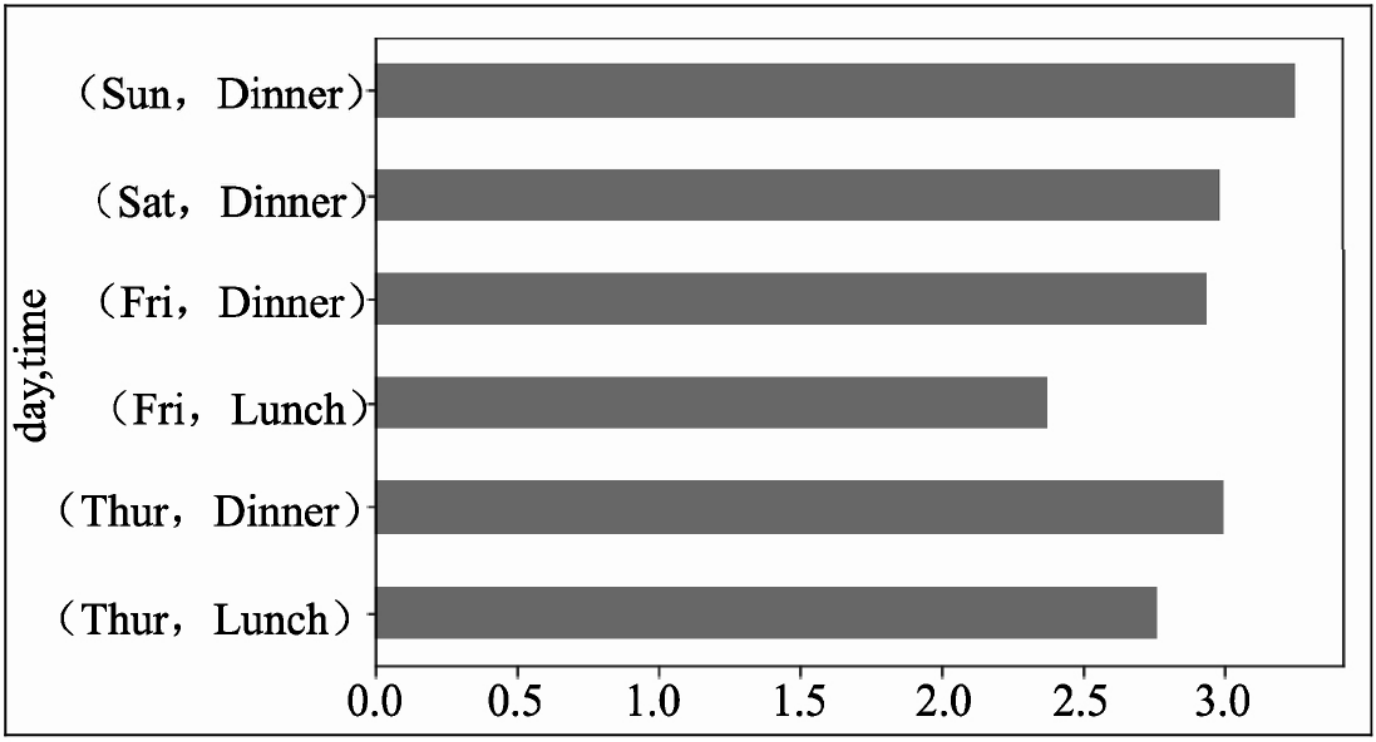

图6.5　时间对小费的影响

GroupBy对象是可迭代的，其构造为一组二元元组，如图6.6所示。

```
In [14]: for name,group in tips.groupby(tips['sex']):
             print(name)
             print(group)
```

```
Male
     total_bill   tip   sex smoker   day    time  size
1         10.34  1.66  Male     No   Sun  Dinner     3
2         21.01  3.50  Male     No   Sun  Dinner     3
3         23.68  3.31  Male     No   Sun  Dinner     2
5         25.29  4.71  Male     No   Sun  Dinner     4
6          8.77  2.00  Male     No   Sun  Dinner     2
7         26.88  3.12  Male     No   Sun  Dinner     4
8         15.04  1.96  Male     No   Sun  Dinner     2
9         14.78  3.23  Male     No   Sun  Dinner     2
10        10.27  1.71  Male     No   Sun  Dinner     2
12        15.42  1.57  Male     No   Sun  Dinner     2
13        18.43  3.00  Male     No   Sun  Dinner     4
15        21.58  3.92  Male     No   Sun  Dinner     2
17        16.29  3.71  Male     No   Sun  Dinner     3
19        20.65  3.35  Male     No   Sat  Dinner     3
20        17.92  4.08  Male     No   Sat  Dinner     2
23        39.42  7.58  Male     No   Sat  Dinner     4
24        19.82  3.18  Male     No   Sat  Dinner     2
```

图6.6　分组迭代

注意：GroupBy由分组名和数据片构成。

size方法可返回各分组的大小，如图6.7所示。

```
tips.groupby(tips['sex']).size()
```

```
sex
Male      157
Female     87
dtype: int64
```

图6.7　size方法

6.1.2　按列名分组

在6.1节中，groupby方法使用的分组键为Series。当然，分组键也支持其他的格式，下面的内容中将一一介绍分组键格式和使用方法。DataFrame数据的列索引名称可以作为分组键，如图6.8所示。用列索引名称可以作为分组键时，用于分组的对象必须是DataFrame数据本身，否则搜索不到索引名称会报错。通过绘制图6.9，可以看出吸烟对小费数据的影响不大。

```
smoker_mean = tips.groupby('smoker').mean()
smoker_mean
```

smoker	total_bill	tip	size
Yes	20.756344	3.008710	2.408602
No	19.188278	2.991854	2.668874

图6.8　按列名分组

```
smoker_mean['tip'].plot(kind='bar')
```

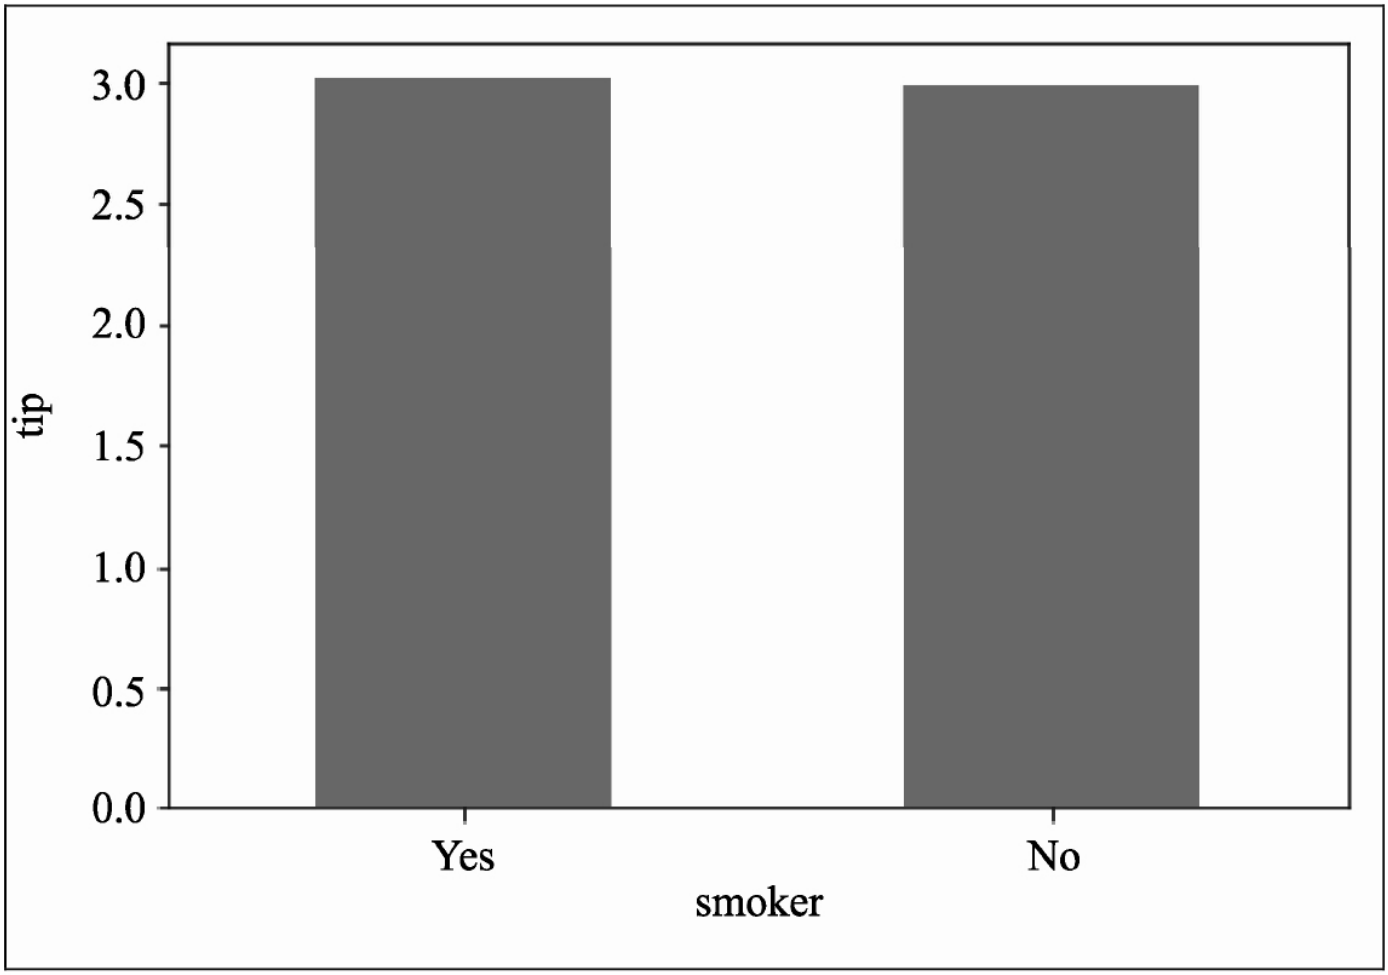

图6.9　吸烟与小费的关系

上述方法返回的是多列DataFrame的数据，如果只需要获取tip（小费）列数据，通过索引选取即可。但GroupBy对象也可通过索引获取tip列，然后再进行聚合运算，它其实相当于语法糖，更好用，如图6.10所示。通过图6.11可看出，小费金额基本上与聚餐人数呈正相关，但人数为5时，有下降的趋势。

```
size_mean1 = tips['tip'].groupby(tips['size']).mean()
size_mean1
```

```
size
1    1.437500
2    2.582308
3    3.393158
4    4.135405
5    4.028000
6    5.225000
Name: tip, dtype: float64
```

```
size_mean2 = tips.groupby('size')['tip'].mean()  #语法糖
size_mean2
```

```
size
1    1.437500
2    2.582308
3    3.393158
4    4.135405
5    4.028000
6    5.225000
Name: tip, dtype: float64
```

图6.10　groupby语法糖

```
size_mean2.plot()
```

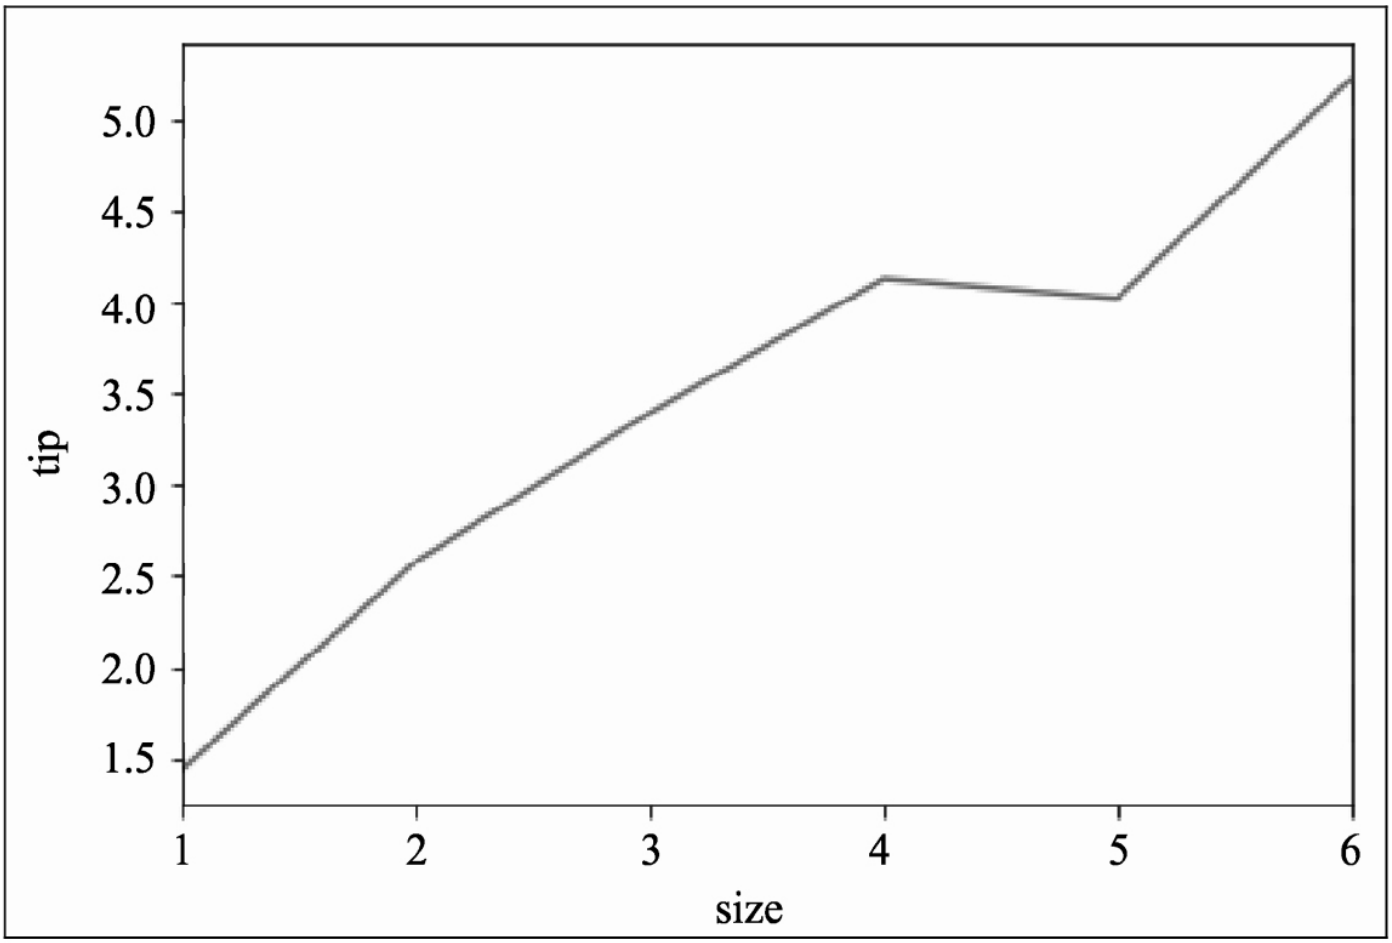

图6.11　聚餐人数（size）与小费（tip）关系

6.1.3　按列表或元组分组

分组键也可以是长度适当的列表或元组，长度适当其实就是要与待分组的DataFrame的行数一样，简单地理解，就是把列表或元组当做DataFrame的一列，然后按其分组，如图6.12所示。

```
df = DataFrame(np.arange(16).reshape(4,4))
df
```

	0	1	2	3
0	0	1	2	3
1	4	5	6	7
2	8	9	10	11
3	12	13	14	15

```
list1 = ['a','b','a','b']
```

```
df.groupby(list1).sum()
```

	0	1	2	3
a	8	10	12	14
b	16	18	20	22

图6.12　按列表分组

6.1.4　按字典分组

如果原始的DataFrame中的分组信息很难确定或者不存在，可通过字典结构，定义分组的信息，如图6.13所示。通过各字母进行分组（不区分大小写），通过字典作为分组键，如图6.14所示。

```
df = DataFrame(np.random.normal(size=(6,6)),index=['a','b','c','A','B','C'])
df
```

	0	1	2	3	4	5
a	0.031512	-0.896280	-0.000981	0.558886	-1.574150	0.030435
b	0.774907	0.020968	0.575220	-0.566894	1.326251	0.775521
c	1.437972	-0.699240	-1.064924	0.235661	1.841803	1.238480
A	-1.756554	0.652186	1.149668	0.192652	2.202044	0.366539
B	-0.575227	0.299196	-0.120483	-2.665255	0.432872	1.627597
C	0.481407	-0.983928	1.270371	-1.581129	-1.568339	-2.122324

图6.13　原始数据

```
dict1 = {
    'a':'one',
    'A':'one',
    'b':'two',
    'B':'two',
    'c':'three',
    'C':'three'
}
```

```
df.groupby(dict1).sum()
```

	0	1	2	3	4	5
one	-1.725042	-0.244095	1.148687	0.751538	0.627894	0.396974
three	1.919380	-1.683169	0.205448	-1.345468	0.273464	-0.883844
two	0.199680	0.320164	0.454738	-3.232148	1.759122	2.403117

图6.14　按字典分组

6.1.5　按函数分组

函数作为分组键的原理类似于字典，通过映射关系进行分组，但是函数分组更加灵活，如图6.15所示。通过DataFrame最后一列的数值进行正负分组。

```
df = DataFrame(np.random.randn(4,4))
df
```

	0	1	2	3
0	0.803694	-1.242886	0.393840	-1.137829
1	1.048137	-0.931402	-0.262153	0.609839
2	0.135432	0.739250	-1.685265	1.562063
3	-0.863777	-0.687589	1.901485	-0.224359

```
def jug(x):
    if x >= 0:
        return 'a'
    else:
        return 'b'
```

```
df[3].groupby(df[3].map(jug)).sum()
```

```
3
a    2.171902
b   -1.362188
Name: 3, dtype: float64
```

图6.15　按函数分组

对于层次化索引，可通过级别进行分组，通过level参数，输入编号或名称即可，如图6.16所示。

```
df = DataFrame(np.arange(16).reshape(4,4),
               index=[['one','one','two','two'],['a','b','a','b']],
               columns=[['apple','apple','orange','orange'],['red','green','red','green']])
df
```

		apple		orange	
		red	green	red	green
one	a	0	1	2	3
	b	4	5	6	7
two	a	8	9	10	11
	b	12	13	14	15

```
df.groupby(level=1).sum()
```

	apple		orange	
	red	green	red	green
a	8	10	12	14
b	16	18	20	22

图6.16　索引级别分组

当然，也可以在列上进行分组（axis=1），如图6.17所示。

```
df.groupby(level=1,axis=1).sum()
```

		green	red
one	a	4	2
	b	12	10
two	a	20	18
	b	28	26

图6.17　按列进行分组

6.2 聚合运算

聚合运算就是对分组后的数据进行计算，产生标量值的数据转换过程。本节将讲解常用的聚合函数和自定义聚合函数的用法。

6.2.1 聚合函数

前面的例子中使用了部分聚合运算方法，如mean、count和sum函数，如表6.1所示为常用的聚合运算方法。

表6.1 聚合运算方法

参　　数	使用说明
count	计数
sum	求和
mean	求平均值
median	求算术中位数
std、var	无偏标准差和方差
min、max	求最小值和最大值
prod	求积
first、last	第一个和最后一个值

注意：空值不参与计算。

然后通过性别分组，计算小费的最大值，如图6.18所示。

```
max_tip = tips.groupby('sex')['tip'].max()
max_tip
```

```
sex
Male      10.0
Female     6.5
Name: tip, dtype: float64
```

```
max_tip.plot(kind='bar')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xcb046a0>
```

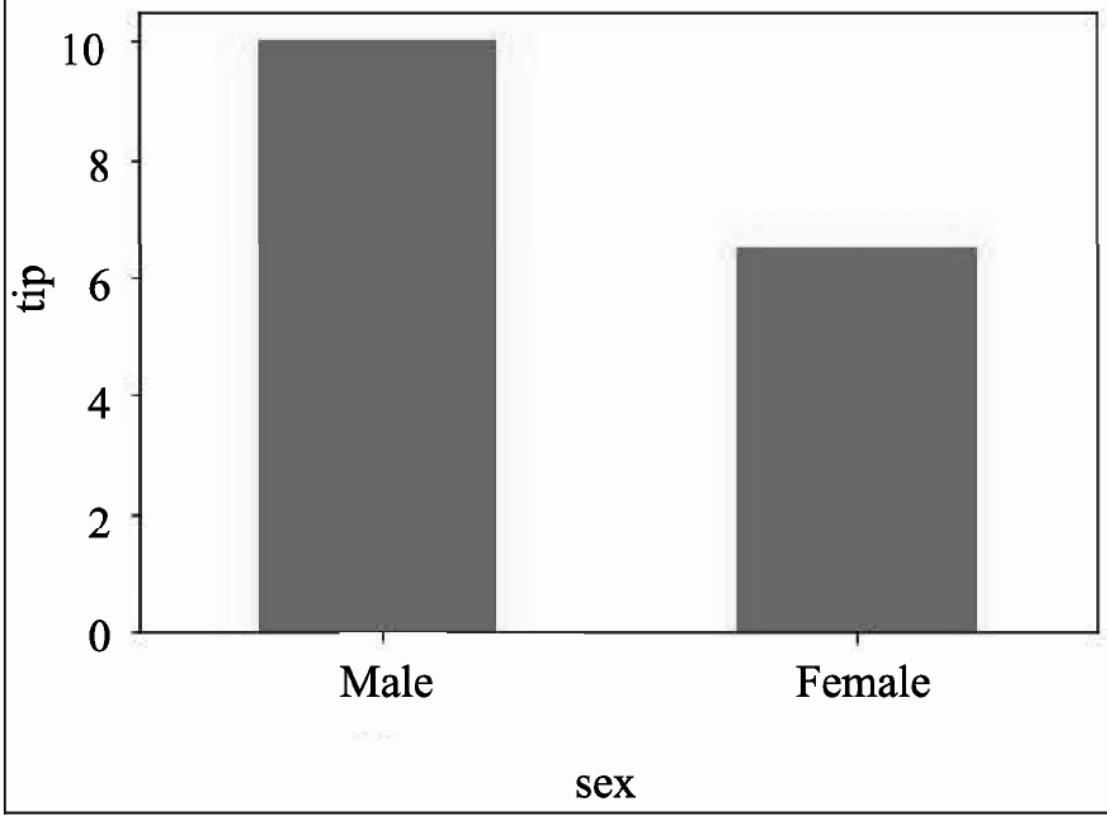

图6.18　小费最大值运算

其实，除了上述聚合运算方法外，只要是Series或DataFrame支持的能用于分组的运算函数都可以拿来使用，如图6.19所示。

对于更加复杂的聚合运算，可以自定义聚合函数，通过aggregate或agg参数传入即可。例如，通过性别分类，计算小费最大值与最小值的差（极差），如图6.20所示。

```
df = DataFrame(np.arange(16).reshape(4,4))
df
```

	0	1	2	3
0	0	1	2	3
1	4	5	6	7
2	8	9	10	11
3	12	13	14	15

```
list1 = ['a','b','a','b']
df.groupby(list1).quantile(0.5)
```

0.5	0	1	2	3
a	4.0	5.0	6.0	7.0
b	8.0	9.0	10.0	11.0

图6.19　分位数运算

```
def get_range(x):
    return x.max()-x.min()
```

```
tips_range = tips.groupby('sex')['tip'].agg(get_range)
tips_range
```

```
sex
Male      9.0
Female    5.5
Name: tip, dtype: float64
```

图6.20　聚合函数

如图6.21所示，可以看出，男性（Male）的小费极差比女性（Female）大很多，说明在小费给予中，男性的差异较大，主观性更大。

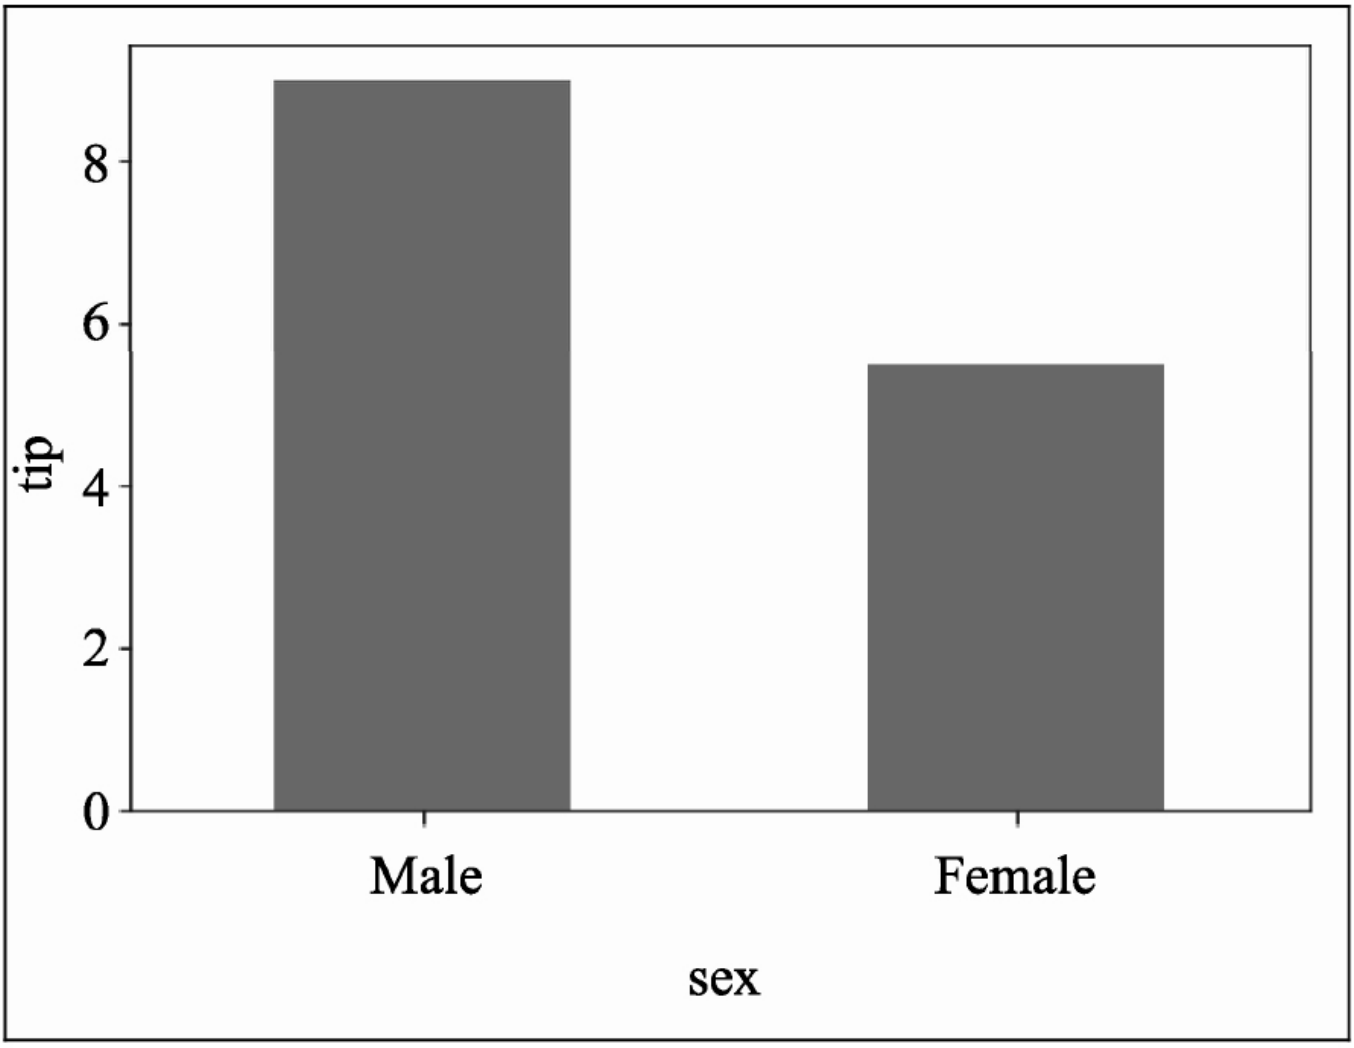

图6.21　小费极差

6.2.2　多函数应用

1．一列多函数

如图6.22所示，对agg参数传入多函数列表，即可完成一列的多函数运算。

```
tips.groupby(['sex','smoker'])['tip'].agg(['mean','std',get_range])
```

		mean	std	get_range
sex	smoker			
Male	Yes	3.051167	1.500120	9.00
	No	3.113402	1.489559	7.75
Female	Yes	2.931515	1.219916	5.50
	No	2.773519	1.128425	4.20

图6.22　一列多函数

如果不想使用默认的运算函数列名，可以元组的形式传入，前面为名称，后面为聚合函数，如图6.23所示。

```
tips.groupby(['sex','smoker'])['tip'].agg([('tip_mean','mean'),('Range',get_range)])
```

		tip_mean	Range
sex	smoker		
Male	Yes	3.051167	9.00
	No	3.113402	7.75
Female	Yes	2.931515	5.50
	No	2.773519	4.20

图6.23　重命名

2．多列多函数

对多列进行多聚合函数运算时，会产生层次化索引，如图6.24所示。

```
tips.groupby(['day','time'])['total_bill','tip'].agg([('tip_mean','mean'),('Range',get_range)])
```

		total_bill		tip	
		tip_mean	Range	tip_mean	Range
day	time				
Thur	Lunch	17.664754	35.60	2.767705	5.45
	Dinner	18.780000	0.00	3.000000	0.00
Fri	Lunch	12.845714	7.69	2.382857	1.90
	Dinner	19.663333	34.42	2.940000	3.73
Sat	Dinner	20.441379	47.74	2.993103	9.00
Sun	Dinner	21.410000	40.92	3.255132	5.49

图6.24　多列多函数

3．不同列不同函数

如果需要对不同列使用不同的函数运算，可以通过字典来定义映射关系，如图6.25和图6.26所示。

```
tips.groupby(['day','time'])['total_bill','tip'].agg({'total_bill':'sum','tip':'mean'})
```

		total_bill	tip
day	time		
Thur	Lunch	1077.55	2.767705
	Dinner	18.78	3.000000
Fri	Lunch	89.92	2.382857
	Dinner	235.96	2.940000
Sat	Dinner	1778.40	2.993103
Sun	Dinner	1627.16	3.255132

图6.25　不同列不同函数1

```
tips.groupby(['day','time'])['total_bill','tip'].agg({'total_bill':['sum','mean'],'tip':'mean'})
```

		total_bill		tip
		sum	mean	mean
day	time			
Thur	Lunch	1077.55	17.664754	2.767705
	Dinner	18.78	18.780000	3.000000
Fri	Lunch	89.92	12.845714	2.382857
	Dinner	235.96	19.663333	2.940000
Sat	Dinner	1778.40	20.441379	2.993103
Sun	Dinner	1627.16	21.410000	3.255132

图6.26　不同列不同函数2

如果希望返回的结果不以分组键为索引，通过as_index=False可以完成，如图6.27所示。

```
no_index = tips.groupby(['sex','smoker'],as_index=False)['tip'].mean()
no_index
```

	sex	smoker	tip
0	Male	Yes	3.051167
1	Male	No	3.113402
2	Female	Yes	2.931515
3	Female	No	2.773519

图6.27　取消分组键为索引

6.3 分组运算

分组运算包含了聚合运算，聚合运算是数据转换的特例。本节将讲解transform和apply方法，通过这两个方法，可以实现更多的分组运算。

6.3.1 transform方法

首先对小费数据集新建一列用于存放男性和女性小费的平均值。常用的方法是，先聚合运算，然后再将其合并，如图6.28所示。

```
df = DataFrame(tips.groupby('sex')['tip'].mean())
df
```

sex	tip
Male	3.089618
Female	2.833448

```
new_tips = pd.merge(tips,df,left_on='sex',right_index=True)
new_tips.head()
```

	total_bill	tip_x	sex	smoker	day	time	size	tip_y
0	16.99	1.01	Female	No	Sun	Dinner	2	2.833448
4	24.59	3.61	Female	No	Sun	Dinner	4	2.833448
11	35.26	5.00	Female	No	Sun	Dinner	4	2.833448
14	14.83	3.02	Female	No	Sun	Dinner	2	2.833448
16	10.33	1.67	Female	No	Sun	Dinner	3	2.833448

图6.28 聚合加合并

上面的方法虽然也能实现，但过于烦琐，不灵活。通过transform方法可以使运算分布到每一行，如图6.29所示。

```
tips.groupby('sex')['tip'].transform('mean')
```

```
0     2.833448
1     3.089618
2     3.089618
3     3.089618
4     2.833448
5     3.089618
6     3.089618
7     3.089618
8     3.089618
9     3.089618
10    3.089618
11    2.833448
12    3.089618
13    3.089618
14    2.833448
15    3.089618
16    2.833448
17    3.089618
18    2.833448
19    3.089618
20    3.089618
```

图6.29　transform方法

6.3.2　apply方法

apply方法的功能更加强大，例如可以计算根据性别分组后小费金额排在前5名的DataFrame数据，如图6.30所示。

```
def top(x,n=5):
    return x.sort_values(by='tip',ascending=False)[-n:]
```

```
tips.groupby('sex').apply(top)
```

		total_bill	tip	sex	smoker	day	time	size
sex								
Male	43	9.68	1.32	Male	No	Sun	Dinner	2
	235	10.07	1.25	Male	No	Sat	Dinner	2
	75	10.51	1.25	Male	No	Sat	Dinner	2
	237	32.83	1.17	Male	Yes	Sat	Dinner	2
	236	12.60	1.00	Male	Yes	Sat	Dinner	2
Female	215	12.90	1.10	Female	Yes	Sat	Dinner	2
	0	16.99	1.01	Female	No	Sun	Dinner	2
	111	7.25	1.00	Female	No	Sat	Dinner	1
	67	3.07	1.00	Female	Yes	Sat	Dinner	1
	92	5.75	1.00	Female	Yes	Fri	Dinner	2

图6.30　apply方法

如果希望返回的结果不以分组键为索引，通过group_keys=False可以完成，如图6.31所示。

```
tips.groupby('sex',group_keys=False).apply(top)
```

	total_bill	tip	sex	smoker	day	time	size
43	9.68	1.32	Male	No	Sun	Dinner	2
235	10.07	1.25	Male	No	Sat	Dinner	2
75	10.51	1.25	Male	No	Sat	Dinner	2
237	32.83	1.17	Male	Yes	Sat	Dinner	2
236	12.60	1.00	Male	Yes	Sat	Dinner	2
215	12.90	1.10	Female	Yes	Sat	Dinner	2
0	16.99	1.01	Female	No	Sun	Dinner	2
111	7.25	1.00	Female	No	Sat	Dinner	1
67	3.07	1.00	Female	Yes	Sat	Dinner	1
92	5.75	1.00	Female	Yes	Fri	Dinner	2

图6.31　禁止分组键

例如，前面对缺失数据的处理可通过数值填充来完成，如图6.32和图6.33所示。也可以通过平均值对缺失值进行填充。

```
data = {
    'name':['张三', '李四', 'peter', '王五', '小明', '小红'],
    'sex':['female', 'female', 'male', 'male','male','female'],
    'math':[67, 72, np.nan, 82, 90, np.nan]
}
df = DataFrame(data)
df['math'] = df['math']
df
```

	math	name	sex
0	67.0	张三	female
1	72.0	李四	female
2	NaN	peter	male
3	82.0	王五	male
4	90.0	小明	male
5	NaN	小红	female

图6.32　数据结构

```
df.fillna(df['math'].mean())
```

	math	name	sex
0	67.00	张三	female
1	72.00	李四	female
2	77.75	peter	male
3	82.00	王五	male
4	90.00	小明	male
5	77.75	小红	female

图6.33　均值插值

可以这样假设：男生和女生的数学成绩还是有区别的，希望通过分组后，再进行插值，如图6.34所示。

```
f = lambda x: x.fillna(x.mean())
df.groupby('sex').apply(f)
```

		math	name	sex
sex				
female	0	67.0	张三	female
	1	72.0	李四	female
	5	69.5	小红	female
male	2	86.0	peter	male
	3	82.0	王五	male
	4	90.0	小明	male

图6.34　分组后插值

6.4　数据透视表

说到数据透视表，读者可能并不陌生，在Excel中，就有数据透视表的功能，通过行、列、值形成一个透视表。在pandas中，通过pivot_table函数也可实现同样的功能，本节将对其进行详细讲解。

6.4.1　透视表

首先介绍pivot_table函数的常用参数，value代表的是值，index为行，columns为例，其他参数在实际案例中讲解。这里以小费数据集为例，如图6.35所示。

```
tips.pivot_table(values='tip',index='sex',columns='smoker')
```

smoker	Yes	No
sex		
Male	3.051167	3.113402
Female	2.931515	2.773519

图6.35　透视表

这里的值计算为平均值（默认），也可以通过aggfunc参数来指定，如图6.36所示。

```
tips.pivot_table(values='tip',index='sex',columns='smoker',aggfunc='sum')
```

smoker	Yes	No
sex		
Male	183.07	302.00
Female	96.74	149.77

图6.36　指定计算函数

通过margins参数可加入分项小计，如图6.37所示。

```
tips.pivot_table(values='tip',index='sex',columns='smoker',aggfunc='sum',margins=True)
```

smoker	Yes	No	All
sex			
Male	183.07	302.00	485.07
Female	96.74	149.77	246.51
All	279.81	451.77	731.58

图6.37　分项小计

注意：更多参数的使用说明，读者可查看帮助文档。

6.4.2　交叉表

交叉表是一种用于计算分组频率的特殊透视表，这里还以小费数据集为例，其使用方法如图6.38所示。

```
cross_table = pd.crosstab(index=tips['day'],columns=tips['size'])
cross_table
```

size	1	2	3	4	5	6
day						
Thur	1	48	4	5	1	3
Fri	1	16	1	1	0	0
Sat	2	53	18	13	1	0
Sun	0	39	15	18	3	1

图6.38　交叉表

通过div函数，可以使得每行的和为1，如图6.39所示。

```
df = cross_table.div(cross_table.sum(1),axis=0)
df
```

size	1	2	3	4	5	6
day						
Thur	0.016129	0.774194	0.064516	0.080645	0.016129	0.048387
Fri	0.052632	0.842105	0.052632	0.052632	0.000000	0.000000
Sat	0.022989	0.609195	0.206897	0.149425	0.011494	0.000000
Sun	0.000000	0.513158	0.197368	0.236842	0.039474	0.013158

图6.39　div函数

这样可以看出聚餐人数的比例情况。在pandas绘图中，通过stacked=True可以绘制堆积图，如图6.40所示。

```
df.plot(kind='bar',stacked = True)
<matplotlib.axes._subplots.AxesSubplot at 0xb9a6080>
```

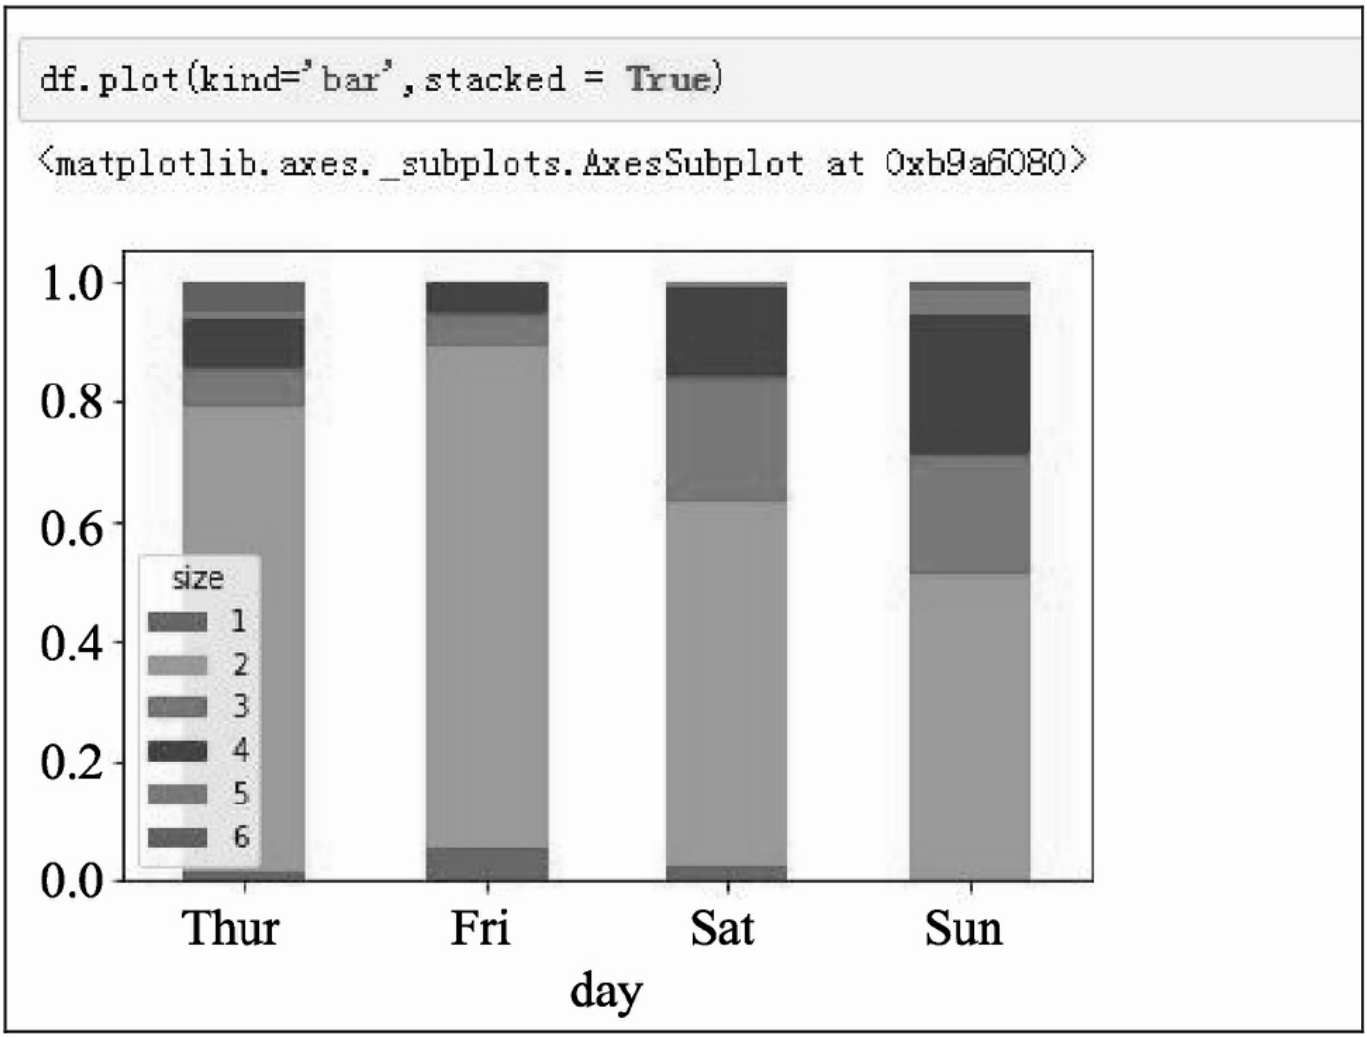

图6.40　每天聚餐规模比例

6.5　综合实例——巴尔的摩公务员工资数据集

本节以美国城市巴尔的摩2016年公务员工资的数据集为基础，讲解数据分析中数据分组统计的使用，并通过可视化手段，分析其工资情况。

6.5.1　数据来源

本例使用的数据集可在该网站https://catalog.data.gov/dataset/baltimore-city-employee-salaries-fy2016进行下载，可支持多种文件结构的下载，这里下载CSV文件，如图6.41所示。

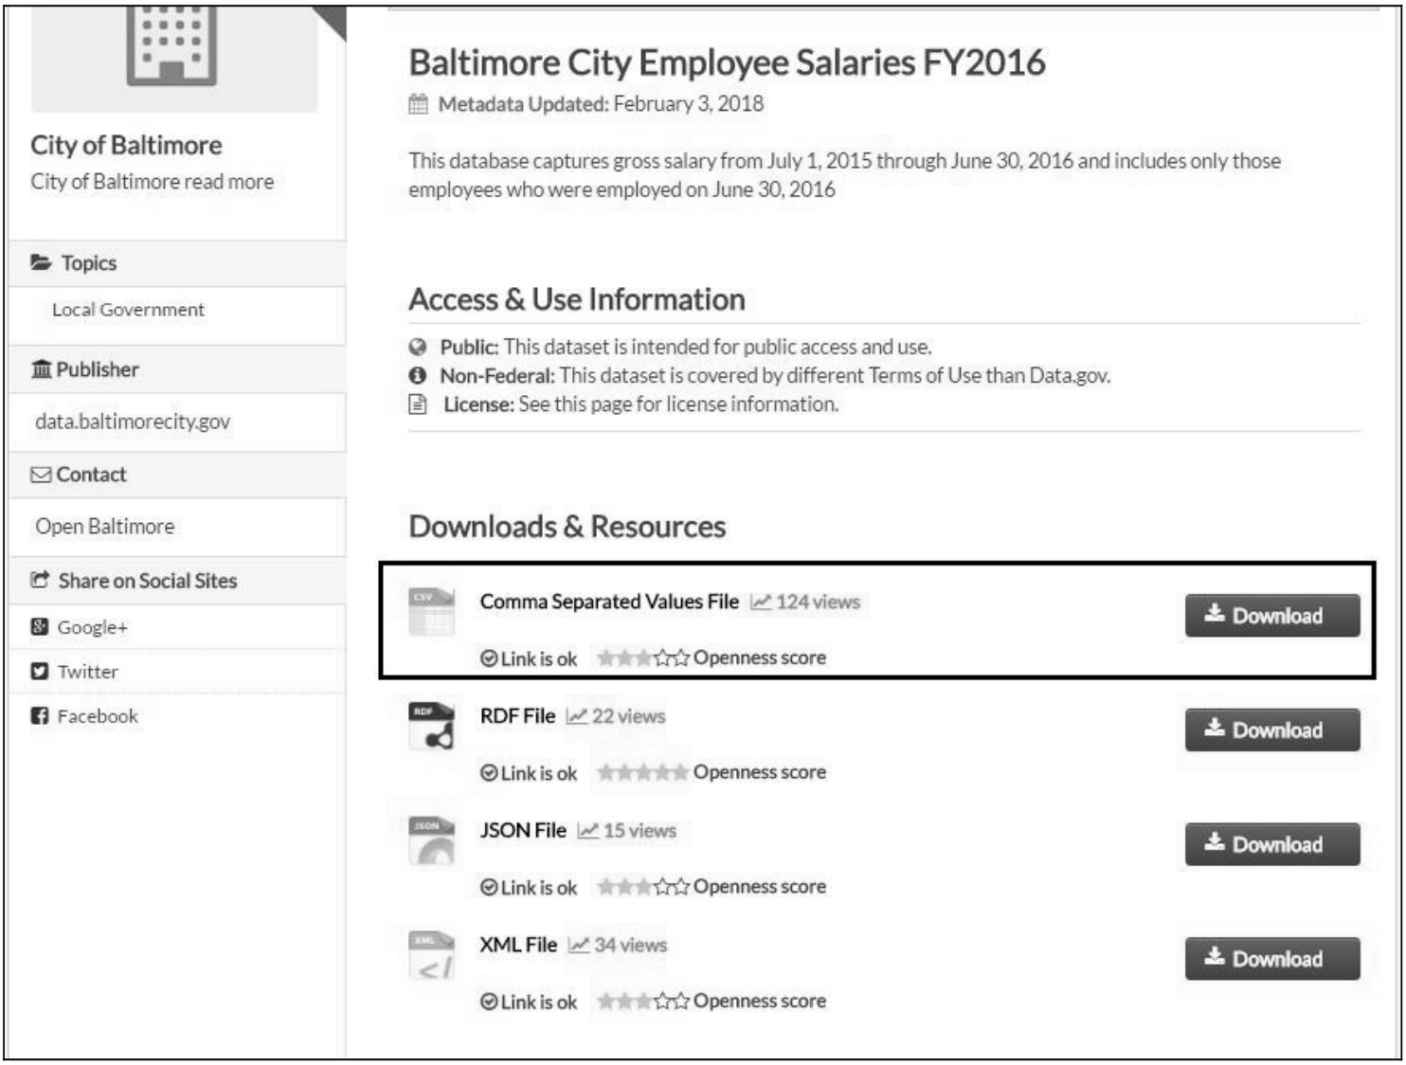

图6.41　数据下载

下载好的CSV文件可通过pandas读取，加载该数据集，如图6.42所示。

该数据为美国政府公开的公职人员的薪资数据。其中，Name为姓名；JobTitle为职位名称；AgencyID和Agency为工号和单位；HireDate为入职日期；AnnualSalary为年薪；GrossPay为总薪资（税前）。

```
import numpy as np
import pandas as pd
%matplotlib inline
```

```
salary = pd.read_csv(open('H:\python数据分析\数据\Baltimore_City_Employee_Salaries_FY2016.csv'))
salary.head()
```

	Name	JobTitle	AgencyID	Agency	HireDate	AnnualSalary	GrossPay
0	Aaron,Patricia G	Facilities/Office Services II	A03031	OED-Employment Dev (031)	10/24/1979 12:00:00 AM	$56705.00	$54135.44
1	Aaron,Petra L	ASSISTANT STATE'S ATTORNEY	A29045	States Attorneys Office (045)	09/25/2006 12:00:00 AM	$75500.00	$72445.87
2	Abbey,Emmanuel	CONTRACT SERV SPEC II	A40001	M-R Info Technology (001)	05/01/2013 12:00:00 AM	$60060.00	$59602.58
3	Abbott-Cole,Michelle	Operations Officer III	A90005	TRANS-Traffic (005)	11/28/2014 12:00:00 AM	$70000.00	$59517.21
4	Abdal-Rahim,Naim A	EMT Firefighter Suppression	A64120	Fire Department (120)	03/30/2011 12:00:00 AM	$64365.00	$74770.82

图6.42　工资数据

6.5.2　定义问题

本次分析中，围绕工资提出几个问题：年薪的分布情况、公务人员入职日期的情况、年薪最高的职务和人数最多的职位。

6.5.3　数据清洗

首先对数据进行简单描述，看是否有缺失值，如图6.43所示。

可以看出，GrossPay列有272个缺失值，因为这里的样本量足够，直接删除这些样本即可，如图6.44所示。

```
salary.shape
```

```
(13818, 7)
```

```
salary.isnull().sum()
```

```
Name              0
JobTitle          0
AgencyID          0
Agency            0
HireDate          0
AnnualSalary      0
GrossPay        272
dtype: int64
```

图6.43　查看缺失值

```
salary = salary.dropna()
```

```
salary.isnull().sum()
```

```
Name            0
JobTitle        0
AgencyID        0
Agency          0
HireDate        0
AnnualSalary    0
GrossPay        0
dtype: int64
```

图6.44　删除缺失值

注意：读者也可以通过职位分组后插入均值。

我们还发现，在工资数据中，年薪和薪资都是字符串结构的，有“$”符号，利用前面讲的字符串用法，将其去掉，并转换为浮点类型，如图6.45所示。

```
salary['AnnualSalary'] = salary['AnnualSalary'].str.strip('$')
salary['GrossPay'] = salary['GrossPay'].str.strip('$')
salary[['AnnualSalary','GrossPay']].head()
```

	AnnualSalary	GrossPay
0	56705.00	54135.44
1	75500.00	72445.87
2	60060.00	59602.58
3	70000.00	59517.21
4	64365.00	74770.82

```
salary['GrossPay'].dtype
```

```
dtype('O')
```

```
salary['AnnualSalary'] = salary['AnnualSalary'].astype(float)
salary['GrossPay'] = salary['GrossPay'].astype(float)
salary['GrossPay'].dtype
```

```
dtype('float64')
```

图6.45　工资处理

对于入职日期，可以新建一列，用于存放入职的月份，如图6.46所示。

```
salary['month'] = salary['HireDate'].str.split('/').str[0]
salary[['HireDate','month']].head()
```

	HireDate	month
0	10/24/1979 12:00:00 AM	10
1	09/25/2006 12:00:00 AM	09
2	05/01/2013 12:00:00 AM	05
3	11/28/2014 12:00:00 AM	11
4	03/30/2011 12:00:00 AM	03

图6.46　日期处理

注意：这里是把日期数据当做字符串来处理，日期数据的处理会在后面具体讲解。

6.5.4　数据探索

我们首先对年薪工资进行直方图绘制。如图6.47所示，年薪基本呈正态分布，但向左略有倾斜，这也说明高工资的职务还是较少的。

```
salary['AnnualSalary'].hist(bins=20)
```

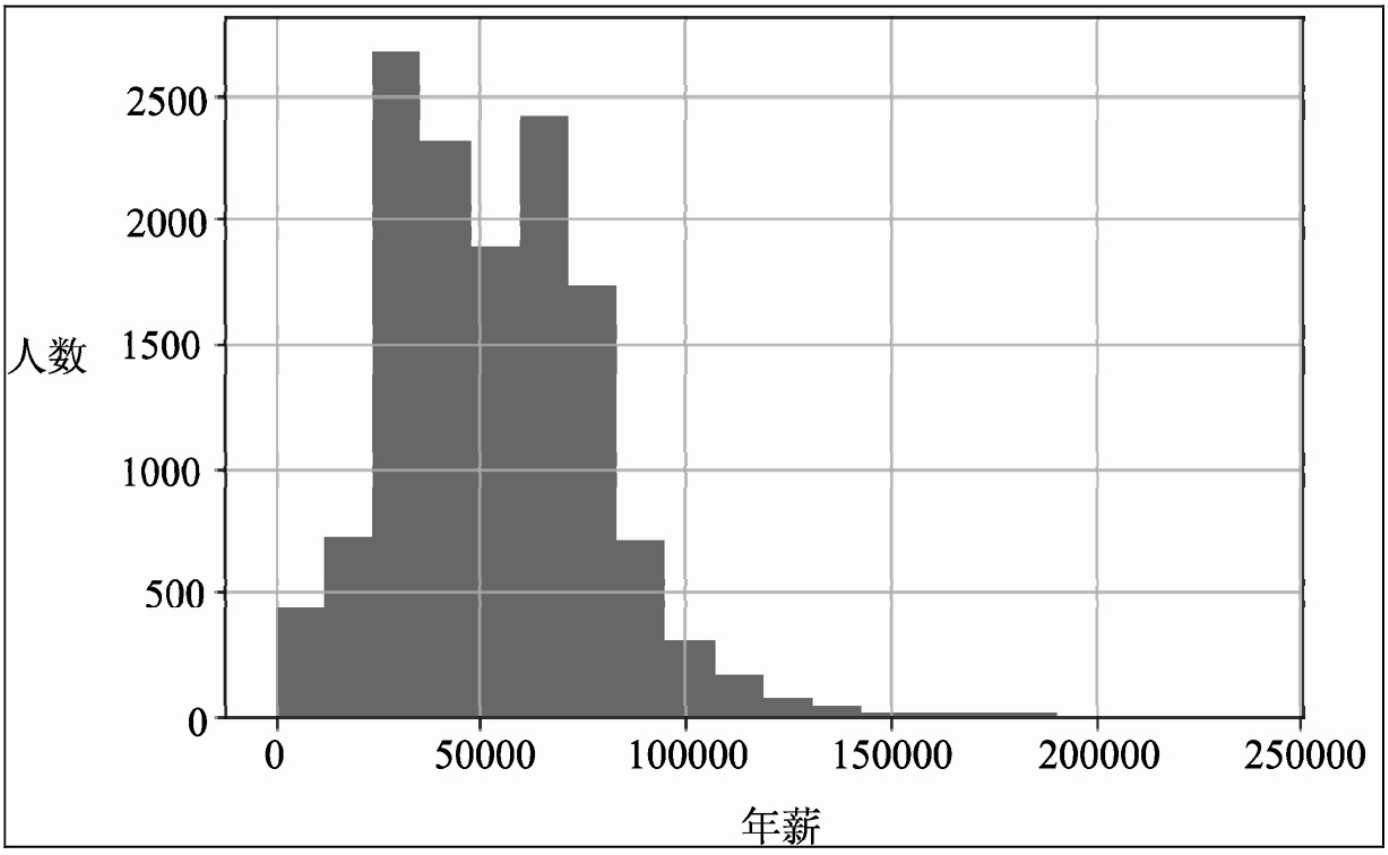

图6.47　年薪分布情况

然后对入职的月份进行计数并绘制柱状图，如图6.48所示。入职的高峰期为9月、8月和6月。

```
month_count = salary['month'].value_counts()
month_count.plot(kind='barh')
```

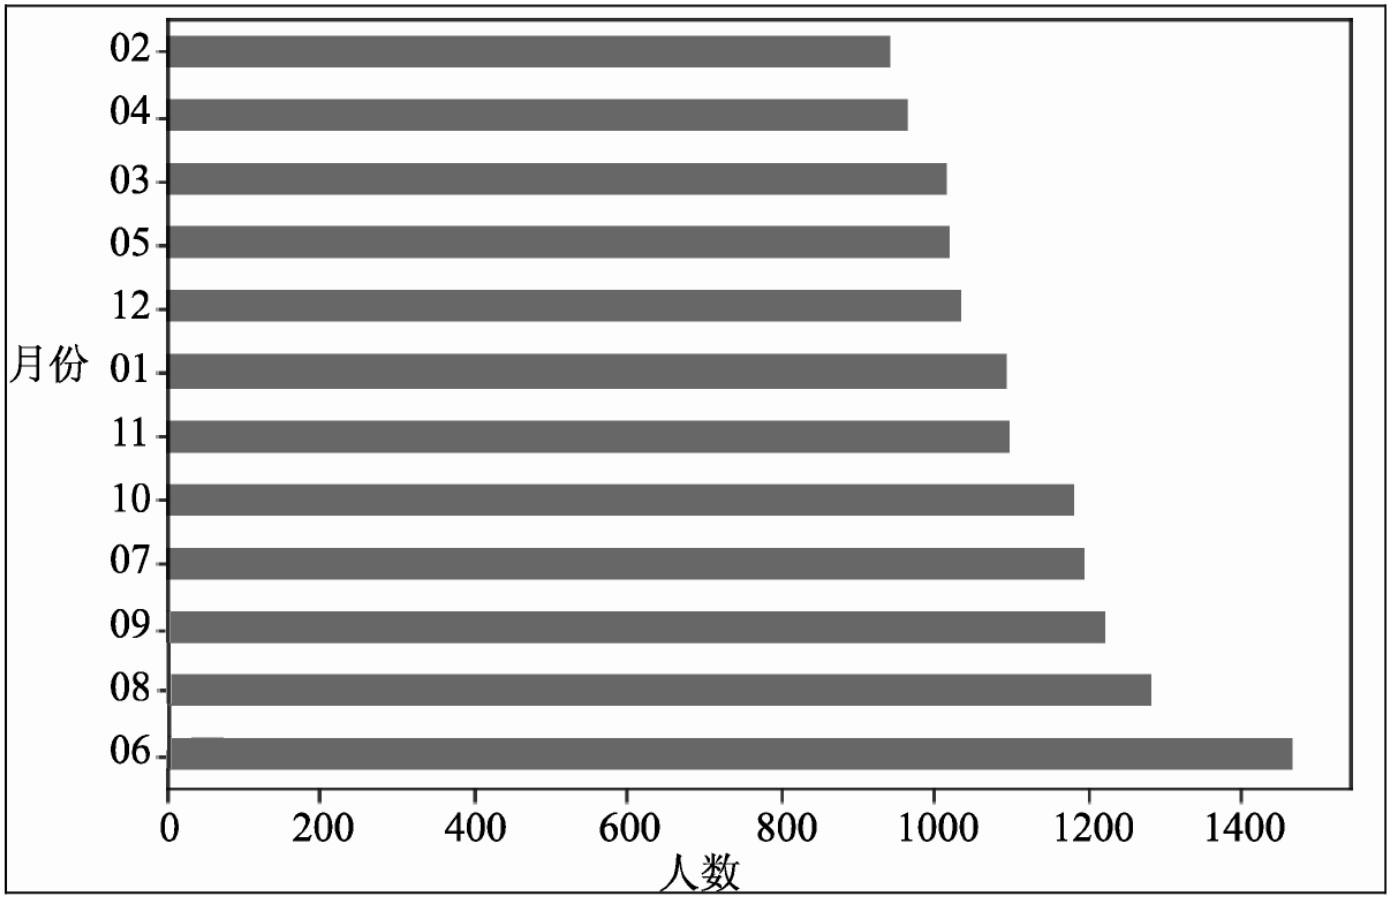

图6.48　入职月份分布情况

接着通过聚合运算，计算各职位的年薪平均值和职位个数，如图6.49所示。

```
agg_salary = salary.groupby('JobTitle')['AnnualSalary'].agg(['mean','count'])
agg_salary
```

JobTitle	mean	count
911 LEAD OPERATOR	49816.750000	4
911 OPERATOR	44829.461538	65
911 OPERATOR SUPERVISOR	57203.500000	4
ACCOUNT EXECUTIVE	57200.000000	4
ACCOUNTANT I	49065.866667	15
ACCOUNTANT II	58172.640000	25
ACCOUNTANT SUPV	67417.142857	7
ACCOUNTANT TRAINEE	36681.000000	1
ACCOUNTING ASST I	29226.333333	6
ACCOUNTING ASST II	34281.533333	15
ACCOUNTING ASST III	43187.818182	33

图6.49　聚合运算

然后再对年薪平均值进行降序排序，取前5名绘制柱状图，如图6.50所示。从图中可以看出，STATE'S ATTORNEY（州检察官）的年薪最高。

```
sort_salary = agg_salary.sort_values(by='mean',ascending=False)[:5]
sort_salary['mean'].plot(kind='bar')
```

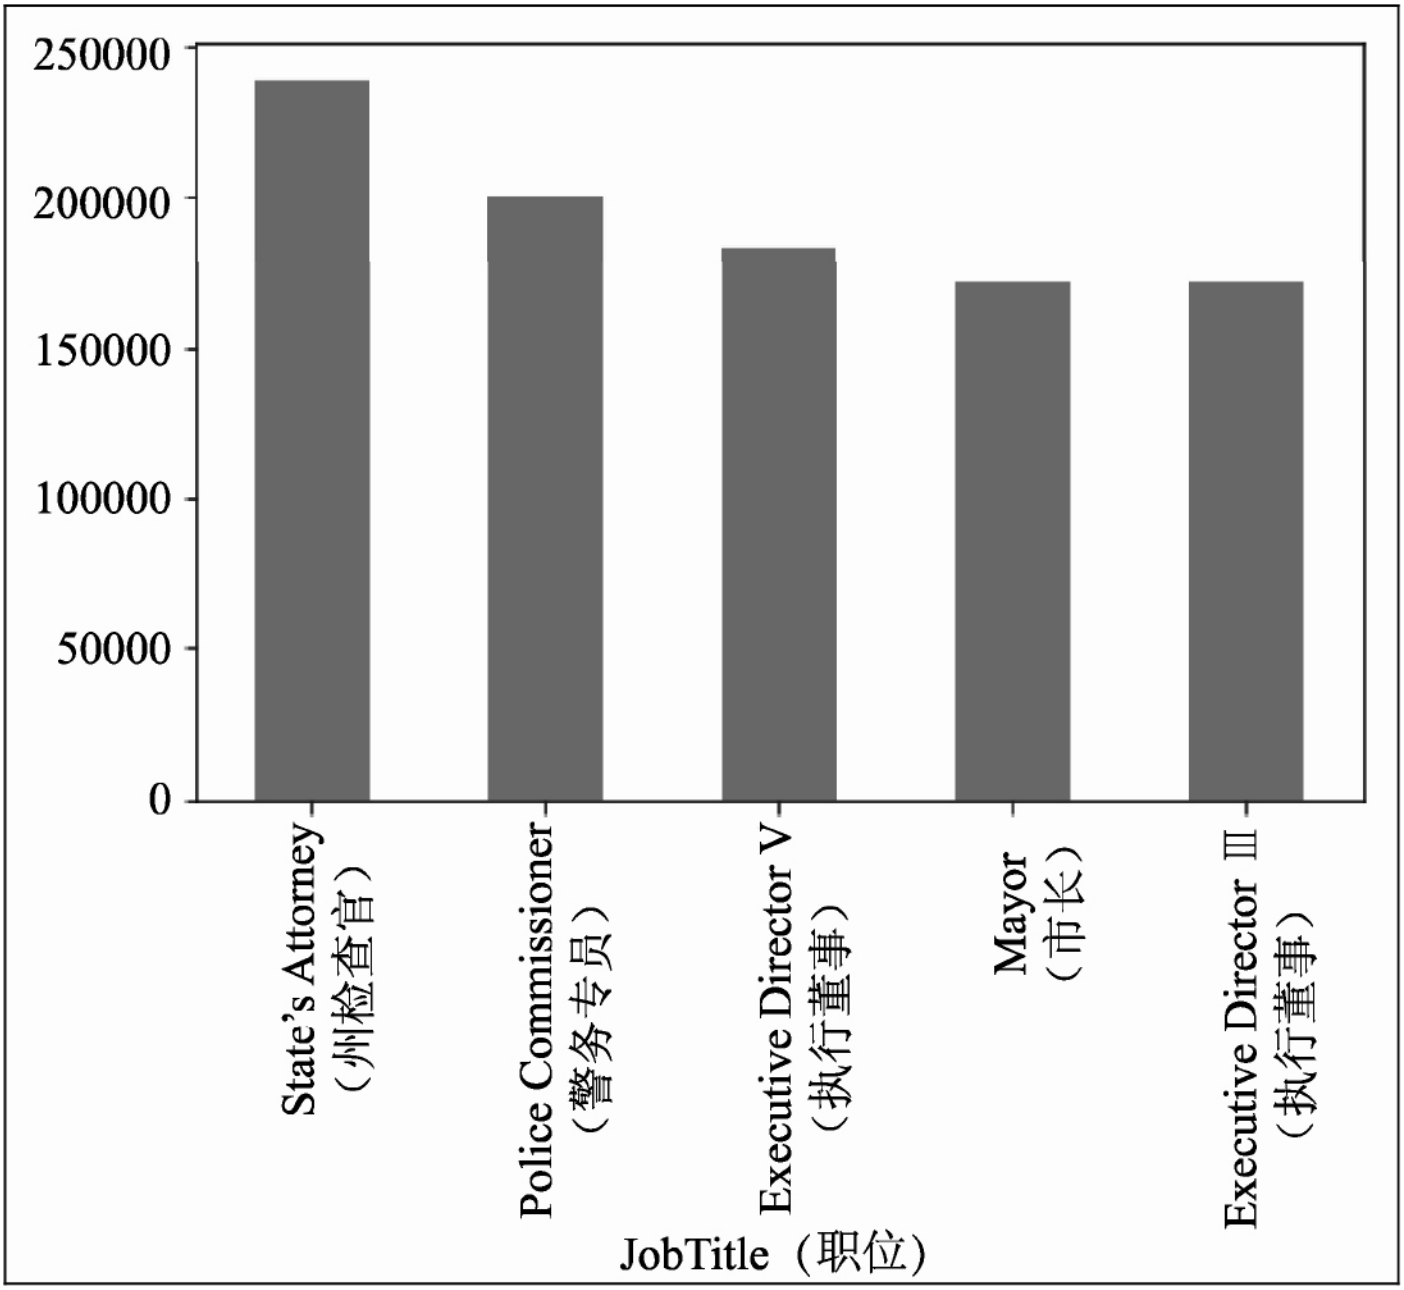

图6.50　年薪职位排名柱状图

按同样的方法，再绘制职位人数排名柱状图，如图6.51所示。可以看出，警察的职位人数远多于其他职位。

```
sort_count = agg_salary.sort_values(by='count',ascending=False)[:5]
sort_count['count'].plot(kind='bar')
```

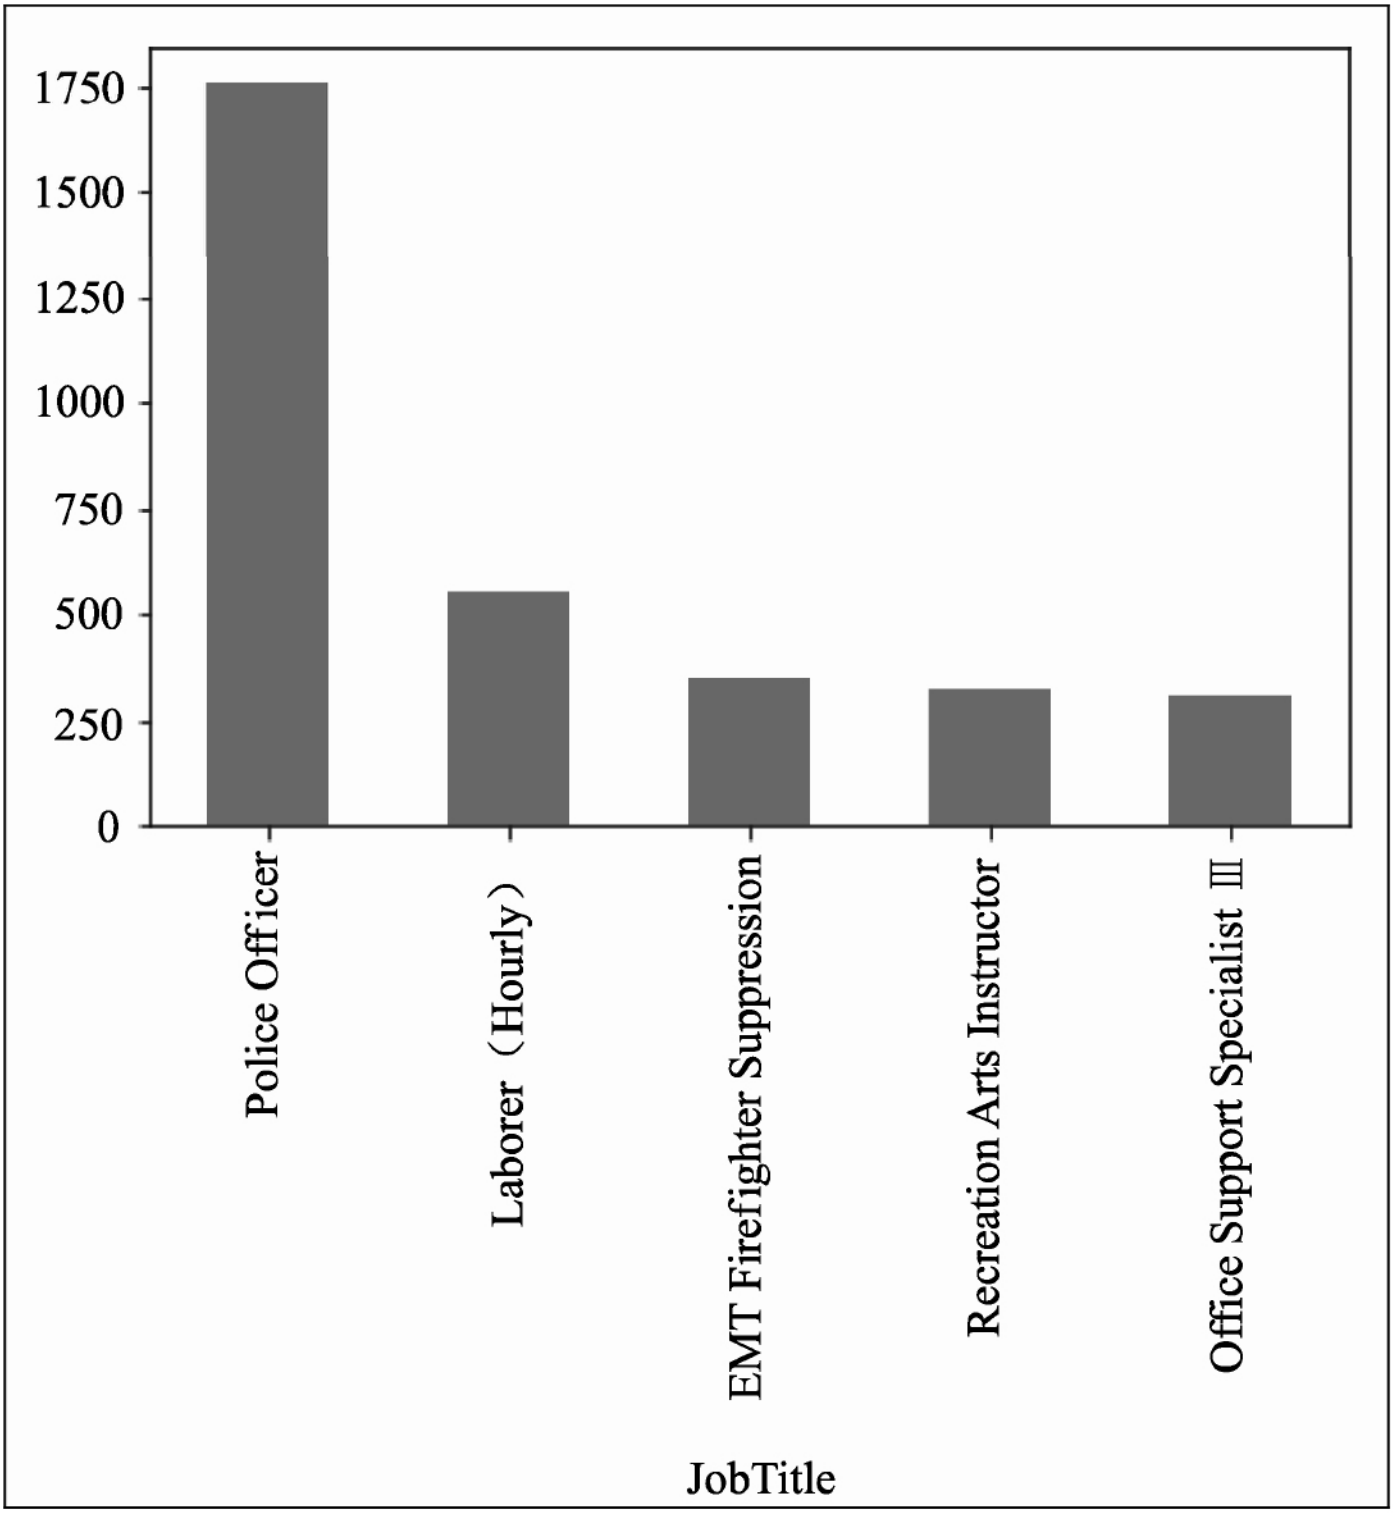

图6.51　职业人数排名柱状图

第7章　matplotlib可视化

数据可视化是数据分析中的一部分，可用于数据的探索和查找缺失值等，也是展现数据的重要手段。matplotlib是一个强大的工具箱，其完整的图表样式函数和个性化的自定义设置，可以满足几乎所有的2D和一些3D绘图的需求。本章介绍了如何利用matplotlib绘制常用数据图表，如线形图、柱状图、散点图和直方图；还介绍了如何使用matplotlib的自定义设置绘制个性化图表；最后使用全球星巴克店铺的数据集进行数据分析和可视化，从而带领读者掌握matplotlib可视化的方法和技巧。

本章主要涉及以下几个知识点：

· 线形图的基本绘制方法和样式设置；

· 各类柱状图的绘制方法；

· 绘制散点图和直方图；

· 灵活运用matplotlib的参数自定义图表设置；

· 通过综合案例掌握matplotlib可视化的方法和技巧。

7.1 线形图

线形图是最基本的图表类型，常用于绘制连续的数据。通过绘制线形图，可以表现出数据的一种趋势变化。例如，公司通过绘制每个月份的产品销售量趋势图，来分析产品的销售情况，以此做出销售方式的调整。本节主要介绍如何利用matplotlib绘制线形图，并介绍通过修改matplotlib中plot函数的参数来修改线条的颜色、线条的形状（线形）和数据点标记的形状。

7.1.1 基本使用

matplotlib的plot函数可以用来绘制线形图，在参数中传入X轴和Y轴坐标即可。X轴和Y轴坐标的数据格式可以是列表、数组和Series。首先创建一个DataFrame数据，如图7.1所示。然后让DataFrame数据的行索引作为X轴，math列索引作为Y轴，开始绘制线形图，如图7.2所示。

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
```

```
data = {
    'name':['张三', '李四', '王五', '小明'],
    'sex':['female', 'female', 'male', 'male'],
    'math':[78, 79, 83, 92],
    'city':['北京', '上海', '广州', '北京']
}
df = pd.DataFrame(data)
df
```

	city	math	name	sex
0	北京	78	张三	female
1	上海	79	李四	female
2	广州	83	王五	male
3	北京	92	小明	male

图7.1 数据情况

```
plt.plot(df.index,df['math'])
```

```
[<matplotlib.lines.Line2D at 0xa6c7518>]
```

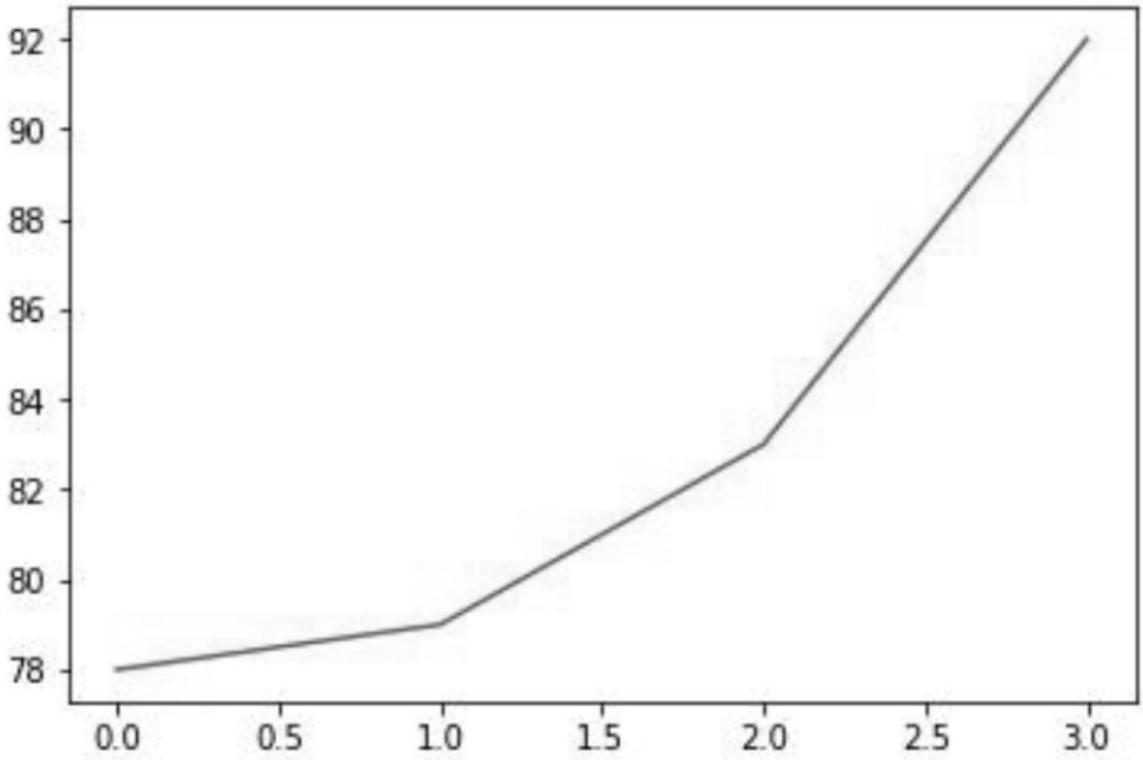

图7.2　绘制线形图

7.1.2　颜色与线形

通过plot函数的color参数可以指定线条的颜色，这里绘制的是红色的线条，如图7.3所示。

```
years = [1950, 1960, 1970, 1980, 1990, 2000, 2010]
gdp = [300.2, 543.3, 1075.9, 2862.5, 5979.6, 10289.7, 14958.3]
plt.plot(years,gdp,color='r')
```

```
[<matplotlib.lines.Line2D at 0xa54c438>]
```

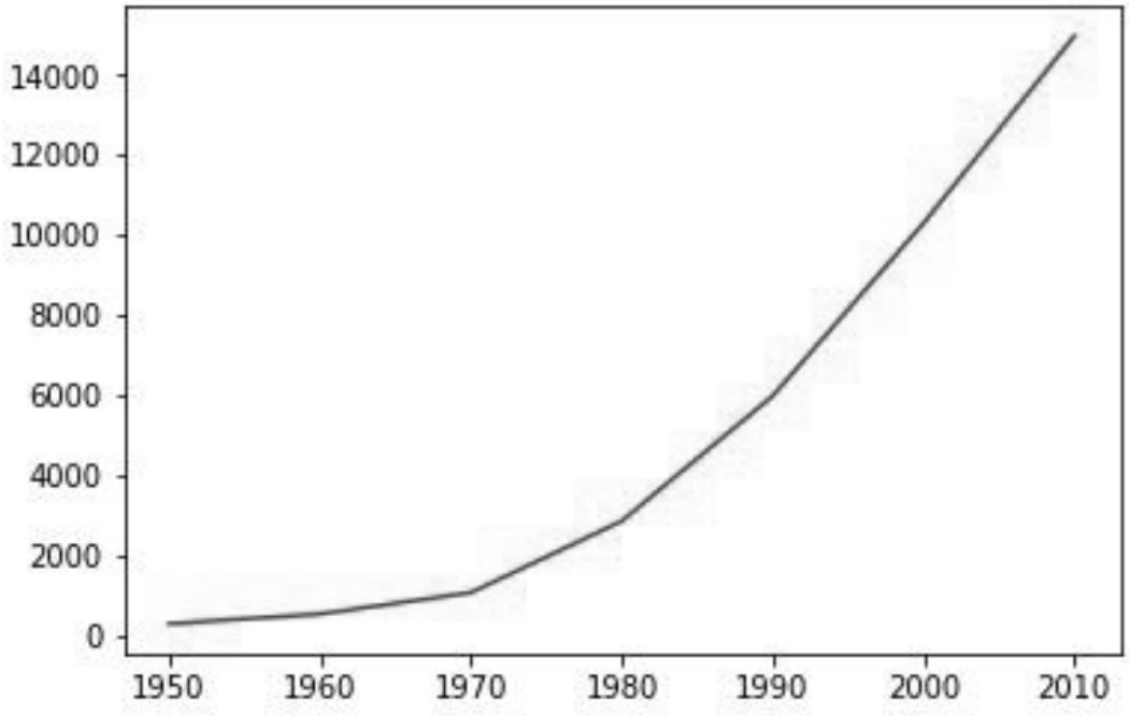

图7.3　颜色设置1

说明：由于是黑白印刷，书中无法显示真实效果，读者可自己操作体验。

也可以指定RGB值来更改线条的颜色，如图7.4所示。

```
plt.plot(years, gdp, color='#FFA500')
```

```
[<matplotlib.lines.Line2D at 0xa3e5160>]
```

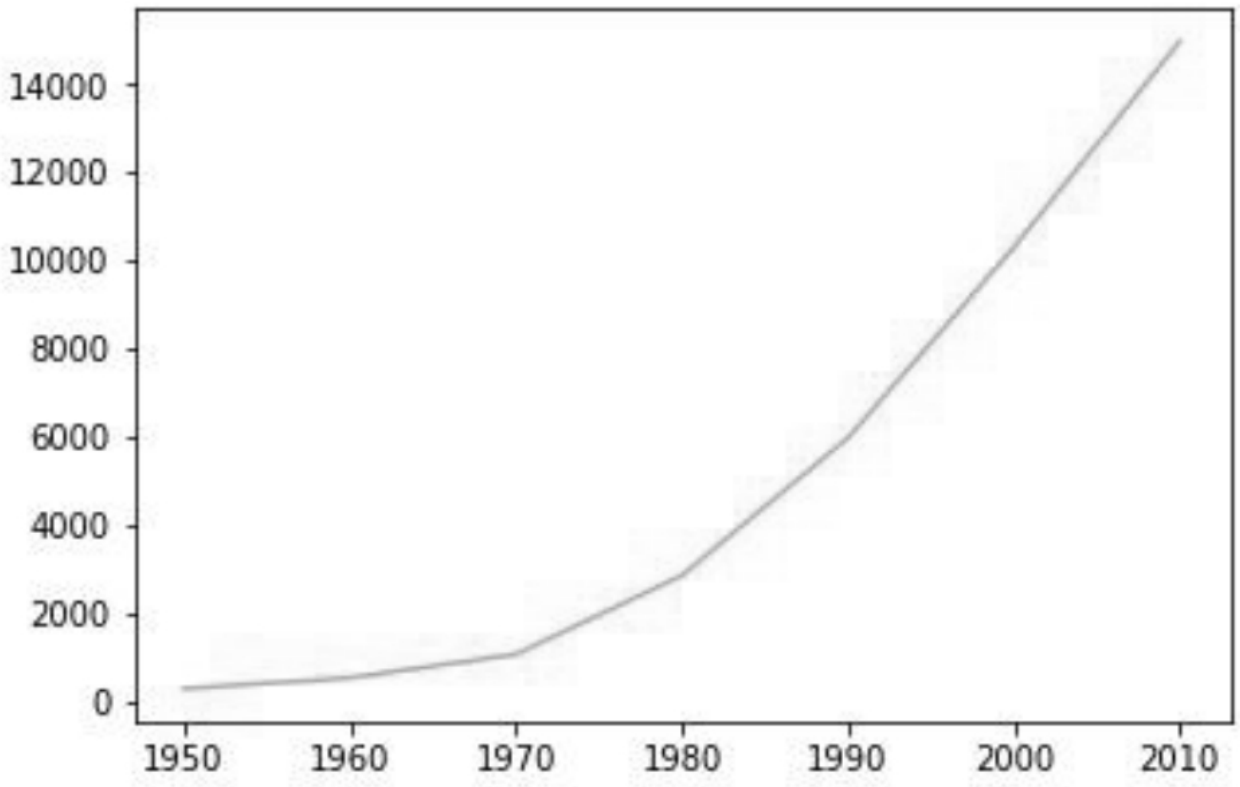

图7.4　颜色设置2

注意：完整的参数列表可参考matplotlib官方文档，也可以参考该博客http://www.cnblogs.com/darkknightzh/p/6117528.html。

通过plot函数的linestyle参数可以指定线条的形状，这里绘制出虚线的线条，如图7.5所示。

```
plt.plot(years,gdp,linestyle='--')
```

```
[<matplotlib.lines.Line2D at 0xbf4d5c0>]
```

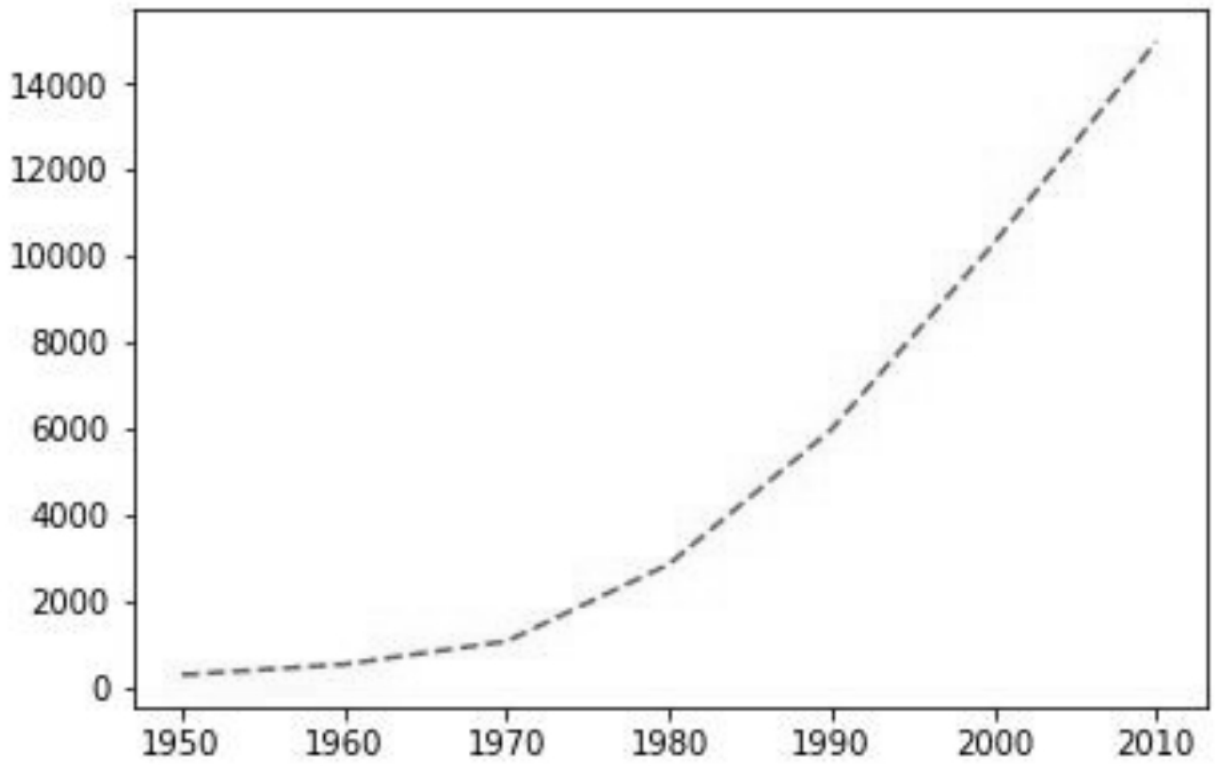

图7.5　线形设置

通过plot函数的linewidth参数可以指定线条的宽度，如图7.6所示。

```
plt.plot(years, gdp, linestyle='--', linewidth=5)
```

```
[<matplotlib.lines.Line2D at 0xc0e3dd8>]
```

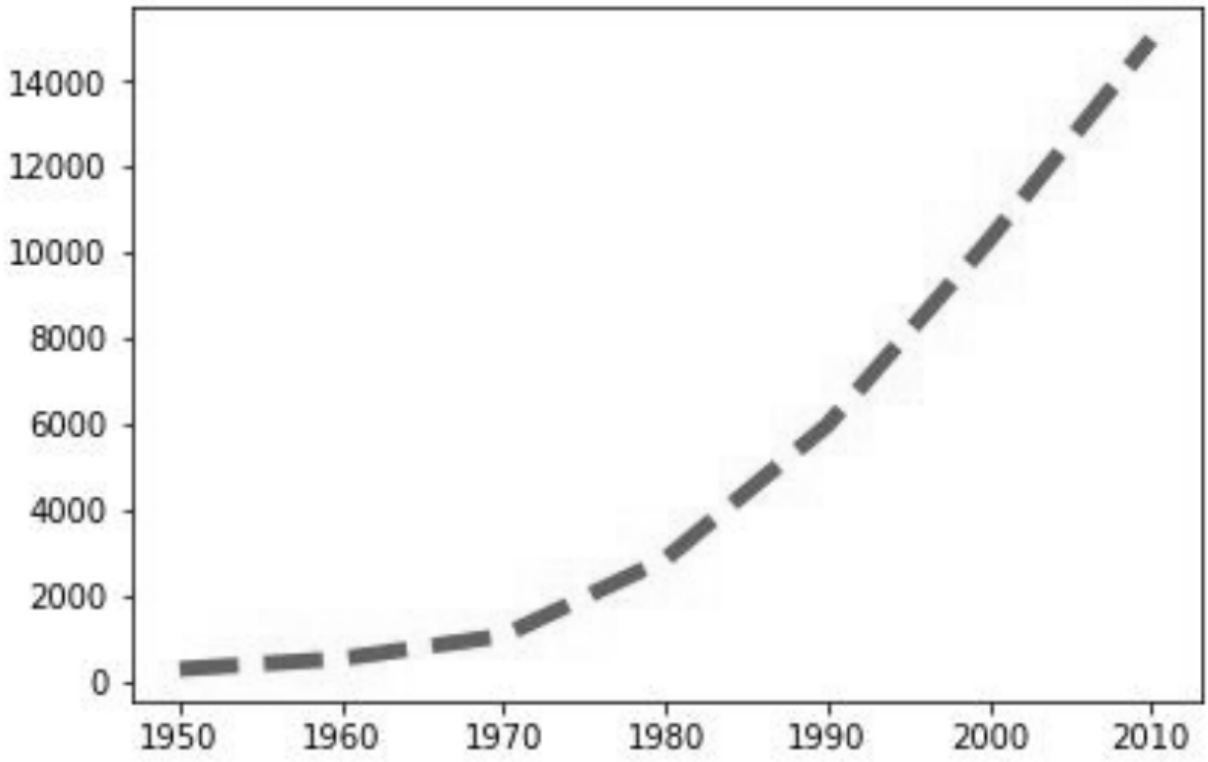

图7.6　线宽设置

7.1.3　点标记

默认情况下，坐标点是没有标记的，通过plot函数的marker参数可对坐标点进行标记，如图7.7所示。

```
plt.plot(years,gdp,marker='D')
```

```
[<matplotlib.lines.Line2D at 0xc14b048>]
```

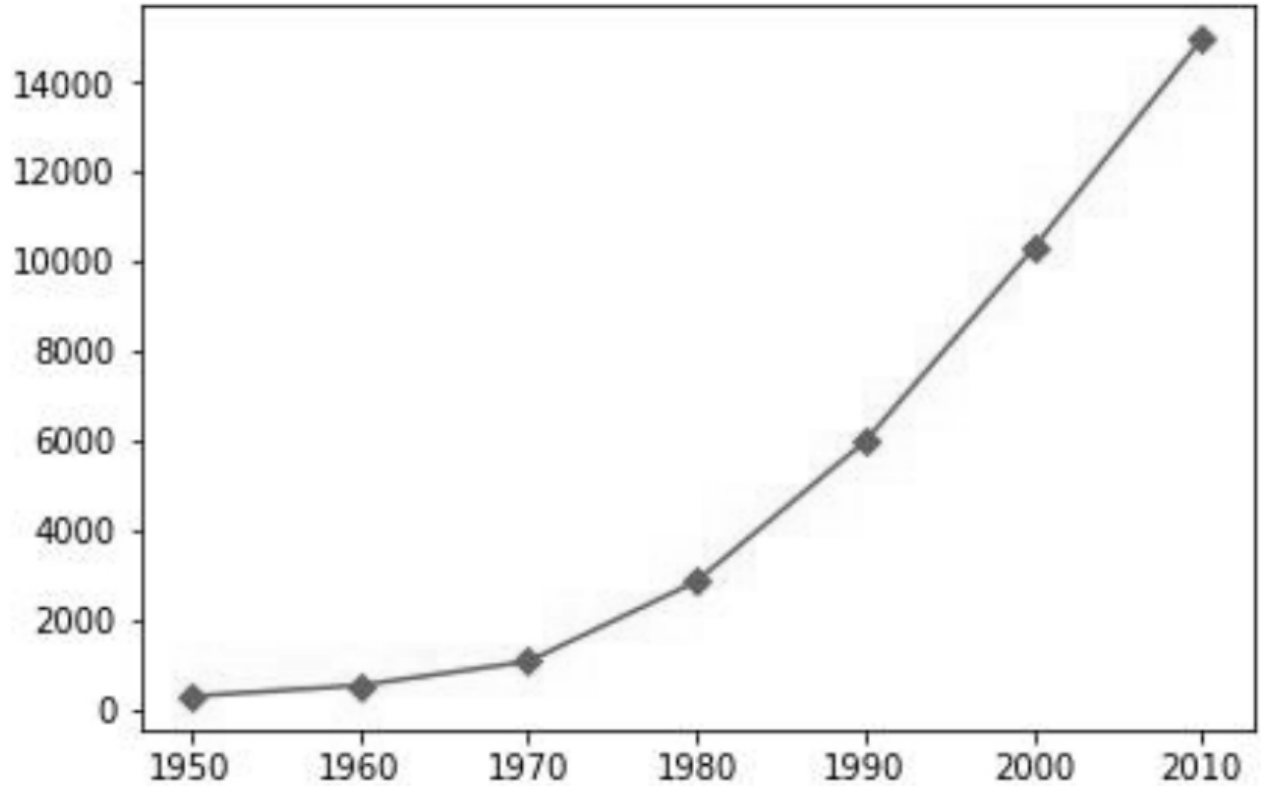

图7.7　点标记

颜色、线条和点的样式可以一起放置于格式字符串中，但颜色设置要放在线条和点的样式的前面，如图7.8所示。

```
plt.plot(years,gdp,'co--')
[<matplotlib.lines.Line2D at 0xc1d35f8>]
```

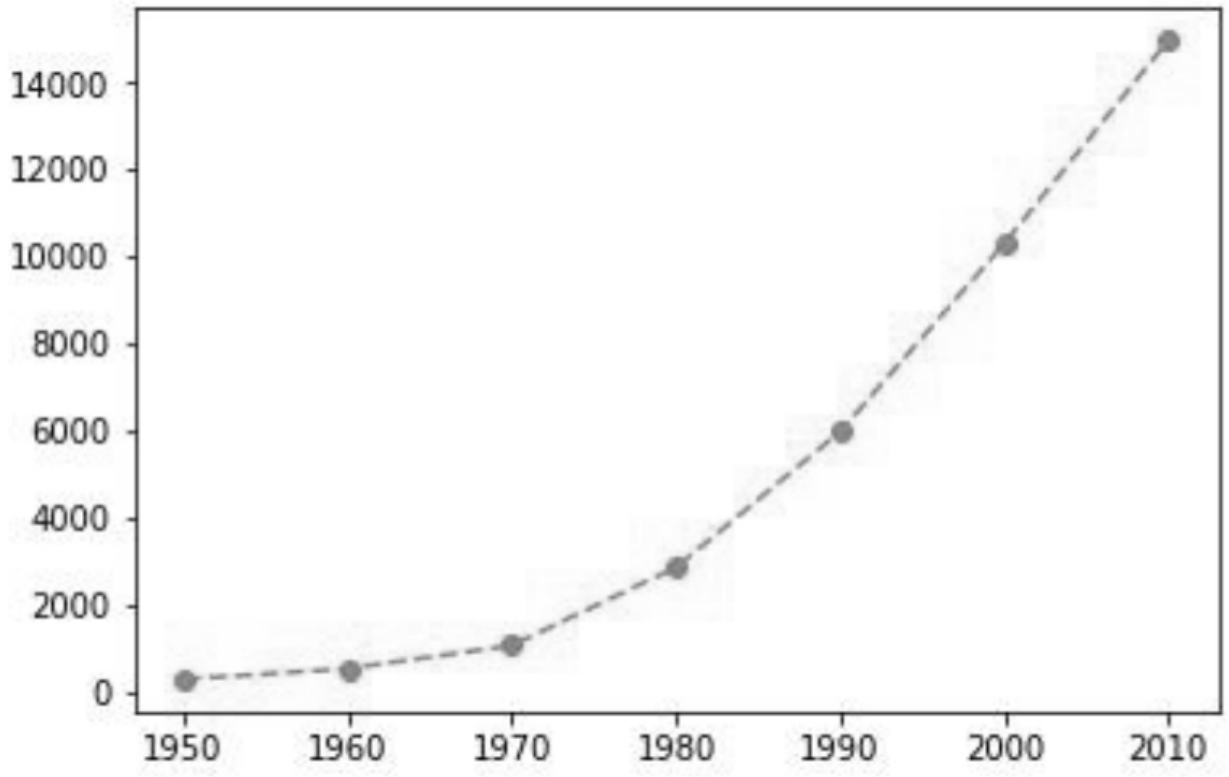

图7.8　各样式设置

7.2　柱状图

柱状图是数据分析中常用的图表。本节将着重讲解通过Matplotlib绘制各类柱状图的方法，通过简单的例子，让读者学会灵活使用matplotlib。

7.2.1　基本使用

绘制柱状图主要是使用matplotlib的bar函数。相比通过pandas绘制柱状图，通过matplotlib绘制柱状图的方法稍显复杂，需传入刻度列表和高度列表，如图7.9所示。

```
data = [23, 85, 72, 43, 52]
plt.bar([1,2,3,4,5],data)
```

```
<Container object of 5 artists>
```

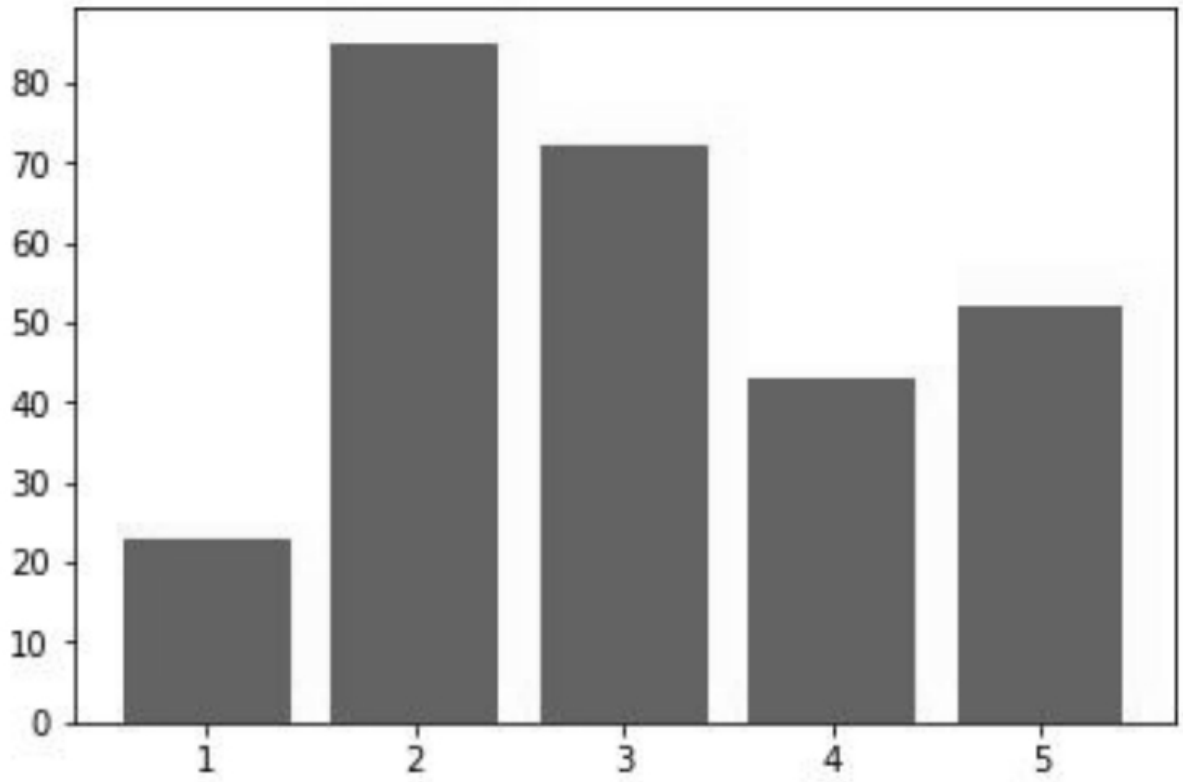

图7.9　绘制柱状图

通过bar函数的color参数可以设置柱状图的填充颜色，alpha参数可以设置透明度，如图7.10所示。

```
plt.bar(range(len(data)),data,color='royalblue',alpha=0.7)
```

```
<Container object of 5 artists>
```

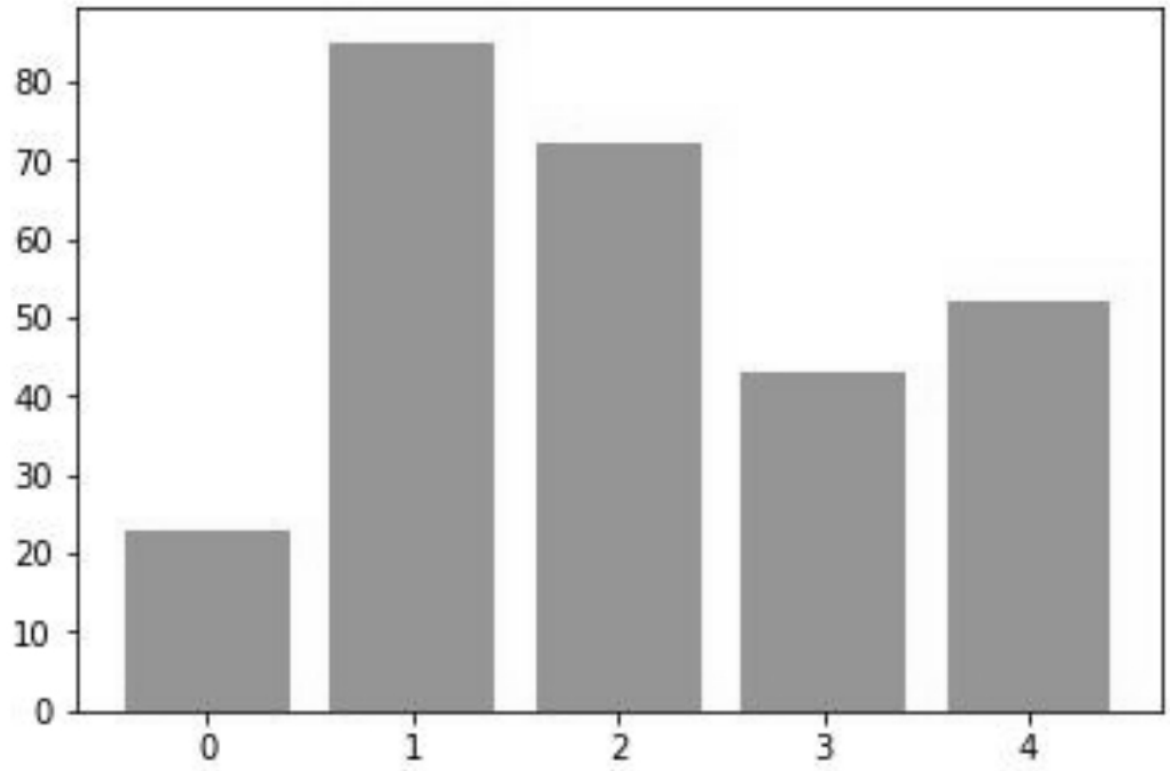

图7.10　颜色设置

grid函数用于绘制格网，通过对参数的个性化设置，可以绘制出个性的格网，如图7.11所示。

```
plt.bar(range(len(data)),data,color='green',alpha=0.7)
plt.grid(color='#95a5a6',linestyle='--', linewidth=1,axis='y',alpha=0.6)
```

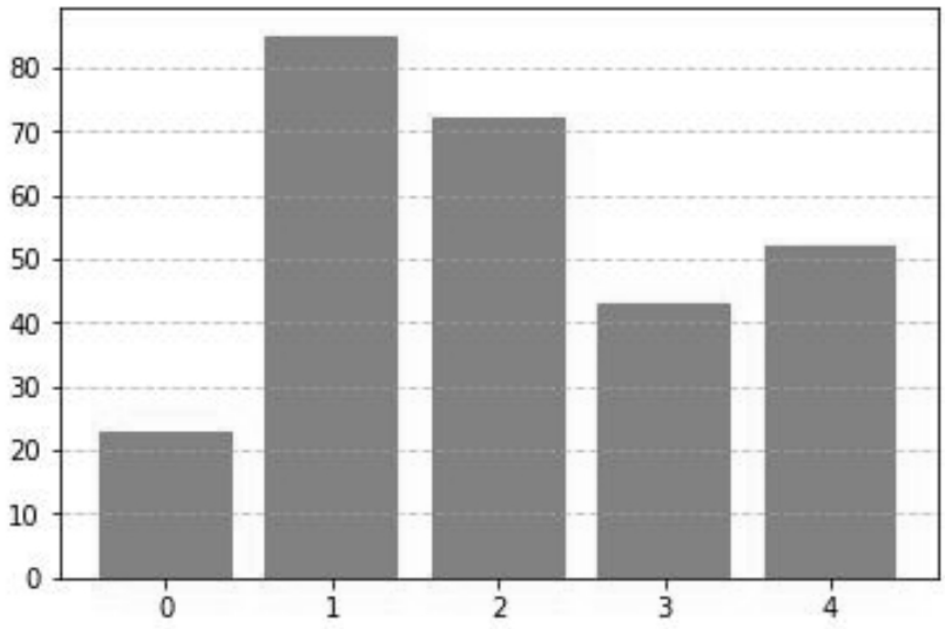

图7.11　格网设置

bar函数的bottom参数用于设置柱状图的高度，以此可以绘制堆积柱状图，如图7.12所示。

```
data1 = [23, 85, 72, 43, 52]
data2 = [42, 35, 21, 16, 9]
plt.bar(range(len(data)),data1)
plt.bar(range(len(data)),data2,bottom=data1)
```

```
<Container object of 5 artists>
```

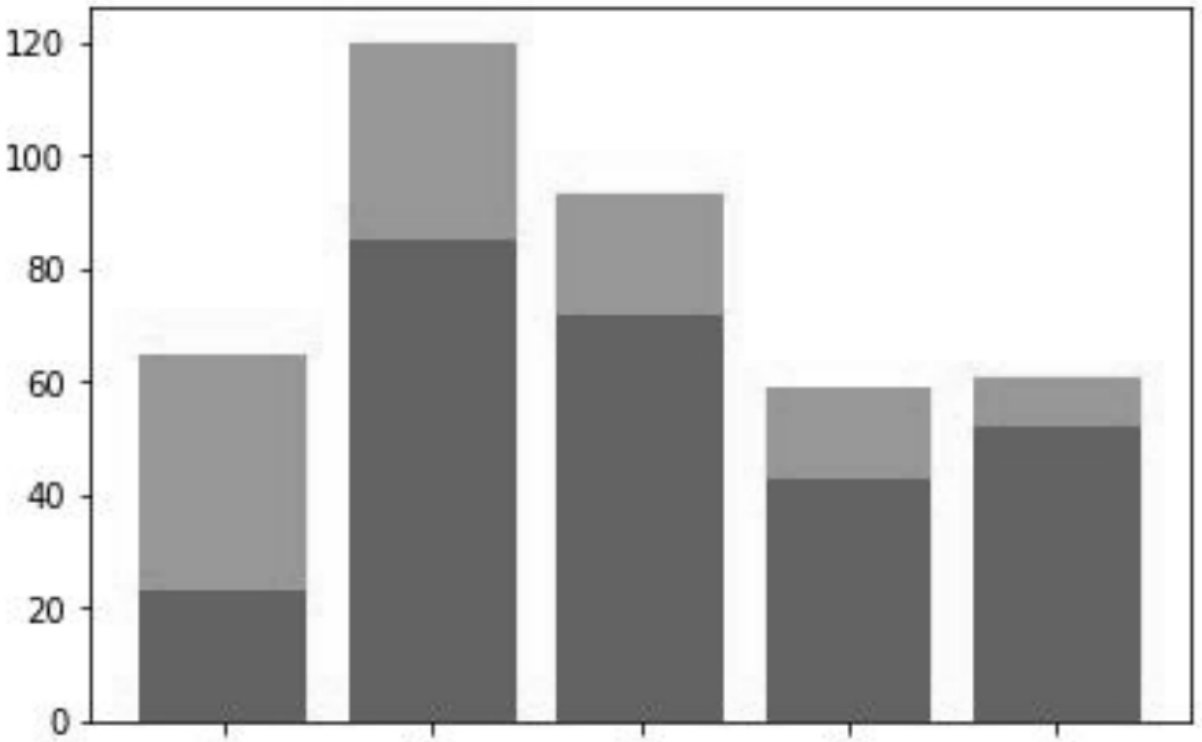

图7.12　堆积柱状图

bar函数的width参数用于设置柱状图的宽度，以此可以绘制并列柱状图，如图7.13所示。

```
data1 = [23, 85, 72, 43, 52]
data2 = [42, 35, 21, 16, 9]
width = 0.3
plt.bar(np.arange(len(data1)),data1,width=width)
plt.bar(np.arange(len(data2))+width,data2,width=width)
```

```
<Container object of 5 artists>
```

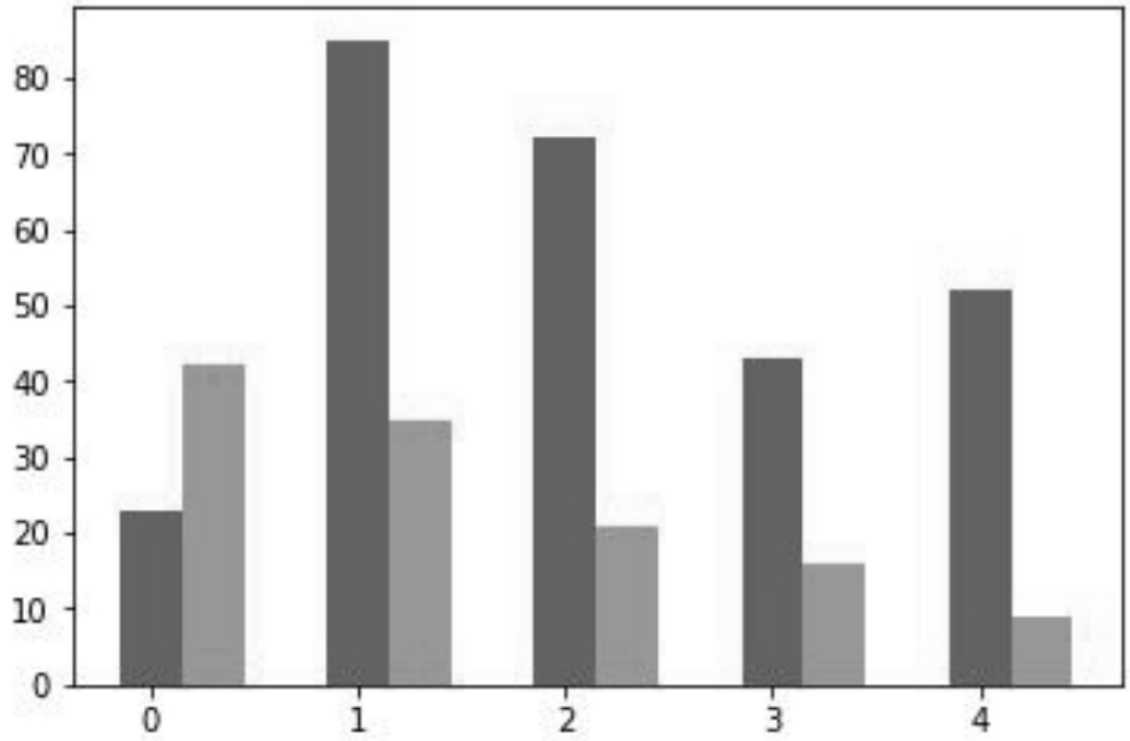

图7.13　并列柱状图

bar函数的通过barh函数可以绘制水平柱状图，如图7.14所示。

```
data1 = [23, 85, 72, 43, 52]
plt.barh(range(len(data1)),data1)
```

```
<Container object of 5 artists>
```

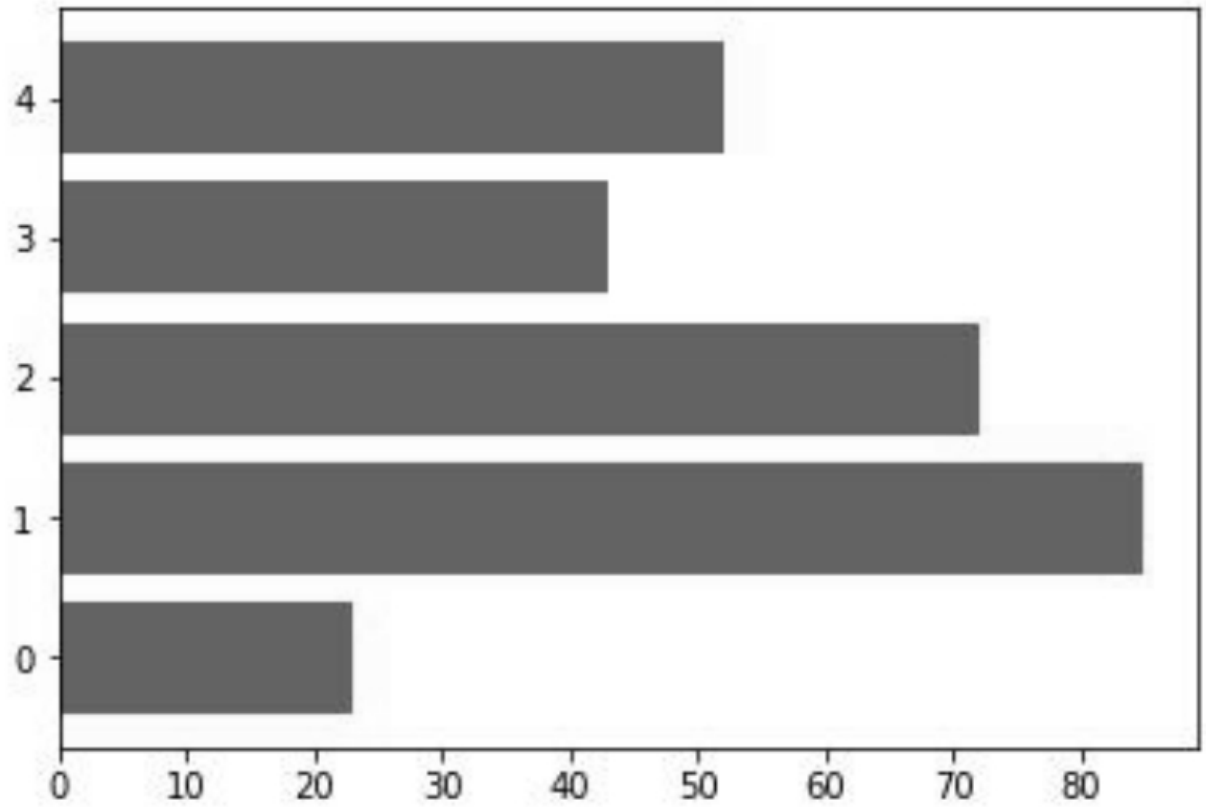

图7.14　水平柱状图

7.2.2　刻度与标签

通过7.2.1节的例子可以看出，绘制的柱状图的X轴刻度上没有对应的刻度标签，但现实中的柱状图的X轴是需要标签的。在matplotlib中，通过xticks函数可以设置图标的X轴刻度和刻度标签，通过以下代码就可以绘制带有标签的柱状图，效果如图7.15所示。

```
data = [23, 85, 72, 43, 52]
labels = ['A','B','C','D','E']
plt.xticks(range(len(data)),labels) #设置刻度和标签
plt.bar(range(len(data)),data)
```

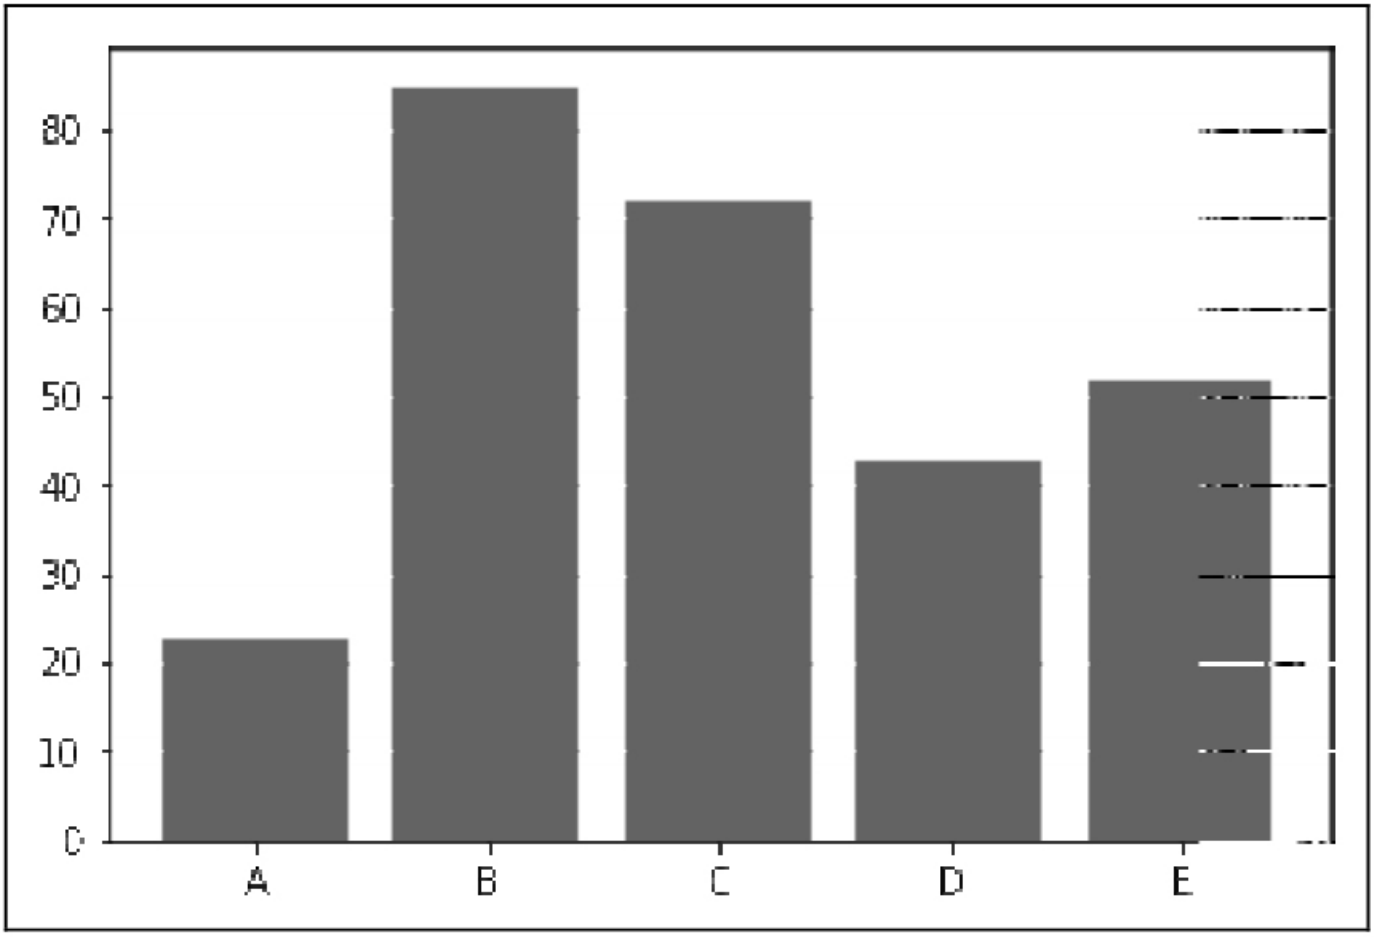

图7.15　设置刻度和刻度标签

注意：通过yticks函数可以修改Y轴的刻度和标签。

通过xlable和ylabel方法给X轴和Y轴添加标签，通过title方法为图表添加标题，如图7.16所示。

```
data = [23, 85, 72, 43, 52]
labels = ['A','B','C','D','E']
plt.xticks(range(len(data)),labels) #设置刻度和标签
plt.xlabel('Class')
plt.ylabel('Amounts')
plt.title('Example1')
plt.bar(range(len(data)),data)
```

```
<Container object of 5 artists>
```

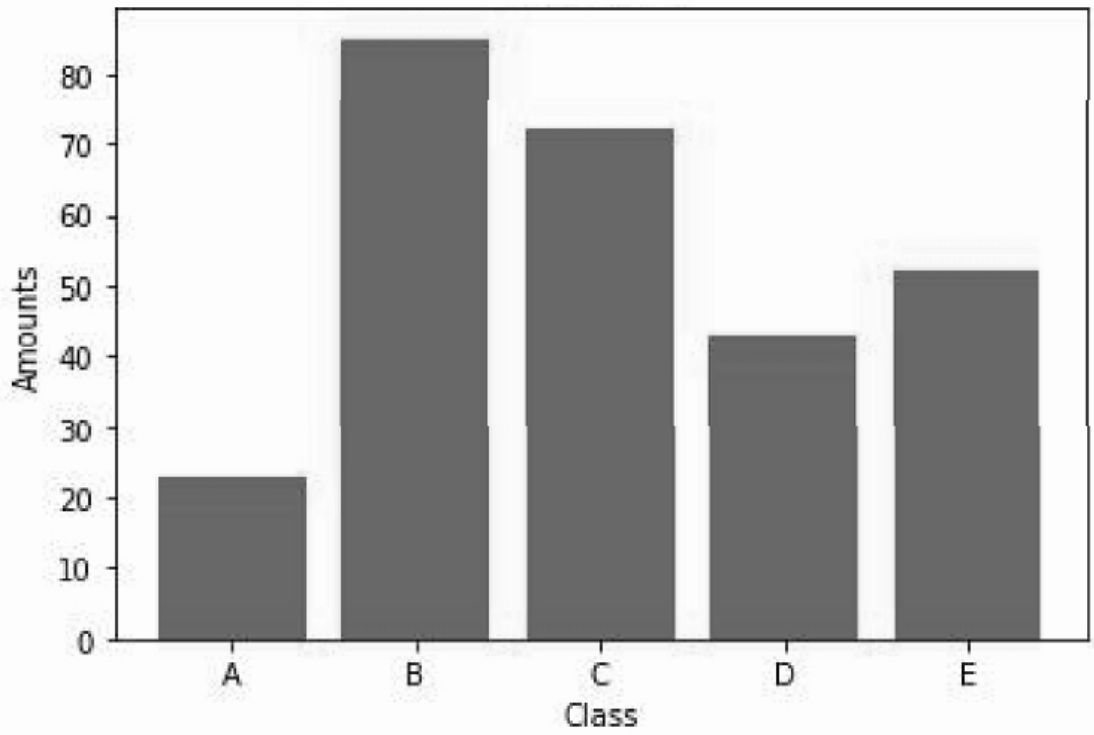

图7.16　添加X、Y轴标签和标题

7.2.3　图例

图例是标识图表元素的重要工具。在bar函数中传入label参数可表明图例名称，通过legend函数即可绘制出图例，如图7.17所示。

```
data1 = [23, 85, 72, 43, 52]
data2 = [42, 35, 21, 16, 9]
width = 0.3
plt.bar(np.arange(len(data1)),data1,width=width,label='one')
plt.bar(np.arange(len(data2))+width,data2,width=width,label='two')
plt.legend()
```

```
<matplotlib.legend.Legend at 0xa63ae48>
```

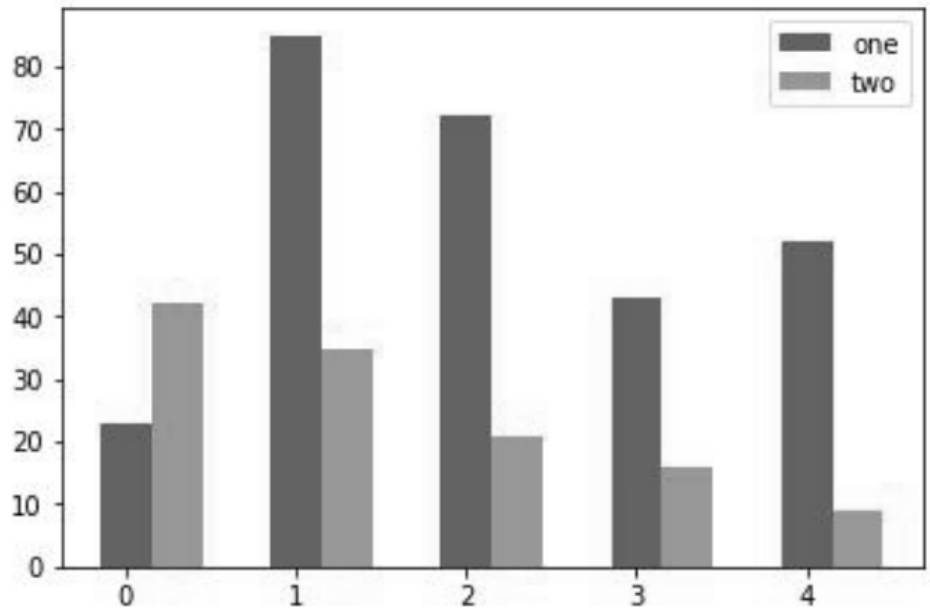

图7.17　添加图例

下面通过小费数据，讲解如何在现实数据中绘制柱状图，如图7.18所示。通过groupby函数可统计男女性别的小费平均值，如图7.18所示。

```
tips=sns.load_dataset('tips')
tips.head()
```

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

```
sex_mean = tips.groupby('sex')['tip'].mean()
sex_mean
```

```
sex
Male      3.089618
Female    2.833448
Name: tip, dtype: float64
```

图7.18　分组数据

说明：图7.18的数据集中，total_bill为消费总金额；tip为小费；sex为顾客性别；smoker为顾客是否抽烟；day为消费的星期；time为聚餐的时间段；size为聚餐人数。

下面给出获取该Series的索引作为X轴刻度标签的代码，绘制的柱状图如图7.19所示。

```
labels = list(sex_mean.index)  #刻度标签
plt.xlabel('sex')  #设置X轴标签
plt.ylabel('tip')  #设置Y轴标签
plt.bar(range(len(labels)),sex_mean,width=0.5)
plt.xticks(range(len(labels)),labels,fontsize=12) #设置刻度和刻度标签
```

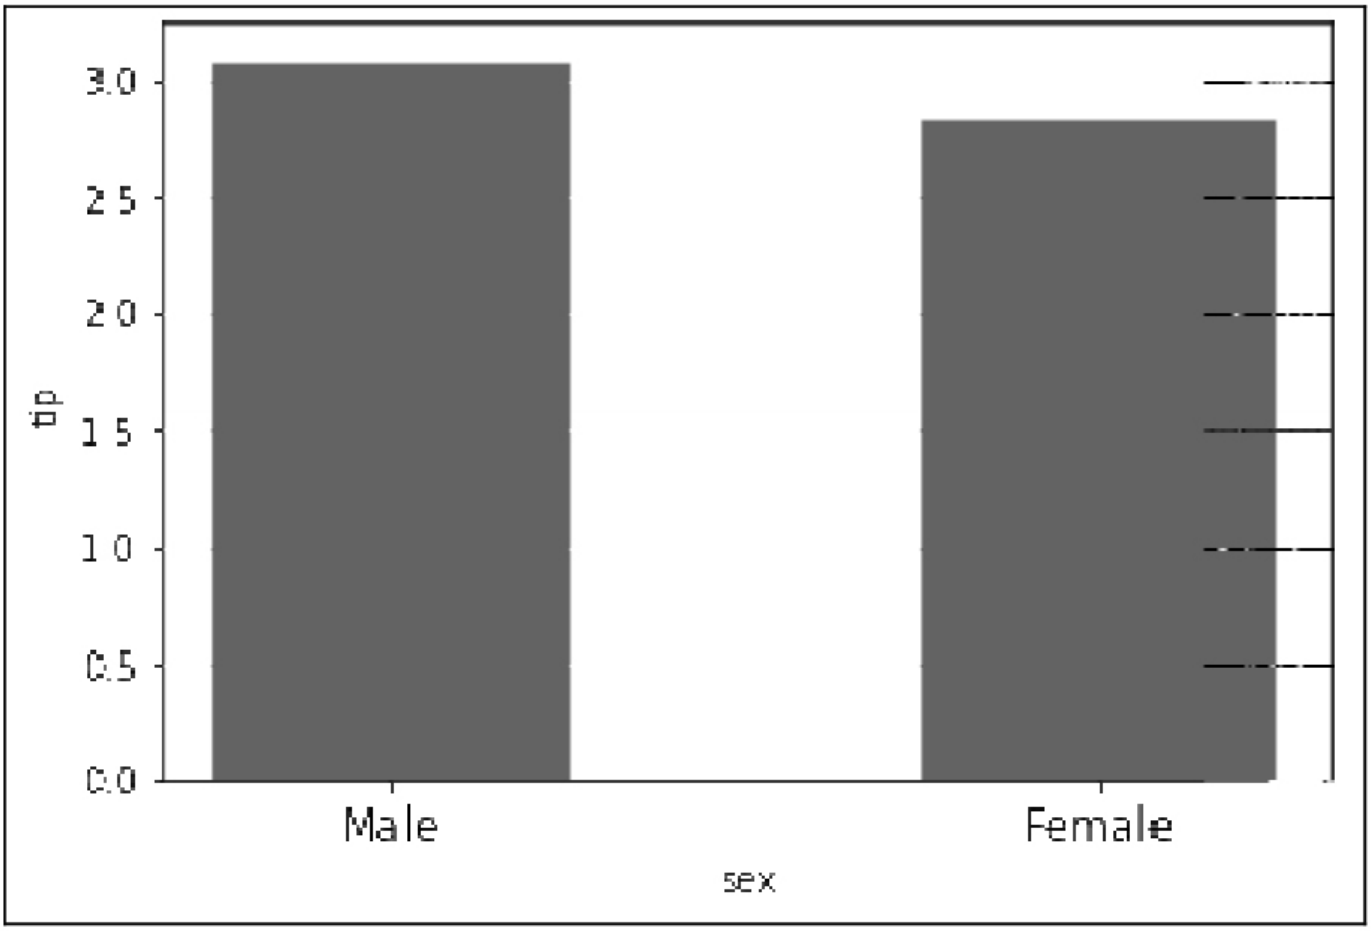

图7.19　性别和小费的关联

7.3　其他基本图表

本节主要讲解其他基本图表的绘制方法，如散点图和直方图。

7.3.1　散点图

matplotlib的scatter函数可以用来绘制散点图，传入X和Y轴坐标即可。首先利用NumPy创建一组随机数，如图7.20所示为绘制的散点图。

```
X = np.random.randn(100)
Y = np.random.randn(100)
plt.scatter(X,Y)
```

```
<matplotlib.collections.PathCollection at 0xcafce10>
```

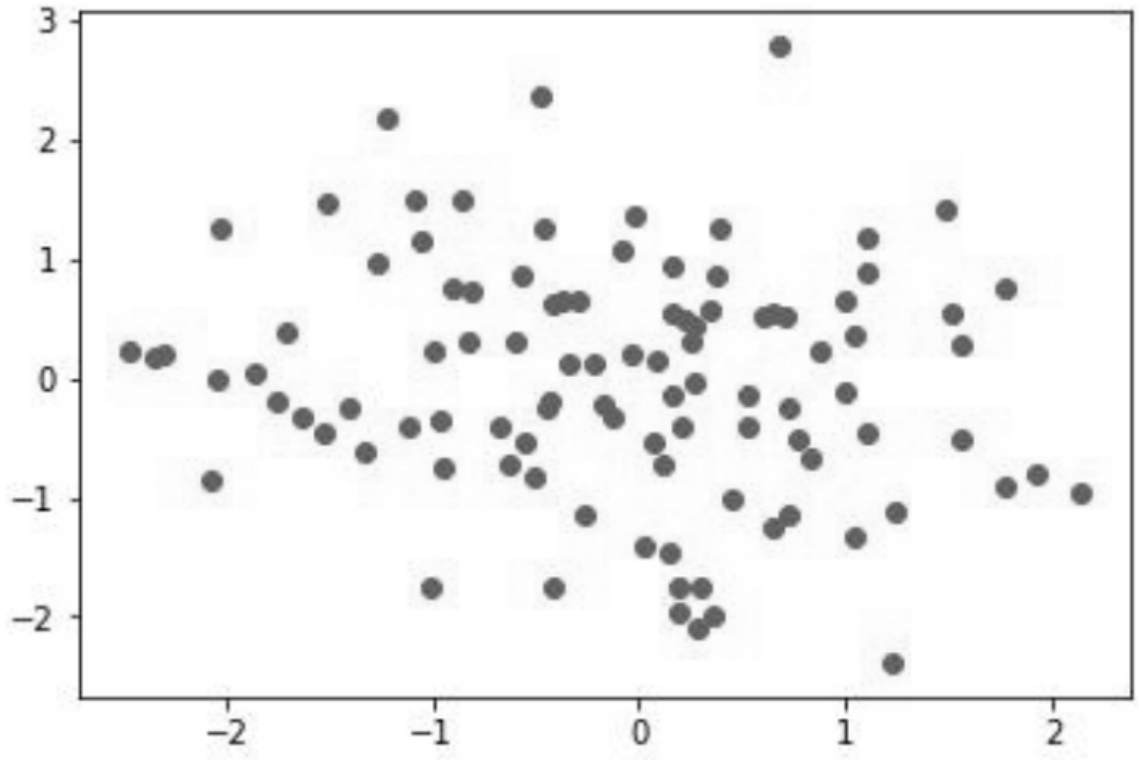

图7.20　散点图

也可以为散点更改颜色和点标记，如图7.21所示。（图7.21中的散点实际为红色）

```
plt.scatter(X,Y,color='red',marker='D')
```

```
<matplotlib.collections.PathCollection at 0xa69c278>
```

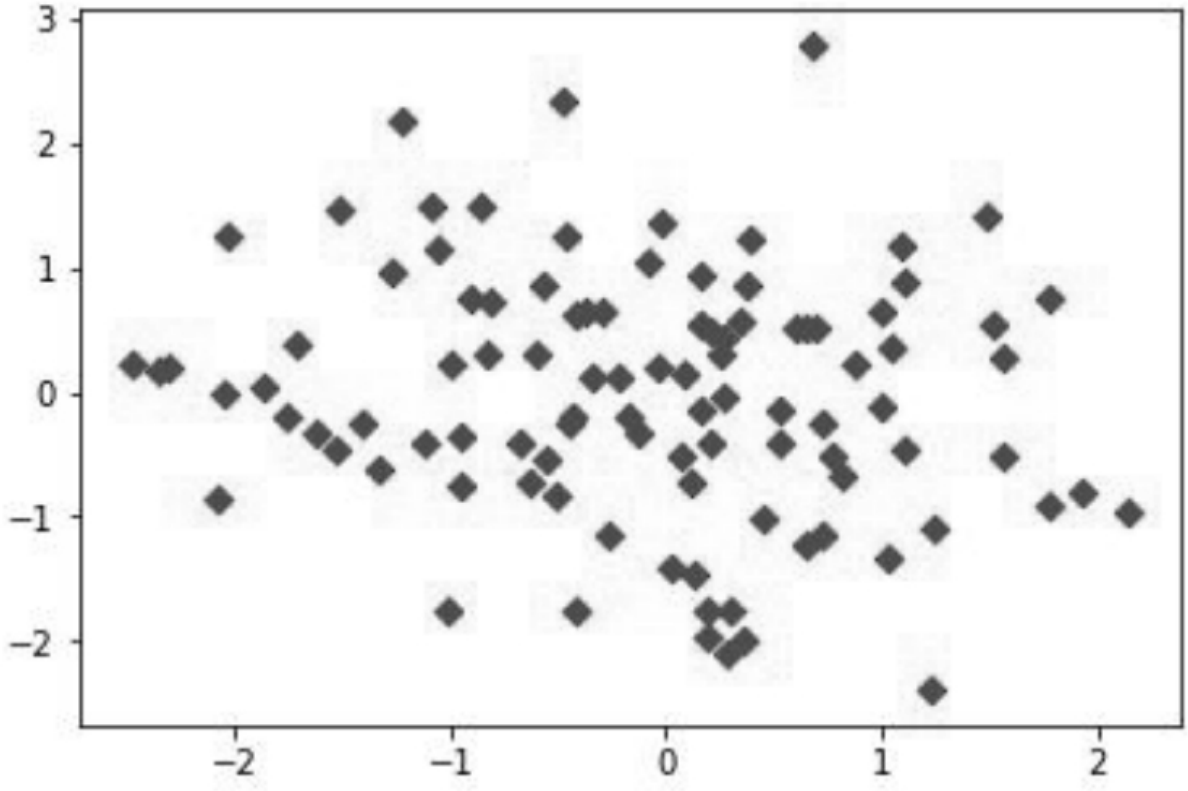

图7.21　样式设置

7.3.2　直方图

matplotlib的hist函数可以用来绘制直方图，如图7.22所示。

```
x = np.random.normal(size=100)
```

```
plt.hist(x,bins=30)
```

```
        0.67399085,  0.81923055,  0.96447025,  1.10970995,  1.25494964,
        1.40018934,  1.54542904,  1.69066874,  1.83590844,  1.98114813,
        2.12638783]),
 <a list of 30 Patch objects>)
```

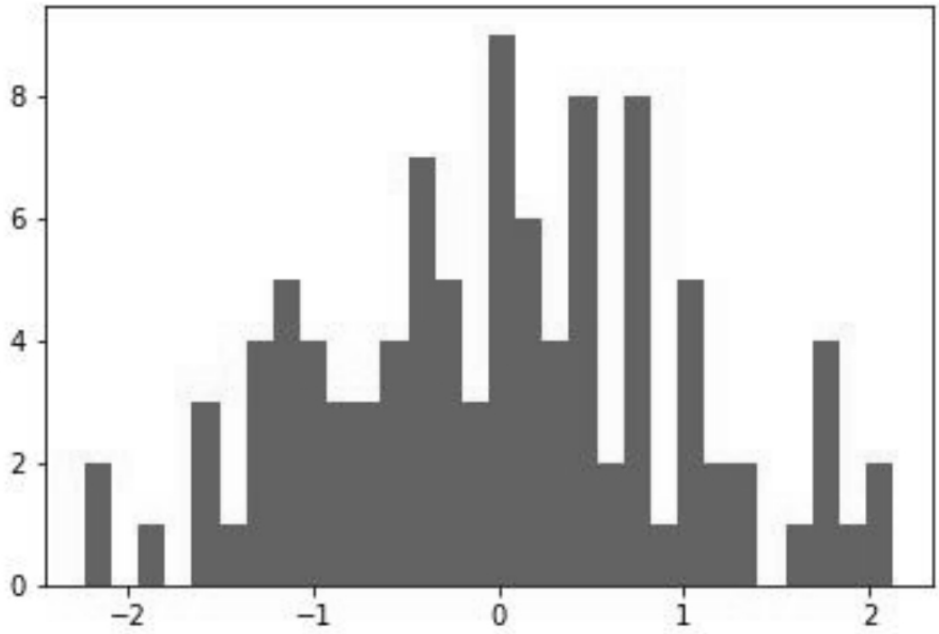

图7.22　直方图

7.4　自定义设置

由于matplotlib是最底层的绘图库，因此有很大的设置空间。本节将讲解如何通过matplotlib进行自定义绘图设置。

7.4.1　图表布局

matplotlib的图像位于Figure对象中。通过figure函数可以创建一个新的Figure，用于绘制图表，其中的figsize参数可以设置图表的长宽比。在创建Figure对象过程中，通过add_subplot函数创建子图，用于绘制图形，如图7.23所示。

```
fig = plt.figure(figsize=(10,6))
ax1 = fig.add_subplot(2,2,1)
ax2 = fig.add_subplot(2,2,2)
ax3 = fig.add_subplot(2,2,3)
```

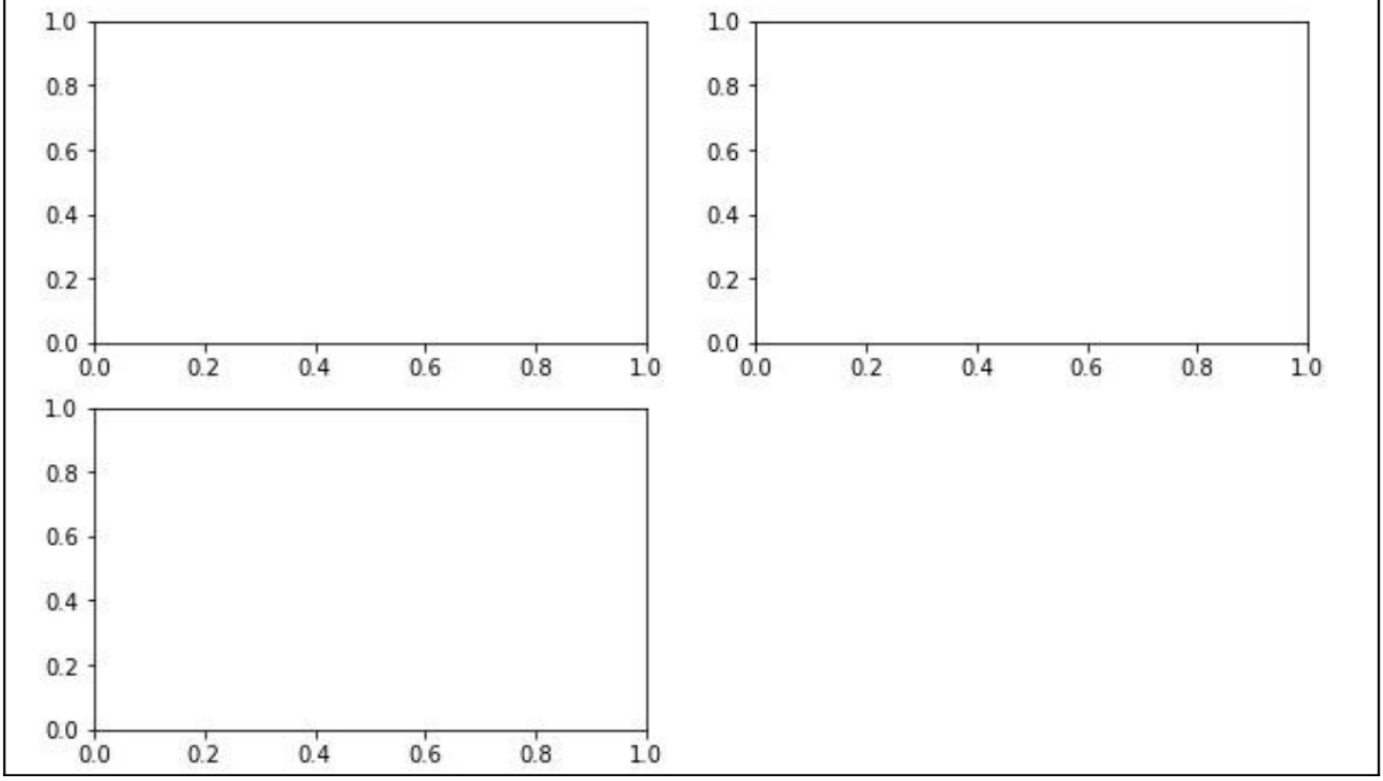

图7.23　创建子图

这时选择不同的ax变量，便可在对应的subplot子图中绘图，如图7.24所示。

```
fig = plt.figure(figsize=(10,6))
ax1 = fig.add_subplot(2,2,1)
ax2 = fig.add_subplot(2,2,2)
ax3 = fig.add_subplot(2,2,3)
years = [1950, 1960, 1970, 1980, 1990, 2000, 2010]
gdp = [300.2, 543.3, 1075.9, 2862.5, 5979.6, 10289.7, 14958.3]
ax1.scatter(years,gdp)
ax2.plot(years,gdp)
ax3.bar(years,gdp)
```

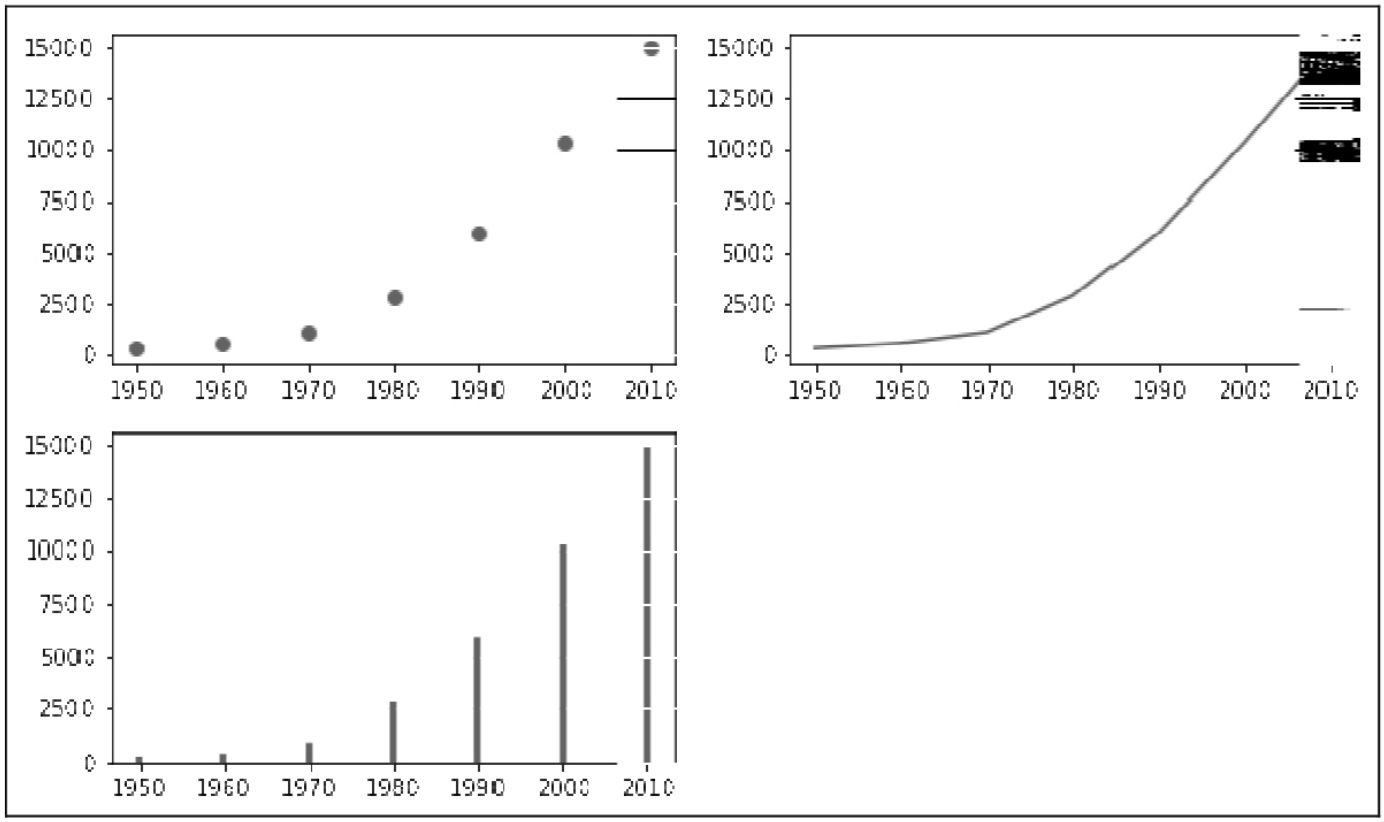

图7.24　subplot子图绘制1

通过plt.subplots可以很轻松地创建子图，而且axes的索引类似于二维数组，这样便可以对指定的子图进行绘制，如图7.25所示。

```
fig, axes = plt.subplots(2, 2, figsize=(10,6))
axes[1,0].plot(years, gdp)
```

```
[<matplotlib.lines.Line2D at 0xdf69198>]
```

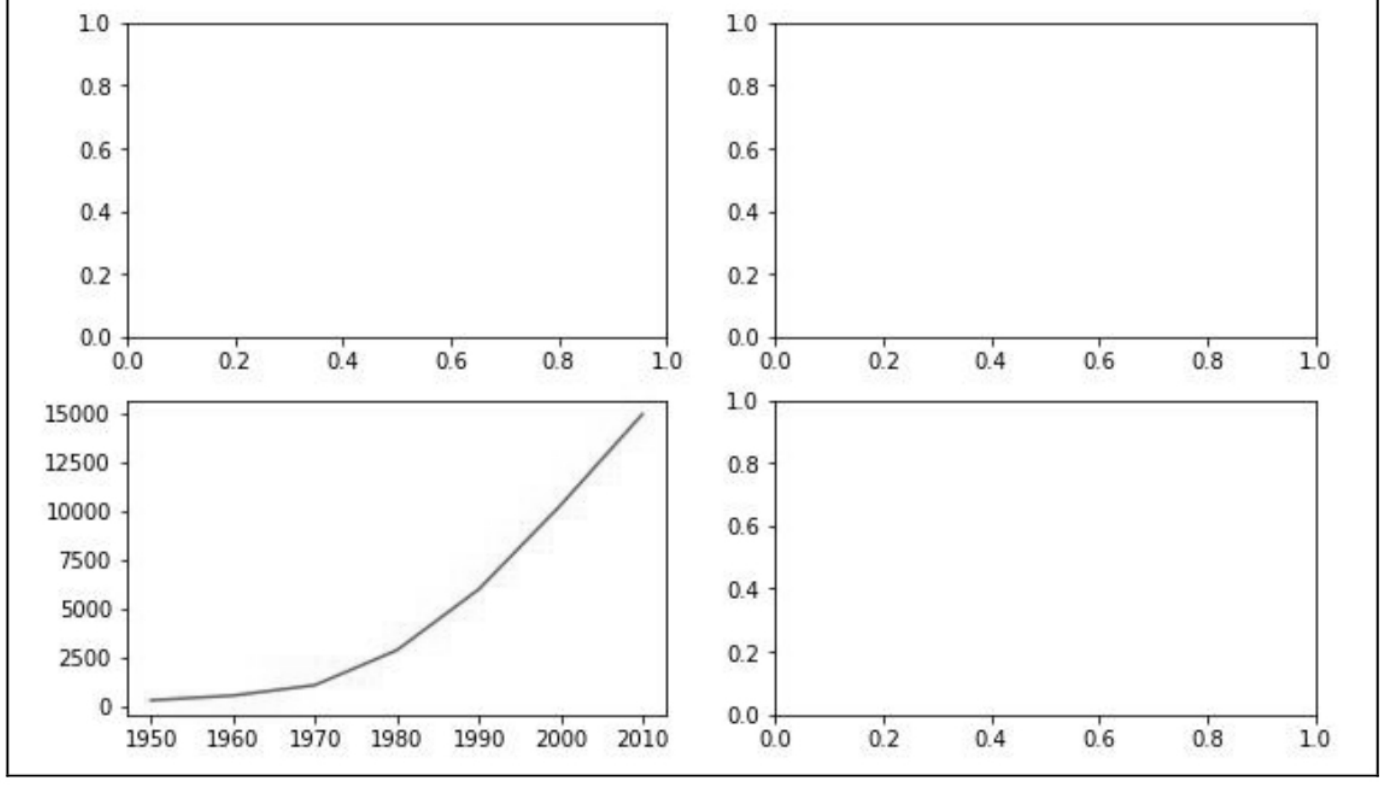

图7.25　subplot子图绘制2

默认情况下，各subplot子图间都会留有一定的间距，如图7.26所示。当没有设置figsize时，创建多子图会显得拥挤。通过plt.subplots_adjust方法，可以设置子图的间距修改子图之间的间距，如图7.27所示。具体参数如下：

```
subplots_adjust(left=None,bottom=None,right=None,top=None,wspace=None,hspace=None)
```

其中，前4个参数用于设置subplot子图的外围边距，wspace和hspace参数用于设置subplot子图间的边距。

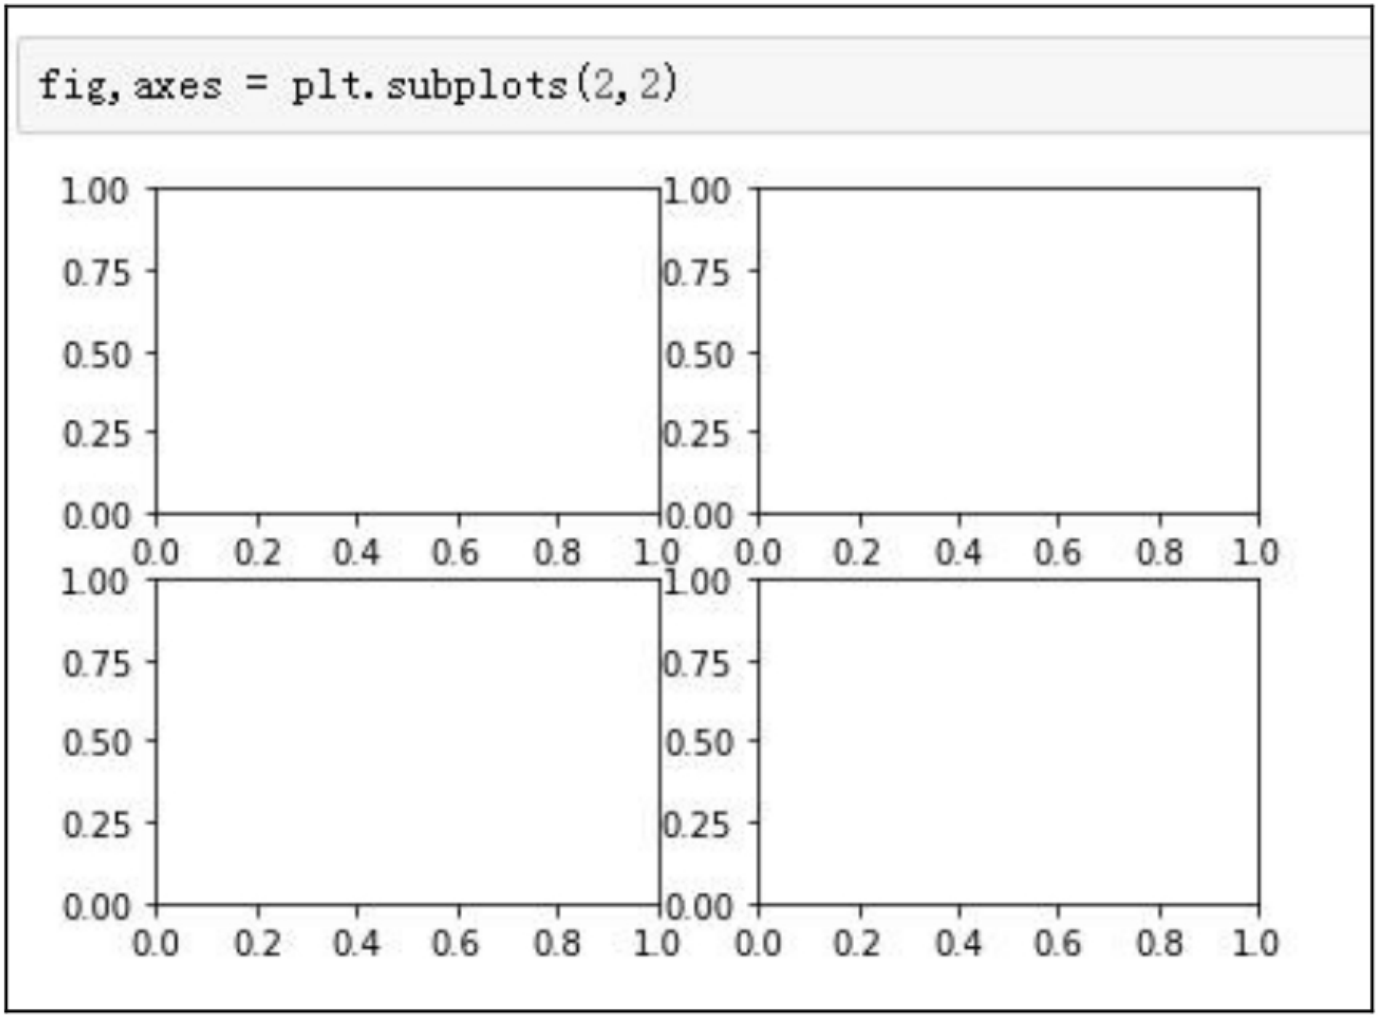

图7.26　修改前

```
fig, axes = plt.subplots(2, 2)
plt.subplots_adjust(wspace=0.3, hspace=0.3)
```

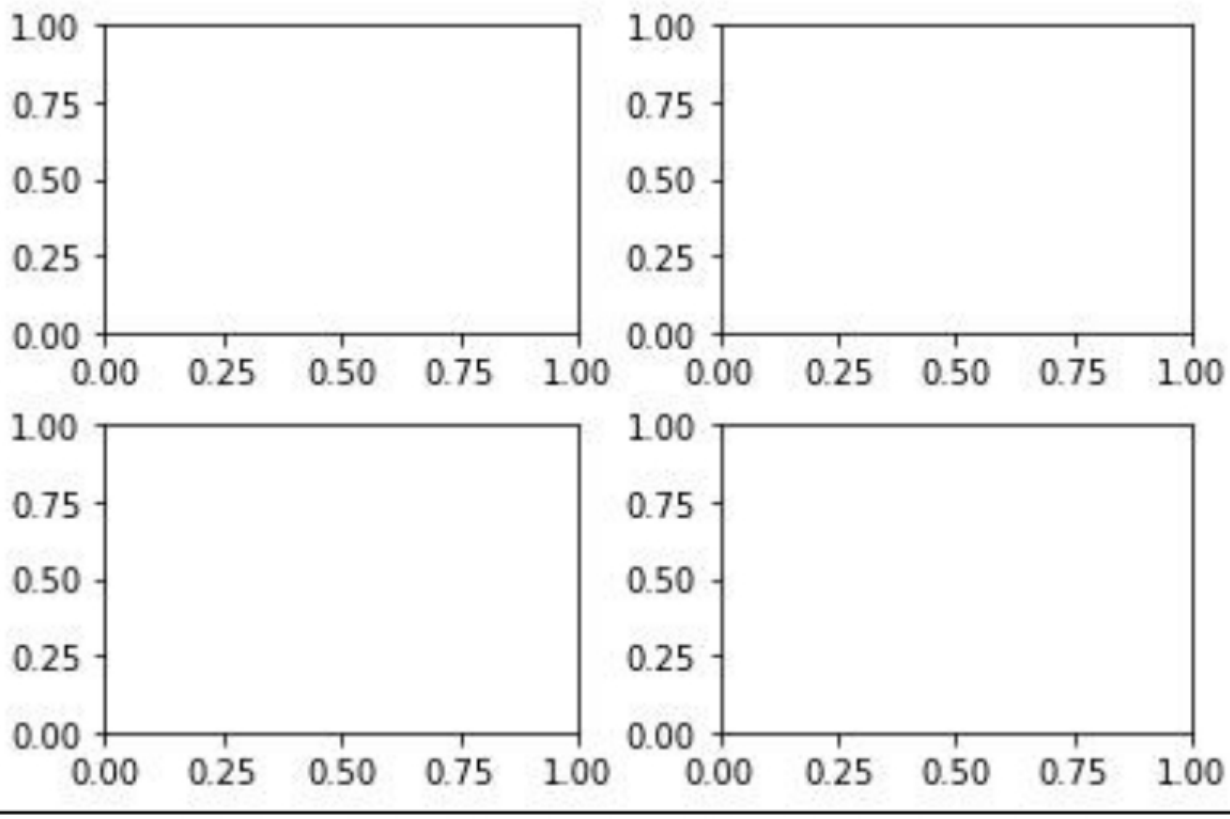

图7.27　修改后

7.4.2　文本注解

有时需要在图表上加上文本注解。例如，在柱状图上加入文本数字，可以很清楚地知道每个类别的数量。通过text函数可以在指定的坐标(x,y)上加入文本注解，如图7.28所示。

```
data = [23, 85, 72, 43, 52]
labels = ['A','B','C','D','E']
plt.xticks(range(len(data)),labels)                    #设置刻度和标签
plt.xlabel('Class')
plt.ylabel('Amounts')
plt.title('Example1')
plt.bar(range(len(data)),data)
for x,y in zip(range(len(data)),data):
plt.text(x, y,y, ha='center', va= 'bottom')            #文本注解
```

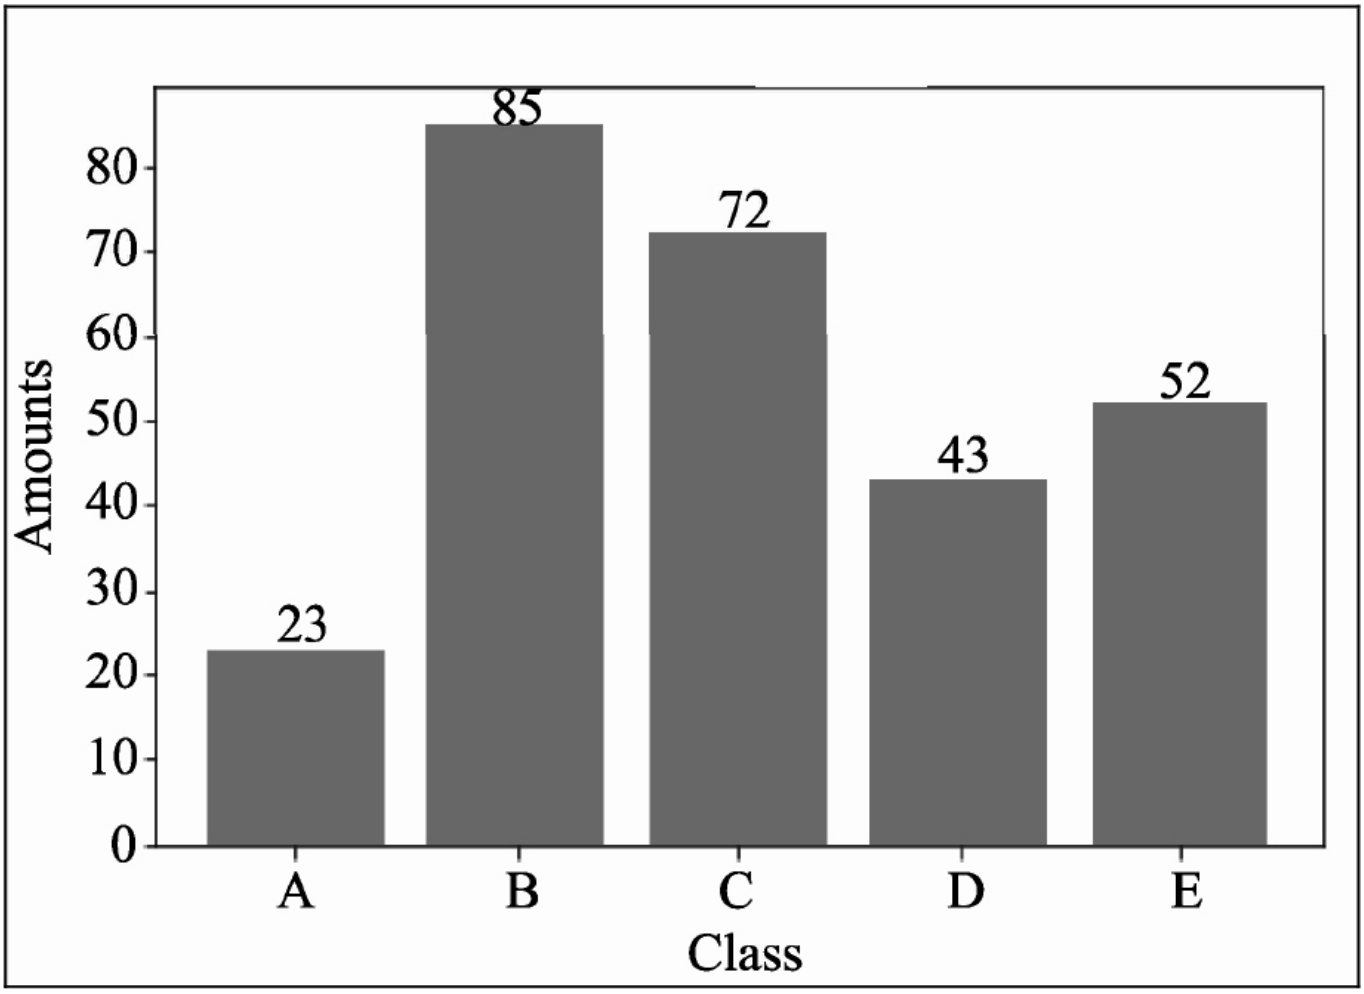

图7.28　文本注解

7.4.3　样式与字体

matplotlib自带了一些样式供用户使用，最常用的是ggplot样式，该样式是参考R语言中的ggplot库。通过plt.style.use('ggplot')函数即可调用该样式绘图，如图7.29所示。

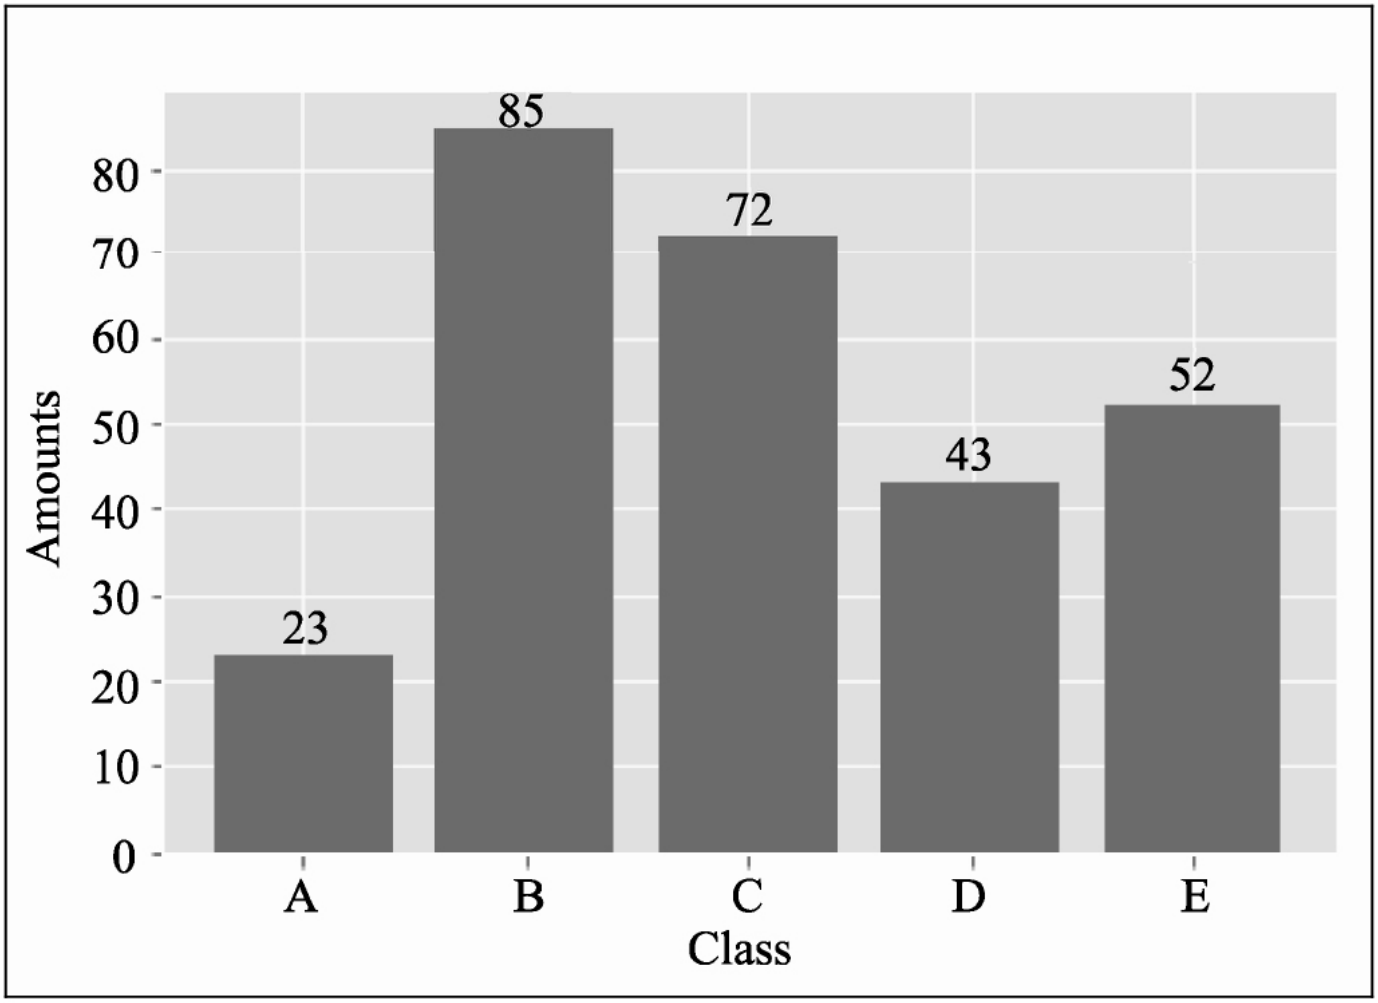

图7.29　样式调用

matplotlib默认为英文字体，如果绘制中出现汉字就会发生乱码，如图7.30所示。

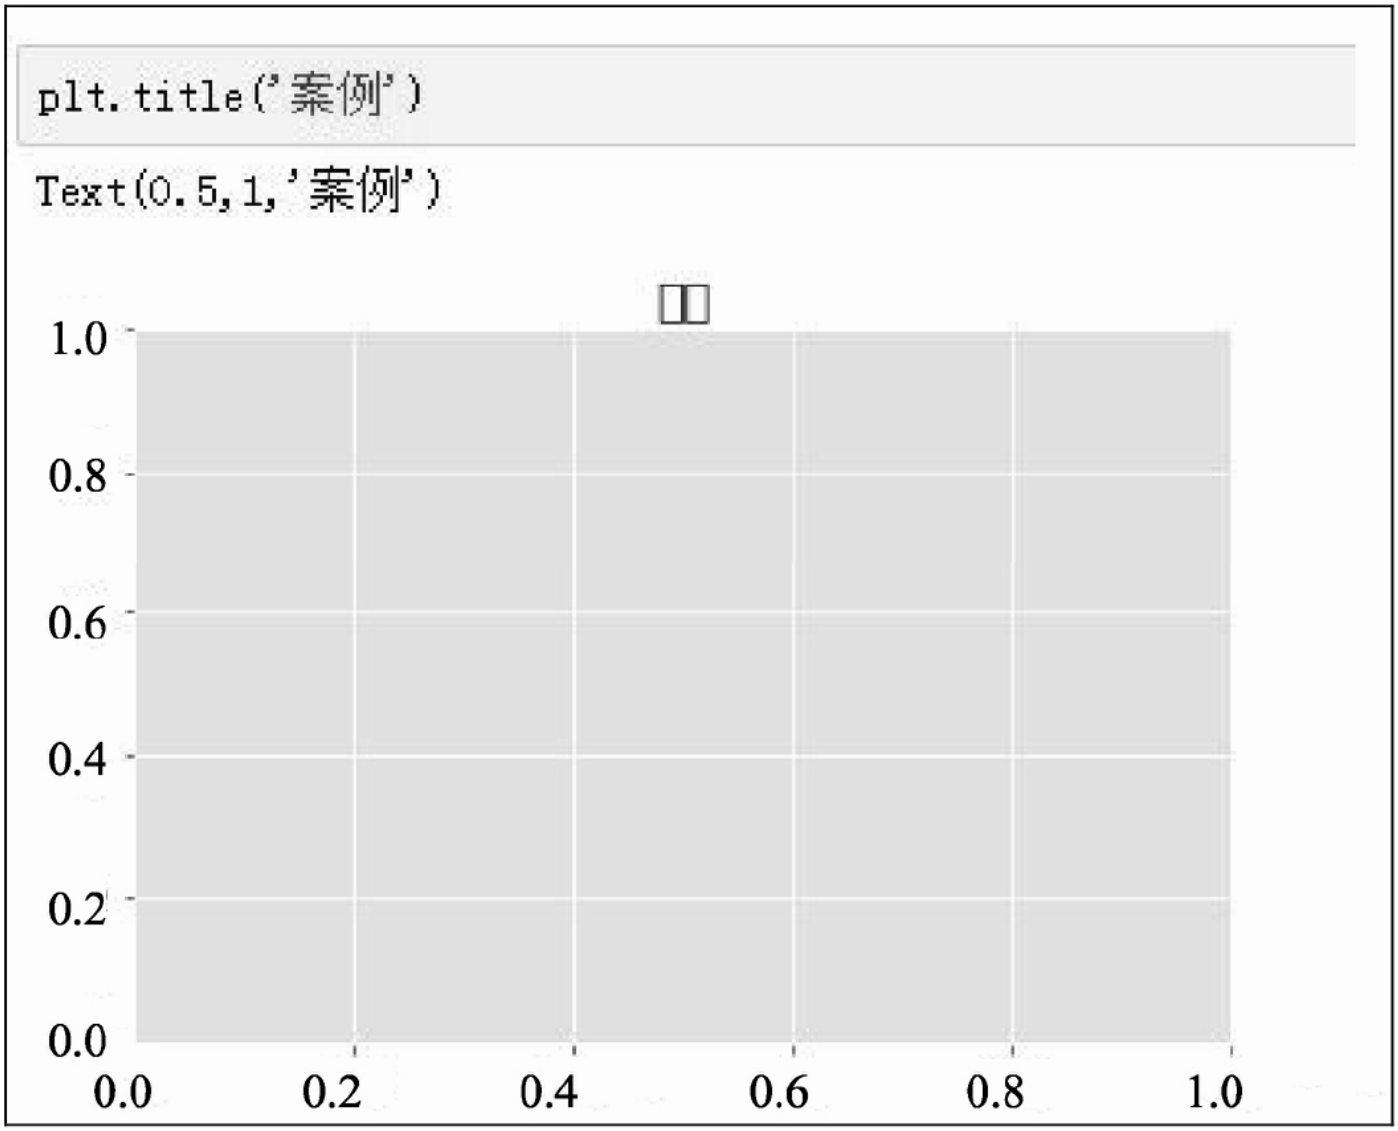

图7.30　中文乱码

注意：之前调用的样式会被保留。

因此需要指定matplotlib的默认字体，这样就可以解决中文乱码的问题，如图7.31所示。代码如下：

```
plt.rcParams['font.sans-serif'] = ['simhei']       #指定默认字体
plt.rcParams['axes.unicode_minus'] = False                                  #解决保存图像时负号'-'显示为方块的问题
plt.title('案例')
```

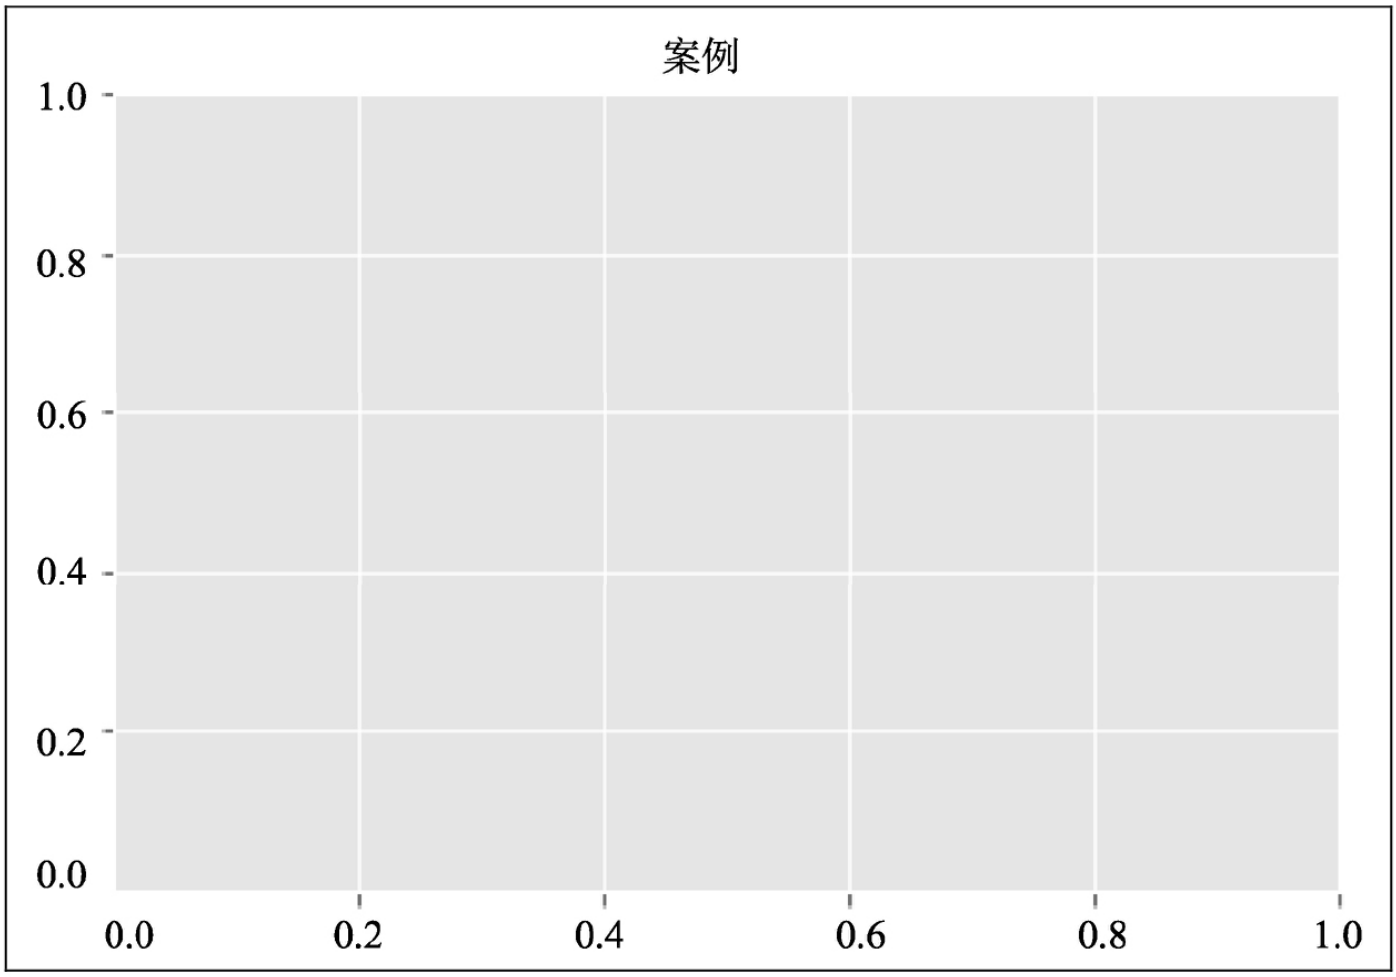

图7.31　修改默认字体

7.5　综合示例——星巴克店铺数据集

本节以kaggle官网中的星巴克店铺数据为例，利用pandas数据分析方法，通过matplotlib可视化的手段，分析星巴克店铺的分布情况。

7.5.1　数据来源

本例中使用的数据集可在kaggle网站上https://www.kaggle.com/starbucks/store-locations下载，如图7.32所示。

注意：下载数据前需注册kaggle账号。

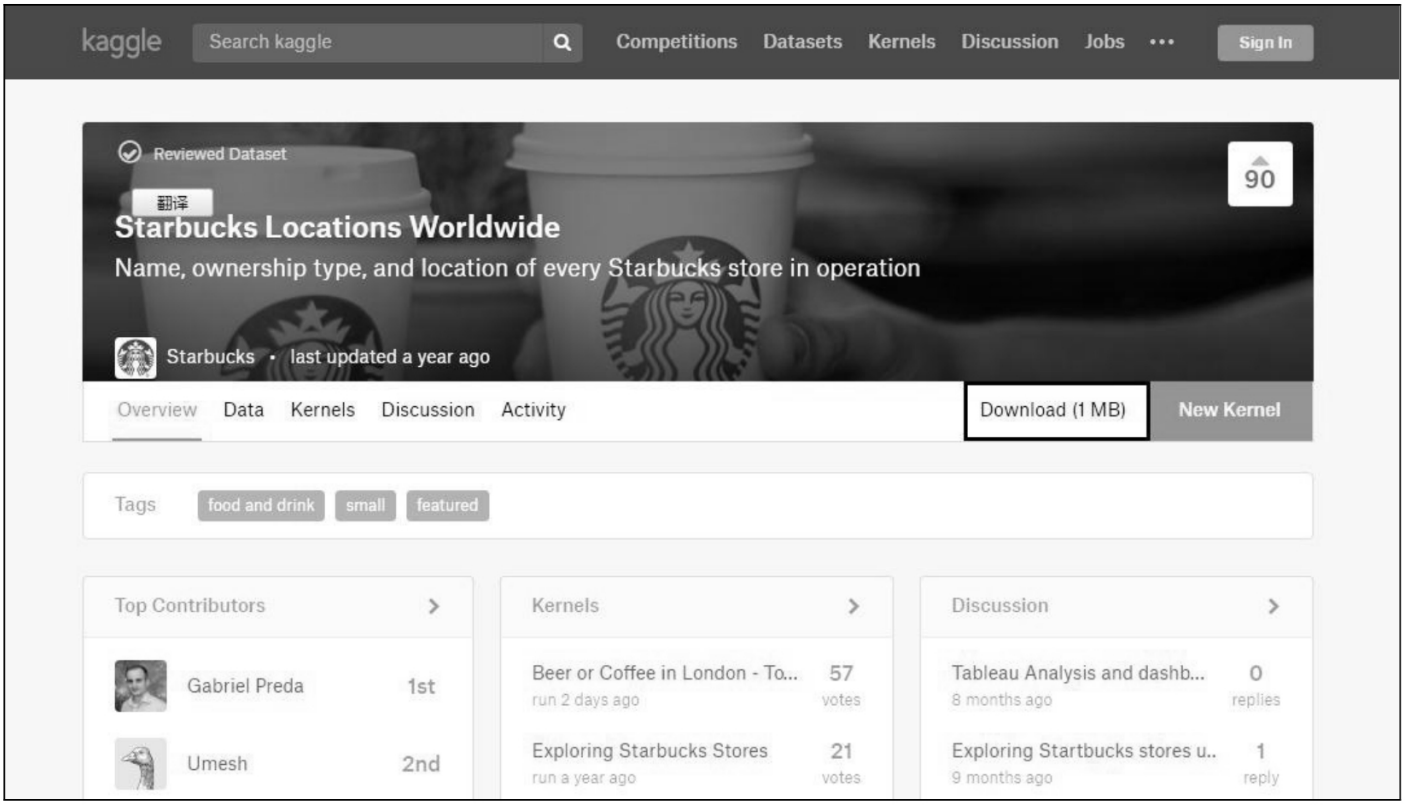

图7.32　数据下载

下载好的CSV文件可以通过pandas读取，如图7.33所示。

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
```

```
starbucks = pd.read_csv(open('H:\python数据分析\数据\directory.csv',encoding='utf-8'))
starbucks.head()
```

	Brand	Store Number	Store Name	Ownership Type	Street Address	City	State/Province	Country	Postcode	Phone Number	Timezone	Longitude	Latitude
0	Starbucks	47370-257954	Meritxell, 96	Licensed	Av. Meritxell, 96	Andorra la Vella	7	AD	AD500	376818720	GMT+1:00 Europe/Andorra	1.53	42.51
1	Starbucks	22331-212325	Ajman Drive Thru	Licensed	1 Street 69, Al Jarf	Ajman	AJ	AE	NaN	NaN	GMT+04:00 Asia/Dubai	55.47	25.42
2	Starbucks	47089-256771	Dana Mall	Licensed	Sheikh Khalifa Bin Zayed St.	Ajman	AJ	AE	NaN	NaN	GMT+04:00 Asia/Dubai	55.47	25.39
3	Starbucks	22126-218024	Twofour 54	Licensed	Al Salam Street	Abu Dhabi	AZ	AE	NaN	NaN	GMT+04:00 Asia/Dubai	54.38	24.48
4	Starbucks	17127-178586	Al Ain Tower	Licensed	Khaldiya Area, Abu Dhabi Island	Abu Dhabi	AZ	AE	NaN	NaN	GMT+04:00 Asia/Dubai	54.54	24.51

图7.33　星巴克店铺数据

以上数据为kaggle官网上公开的星巴克在全球的店铺数据。数据的介绍信息可通过kaggle官网进行查看，如图7.34所示。选择Data标签后，可查看前100行数据信息，以及字段的解释性信息。这里主要的字段有：City为店铺所在城市；State/Province为店铺所在的州和省份；Country为店铺所在国家。

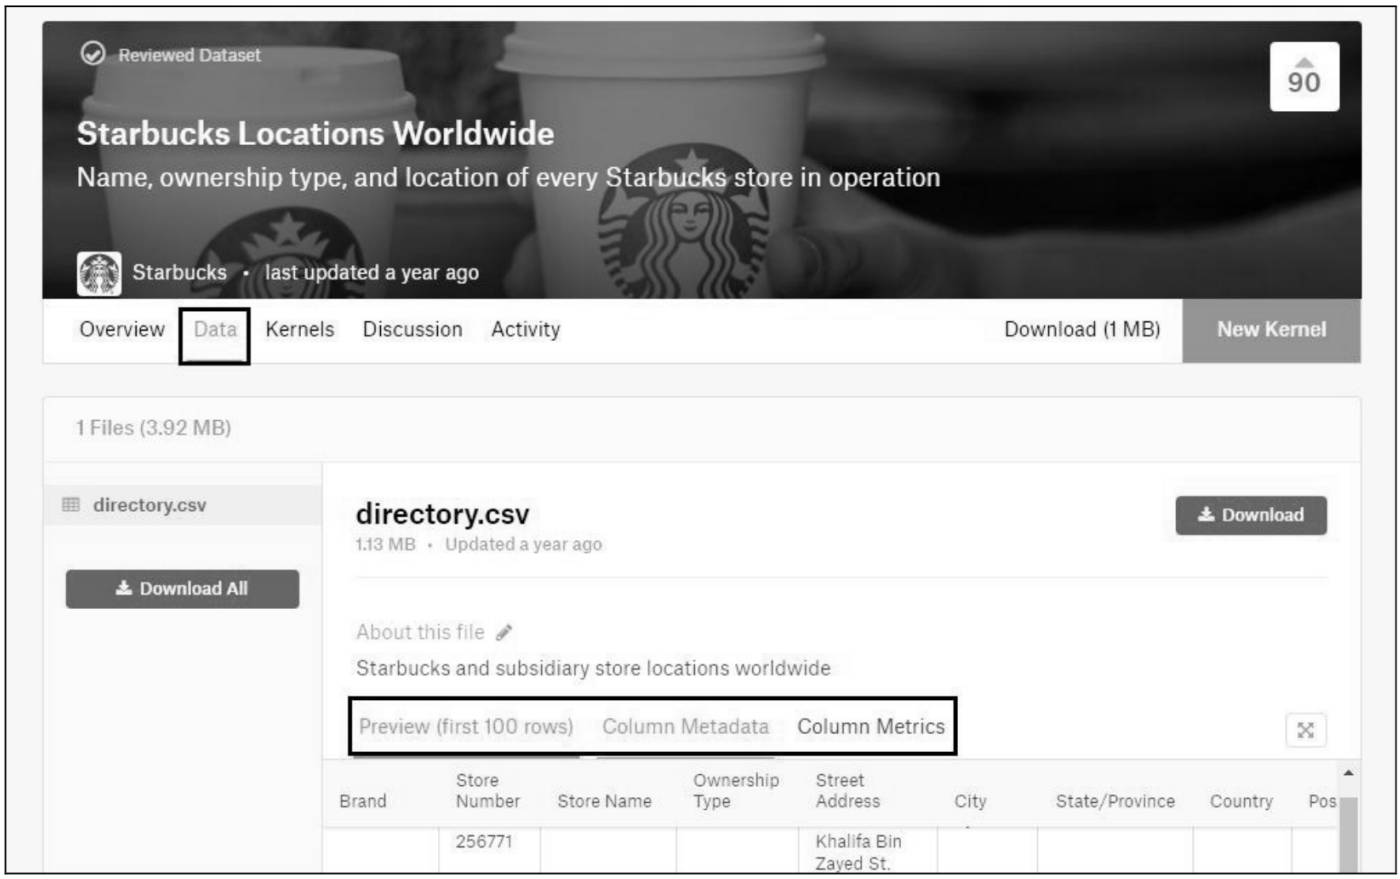

图7.34　星巴克店铺数据信息

7.5.2　定义问题

本次分析中，围绕星巴克店铺所在地提出几个问题：星巴克店铺在全球的分布情况；哪些国家星巴克店铺较多；哪些城市星巴克店铺较多；星巴克店铺在我国的分布情况。

7.5.3　数据清洗

针对City、State/Province和Country地区字段，查看是否有缺失值，如图7.35所示。

```
starbucks.isnull().sum()
```

```
Brand                0
Store Number         0
Store Name           0
Ownership Type       0
Street Address       2
City                15
State/Province       0
Country              0
Postcode          1522
Phone Number      6861
Timezone             0
Longitude            1
Latitude             1
dtype: int64
```

图7.35　查看缺失值1

可以看出，City列有15个缺失值，这里对这些缺失值进行查看。如图7.36所示，发现多为埃及（EG）国家，这里分析可能是没有统计到具体城市。为了样本的完整性，定义填充函数，用State/Province进行填充，如图7.37所示。

然后查看Brand字段的唯一值，发现店铺并不只有星巴克，还有一些其他的店面，但这里是分析星巴克店铺的信息，所以需要先“清洗”数据，然后将清洗好的数据进行存储，如图7.38所示。

```
starbucks[starbucks['City'].isnull()]
```

	Brand	Store Number	Store Name	Ownership Type	Street Address	City	State/Province	Country	Postcode	Phone Number	Timezone	Longitude	Latitude
5069	Starbucks	31657-104436	سان ستيفانو	Licensed	طريق الكورنيش أبراج سان ستيفانو	NaN	ALX	EG	NaN	20120800287	GMT+2:00 Africa/Cairo	29.96	31.24
5088	Starbucks	32152-109504	النايل سيتى	Licensed	كورنيش النيل أبراج النايل سيتى	NaN	C	EG	NaN	20120800307	GMT+2:00 Africa/Cairo	31.23	30.07
5089	Starbucks	32314-115172	أسكندرية الصحراوى	Licensed	الكيلو 28 طريق الاسكندرية الصحراوى, سيتى سنتر ...	NaN	C	EG	NaN	20185022214	GMT+2:00 Africa/Cairo	31.03	30.06
5090	Starbucks	31479-105246	مكرم عبيد	Licensed	شارع مكرم عبيد, سيتى ستارز مول	NaN	C	EG	NaN	20120800332	GMT+2:00 Africa/Cairo	31.34	30.09
5091	Starbucks	31756-107161	سيتى ستارز 1	Licensed	شارع عمر بن الخطاب, سيتى ستارز مول	NaN	C	EG	NaN	20120800350	GMT+2:00 Africa/Cairo	31.33	30.06
5092	Starbucks	1397-139244	سيتى ستارز 3	Licensed	شارع عمر بن الخطاب, كارفور المعادى	NaN	C	EG	NaN	20120029885	GMT+2:00 Africa/Cairo	31.33	30.06
5093	Starbucks	32191-116645	معادى سيتى سنتر	Licensed	القطامية الطريق الدائرى	NaN	C	EG	NaN	20185002677	GMT+2:00 Africa/Cairo	31.30	29.99

图7.36　查看缺失值2

```
def fill_na(x):
    return x
```

```
starbucks['City'] = starbucks['City'].fillna(fill_na(starbucks['State/Province']))
starbucks[starbucks['Country']=='EG']
```

	Brand	Store Number	Store Name	Ownership Type	Street Address	City	State/Province	Country	Postcode	Phone Number	Timezone	Longitude	Latitude
5069	Starbucks	31657-104436	سان ستيفانو	Licensed	طريق الكورنيش أبراج سان ستيفانو	ALX	ALX	EG	NaN	20120800287	GMT+2:00 Africa/Cairo	29.96	31.24
5070	Starbucks	15433-161464	Cityscape	Licensed	6 Of Octobe, El Horya Square, Giza	Cairo	C	EG	NaN	NaN	GMT+2:00 Africa/Cairo	31.35	30.13
5071	Starbucks	25827-242606	The Corner	Licensed	Zaker Hussein St. extension, Plot no. 4, Unit ...	Cairo	C	EG	NaN	NaN	GMT+2:00 Africa/Cairo	31.25	30.05
5072	Starbucks	26054-236446	The Hub	Licensed	Unit no :A1 Front of British School, 6 of oct/...	Cairo	C	EG	NaN	NaN	GMT+2:00 Africa/Cairo	31.27	30.01

图7.37　填充缺失值

```
starbucks['Brand'].unique()
```

```
array(['Starbucks', 'Teavana', 'Evolution Fresh', 'Coffee House Holdings'], dtype=object)
```

```
new_data = starbucks[starbucks['Brand'] == 'Starbucks']
```

```
new_data['Brand'].unique()
```

```
array(['Starbucks'], dtype=object)
```

```
new_data.to_csv('H:\python数据分析\数据\starbucks.csv',index=False,encoding='utf-8')
```

图7.38　过滤数据

7.5.4　数据探索

通过简单统计可以看出，星巴克店铺共有25247家分店，分布在72个国家或地区、5405个城市，如图7.39所示。

对Country字段进行计数，筛选出店铺数量排名前10位的国家，如图7.40所示。从图中可知，美国位居榜首，中国次之。

```
starbucks.shape
```

```
(25247, 13)
```

```
len(starbucks['Country'].unique())
```

```
72
```

```
len(starbucks['City'].unique())
```

```
5405
```

图7.39　店铺基本情况

```
country_count = starbucks['Country'].value_counts()[0:10]
country_count
```

```
US    13311
CN     2734
CA     1415
JP     1237
KR      993
GB      901
MX      579
TR      326
PH      298
TH      289
Name: Country, dtype: int64
```

图7.40　星巴克分布国家Top10

通过下面的代码绘制柱状图，结果如图7.41所示。

```
plt.style.use('ggplot')                                    #设置图表样式
labels = list(country_count.index)                         #刻度标签
plt.xlabel('Country')                                          #设置X轴标签
plt.ylabel('Count')                                        #设置Y轴标签
plt.title('Country Top 10')
```

```
plt.bar(range(len(labels)),country_count)
plt.xticks(range(len(labels)),labels,fontsize=12)                    #设置刻度和刻度标签
```

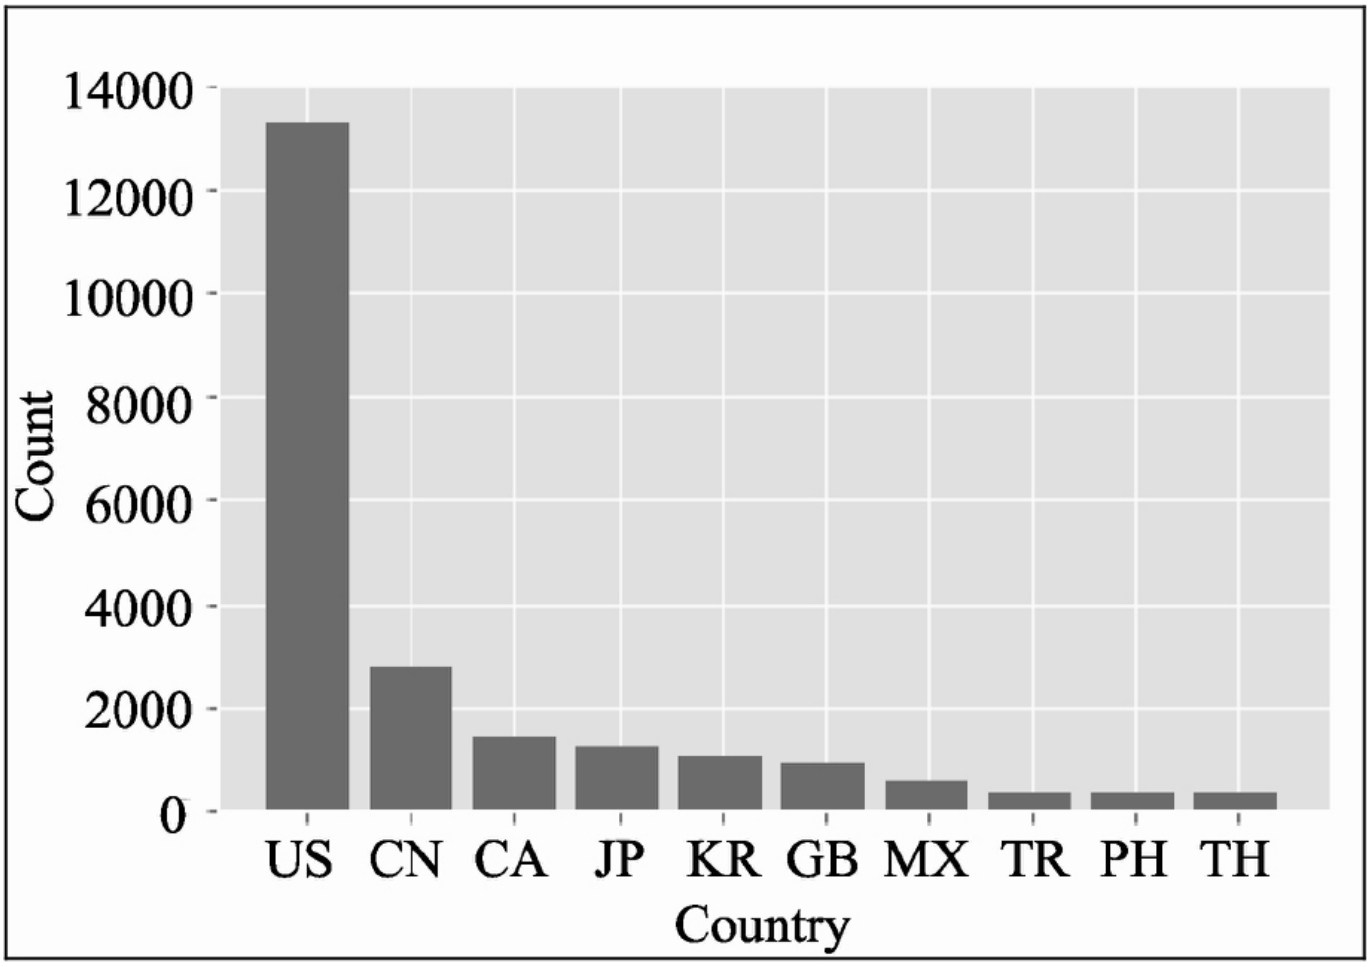

图7.41　星巴克分布国家Top10柱状图

对City字段进行计数，筛选出店铺数量前10位的城市，如图7.42所示。上海市作为国际化大都市，星巴克店铺数量最多，多于排名第2的城市将近300家，而西雅图作为星巴克的总部城市，排于第10名。

```
city_count = starbucks['City'].value_counts()[0:10]
city_count
```

```
上海市            542
Seoul           243
北京市             234
New York        230
London          215
Toronto         186
Mexico City     180
Chicago         179
Las Vegas       153
Seattle         151
Name: City, dtype: int64
```

图7.42　星巴克分布城市Top10

说明：图中的Mexico City指墨西哥的一些城市分布，数据集中将其算在一起了。

通过下面的代码绘制柱状图，如图7.43所示。

```
plt.figure(figsize=(10,6))                                    #设置图片大小
plt.rcParams['font.sans-serif'] = ['simhei']                  #指定默认字体
plt.rcParams['axes.unicode_minus'] = False
labels = list(city_count.index)                               #刻度标签
plt.xlabel('City')                                              #设置x轴标签
plt.ylabel('Count')                                             #设置y轴标签
plt.title('City Top 10')
plt.bar(range(len(labels)),city_count)
plt.xticks(range(len(labels)),labels) #设置刻度和刻度标签
```

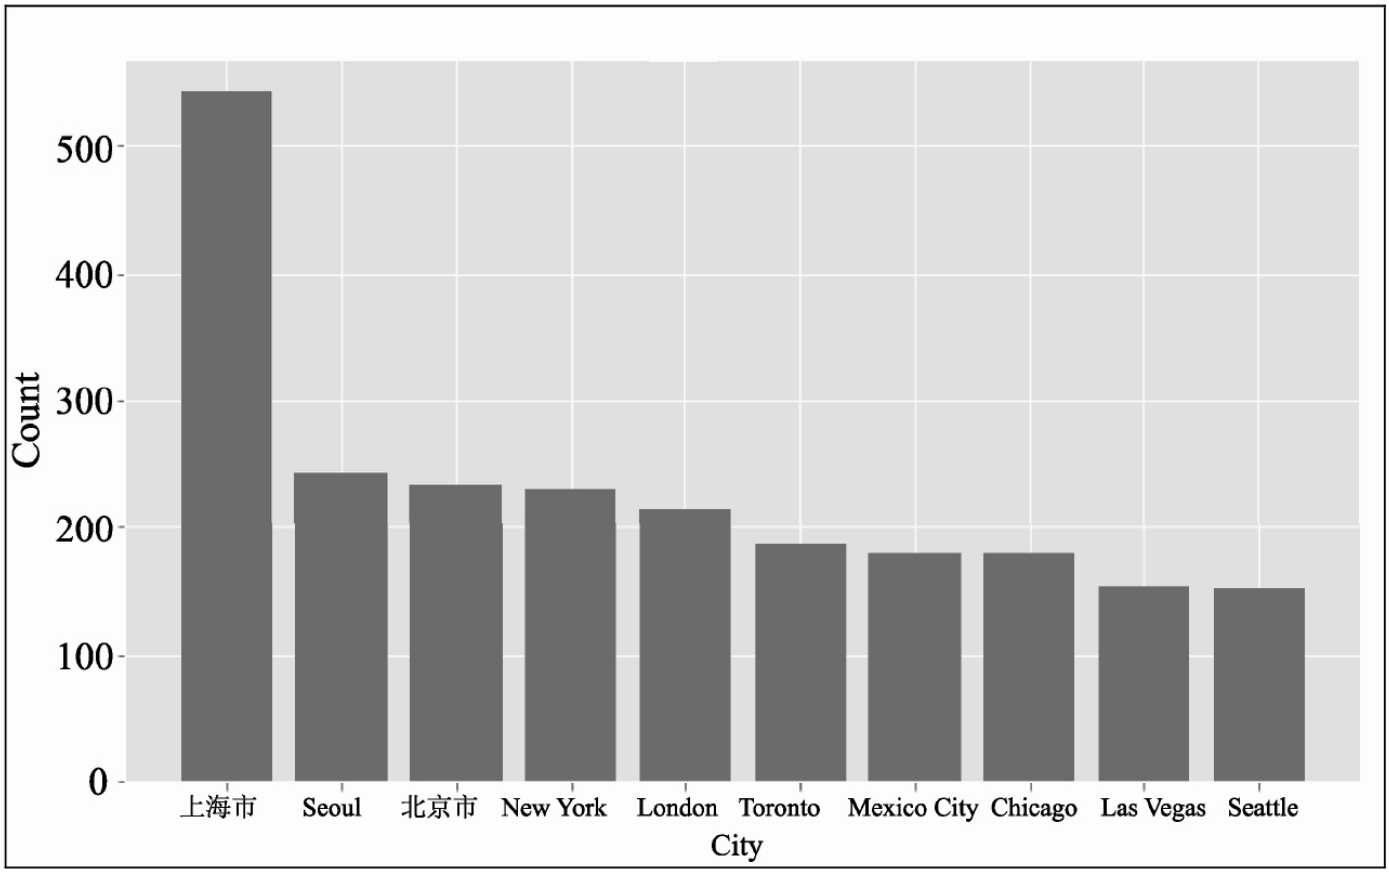

图7.43　星巴克分布城市Top10柱状图

为了分析星巴克店铺在我国的分布情况，提取其中国的店铺数据进行单独存储，如图7.44所示。

```
china_data = starbucks[starbucks['Country'] == 'CN']
china_data.head()
```

	Brand	Store Number	Store Name	Ownership Type	Street Address	City	State/Province	Country
2036	Starbucks	22901-225145	北京西站第一咖啡店	Company Owned	丰台区, 北京西站通廊7-1号, 中关村南大街2号	北京市	11	CN
2037	Starbucks	32320-116537	北京华宇时尚店	Company Owned	海淀区, 数码大厦B座华宇时尚购物中心内, 蓝色港湾国际商区1座C1-3单元首层、	北京市	11	CN
2038	Starbucks	32447-132306	北京蓝色港湾圣拉娜店	Company Owned	朝阳区朝阳公园路6号, 二层C1-3单元及二层阳台, 太阳宫中路12号	北京市	11	CN
2039	Starbucks	17477-161286	北京太阳宫凯德嘉茂店	Company Owned	朝阳区, 太阳宫凯德嘉茂一层01-44/45号, 东三环北路27号	北京市	11	CN
2040	Starbucks	24520-237564	北京东三环北店	Company Owned	朝阳区, 嘉铭中心大厦A座B1层024商铺, 金融大街7号	北京市	11	CN

```
china_data.to_csv('H:\python数据分析\数据\cn_starbucks.csv',index=False,encoding='utf-8')
```

图7.44　星巴克中国分布信息

对City字段进行计数，筛选出星巴克中国店铺数量前10位的城市，如图7.45所示。星巴克作为“小资”的标志，所以选址间接地反映了当地的经济实力。在中国，北（京）、上（海）、广（州）、深（圳）城市的店铺排名都是靠前的，这与当地的经济实力有密切的关系。

```
city_count = cn_starbucks['City'].value_counts()[0:10]
city_count
```

```
上海市          542
北京市          234
杭州市          117
深圳市          113
广州市          106
香港特别行政区    104
成都市           98
苏州市           90
南京市           73
武汉市           67
Name: City, dtype: int64
```

图7.45　星巴克中国分布城市Top10

通过下面的代码绘制柱状图，如图7.46所示。

```
plt.rcParams['font.sans-serif'] = ['simhei']                    #指定默认字体
plt.rcParams['axes.unicode_minus'] = False
labels = list(city_count.index)                                 #刻度标签
plt.xlabel('City')                                                          #设置X轴标签
plt.ylabel('Count')                                                         #设置Y轴标签
plt.title('星巴克各城市分布')
plt.barh(range(len(labels)),city_count)
plt.yticks(range(len(labels)),labels)                           #设置刻度和刻度标签
```

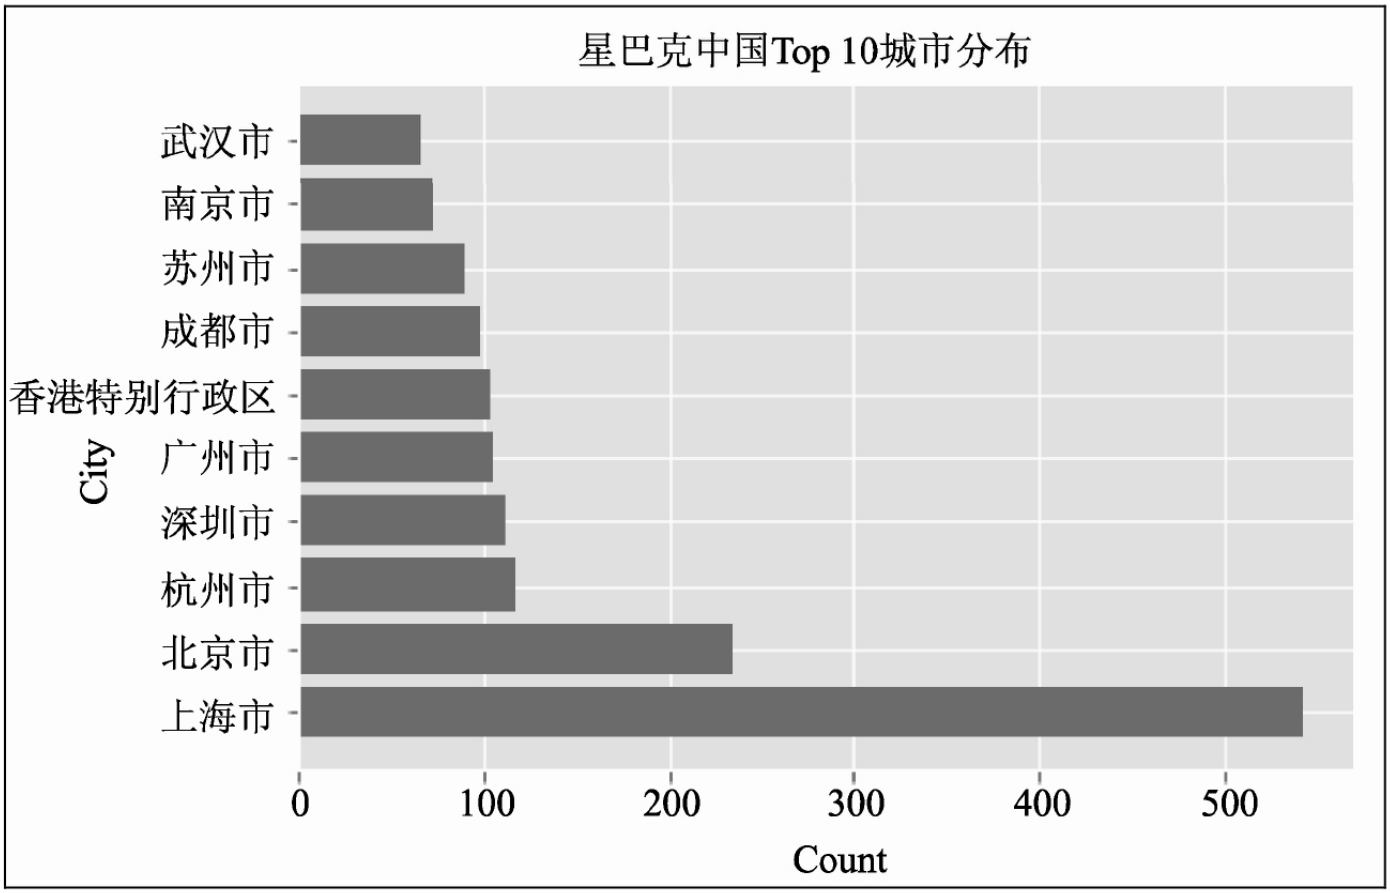

图7.46　星巴克中国分布城市Top10柱状图

第8章　seaborn可视化

seaborn其实是在matplotlib的基础上进行了更高级的API封装，从而使绘图更容易、更美观。本章首先讲解如何使用seaborn样式和分布图，并介绍如何使用seaborn绘制分类图；然后介绍回归图的绘制和网格技术；最后通过一个综合示例，巩固seaborn的可视化方法和技巧。

下面给出本章涉及的知识点与学习目标。

· 样式与分布图：学会seaborn的样式和分布图的绘制方法。

· 分类图：学会利用seaborn绘制分类图。

· 回归图与网格：学会绘制回归图和网格技术。

8.1　样式与分布图

本节主要介绍seaborn中设定好的5种主题样式，并介绍怎样自定义样式，讲解如何通过seaborn绘制分布图。

8.1.1　seaborn样式

seaborn中有预先设计好的5种主题样式：darkgrid、dark、whitegrid、white和ticks，默认使用darkgrid主题样式。首先使用matplotlib库进行绘图，如图8.1所示为matplotlib默认的样式。

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline
#导入对应的库

years = [1950, 1960, 1970, 1980, 1990, 2000, 2010]
gdp = [300.2, 543.3, 1075.9, 2862.5, 5979.6, 10289.7, 14958.3]
```

```
#定义数据
plt.scatter(years, gdp)
#绘图
```

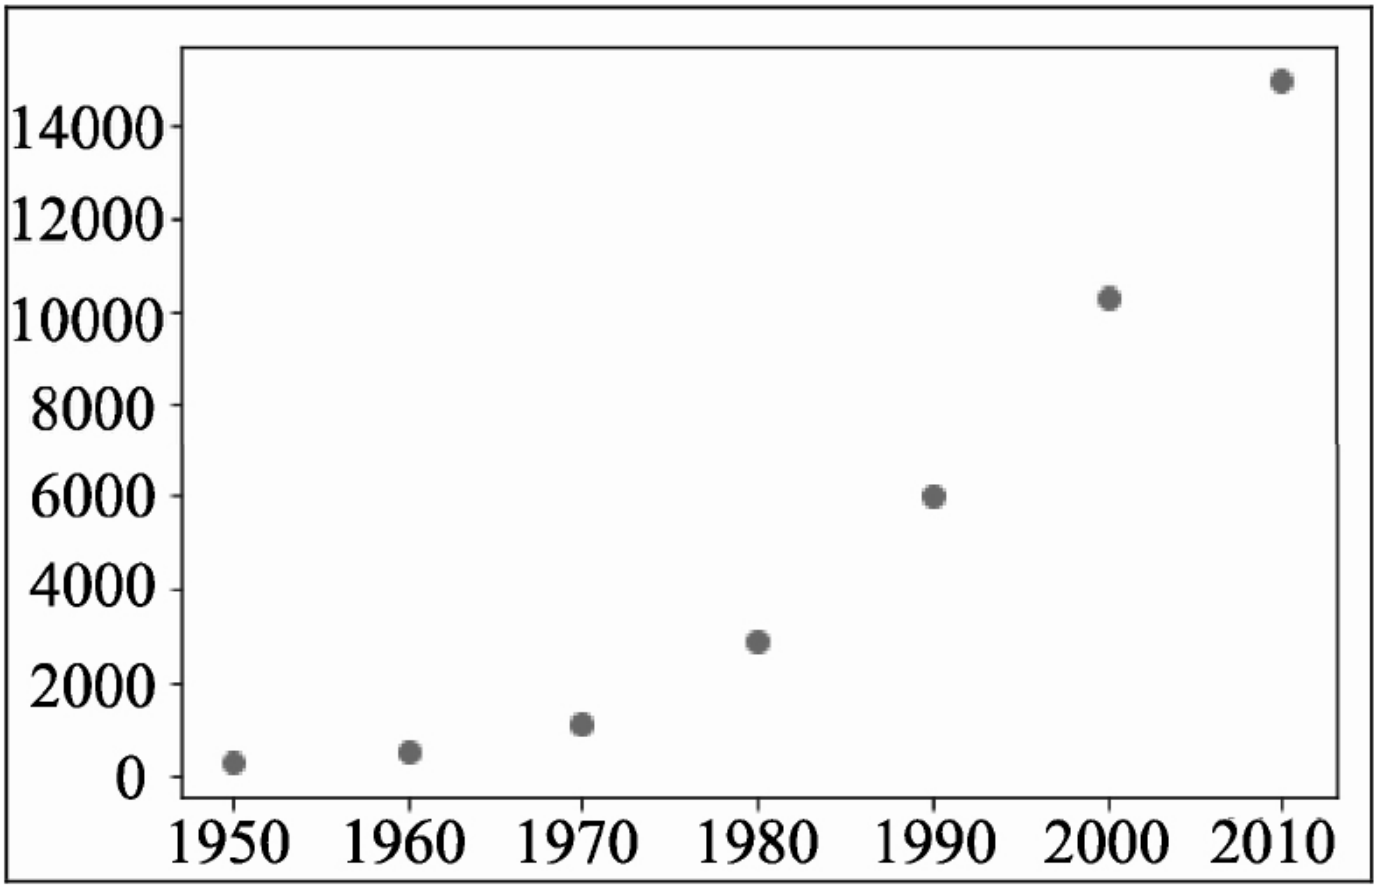

图8.1　matplotlib默认样式

通过set_style方法可以进行主题样式的设置，这里使用darkgrid主题，与matplotlib的默认样式进行对比。如图8.2所示，可以看出图中增加了灰白色的背景和网格线。

```
sns.set_style("darkgrid")
plt.scatter(years, gdp)
```

而使用dark主题就不会有网格线，如图8.3所示。

```
sns.set_style("dark")
plt.scatter(years, gdp)
```

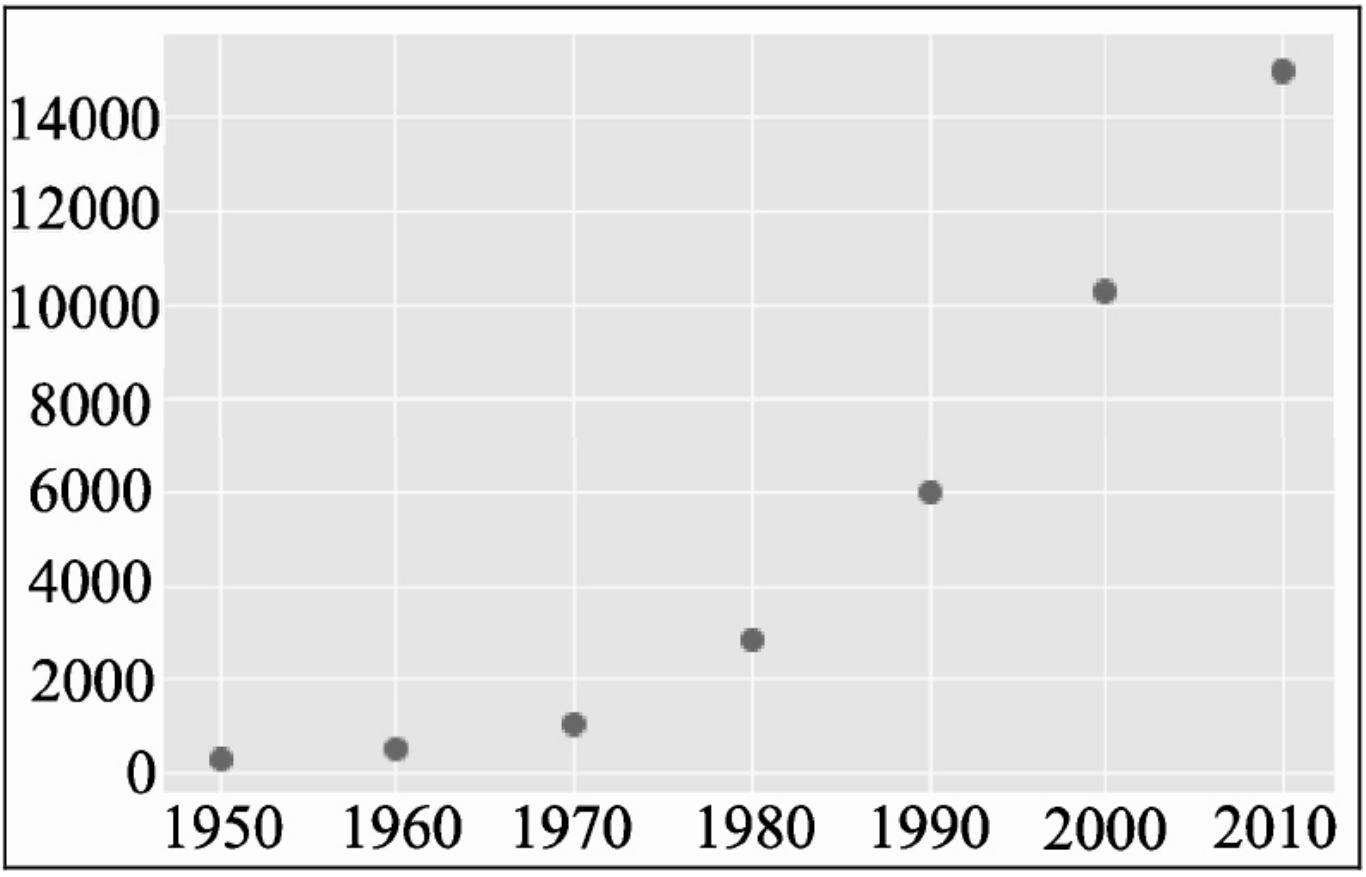

图8.2　darkgrid主题

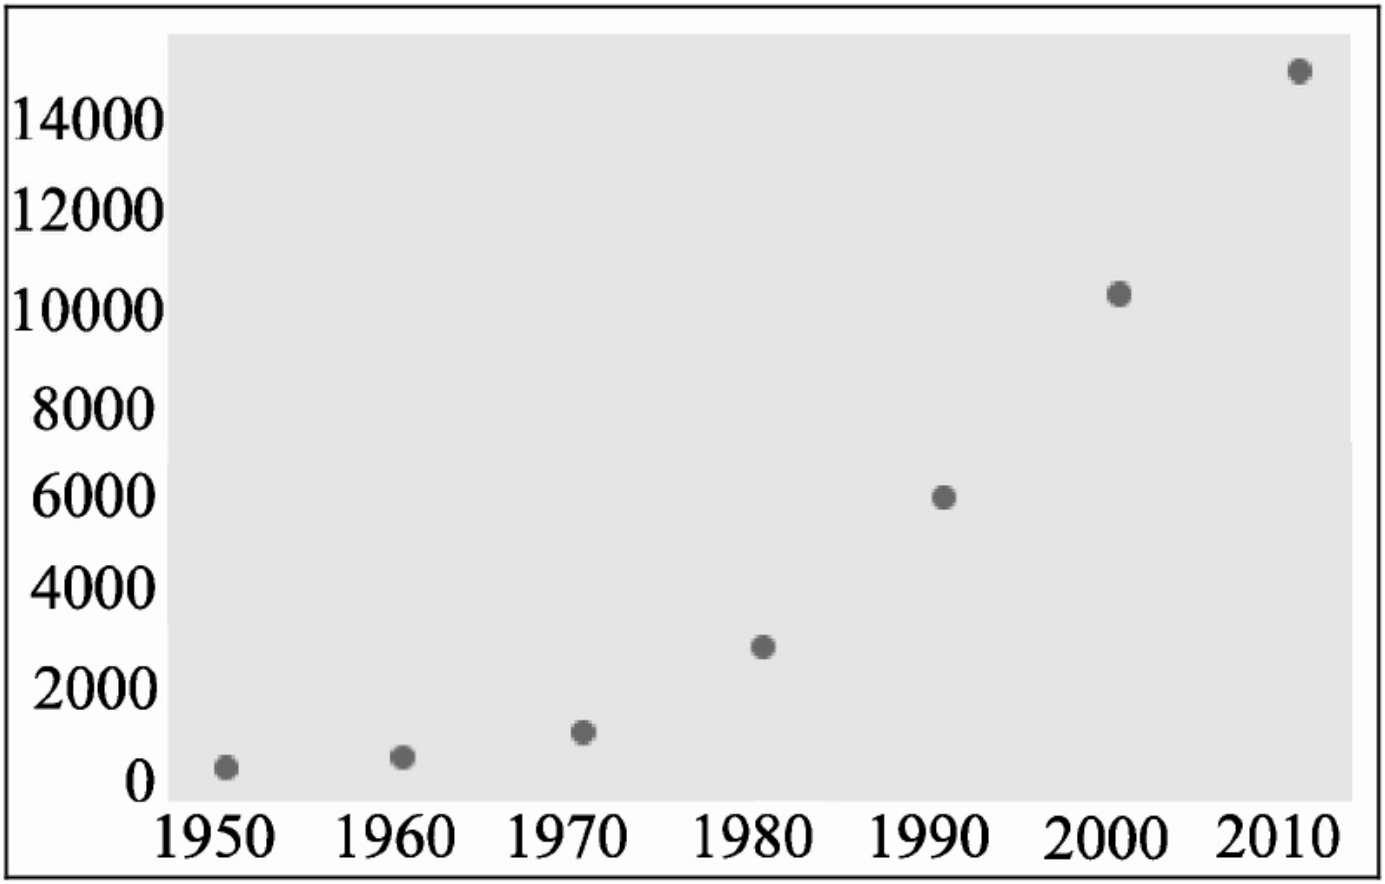

图8.3　dark主题

注意：其余样式读者可以自行测试。

在seaborn中，set方法更为常用，因为其可以同时设置主题、调色板等多个样式。style参数为主题设置；palette参数用于设置调色板，当设置不同的调色板时，使用的图表颜色也不同；color_codes参数设置颜色代码，设置过后，可以使用r、g来设置颜色，如图8.4所示。

```
sns.set(style="white", palette="muted", color_codes=True)
```

```
plt.plot(np.arange(10))
#style为主题
#palette为调色板
# color_codes为颜色代码
```

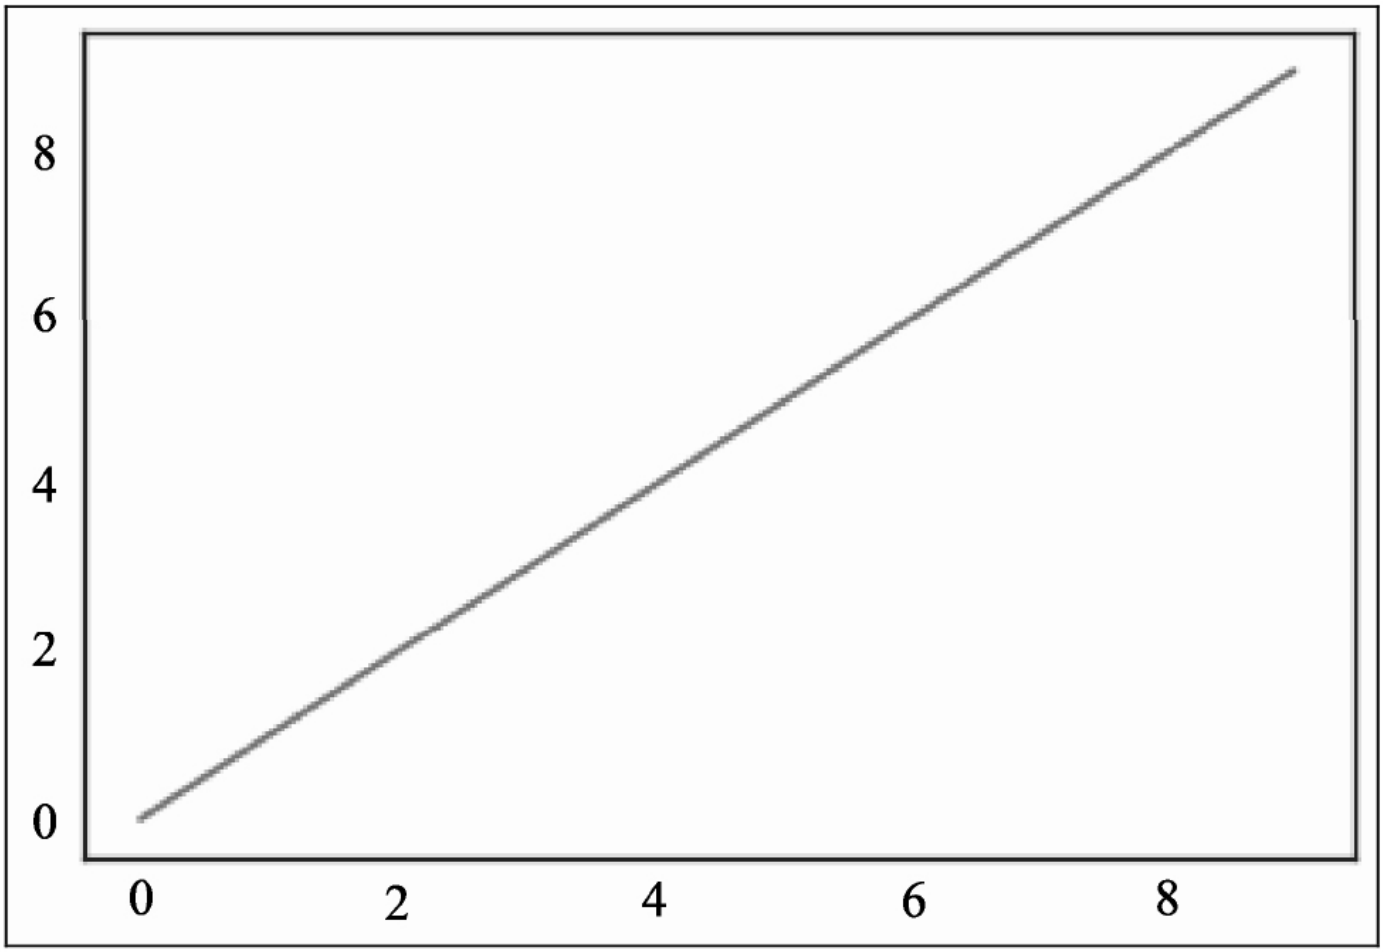

图8.4　通过set方法绘制

8.1.2　坐标轴移除

在seaborn主题中，white和ticks主题都会存在4个坐标轴。在matplotlib中是无法去掉多余的顶部和右侧坐标轴的，而在seaborn中却可以使用despine方法轻松地去除，如图8.5所示。

```
sns.set(style="white", palette="muted", color_codes=True)
plt.plot(np.arange(10))
sns.despine()
```

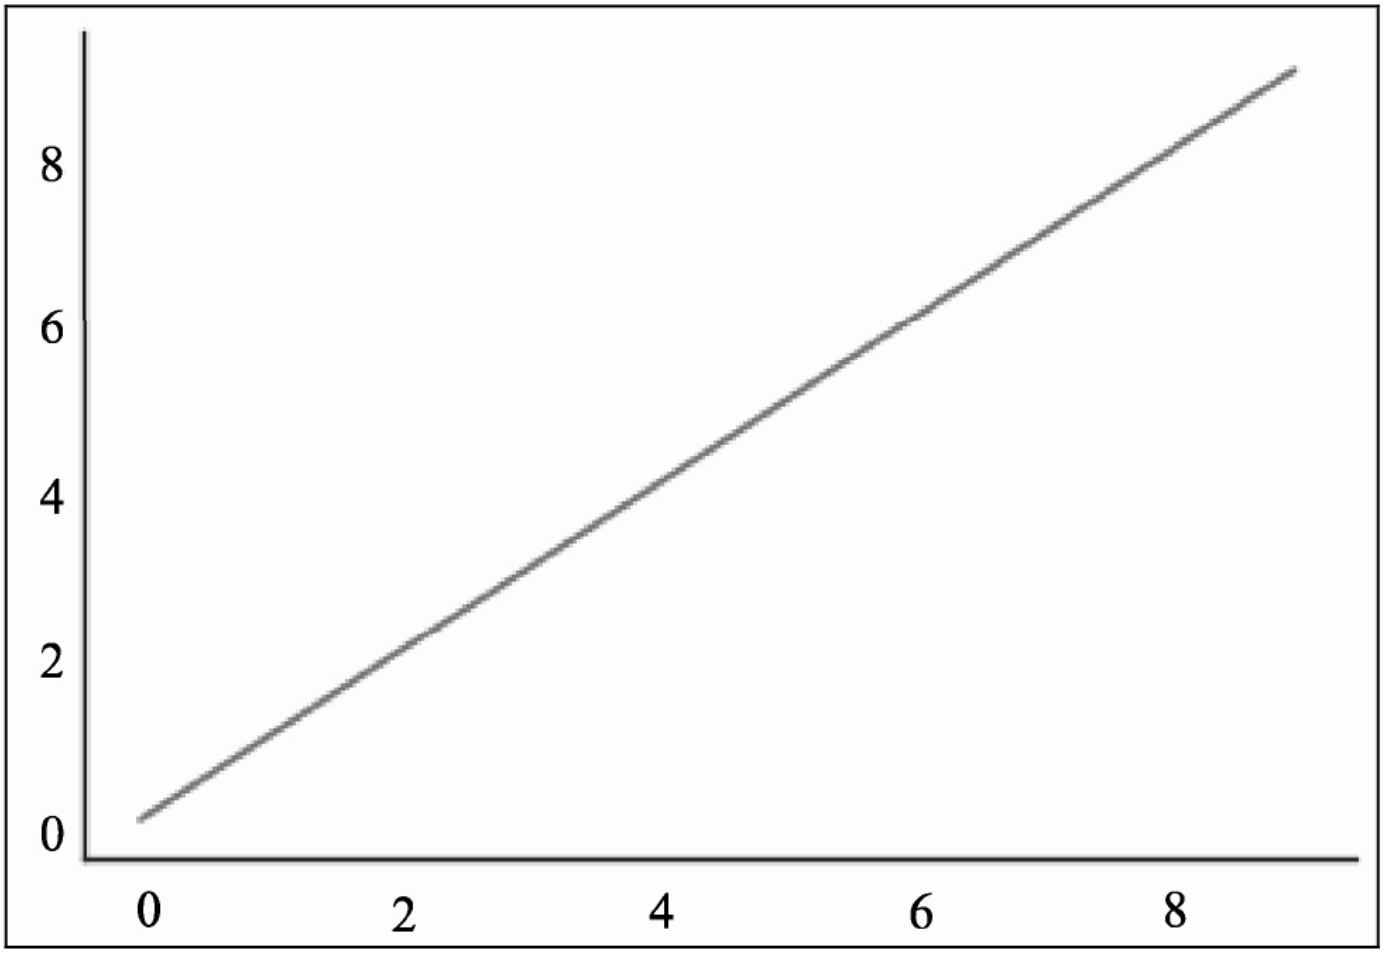

图8.5　通过despine方法绘制1

使用despine方法可以对坐标轴进行更有趣的变化，设置offset参数可以偏移坐标轴，trim参数可修剪刻度，如图8.6所示。

```
sns.set(style="white", palette="muted", color_codes=True)
plt.plot(np.arange(10))
sns.despine(offset=10, trim=True)
```

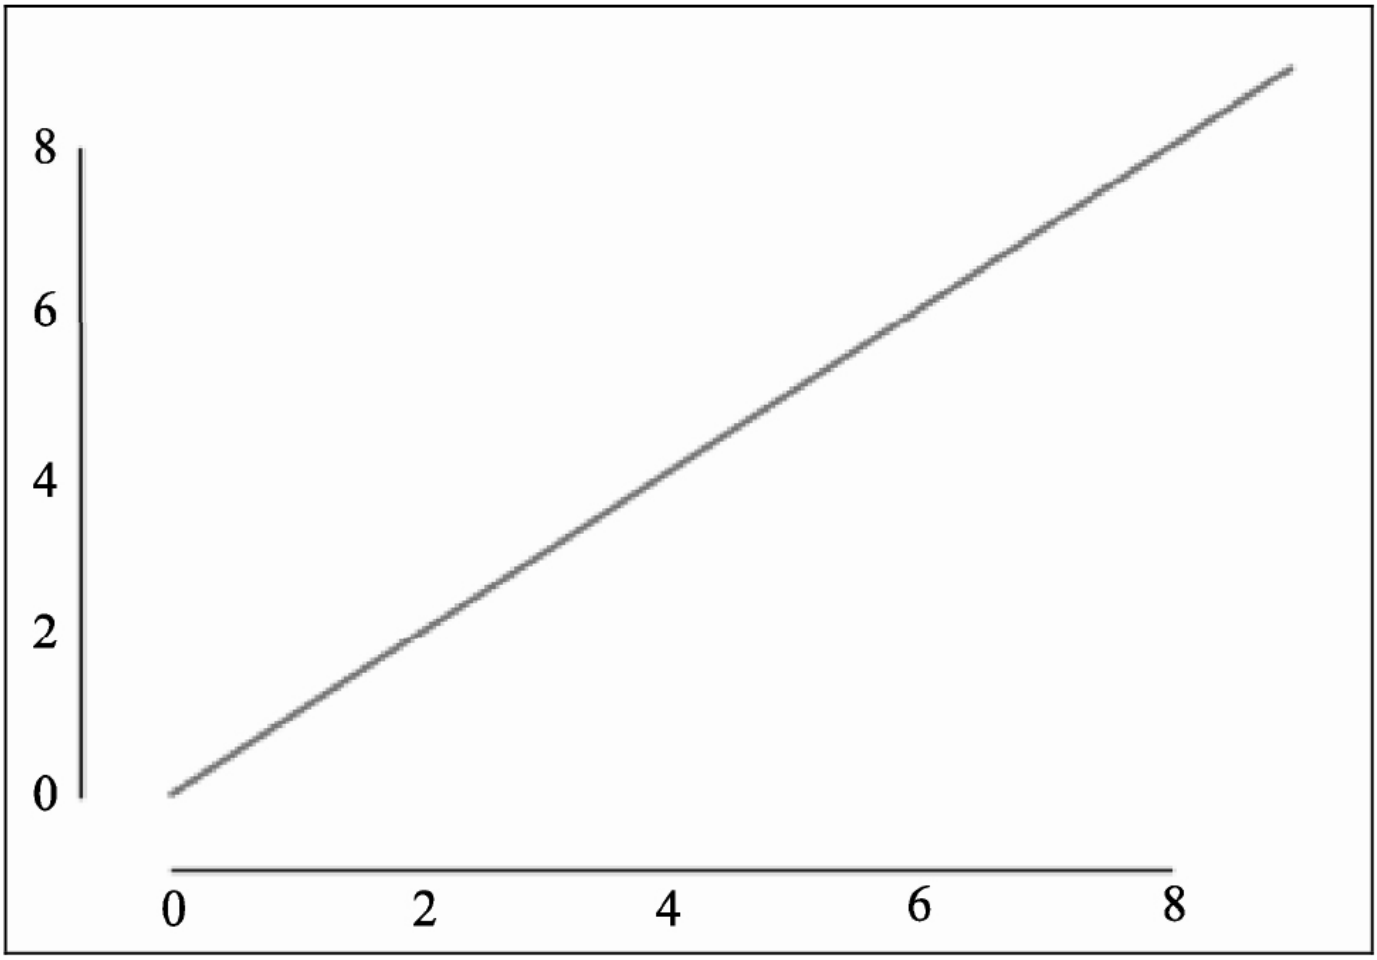

图8.6　通过despine方法绘制2

当然也可以指定移除哪些坐标轴，如图8.7所示。

```
sns.set(style="whitegrid", palette="muted", color_codes=True)
plt.plot(np.arange(10))
sns.despine(left=True, bottom=True)
```

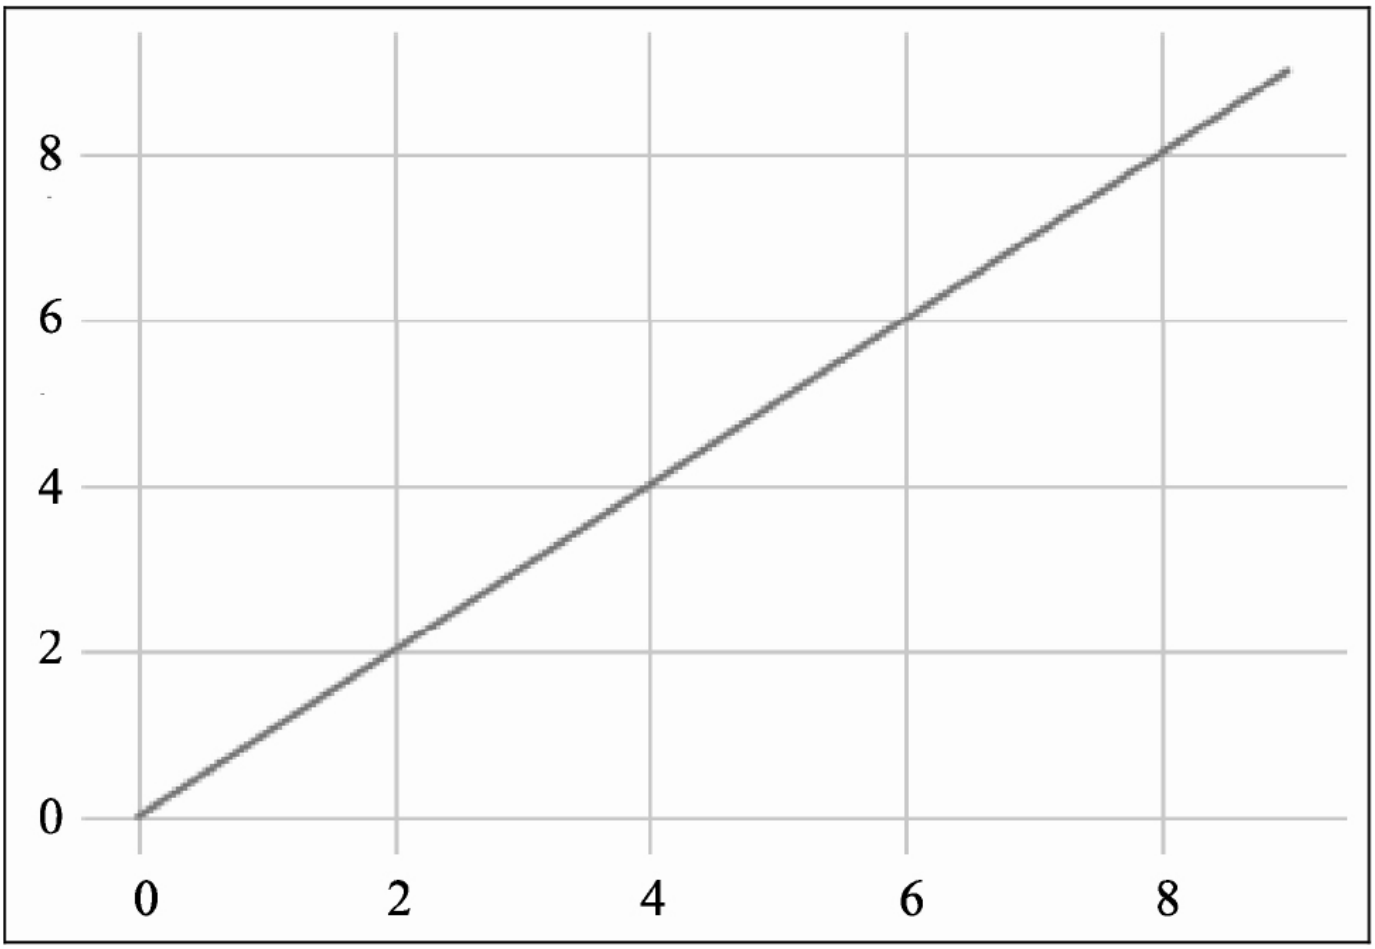

图8.7　通过despine方法绘制3

8.1.3　单变量分布图

在接下来的seaborn可视化中，使用seaborn中自带的小费数据集，首先将其读入DataFrame中，如图8.8所示。

```
tips=sns.load_dataset('tips')
tips.head()
```

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

图8.8　小费数据集

说明：小费数据集中，total_bill为消费总金额；tip为小费；sex为顾客性别；smoker为顾客是否抽烟；day为消费的星期；time为聚餐的时间段；size为聚餐人数。

对于单变量分布图的绘制，在seaborn中使用distplot函数。默认情况下会绘制一个直方图，并嵌套一个与之对应的密度图。这里绘制total_bill的分布图，如图8.9所示。

```
sns.set(color_codes=True)
sns.distplot(tips['total_bill'])
```

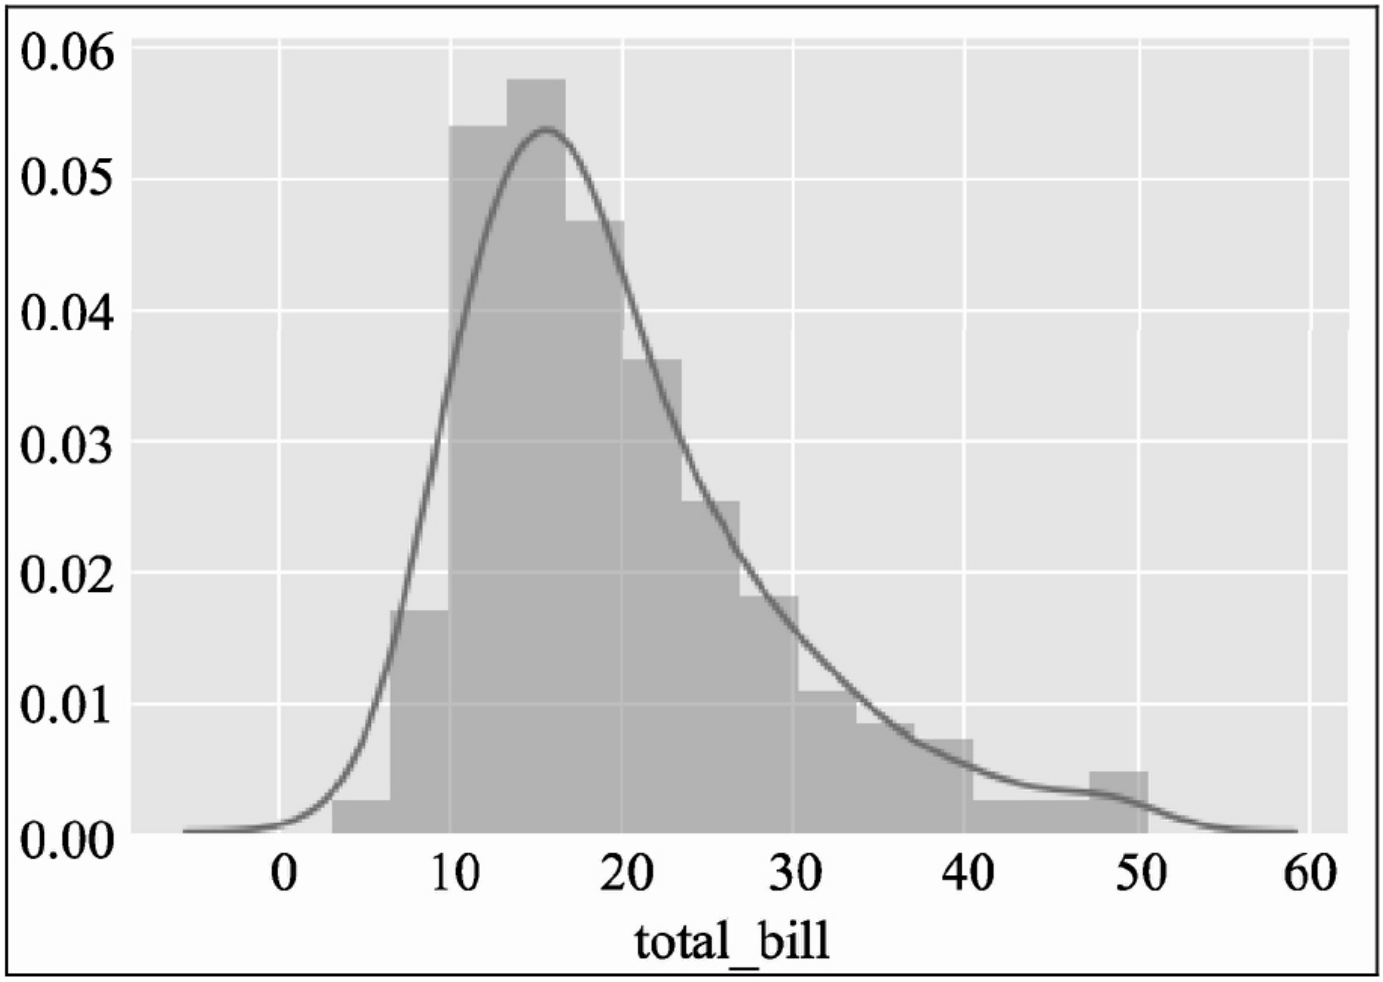

图8.9　通过distplot方法绘制1

利用distplot方法绘制的直方图与matplotlib是类似的。在ditplot的参数中，可以选择不绘制密度图。这里使用rug参数绘制毛毯图，其可以为每个观测值绘制小细线（边际毛毯），也可以单独用rugplot进行绘制，如图8.10所示。

```
sns.distplot(tips['total_bill'], kde=False, rug=True)
#不绘制kde，绘制rug
```

在matplotlib中，可以通过bins参数来设置分段。在distplot方法中也是同样的设置方法，如图8.11所示。

```
sns.distplot(tips['total_bill'],bins=30, kde=False, rug=True)
```

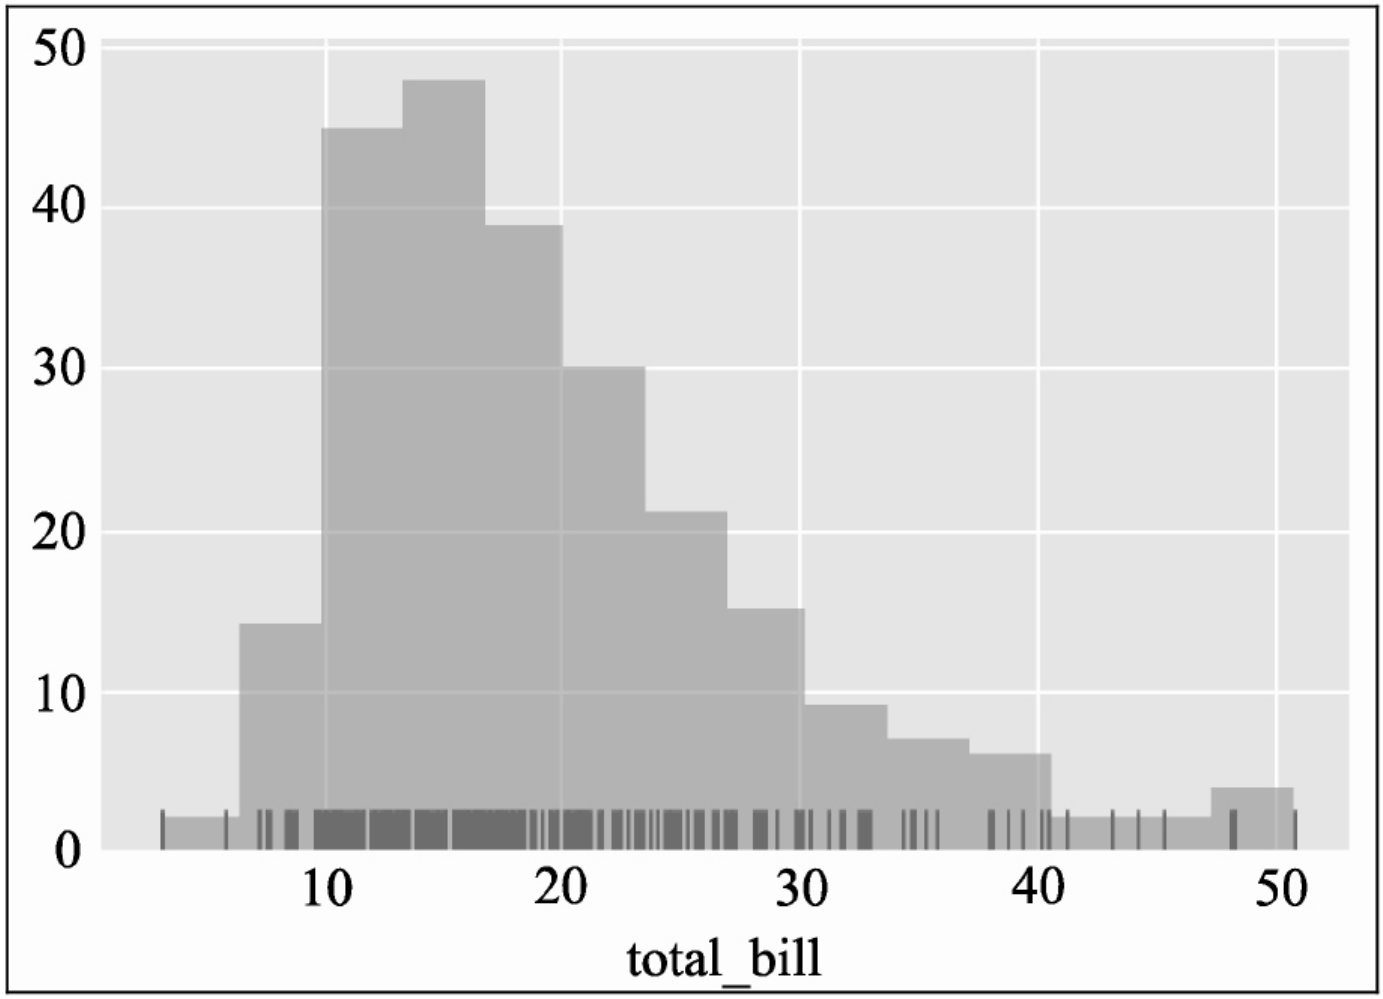

图8.10　通过distplot方法绘制2

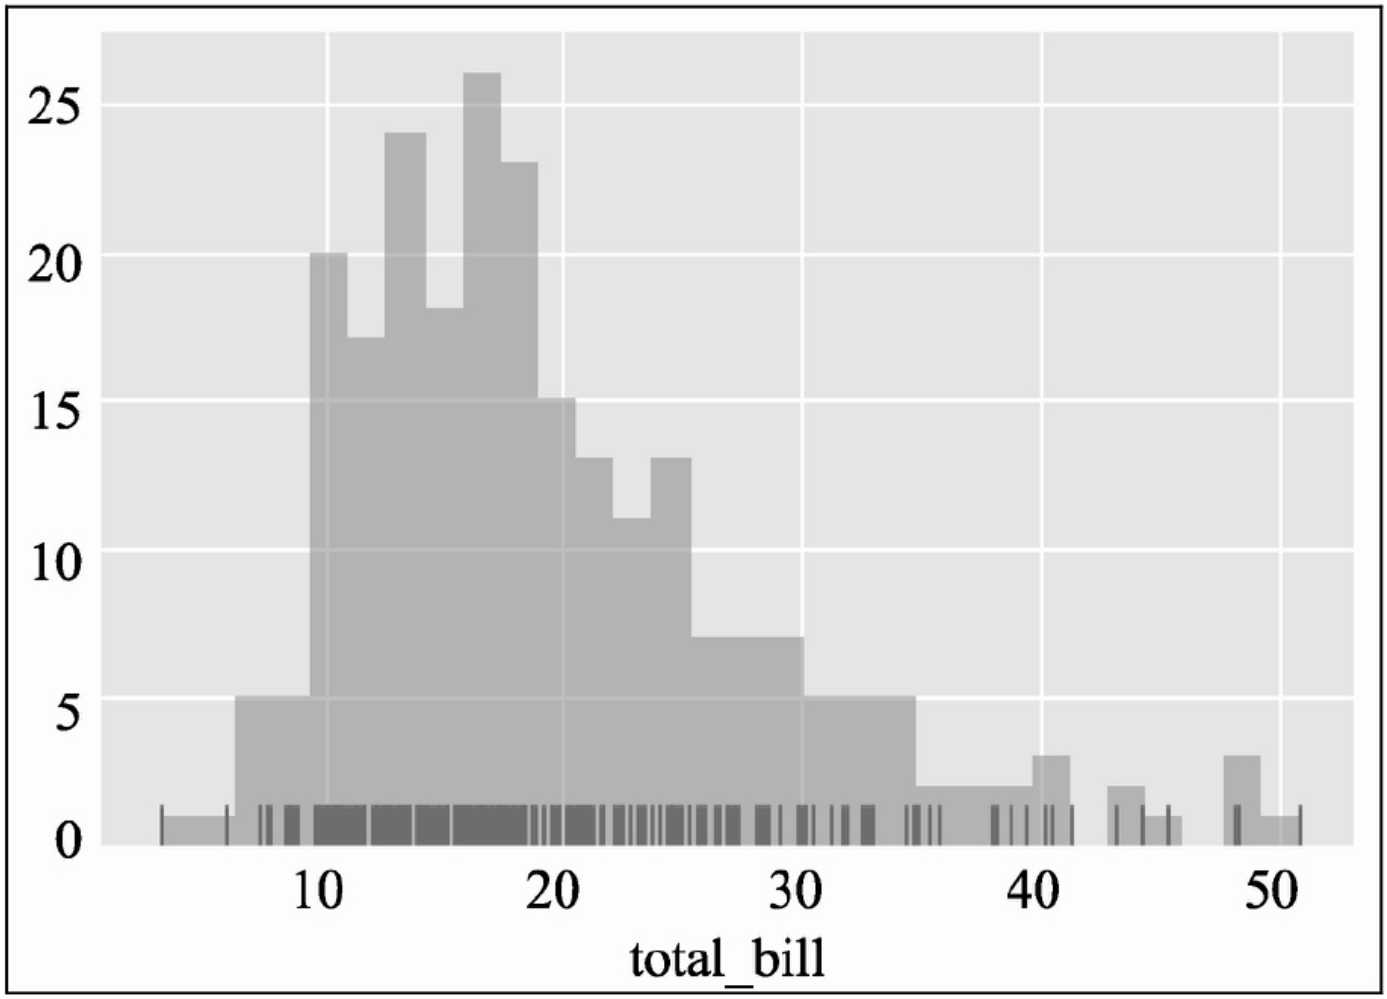

图8.11　通过distplot方法绘制3

如果设置hist为False，就可以去掉直方图而绘制密度图，如图8.12所示。

```
sns.distplot(tips['total_bill'], hist=False, rug=True)
```

通过distplot函数可以同时绘制直方图、密度图和毛毯图，但这些分布图都有对应的具体绘图函数。其中，kdeplot函数可以绘制密度图，rugplot函数用于绘制毛毯图。下面通过matplotlib的subplots函数创建两个子图，然后分别用distplot函数绘制对应的分布图表，如图8.13所示。

```
fig, axes = plt.subplots(1,2,figsize=(10, 5))              #设置子图和图表大小
sns.distplot(tips['total_bill'], ax = axes[0], kde = False)
sns.rugplot(tips['total_bill'], ax = axes[0])
sns.kdeplot(tips['total_bill'], ax = axes[1], shade=True)#设置shade加阴影
sns.rugplot(tips['total_bill'], ax = axes[1])
```

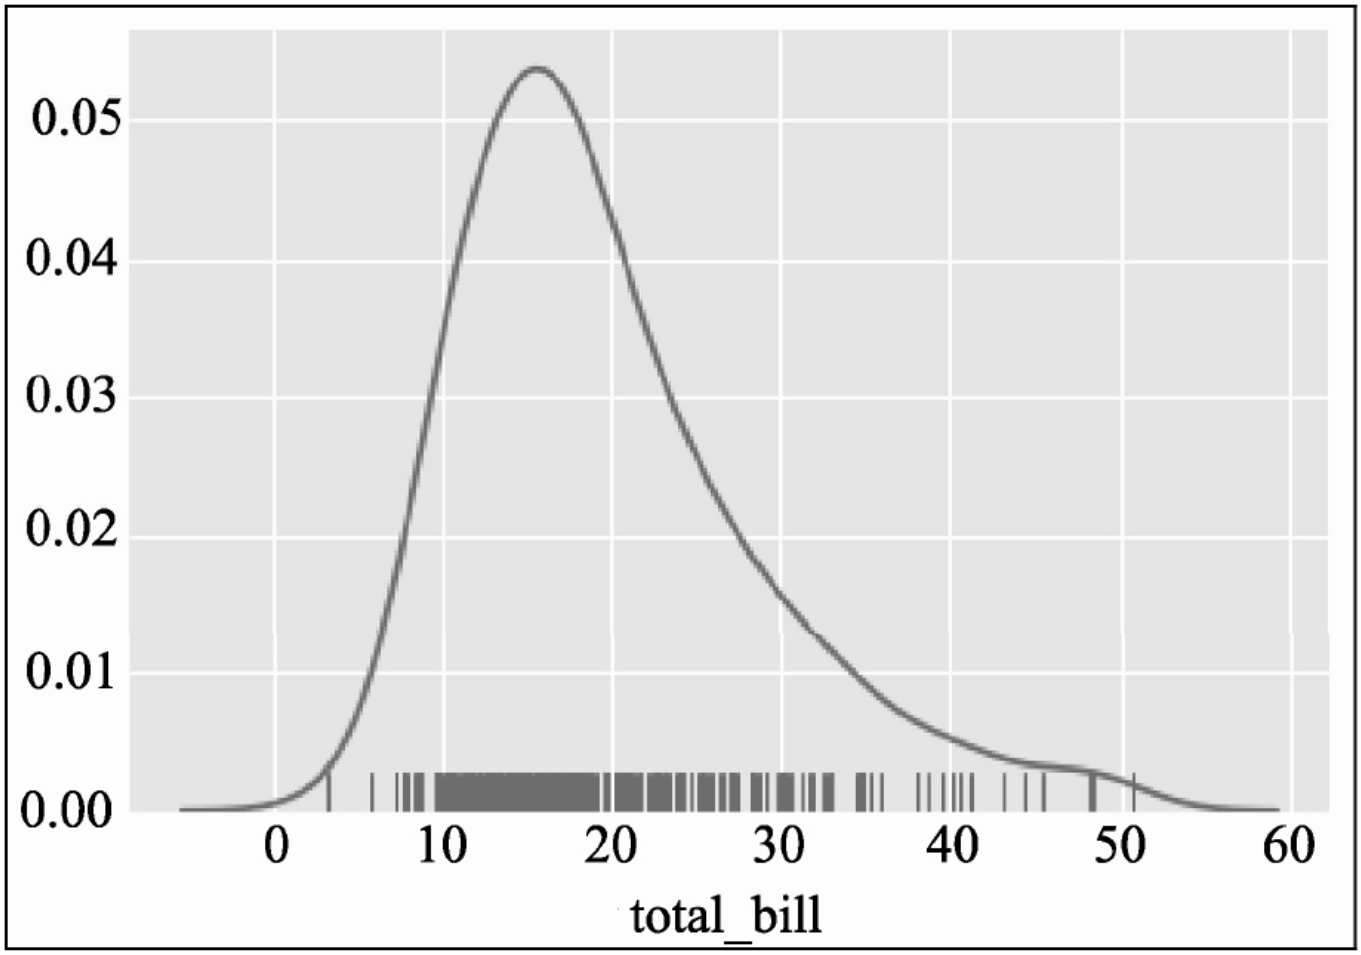

图8.12　通过distplot方法绘制4

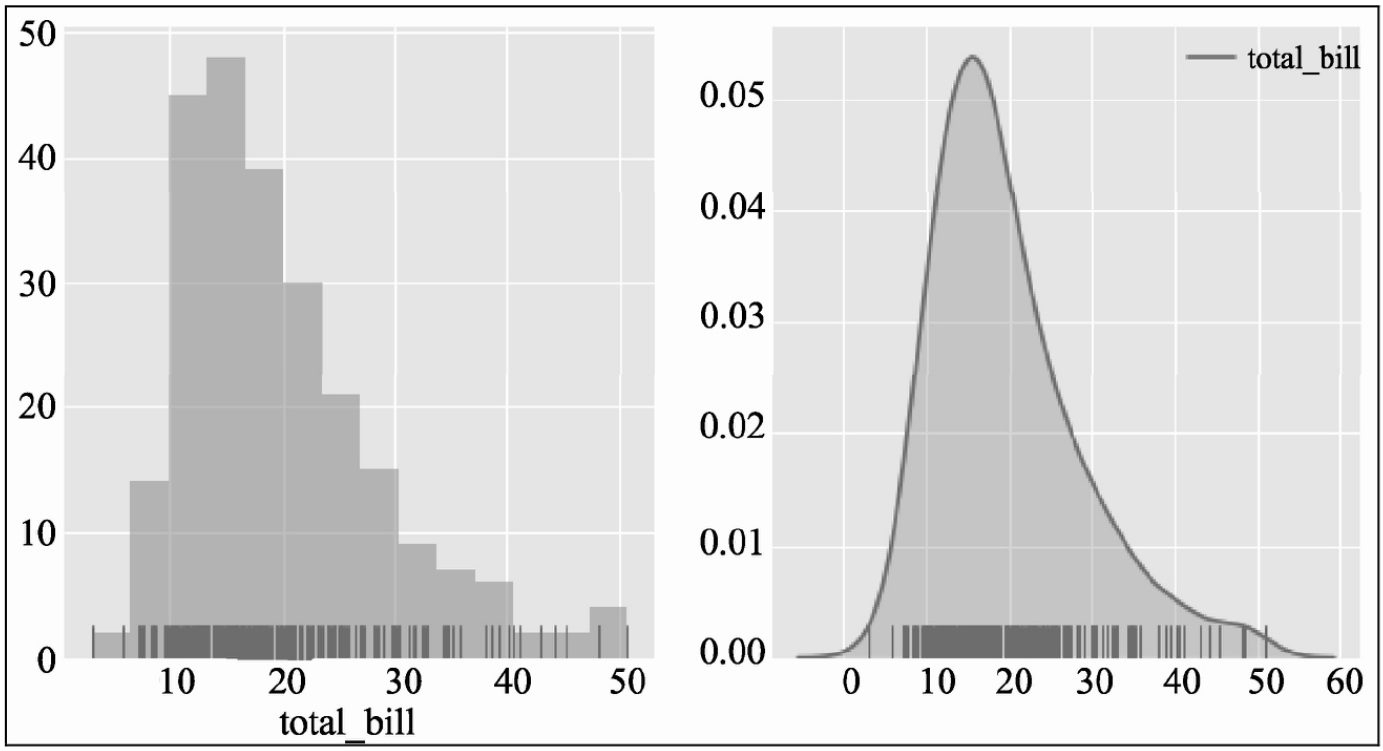

图8.13　各类分布图

8.1.4　多变量分布图

在matplotlib中，为了绘制两个变量的分布关系，常使用散点图的方法。在seaborn中，使用jointplot函数绘制一个多面板图，不仅可以显示两个变量的关系，也可以显示每个单变量的分布情况。

下面绘制tip和total_bill的分布图，如图8.14所示。这里除了有散点图外，还有两个变量的直方图。

```
sns.jointplot(x="tip", y="total_bill", data=tips)
```

```
#x和y是列名
#data是数据来源，这里是小费的DataFrame
```

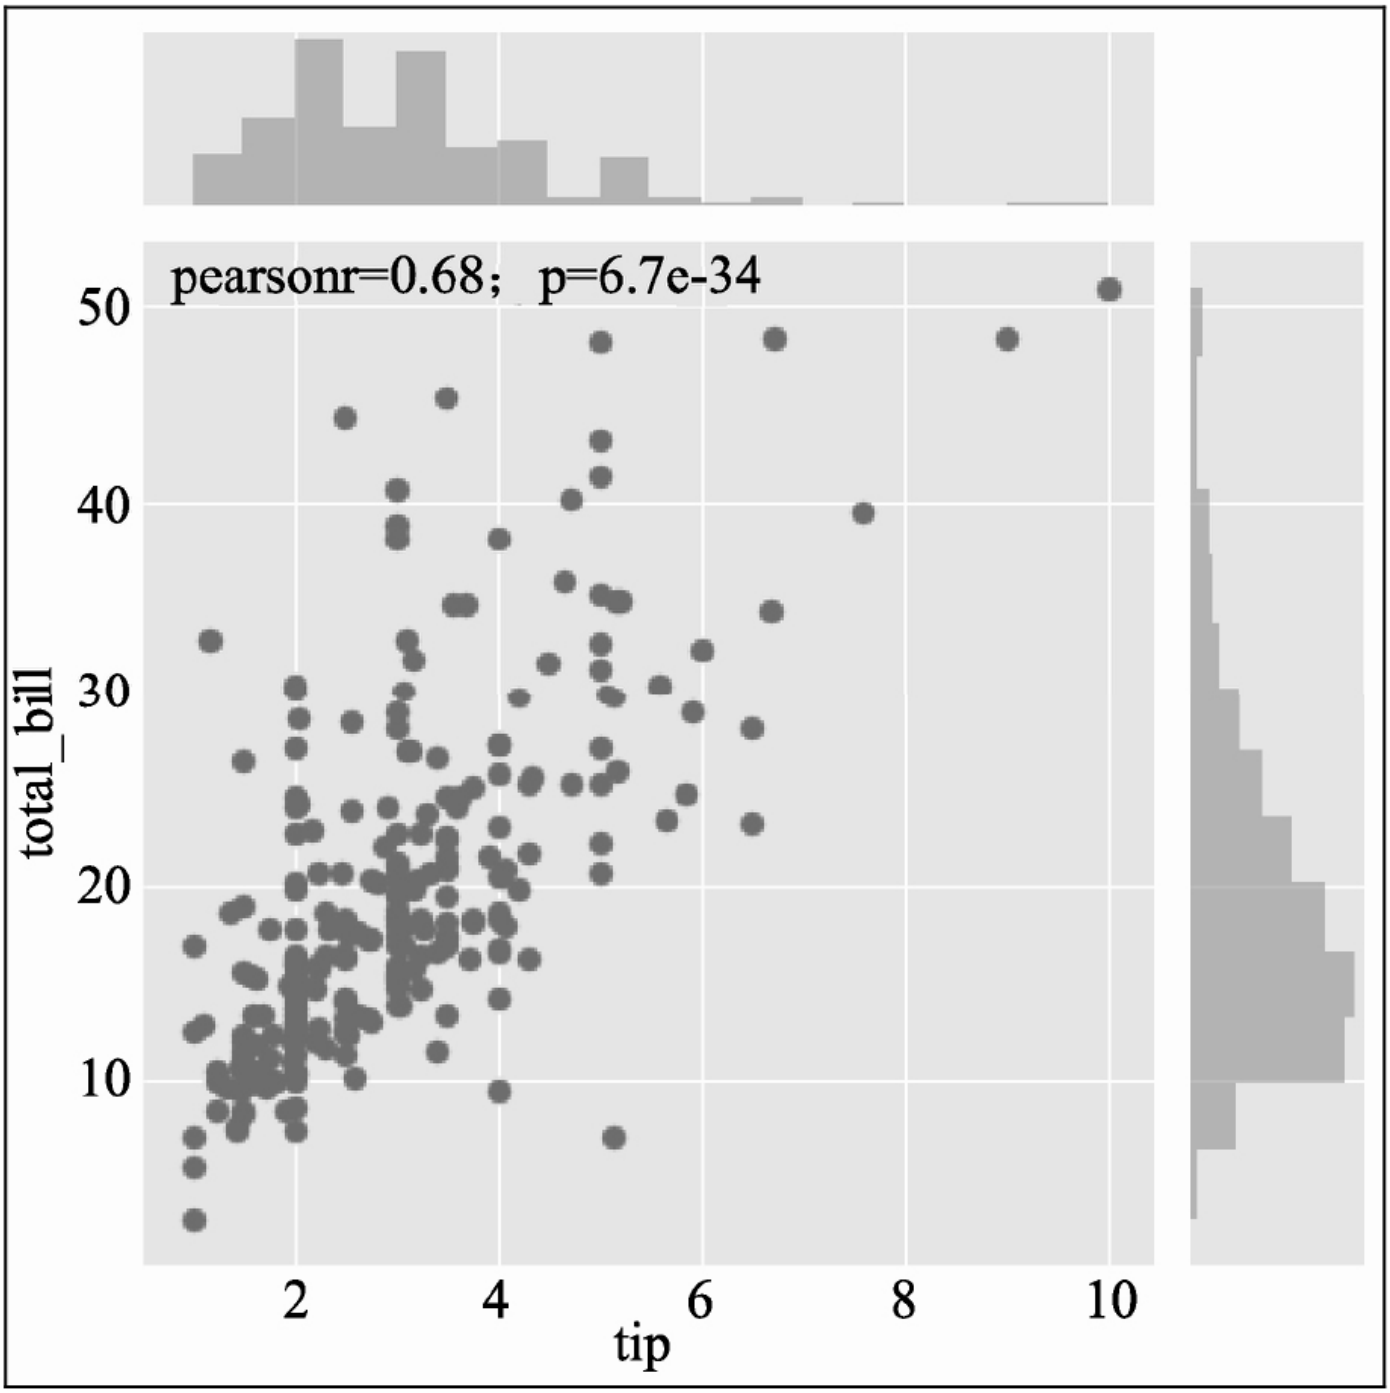

图8.14　通过jointplot函数绘制1

在jointplot函数中，改变kind参数为kde（密度图），单变量的分布就会用密度图来代替，而散点图会被等高线图代替，如图8.15所示。

```
sns.jointplot(x="tip", y="total_bill", data=tips, kind='kde')
```

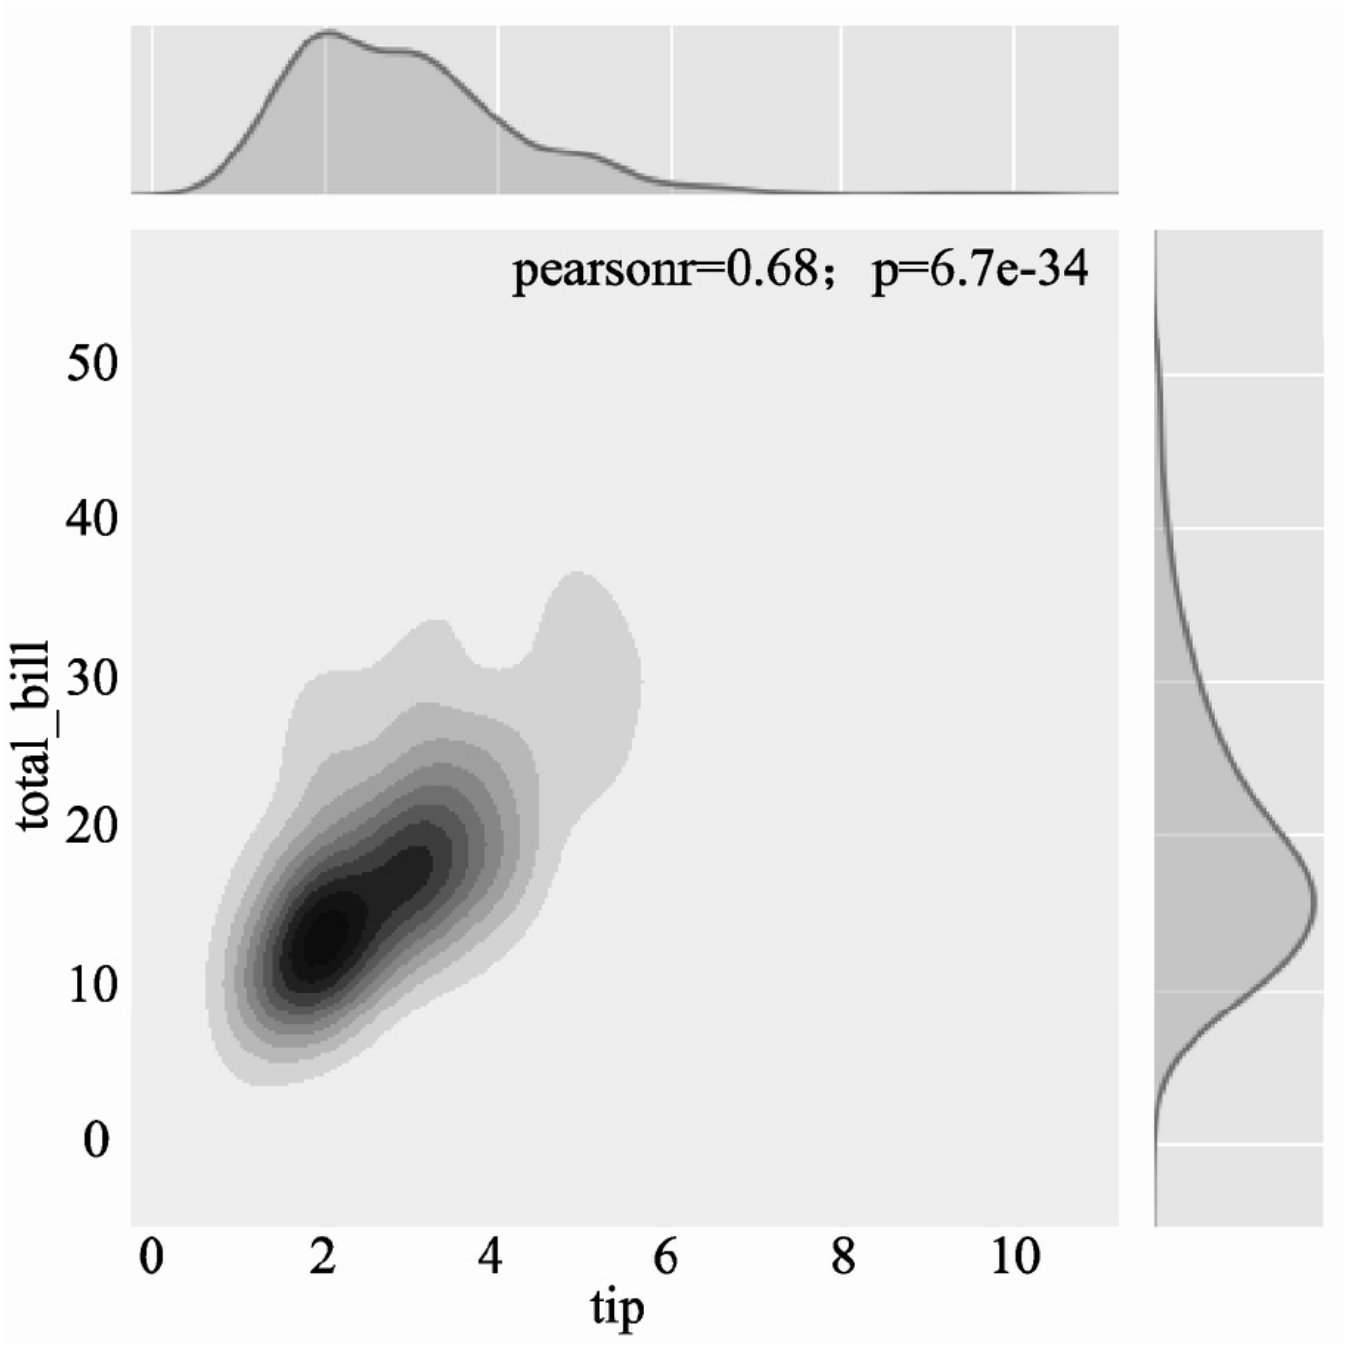

图8.15　通过jointplot函数绘制2

在数据集中，如果要体现多变量的分布情况，就需要成对的二元分布图。在seaborn中，可以使用pairplot函数来完成二元分布图，该函数会创建一个轴矩阵，以此显示DataFrame中每两列的关系，在对角上为单变量的分布情况。

pairplot函数只对数值类型的列有效。如图8.16所示为绘制小费数据集的多变量分布情况图：代码如下：

```
sns.pairplot(tips)
```

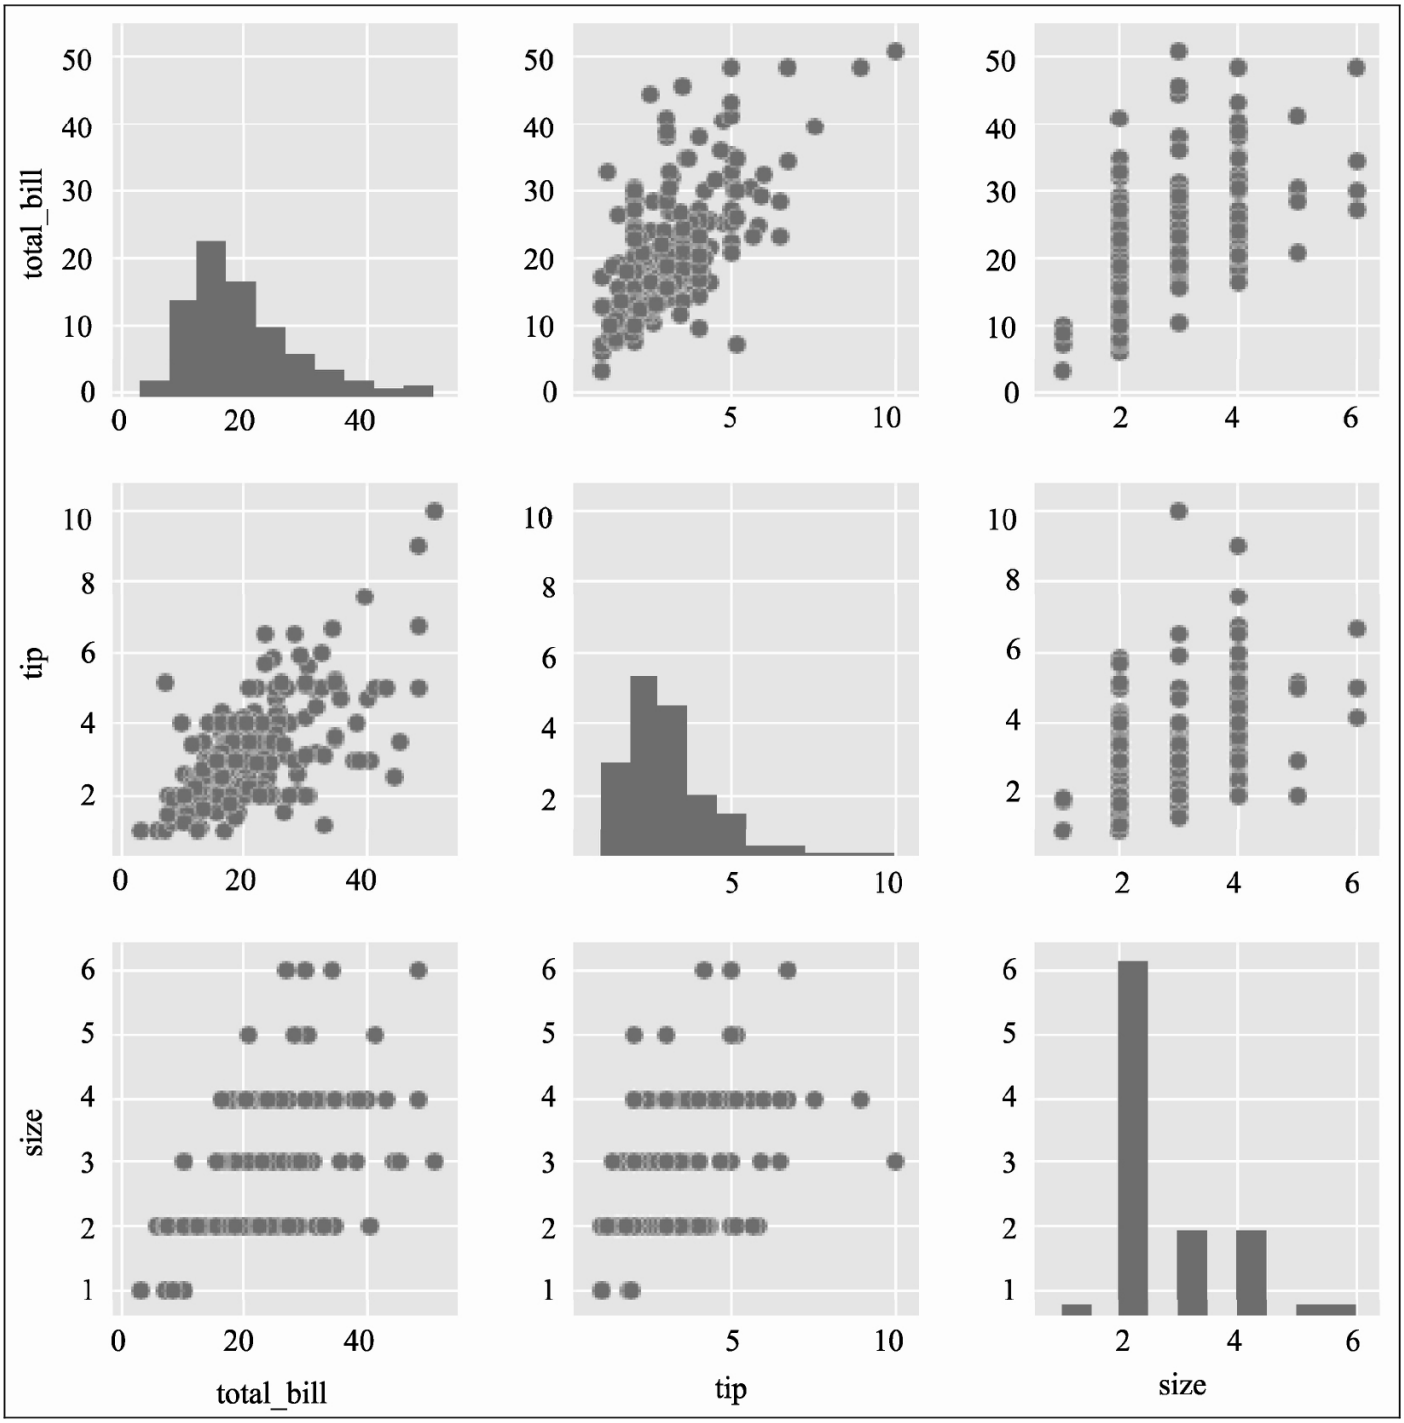

图8.16　小费数据集多变量分布图

8.2　分类图

本节讲解分类数据的可视化技术，主要介绍在seaborn中如何绘制分类散点图、箱线图、琴形图和柱状图。

8.2.1　分类散点图

在seaborn中，通过stripplot函数可以显示度量变量在每个类别的值。在小费数据集中，显示total_bill在day上的值的分布，效果如图8.17所示。代码如下：

```
sns.set(style="white", color_codes=True)                    #设置样式
sns.stripplot(x="day", y="total_bill", data=tips)
sns.despine()                                                #去坐标轴
```

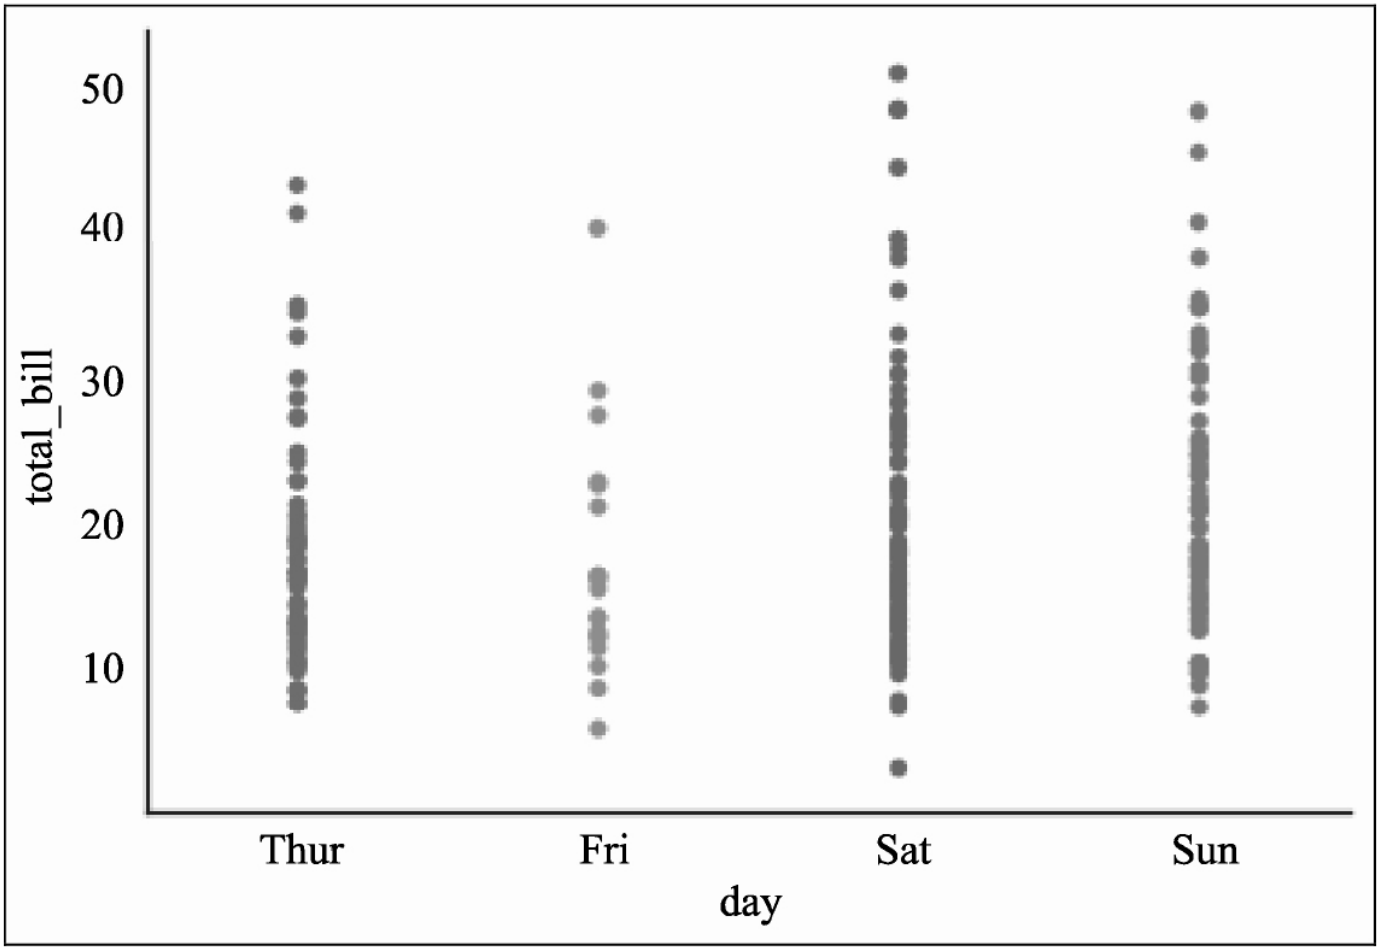

图8.17　通过stripplot函数绘制1

从图8.17中可以看出，散点图中由于数据较多，很多散点都会被覆盖。这时可以加入抖动（jitter=True），这样就可以看清多数数据点，效果如图8.18所示。代码如下：

```
sns.stripplot(x="day", y="total_bill", data=tips, jitter=True)
sns.despine()
```

如果需要看清每个数据点，可以使用swarmplot函数，效果如图8.19所示。代码如下：

```
sns.swarmplot(x="day", y="total_bill", data=tips)
sns.despine()
```

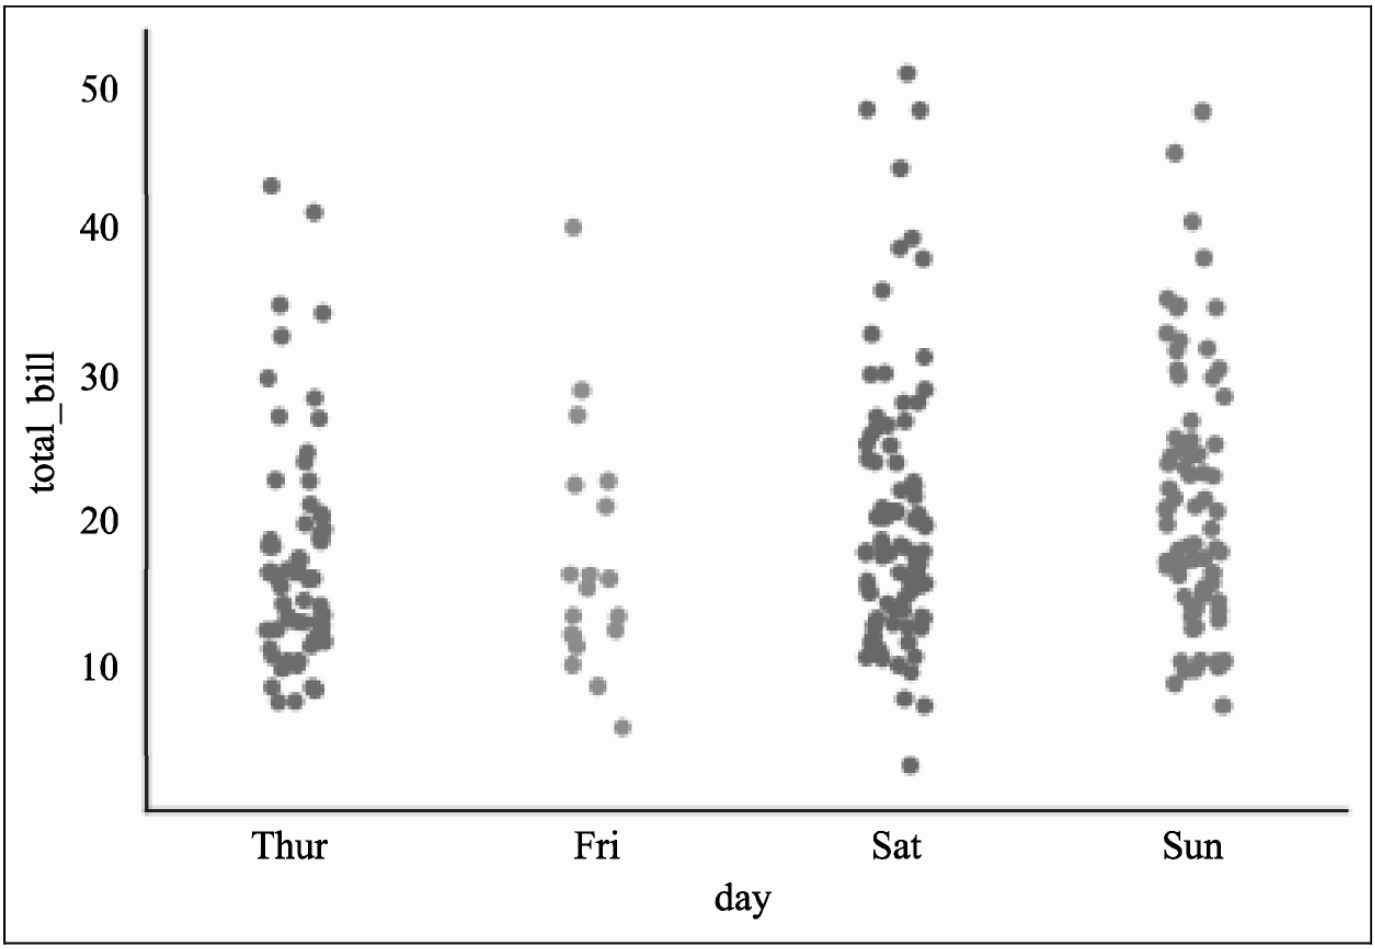

图8.18　stripplot函数绘制2

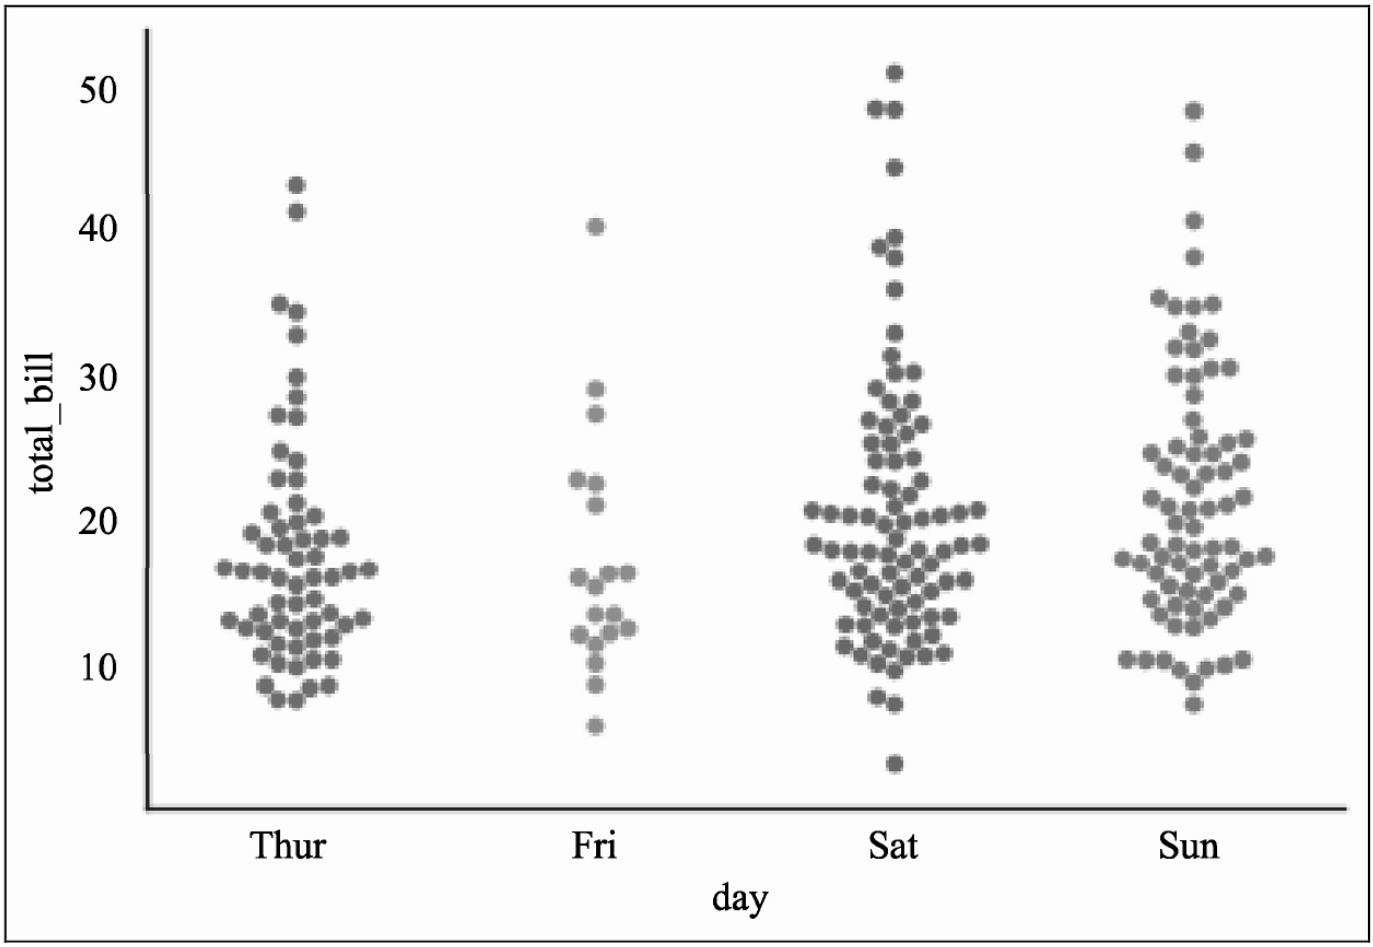

图8.19　swarmplot函数绘制1

通过swarmplot函数的hue参数可以多嵌套一个分类变量，在图表中会以不同的色彩来表现，如图8.20所示。

```
sns.swarmplot(x="day", y="total_bill", hue="sex", data=tips)
sns.despine()
```

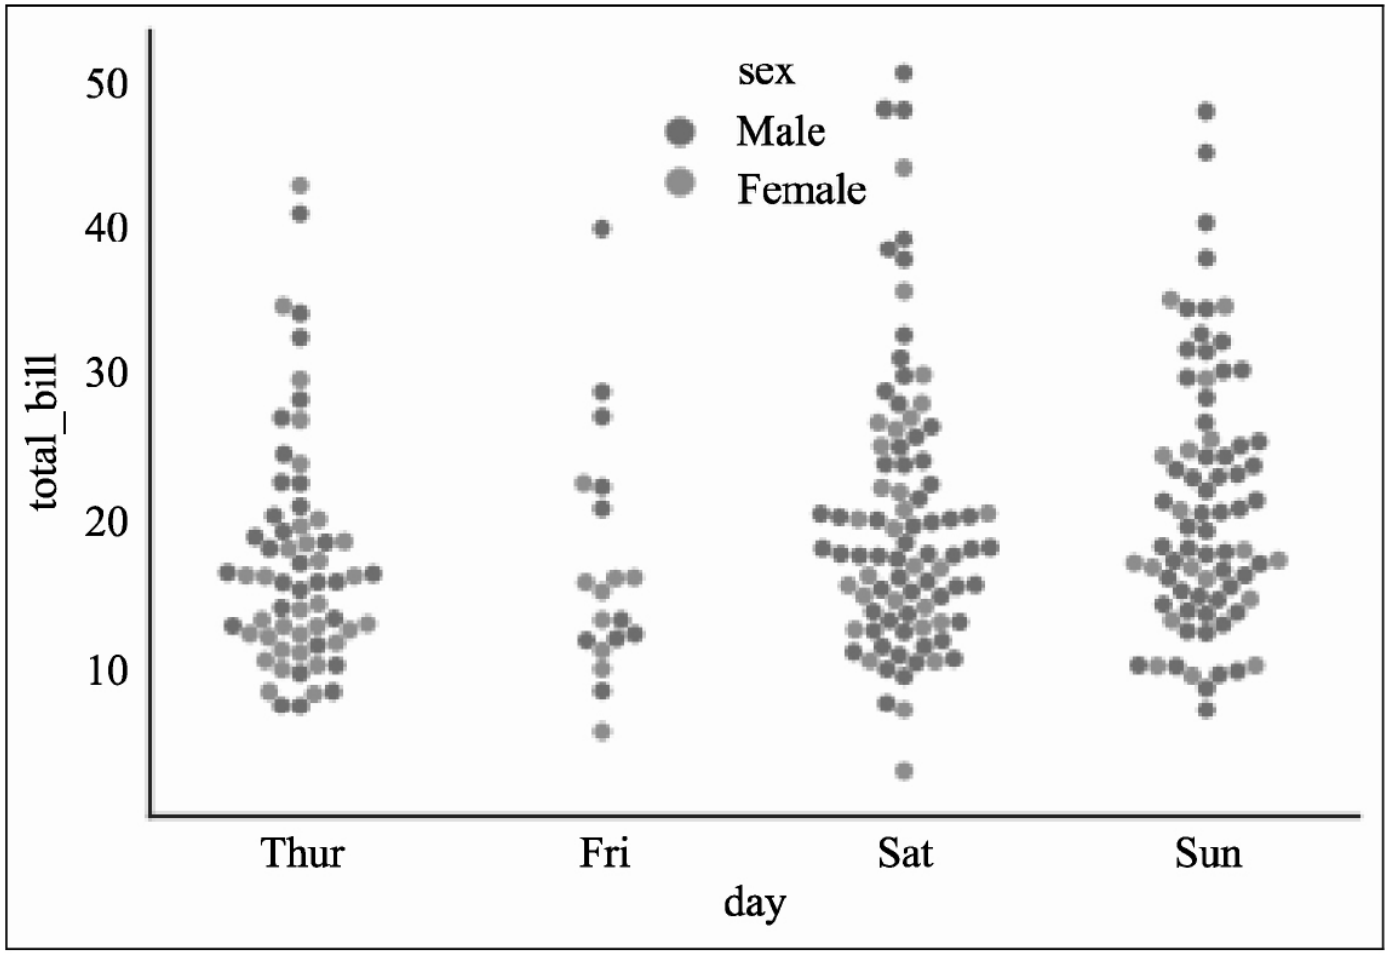

图8.20　swarmplot函数绘制2

8.2.2　箱线图与琴形图

在某些情况下，分类散点图表达的值的分布信息有限，这时就需要一些其他的绘图图形。箱线图就是一个不错的选择，箱线图可以观察四分位数、中位数和极值。在seaborn中使用boxplot函数来绘制箱线图，效果如图8.21所示。代码如下：

```
sns.boxplot(x="day", y="total_bill", hue="time", data=tips)
sns.despine()
```

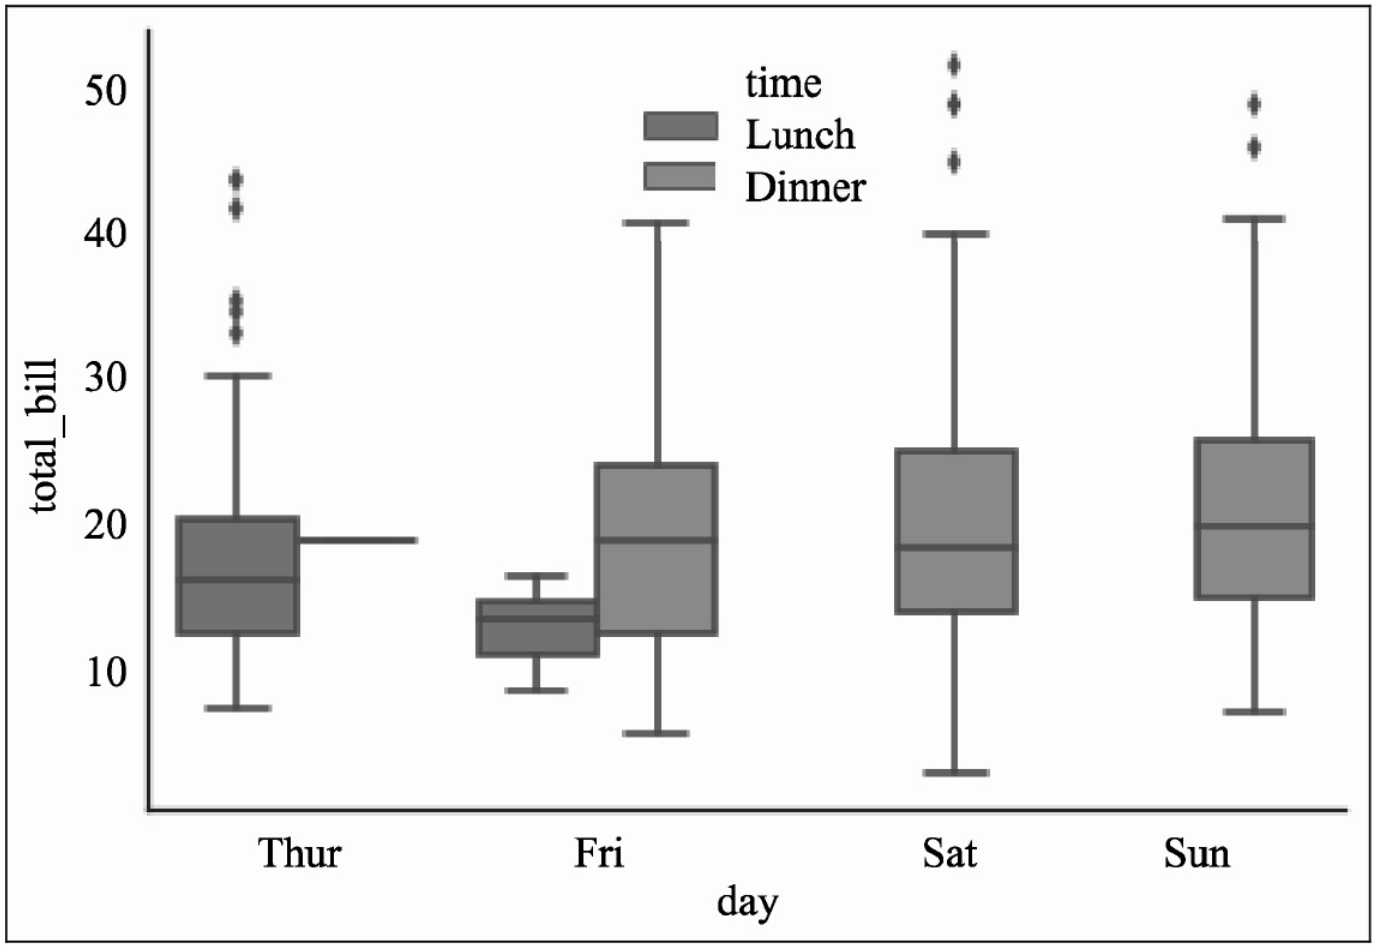

图8.21　箱线图

琴形图结合了箱线图与核密度估计图，在seaborn中，使用violinplot来绘制琴形图，效果如图8.22所示。代码如下：

```
sns.set(style="whitegrid", color_codes=True)
sns.violinplot(x="total_bill", y="day", hue="time", data=tips)
#x和y轴颠倒
```

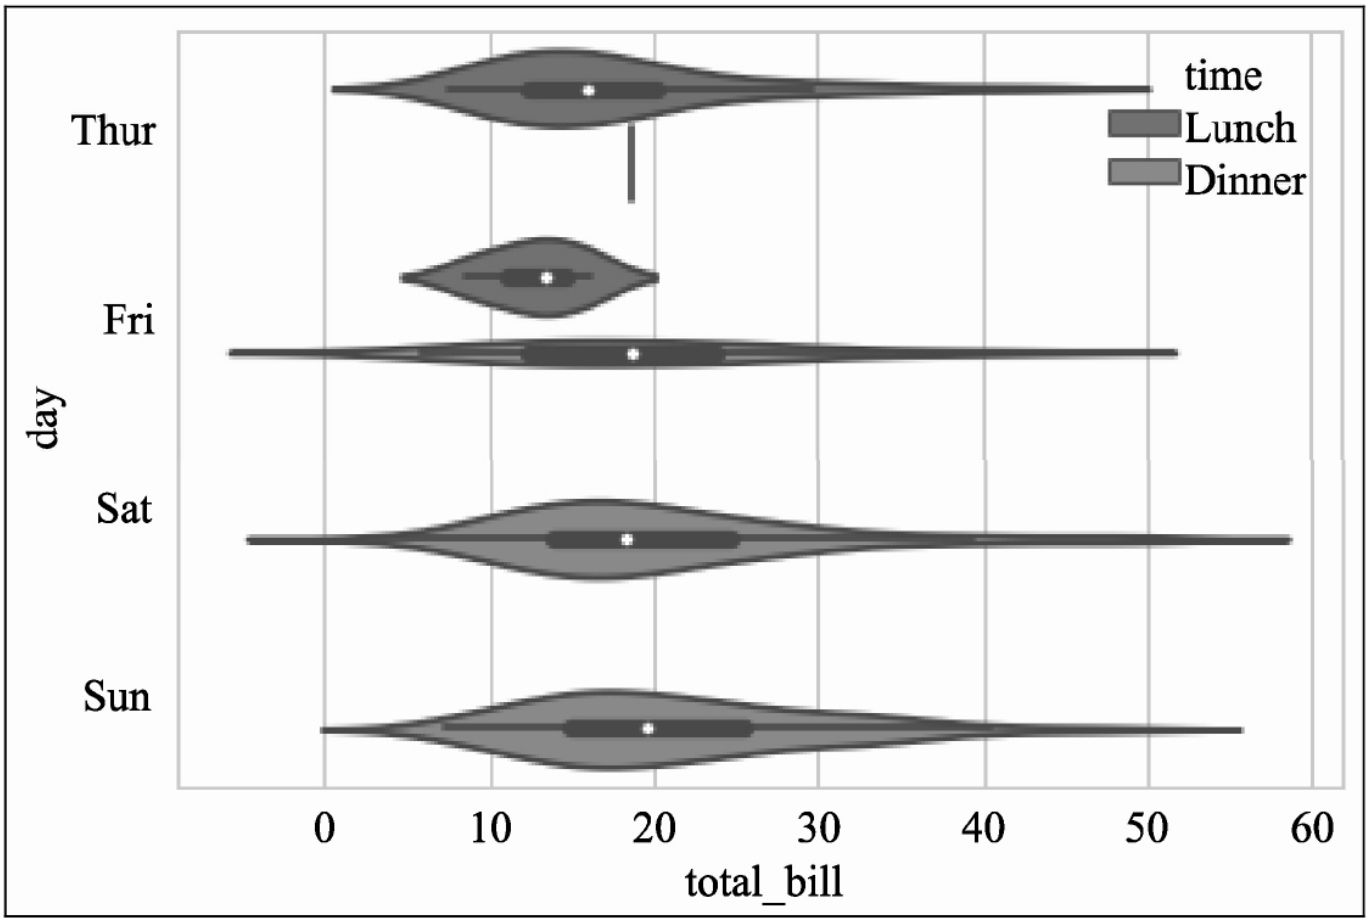

图8.22　琴形图1

利用split参数可以将分类数据进行切分，这样绘制的琴形图两边的颜色就代表了不同的类别；在琴形图中，利用inner参数可以对每个数据进行可视化，而不是只能查看箱线图的那几个统计值，效果如图8.23所示。代码如下：

```
sns.set(style="whitegrid", color_codes=True)
fig, axes = plt.subplots(1,2,figsize=(10, 5))
#设置样式与子图

sns.violinplot(x="day", y="total_bill", hue="sex", data=tips,
               split=True, ax=axes[0])
#对数据切分

sns.violinplot(x="day", y="total_bill", hue="sex", data=tips,
               split=True, inner="stick", palette="Set3",ax=axes[1])
#对数据切分并对每个数据可视化
```

这些分类图函数可以相互组合，实现更加强大的可视化效果，效果如图8.24所示。代码如下：

```
sns.set(style="whitegrid", color_codes=True)
fig, axes = plt.subplots(1,2,figsize=(10, 5))
#设置样式与子图

sns.violinplot(x="day", y="total_bill", data=tips,
               inner=None, ax=axes[0])
#inner内部不填充
sns.swarmplot(x="day", y="total_bill", data=tips,
              color="w", alpha=.5, ax=axes[0])

sns.boxplot(x="day", y="total_bill", data=tips, ax=axes[1])
sns.stripplot(x="day", y="total_bill", data=tips,
              jitter=True, color="w", alpha=.5, ax=axes[1])
```

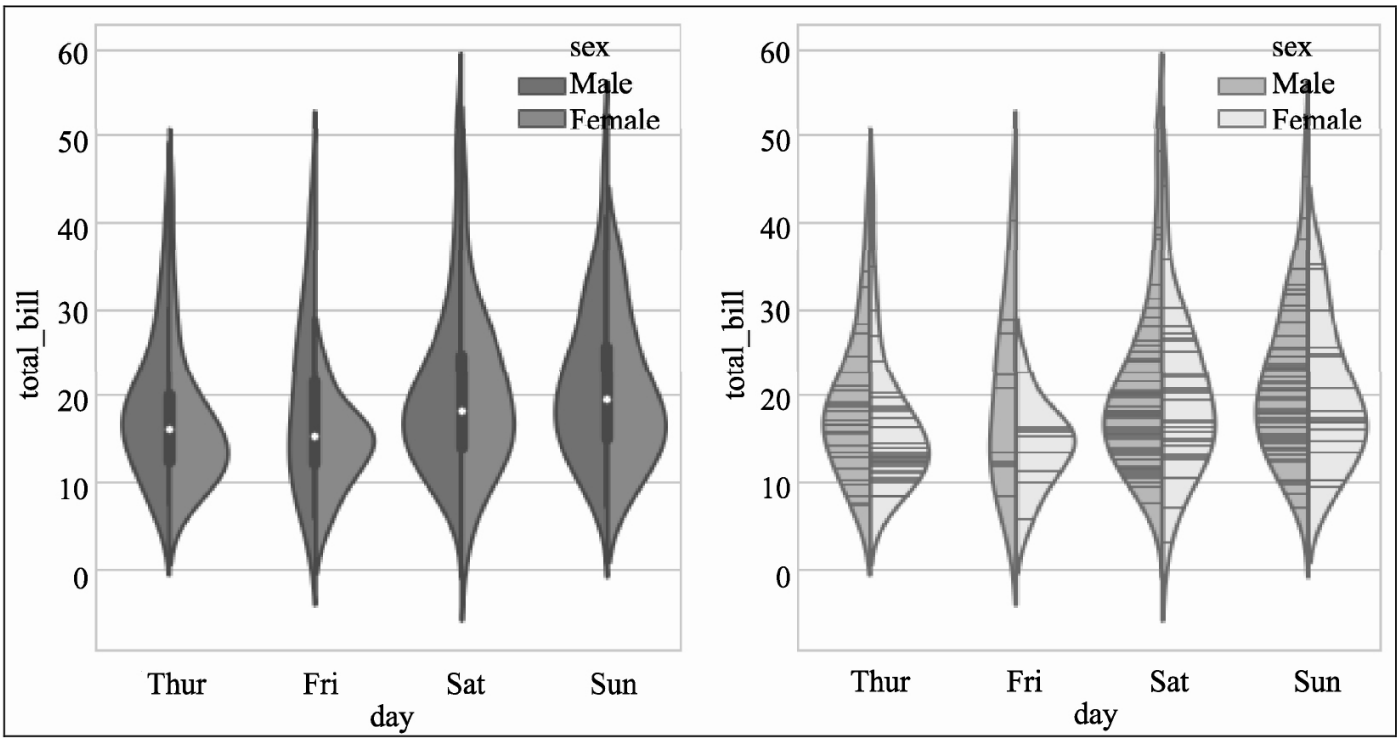

图8.23　琴形图2

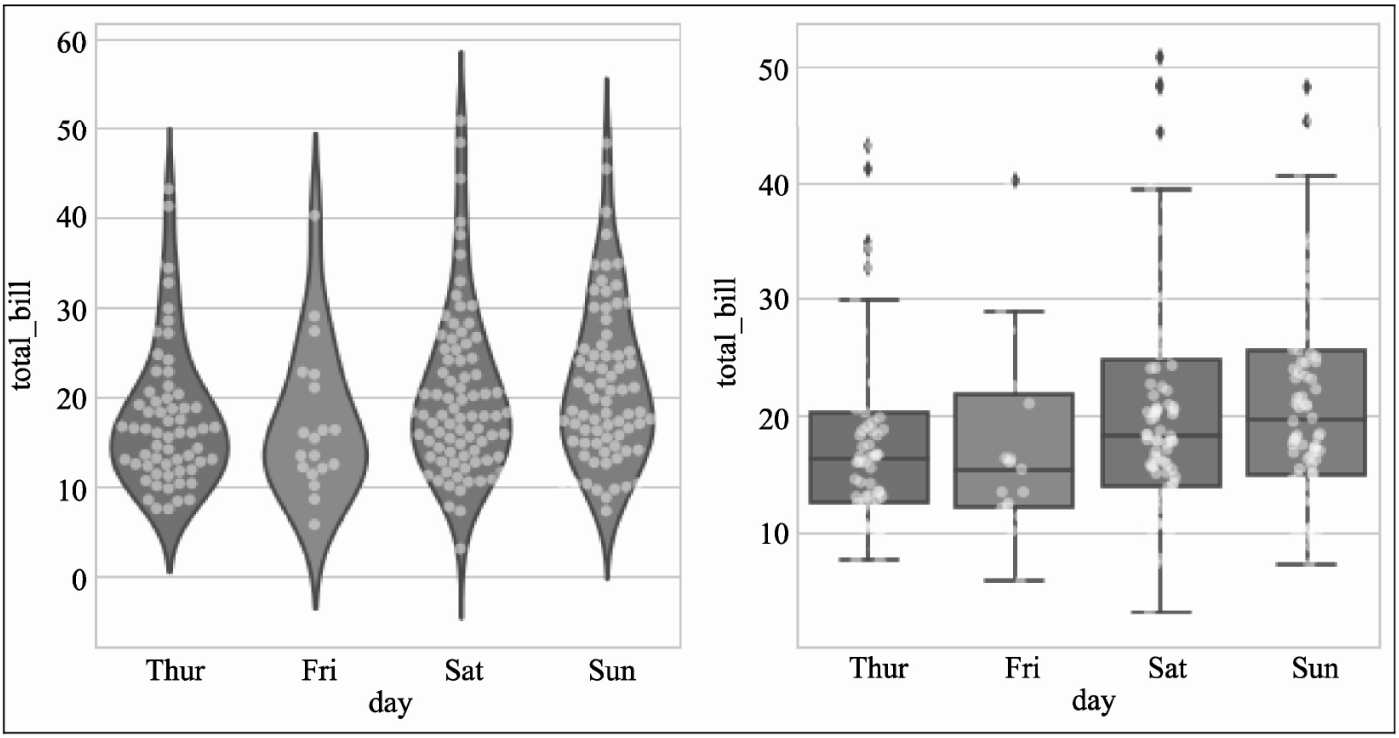

图8.24　分类图组合

8.2.3　柱状图

在seaborn中使用barplot函数来绘制柱状图，默认情况下使用barplot函数绘制的y轴是平均值，且在每个柱状条上会绘制误差条，如图8.25所示。

```
sns.barplot(x="sex", y="tip", hue="day", data=tips)
```

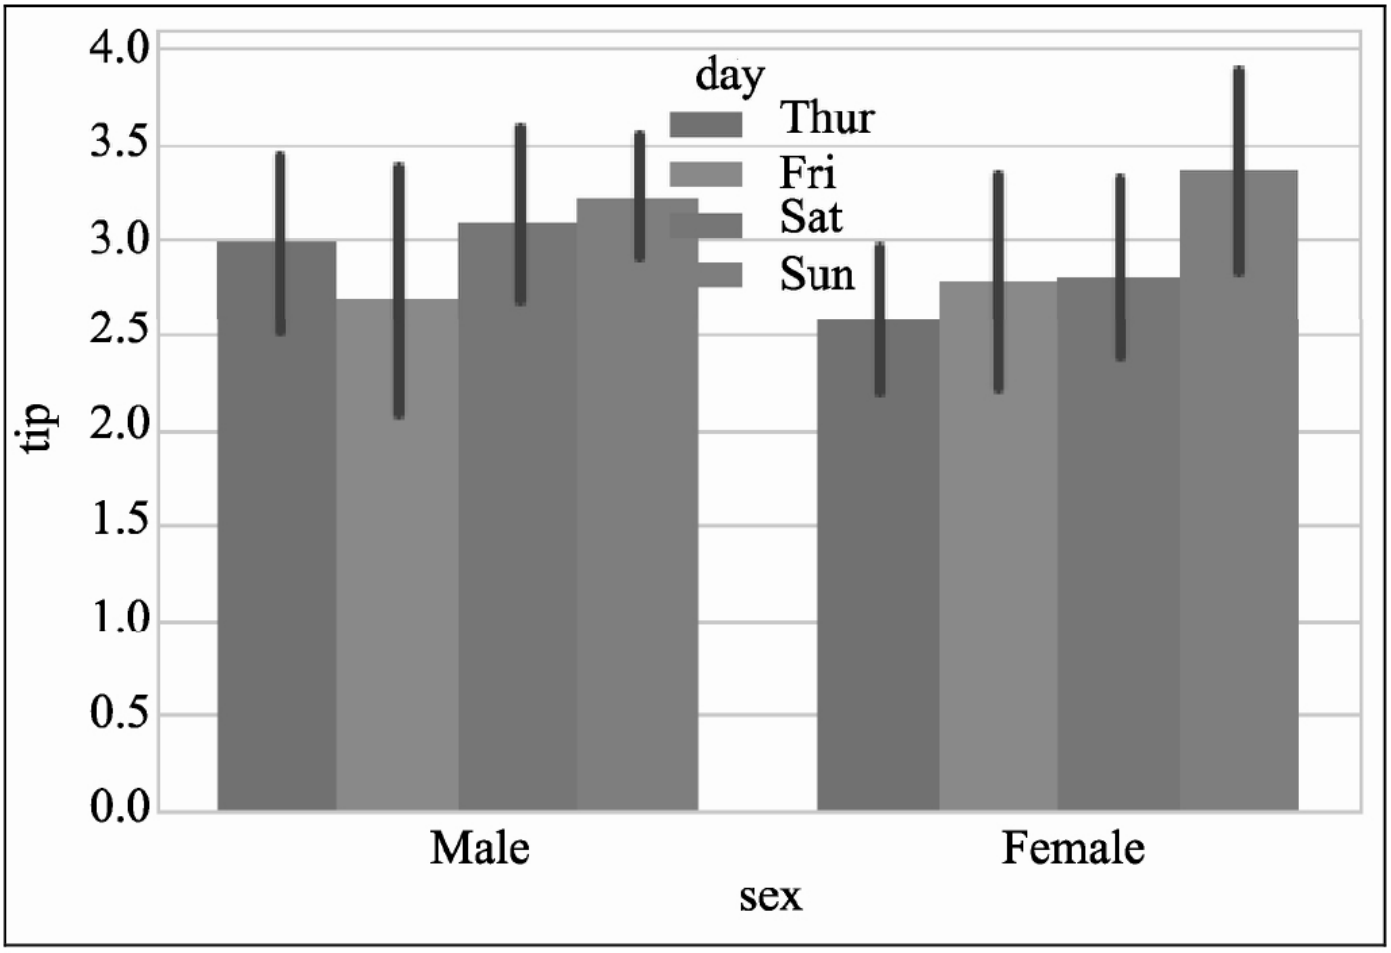

图8.25　使用barplot函数绘制柱状图

在柱状图中，常绘制类别的计数柱状图。如果使用matplotlib函数进行绘制，首先需要对DataFrame进行计算；而在seaborn中，使用countplot函数即可，如图8.26所示。

```
sns.countplot(x="size",data=tips, palette="Greens_d")
#绿色渐变调色板
```

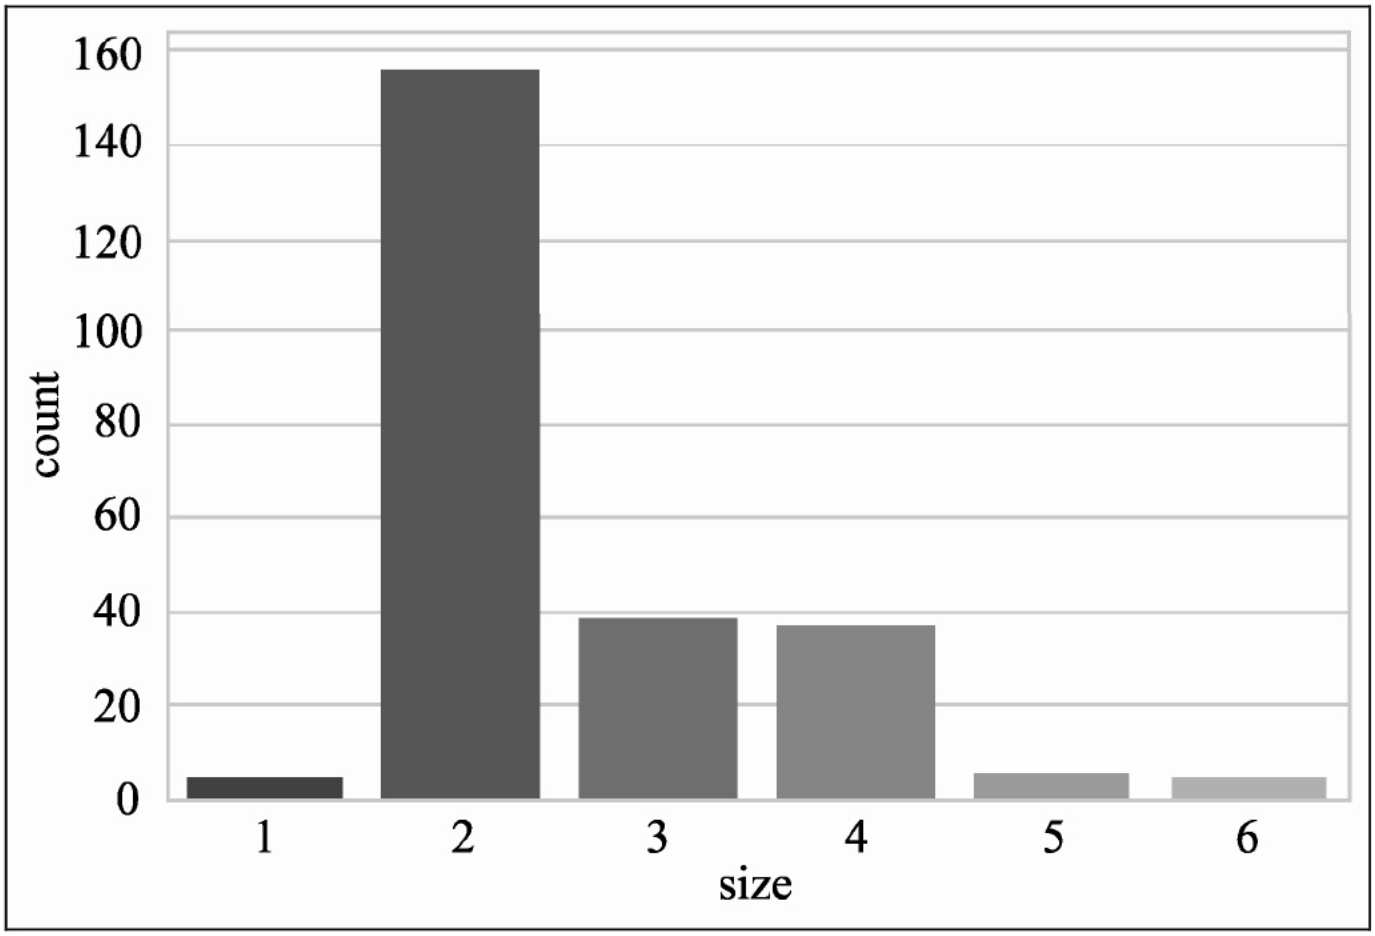

图8.26　使用countplot函数绘制柱状图

8.3　回归图与网格

本节将讲解如何利用seaborn绘制回归图来揭示两个变量间的线性关系，以及如何利用网格技术绘制多子图。

8.3.1　回归图

在seaborn中，使用jointplot函数可以显示两个变量的联合分布情况，使用统计模型来估计两个变量间的简单关系也是非常有必要的。可以使用regplot和lmplot函数来绘制回归图，其绘制的图表是一样的，如图8.27所示。

```
sns.set(style="darkgrid", color_codes=True)
sns.regplot(x="total_bill", y="tip", data=tips)

sns.lmplot(x="total_bill", y="tip", data=tips)
```

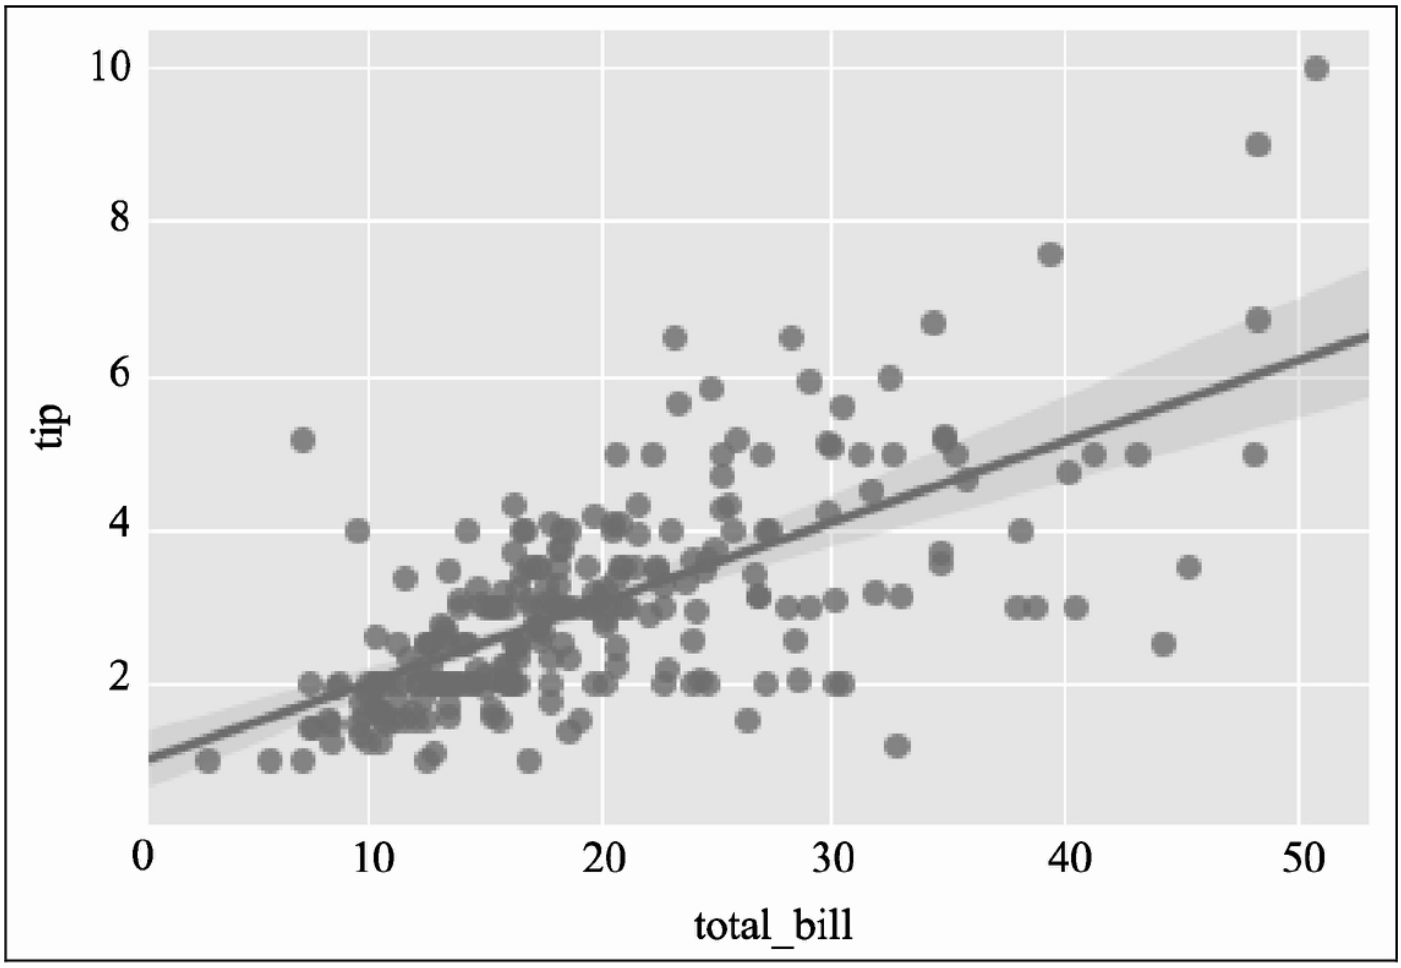

图8.27　回归图1

注意：regplot和lmplot函数传入的数据格式略有不同。

在回归图中，也可以不绘制置信区间，如图8.28所示。

```
sns.lmplot(x="total_bill", y="tip", data=tips, ci=None)
```

在上面的回归图中显示的是一对变量间的关系，使用hue参数可以加入一个分类的变量，通过不同颜色来表现，效果如图8.29所示。代码如下：

```
sns.lmplot(x="total_bill", y="tip", hue="smoker", data=tips)
```

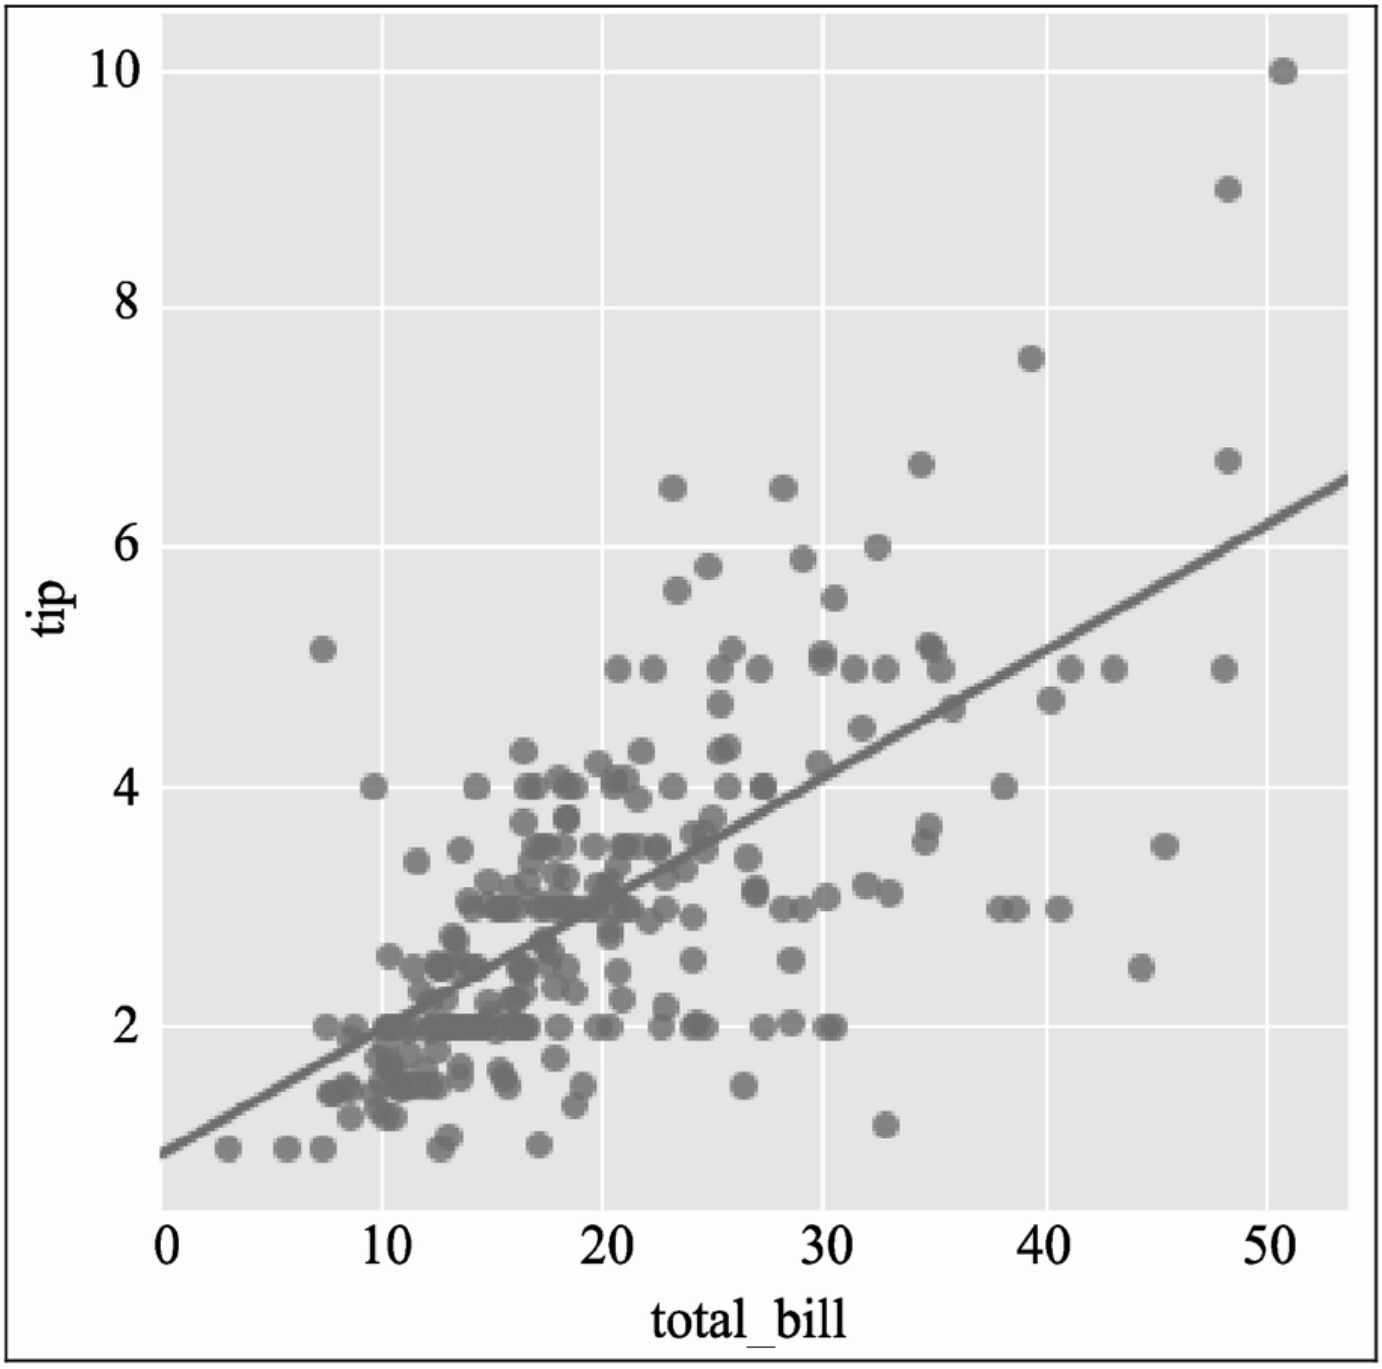

图8.28　回归图2

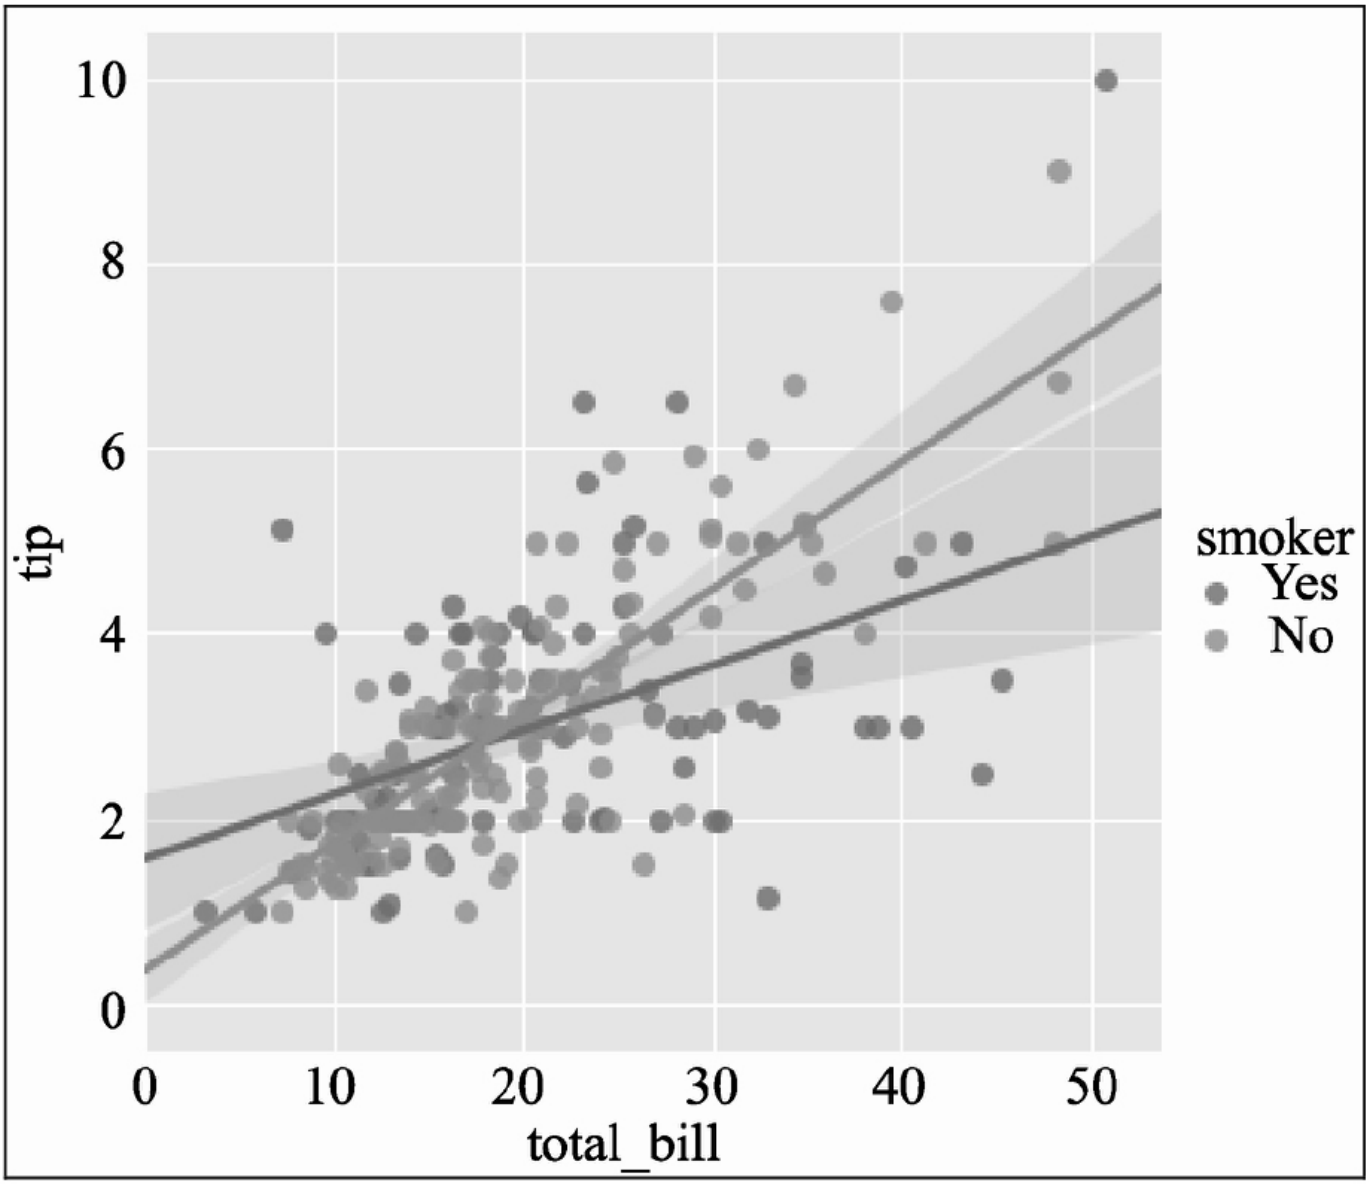

图8.29　回归图3

如果添加一个变量，可以绘制子图，效果如图8.30所示。代码如下：

```
sns.lmplot(x="total_bill", y="tip", hue="smoker", col="time", data=tips)
```

同样再添加两个变量，效果如图8.31所示。代码如下：

```
sns.lmplot(x="total_bill", y="tip", hue="smoker",
           col="time", row="sex", data=tips)
```

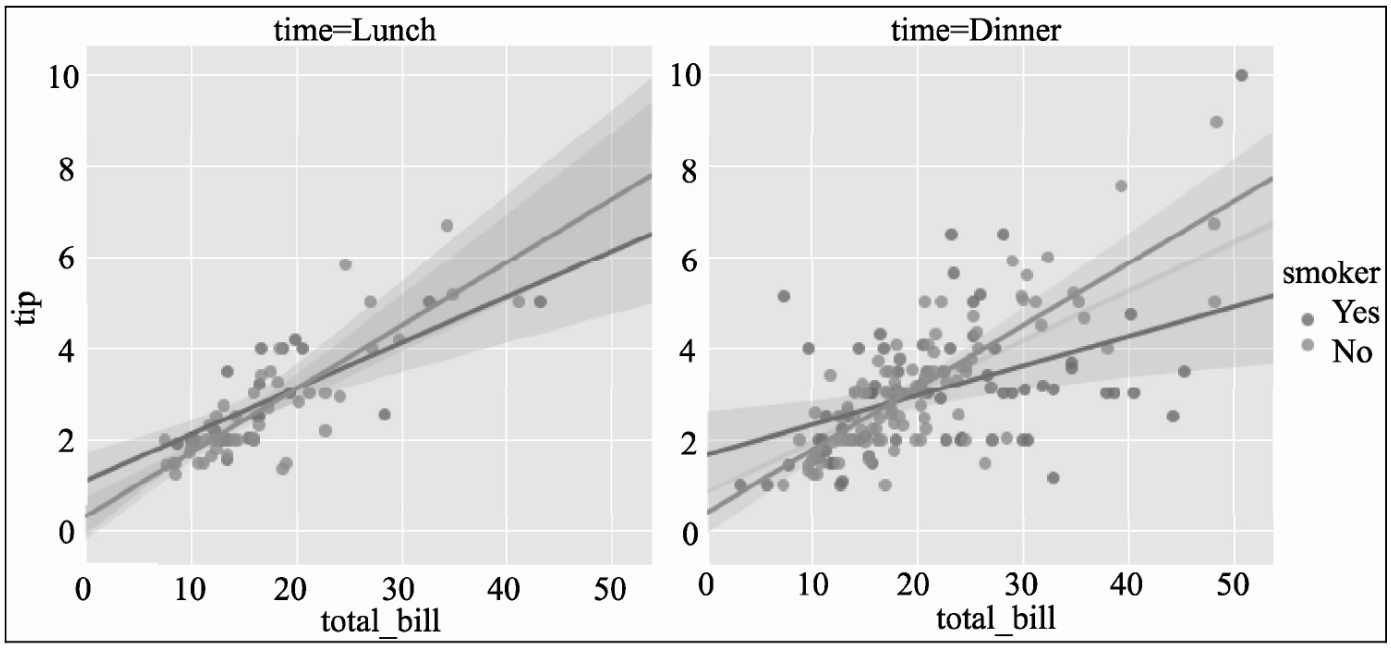

图8.30　回归图4

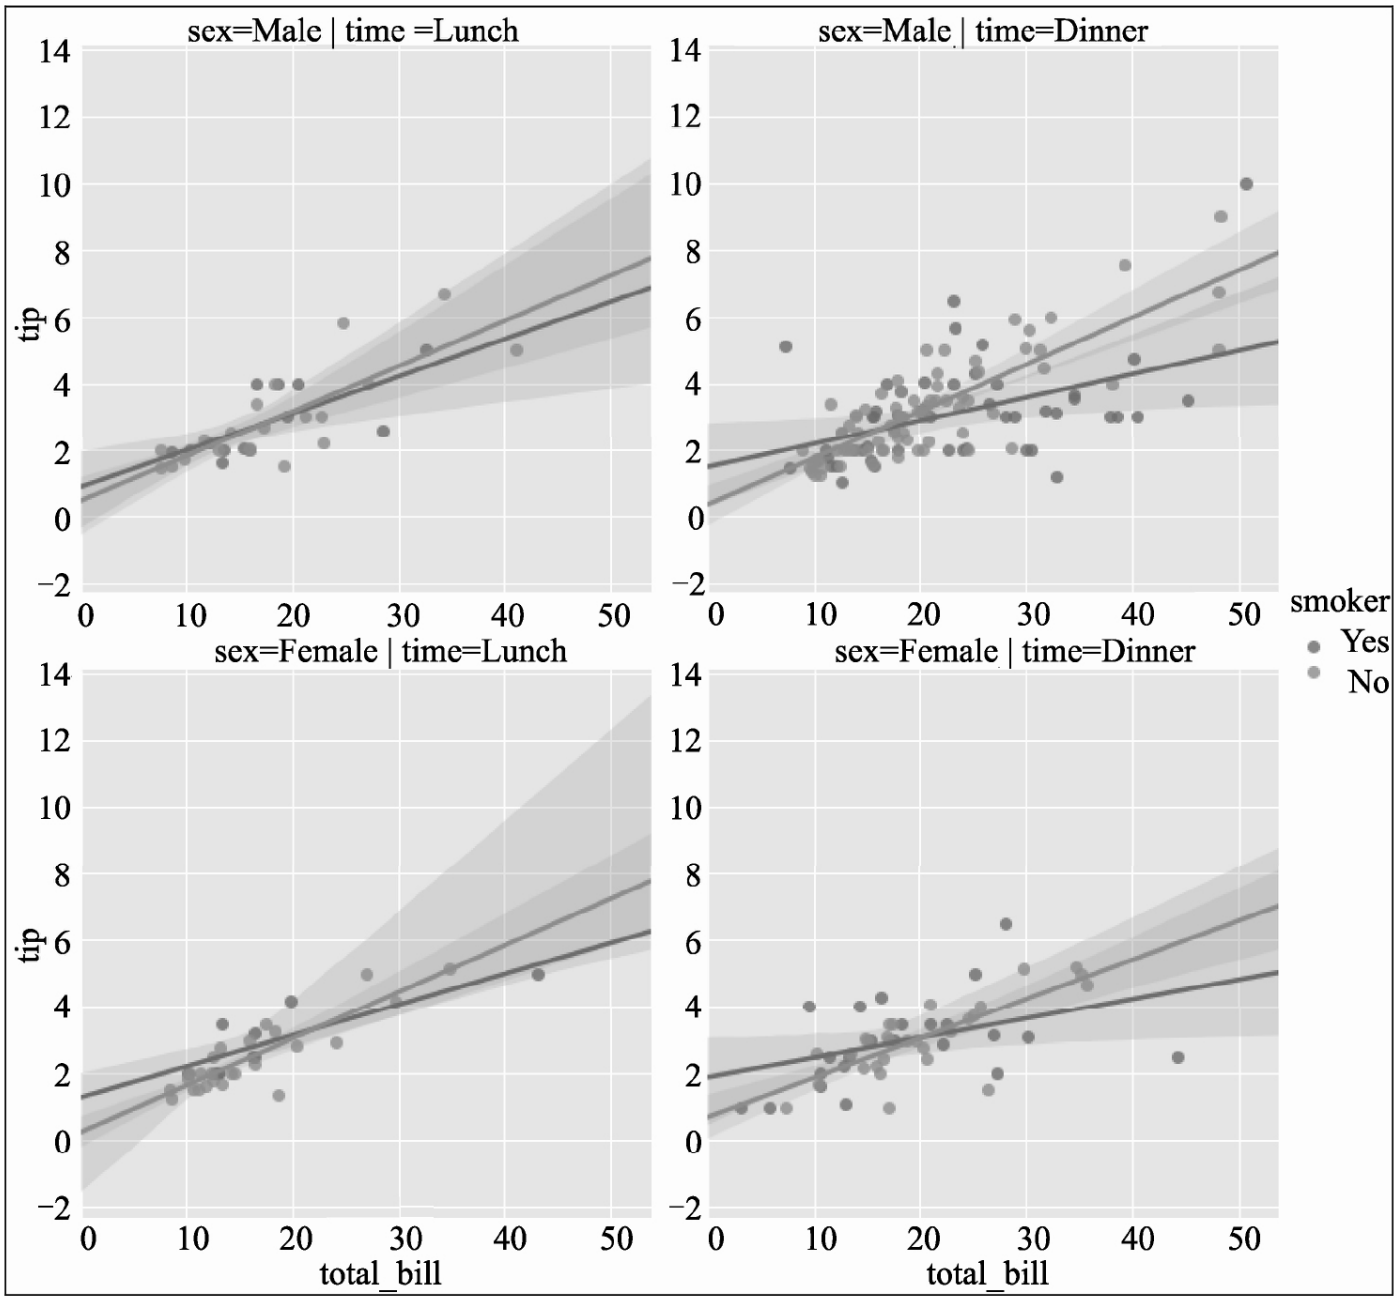

图8.31　回归图5

8.3.2 网格

在对多维度数据进行可视化时，在数据集的不同子集上绘制同一个绘图的多个实例是一件非常有用的事情，这种技术被称为网格技术。在seaborn中，使用FacetGrid来创建对象，然后使用map方法就可以绘制多个实例图表了，效果如图8.32所示。代码如下：

```
g = sns.FacetGrid(tips, col="time")
g.map(plt.hist, "tip")
```

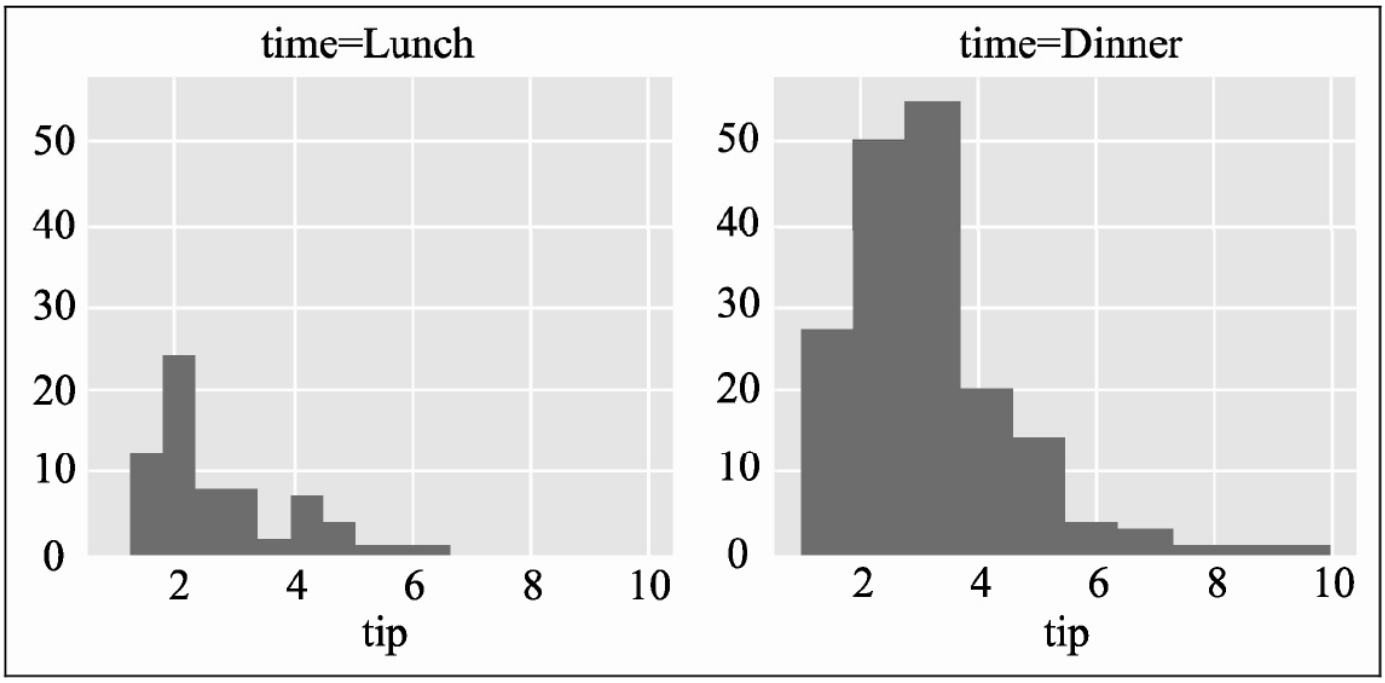

图8.32 网格技术绘图1

matplotlib的基本图形都可以在该对象中绘制，如图8.33所示为绘制的散点图。代码如下：

```
g = sns.FacetGrid(tips, col="sex", hue="smoker")
g.map(plt.scatter, "total_bill", "tip", alpha=.7)
g.add_legend()
```

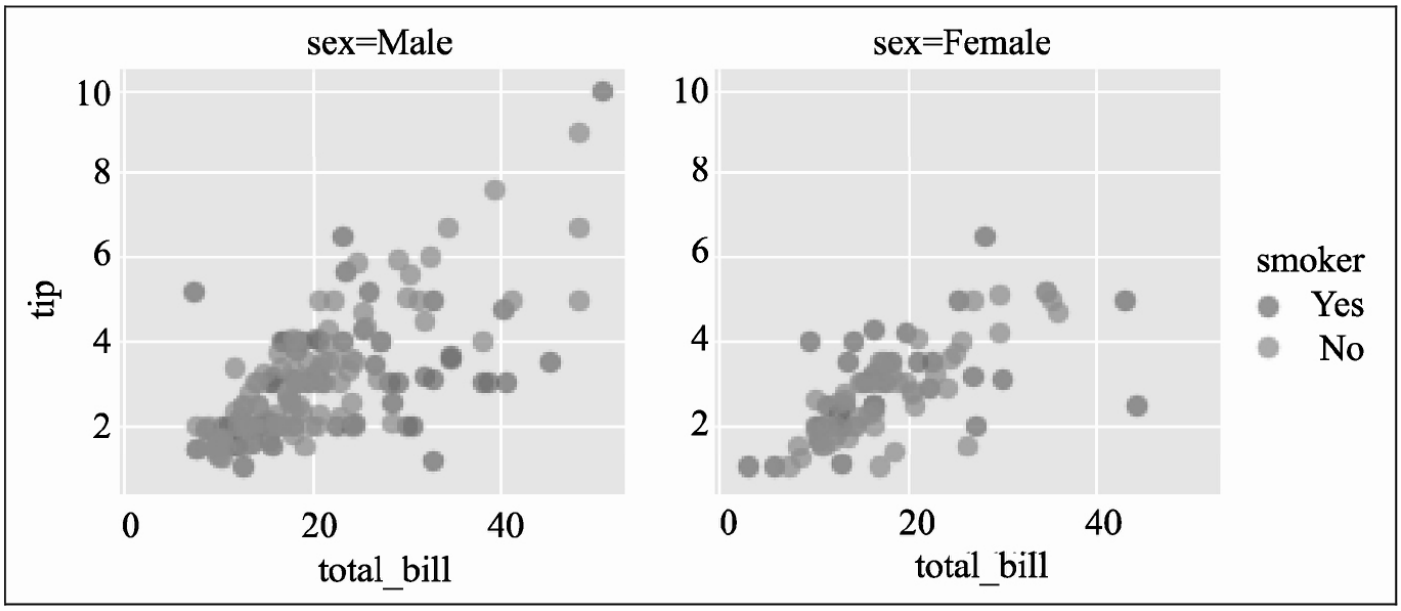

图8.33 网格技术绘图2

同样，也可以添加多个变量用于绘制多个图表，效果如图8.34所示。代码如下：

```
g = sns.FacetGrid(tips, col="sex", row='time')
g.map(sns.boxplot, 'size', 'tip')
```

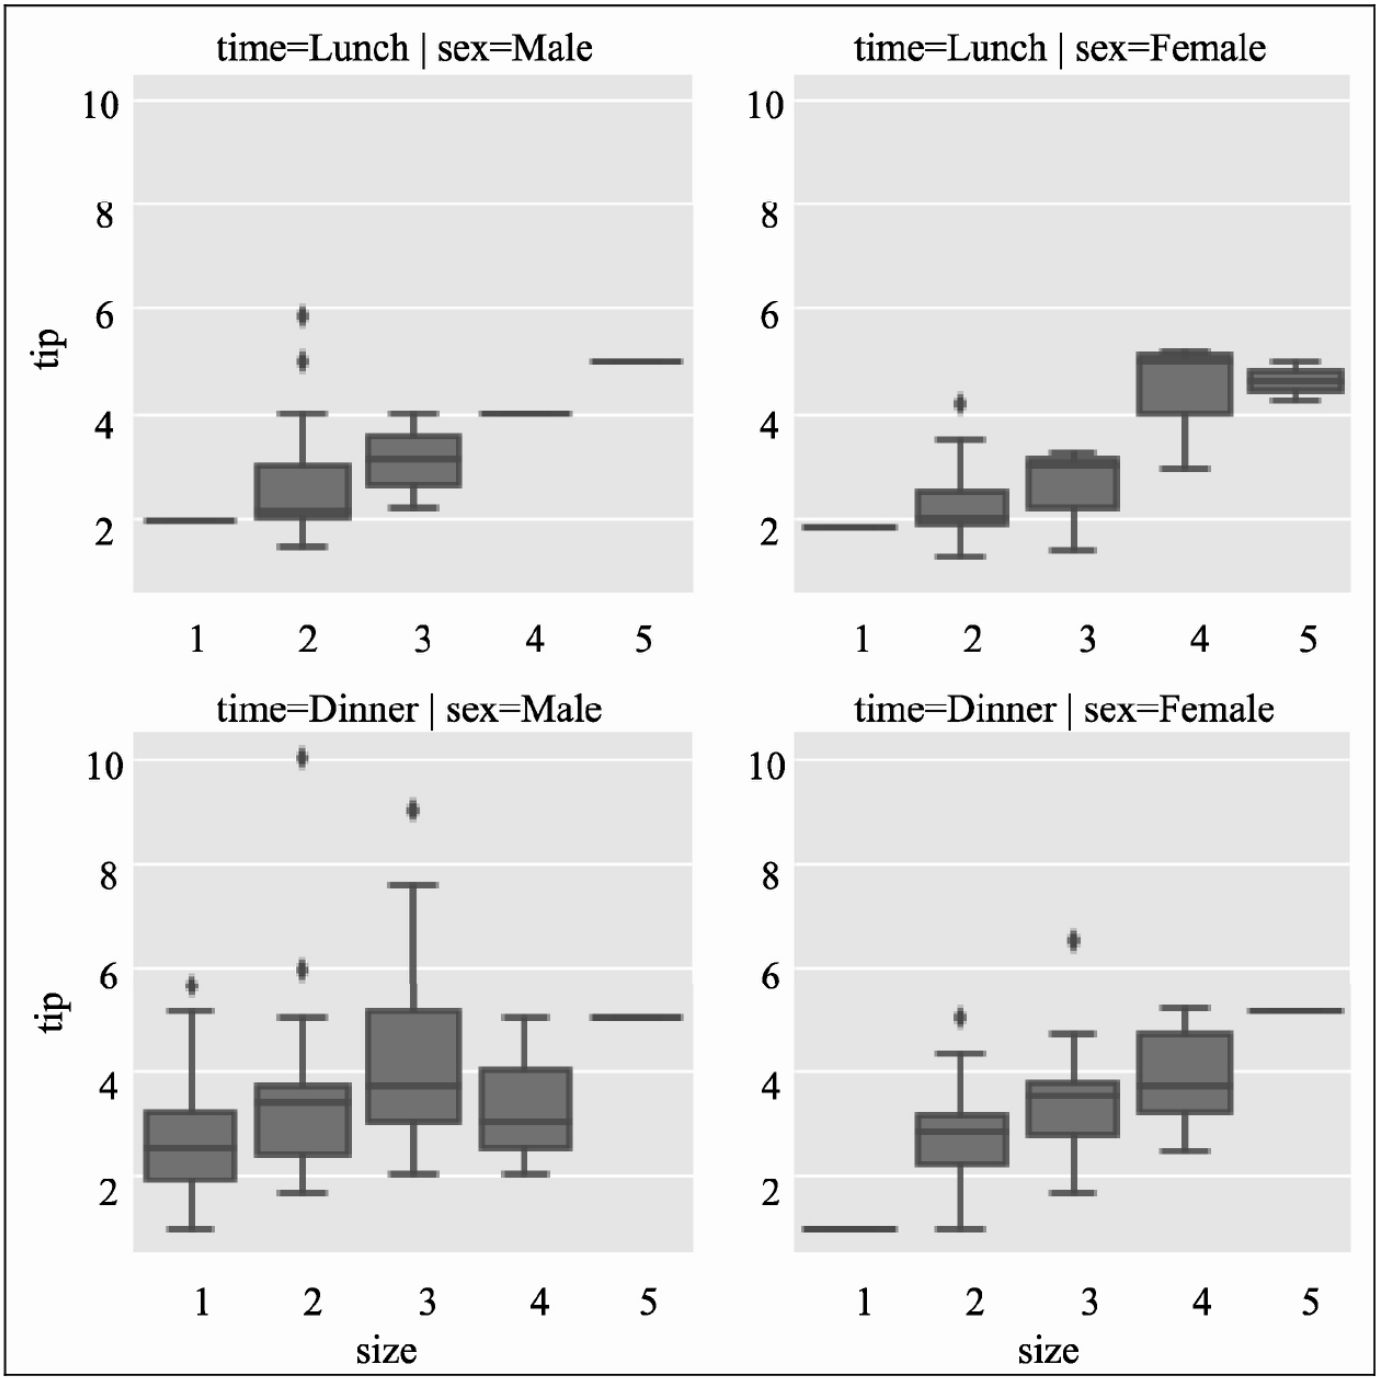

图8.34　网格技术绘图3

8.4　综合示例——泰坦尼克号生还者数据

本节以泰坦尼克号的生还者数据为例，讲解seaborn的可视化方法和技巧。

8.4.1　数据来源

本例使用seaborn中自带的泰坦尼克号生还乘客的数据集，如图8.35所示。

其中，主要的字段有：survived和alive为乘客的生还情况；pclass与class为船舱等级；sex和who为乘客性别；age为乘客年龄；silbsp和parch为是否带有家属，后面统一用alone字段代表是否有家属；fare为船票价格；embarked和embarked_town为上船地点。

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
```

```
titanic = sns.load_dataset("titanic")
titanic.head()
```

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive	alone
0	0	3	male	22.0	1	0	7.2500	S	Third	man	True	NaN	Southampton	no	False
1	1	1	female	38.0	1	0	71.2833	C	First	woman	False	C	Cherbourg	yes	False
2	1	3	female	26.0	0	0	7.9250	S	Third	woman	False	NaN	Southampton	yes	True
3	1	1	female	35.0	1	0	53.1000	S	First	woman	False	C	Southampton	yes	False
4	0	3	male	35.0	0	0	8.0500	S	Third	man	True	NaN	Southampton	no	True

图8.35　数据情况

注意：这里的数据与kaggle上的竞赛题略有不同，已进行过处理。

8.4.2　定义问题

本次分析中提出两个问题：泰坦里克号乘客的基本信息分布情况；乘客的信息与生还数据是否有关联。

8.4.3　数据清洗

首先查看是否有缺失值，如图8.36所示。

```
titanic.isnull().sum()
```

```
survived      0
pclass        0
sex           0
age         177
sibsp         0
parch         0
fare          0
```

```
fare            0
embarked        2
class           0
who             0
adult_male      0
deck          688
embark_town     2
alive           0
alone           0
dtype: int64
```

图8.36　查看缺失值

然后对年龄缺失值进行处理。通过seaborn的distplot函数查看乘客的年龄分布，效果如图8.37所示。代码如下：

```
sns.set(style="darkgrid", palette="muted", color_codes=True)
sns.distplot(titanic[titanic['age'].notnull()]['age'])
```

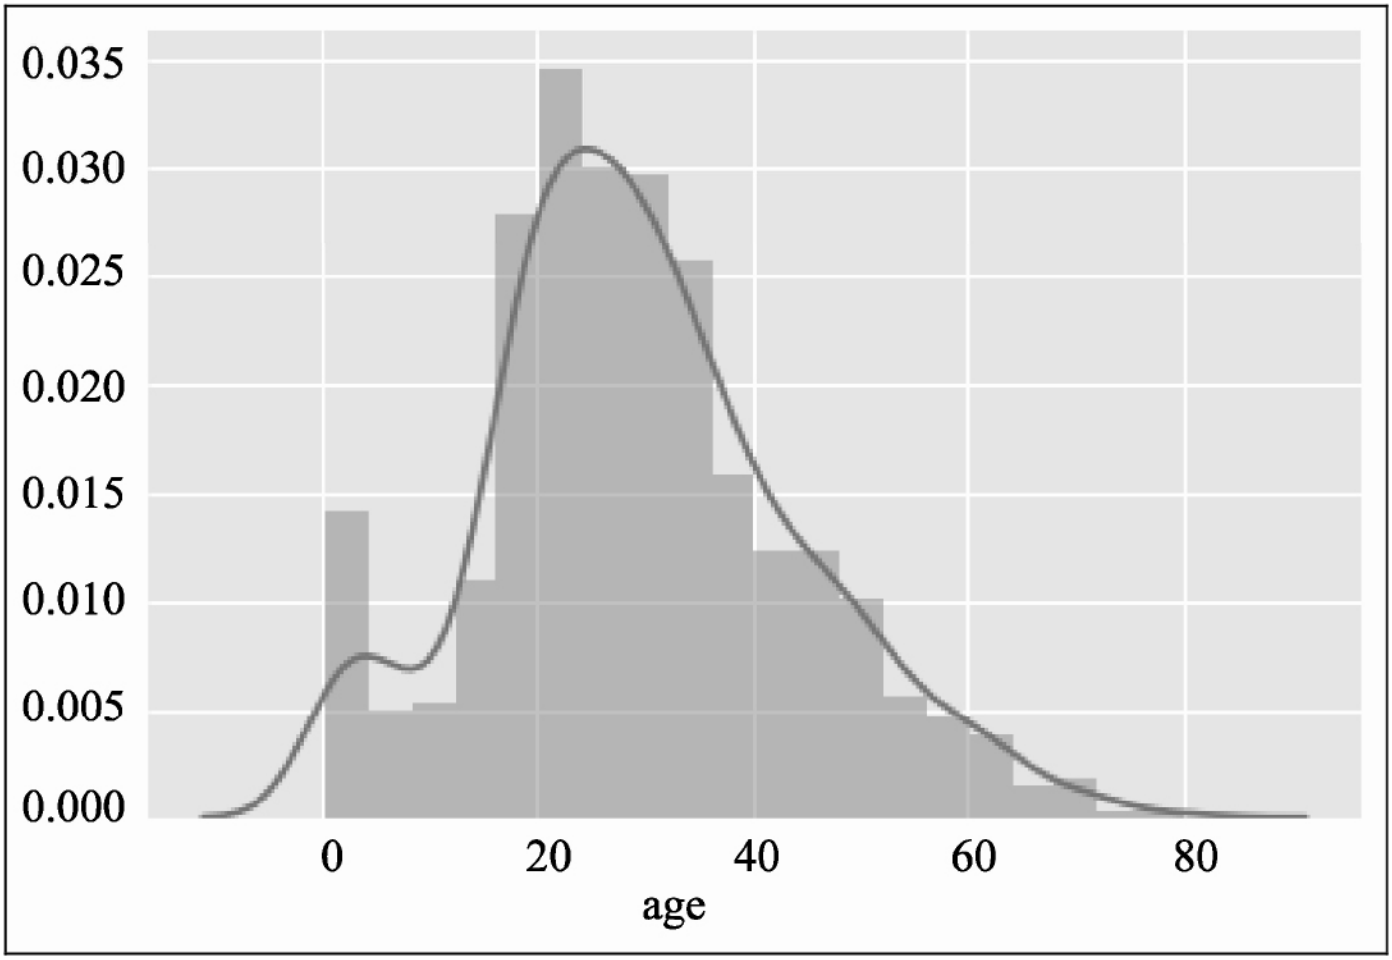

图8.37　年龄分布

这里发现年龄呈正态分布，于是用年龄的均值进行缺失值的填充，再进行年龄分布的可视化，效果如图8.38所示。代码如下：

```
titanic['age'] = titanic['age'].fillna(titanic['age'].mean())
sns.distplot(titanic['age'])
```

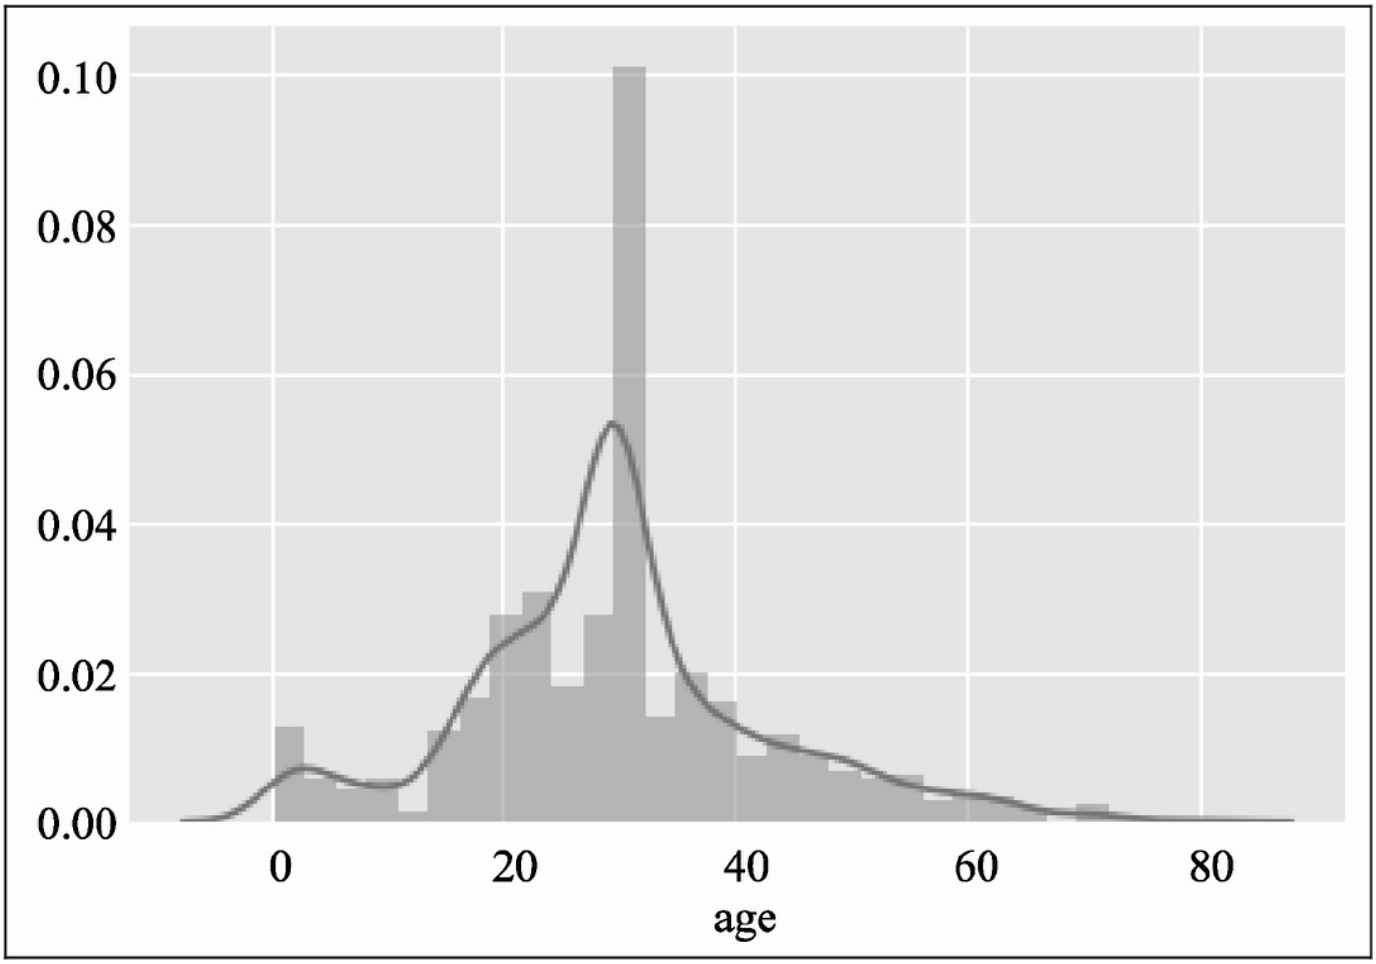

图8.38　年龄插值

然后利用countplo方法对embarked进行可视化，效果如图8.39所示。代码如下：

```
sns.countplot(x="embarked",data=titanic)
```

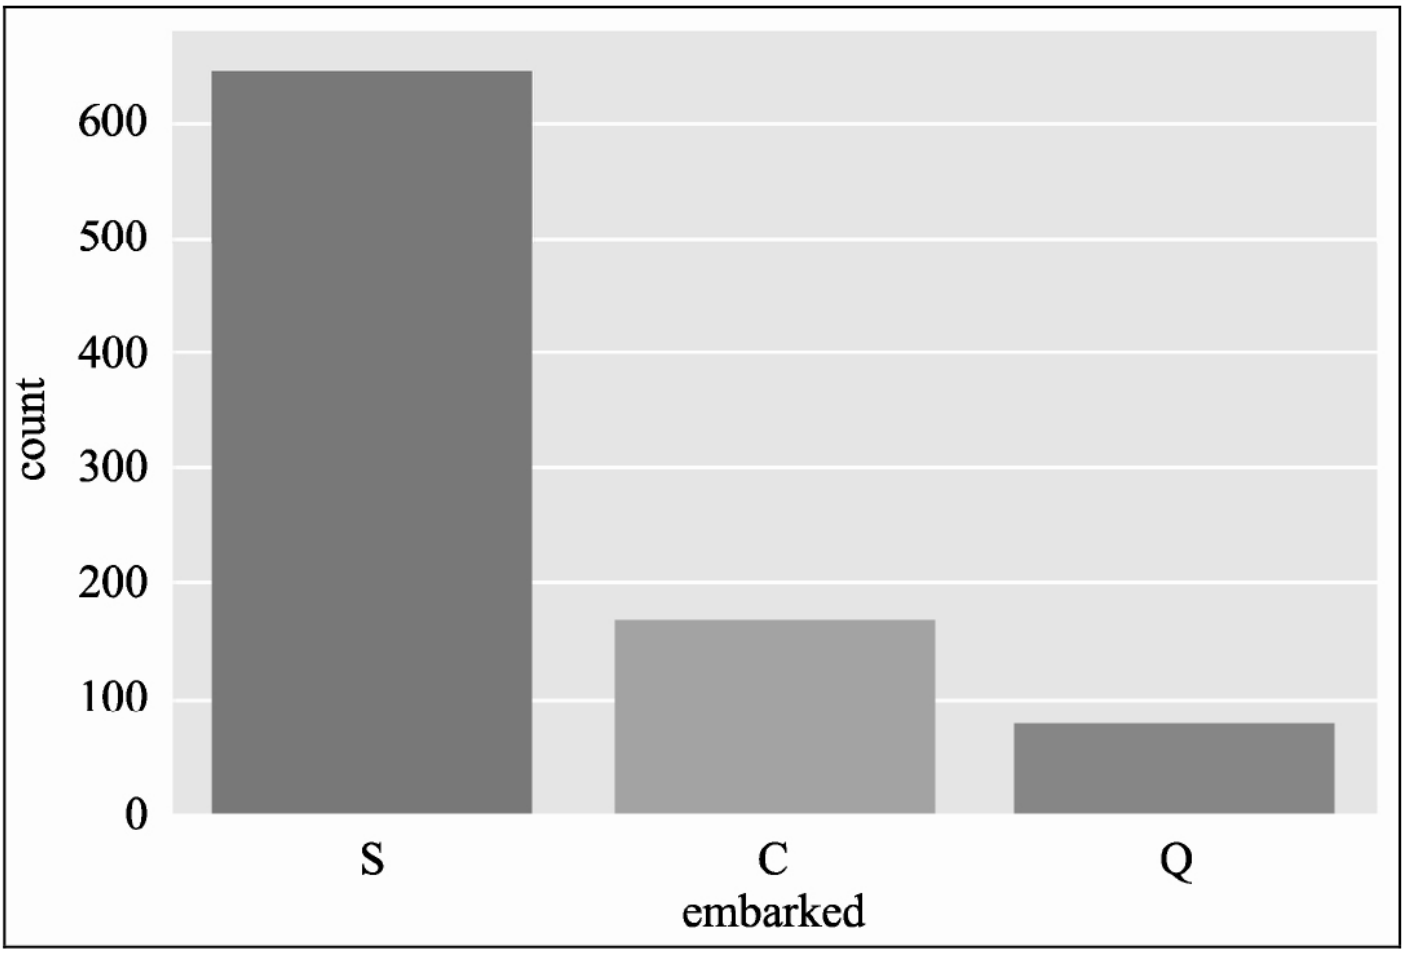

图8.39　embarked计数

接着再利用正确的登船地点S进行缺失值的填充，效果如图8.40所示。代码如下：

```
titanic['embarked'] = titanic['embarked'].fillna('S')
titanic.isnull().sum()
```

```
survived         0
pclass           0
sex              0
age              0
sibsp            0
parch            0
fare             0
embarked         0
class            0
who              0
adult_male       0
deck           688
embark_town      2
alive            0
alone            0
dtype: int64
```

图8.40　填充embarked字段

对于deck字段，由于缺失值太多，因此将其删除；数据中有许多多余字段，在这里一次性进行删除。如图8.41所示为数据清洗后的数据。代码如下：

```
titanic
titanic.drop(['survived','pclass','sibsp','parch','who','
adult_male','deck','embark_town'],axis=1)
titanic.head()
```

	sex	age	fare	embarked	class	alive	alone
0	male	22.0	7.2500	S	Third	no	False
1	female	38.0	71.2833	C	First	yes	False
2	female	26.0	7.9250	S	Third	yes	True
3	female	35.0	53.1000	S	First	yes	False
4	male	35.0	8.0500	S	Third	no	True

图8.41　清洗后的数据

8.4.4 数据探索

首先可视化乘客的性别分布，效果如图8.42所示。由图可知，男性乘客比女性乘客更多一些。代码如下：

```
sns.countplot(x="sex",data=titanic)
```

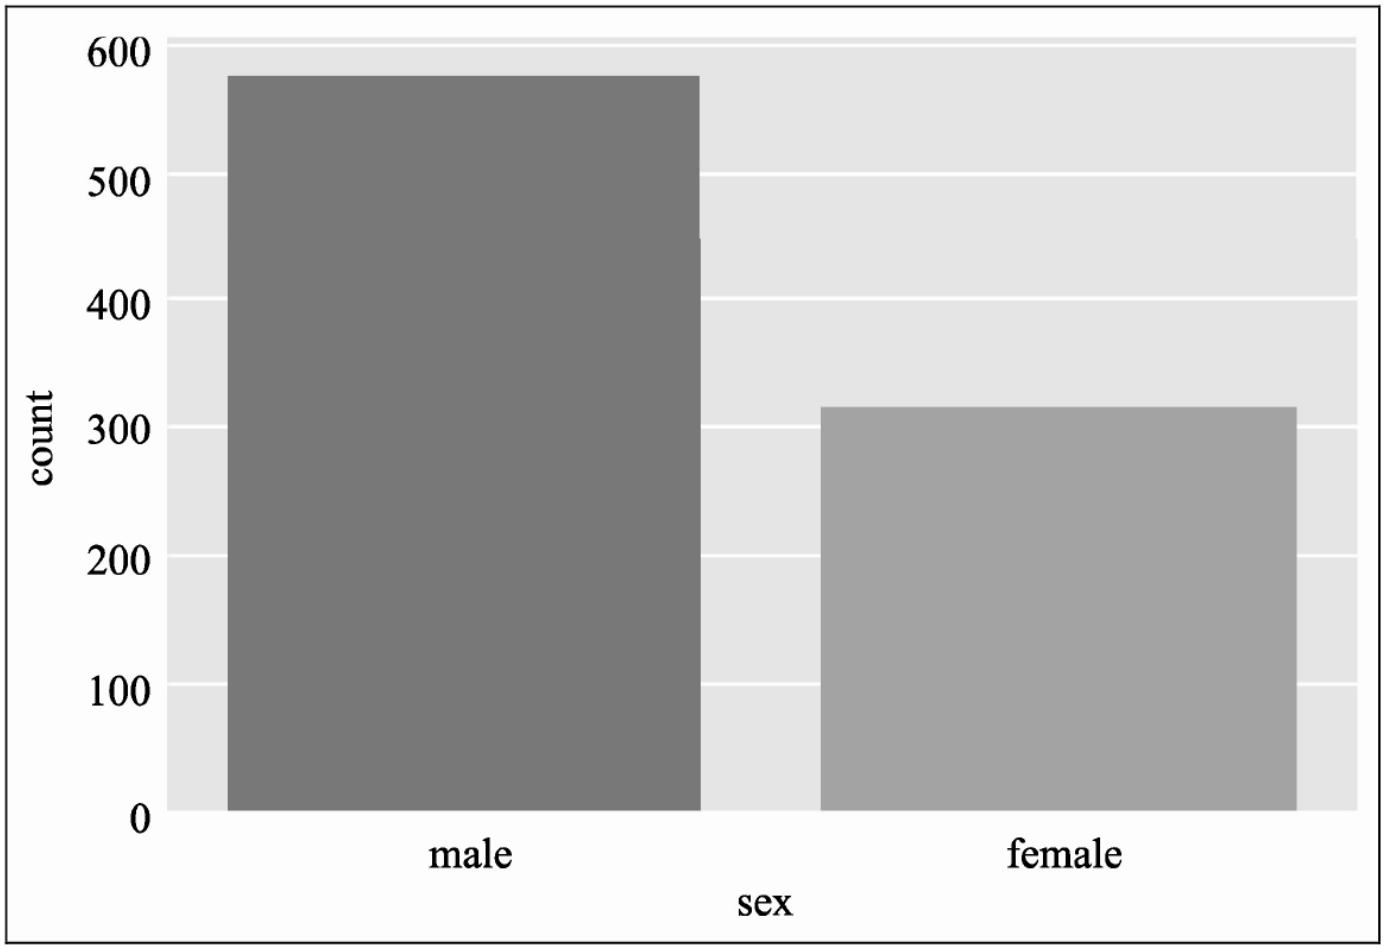

图8.42 性别分布

然后结合性别，绘制乘客年龄分布箱线图，效果如图8.43所示。由图可以看出，男性与女性的年龄分布很接近，但女性乘客的年龄跨度更大一些。代码如下：

```
sns.boxplot(x='sex',y='age',data=titanic)
```

接着对船舱等级进行计数，效果如图8.44所示。由图可以看出，第三级船舱数量最多。代码如下：

```
sns.countplot(x="class",data=titanic)
```

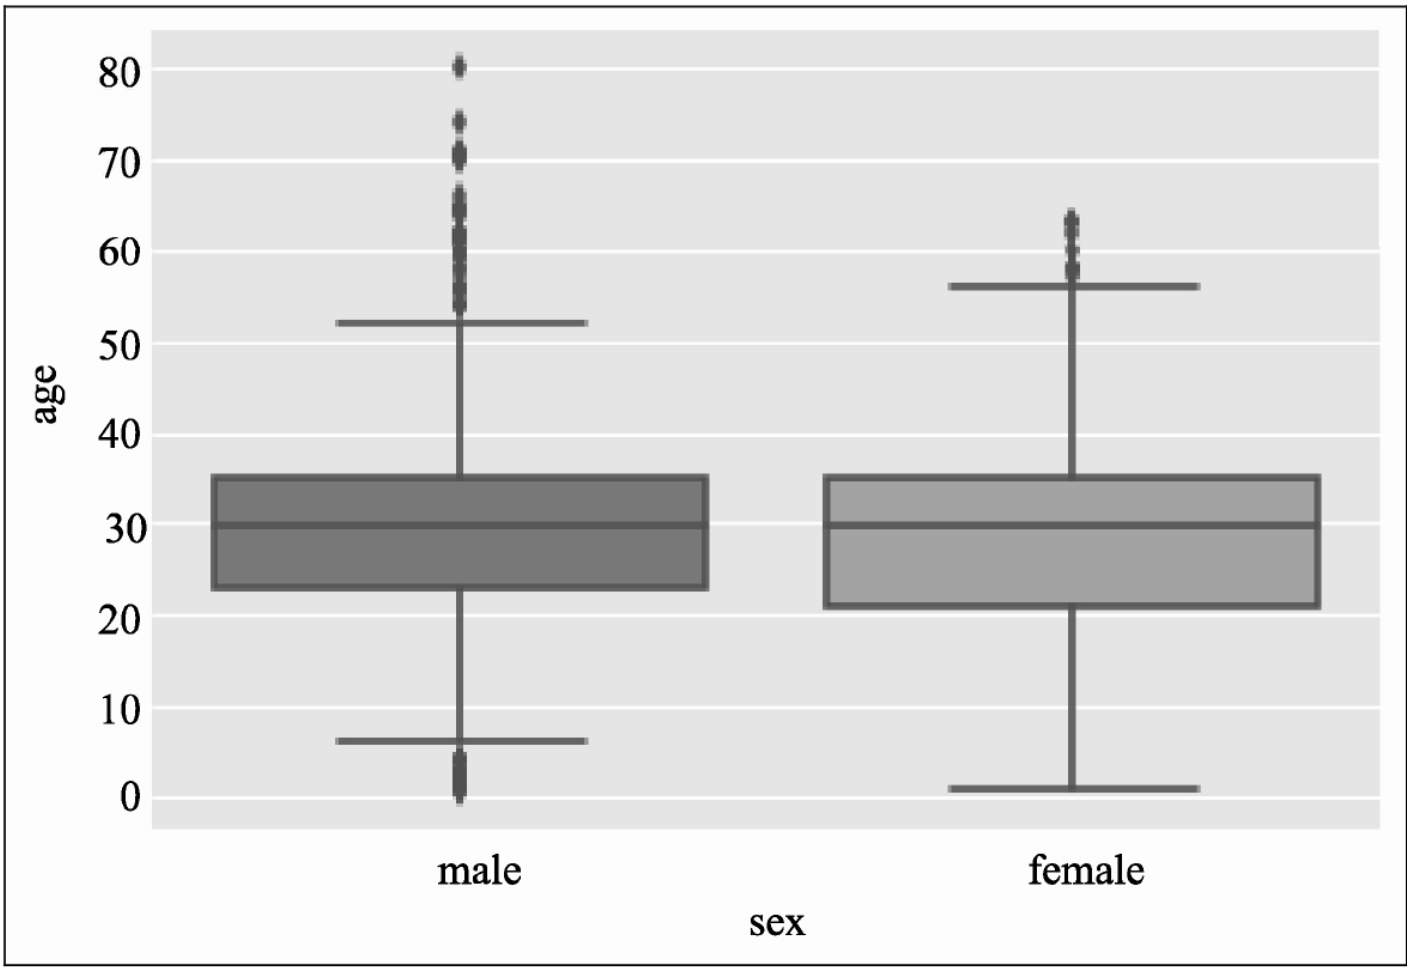

图8.43　性别、年龄分布箱线图

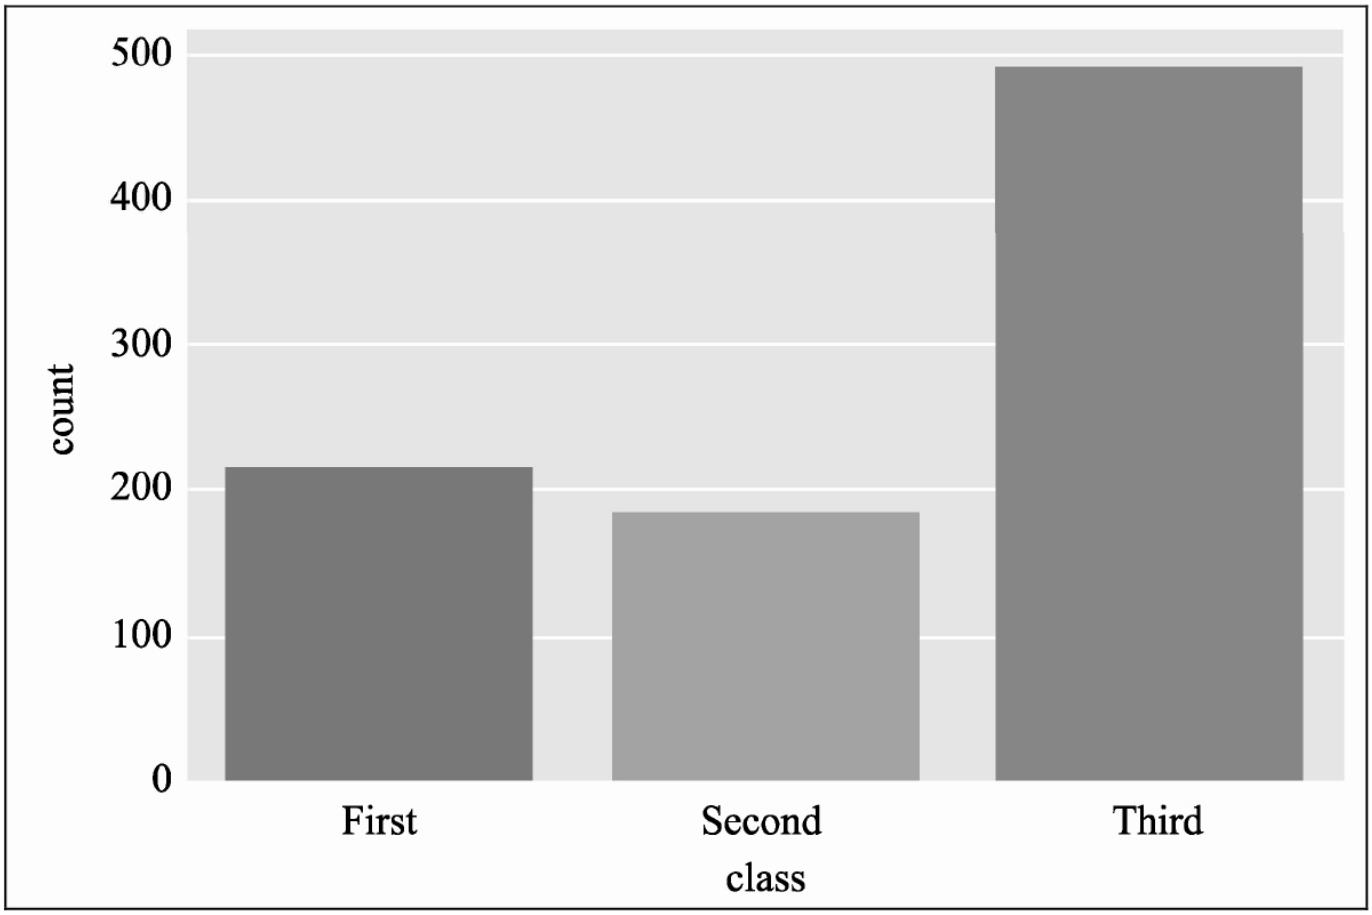

图8.44　船舱等级数量分布

然后再结合船舱等级，绘制乘客年龄分布箱线图，效果如图8.45所示。由图中可以看出，头等舱的年龄跨度较大，第三级船舱的中年人分布最多。代码如下：

```
sns.violinplot(x="class", y="age", data=titanic)
```

接着对alone字段进行计数，效果如图8.46所示》由图可以看出，单独的乘客数量更多一些。代码如下：

```
sns.countplot(x="alone",data=titanic)
```

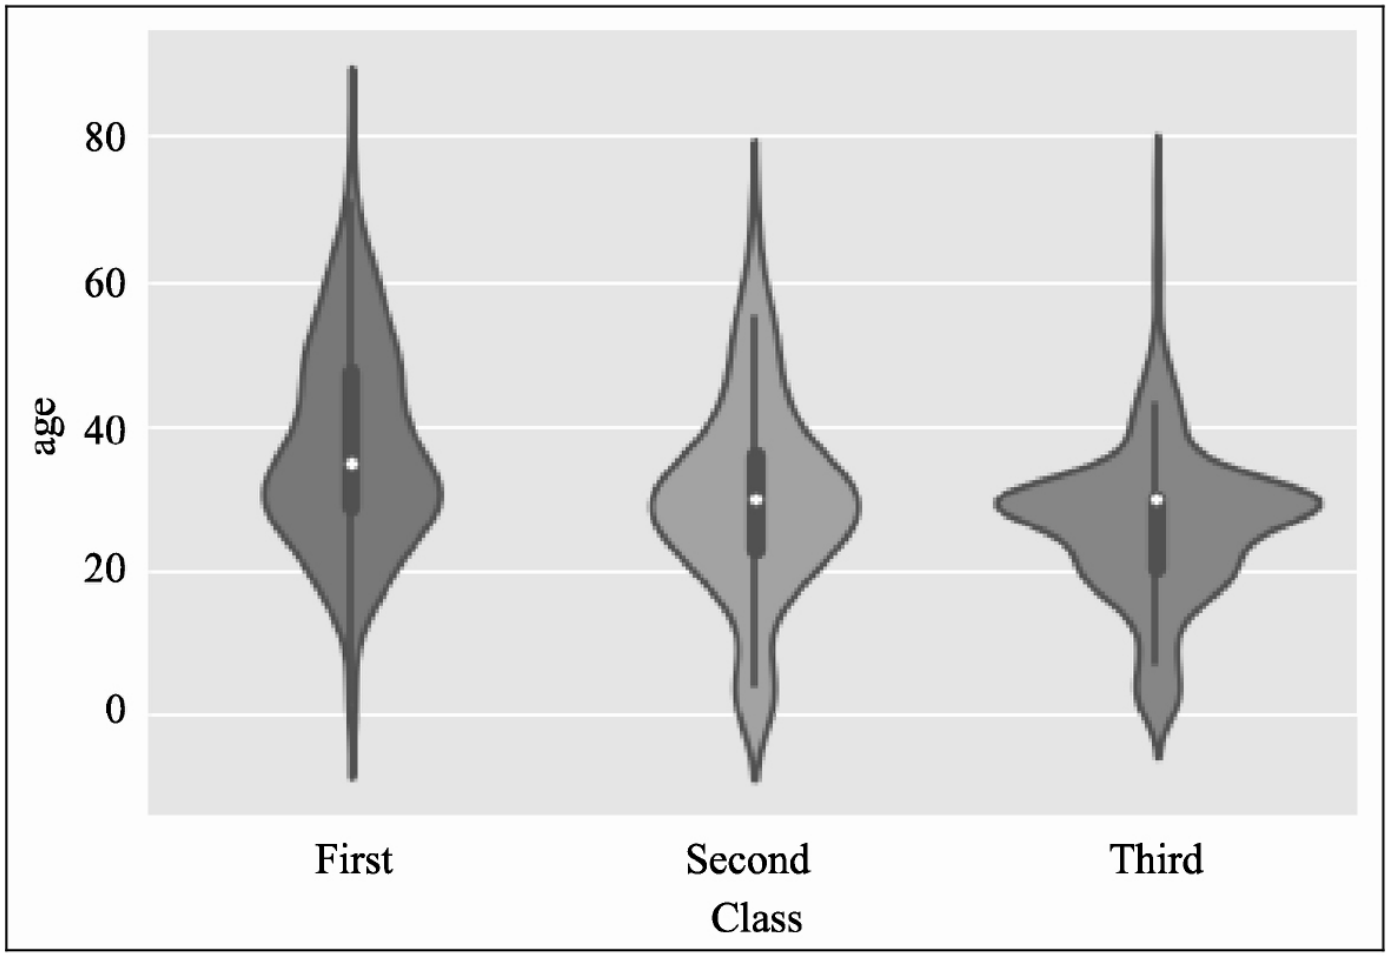

图8.45　船仓等级年龄分布

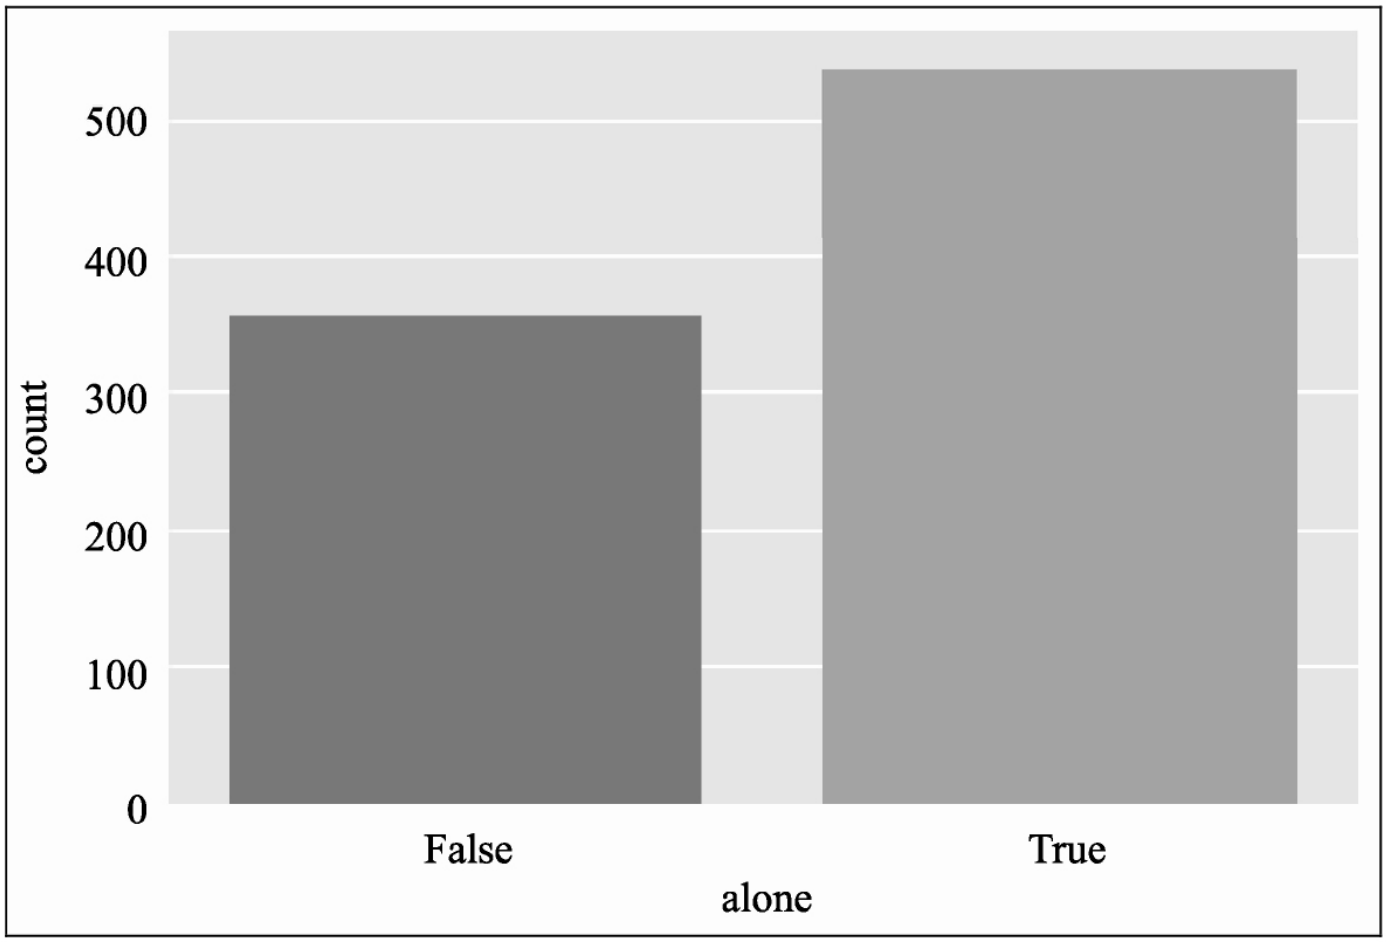

图8.46　alone分布

接下来重点分析生还乘客与其他字段之间是否有关联。首先，对生还字段计数可视化，效果如图8.47所示。从图中可以看出，未生还的乘客人数更多一些。代码如下：

```
sns.countplot(x="alive",data=titanic)
```

一般，女性在特殊情况下会被优先考虑。如图8.48所示，生还乘客中女性占大多数，代码如下：

```
sns.countplot(x='alive',hue='sex',data=titanic)
```

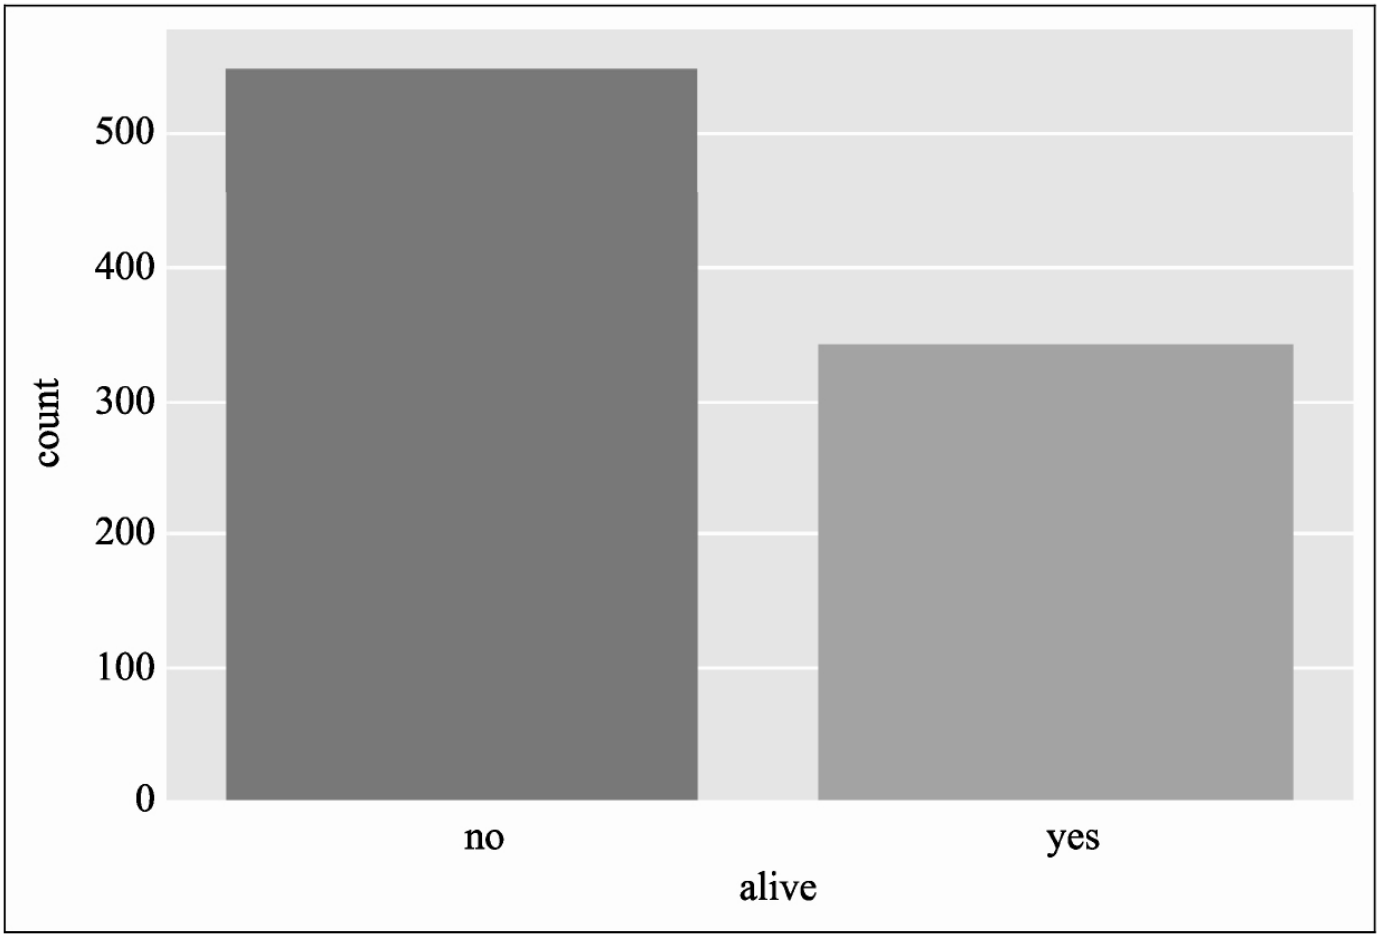

图8.47　生还乘客分布

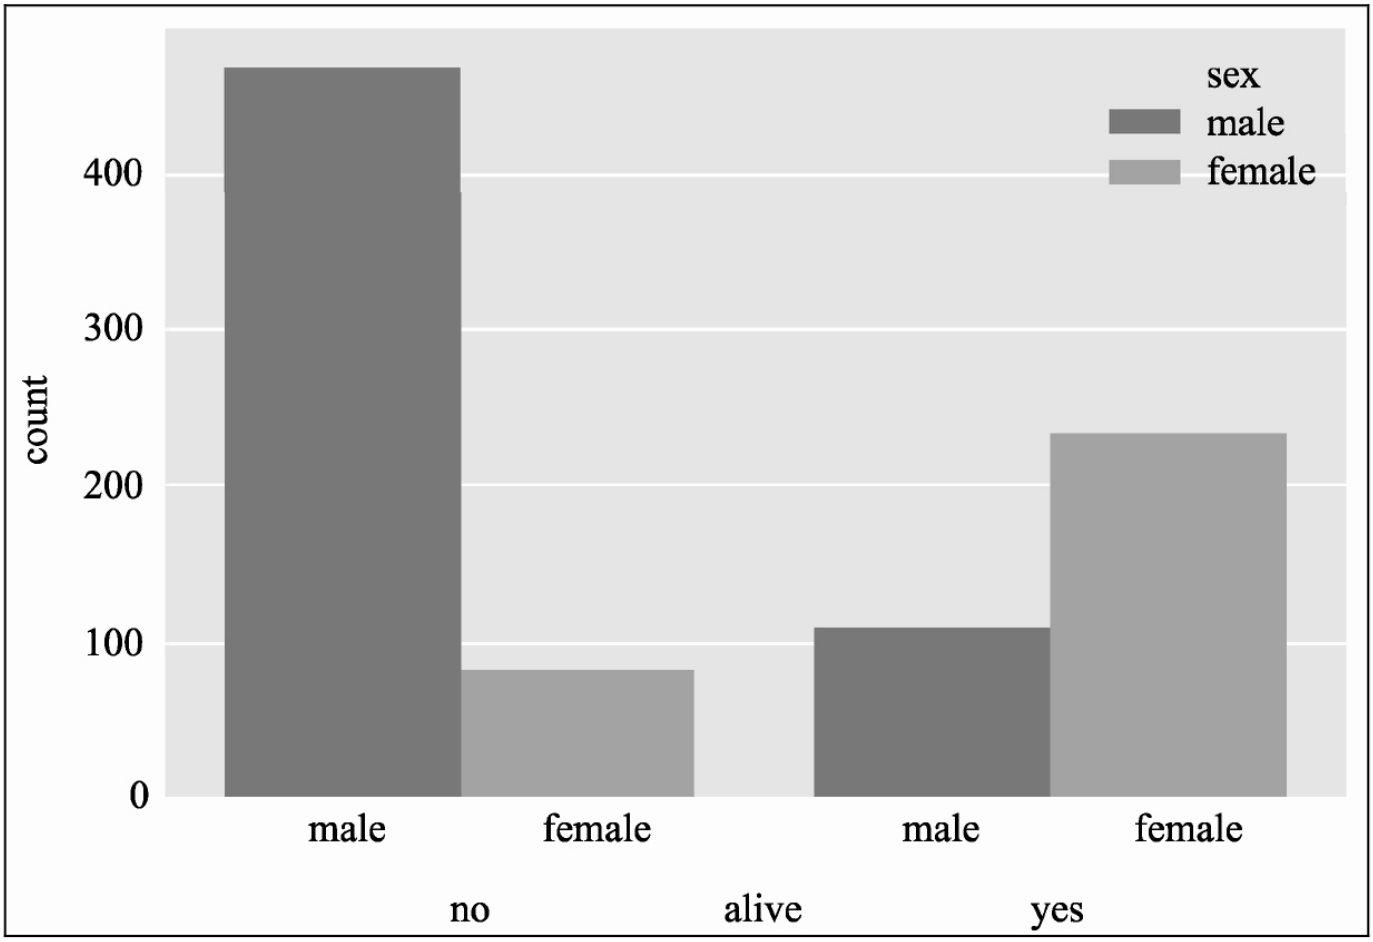

图8.48　乘客性别与生还关系1

利用网格技术，可以进行更好的对比，效果如图8.49所示。代码如下：

```
g = sns.FacetGrid(titanic, col='sex')
```

```
g.map(sns.countplot, 'alive')
```

此外，老人和小孩也是优先考虑的对象，因此这里对年龄进行分级，分开小孩和老人的数据，数据如图8.50所示。代码如下：

```
def agelevel(age):
    if age <= 16:
        return 'child'
    elif age >= 60:
        return 'aged'
    else:
        return 'midlife'

titanic['age_level'] = titanic['age'].map(agelevel)
```

图8.49　乘客性别与生还关系2

```
titanic.head()
```

	sex	age	fare	embarked	class	alive	alone	age_level
0	male	22.0	7.2500	S	Third	no	False	midlife
1	female	38.0	71.2833	C	First	yes	False	midlife
2	female	26.0	7.9250	S	Third	yes	True	midlife
3	female	35.0	53.1000	S	First	yes	False	midlife
4	male	35.0	8.0500	S	Third	no	True	midlife

图8.50　年龄分级

然后对分级后的年龄进行可视化，效果如图8.51所示。由图可以看出，成年人乘客数量占比很大，而小孩和年长乘客的占比较小。代码如下：

```
sns.countplot(x='age_level',data=titanic)
```

如图8.52所示，乘客年龄与生还乘客之间的关系并不明显，但小孩的生还几率还是比较大的，而老人却相对更小。

```
sns.countplot(x='alive',hue='age_level',data=titanic)
```

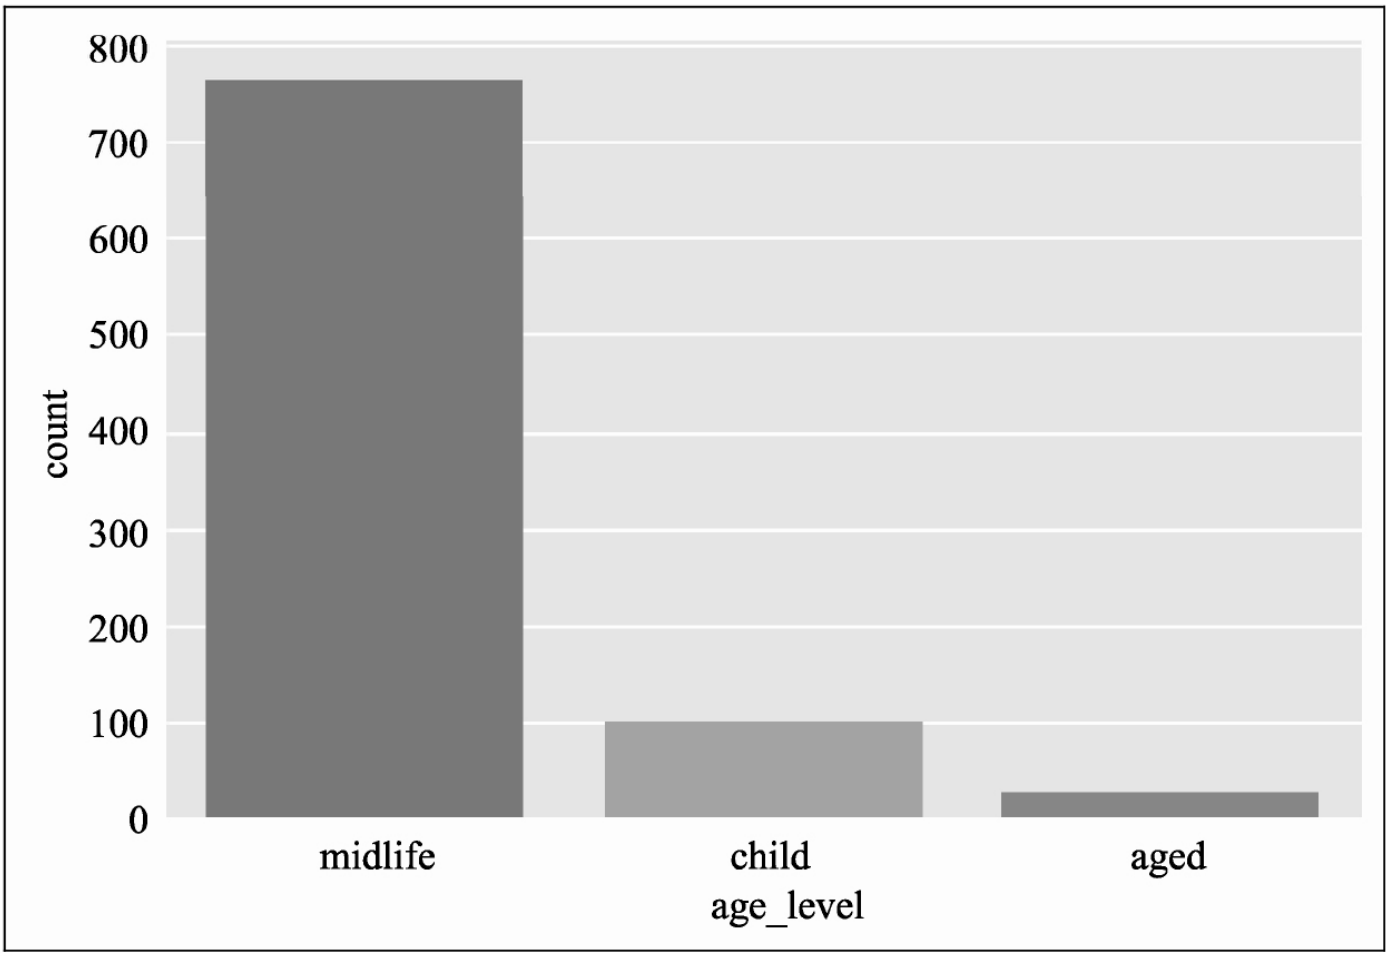

图8.51　乘客年龄等级分布

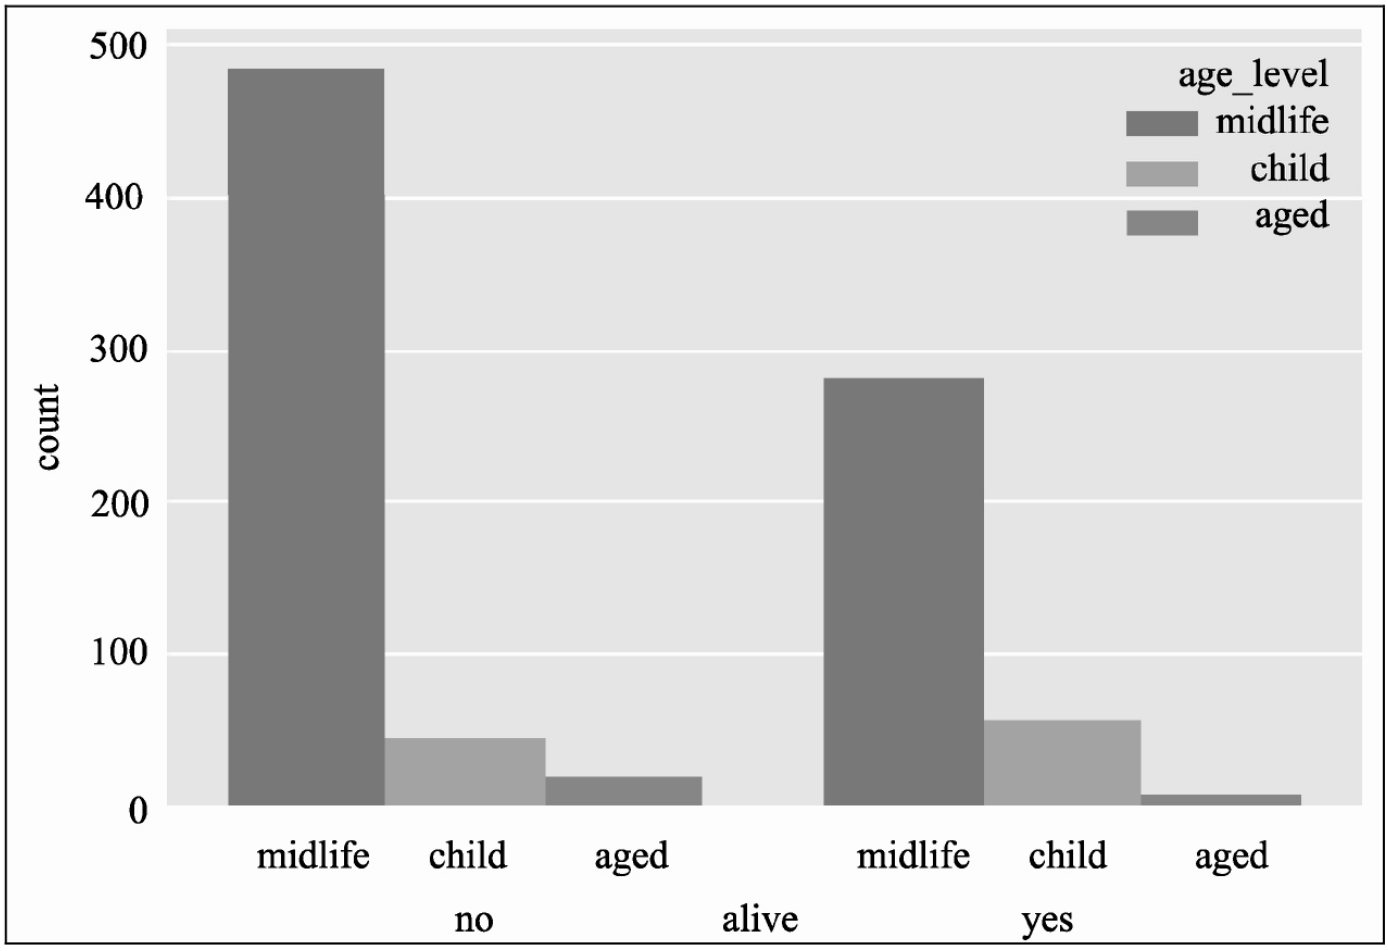

图8.52　乘客年龄与生还关系

最后结合class和alone字段进行分析，效果如图8.53所示。由图可以看出，乘客舱位等级越高，生还的几率越大，单独的乘客生还的几率也更大一些。代码如下：

```
g = sns.FacetGrid(titanic, col='class', row='alone')
g.map(sns.countplot, 'alive')
```

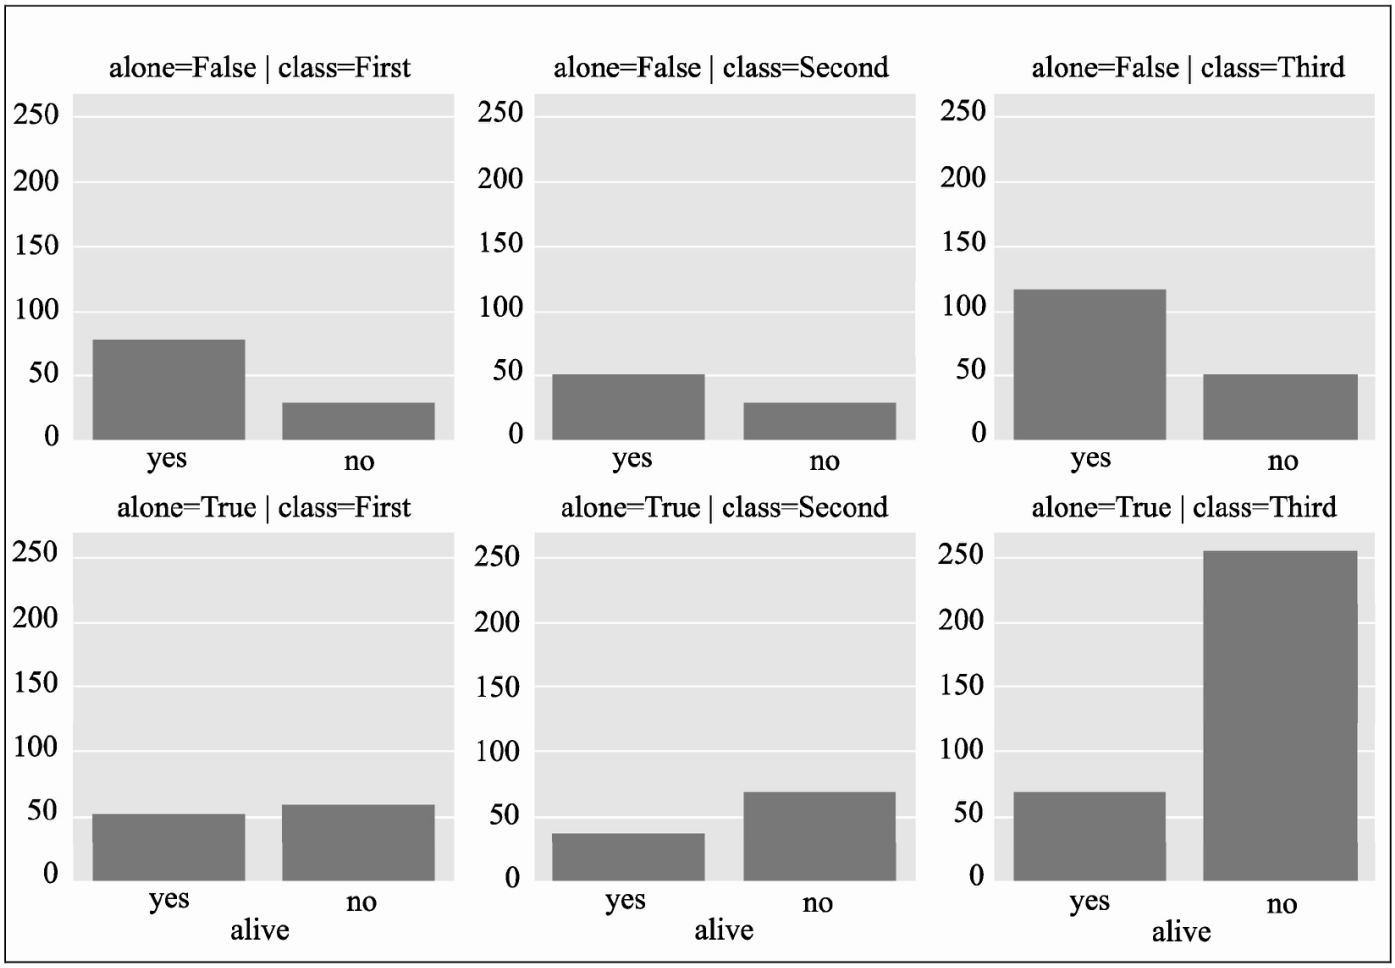

图8.53　舱位等级（class）、是否有家属（alone）字段与生还关系

第9章　pyecharts可视化

pyecharts是一个用于生成Echarts图表的类库；而Echarts是百度开源的一个数据可视化JavaScnpt库。使用pyecharts绘制的图表美观且具有交互性。本章首先讲解如何安装pyecharts库；如何使用pyecharts库绘制基本图表；如何绘制其他各类图表。最后通过一个综合示例，巩固pyecharts的绘制方法和技巧。

下面给出本章涉及的知识点与学习目标。

· pyecharts库：学会该库的安装和基本用法。

· 其他图表：学会绘制饼图和箱线图。

9.1　基础图表

pyecharts绘制的图表不仅美观而且操作简单。本节将讲解如何通过pip工具安装pyecharts库，并介绍绘制散点图、折线图和柱状图的方法。

9.1.1　pyecharts安装

pyecharts库使用PIP工具安装即可，具体见图9.1所示。

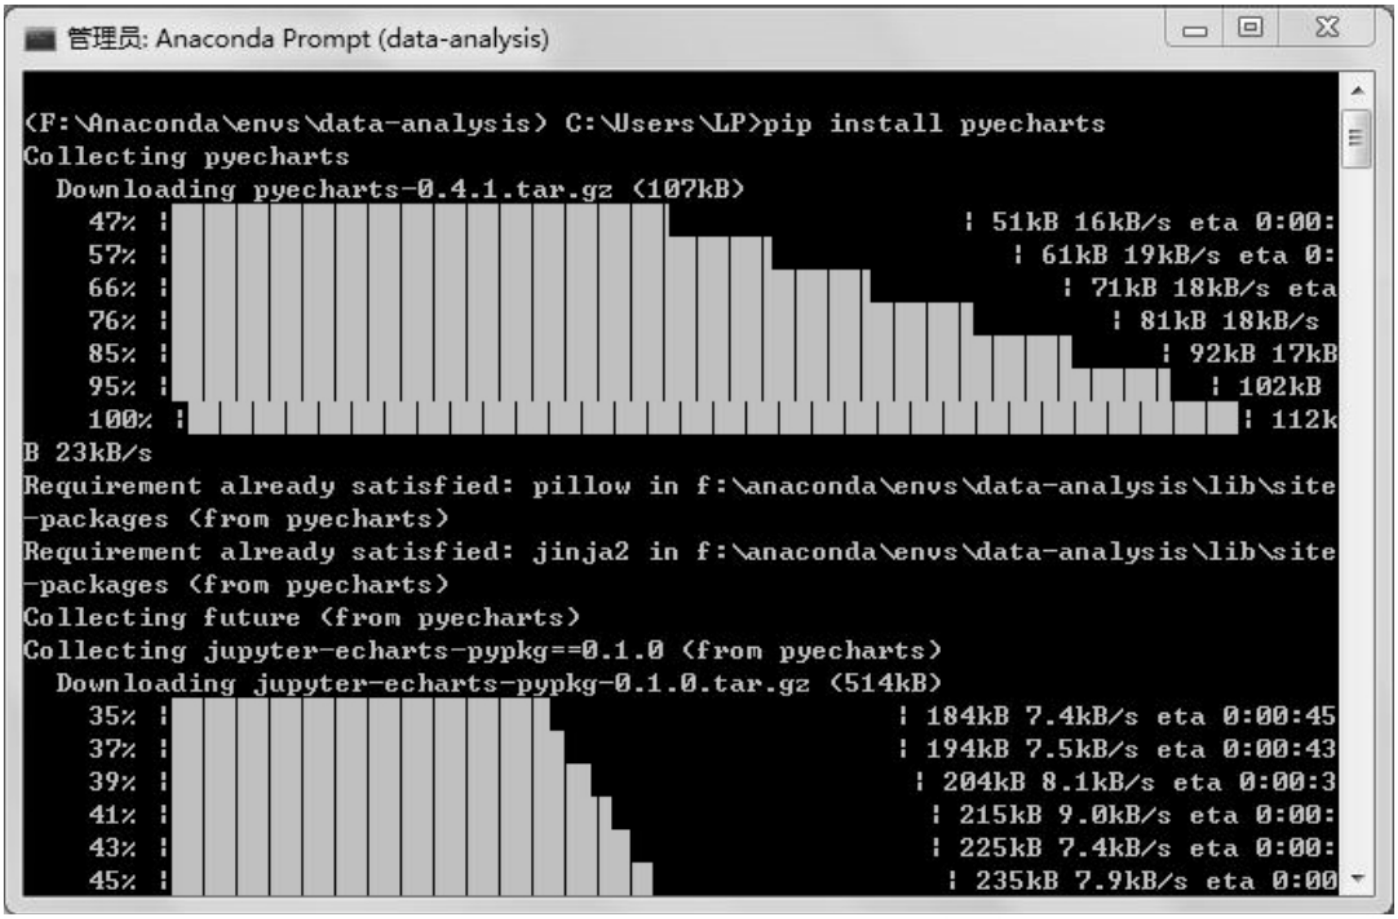

图9.1　安装pyecharts

如果显示如图9.2所示的提示，则表示安装成功。

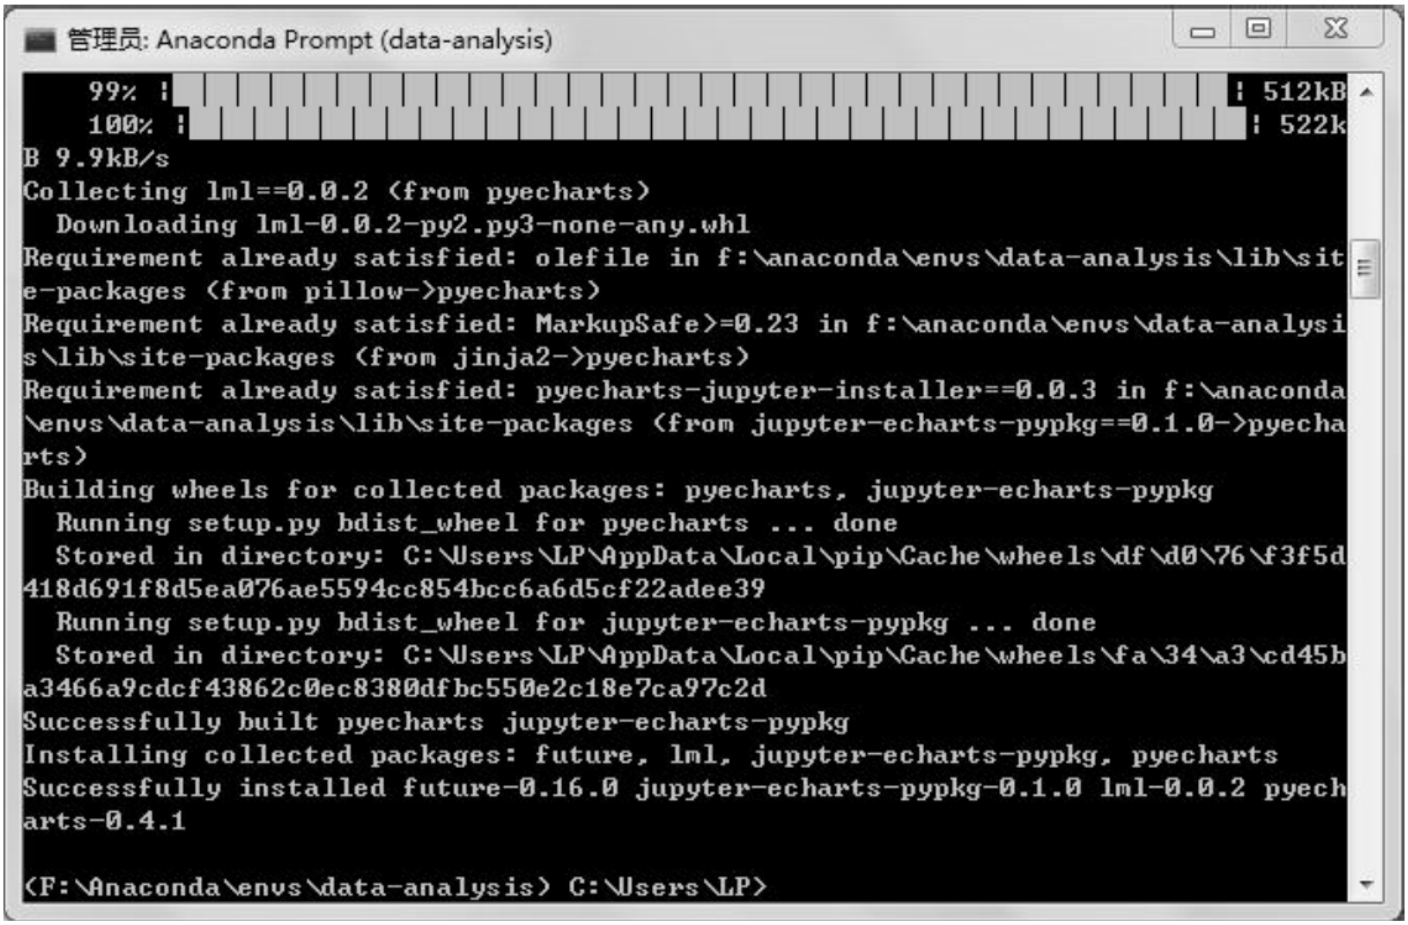

图9.2　安装成功

9.1.2 散点图

pyecharts库可绘制多种图形。利用Scatter方法可绘制散点图，代码如下：

```
import numpy as np
import pandas as pd
import pyecharts

x = [10, 20, 30, 40, 50, 60]
y = [10, 20, 30, 40, 50, 60]
scatter = pyecharts.Scatter("散点图示例")                    #加入标题
scatter.add('A', x, y)                                       #绘制散点图
scatter
```

pyecharts绘图的核心代码是add方法，该方法用于添加图表的数据和设置各种配置项。在scatter中，add函数的参数如下，其中，name为图例名称，后面依次为x轴和y轴，symbol_size为散点图大小，默认为10。

```
add(name, x_axis, y_axis,
    extra_data=None,
symbol_size=10, **kwargs)
```

绘制的散点图如图9.3所示。

利用Visualmap组件，可以通过图形点大小映射数值，效果如图9.4所示。代码如下：

```
x = [10, 20, 30, 40, 50, 60]
y = [10, 20, 30, 40, 50, 60]
scatter = pyecharts.Scatter("散点图示例")
scatter.add('A', x, y, is_visualmap=True,
            visual_type='size', visual_range_size=[10, 60])
scatter
```

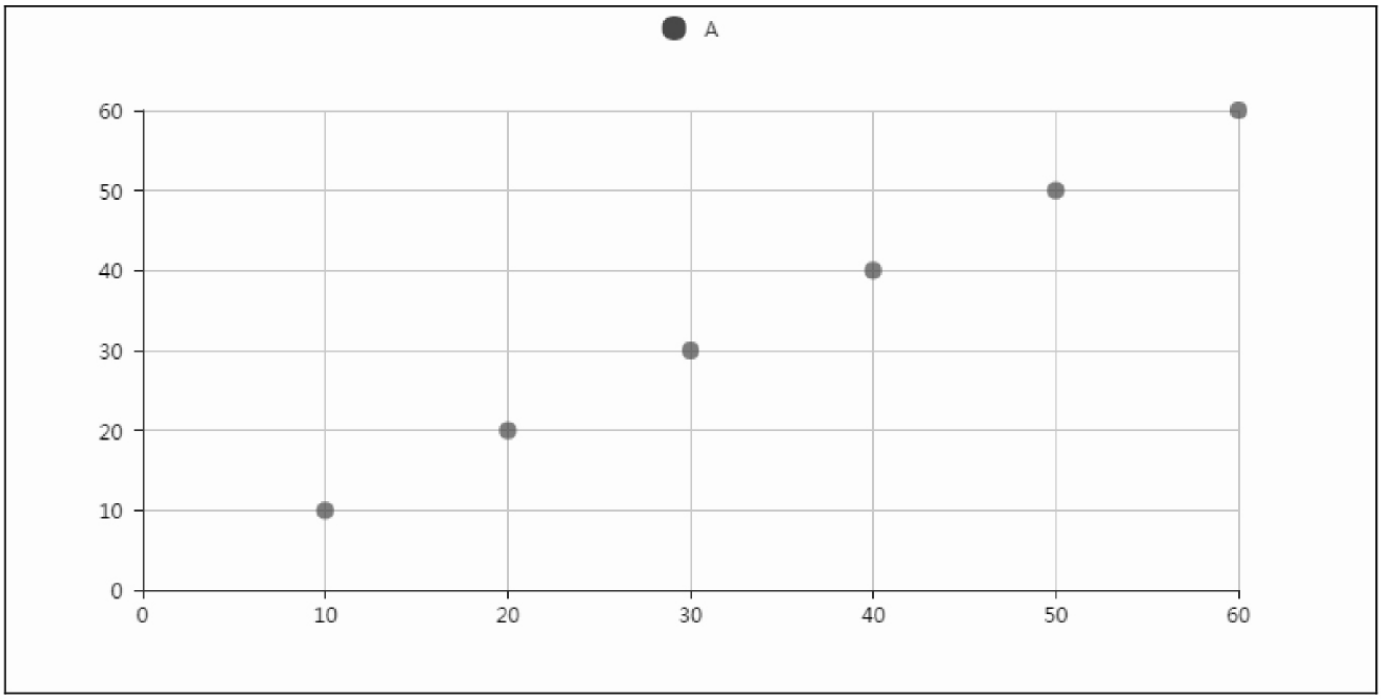

图9.3 散点图1

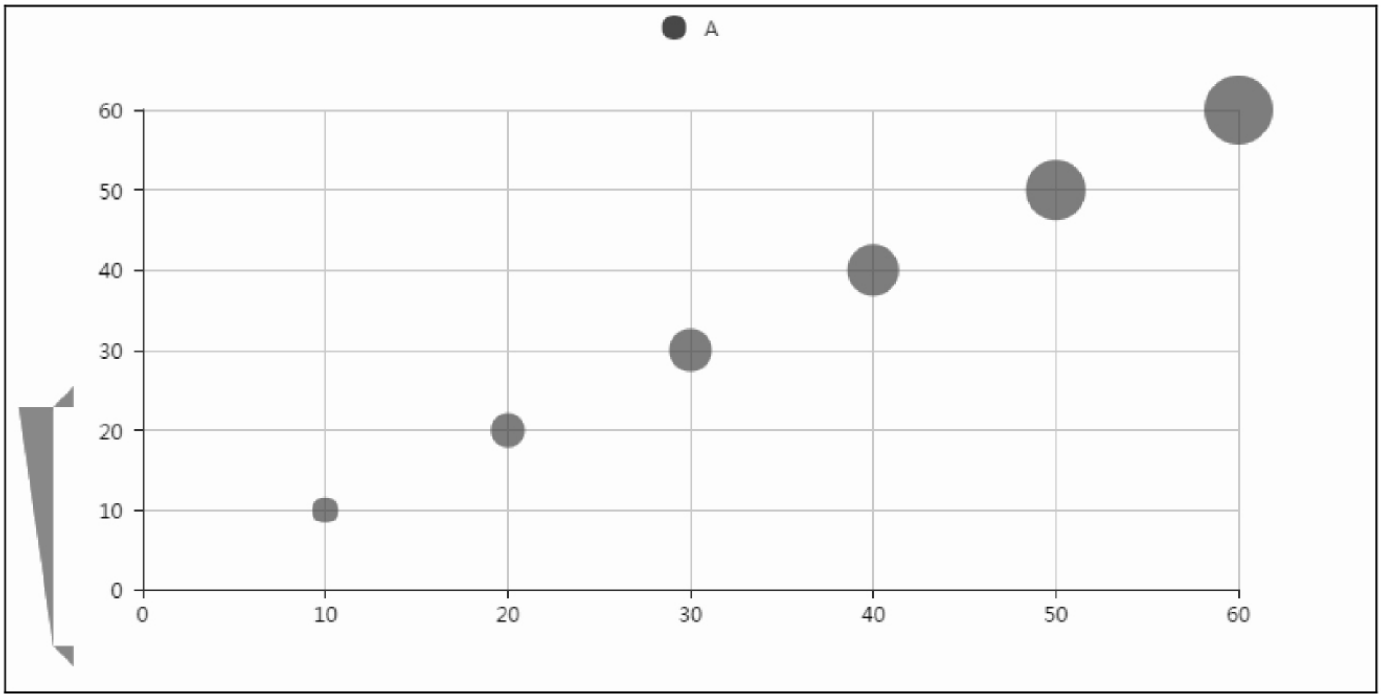

图9.4　散点图2

9.1.3　折线图

利用Line方法可绘制折线图，代码如下：

```
years = [1950, 1960, 1970, 1980, 1990, 2000, 2010]
gdp = [300.2, 543.3, 1075.9, 2862.5, 5979.6, 10289.7, 14958.3]
line = pyecharts.Line("折线图示例")
line.add("GDP", years, gdp, mark_point=["average"])                    #标记平均值
line
```

下面给出line.add方法的参数。is_symbol_show显示标记图形；is_smooth显示平滑曲线；is_stack显示数据堆叠；is_step设置阶梯线图；is_fill绘制面积图，具体代码如下：

```
add(name, x_axis, y_axis,
    is_symbol_show=True,
    is_smooth=False,
    is_stack=False,
    is_step=False,
is_fill=False, **kwargs)
```

绘制的折线图如图9.5所示。

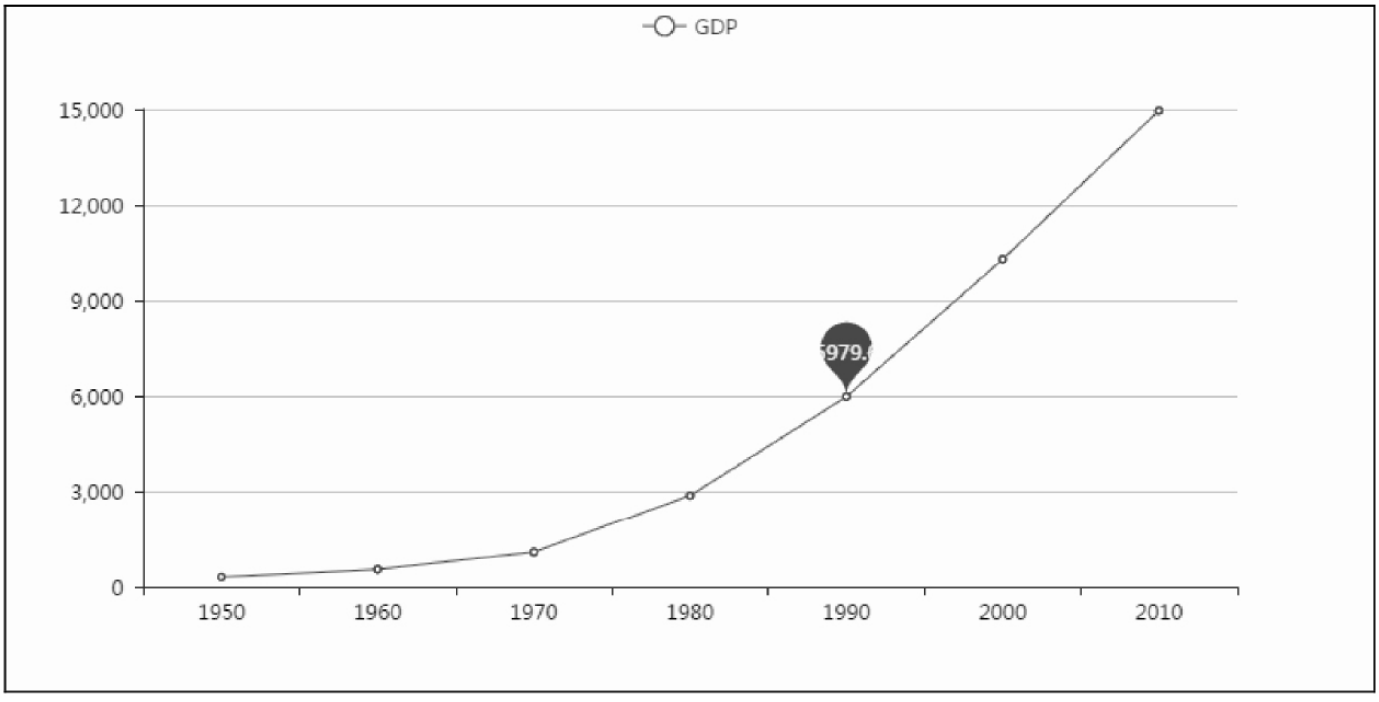

图9.5　折线图

下面给出通过设置is_step参数绘制阶梯图的代码，最终的效果如图9.6所示。

```
years = [1950, 1960, 1970, 1980, 1990, 2000, 2010]
gdp = [300.2, 543.3, 1075.9, 2862.5, 5979.6, 10289.7, 14958.3]
line = pyecharts.Line("阶梯图")
line.add("GDP", years, gdp, is_step=True)
line
```

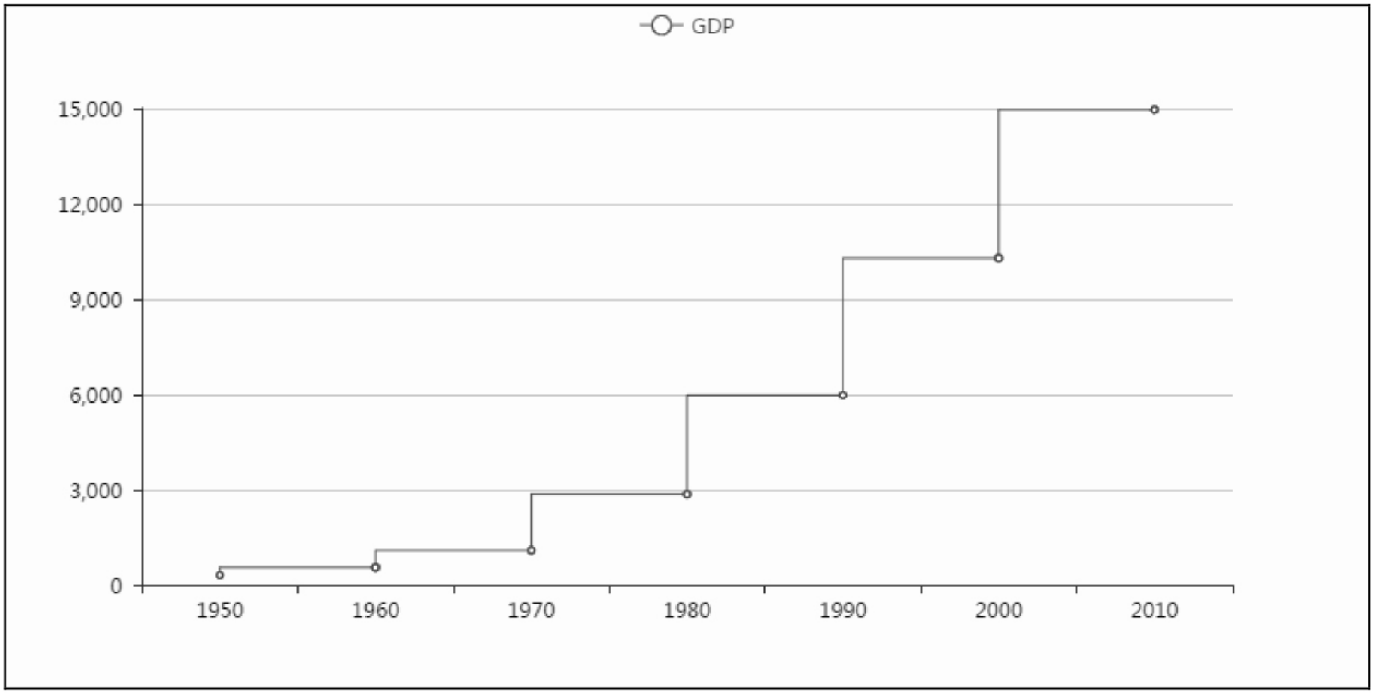

图9.6　阶梯图

下面给出通过设置is_fill参数绘制面积图的代码。其中，area_color为填充颜色，area_opacity为透明度，效果如图9.7所示。

```
years = [1950, 1960, 1970, 1980, 1990, 2000, 2010]
gdp = [300.2, 543.3, 1075.9, 2862.5, 5979.6, 10289.7, 14958.3]
line = pyecharts.Line("面积图")
line.add("GDP", years, gdp, is_fill=True, area_color='#000',area_opacity=0.3)
line
```

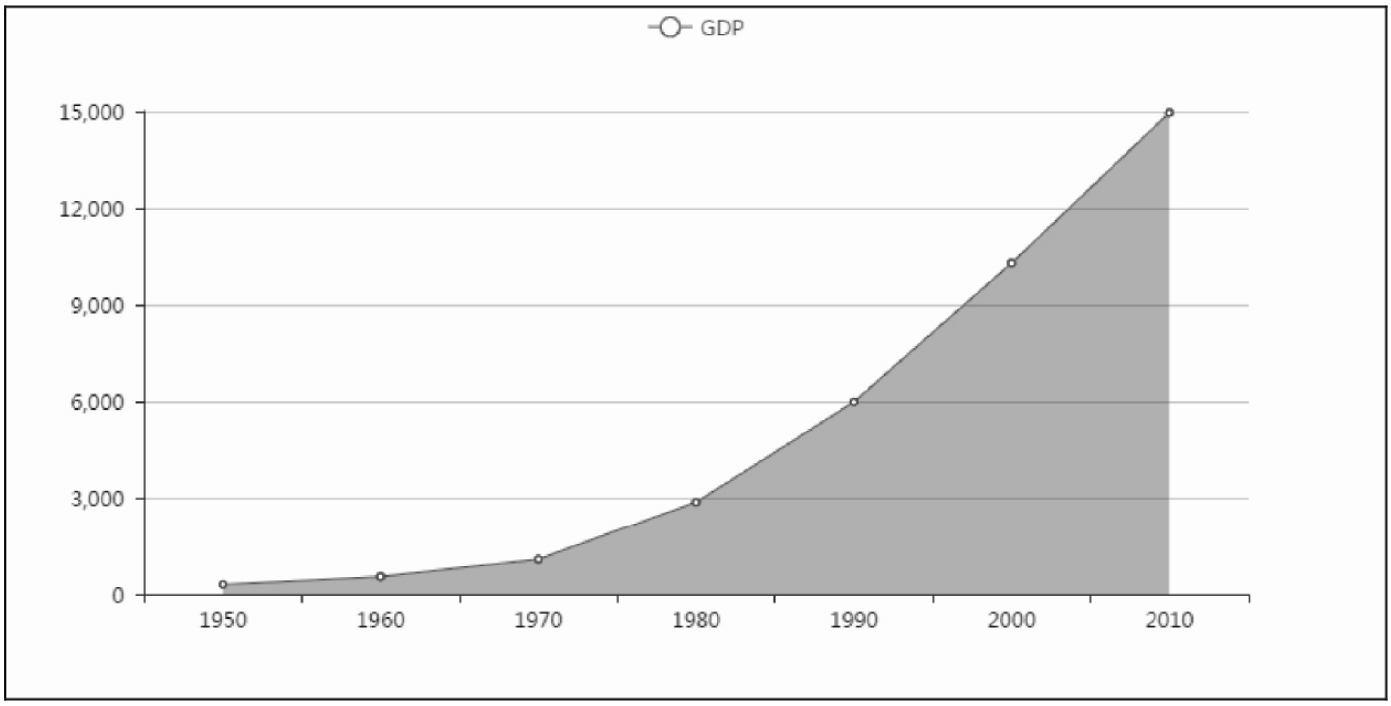

图9.7　面积图

9.1.4　柱状图

利用Bar方法可以绘制柱状图，代码如下：

```
data = [23, 85, 72, 43, 52]
labels = ['A','B','C','D','E']
bar = pyecharts.Bar("柱状图")
bar.add("one", labels, data)
bar
```

下面给出bar.add方法的参数。其中，is_stack为堆积柱状图；bar_category_gap为类目间的距离，值为0时则可以绘制直方图。

```
add(name, x_axis, y_axis,
    is_stack=False,
bar_category_gap='20%', **kwargs)
```

绘制的柱状图如图9.8所示。

使用多个add方法可以绘制并列柱状图，效果如图9.9所示，代码如下：

```
data1 = [23, 85, 72, 43, 52]
data2 = [14, 35, 62, 41, 19]
labels = ['A','B','C','D','E']
bar = pyecharts.Bar("并列柱状图")
bar.add("one", labels, data1)
bar.add('two', labels, data2)
bar
```

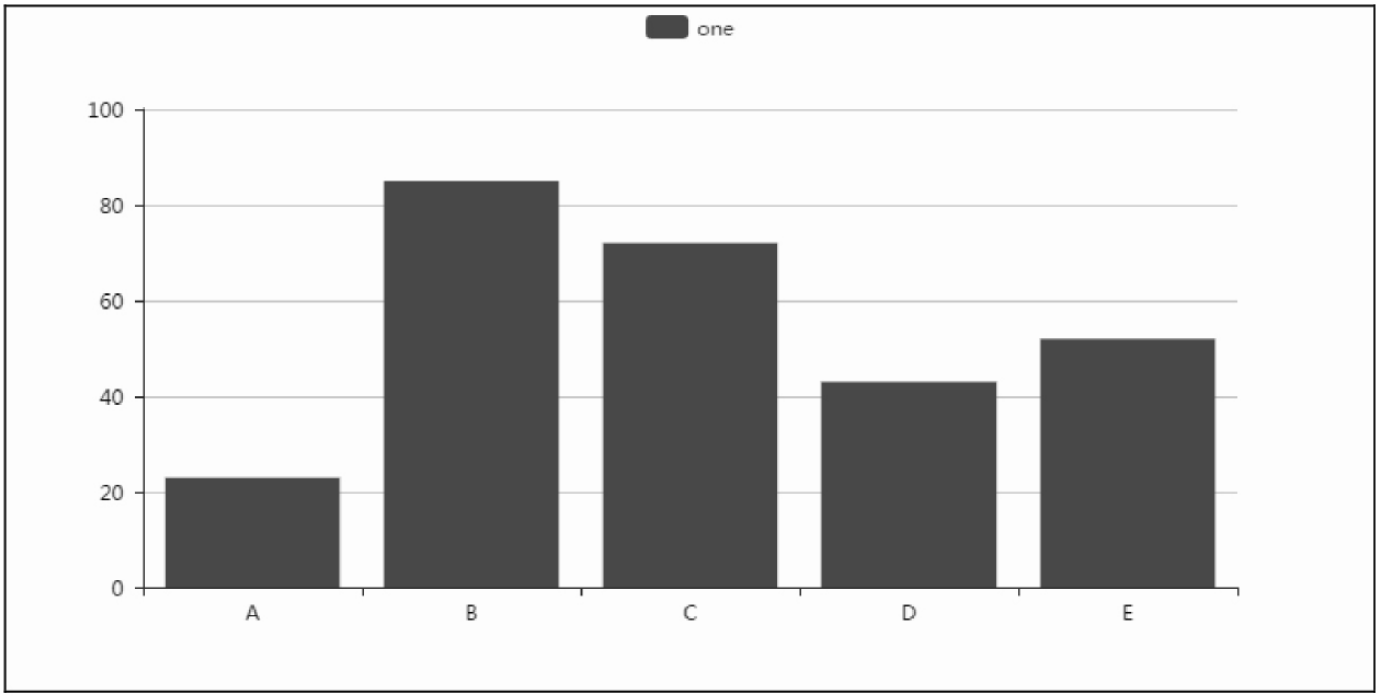

图9.8　柱状图

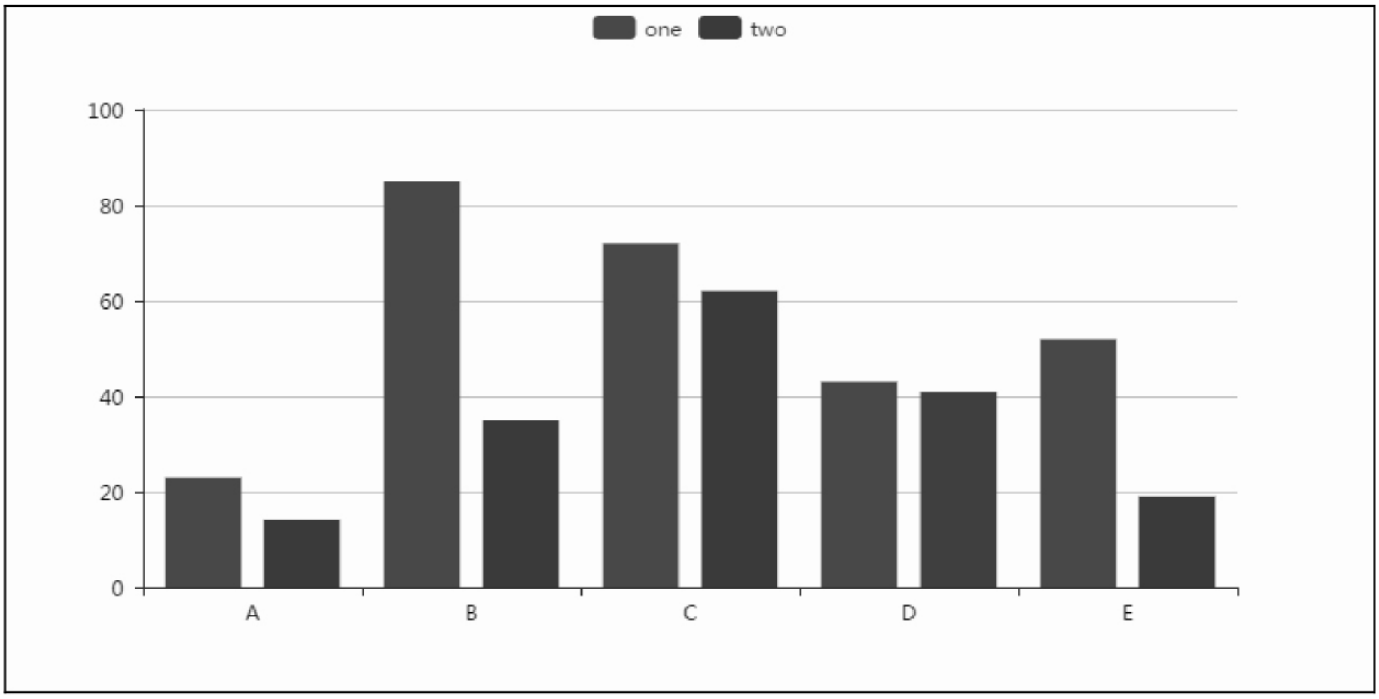

图9.9　并列柱状图

通过设置is_stack参数可以绘制堆积柱状图，效果如图9.10所示。代码如下：

```
data1 = [23, 85, 72, 43, 52]
data2 = [14, 35, 62, 41, 19]
labels = ['A','B','C','D','E']
bar = pyecharts.Bar("堆积柱状图")
bar.add("one", labels, data1, is_stack=True)
```

```
bar.add('two', labels, data2, is_stack=True)
bar
```

通过设置is_convert参数可以绘制垂直柱状图，效果如图9.11所示。代码如下：

```
data1 = [23, 85, 72, 43, 52]
labels = ['A','B','C','D','E']
bar = pyecharts.Bar("垂直柱状图")
bar.add("one", labels, data1, is_convert=True)
bar
```

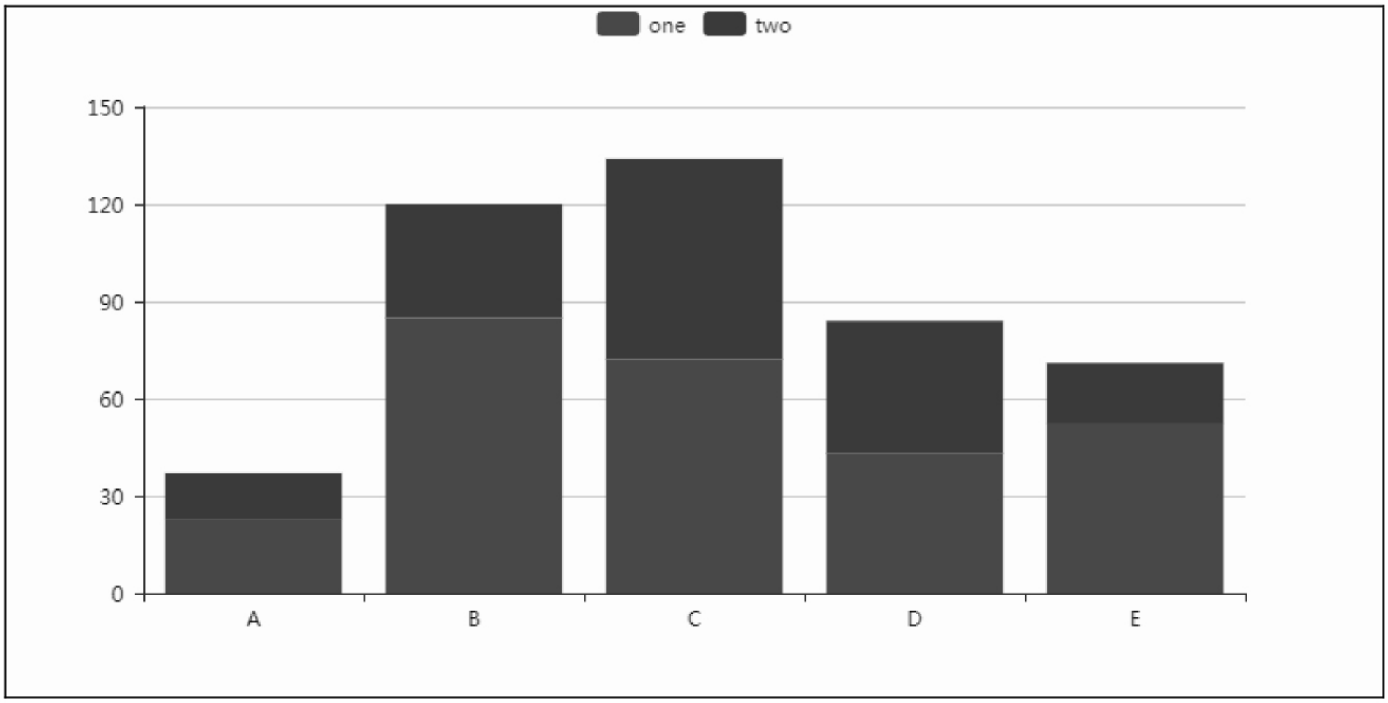

图9.10　堆积柱状图

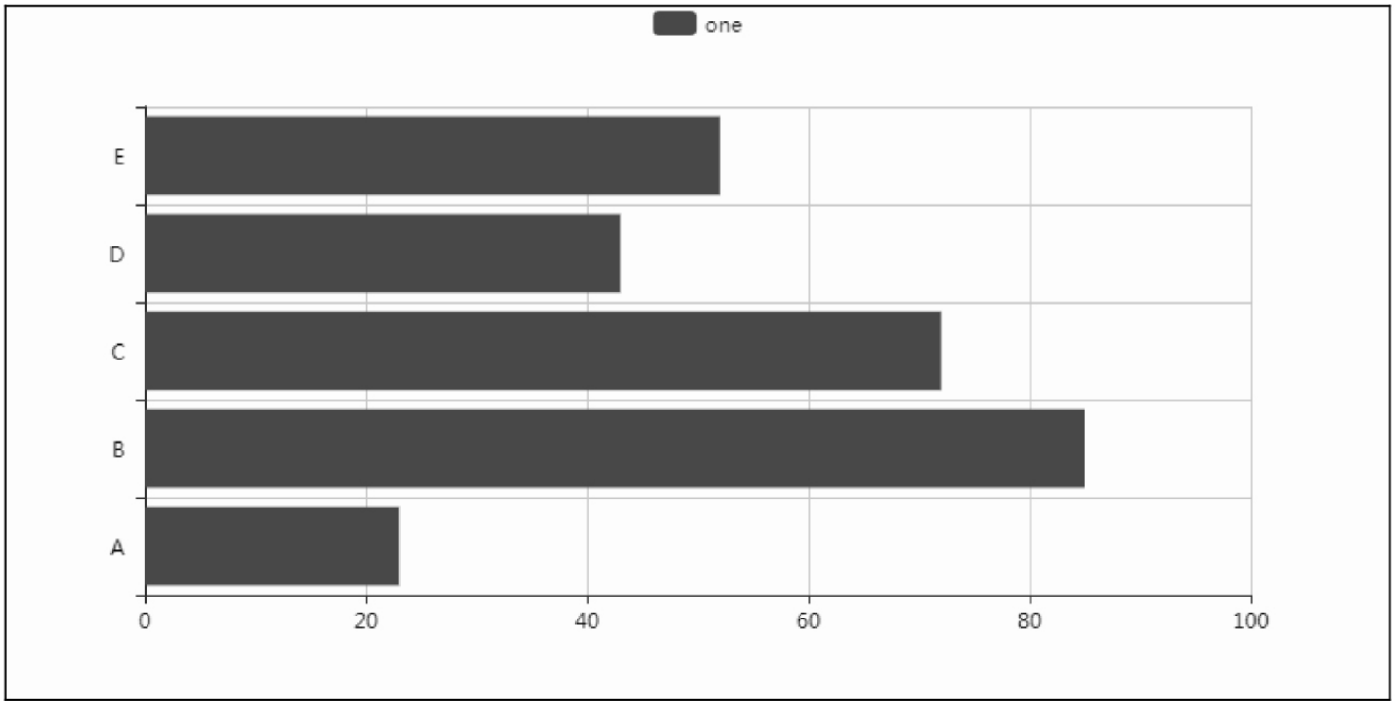

图9.11　垂直柱状图

通过设置mark_point和mark_line参数可以标记点和线，效果如图9.12所示。代码如下：

```
data1 = [23, 85, 72, 43, 52]
data2 = [14, 35, 62, 41, 19]
labels = ['A','B','C','D','E']
bar = pyecharts.Bar("标记点和线")
bar.add("one", labels, data1, mark_point=['average'])
bar.add('two', labels, data2, mark_point=['max'], mark_line=['min','max'])
bar
```

注意：全局变量mark_line要写入最后一个add方法中。

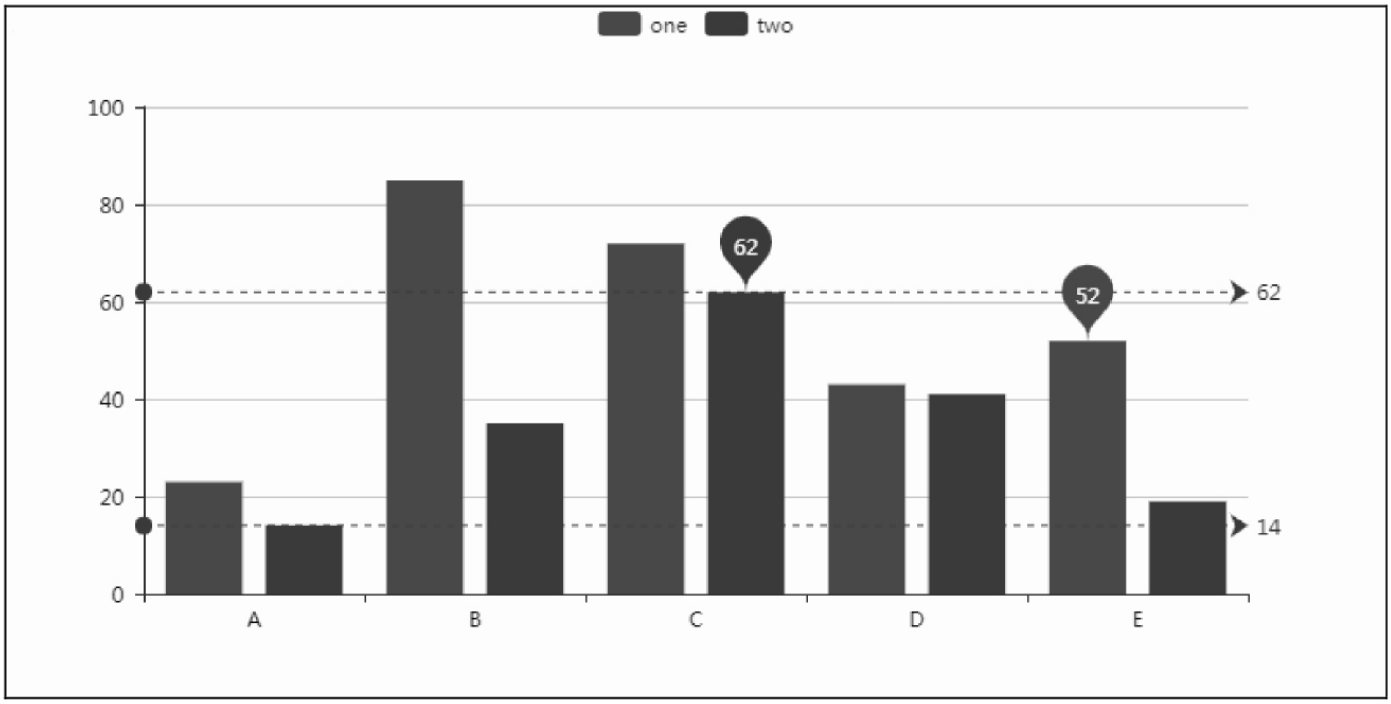

图9.12　标记点和线

令bar_category_gap参数为0，可绘制直方图，效果如图9.13所示。代码如下：

```
data = [23, 85, 72, 43, 52, 67, 98, 76]
labels = ['A','B','C','D','E','F','G','H']
bar = pyecharts.Bar("直方图")
bar.add("", labels, data, bar_category_gap=0)
bar
```

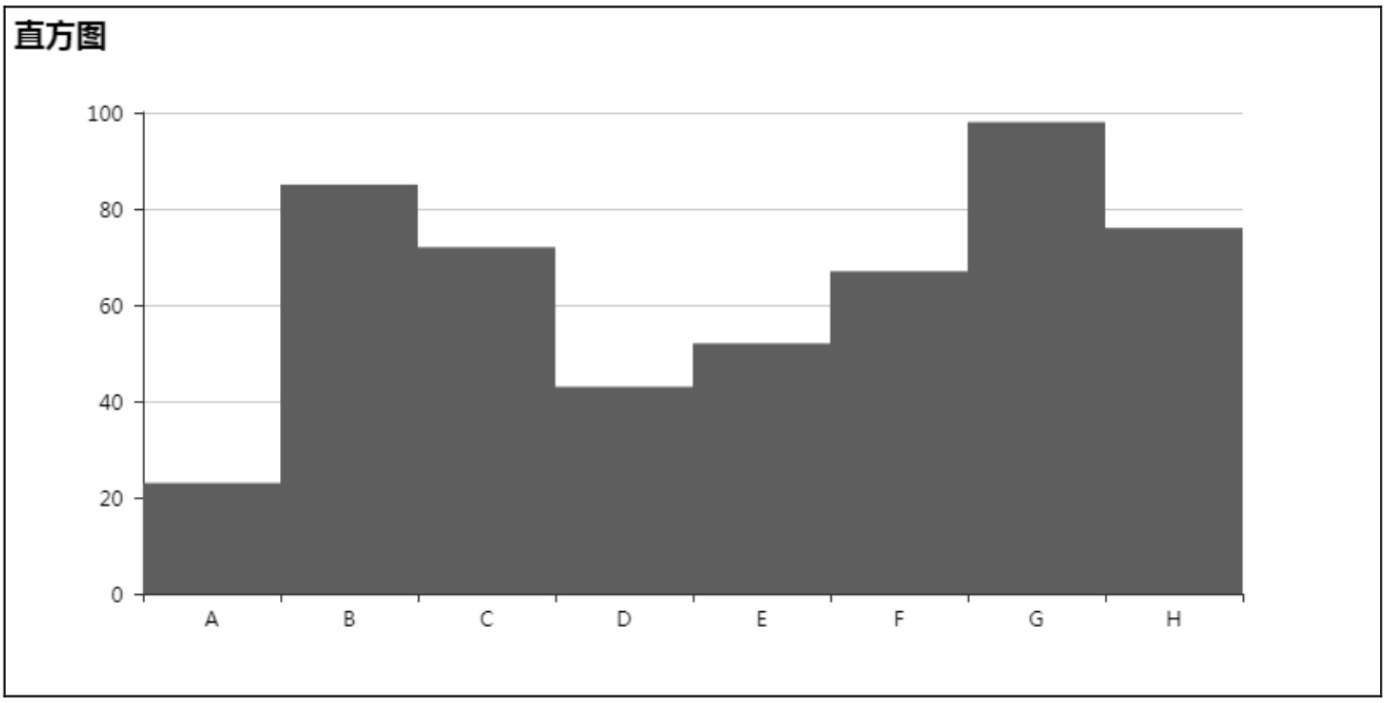

图9.13　直方图

9.2　其他图表

本节讲解如何利用pyecharts库绘制其他图表：通过设置绘图参数，来绘制不同类别的饼图（如圆环图和玫瑰图）和箱线图。

9.2.1　饼图

饼图用于表现不同类别的占比情况。利用Pie方法可绘制饼图，代码如下：

```
data = [45, 76, 35, 47, 56]
labels = ['电脑','手机','冰箱','彩电','洗衣机']
pie = pyecharts.Pie('饼图')
pie.add('', labels, data, is_label_show=True)
pie
```

下面给出pie.add方法的参数。其中，radius为设置饼图半径，默认为[0,75]，第一项为内半径，第二项为外半径；center为设置饼图中心坐标，默认为[50,50]，第一项为横坐标，第二项为纵坐标；rosetype可以设置南丁格尔图（玫瑰图），有两种表现形式，分别为radius和area。

```
add(name, attr, value,
    radius=None,
    center=None,
    rosetype=None, **kwargs)
```

绘制的饼图如图9.14所示。

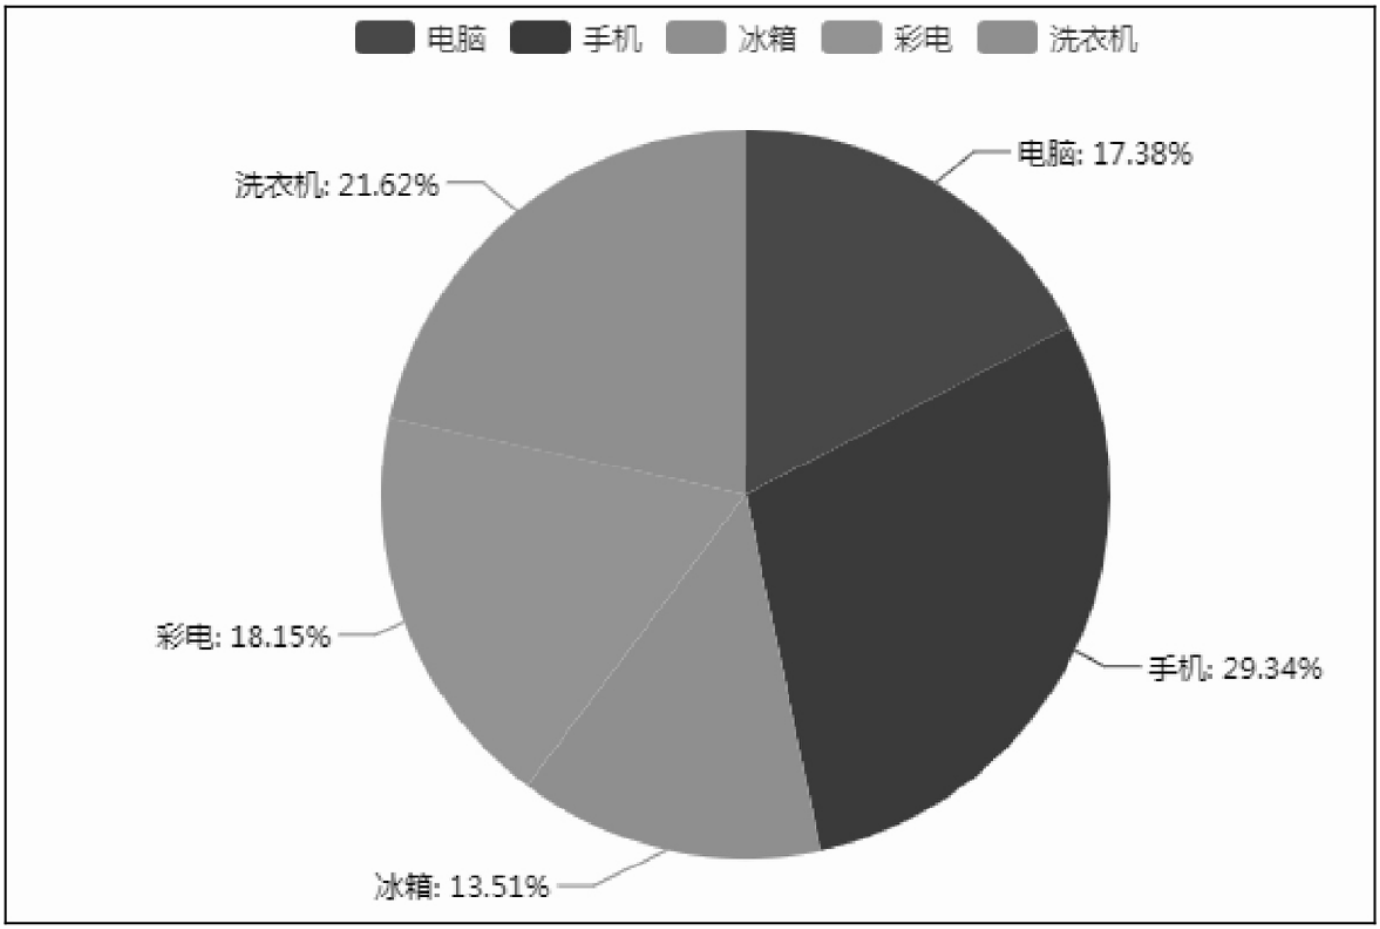

图9.14　饼图

设置radius参数为[40,75]，这样就有了内半径值，就可以绘制圆环图了，效果如图9.15所示。代码如下：

```
data = [45, 76, 35, 47, 56]
labels = ['电脑','手机','冰箱','彩电','洗衣机']
pie = pyecharts.Pie('圆环图')
pie.add('', labels, data, radius=[40,75], is_label_show=True)
pie
```

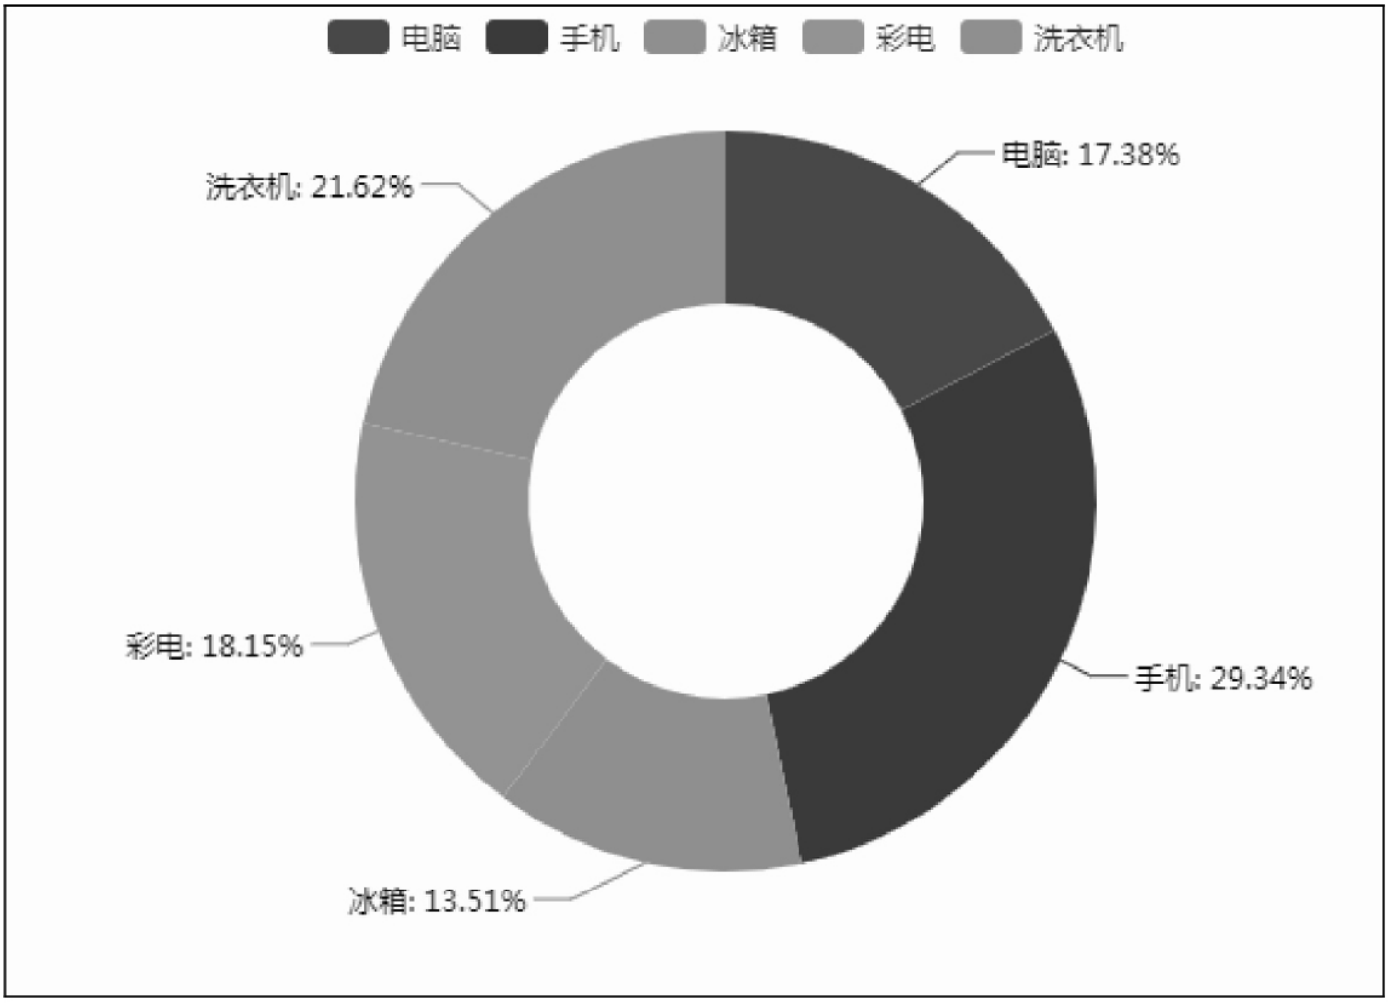

图9.15　圆环图

设置radius参数为[40,75]，这样就有了内半径值，就可以绘制圆环图了，效果如图9.16所示。代码如下：

```
data = [45, 76, 35, 47, 56]
labels = ['电脑','手机','冰箱','彩电','洗衣机']
pie = pyecharts.Pie('圆环图')
pie.add('', labels, data, radius=[40,75], is_label_show=True)
pie
```

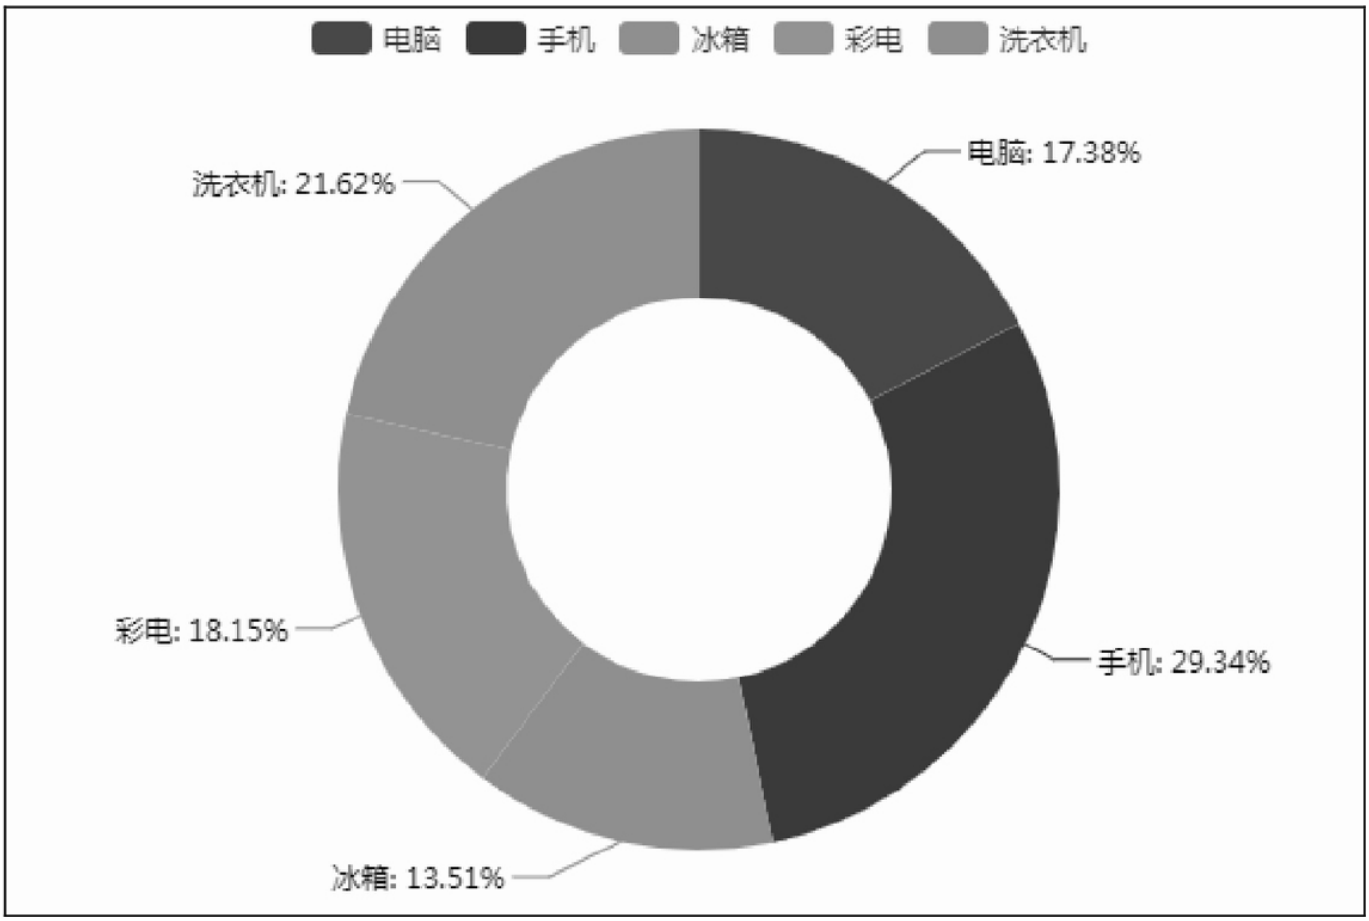

图9.16　圆环图

通过设置center参数可以绘制多个饼图，这样就可以比较两种玫瑰图的区别。通过图9.17可以看出，通过radius参数绘制的玫瑰图的圆心角不同，以此来显示其数据的百分比，玫瑰图的半径显示数据的数值大小；通过area参数绘制的玫瑰图的圆心角相同，仅通过半径大小来显示数据的区别。实现代码如下：

```
data = [45, 76, 35, 47, 56]
labels = ['电脑','手机','冰箱','彩电','洗衣机']
pie = pyecharts.Pie('玫瑰图')

pie.add('', labels, data, radius=[20,75], center=[25,50],
        rosetype='radius')
pie.add('', labels, data, radius=[20,75], center=[75,50],
        rosetype='area', is_label_show=True)

pie
```

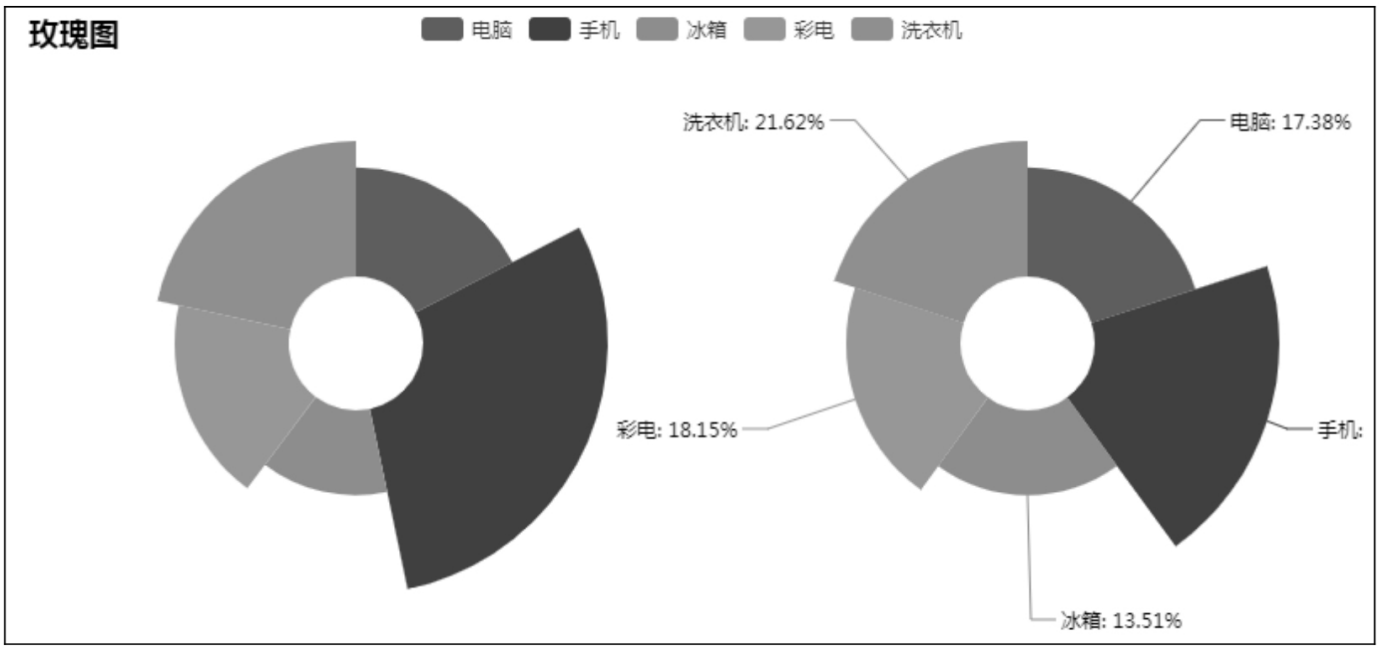

图9.17　玫瑰图

9.2.2　箱线图

箱线图可显示一组数据的最大值、最小值、中位数、下四分位数及上四分位数，可以体现数据的分布规律。利用Boxplot方法可绘制饼图，其参数见下文。其中，x_axis为横坐标列表；y_axis为嵌套列表。每个列表为[min,Q1,median(or Q2),Q3,max]，该列表可通过内置的prepare_data方法转换。

```
add(name, x_axis, y_axis, **kwargs)
```

这里以Iris数据为例，首先读入数据，如图9.18所示。

```
iris_data = pd.read_csv(open('H:\python数据分析\数据\iris-data.csv'))
iris_data.head()
```

	sepal_length_cm	sepal_width_cm	petal_length_cm	petal_width_cm	class
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa

图9.18　Iris数据

通过以下代码即可绘制箱线图，如图9.19所示。

```
x = list(iris_data.columns[0:4])
y = [list(iris_data.sepal_length_cm),
    list(iris_data.sepal_width_cm),
    list(iris_data.petal_length_cm),
    list(iris_data.petal_width_cm)]      #构造y

boxplot = pyecharts.Boxplot("箱线图")
y_data = boxplot.prepare_data(y)       #数据转化
boxplot.add('', x, y_data)
boxplot
```

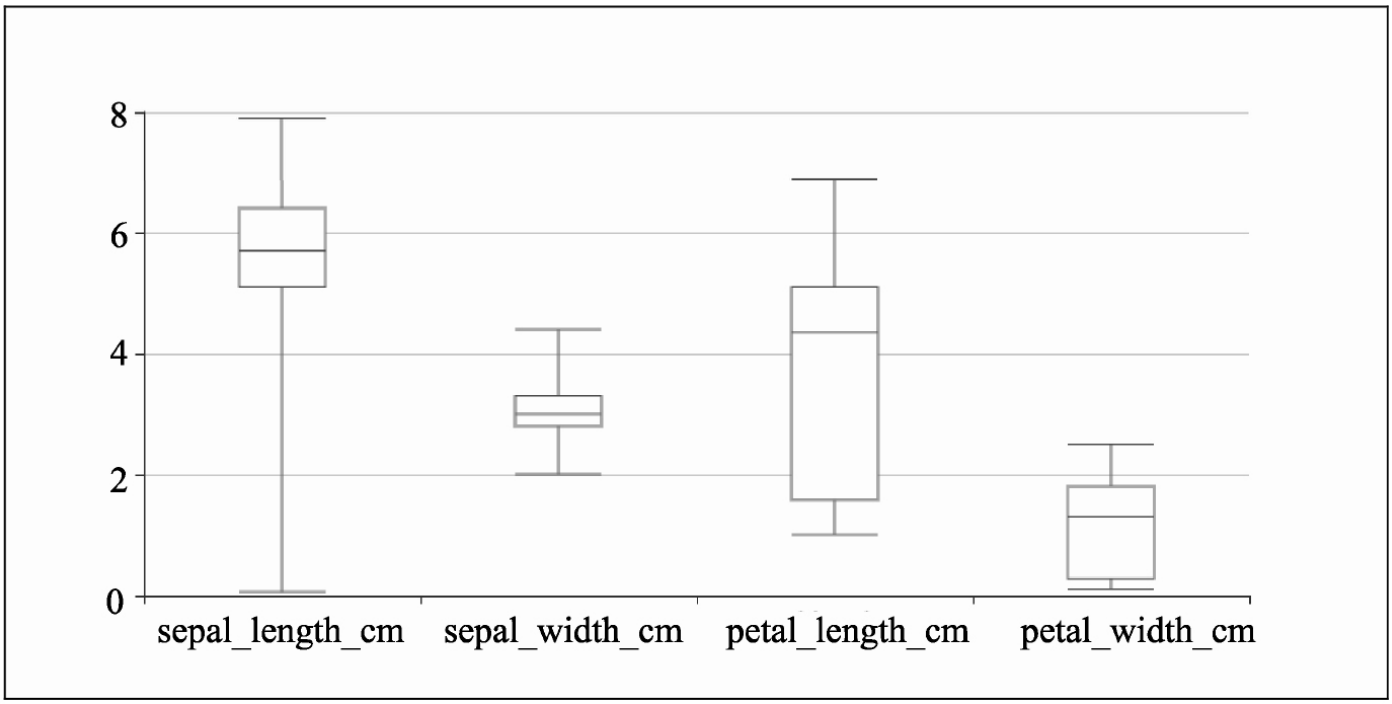

图9.19　箱线图

9.3　综合示例——糗事百科用户数据

本节将利用网络爬取的数据以及利用pandas数据分析方法，通过pyecharts可视化的手段来分析糗事百科用户的信息。

9.3.1 数据来源

本节示例数据来源于网络爬虫，笔者爬取了糗事百科的段子信息和对应的用户信息。

注意：该数据可以从本书配套资源中找到。

该数据有两个CSV文件，通过pandas依次读取段子数据，如图9.20所示。

```
import numpy as np
import pandas as pd
import pyecharts
```

```
data1 = pd.read_csv(open(r'H:\python数据分析\数据\qiushi_info.csv',encoding='utf-8'))
data1.head()
```

	id	sex	age	laugh	comment	user_url	content

图9.20 读取糗事百科段子数据

该数据包括用户的id、性别（sex）、年龄（age）、好笑数（laugh）、评论数（comment）、用户的URL和段子内容（content）。

读取用户数据，如图9.21所示。该用户数据包括用户的一些个人信息：粉丝（fans）、关注（topic）、段子数量（qiushi）、评论量（comment_1）、笑脸（favour）、糗事精选（handpick）、婚姻状况（martial_status）、星座（constellation）、职业（profession）、家乡（home）和用户URL。

```
data2 = pd.read_csv(open(r'H:\python数据分析\数据\user_info.csv',encoding='utf-8'))
data2.head()
```

	fans	topic	qiushi	comment_1	favour	handpick	martial_status	constellation	profession	home	qiushi_age	user_url
0	0.0	1.0	47.0	8.0	20428.0	0.0	married	双鱼座	手艺汪	国外 · 冰岛	2876天	https://www.qiushibaike.com/users/112899/
1	43.0	0.0	60.0	172.0	25162.0	0.0	married	处女座	IT汪	浙江 · 杭州	73天	https://www.qiushibaike.com/users/36401850/
2	1.0	0.0	9.0	26.0	684.0	0.0	不详	双子座	公务猿	广西 · 贺州	1464天	https://www.qiushibaike.com/users/15047842/
3	0.0	7.0	51.0	21.0	16166.0	0.0	single	摩羯座	手艺汪	河南 · 郑州	11天	https://www.qiushibaike.com/users/37267710/
4	0.0	8.0	29.0	16.0	6596.0	0.0	不详	处女座	商务汪	辽宁 · 锦州	1231天	https://www.qiushibaike.com/users/22688287/

图9.21 用户数据

9.3.2 定义问题

在本次分析中，将围绕段子和用户的数据提出几个问题：段子的评论量、段子的点赞数、用户的男女分布、用户的星座和地区分布等。

9.3.3 数据清洗

首先对段子数据进行清洗。通过info函数可以看出，age是object对象，user_url有缺失值，在对段子数据进行分析时，没有使用到用户的URL，这里进行保留，如图9.22所示。

通过unique函数可以看出，在年龄中有不详的数据，如图9.23所示。

```
data1.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 325 entries, 0 to 324
Data columns (total 7 columns):
id          325 non-null object
sex         325 non-null object
age         325 non-null object
laugh       325 non-null int64
comment     325 non-null int64
user_url    310 non-null object
content     325 non-null object
dtypes: int64(2), object(5)
memory usage: 17.9+ KB
```

图9.22　数据情况

```
data1['age'].unique()
```

```
array(['38', '100', '28', '32', '26', '84', '不详', '22', '40', '27', '99',
       '21', '25', '98', '34', '30', '33', '31', '0', '19', '101', '62',
       '12', '37', '20', '13', '36', '54', '23', '42', '41', '29', '35',
       '17', '24', '83', '39', '45', '93', '48', '80'], dtype=object)
```

图9.23　查看唯一值

这里的处理方法为：首先将不详的数据替换为0数据，然后将age字段转换为int数据类型，最后利用平均值来替换0值，如图9.24所示。

对用户数据进行处理，首先查看缺失值，前几个用户字段都有5个缺失值，如图9.25所示。

```
data1['age'].replace('不详',0,inplace=True)
data1['age'] = data1['age'].astype('int64')
```

```
data1['age'].replace(0,int(data1[data1['age']!=0]['age'].mean()),inplace=True)
```

```
data1['age'].unique()
```

```
array([ 38, 100,  28,  32,  26,  84,  39,  22,  40,  27,  99,  21,  25,
        98,  34,  30,  33,  31,  19, 101,  62,  12,  37,  20,  13,  36,
        54,  23,  42,  41,  29,  35,  17,  24,  83,  45,  93,  48,  80], dtype=int64)
```

```
data1.dtypes
```

```
id          object
sex         object
age          int64
laugh        int64
comment      int64
user_url    object
content     object
dtype: object
```

图9.24　age字段处理

```
data2.isnull().sum()
```

```
fans            5
topic           5
qiushi          5
comment_1       5
favour          5
handpick        5
martial_status  0
constellation   0
profession      0
home            0
qiushi_age      0
user_url        0
dtype: int64
```

图9.25　查看缺失值

可以直接用dropna方法删除缺失值，如图9.26所示。前几个字段为浮点数数据类型，将其转化为整数类型，如图9.27所示。

```
data2.dropna(inplace=True)
data2.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 219 entries, 0 to 220
Data columns (total 12 columns):
fans                219 non-null float64
topic               219 non-null float64
qiushi              219 non-null float64
comment_1           219 non-null float64
favour              219 non-null float64
handpick            219 non-null float64
martial_status      219 non-null object
constellation       219 non-null object
profession          219 non-null object
home                219 non-null object
qiushi_age          219 non-null object
user_url            219 non-null object
dtypes: float64(6), object(6)
memory usage: 22.2+ KB
```

图9.26　删除缺失值

```
data2['fans'] = data2['fans'].astype('int64')
data2['topic'] = data2['topic'].astype('int64')
data2['qiushi'] = data2['qiushi'].astype('int64')
data2['comment_1'] = data2['comment_1'].astype('int64')
data2['favour'] = data2['favour'].astype('int64')
data2['handpick'] = data2['handpick'].astype('int64')
```

图9.27　转化数据类型

对于home字段，为了数据的可视化，这里通过字符串处理新加一列，用于获取省份的数据，效果如图9.28所示。代码如下：

```
data2['province'] = data2['home'].str.split('· ').str[0]
data2.head()
```

constellation	profession	home	qiushi_age	user_url	province
双鱼座	手艺汪	国外 · 冰岛	2876天	https://www.qiushibaike.com/users/112899/	国外
处女座	IT汪	浙江 · 杭州	73天	https://www.qiushibaike.com/users/36401850/	浙江
双子座	公务猿	广西 · 贺州	1464天	https://www.qiushibaike.com/users/15047842/	广西
摩羯座	手艺汪	河南 · 郑州	11天	https://www.qiushibaike.com/users/37267710/	河南
处女座	商务汪	辽宁 · 锦州	1231天	https://www.qiushibaike.com/users/22688287/	辽宁

图9.28　字符串处理1

对于用户的糗事年龄，删除“天”字后，转化为int类型，效果如图9.29所示。代码如下：

```
data2['qiushi_age'] = data2['qiushi_age'].str.strip('天')
data2['qiushi_age'] = data2['qiushi_age'].astype('int64')
```

constellation	profession	home	qiushi_age	user_url	province
双鱼座	手艺汪	国外 · 冰岛	2876	https://www.qiushibaike.com/users/112899/	国外
处女座	IT汪	浙江 · 杭州	73	https://www.qiushibaike.com/users/36401850/	浙江
双子座	公务猿	广西 · 贺州	1464	https://www.qiushibaike.com/users/15047842/	广西
摩羯座	手艺汪	河南 · 郑州	11	https://www.qiushibaike.com/users/37267710/	河南
处女座	商务汪	辽宁 · 锦州	1231	https://www.qiushibaike.com/users/22688287/	辽宁

图9.29　字符串处理2

9.3.4　数据探索

首先对段子数据进行分析，分析好笑数和评论多的段子是哪些用户发的。通过对laugh字段排序，选取前10条搞笑的数据，如图9.30所示。

```
laugh_sort = data1.sort_values(by = 'laugh',ascending=False)[0:10]
laugh_sort
```

	id	sex	age	laugh	comment	user_url	content
10	星劫	男	27	19428	101	https://www.qiushibaike.com/users/14849114/	最佩服[redacted]是我表弟，相亲的时候女方问他什么学历，他眼神盯着远方，深沉的说遗憾当年没考上博士...
183	（驹迷）真的爱你	男	19	12403	107	https://www.qiushibaike.com/users/22085995/	戴着墨镜等红灯，旁边妹子在打电话，听声音是真帅，扭过头看看她，然后她在扭过头看看我，，面对面...
136	十里柔情一帘幽梦	女	100	10026	214	https://www.qiushibaike.com/users/8737794/	下午同事给我一包减肥茶，我喝了，别说，效果又快又好，我一下午都在厕所里渡过，客户被同事一个人...
295	青刺莓	女	99	9816	94	https://www.qiushibaike.com/users/28437800/	老公这些天加班，特别忙，我打电话问他："中午吃饭了吗？"他说木有，刚才吃了泡面。没吃饱。
12	十里柔情一帘幽梦	女	100	9334	68	https://www.qiushibaike.com/users/8737794/	小丽的相亲对象对小丽一见倾心，各种追求，可对方不是她的菜。。
235	鲨鱼光膀子	男	31	9293	113	https://www.qiushibaike.com/users/30803387/	楼下新开一家成 人 用 品，我家那个淘气娃，不知怎么就溜进去了，回来兴冲冲的对我说"爸爸，我...
290	爱新觉罗.黄瓜	男	30	8797	127	https://www.qiushibaike.com/users/11320295/	晚上下夜班，看到老婆穿着性感的睡衣站在楼道迎接我，我心里一暖，上前抱住她心疼的说道:"宝贝，...
169	不知不觉的年纪	男	29	8401	61	https://www.qiushibaike.com/users/11086904/	老婆:老公，我感觉我生病了，浑身没劲，我要死了。
255	傻晴°	女	26	8096	68	https://www.qiushibaike.com/users/23331917/	同事夫妻俩都在店里上班，刚吃饭的时候，两个人哗啦吧啦说了一大堆家乡话，我跟另一个同事说:这俩...
140	贱°人°余	男	98	8051	45	https://www.qiushibaike.com/users/36760891/	自从上次公司聚餐我带老妈去了以后，一女同事开始隔三差五的对我示好，经常关心我。虽然自己有点小...

图9.30　laugh字段排序

通过代码绘制好笑数前10条的用户柱状图，如图9.31所示。其中用户名为“星劫”的段子好笑数最多，为19428，而平均好笑数为10364.5，也有用户上榜两条。

```
bar = pyecharts.Bar('搞笑段子用户排名')
attr = list(laugh_sort['id'])
v1 = list(laugh_sort['laugh'])
bar.add('好笑数',attr,v1,is_label_show=True,
        mark_point=['max','min'],mark_line=['average'],
        is_xaxislabel_align=True,xaxis_interval=0,
       xaxis_name_size=12,xaxis_rotate=30)
bar

# is_xaxislabel_align=True为x轴刻度与x标签对应
# xaxis_interval=0设置每个x标签都显示
#xaxis_name_size=12设置x标签大小
#xaxis_rotate=30设置x轴标签旋转
```

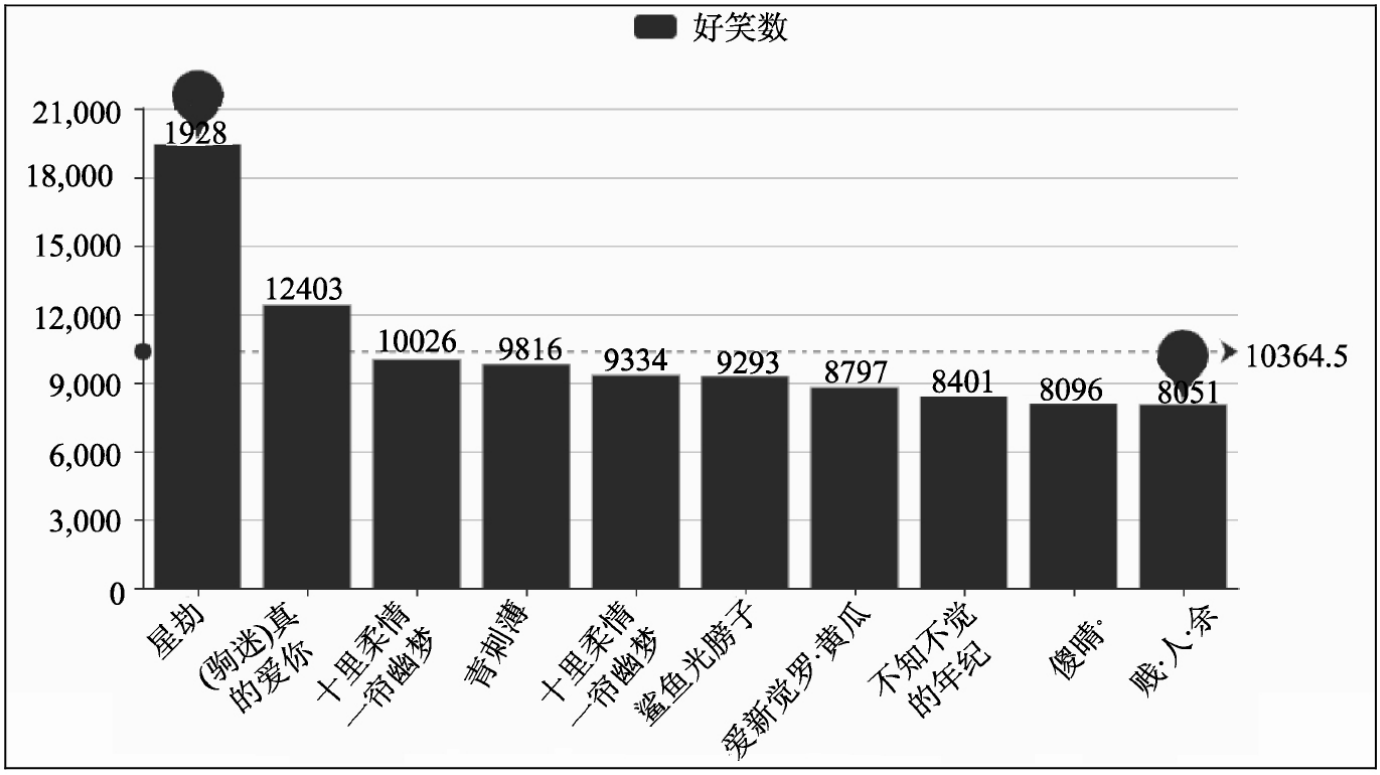

图9.31　好笑数前10位用户排名

按照同样的方法，对comment字段进行排序，选取前10条评论量最多的数据，结果如图9.32所示。代码如下：

```
comment_sort = data1.sort_values(by = 'comment',ascending=False)[0:10]
comment_sort
```

	id	sex	age	laugh	comment	user_url	content
13	名字帅人才帅	男	27	4522	227	https://www.qiushibaike.com/users/23745221/	LZ晋升主管，请同事吃饭庆祝，吃过饭，经理抢着买单，八个人花了八百多，经理对我说，你要实在不...
136	十里柔情一帘幽梦	女	100	10026	214	https://www.qiushibaike.com/users/8737794/	下午同事给我一包减肥茶，我喝了，别说，效果又快又好，我一下午都在厕所里渡过，客户被同事一个人...
84	虎头鲸凶三	男	54	7382	155	https://www.qiushibaike.com/users/30082002/	回家路过卖水果的小摊，问了桔子的价格，比超市便宜很多，于是买了两斤，老板说五块三，算五块了。...
142	傻晴°	女	26	5190	151	https://www.qiushibaike.com/users/23331917/	房东家刚买了一颗长满果实的橘子树，每次路过都想偷偷摘两个！
158	贱°人°余	男	98	7963	139	https://www.qiushibaike.com/users/36760891/	上学的时候，最喜欢欺负女同桌，这小丫头片子心眼少，容易欺负。
156	勇敢的小红军	男	34	7065	133	https://www.qiushibaike.com/users/10413669/	我做软件开发的。一次叫个外卖（不提名字以避免战争），吃饭时，送外卖的小哥帮我调试程序，居然把...
189	非法用户名IkKx...	女	23	7878	131	https://www.qiushibaike.com/users/29482428/	最近发现了单位两个领导的婚外情，一对就让我够吃惊的了，竟然还两对而且四个人还都是本单位的！天...
290	爱新觉罗.黄瓜	男	30	8797	127	https://www.qiushibaike.com/users/11320295/	晚上下夜班，看到老婆穿着性感的睡衣站在楼道迎接我，我心里一暖，上前抱住她心疼的说道:"宝贝，...
111	匿名用户	不详	39	5266	121	NaN	同学聚会，期间一个同学说自己刚买了车子，房子花了几百万，好辛苦什么的。
235	鲨鱼光膀子	男	31	9293	113	https://www.qiushibaike.com/users/30803387/	楼下新开一家成 人 用 品，我家那个淘气娃，不知怎么就溜进去了，回来兴冲冲的对我说"爸爸，我...

图9.32　comment字段排序

通过以下代码绘制评论量前10位的用户柱状图，如图9.33所示。评论量总体不多，平均为150条左右。

```
bar = pyecharts.Bar('评论段子用户排名')
attr = list(comment_sort['id'])
v1 = list(comment_sort['comment'])
bar.add('评论数',attr,v1,is_label_show=True,
        mark_point=['max','min'],mark_line=['average'],
        is_xaxislabel_align=True,xaxis_interval=0,
       xaxis_name_size=12,xaxis_rotate=30)
bar
```

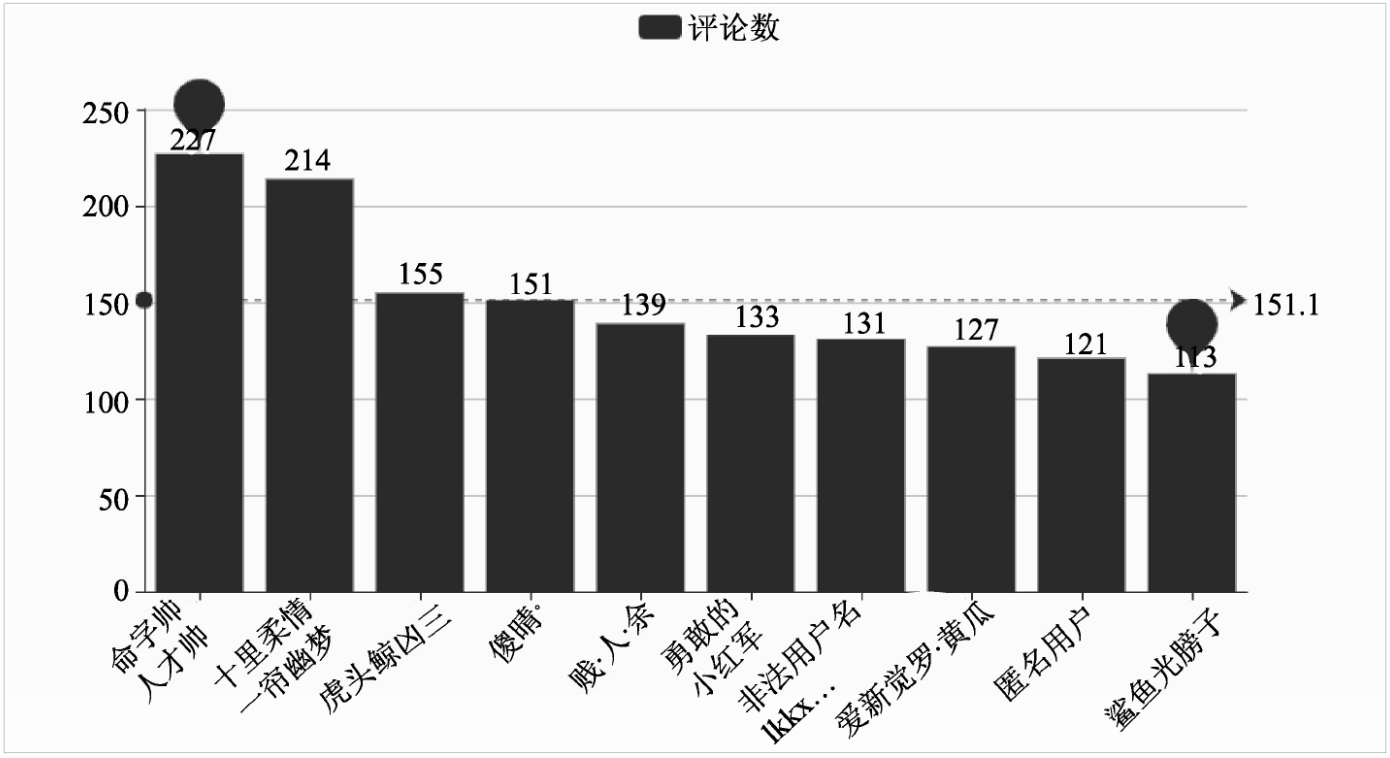

图9.33　评论量前10位用户排名

对用户数据进行分析时，需用到段子数据中的用户性别和年龄等信息。这里首先将段子数据中的user_info缺失值的行删除（这些用户为匿名用户），然后通过merge函数将两张表合并（连接键为user_info），最后删除重复数据（前文中发现用户会出现重复情况）。代码如下：

```
data1 = data1.dropna()                                  #删除缺失值
data = pd.merge(data1,data2,on='user_url')              #合并数据
data = data.drop_duplicates(['id'])                     #删除重复值
```

首先计算用户的平均年龄，如图9.34所示为35岁。然后对sex字段进行计数，查看用户的男女分布比例，如图9.35所示。从图中可以看出男性用户数量较多，为女性用户的3倍左右。

```
data['age'].mean()
```

```
35.412903225806445
```

图9.34　用户年龄

通过下面的代码绘制饼图，效果如图9.36所示。

```
attr = list(sex_count.index)
v = list(sex_count)
pie = pyecharts.Pie('用户男女分布')
pie.add('', attr, v, is_label_show=True)
pie
```

```
sex_count = data['sex'].value_counts()
sex_count
```

```
男    115
女     40
Name: sex, dtype: int64
```

图9.35　性别计数

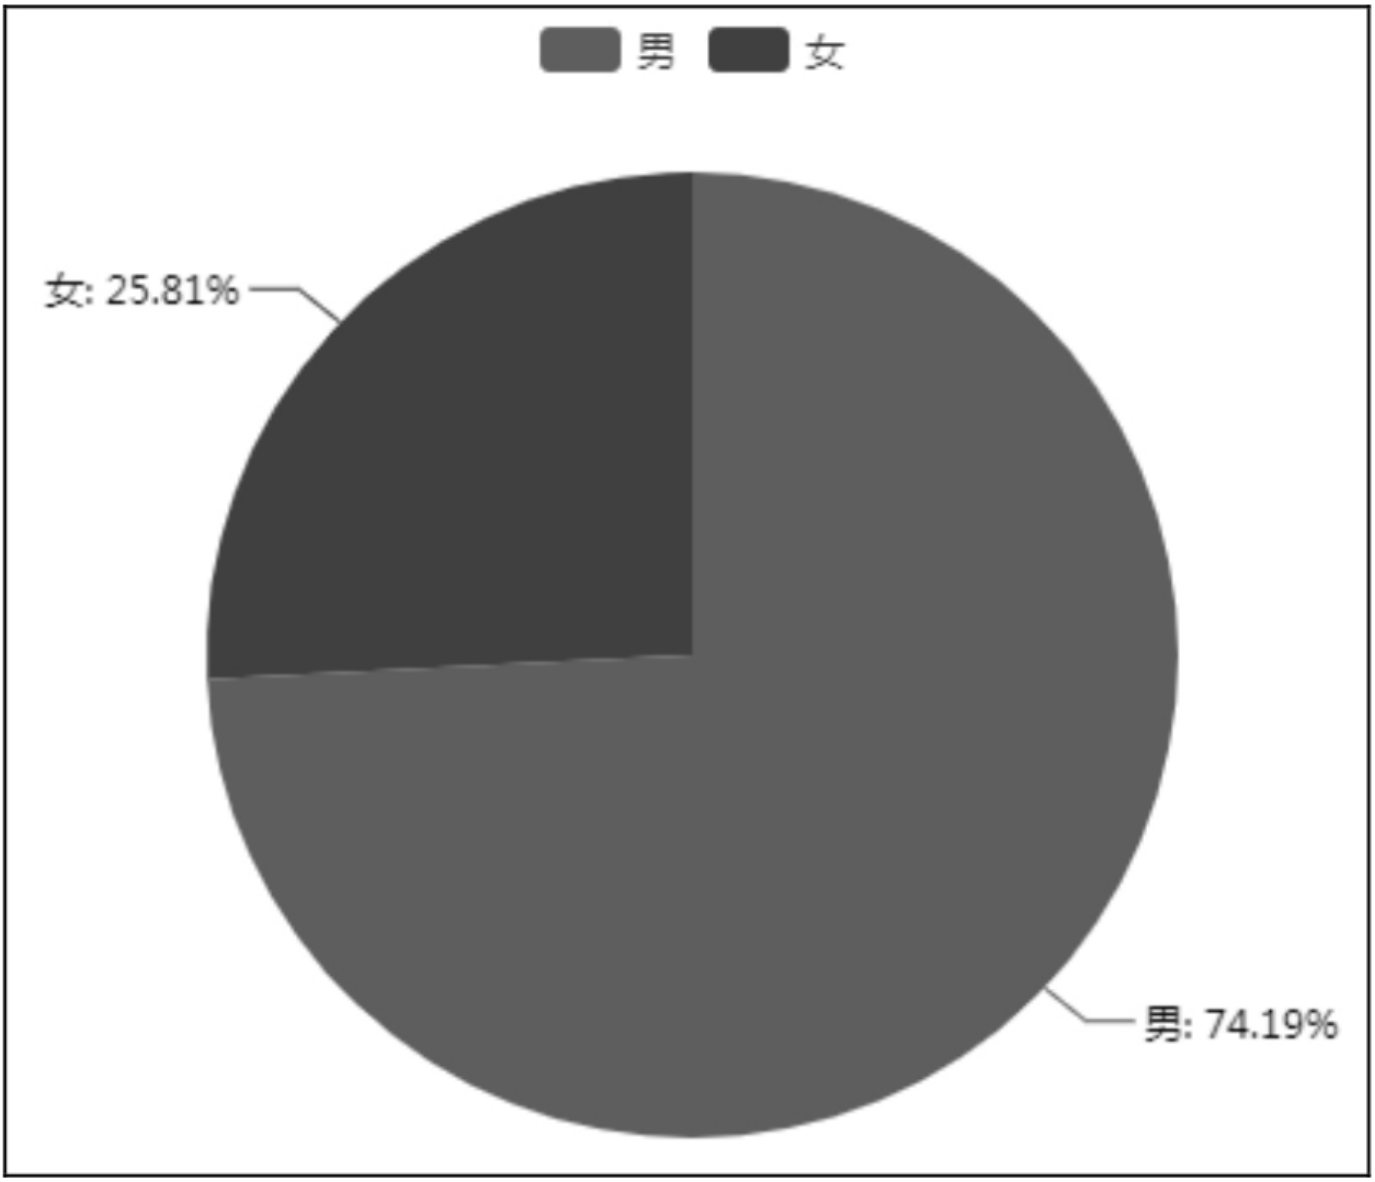

图9.36　男女用户分布图

对martial_status字段计数，发现有“不详”和secret两个字段，这里全部替代为secret字段再进行计数，然后查看用户的婚姻情况，如图9.37所示。从图中可以看出，信息保密的用户（secret）较多，单身用户（single）和已婚用户（married）的数量接近，热恋中的用户（inlove）较少。

```
marry_count = data['martial_status'].value_counts()
marry_count
```

```
secret     53
不详         41
single     31
married    23
inlove      7
Name: martial_status, dtype: int64
```

```
data['martial_status'].replace('不详','secret',inplace=True)
```

```
marry_count = data['martial_status'].value_counts()
marry_count
```

```
secret     94
single     31
married    23
inlove      7
Name: martial_status, dtype: int64
```

图9.37　用户婚姻情况计数

通过下面的代码绘制圆环图，效果如图9.38所示。

```
attr = list(marry_count.index)
v = list(marry_count)
pie = pyecharts.Pie('用户婚姻状况')
pie.add('', attr, v, radius=[40,75], is_label_show=True)
pie
```

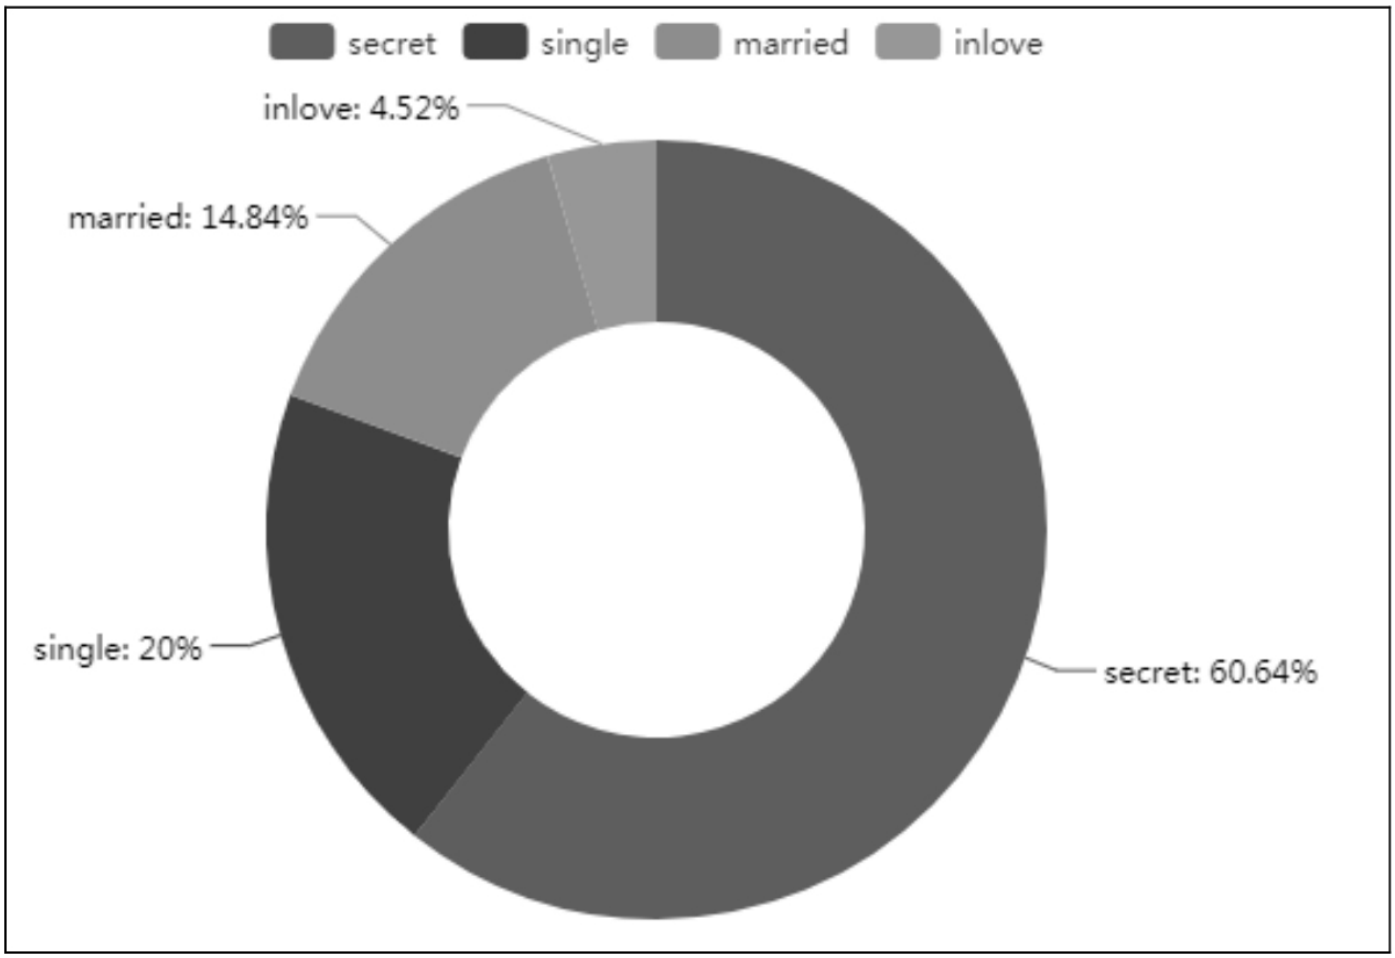

图9.38　用户婚姻状况圆环图

然后对用户星座进行计数，查看用户的星座分布情况，如图9.39所示。由图可知，摩羯座用户数量最多，其他的各星座用户数量相差不大。

```
con_count = data['constellation'].value_counts()
con_count
```

```
摩羯座    19
天秤座    18
天蝎座    16
处女座    15
狮子座    14
白羊座    12
双子座    12
水瓶座    10
双鱼座     9
巨蟹座     9
射手座     8
不详       8
金牛座     5
Name: constellation, dtype: int64
```

图9.39　用户星座计数

接着通过下面的代码绘制柱状图，效果如图9.40所示。

```
attr = list(con_count.index)
v1 = list(con_count)
bar = pyecharts.Bar('用户星座分布')
bar.add('星座',attr,v1,is_label_show=True,
        mark_point=['max','min'],mark_line=['average'],
        is_xaxislabel_align=True,xaxis_interval=0,
       xaxis_name_size=12,xaxis_rotate=30)
bar
```

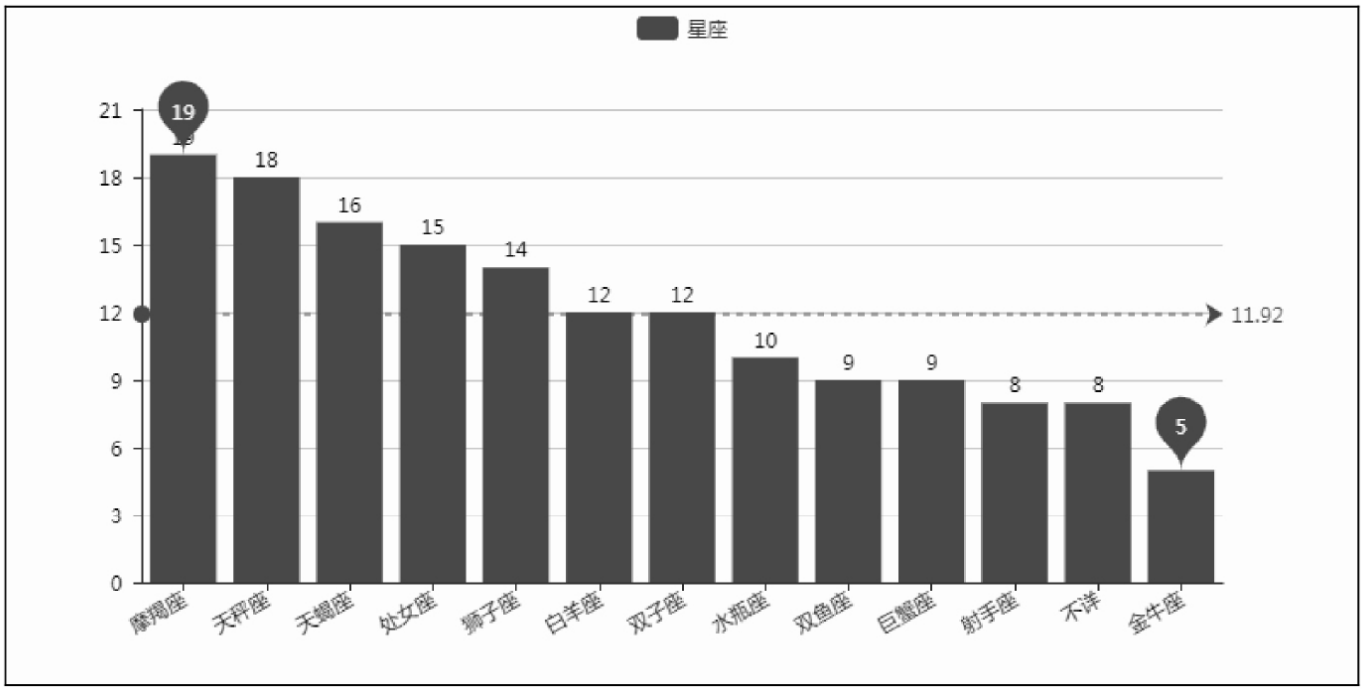

图9.40　用户星座分布柱状图

然后通过对province字段的计算来分析用户的地区分布情况。由于province中有空格，首先去除空格然后再进行计算，如图9.41所示。由于用户数据不多，各地区分布没有太大的差异性。

```
data['province'] = data['province'].str.strip()
data.head()
```

```
province_count = data['province'].value_counts()
province_count
```

```
未知    21
江苏    16
国外    15
山东    10
广东     9
不详     9
安徽     9
河北     7
广西     7
湖南     7
辽宁     6
四川     5
湖北     5
```

图9.41　用户地区计数

最后通过pyecharts的Bar方法绘制地区分布柱状图，效果如图9.42所示。代码如下：

```
attr = list(province_count[0:10].index)
v1 = list(province_count[0:10])
bar = pyecharts.Bar('用户地区分布')
bar.add('地区',attr,v1,is_label_show=True,
        mark_point=['max','min'],mark_line=['average'],
        is_xaxislabel_align=True,xaxis_interval=0,
       xaxis_name_size=12,xaxis_rotate=30)
bar
```

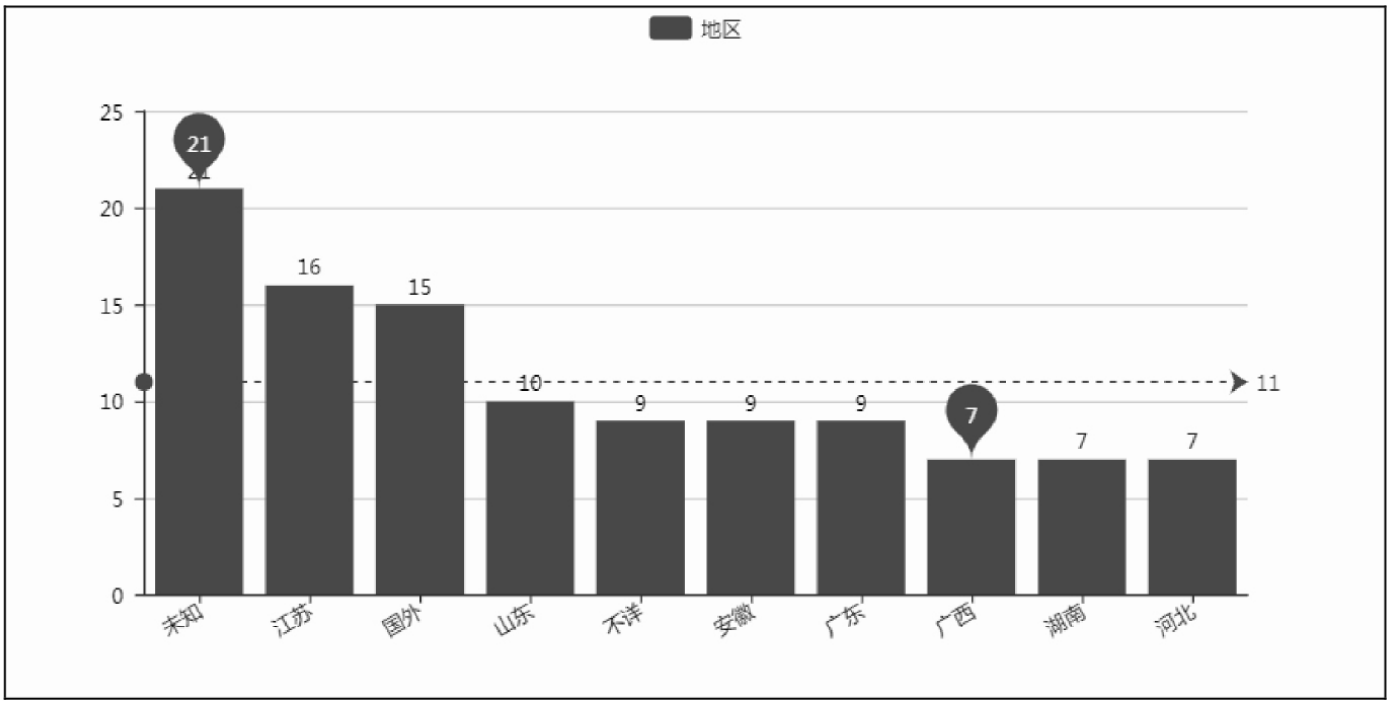

图9.42　用户地区分布柱状图

第10章　时间序列

在许多行业中，时间序列数据是一种重要的结构化数据类型。本章主要讲解datetime的数据类型及与字符串的相互转换方法；时间序列的构造和使用方法；日期和时期数据的使用方法；时间序列的频率转换与重采样；最后通过一个综合示例，讲解时间序列数据的处理与分析方法。

下面给出本章涉及的知识点与学习目标。

· datetime库：学会构造时间数据及其与字符串的相互转换。

· 时间序列：学会构造时间序列和使用方法。

· 日期与时期：学会日期与时期的使用方法。

· 频率转换与重采样：学会resample函数的使用方法。

10.1　datetime模块

本节将讲解Python标准库中datetime库的使用方法，以及datetime库的数据和字符串数据的相互转换方法。

10.1.1　datetime构造

Python的标准库datetime可用于创建时间数据类型。如表10.1所示为datetime库的时间数据类型。

表10.1　datetime库的时间数据类型

类　　型	使用说明
date	日期（年、月、日）
time	时间（时、分、秒、毫秒）
datetime	日期和时间
timedelta	两个datetime的差（日、秒、毫秒）

其中，date类数据可用于创建日期类数据，通过年、月、日来进行存储，如图10.1所示。

time类数据用于存储时间数据，通过时、分、秒、毫秒进行存储，如图10.2所示。

```
import datetime
```

```
date = datetime.date(2018, 3, 2)
date
```

```
datetime.date(2018, 3, 2)
```

```
date.year
```

```
2018
```

```
date.day
```

```
2
```

图10.1　date数据类型

```
time = datetime.time(9, 10, 34)
time
```

```
datetime.time(9, 10, 34)
```

```
time.hour, time.minute, time.second
```

```
(9, 10, 34)
```

图10.2　time数据类型

datetime类数据可以看做是date类和time类的组合，通过now方法可以查看当前的时间，如图10.3所示。

```
now = datetime.datetime.now()
now
```

```
datetime.datetime(2018, 4, 13, 10, 12, 10, 843298)
```

图10.3　datetime数据类型

timedelta类数据为两个datetime类数据的差，也可通过给datetime类对象加或减去timedelta类对象，以此获取新的datetime类对象，如图10.4所示。

```
delta = now - datetime.datetime(2018, 3, 5, 9, 12)
delta
```

```
datetime.timedelta(39, 3610, 843298)
```

```
now
```

```
datetime.datetime(2018, 4, 13, 10, 12, 10, 843298)
```

```
now + datetime.timedelta(10)
```

```
datetime.datetime(2018, 4, 23, 10, 12, 10, 843298)
```

图10.4　timedelta数据类型

10.1.2　数据转换

在数据分析中，字符串和datetime类数据需要进行转换，通过str方法可以直接将datetime类数据转换为字符串数据，如图10.5所示。

```
from datetime import datetime
stamp = datetime(2018, 5, 12)
stamp
```

```
datetime.datetime(2018, 5, 12, 0, 0)
```

```
str(stamp)
```

```
'2018-05-12 00:00:00'
```

图10.5　datetime类数据转换为字符串格式

如果需要将datetime类数据转换为特定格式的字符串数据（格式化），需要使用strftime方法，如图10.6所示。

```
stamp.strftime('%Y/%m/%d')
'2018/05/12'

stamp.strftime('%W')
'19'
```

图10.6　datetime类数据转换为特定的字符串格式

如表10.2所示为部分格式化编码。

表10.2　格式定义

代　　码	使用说明
%Y	4位数的年
%y	2位数的年
%m	2位数的月
%d	2位数的天
%H	时（24小时制）
%I	时（12小时制）
%M	2位数的分
%W	每年的第几周，星期一为每周第一天

通过datetime.strptime方法可将字符串格式转换为datetime数据类型，如图10.7所示。

```
value = '2018-4-12'

datetime.strptime(value, '%Y-%m-%d')
datetime.datetime(2018, 4, 12, 0, 0)
```

图10.7　字符串转换为datetime类

在pandas中，可通过to_datetime方法快速将一列字符串数据转换为时间数据。以第6章的中综合示例为例，可以看出HireDate字段的数据类型为字符串，如图10.8所示。

```
import pandas as pd
salary = pd.read_csv(open('H:\python数据分析\数据\Baltimore_City_Employee_Salaries_FY2016.csv'))
salary.head()
```

	Name	JobTitle	AgencyID	Agency	HireDate	AnnualSalary	GrossPay
0	Aaron,Patricia G	Facilities/Office Services II	A03031	OED-Employment Dev (031)	10/24/1979 12:00:00 AM	$56705.00	$54135.44
1	Aaron,Petra L	ASSISTANT STATE'S ATTORNEY	A29045	States Attorneys Office (045)	09/25/2006 12:00:00 AM	$75500.00	$72445.87
2	Abbey,Emmanuel	CONTRACT SERV SPEC II	A40001	M-R Info Technology (001)	05/01/2013 12:00:00 AM	$60060.00	$59602.58
3	Abbott-Cole,Michelle	Operations Officer III	A90005	TRANS-Traffic (005)	11/28/2014 12:00:00 AM	$70000.00	$59517.21
4	Abdal-Rahim,Naim A	EMT Firefighter Suppression	A64120	Fire Department (120)	03/30/2011 12:00:00 AM	$64365.00	$74770.82

```
type(salary['HireDate'][0])
```

```
str
```

图10.8　字符串类型

通过to_datetime方法可以将HireDate字段进行转换，如图10.9所示。该数据为Timestamp类型（时间戳）。

```
salary['HireDate'] = pd.to_datetime(salary['HireDate'])
salary.head()
```

	Name	JobTitle	AgencyID	Agency	HireDate	AnnualSalary	GrossPay
0	Aaron,Patricia G	Facilities/Office Services II	A03031	OED-Employment Dev (031)	1979-10-24	$56705.00	$54135.44
1	Aaron,Petra L	ASSISTANT STATE'S ATTORNEY	A29045	States Attorneys Office (045)	2006-09-25	$75500.00	$72445.87
2	Abbey,Emmanuel	CONTRACT SERV SPEC II	A40001	M-R Info Technology (001)	2013-05-01	$60060.00	$59602.58
3	Abbott-Cole,Michelle	Operations Officer III	A90005	TRANS-Traffic (005)	2014-11-28	$70000.00	$59517.21
4	Abdal-Rahim,Naim A	EMT Firefighter Suppression	A64120	Fire Department (120)	2011-03-30	$64365.00	$74770.82

```
type(salary['HireDate'][0])
```

```
pandas._libs.tslib.Timestamp
```

图10.9　将HireDate字段转换为datetime类

10.2　时间序列基础

时间序列是以时间戳为索引的Series或DataFrame。本节将讲解时间序列的构造方法，以及时间序列的索引和切片。

10.2.1　时间序列构造

pandas中的时间序列指的是以时间数据为索引的Series或DataFrame。如图10.10所示为创建的一个时间序列Series。

```
from datetime import datetime
import numpy as np
import pandas as pd
```

```
date = [datetime(2018, 4, 1), datetime(2018, 4, 5),
        datetime(2018, 4, 7), datetime(2018, 4, 9),
        datetime(2018, 4, 10), datetime(2018, 4, 15)]
```

```
s = pd.Series(np.arange(6),index=date)
s
```

```
2018-04-01    0
2018-04-05    1
2018-04-07    2
2018-04-09    3
2018-04-10    4
2018-04-15    5
dtype: int32
```

图10.10　时间序列Series

创建的这个时间序列Series的索引为DatetimeIndex对象，如图10.11所示。而DatetimeIndex对象的每个标量值是pandas的Timestamp对象，如图10.12所示。该对象可以保存频率信息，后面会讲解其用途。

```
s.index
```

```
DatetimeIndex(['2018-04-01', '2018-04-05', '2018-04-07', '2018-04-09',
               '2018-04-10', '2018-04-15'],
              dtype='datetime64[ns]', freq=None)
```

图10.11　DatetimeIndex对象

```
s.index[0]
```

```
Timestamp('2018-04-01 00:00:00')
```

图10.12　Timestamp对象

跟普通的Series一样，不同索引的时间序列的算术运算会按照索引对齐，如图10.13所示。

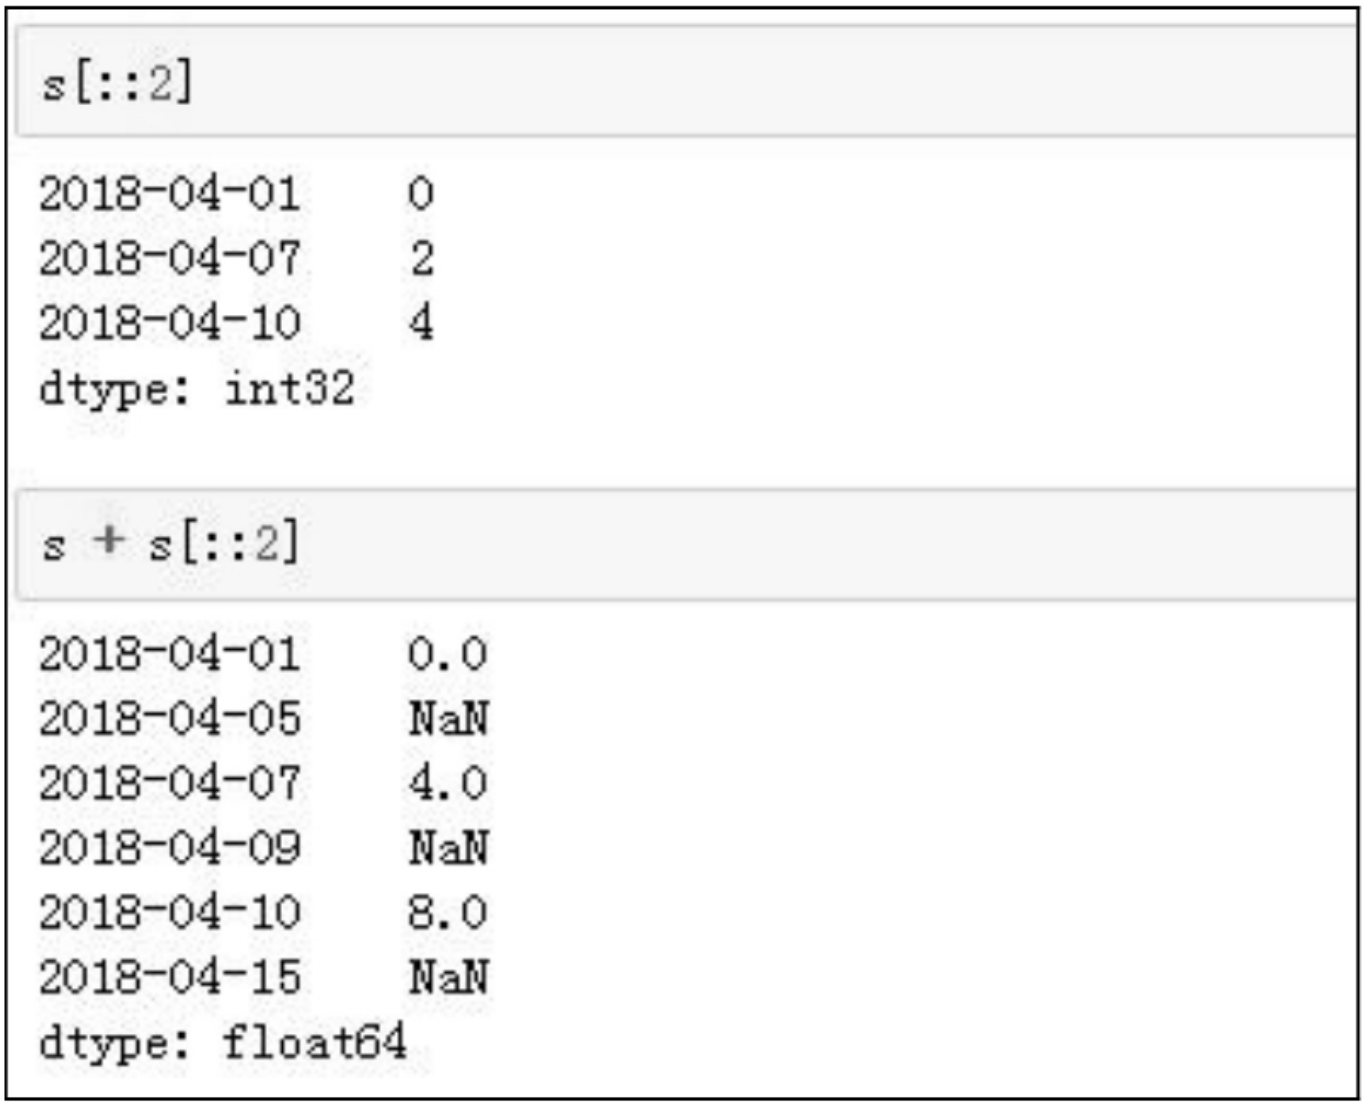

图10.13　算术运算

10.2.2　索引与切片

时间序列的索引用法和pandas基础数据类型的用法是一样的，如图10.14所示。传入一个可用于解释的日期字符串，同样也可以完成索引工作，这是一种较方便的用法，如图10.15所示。

```
s
```

```
2018-04-01    0
2018-04-05    1
2018-04-07    2
2018-04-09    3
2018-04-10    4
2018-04-15    5
dtype: int32
```

```
s[2]
```

```
2
```

图10.14　时间序列索引1

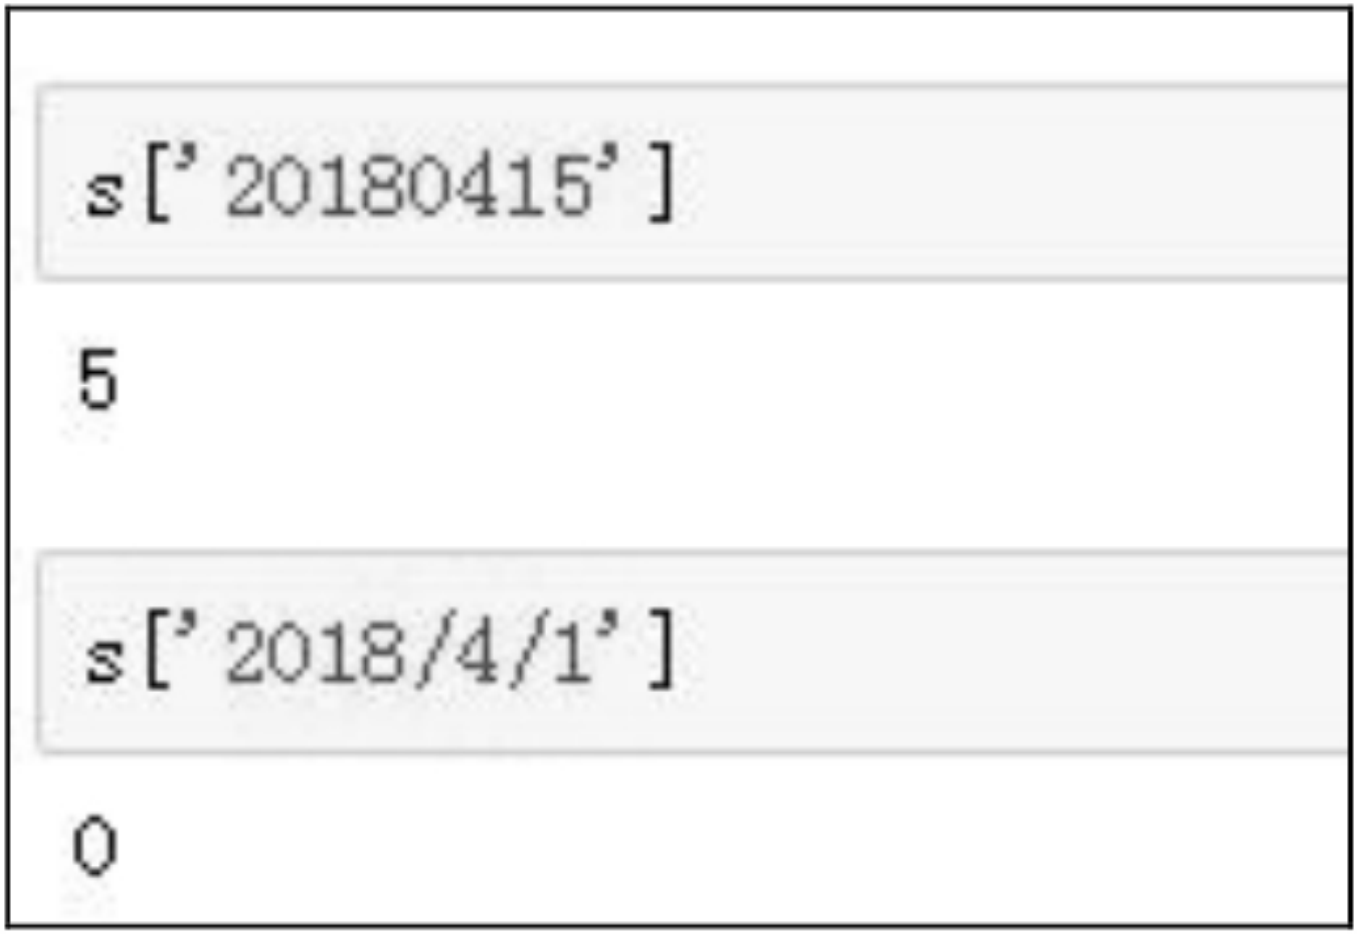

图10.15　时间序列索引2

切片的使用方法和pandas基础数据的用法是一样的，如图10.16所示。同样的，传入日期字符串或者datetime类数据也可以完成切片。由于大部分时间序列数据是按时间先后顺序排列的，如果索引值不在该时间序列中也可以实现切片，如图10.17所示。

```
s
```

```
2018-04-01    0
2018-04-05    1
2018-04-07    2
2018-04-09    3
2018-04-10    4
2018-04-15    5
dtype: int32
```

```
s[2:5]
```

```
2018-04-07    2
2018-04-09    3
2018-04-10    4
dtype: int32
```

图10.16　时间序列切片1

```
s['2018/4/5':'2018/4/11']
```

```
2018-04-05    1
2018-04-07    2
2018-04-09    3
2018-04-10    4
dtype: int32
```

```
s[datetime(2018, 4, 7):]
```

```
2018-04-07    2
2018-04-09    3
2018-04-10    4
2018-04-15    5
dtype: int32
```

图10.17　时间序列切片2

对于长时间序列来说，可以通过年、月来轻松获取时间序列的切片，如图10.18和图10.19所示。

```
date2 = [datetime(2018, 4, 1), datetime(2018, 4, 5),
        datetime(2018, 4, 13), datetime(2018, 4, 27),
        datetime(2018, 9, 4), datetime(2018, 9, 8),
        datetime(2018, 9, 12), datetime(2018, 9, 23),
        datetime(2019, 3, 12), datetime(2019, 3, 27),
        datetime(2019, 6, 7), datetime(2019, 6, 17)]
```

```
long_s = pd.Series(np.arange(12),index=date2)
long_s
```

```
2018-04-01     0
2018-04-05     1
2018-04-13     2
2018-04-27     3
2018-09-04     4
2018-09-08     5
2018-09-12     6
2018-09-23     7
2019-03-12     8
2019-03-27     9
2019-06-07    10
2019-06-17    11
dtype: int32
```

图10.18　创建时间序列Series

```
long_s['2019']
```

```
2019-03-12     8
2019-03-27     9
2019-06-07    10
2019-06-17    11
dtype: int32
```

```
long_s['2018-9']
```

```
2018-09-04    4
2018-09-08    5
2018-09-12    6
2018-09-23    7
dtype: int32
```

图10.19　数据切片

注意：时间序列的DataFrame的索引和切片使用方法同上面一样，不再赘述。

对于具有重复索引的时间序列，可通过索引的is_unique属性进行检查，如图10.20所示。

```
date3 = pd.DatetimeIndex(['2018/4/14', '2018/4/14',
                          '2018/5/23', '2018/5/23',
                          '2018/6/13', '2018/6,13'])
```

```
dup_s = pd.Series(np.arange(6), index=date3)
dup_s
```

```
2018-04-14    0
2018-04-14    1
2018-05-23    2
2018-05-23    3
2018-06-13    4
2018-06-13    5
dtype: int32
```

```
dup_s.index.is_unique
```

```
False
```

图10.20　重复索引检查

对重复索引的时间序列进行索引时，产生的是切片，如图10.21所示。

这样可通过groupby函数对其进行聚合，如图10.22所示。

```
dup_s['20180523']
```

```
2018-05-23    2
2018-05-23    3
dtype: int32
```

图10.21　重复索引

```
dup_s.groupby(level=0).mean()
```

```
2018-04-14    0.5
2018-05-23    2.5
2018-06-13    4.5
dtype: float64
```

```
dup_s.groupby(level=0).sum()
```

```
2018-04-14    1
2018-05-23    5
2018-06-13    9
dtype: int32
```

图10.22　通过groupby函数聚合

10.3　日期

本节将讲解如何生成指定长度的DatetimeIndex，时间序列中的基础频率及如何移动时间数据。

10.3.1　日期范围

使用pd.date_range函数可以创建指定长度的DatetimeIndex索引，如图10.23所示。

```
index = pd.date_range('2018/4/1', '2018/5/30')
index
```

```
DatetimeIndex(['2018-04-01', '2018-04-02', '2018-04-03', '2018-04-04',
               '2018-04-05', '2018-04-06', '2018-04-07', '2018-04-08',
               '2018-04-09', '2018-04-10', '2018-04-11', '2018-04-12',
               '2018-04-13', '2018-04-14', '2018-04-15', '2018-04-16',
               '2018-04-17', '2018-04-18', '2018-04-19', '2018-04-20',
               '2018-04-21', '2018-04-22', '2018-04-23', '2018-04-24',
               '2018-04-25', '2018-04-26', '2018-04-27', '2018-04-28',
               '2018-04-29', '2018-04-30', '2018-05-01', '2018-05-02',
               '2018-05-03', '2018-05-04', '2018-05-05', '2018-05-06',
               '2018-05-07', '2018-05-08', '2018-05-09', '2018-05-10',
               '2018-05-11', '2018-05-12', '2018-05-13', '2018-05-14',
               '2018-05-15', '2018-05-16', '2018-05-17', '2018-05-18',
               '2018-05-19', '2018-05-20', '2018-05-21', '2018-05-22',
               '2018-05-23', '2018-05-24', '2018-05-25', '2018-05-26',
               '2018-05-27', '2018-05-28', '2018-05-29', '2018-05-30'],
              dtype='datetime64[ns]', freq='D')
```

图10.23　日期范围1

如图10.23所示，默认情况下，产生的DatetimeIndex索引的间隔为天，也就是说，时间频率是天。通过freq参数可以使用其他频率，如图10.24所示。

```
index = pd.date_range('2018/4/1', '2018/12/31', freq='M')
index
```

```
DatetimeIndex(['2018-04-30', '2018-05-31', '2018-06-30', '2018-07-31',
               '2018-08-31', '2018-09-30', '2018-10-31', '2018-11-30',
               '2018-12-31'],
              dtype='datetime64[ns]', freq='M')
```

图10.24　日期范围2

在pd.date_range函数中传入起始或结束日期，再传入一个表示一段时间的数据，就可以创建指定长度的DatetimeIndex索引，如图10.25所示。

```
pd.date_range(start = '2018/4/1', periods=20)
```

```
DatetimeIndex(['2018-04-01', '2018-04-02', '2018-04-03', '2018-04-04',
               '2018-04-05', '2018-04-06', '2018-04-07', '2018-04-08',
               '2018-04-09', '2018-04-10', '2018-04-11', '2018-04-12',
               '2018-04-13', '2018-04-14', '2018-04-15', '2018-04-16',
               '2018-04-17', '2018-04-18', '2018-04-19', '2018-04-20'],
              dtype='datetime64[ns]', freq='D')
```

```
pd.date_range(end = '2018/6/1', periods=20)
```

```
DatetimeIndex(['2018-05-13', '2018-05-14', '2018-05-15', '2018-05-16',
               '2018-05-17', '2018-05-18', '2018-05-19', '2018-05-20',
               '2018-05-21', '2018-05-22', '2018-05-23', '2018-05-24',
               '2018-05-25', '2018-05-26', '2018-05-27', '2018-05-28',
               '2018-05-29', '2018-05-30', '2018-05-31', '2018-06-01'],
              dtype='datetime64[ns]', freq='D')
```

图10.25　日期范围3

默认情况下，pd.date_range函数会保留完整的时间信息，但可通过normalize参数使其规范化，如图10.26所示。

```
pd.date_range(start = '2018/6/1 15:11:34', periods=10)
```

```
DatetimeIndex(['2018-06-01 15:11:34', '2018-06-02 15:11:34',
               '2018-06-03 15:11:34', '2018-06-04 15:11:34',
               '2018-06-05 15:11:34', '2018-06-06 15:11:34',
               '2018-06-07 15:11:34', '2018-06-08 15:11:34',
               '2018-06-09 15:11:34', '2018-06-10 15:11:34'],
              dtype='datetime64[ns]', freq='D')
```

```
pd.date_range(start = '2018/6/1 15:11:34', periods=10, normalize=True)
```

```
DatetimeIndex(['2018-06-01', '2018-06-02', '2018-06-03', '2018-06-04',
               '2018-06-05', '2018-06-06', '2018-06-07', '2018-06-08',
               '2018-06-09', '2018-06-10'],
              dtype='datetime64[ns]', freq='D')
```

图10.26　日期范围4

10.3.2　频率与移动

时间序列的频率由基础频率和日期偏移量组成。例如，通过4H就可以创建以4个小时为频率的DatetimeIndex索引，如图10.27所示。

```
pd.date_range(start = '2018/4/1', periods=10, freq='4H')
```

```
DatetimeIndex(['2018-04-01 00:00:00', '2018-04-01 04:00:00',
               '2018-04-01 08:00:00', '2018-04-01 12:00:00',
               '2018-04-01 16:00:00', '2018-04-01 20:00:00',
               '2018-04-02 00:00:00', '2018-04-02 04:00:00',
               '2018-04-02 08:00:00', '2018-04-02 12:00:00'],
              dtype='datetime64[ns]', freq='4H')
```

图10.27　频率1

更为复杂的频率字符串，也可以被高效地解析为相对应的频率，如图10.28所示。

```
pd.date_range(start = '2018/4/1', periods=20, freq='2H20min38S')
```

```
DatetimeIndex(['2018-04-01 00:00:00', '2018-04-01 02:20:38',
               '2018-04-01 04:41:16', '2018-04-01 07:01:54',
               '2018-04-01 09:22:32', '2018-04-01 11:43:10',
               '2018-04-01 14:03:48', '2018-04-01 16:24:26',
               '2018-04-01 18:45:04', '2018-04-01 21:05:42',
               '2018-04-01 23:26:20', '2018-04-02 01:46:58',
               '2018-04-02 04:07:36', '2018-04-02 06:28:14',
               '2018-04-02 08:48:52', '2018-04-02 11:09:30',
               '2018-04-02 13:30:08', '2018-04-02 15:50:46',
               '2018-04-02 18:11:24', '2018-04-02 20:32:02'],
              dtype='datetime64[ns]', freq='8438S')
```

图10.28　频率2

时间序列的常用基础频率如表10.3所示。

表10.3　时间序列的常用基础频率

别　名	使用说明
D	每日历日
B	每工作日
H	每小时
T或者min	每分钟
S	每秒
M	每月最后一个日历日
BM	每月最后一个工作日
A-JAN、A-FEB…	每年指定月份的最后一个日历日

移动数据就是沿着时间索引将数据向前移或向后移。通过shift方法可以完成移动数据的操作，如图10.29所示。

```
date4 = pd.date_range('2018/4/1', periods=5)
s = pd.Series(np.arange(5), index=date4)
s
```

```
2018-04-01    0
2018-04-02    1
2018-04-03    2
2018-04-04    3
2018-04-05    4
Freq: D, dtype: int32
```

```
s.shift(2)
```

```
2018-04-01    NaN
2018-04-02    NaN
2018-04-03    0.0
2018-04-04    1.0
2018-04-05    2.0
Freq: D, dtype: float64
```

```
s.shift(-2)
```

```
2018-04-01    2.0
2018-04-02    3.0
2018-04-03    4.0
2018-04-04    NaN
2018-04-05    NaN
Freq: D, dtype: float64
```

图10.29　移动数据1

这种单纯的移动不会修改索引，而是使部分数据被丢弃。如果在shift方法中传入频率参数，这样就是修改索引了，如图10.30所示。

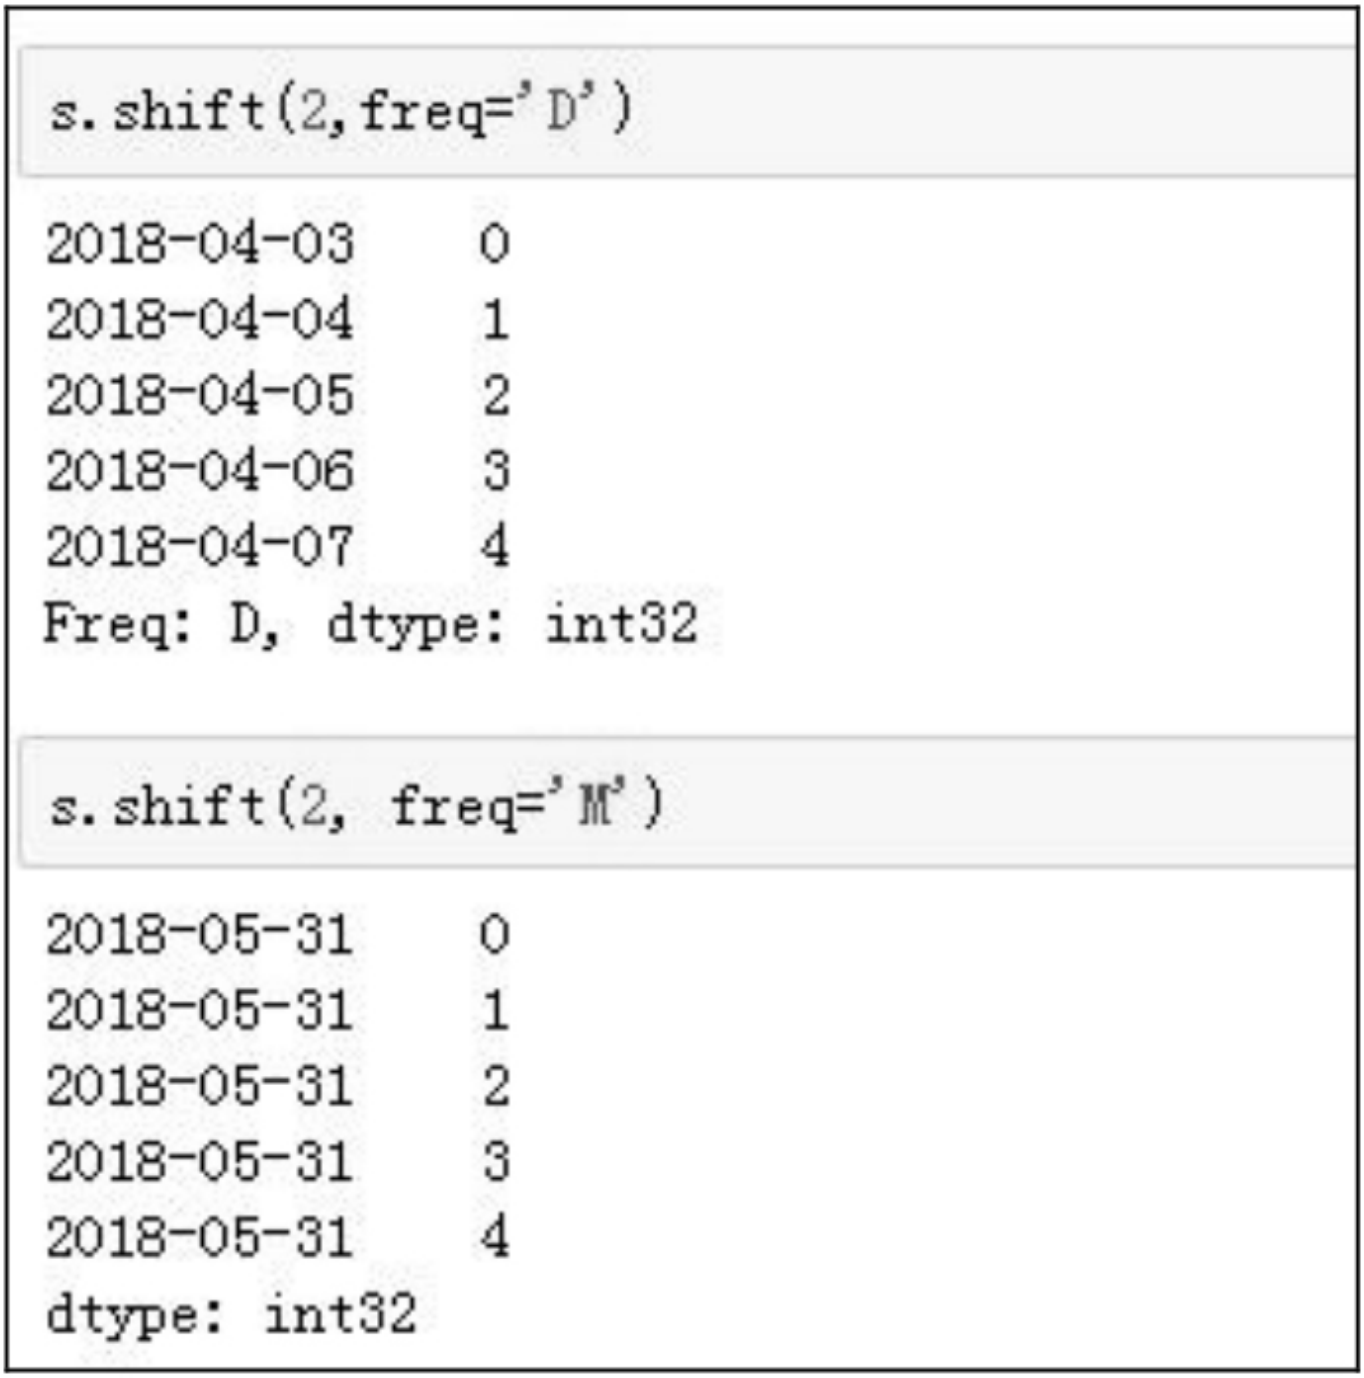

图10.30　移动数据2

10.4　时期

时期表示的是时间区间，如数日、数月和数年等。本节将讲解时期的构造方法、时期数据的频率转换和其数据转换。

10.4.1　时期基础

Period可以创建时期数据类型，传入字符串或者整数、频率即可，如图10.31所示。

图10.31中的Period对象表示从2018年1月1日到2018年12月31日之间的整段时间。该Period对象可以进行加法和减法计算，使其进行时间的偏移。两个Period对象如果有相同频率，则它们的差为它们之间的单位数量，如图10.32所示。

```
p = pd.Period(2018, freq='A-DEC')
p
```

```
Period('2018', 'A-DEC')
```

图10.31　时期数据类型

```
p + 2
```

```
Period('2020', 'A-DEC')
```

```
p - 5
```

```
Period('2013', 'A-DEC')
```

```
pd.Period(2025, freq='A-DEC') - p
```

```
7
```

图10.32　时期计算

类似于pd.date_range，pd.period_range函数可以创建时期范围，PeriodIndex索引同样可以构造Series或DataFrame，如图10.33所示。

```
date5 = pd.period_range('2018/4/1', '2018/10/5', freq='M')
date5
```

```
PeriodIndex(['2018-04', '2018-05', '2018-06', '2018-07', '2018-08', '2018-09',
             '2018-10'],
            dtype='period[M]', freq='M')
```

```
pd.Series(np.arange(7),index=date5)
```

```
2018-04    0
2018-05    1
2018-06    2
2018-07    3
2018-08    4
2018-09    5
2018-10    6
Freq: M, dtype: int32
```

图10.33　时期范围

10.4.2　频率转换

Period和PeriodIndex对象可以通过asfreq方法转换频率，如图10.34所示为将年度时期转换为月度时期。

当年度的频率不是位于12月时，转换频率就会发生变化，如图10.35所示。

```
p = pd.Period(2018, freq='A-DEC')
p
```

```
Period('2018', 'A-DEC')
```

```
p.asfreq('M', how='start')
```

```
Period('2018-01', 'M')
```

```
p.asfreq('M', how='end')
```

```
Period('2018-12', 'M')
```

图10.34　频率转换1

```
p = pd.Period(2018, freq='A-JUN')
p
```

```
Period('2018', 'A-JUN')
```

```
p.asfreq('M', how='start')
```

```
Period('2017-07', 'M')
```

```
p.asfreq('M', how='end')
```

```
Period('2018-06', 'M')
```

图10.35　频率转换2

PeriodIndex对象的频率转换方式也一样，如图10.36所示。

```
date6 = pd.period_range('2014', '2018', freq='A-DEC')
date6
```

```
PeriodIndex(['2014', '2015', '2016', '2017', '2018'], dtype='period[A-DEC]', freq='A-DEC')
```

```
ps = pd.Series(np.arange(5), index=date6)
ps
```

```
2014    0
2015    1
2016    2
2017    3
2018    4
Freq: A-DEC, dtype: int32
```

```
ps.asfreq('M', how='start')
```

```
2014-01    0
2015-01    1
2016-01    2
2017-01    3
2018-01    4
Freq: M, dtype: int32
```

图10.36　频率转换3

10.4.3 时期数据转换

利用to_period方法可以将由时间戳索引的时间序列数据转换为以时期为索引，如图10.37所示。

```
date7 = pd.date_range('2018/4/1', periods=4, freq='M')
s = pd.Series(np.arange(4), index=date7)
s
```

```
2018-04-30    0
2018-05-31    1
2018-06-30    2
2018-07-31    3
Freq: M, dtype: int32
```

```
ps = s.to_period()
ps
```

```
2018-04    0
2018-05    1
2018-06    2
2018-07    3
Freq: M, dtype: int32
```

图10.37　to_period方法

当然，也可以指定转换的频率，如图10.38所示。通过to_timestamp方法可以进行逆操作，如图10.39所示。

```
ps = s.to_period('A-DEC')
ps
```

```
2018    0
2018    1
2018    2
2018    3
Freq: A-DEC, dtype: int32
```

图10.38　指定频率

```
ps = s.to_period()
ps
```

```
2018-04    0
2018-05    1
2018-06    2
2018-07    3
Freq: M, dtype: int32
```

```
ps.to_timestamp(how='start')
```

```
2018-04-01    0
2018-05-01    1
2018-06-01    2
2018-07-01    3
Freq: MS, dtype: int32
```

图10.39　进行逆操作

10.5　频率转换与重采样

重采样是时间序列频率转换的处理过程。高频率聚合到低频率称为降采样，而低频率转换为高频率为升采样。本节将讲解重采样的使用方法。

10.5.1　重采样

pandas中的resample方法用于各种频率的转换工作。如图10.40所示为将间隔为“天”的频率转换为间隔为“月度”的频率，这里的聚合方法为平均值。

```
date = pd.date_range(start = '2018/4/1', periods=100, freq='D')
s = pd.Series(np.arange(100),index=date)
s.head(10)
```

```
2018-04-01    0
2018-04-02    1
2018-04-03    2
2018-04-04    3
2018-04-05    4
2018-04-06    5
2018-04-07    6
2018-04-08    7
2018-04-09    8
2018-04-10    9
Freq: D, dtype: int32
```

```
s.resample('M').mean()
```

```
2018-04-30    14.5
2018-05-31    45.0
2018-06-30    75.5
2018-07-31    95.0
Freq: M, dtype: float64
```

图10.40　天频率转换为月度频率

如表10.4所示为resample方法的参数及说明，具体使用方法后面会详细解说。

表10.4　resample方法的参数及说明

参　　数	使用说明
freq	转换频率
axies=0	重采样的轴
closed='right'	在降采样中，设置各时间段哪端是闭合的
label='right'	在降采样中，如何设置聚合值的标签
loffset=None	设置时间偏移量
kind=None	聚合到时期或时间戳，默认为时间序列的索引类型
convention=None	升采样所采用的约定（start或end）。默认为end

10.5.2　降采样

在降采样中，重点需要考虑的是closed和label参数，这两个参数分别表示哪边区间是闭合的，哪边用于标记。如图10.41所示为将两个参数值都设置为right。

```
date = pd.date_range(start = '2018/4/1', periods=12, freq='D')
s = pd.Series(np.arange(12),index=date)
s
```

```
2018-04-01     0
2018-04-02     1
2018-04-03     2
2018-04-04     3
2018-04-05     4
2018-04-06     5
2018-04-07     6
2018-04-08     7
2018-04-09     8
2018-04-10     9
2018-04-11    10
2018-04-12    11
Freq: D, dtype: int32
```

```
s.resample('5D', closed='right', label='right').sum()
```

```
2018-04-01     0
2018-04-06    15
2018-04-11    40
2018-04-16    11
Freq: 5D, dtype: int32
```

图10.41　降采样1

如图10.42所示为将closed和label参数值均设为left。其处理的过程如图10.43所示。

```
s.resample('5D', closed='left', label='left').sum()
```

```
2018-04-01    10
2018-04-06    35
2018-04-11    21
Freq: 5D, dtype: int32
```

图10.42　降采样2

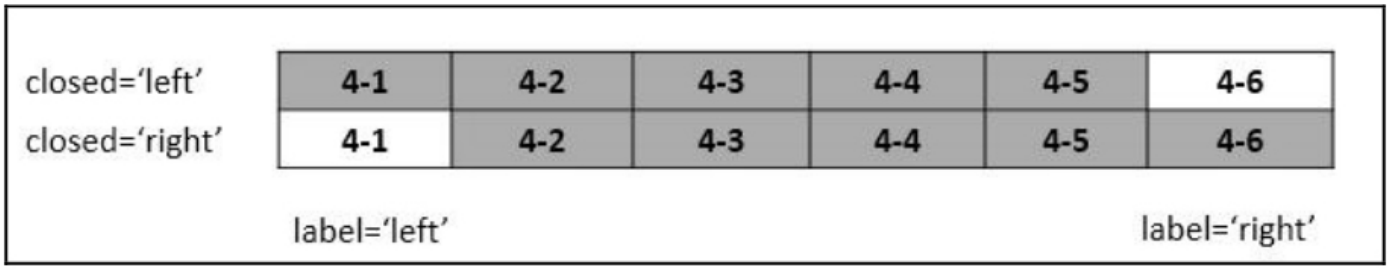

图10.43　参数示例

通过设置loffset日期偏移量，也可以看出其时间戳所属的区间，如图10.44所示。

```
s.resample('5D', closed='right', label='right', loffset='-1D').sum()

2018-03-31     0
2018-04-05    15
2018-04-10    40
2018-04-15    11
Freq: 5D, dtype: int32
```

图10.44　设置loffset偏移量

10.5.3　升采样

在升采样中用到的就不再是聚合，而是需要对缺失值进行填充，其填充方法与前面介绍的fillna一样，如图10.45所示。也可以设置填充的个数，如图10.46所示。

```
date = [datetime(2018,4,3), datetime(2018,4,13)]
s = pd.Series([2, 5],index=date)
s
```

```
2018-04-03    2
2018-04-13    5
dtype: int64
```

```
s.resample('D').ffill()
```

```
2018-04-03    2
2018-04-04    2
2018-04-05    2
2018-04-06    2
2018-04-07    2
2018-04-08    2
2018-04-09    2
2018-04-10    2
2018-04-11    2
2018-04-12    2
2018-04-13    5
Freq: D, dtype: int64
```

图10.45　升采样1

```
s.resample('D').ffill(2)
```

```
2018-04-03    2.0
2018-04-04    2.0
2018-04-05    2.0
2018-04-06    NaN
2018-04-07    NaN
2018-04-08    NaN
2018-04-09    NaN
2018-04-10    NaN
2018-04-11    NaN
2018-04-12    NaN
2018-04-13    5.0
Freq: D, dtype: float64
```

图10.46　升采样2

10.6　综合示例——自行车租赁数据

本节以Kaggle官网中的华盛顿自行车租赁数据为例，利用时间序列方法，通过pandas可视化的手段，分析自行车租赁随时间及天气变化的分布情况。

10.6.1　数据来源

该案例使用的数据集可在Kaggle网站（https://www.kaggle.com/c/bike-sharing-demand/data）中下载，这里下载训练集，如图10.47所示。

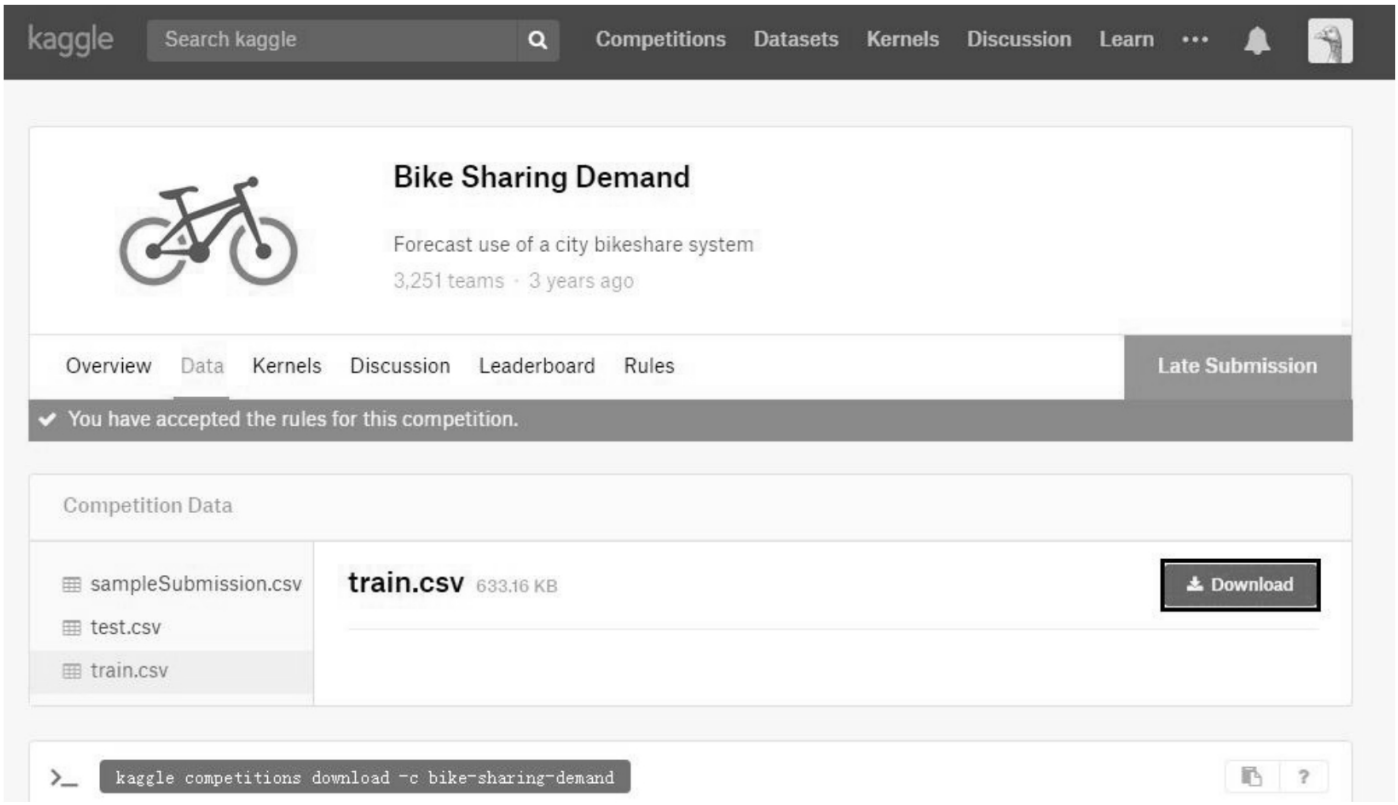

图10.47　数据下载

如图10.48所示，通过pandas读取下载好的CSV文件，即可加载该数据集。该数据为Kaggle官网上公开的华盛顿自行车共享计划中的自行车租赁数据。数据字段介绍信息可通过Kaggle官网进行查看，如图10.49所示。在自行车租赁数据集中：datetime为租赁时间；season为季节，1为春季、2为夏季，依此类推；holiday表示是否为假期，0为非假期，1为假期；workingday与holiday值正好相反，0为非工作日，1为工作日；weather为天气情况，数字越大，天气越差；temp和atemp为气温；humidity为湿度；windspeed为风速；casual为普通用户；registered为注册用户；count为租赁自行车数量。

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
```

```
bike = pd.read_csv(open(r'H:\python数据分析\数据\bike.csv'))
bike.head()
```

	datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual	registered	count
0	2011-01-01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3	13	16
1	2011-01-01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8	32	40
2	2011-01-01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5	27	32
3	2011-01-01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3	10	13
4	2011-01-01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0	1	1

图10.48　自行车租赁数据

图10.49　数据字段信息

10.6.2　定义问题

本次分析围绕时间提出问题：时间段与自行车租赁的关系情况。

10.6.3　数据清洗

首先查看各字段是否有缺失值，如图10.50所示。可以看出，各字段没有缺失值。

然后查看各字段数据类型，发现datetime字段不是时间数据类型，如图10.51所示。

```
bike.isnull().sum()
```

```
datetime      0
season        0
holiday       0
workingday    0
weather       0
temp          0
atemp         0
humidity      0
windspeed     0
casual        0
registered    0
count         0
dtype: int64
```

图10.50　查看缺失值

```
bike.dtypes
```

```
datetime       object
season          int64
holiday         int64
workingday      int64
weather         int64
temp          float64
atemp         float64
humidity        int64
windspeed     float64
casual          int64
registered      int64
count           int64
dtype: object
```

图10.51　查看数据类型

此时需利用pd.to_datetime函数将其转换为datetime类数据，如图10.52所示。

```
bike['datetime'] = pd.to_datetime(bike['datetime'])
bike.dtypes
```

```
datetime      datetime64[ns]
season                 int64
holiday                int64
workingday             int64
weather                int64
temp                 float64
atemp                float64
humidity               int64
windspeed            float64
casual                 int64
registered             int64
count                  int64
dtype: object
```

图10.52　转换为datetime类数据

最后将datetime字段设置为DataFrame的索引，这样就成为了时间序列数据，如图10.53所示。

```
bike = bike.set_index('datetime')
bike.head()
```

datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual	registered	count
2011-01-01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3	13	16
2011-01-01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8	32	40
2011-01-01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5	27	32
2011-01-01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3	10	13
2011-01-01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0	1	1

图10.53　设置索引

10.6.4　数据探索

首先利用groupby方法也可以进行降采样，这里降采样到年份数据，如图10.54所示。可以看出，2012年的租赁数要高于2011年。

```
y_bike = bike.groupby(lambda x: x.year).mean()
y_bike['count']
```

```
2011    144.223349
2012    238.560944
Name: count, dtype: float64
```

图10.54　年份租赁数

然后通过下面的代码绘制柱状图，如图10.55所示。

```
y_bike['count'].plot(kind='bar')
```

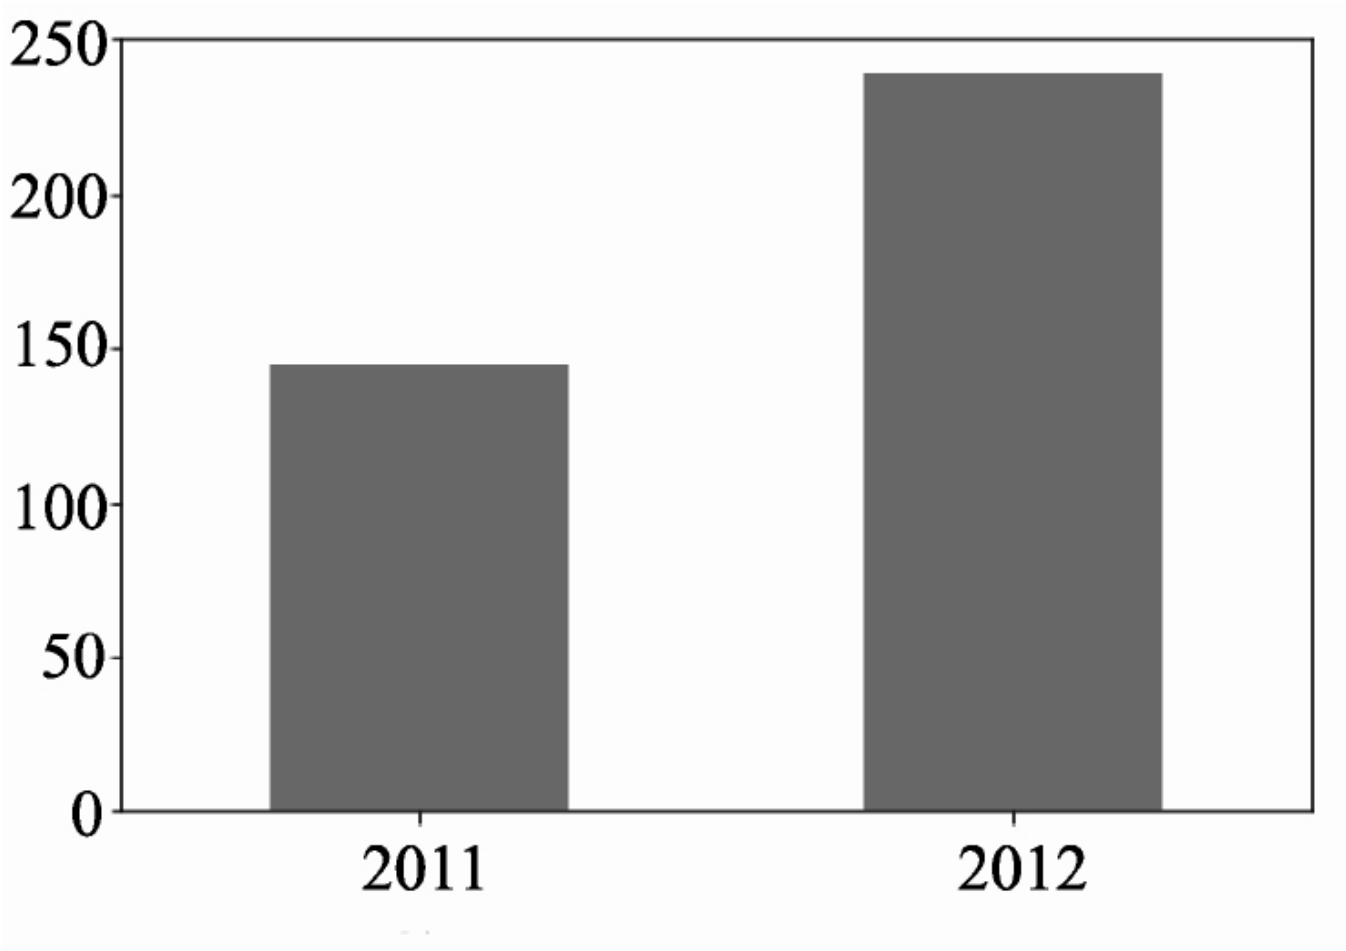

图10.55　自行车年份租赁数分布

接着再利用resample方法，将数据重采样到月份，类型为时期类型，如图10.56所示。

```
m_bike = bike.resample('M', kind='period').mean()
m_bike.head()
```

datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual	registered	count
2011-01	1.0	0.055684	0.612529	1.440835	8.633782	10.767981	56.308585	13.749830	4.658933	49.986079	54.645012
2011-02	1.0	0.000000	0.733184	1.378924	11.331076	13.999922	53.580717	15.509298	8.466368	65.174888	73.641256
2011-03	1.0	0.000000	0.735426	1.466368	14.063184	16.895594	55.923767	16.033866	17.735426	69.114350	86.849776
2011-04	2.0	0.052747	0.630769	1.619780	17.776879	21.239835	66.285714	15.844234	26.876923	84.149451	111.026374
2011-05	2.0	0.000000	0.736842	1.528509	21.528596	25.455143	71.421053	12.355358	34.791667	140.017544	174.809211

图10.56　重采样

然后利用plot方法绘制时间序列图，如图10.57所示。由图可知，2011年和2012的趋势大致相同，前几月逐渐增加，到5、6月份到达峰值，再到9月份后逐渐减少。

```
fig, axes = plt.subplots(2, 1)                                  #两行一列
m_bike['2011']['count'].plot(ax=axes[0],sharex=True)            #贡献X轴
m_bike['2012']['count'].plot(ax=axes[1])
```

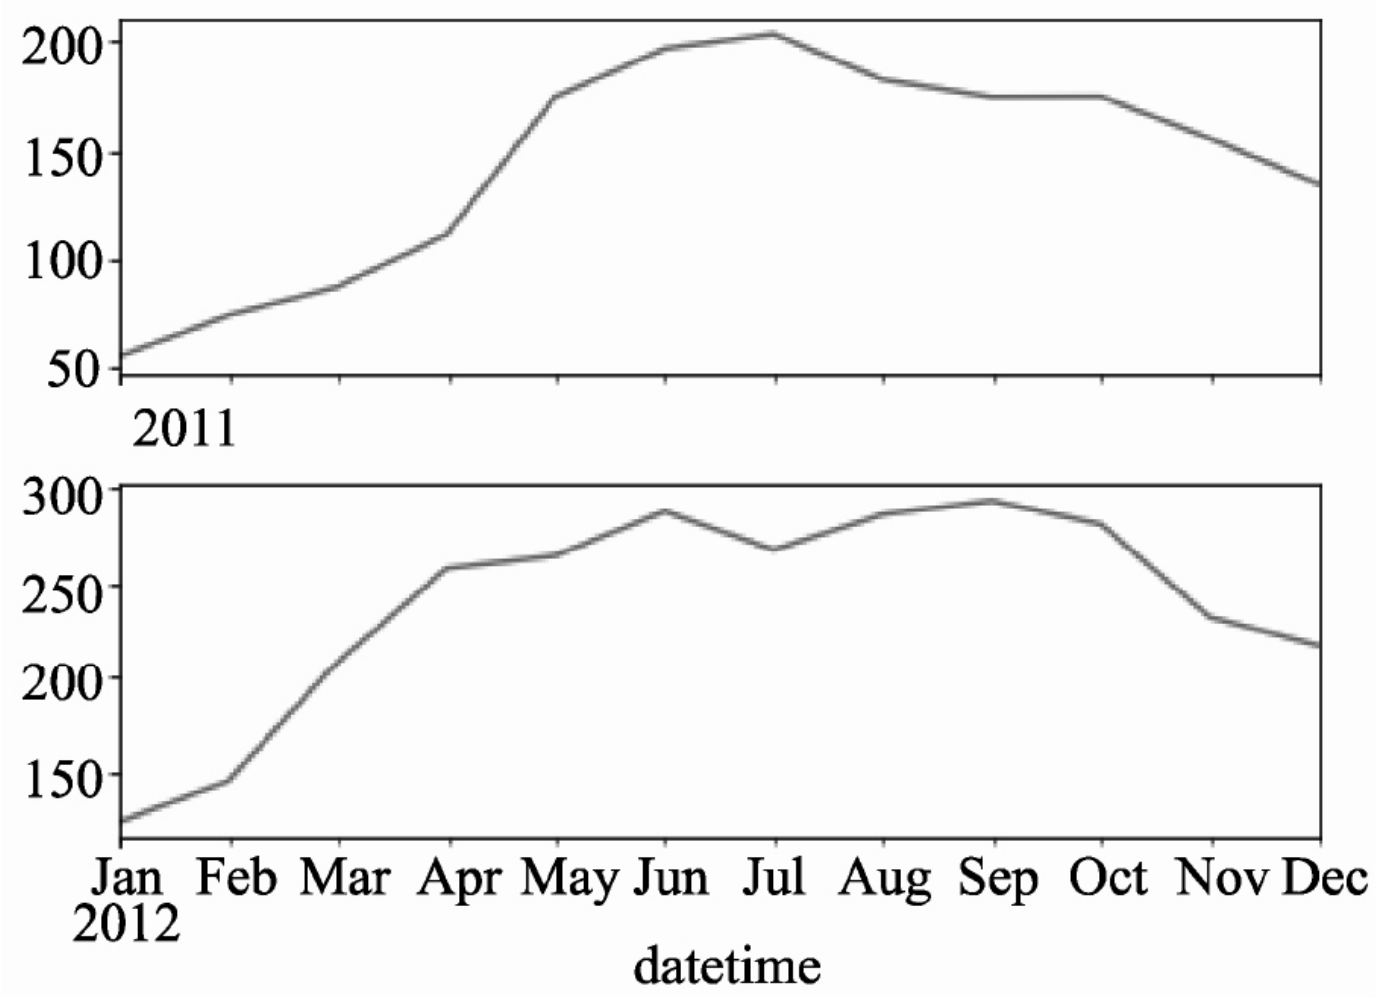

图10.57　自行车月份租赁数分布

为了分析每天和每小时的租赁数分布情况，对日（day）和时（hour）的数据进行单独存储，如图10.58所示。

```
bike['day'] = bike.index.day
bike['hour'] = bike.index.hour
bike.head()
```

datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual	registered	count	day	hour
2011-01-01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3	13	16	1	0
2011-01-01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8	32	40	1	1
2011-01-01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5	27	32	1	2
2011-01-01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3	10	13	1	3
2011-01-01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0	1	1	1	4

图10.58　day和hour字段

然后对day字段进行分组统计，如图10.59所示。

注意：训练数据只有前19天。

通过下面的代码绘制折线图，如图10.60所示。

```
d_bike.plot()
```

```
d_bike = bike.groupby('day')['count'].mean()
d_bike
```

```
day
1      180.333913
2      183.910995
3      194.696335
4      195.705575
5      189.765217
6      189.860140
7      183.773519
8      179.041812
9      187.897391
10     195.183566
11     195.679577
12     190.675393
13     194.160279
14     195.829268
15     201.527875
16     191.353659
17     205.660870
18     192.605684
19     192.311847
Name: count, dtype: float64
```

图10.59　自行车每日租赁数

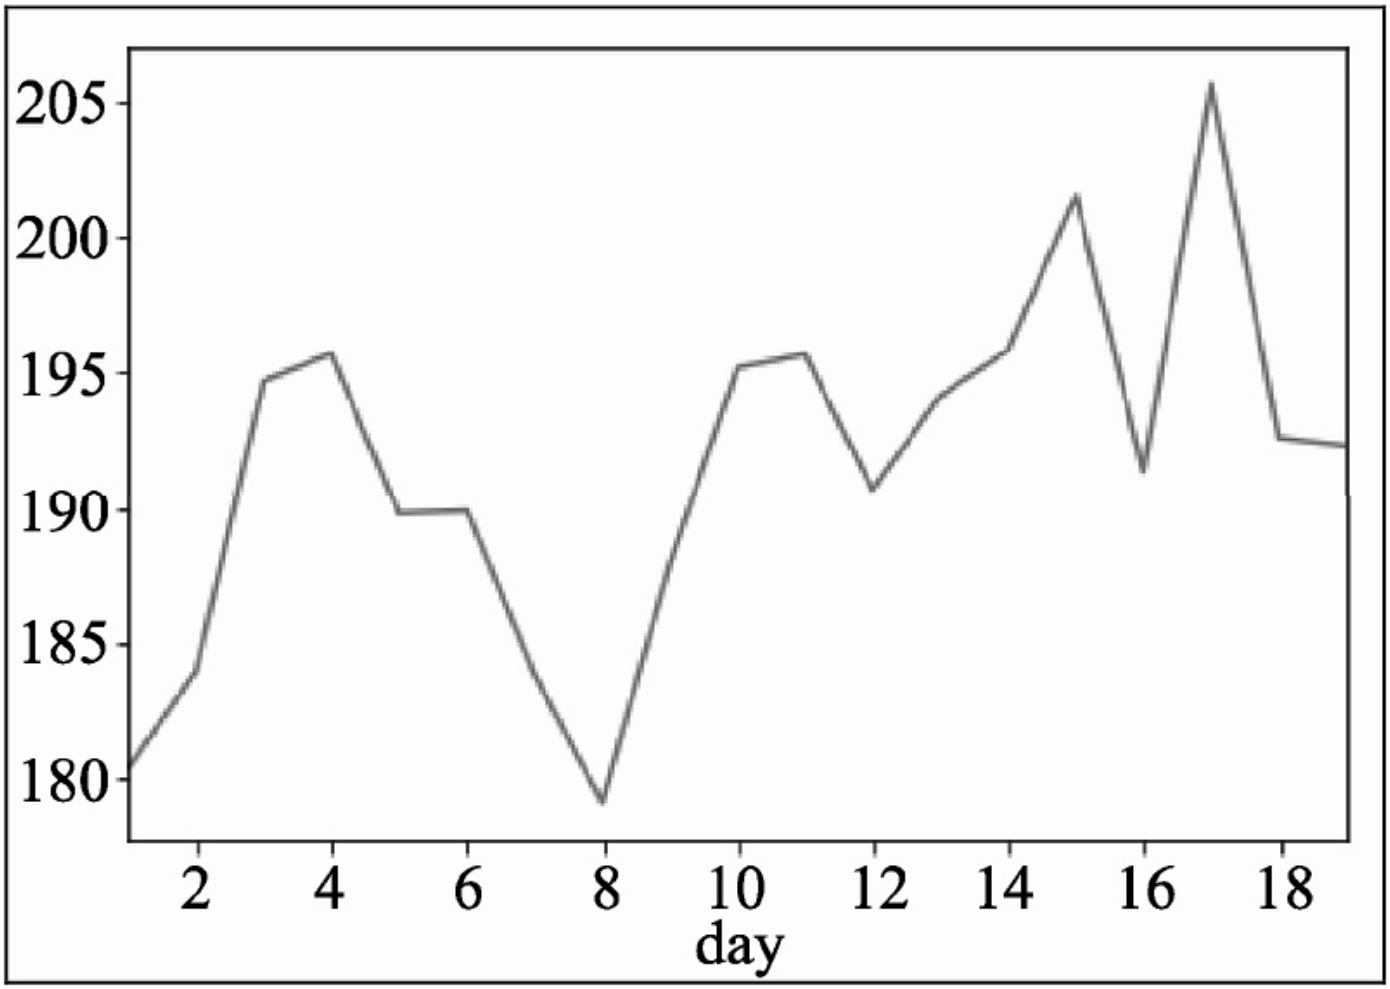

图10.60　自行车每日租赁数分布

同样，再对hour字段进行处理，如图10.61所示。图中有明显的两个峰值，都是上、下班时间段，并且晚上的峰值更高。

```
h_bike = bike.groupby('hour')['count'].mean()
h_bike.plot()
```

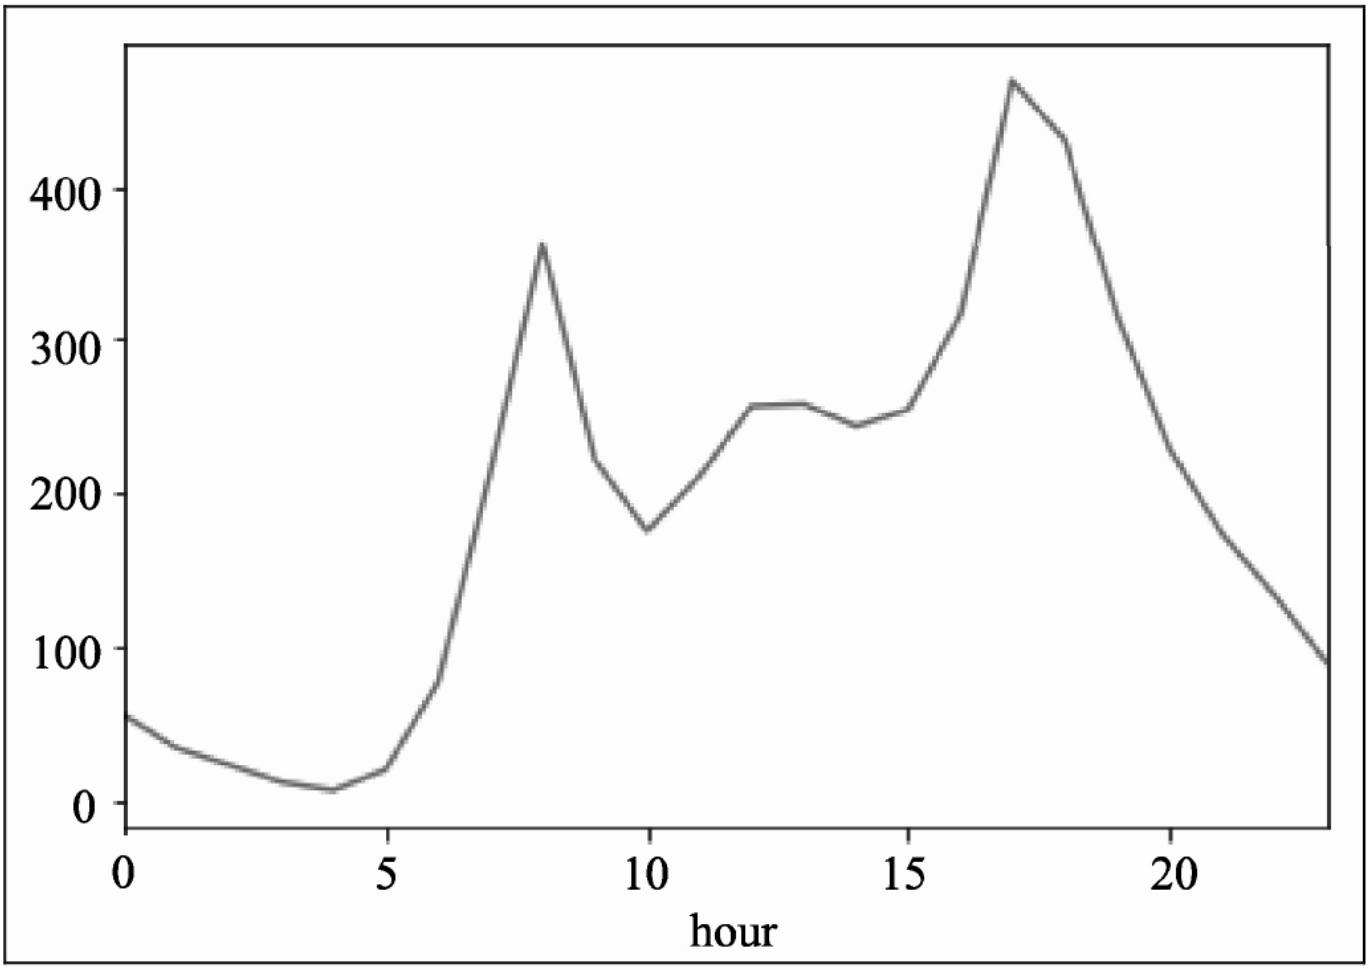

图10.61　自行车每小时租赁数分布

最后来分析下天气对自行车租赁数据的影响，如图10.62所示。可以看出，天气越差，自行车租赁数越少，但在极端天气下却略有上升。

```
weather_bike = bike.groupby('weather')['count'].mean()
weather_bike
```

```
weather
1    205.236791
2    178.955540
3    118.846333
4    164.000000
Name: count, dtype: float64
```

```
weather_bike.plot(kind='bar')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x110fc5c0>
```

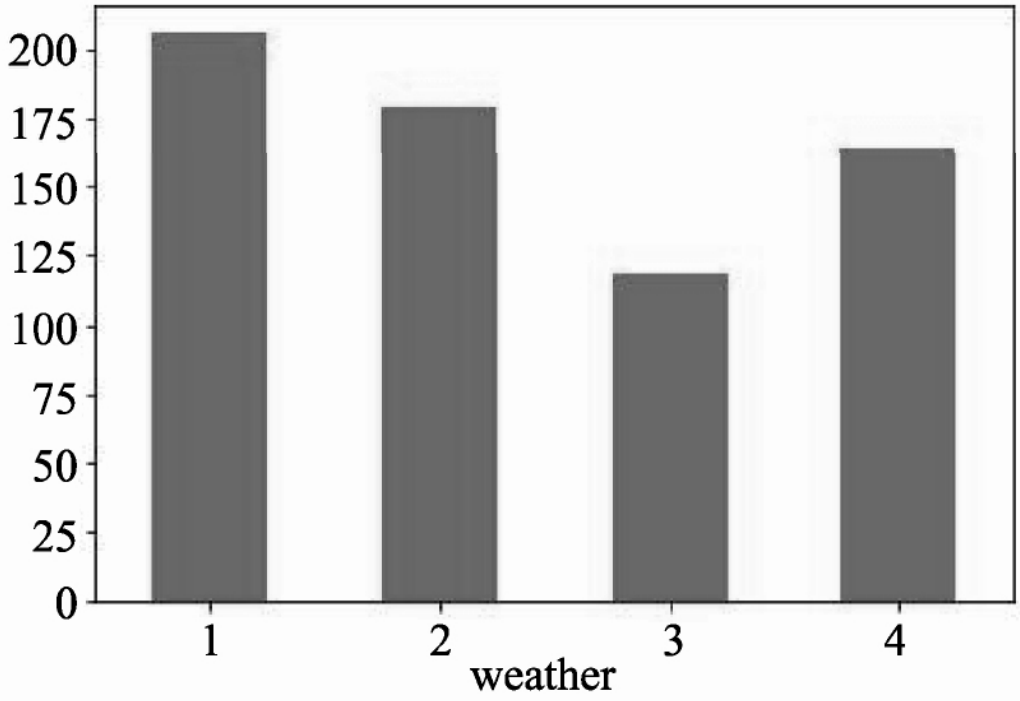

图10.62　天气情况与自行车租赁数分布

第11章　综合案例——网站日志分析

网站的日志数据记录了所有Web对服务器的访问活动。本章主要讲解如何通过Python第三方库解析网站日志；如何利用pandas对网站日志数据进行预处理，并结合前面章节中的数据分析和数据可视化技术，对网站日志数据进行分析。

下面给出本章涉及的知识点与学习目标。

· 网站日志解析：学会apache-log-parser的安装和使用。

· 数据清洗：学会网站日志数据的清洗。

· 数据分析：巩固前面章节中介绍的数据分析和可视化技术。

11.1　数据来源

本节将讲解如何利用Python第三方库apache-log-parser解析网站日志，并利用pandas对数据进行预处理。

11.1.1 网站日志解析

本章使用的Apache log数据如图11.1所示。

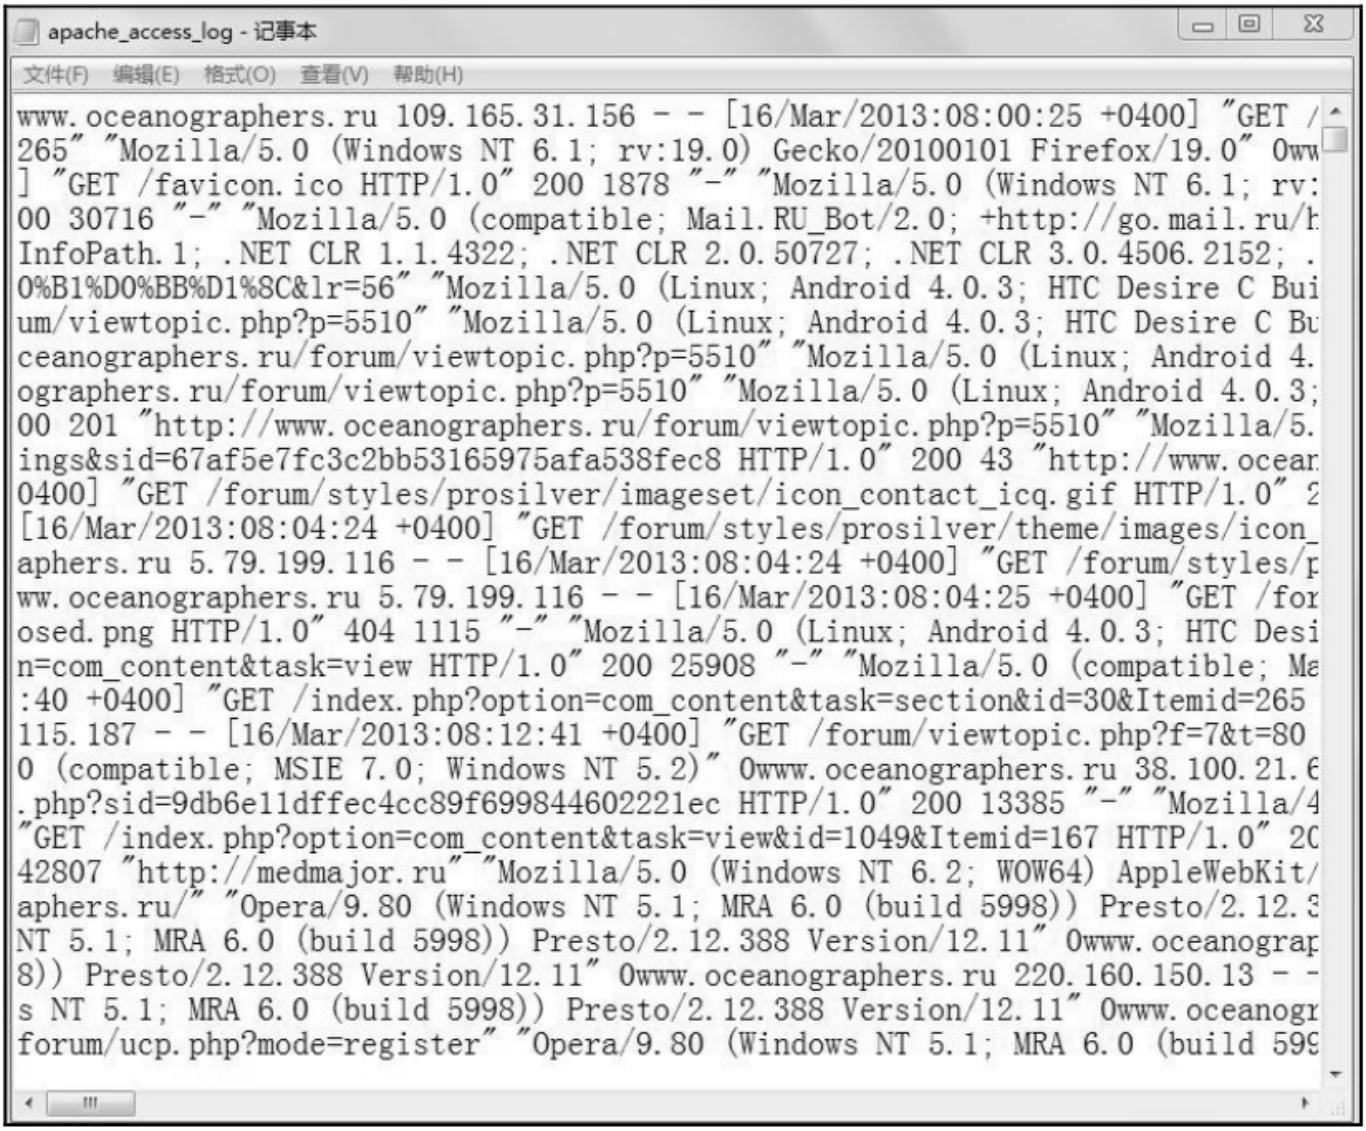

图11.1 Apache log数据

注意：该数据集可以从本书的配套资源中下载。

网站日志数据是有对应格式的，这里需要通过apache-log-parser库对该数据进行解析，使其变为规范的数据结构。如图11.2所示，首先通过PIP安装apache-log-parser解析库。

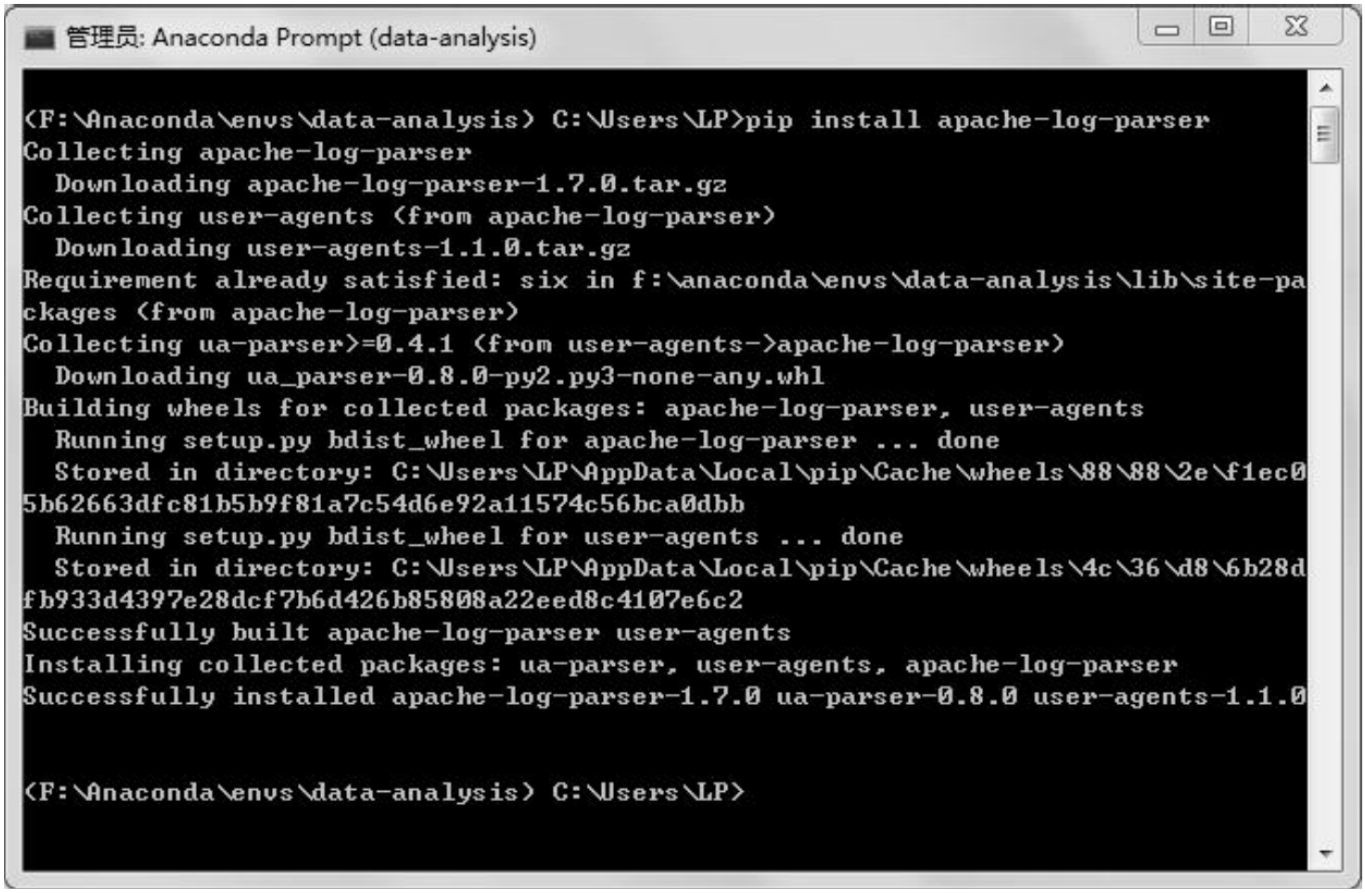

图11.2　安装解析库

apache-log-parser解析库的使用方法很简单，首先需要了解该日志的格式，以此定义网站日志的数据格式，然后通过make_parse传入即可创建解析器，如图11.3所示。

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import apache_log_parser
%matplotlib inline
```

```
fformat = '%V %h %l %u %t \"%r\" %>s %b \"%{Referer}i\" \"%{User-Agent}i\" %T'
p = apache_log_parser.make_parser(fformat)
```

图11.3　创建解析器

注意：各字段的含义可参考网站https://stackoverflow.com/questions/9234699/understanding-apaches-access-log上的说明。

在log文件中提取一条日志，利用解析器去解析，如图11.4所示。可以看出，解析后的数据为字典结构。

```
sample_string = 'koldunov.net 85.26.235.202 - - [16/Mar/2013:00:19:43 +0400] "GET /?p=364 HTTP/1.0" 200 65237 "http://koldunov.net/?p=364" "Moz
data = p(sample_string)
data
```

```
{'remote_host': '85.26.235.202',
 'remote_logname': '-',
 'remote_user': '-',
 'request_first_line': 'GET /?p=364 HTTP/1.0',
 'request_header_referer': 'http://koldunov.net/?p=364',
 'request_header_user_agent': 'Mozilla/5.0 (Windows NT 5.1) AppleWebKit/537.11 (KHTML, like Gecko) Chrome/23.0.1271.64 Safari/537.11',
 'request_header_user_agent__browser__family': 'Chrome',
 'request_header_user_agent__browser__version_string': '23.0.1271',
 'request_header_user_agent__is_mobile': False,
 'request_header_user_agent__os__family': 'Windows',
 'request_header_user_agent__os__version_string': 'XP',
 'request_http_ver': '1.0',
 'request_method': 'GET',
 'request_url': '/?p=364',
 'request_url_fragment': '',
 'request_url_hostname': None,
 'request_url_netloc': '',
 'request_url_password': None,
 'request_url_path': '/',
 'request_url_port': None,
 'request_url_query': 'p=364',
 'request_url_query_dict': {'p': ['364']},
 'request_url_query_list': [('p', '364')],
 'request_url_query_simple_dict': {'p': '364'},
 'request_url_scheme': '',
 'request_url_username': None,
```

图11.4　解析日志示例

通过以下代码读取log文件，逐行进行读取并解析为字典，然后将字典传入列表中，以此构造DataFrame，如图11.5所示。这里提取感兴趣的几个字段，status为状态码，response_bytes_clf为返回的字节数（流量），remote_host为远端主机IP地址，request_first_line为请求内容，time_received为时间数据。

```
datas = open(r'H:\python数据分析\数据\apache_access_log').readlines()
log_list = []
for line in datas:
    data = p(line)
    data['time_received'] = data['time_received'][1:12]+' '+data['time_
    received'][13:21]+' '+data['time_received'][22:27]                #时间数据整理
    log_list.append(data)                                                    #传入列表

log = pd.DataFrame(log_list)                                                 #构造DataFrame
log = log[['status','response_bytes_clf','remote_host','request_first_
line','time_received']]                                                      #提取感兴趣的字段
log.head()
```

	status	response_bytes_clf	remote_host	request_first_line	time_received
0	200	26126	109.165.31.156	GET /index.php?option=com_content&task=section...	16/Mar/2013 08:00:25 +0400
1	200	10532	109.165.31.156	GET /templates/ja_procyon/css/template_css.css...	16/Mar/2013 08:00:25 +0400
2	200	1853	109.165.31.156	GET /templates/ja_procyon/switcher.js HTTP/1.0	16/Mar/2013 08:00:25 +0400
3	200	37153	109.165.31.156	GET /includes/js/overlib_mini.js HTTP/1.0	16/Mar/2013 08:00:25 +0400
4	200	3978	109.165.31.156	GET /modules/ja_transmenu/transmenuh.css HTTP/1.0	16/Mar/2013 08:00:25 +0400

图11.5　日志解析数据

11.1.2　日志数据清洗

首先查看各字段是否有缺失值，如图11.6所示。可以看出，各字段中没有缺失值。

```
log.isnull().sum()
```

```
status                0
response_bytes_clf    0
remote_host           0
request_first_line    0
time_received         0
dtype: int64
```

图11.6　查看缺失值

然后把time_received字段转换为时间数据类型，并设置为索引，如图11.7所示。

```
log['time_received'] = pd.to_datetime(log['time_received'])
log = log.set_index('time_received')
log.head()
```

time_received	status	response_bytes_clf	remote_host	request_first_line
2013-03-16 04:00:25	200	26126	109.165.31.156	GET /index.php?option=com_content&task=section...
2013-03-16 04:00:25	200	10532	109.165.31.156	GET /templates/ja_procyon/css/template_css.css...
2013-03-16 04:00:25	200	1853	109.165.31.156	GET /templates/ja_procyon/switcher.js HTTP/1.0
2013-03-16 04:00:25	200	37153	109.165.31.156	GET /includes/js/overlib_mini.js HTTP/1.0
2013-03-16 04:00:25	200	3978	109.165.31.156	GET /modules/ja_transmenu/transmenuh.css HTTP/1.0

图11.7　转换为datetime类数据

接着查看各字段数据类型，将status字段转换为int类型，如图11.8所示。

```
log.dtypes
```

```
status                 object
response_bytes_clf     object
remote_host            object
request_first_line     object
dtype: object
```

```
log['status'] = log['status'].astype('int')
```

图11.8　转换类型

此时在对response_bytes_clf字段进行转换的过程中报错，查找原因发现其中含有“-”字符数据，如图11.9所示。

```
log[log['response_bytes_clf'] == '-'].head()
```

time_received	status	response_bytes_clf	remote_host	request_first_line
2013-03-16 04:19:41	304	-	178.154.206.250	GET /images/stories/researchers/laplace.jpg HT...
2013-03-16 04:33:14	304	-	178.154.206.250	GET /images/stories/researchers/treshnikov.jpg...
2013-03-16 04:42:43	304	-	178.154.206.250	GET /mypict/moc2.png HTTP/1.0
2013-03-16 04:47:04	302	-	176.8.91.244	POST /podcast/wp-comments-post.php HTTP/1.0
2013-03-16 05:14:31	304	-	178.154.206.250	GET /mypict/liza2_4_converted.jpg HTTP/1.0

图11.9　字符数据

这里定义转换函数，当为“-”字符时，将其替换为空值，并将字节数据转换为M数据，如图11.10所示。

```
def dash2nan(x):
    if x == '-':
        x = np.nan
    else:
        x = float(x)/1048576
    return x

log['response_bytes_clf'] = log['response_bytes_clf'].map(dash2nan)
log.head()
```

time_received	status	response_bytes_clf	remote_host	request_first_line
2013-03-16 04:00:25	200	2.376146e-08	109.165.31.156	GET /index.php?option=com_content&task=section...
2013-03-16 04:00:25	200	9.578798e-09	109.165.31.156	GET /templates/ja_procyon/css/template_css.css...
2013-03-16 04:00:25	200	1.685294e-09	109.165.31.156	GET /templates/ja_procyon/switcher.js HTTP/1.0
2013-03-16 04:00:25	200	3.379046e-08	109.165.31.156	GET /includes/js/overlib_mini.js HTTP/1.0
2013-03-16 04:00:25	200	3.617970e-09	109.165.31.156	GET /modules/ja_transmenu/transmenuh.css HTTP/1.0

图11.10　转换数据

11.2　日志数据分析

本节将利用时间序列绘图技术和pandas可视化技术，来可视化分析网站流量、网站的状态码和IP地址信息。

11.2.1　网站流量分析

首先对流量字段进行可视化，如图11.11所示。可以看出，流量起伏不大，但有一个极大峰值超过了20MB。

```
log['response_bytes_clf'].plot()
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x9a3b278>
```

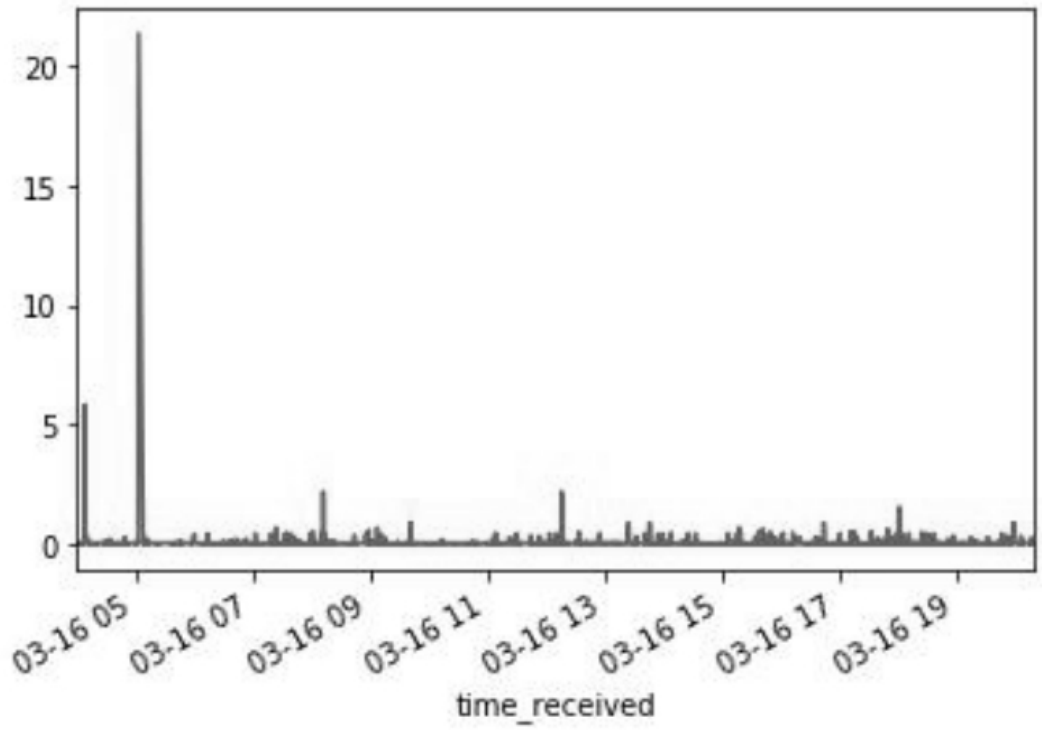

图11.11　流量分析

这个流量峰值是怎样造成的？是网络攻击吗？找到该条数据发现是用户下载了一个PDF文件，因此导致流量很大，如图11.12所示。

```
log[log['response_bytes_clf']>20]
```

time_received	status	response_bytes_clf	remote_host	request_first_line
2013-03-16 05:02:59	200	21.365701	77.50.248.20	GET /books/Bondarenko.pdf HTTP/1.0

图11.12　查看流量峰值

然后对时间进行重采样（30min）并继续计数，可以看出每个时间段访问的次数。如图11.13所示，在早上8点的访问次数最多，其余时间处于上下波动中。

```
t_log = log['response_bytes_clf'].resample('30t').count()
t_log.plot()
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xc7e03c8>
```

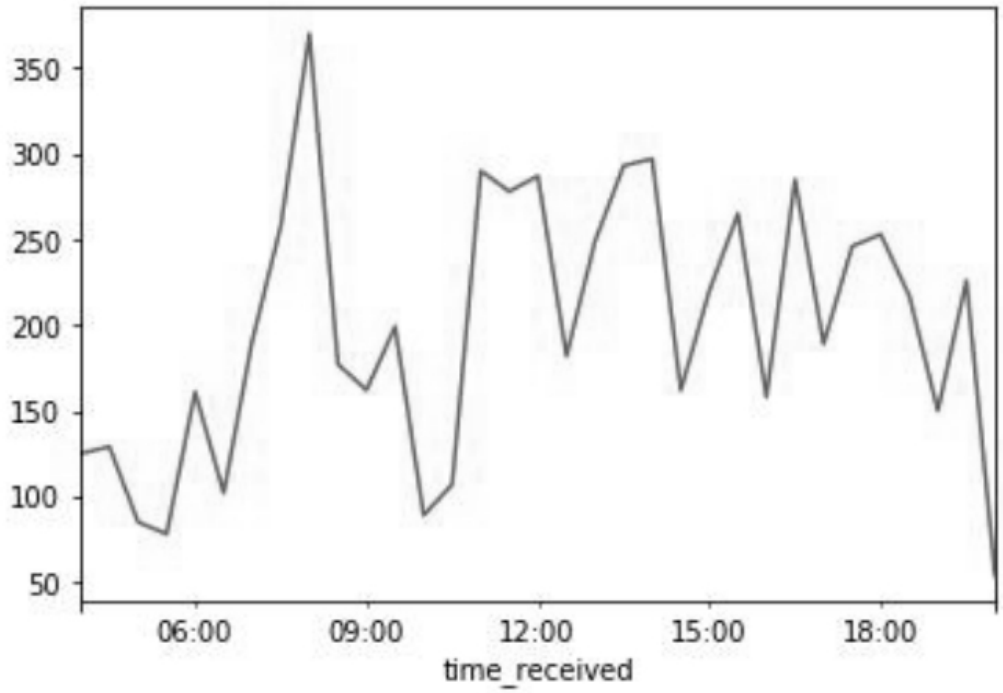

图11.13　访问次数分布1

当继续转换频率到低频率时，上下波动就不明显了，如图11.14所示。

```
h_log = log['response_bytes_clf'].resample('H').count()
h_log.plot()
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xb43aef0>
```

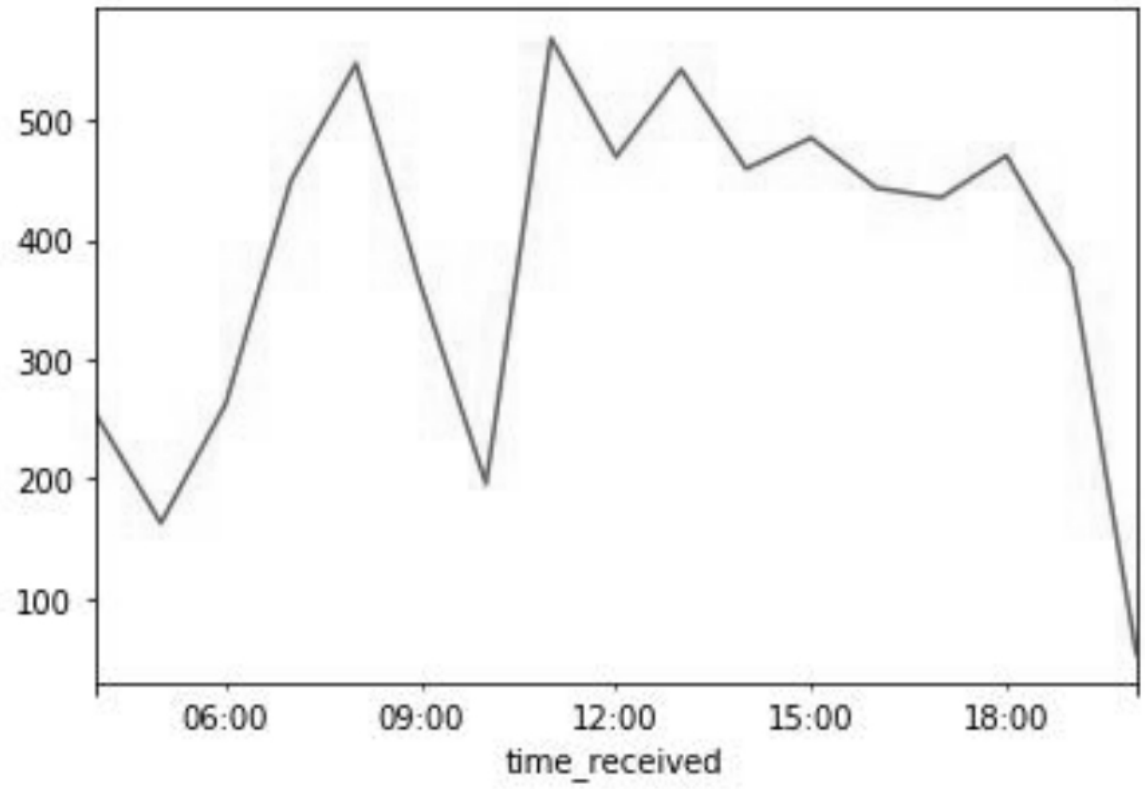

图11.14　访问次数分布2

这里构造访问次数和访问流量的DataFrame，以分析它们之间的关联，如图11.15所示。

```
d_log = pd.DataFrame({'count':log['response_bytes_clf'].resample('10t').count(),
                      'sum':log['response_bytes_clf'].resample('10t').sum()})
d_log.head()
```

time_received	count	sum
2013-03-16 04:00:00	59	6.957677
2013-03-16 04:10:00	35	0.929472
2013-03-16 04:20:00	31	0.771323
2013-03-16 04:30:00	35	0.771191
2013-03-16 04:40:00	38	0.943575

图11.15　构造DataFrame

通过以下代码绘制折线图，效果如图11.16所示。由图可以看出，访问次数与流量具有相关性。

```
plt.figure(figsize=(10,6))                                    #设置图表大小
ax1 = plt.subplot(111)                                          #一个subplot
ax2 = ax1.twinx()                                               #公用x轴
ax1.plot(d_log['count'],color='r',label='count')
```

```
ax1.legend(loc=2)
ax2.plot(d_log['sum'],label='sum')
ax2.legend(loc=0)
```

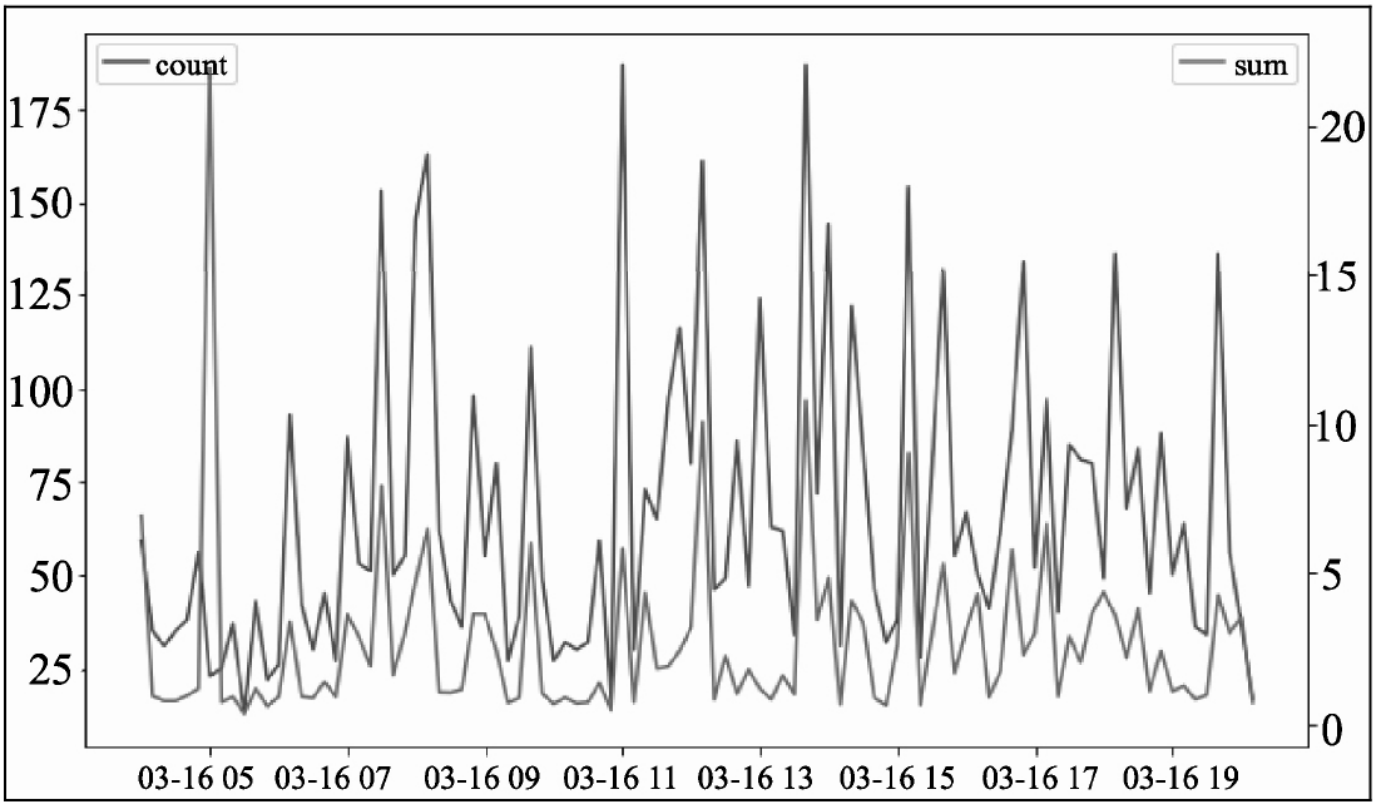

图11.16　流量与访问次数分布图

对于相关性大小，可以通过求相关系数来计算，如图11.17所示。

```
d_log.corr()
```

	count	sum
count	1.000000	0.512629
sum	0.512629	1.000000

图11.17　相关系数

11.2.2　状态码分析

首先对状态码进行分组统计，如图11.18所示。

```
status_log = log.groupby('status')['remote_host'].count()
status_log
```

```
status
200    5606
206      11
301     629
302       6
304      75
400       1
403     247
404      59
Name: remote_host, dtype: int64
```

图11.18　状态码分组统计

然后对状态码数据进行可视化，效果如图11.19所示，可以看出正常访问的状态是最多的。

```
status_log.plot(kind='bar')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xc868f98>
```

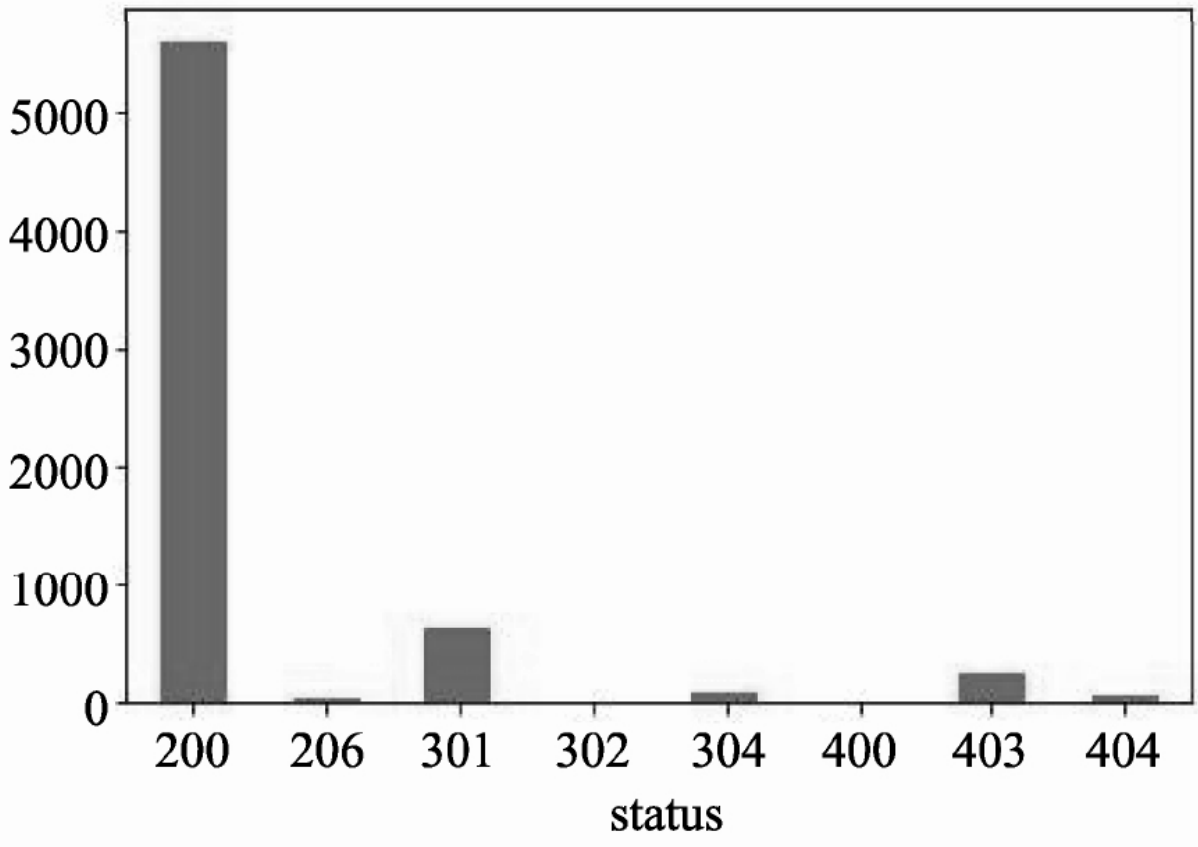

图11.19　状态码可视化

接着对404、403和200状态码进行时间序列分析，通过以下代码构造DataFrame，如图11.20所示。

```
log_404 = log['status'][log['status'] == 404].resample('2H').count()
log_403 = log['status'][log['status'] == 403].resample('2H').count()
log_200 = log['status'][log['status'] == 200].resample('2H').count()

new_log = pd.DataFrame({'Not Found':log_404, 'Forbidden':log_403,
'Success':log_200})  #构造DataFrame
new_log
```

time_received	Forbidden	Not Found	Success
2013-03-16 04:00:00	22	3	375
2013-03-16 06:00:00	26	2	607
2013-03-16 08:00:00	45	2	780
2013-03-16 10:00:00	29	4	699
2013-03-16 12:00:00	27	5	886
2013-03-16 14:00:00	42	21	785
2013-03-16 16:00:00	16	14	757
2013-03-16 18:00:00	38	6	669
2013-03-16 20:00:00	2	2	48

图11.20　构造DataFrame

说明：图11.20中，Forbidden字段对应的状态码为404；Not Found字段对应的状态码为403；Success字段对应的状态码为200。

然后将这些数据进行可视化，代码和效果如图11.21所示。

```
new_log.plot(figsize=(10, 3))
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xcaa8b70>
```

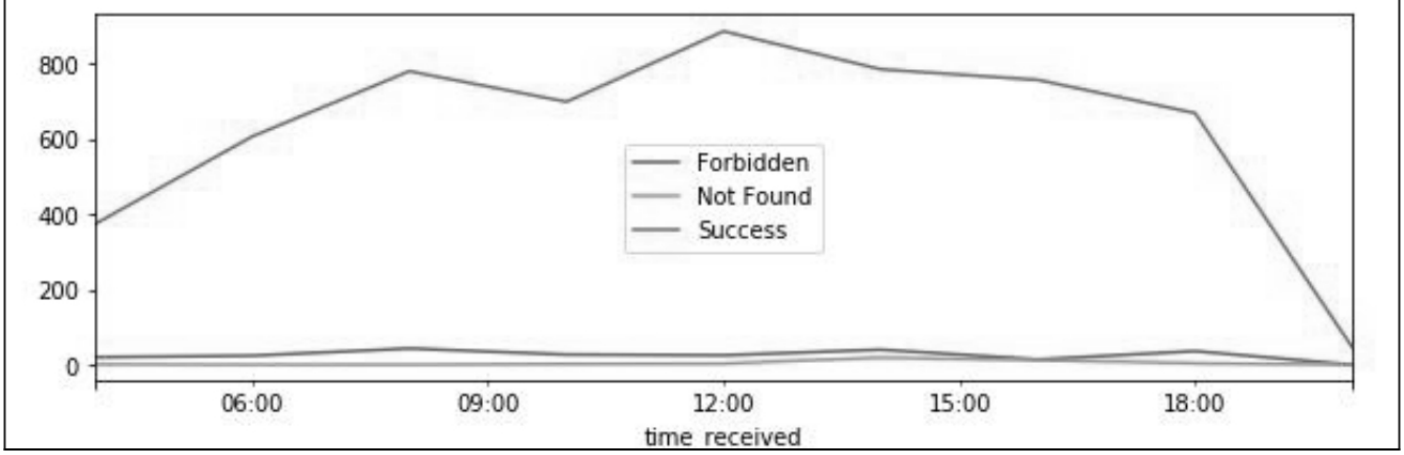

图11.21　状态码时间序列

也可以通过这些数据来绘制堆积柱状图，如图11.22所示。

```
new_log.plot(kind='barh', stacked=True, figsize=(10, 7))
```

```
<matplotlib.axes._subplots.AxesSubplot at 0xcb2f5c0>
```

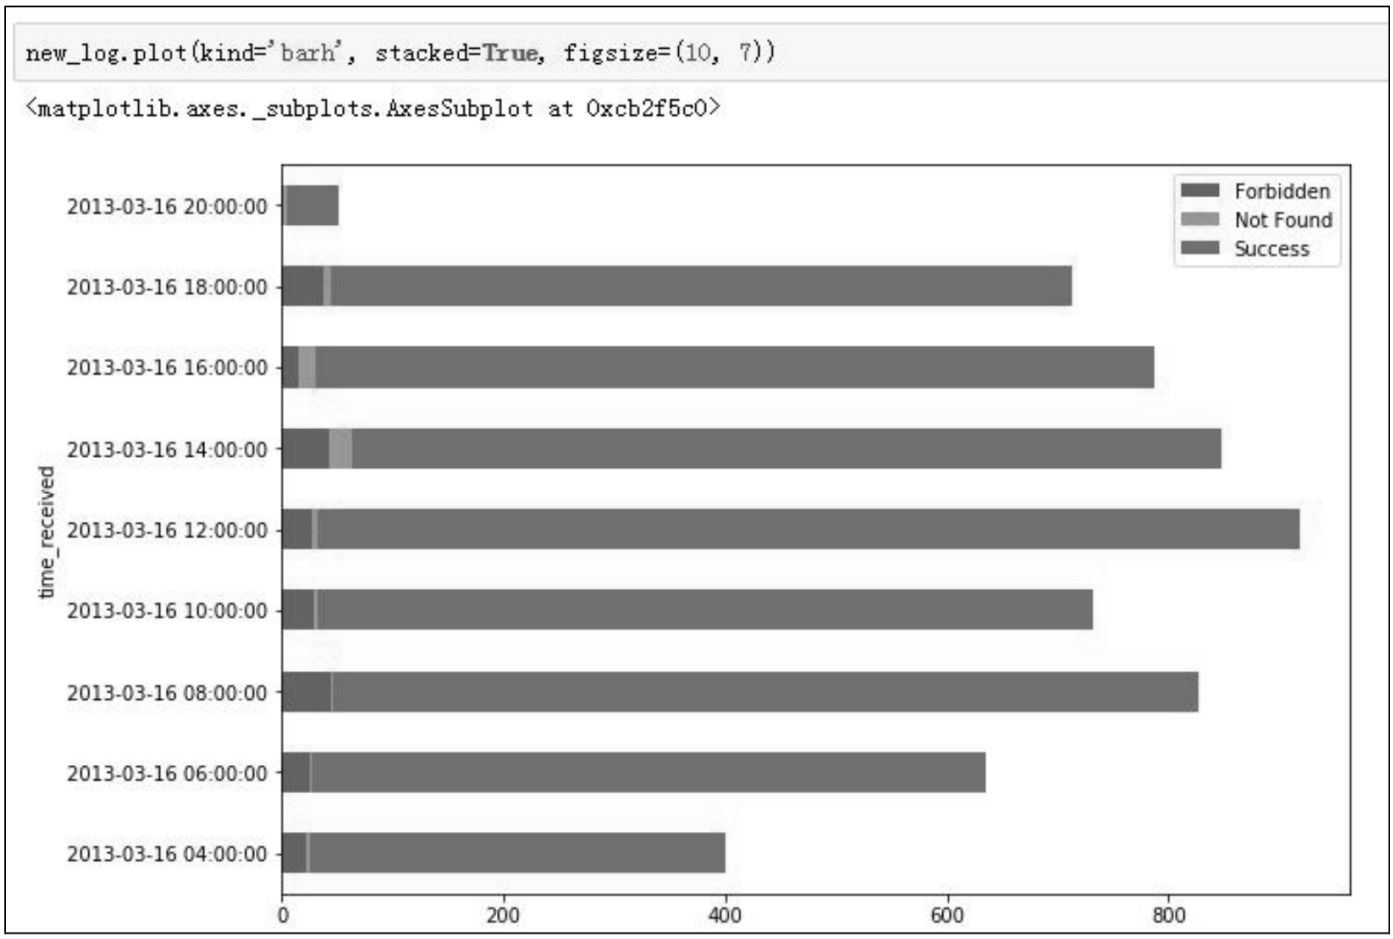

图11.22　堆积柱状图

11.2.3　IP地址分析

首先对remote_host字段进行计数，筛选前10位的IP进行绘图，效果如图11.23所示。代码如下：

```
ip_count = log['remote_host'].value_counts()[0:10]
ip_count.plot(kind='barh')
```

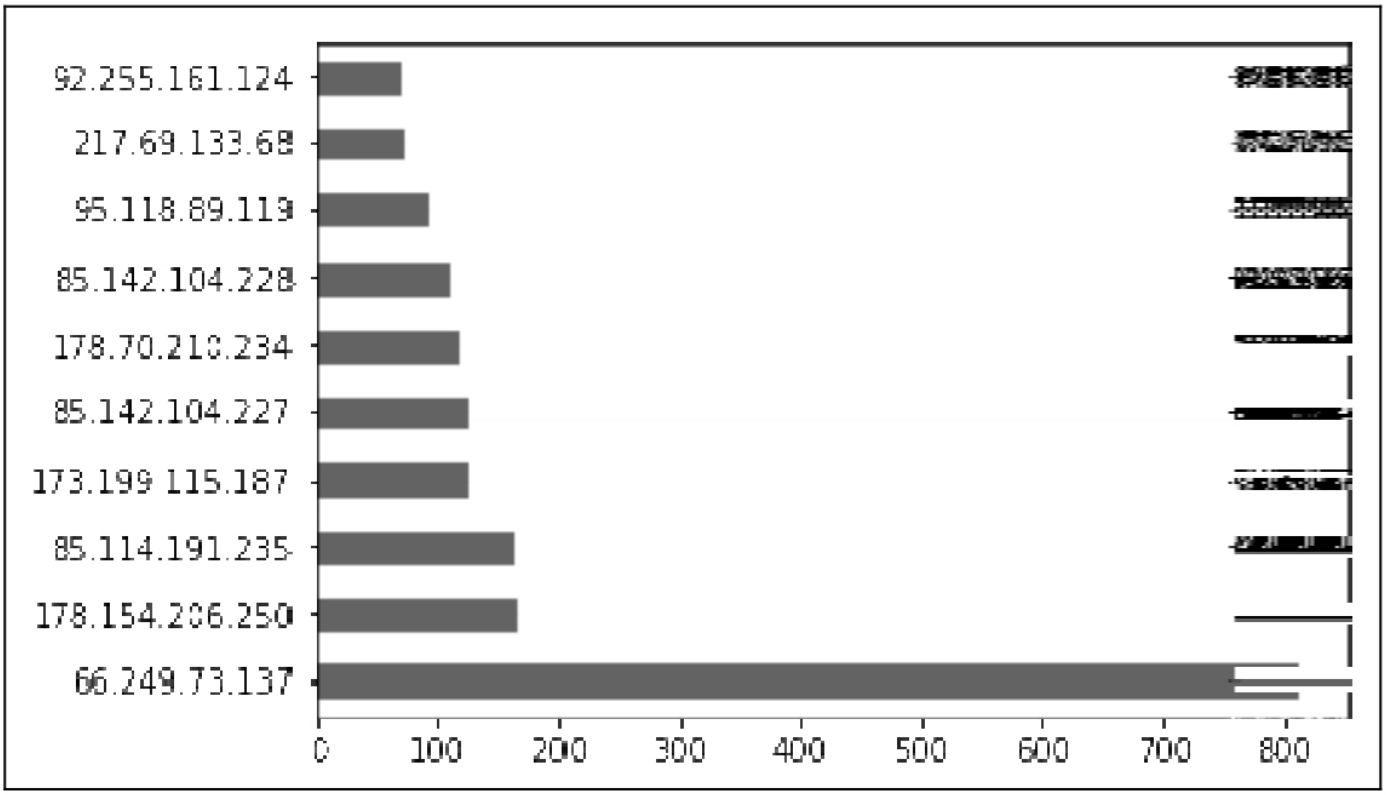

图11.23　IP前10位

pygeoip库可以将IP地址解析为地理数据，通过PIP进行安装，如图11.24所示。与此同时，需在该网站上（https://dev.maxmind.com/geoip/legacy/geolite/）下载DAT文件才可以解析IP地址，如图11.25所示。

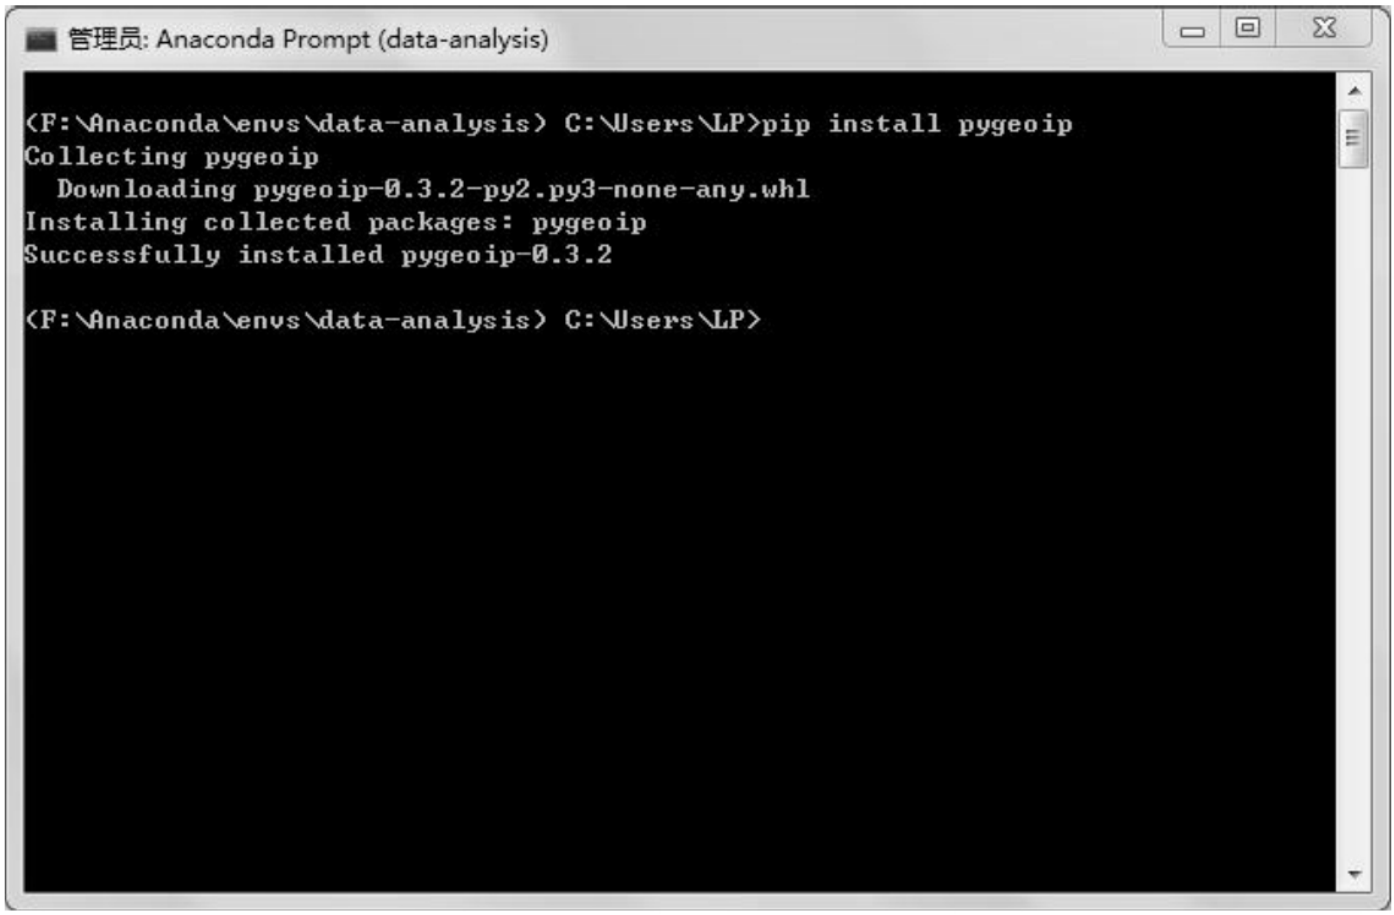

图11.24　pygeoip库安装

Downloads

	Download links				
Database	**Binary / gzip**	**Binary / xz**	**CSV / gzip**	**CSV / zip**	**CSV / xz**
GeoLite Country	Download	Gzip only	Zip only	Download	Zip only
GeoLite Country IPv6	Download	Gzip only	Download	Gzip only	Gzip only
GeoLite City	Download	Download	Zip and xz only	Download	Download
GeoLite City IPv6 (Beta)	Download	Gzip only	Download	Gzip only	Gzip only
GeoLite ASN	Download	Gzip only	Zip only	Download	Zip only
GeoLite ASN IPv6	Download	Gzip only	Zip only	Download	Zip only

The GeoLite Legacy databases may also be downloaded and updated with our GeoIP Update program.

图11.25　DAT文件下载

通过以下代码可以轻松解析IP地址，如图11.26所示。

```
import pygeoip
gi = pygeoip.GeoIP(r'H:\python数据分析\数据\GeoLiteCity.dat', pygeoip.MEMORY_CACHE)
info = gi.record_by_addr('64.233.161.99')
info
```

```
{'area_code': 650,
 'city': 'Mountain View',
 'continent': 'NA',
 'country_code': 'US',
 'country_code3': 'USA',
 'country_name': 'United States',
 'dma_code': 807,
 'latitude': 37.41919999999999,
 'longitude': -122.0574,
 'metro_code': 'San Francisco, CA',
 'postal_code': '94043',
 'region_code': 'CA',
 'time_zone': 'America/Los_Angeles'}
```

图11.26　解析IP地址

然后通过IP地址进行分组统计，结果如图11.27所示。代码如下：

```
ips = log.groupby('remote_host')['status'].agg(['count'])
ips.head()
```

remote_host	count
100.44.124.8	26
108.171.252.242	24
109.165.31.156	12
109.171.109.164	4
109.191.82.110	14

图11.27　分组统计

通过以下代码将IP解析的国家和经纬度写入DataFrame中，如图11.28所示。

```
ips['country'] = [gi.record_by_addr(i)['country_code3'] for i in ips.
index]
ips['latitude'] = [gi.record_by_addr(i)['latitude'] for i in ips.index]
ips['longitude'] = [gi.record_by_addr(i)['longitude'] for i in ips.index]

ips.head()
```

remote_host	count	country	latitude	longitude
100.44.124.8	26	USA	37.7510	-97.8220
108.171.252.242	24	USA	34.0115	-117.8535
109.165.31.156	12	RUS	47.2364	39.7139
109.171.109.164	4	RUS	55.0415	82.9346
109.191.82.110	14	RUS	55.1544	61.4297

图11.28　IP地址数据

最后对country字段进行分组统计，筛选出前10位的国家或地区进行绘图，如图11.29所示。可以看出，俄罗斯的访问量是最多的，由此可以推断出该网站来源于俄罗斯。

```
country = ips.groupby('country')['count'].sum()
country = country.sort_values(ascending=False)[0:10]
```

```
country.plot(kind='bar')
```

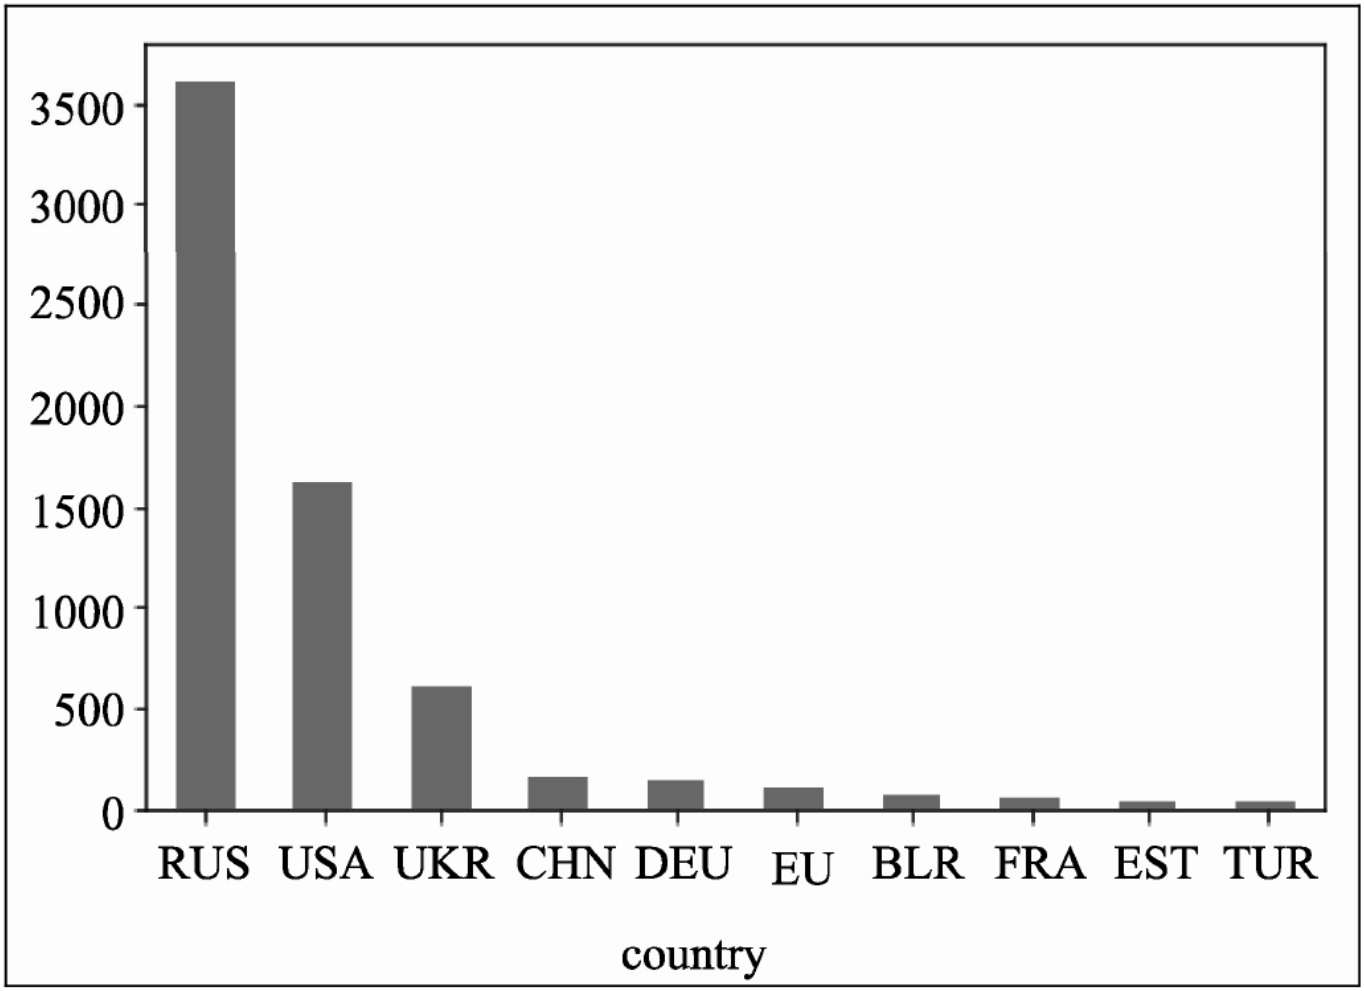

图11.29　全球IP地址分布图